บทที่ 2 · การประเมินผลระบบผู้แนะนำ (Recommender System Evaluation)

ข้อมูลโจทย์และใบงาน — เปรียบเทียบ Model X กับ Model Y ที่ K = 5

ชุดข้อมูลตั้งต้น เงื่อนไขที่ประกาศ และใบงานสำหรับคำนวณตัวชี้วัดแปดตัวด้วยมือ · ไม่มีเฉลยในไฟล์นี้

ค่าตัด K = 5 | Ground Truth 6 รายการ/ผู้ใช้ | Candidate Set 12 รายการ | ผู้ใช้ 3 คน: ชาคร · อสมา · ปานระวี | rel ∈ {0,1} และภาคขยาย 0–3

1. เงื่อนไขที่ประกาศไว้ (Protocol)

สิ่งที่ต้องประกาศ	ค่าที่ใช้
ค่าตัด K	K = 5 (ระบบแสดงผลเพียง 5 อันดับแรก)
Candidate Set	12 รายการ (i1–i12) เท่ากันทุกผู้ใช้และทุกโมเดล
Ground Truth	6 รายการต่อผู้ใช้ $\|\mathcal{R}_u\| = 6 > K = 5$
ฟังก์ชันผลได้ (Gain)	ตอนที่ 1–7: gain(rel) = rel, rel ∈ {0,1} · ตอนที่ 8: gain(rel) = 2^rel - 1, rel ∈ {0,1,2,3}
ฟังก์ชันส่วนลด (Discount)	$1 / \log_2(i + 1)$
ตัวส่วนของ AP@K	$\min(K, \|\mathcal{R}_u\|) = \min(5, 6) = 5$
การเฉลี่ยข้ามผู้ใช้	Macro-average (ถ่วงน้ำหนักผู้ใช้เท่ากัน)

จุดที่ต่างจากตัวอย่างในบทเรียน — บทที่ 2 ใช้ K = 10 กับ Ground Truth 3 รายการ ($|\mathcal{R}_u| < K$) แต่ชุดนี้กลับด้าน คือ $|\mathcal{R}_u| = 6 > K = 5$ ผลคือ **Recall@5 ไม่มีทางเท่ากับ 1.0000** (เพดานคือ 5/6 = 0.8333) ขณะที่ **Precision@5 มีโอกาสเท่ากับ 1.0000** ได้

2. สูตรที่ใช้

Precision@K — ในของที่แนะนำ K ชิ้น ถูกใจกี่ส่วน

$$\text{Precision@K} = |\mathcal{L}_u^K \cap \mathcal{R}_u| / K$$

Recall@K — ในของที่ชอบทั้งหมด แนะนำได้กี่ส่วน

$$\text{Recall@K} = |\mathcal{L}_u^K \cap \mathcal{R}_u| / |\mathcal{R}_u|$$

F1@K — ค่าเฉลี่ยฮาร์มอนิก

$$F1@K = 2 \cdot P \cdot R / (P + R)$$

HR@K — โดนอย่างน้อยหนึ่งชิ้นหรือไม่

$$\text{HR@K} = 1 \text{ ถ้า } |\mathcal{L}_u^K \cap \mathcal{R}_u| \geq 1 \text{ มิฉะนั้น } 0$$

RR / MRR — ตำแหน่งของรายการถูกต้องชิ้นแรก

$$RR = 1 / \text{rank(ชิ้นแรก)} \cdot MRR = (1/|U|) \sum RR$$

AP@K / MAP@K — รายการถูกต้องทุกชิ้นอยู่ต้นเพียงใด

$$AP@K = [\sum \text{Precision@i} \cdot \text{rel(i)}] / \min(K, |\mathcal{R}_u|)$$

nDCG@K — ใกล้ลำดับอุดมคติเพียงใด

$$DCG@K = \sum \text{gain}(rel_i)/\log_2(i+1) \cdot nDCG = DCG/IDCG$$

AUC — นับคู่ที่เรียงถูกทั้ง Candidate Set

$$AUC = (\#\text{คู่ที่เรียงถูก}) / (|\mathcal{R}_u| \times |\mathcal{N}_u|)$$

3. ข้อมูลตั้งต้น

Candidate Set = {i1, i2, i3, i4, i5, i6, i7, i8, i9, i10, i11, i12} รวม 12 รายการ · **เส้นทึบหนา** คือขอบเขต Top-5 ที่ผู้ใช้มองเห็นจริง · **ช่องเขียว ✓** คือรายการที่อยู่ใน Ground Truth

ผู้ใช้ U1 — ชาคร

Ground Truth ($\mathcal{R}_u$) = {i1, i2, i4, i7, i9, i11} $|\mathcal{R}_u| = 6$ · รายการไม่เกี่ยวข้อง ($\mathcal{N}_u$) = 6 รายการ

อันดับ	1	2	3	4	5	6	7	8	9	10	11	12
Model X	i1 ✓	i2 ✓	i5	i4 ✓	i8	i7 ✓	i3	i9 ✓	i6	i10	i11 ✓	i12
Model Y	i5	i8	i1 ✓	i2 ✓	i4 ✓	i3	i7 ✓	i6	i9 ✓	i10	i12	i11 ✓

ผู้ใช้ U2 — อสมา

Ground Truth ($\mathcal{R}_u$) = {i2, i3, i5, i8, i10, i12} $|\mathcal{R}_u| = 6$ · รายการไม่เกี่ยวข้อง ($\mathcal{N}_u$) = 6 รายการ

อันดับ	1	2	3	4	5	6	7	8	9	10	11	12
Model X	i2 ✓	i1	i3 ✓	i6	i5 ✓	i4	i8 ✓	i7	i10 ✓	i12 ✓	i9	i11
Model Y	i1	i2 ✓	i6	i3 ✓	i5 ✓	i8 ✓	i4	i7	i9	i10 ✓	i12 ✓	i11

ผู้ใช้ U3 — ปานระวี

Ground Truth ($\mathcal{R}_u$) = {i1, i4, i6, i7, i9, i10} $|\mathcal{R}_u| = 6$ · รายการไม่เกี่ยวข้อง ($\mathcal{N}_u$) = 6 รายการ

อันดับ	1	2	3	4	5	6	7	8	9	10	11	12
Model X	i2	i1 ✓	i4 ✓	i6 ✓	i3	i7 ✓	i5	i9 ✓	i8	i12	i10 ✓	i11
Model Y	i2	i3	i1 ✓	i4 ✓	i6 ✓	i5	i8	i7 ✓	i9 ✓	i11	i12	i10 ✓

เงื่อนไขสำคัญที่ต้องสังเกต: ทั้ง Model X และ Model Y มีรายการถูกต้องอยู่ใน Top-5 จำนวนเท่ากันพอดี (3 ชิ้น) ในผู้ใช้ทุกคน ต่างกันเพียง “ตำแหน่ง” ที่วางเท่านั้น

4. ใบงาน — กรอกคำตอบลงในช่องว่าง

ตอนที่ 1 · ตัวชี้วัดเชิงกลุ่ม (อ่านเฉพาะห้าอันดับแรก)

ผู้ใช้	โมเดล	จำนวน hit ใน Top-5	Precision@5	Recall@5	F1@5	HR@5
U1 — ชาคร	Model X					
	Model Y					
U2 — อสมา	Model X					
	Model Y					
U3 — ปานระวี	Model X					
	Model Y					
ค่าเฉลี่ยของ Model X		—				
ค่าเฉลี่ยของ Model Y		—				

ตอนที่ 2 · RR และ MRR

ผู้ใช้	โมเดล	อันดับของรายการถูกต้องชิ้นแรก	RR
U1 — ชาคร	Model X		
	Model Y		
U2 — อสมา	Model X		
	Model Y		
U3 — ปานระวี	Model X		
	Model Y		
MRR ของ Model X			
MRR ของ Model Y			

ตอนที่ 3 · AP@5 และ MAP@5

ตัวส่วน min(K, $|\mathcal{R}_u|$) = min(5, 6) = _____

ผู้ใช้	โมเดล	ตำแหน่ง i ที่ rel = 1 (ใน Top-5)	Precision@i แต่ละจุด	AP@5
U1 — ชาคร	Model X			
	Model Y			
U2 — อสมา	Model X			
	Model Y			
U3 — ปานระวี	Model X			
	Model Y			
MAP@5 ของ Model X				
MAP@5 ของ Model Y				

ตอนที่ 4 · nDCG@5

ตำแหน่ง i	1	2	3	4	5
ส่วนลด $1/\log_2(i+1)$					

IDCG@5 (ลำดับอุดมคติ เต็มทั้งห้าช่องเพราะ $|\mathcal{R}_u| = 6 \geq K$) = _____

ผู้ใช้	โมเดล	ตำแหน่งที่พบใน Top-5	DCG@5	nDCG@5
U1 — ชาคร	Model X	1, 2, 4		
	Model Y	3, 4, 5		
U2 — อสมา	Model X	1, 3, 5		
	Model Y	2, 4, 5		
U3 — ปานระวี	Model X	2, 3, 4		
	Model Y	3, 4, 5		
nDCG@5 เฉลี่ยของ Model X			—	
nDCG@5 เฉลี่ยของ Model Y			—	

ตอนที่ 5 · AUC (นับคู่ทีละคู่บน Candidate Set ทั้ง 12 รายการ)

$|\mathcal{R}_u|$ = _____ · $|\mathcal{N}_u|$ = _____ · จำนวนคู่ทั้งหมด = _____ คู่

ผู้ใช้	โมเดล	ตำแหน่งของรายการเกี่ยวข้องทั้ง 6 ชิ้น	จำนวนคู่ที่เรียงถูก	AUC
U1 — ชาคร	Model X	1, 2, 4, 6, 8, 11		
	Model Y	3, 4, 5, 7, 9, 12		
U2 — อสมา	Model X	1, 3, 5, 7, 9, 10		
	Model Y	2, 4, 5, 6, 10, 11		
U3 — ปานระวี	Model X	2, 3, 4, 6, 8, 11		
	Model Y	3, 4, 5, 8, 9, 12		
AUC เฉลี่ยของ Model X			—	
AUC เฉลี่ยของ Model Y			—	

ตอนที่ 6 · ตารางสรุปตัวชี้วัดทั้งแปดตัว

ตัวชี้วัด	Model X	Model Y	ผลต่าง (X - Y)	อัตราส่วน X/Y	แยกความต่างได้หรือไม่
Precision@5					
Recall@5					
F1@5					
HR@5					
MRR					
MAP@5					
nDCG@5					
AUC					

ตอนที่ 8 · ภาคขยาย — ความเกี่ยวข้องหลายระดับ (เฉพาะผู้ใช้ U1 — ชาคร)

ประกาศ gain(rel) = 2^rel - 1 · ส่วนลดเดิม 1 / $\log_2(i + 1)$

รายการใน $\mathcal{R}_u$	i1	i2	i4	i7	i9	i11
rel	1	3	2	3	1	2
gain = 2^rel - 1	1	7	3	7	1	3

ตำแหน่ง i (Model X)	1	2	3	4	5	รวม
รายการ	i1	i2	i5	i4	i8	–
rel	1	3	0	2	0	–
gain × ส่วนลด						

ตำแหน่ง i (Model Y)	1	2	3	4	5	รวม
รายการ	i5	i8	i1	i2	i4	–
rel	0	0	1	3	2	–
gain × ส่วนลด						

IDCG@5 (rel อุดมคติ = 3, 3, 2, 2, 1) = _____

โมเดล	DCG@5 (หลายระดับ)	nDCG@5 (หลายระดับ)	nDCG@5 (ทวิภาค จากตอนที่ 4)
Model X			
Model Y			

5. คำถามอภิปรายผล

ก. คำถามคำนวณสั้น

คำถาม	คำตอบ
1. เมื่อ K = 5 และ $\|\mathcal{R}_u\| = 6$ ค่า **Recall@5 สูงสุด**ที่เป็นไปได้ในทางทฤษฎีเท่ากับเท่าใด	
2. ในเงื่อนไขเดียวกัน ค่า **Precision@5 สูงสุด**ที่เป็นไปได้เท่ากับเท่าใด	
3. จากตัวชี้วัดทั้ง 8 ตัว มีกี่ตัวที่**แยกความต่าง**ระหว่าง X กับ Y **ไม่ได้**	
4. ตัวชี้วัดใดให้**อัตราส่วน X/Y สูงที่สุด** (ขยายความต่างมากที่สุด)	
5. ถ้าขยายหน้าจอเป็น K = 6 ค่า **Recall@6** ของ U1 / Model X จะเท่ากับเท่าใด	
6. ในเงื่อนไขข้อ 5 ค่า **Precision@6** ของ U1 / Model X จะเท่ากับเท่าใด	
7. ค่า AUC เฉลี่ยของ Model Y ต่ำกว่า 0.5 ควรตีความว่าอย่างไร	
8. Model Y ทำคะแนน RR ได้ดีที่สุดกับผู้ใช้คนใด	

ข. คำถามเขียนอภิปราย

ข้อ 1 · เขียนย่อหน้าสรุปเชิงเปรียบเทียบ 3–5 บรรทัด

ต้องมี: ตัวชี้วัดที่ใช้เป็นหลัก · ตัวเลขของทั้งสองโมเดล · ผลต่างเป็นจุด · อัตราส่วนเป็นเท่า · ประโยคจำกัดขอบเขตการอ้าง

ข้อ 2 · ถ้าระบบจริงแสดงผลเพียง 5 อันดับแรก จะประกาศ Primary Metric ตัวใด และตั้ง Guardrail อะไรบ้าง

ตอบให้ครบสามส่วน: Primary Metric พร้อมเหตุผล · Guardrail พร้อมเกณฑ์ตัวเลข · เหตุผลที่ไม่เลือกตัวอื่น

ข้อ 3 · เหตุใด Precision@5, Recall@5, F1@5 และ HR@5 จึงให้ค่าเท่ากันทั้งสองโมเดล และบทเรียนเชิงวิธีวิทยาคืออะไร

อธิบายกลไก แล้วต่อยอดเป็นข้อสรุปว่าการเลือกตัวชี้วัดส่งผลต่อข้อสรุปอย่างไร

ข้อ 4 · Model Y มี AUC ต่ำกว่า 0.5 ในผู้ใช้บางคน ตีความอย่างไร และเหตุใดจึงไม่ควรพูดว่า “Model X ดีกว่า 35%”

แยกให้ชัดระหว่างความหมายของ AUC กับ “ความแม่นยำ” และระวังการอ้างเปอร์เซ็นต์ข้ามตัวชี้วัด

ข้อ 5 · ข้อจำกัดของการสรุปจากข้อมูลออฟไลน์ชุดนี้ และจะออกแบบขั้นถัดไปอย่างไร

ครอบคลุม: ขนาดตัวอย่างและความไม่แน่นอน · Exposure bias / Pseudo FP-FN · วิธีแบ่งข้อมูล · Sampled Negatives · การยืนยันกับผู้ใช้จริง