บทที่ 2 · การประเมินผลระบบผู้แนะนำ (Recommender System Evaluation)

# เฉลยละเอียดพร้อมวิธีคำนวณ — เปรียบเทียบ Model X กับ Model Y ที่ K = 5

เฉลยทุกช่องพร้อมการแทนค่าทีละขั้น ตารางสรุปตัวชี้วัดแปดตัว และแนวคำตอบข้อเขียนทั้งห้าข้อ · สำหรับผู้สอน

ค่าตัด K = 5 | Ground Truth 6 รายการ/ผู้ใช้ | Candidate Set 12 รายการ | ผู้ใช้ 3 คน: ชาคร · อสมา · ปานระวี | IDCG@5 = 2.9485

## 1. เงื่อนไขที่ประกาศไว้ (Protocol)

| สิ่งที่ต้องประกาศ | ค่าที่ใช้ |
|---|---|
| ค่าตัด K | K = 5 (ระบบแสดงผลเพียง 5 อันดับแรก) |
| Candidate Set | 12 รายการ (i1–i12) เท่ากันทุกผู้ใช้และทุกโมเดล |
| Ground Truth | 6 รายการต่อผู้ใช้ $\|\mathcal{R}_u\| = 6 > K = 5$ |
| ฟังก์ชันผลได้ (Gain) | ตอนที่ 1–7: gain(rel) = rel, rel ∈ {0,1} · ตอนที่ 8: gain(rel) = 2^rel - 1, rel ∈ {0,1,2,3} |
| ฟังก์ชันส่วนลด (Discount) | $1 / \log_2(i + 1)$ |
| ตัวส่วนของ AP@K | $\min(K, \|\mathcal{R}_u\|) = \min(5, 6) = 5$ |
| การเฉลี่ยข้ามผู้ใช้ | Macro-average (ถ่วงน้ำหนักผู้ใช้เท่ากัน) |

**จุดที่ต่างจากตัวอย่างในบทเรียน** — บทที่ 2 ใช้ K = 10 กับ Ground Truth 3 รายการ ($|\mathcal{R}_u| < K$) แต่ชุดนี้กลับด้าน คือ $|\mathcal{R}_u| = 6 > K = 5$ ผลคือ **Recall@5 ไม่มีทางเท่ากับ 1.0000** (เพดานคือ 5/6 = 0.8333) ขณะที่ **Precision@5 มีโอกาสเท่ากับ 1.0000** ได้

## 2. สูตรที่ใช้

Precision@K — ในของที่แนะนำ K ชิ้น ถูกใจกี่ส่วน

$$\text{Precision@K} = |\mathcal{L}_u^K \cap \mathcal{R}_u| / K$$

Recall@K — ในของที่ชอบทั้งหมด แนะนำได้กี่ส่วน

$$\text{Recall@K} = |\mathcal{L}_u^K \cap \mathcal{R}_u| / |\mathcal{R}_u|$$

F1@K — ค่าเฉลี่ยฮาร์มอนิก

$$F1@K = 2 \cdot P \cdot R / (P + R)$$

HR@K — โดนอย่างน้อยหนึ่งชิ้นหรือไม่

$$\text{HR@K} = 1 \text{ ถ้า } |\mathcal{L}_u^K \cap \mathcal{R}_u| \geq 1 \text{ มิฉะนั้น } 0$$

RR / MRR — ตำแหน่งของรายการถูกต้องชิ้นแรก

$$RR = 1 / \text{rank(ชิ้นแรก)} \cdot MRR = (1/|U|) \sum RR$$

AP@K / MAP@K — รายการถูกต้องทุกชิ้นอยู่ต้นเพียงใด

$$AP@K = [\sum \text{Precision@i} \cdot \text{rel(i)}] / \min(K, |\mathcal{R}_u|)$$

nDCG@K — ใกล้ลำดับอุดมคติเพียงใด

$$DCG@K = \sum \text{gain}(rel_i)/\log_2(i+1) \cdot nDCG = DCG/IDCG$$

AUC — นับคู่ที่เรียงถูกทั้ง Candidate Set

$$AUC = (\#\text{คู่เรียงถูก}) / (|\mathcal{R}_u| \times |\mathcal{N}_u|)$$

## 3. ข้อมูลตั้งต้น

**Candidate Set** = {i1, i2, i3, i4, i5, i6, i7, i8, i9, i10, i11, i12} รวม 12 รายการ · **เส้นทึบหนา** คือขอบเขต Top-5 ที่ผู้ใช้มองเห็นจริง · **ช่องเขียว ✓** คือรายการที่อยู่ใน Ground Truth

### ผู้ใช้ U1 — ชาคร

Ground Truth ($\mathcal{R}_u$) = {i1, i2, i4, i7, i9, i11} $|\mathcal{R}_u| = 6$ · รายการไม่เกี่ยวข้อง ($\mathcal{N}_u$) = 6 รายการ

| อันดับ | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Model X | i1 ✓ | i2 ✓ | i5 | i4 ✓ | i8 | i7 ✓ | i3 | i9 ✓ | i6 | i10 | i11 ✓ | i12 |
| Model Y | i5 | i8 | i1 ✓ | i2 ✓ | i4 ✓ | i3 | i7 ✓ | i6 | i9 ✓ | i10 | i12 | i11 ✓ |

### ผู้ใช้ U2 — อสมา

Ground Truth ($\mathcal{R}_u$) = {i2, i3, i5, i8, i10, i12} $|\mathcal{R}_u| = 6$ · รายการไม่เกี่ยวข้อง ($\mathcal{N}_u$) = 6 รายการ

| อันดับ | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Model X | i2 ✓ | i1 | i3 ✓ | i6 | i5 ✓ | i4 | i8 ✓ | i7 | i10 ✓ | i12 ✓ | i9 | i11 |
| Model Y | i1 | i2 ✓ | i6 | i3 ✓ | i5 ✓ | i8 ✓ | i4 | i7 | i9 | i10 ✓ | i12 ✓ | i11 |

### ผู้ใช้ U3 — ปานระวี

Ground Truth ($\mathcal{R}_u$) = {i1, i4, i6, i7, i9, i10} $|\mathcal{R}_u| = 6$ · รายการไม่เกี่ยวข้อง ($\mathcal{N}_u$) = 6 รายการ

| อันดับ | 1 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12 |
|---|---|---|---|---|---|---|---|---|---|---|---|---|
| Model X | i2 | i1 ✓ | i4 ✓ | i6 ✓ | i3 | i7 ✓ | i5 | i9 ✓ | i8 | i12 | i10 ✓ | i11 |
| Model Y | i2 | i3 | i1 ✓ | i4 ✓ | i6 ✓ | i5 | i8 | i7 ✓ | i9 ✓ | i11 | i12 | i10 ✓ |

**เงื่อนไขสำคัญที่ต้องสังเกต:** ทั้ง Model X และ Model Y มีรายการถูกต้องอยู่ใน Top-5 จำนวนเท่ากันพอดี (3 ชิ้น) ในผู้ใช้ทุกคน ต่างกันเพียง “ตำแหน่ง” ที่วางเท่านั้น

## 4. เฉลยพร้อมวิธีคำนวณทีละขั้น

### ตอนที่ 1 · ตัวชี้วัดเชิงกลุ่ม

| ผู้ใช้ | โมเดล | ตำแหน่งที่พบใน Top-5 | hit | Precision@5 | Recall@5 | F1@5 | HR@5 |
|---|---|---|---|---|---|---|---|
| U1 — ชาคร | Model X | 1, 2, 4 | 3 | 0.6000 | 0.5000 | 0.5455 | 1 |
| | Model Y | 3, 4, 5 | 3 | 0.6000 | 0.5000 | 0.5455 | 1 |
| U2 — อสมา | Model X | 1, 3, 5 | 3 | 0.6000 | 0.5000 | 0.5455 | 1 |
| | Model Y | 2, 4, 5 | 3 | 0.6000 | 0.5000 | 0.5455 | 1 |
| U3 — ปานระวี | Model X | 2, 3, 4 | 3 | 0.6000 | 0.5000 | 0.5455 | 1 |
| | Model Y | 3, 4, 5 | 3 | 0.6000 | 0.5000 | 0.5455 | 1 |
| **ค่าเฉลี่ยของ Model X** | | | — | **0.6000** | **0.5000** | **0.5455** | **1.0000** |
| **ค่าเฉลี่ยของ Model Y** | | | — | **0.6000** | **0.5000** | **0.5455** | **1.0000** |

**U1 ชาคร / Model X** — Top-5 คือ i1, i2, i5, i4, i8 พบรายการถูกต้องที่ตำแหน่ง **1, 2, 4** รวม 3 ชิ้น
`Precision@5 = 3/5 = 0.6000 · Recall@5 = 3/6 = 0.5000 · F1@5 = 2(0.6000)(0.5000)/(0.6000+0.5000) = 0.5455 · HR@5 = 1`

**U1 ชาคร / Model Y** — Top-5 คือ i5, i8, i1, i2, i4 พบรายการถูกต้องที่ตำแหน่ง **3, 4, 5** รวม 3 ชิ้น
`Precision@5 = 3/5 = 0.6000 · Recall@5 = 3/6 = 0.5000 · F1@5 = 2(0.6000)(0.5000)/(0.6000+0.5000) = 0.5455 · HR@5 = 1`

**U2 อสมา / Model X** — Top-5 คือ i2, i1, i3, i6, i5 พบรายการถูกต้องที่ตำแหน่ง **1, 3, 5** รวม 3 ชิ้น
`Precision@5 = 3/5 = 0.6000 · Recall@5 = 3/6 = 0.5000 · F1@5 = 2(0.6000)(0.5000)/(0.6000+0.5000) = 0.5455 · HR@5 = 1`

**U2 อสมา / Model Y** — Top-5 คือ i1, i2, i6, i3, i5 พบรายการถูกต้องที่ตำแหน่ง **2, 4, 5** รวม 3 ชิ้น
`Precision@5 = 3/5 = 0.6000 · Recall@5 = 3/6 = 0.5000 · F1@5 = 2(0.6000)(0.5000)/(0.6000+0.5000) = 0.5455 · HR@5 = 1`

**U3 ปานระวี / Model X** — Top-5 คือ i2, i1, i4, i6, i3 พบรายการถูกต้องที่ตำแหน่ง **2, 3, 4** รวม 3 ชิ้น
`Precision@5 = 3/5 = 0.6000 · Recall@5 = 3/6 = 0.5000 · F1@5 = 2(0.6000)(0.5000)/(0.6000+0.5000) = 0.5455 · HR@5 = 1`

**U3 ปานระวี / Model Y** — Top-5 คือ i2, i3, i1, i4, i6 พบรายการถูกต้องที่ตำแหน่ง **3, 4, 5** รวม 3 ชิ้น
`Precision@5 = 3/5 = 0.6000 · Recall@5 = 3/6 = 0.5000 · F1@5 = 2(0.6000)(0.5000)/(0.6000+0.5000) = 0.5455 · HR@5 = 1`

**สิ่งที่ต้องสังเกต:** ทั้งหกแถวให้ค่าชุดเดียวกันหมด แม้ตำแหน่งที่วางจะต่างกันสิ้นเชิง เพราะตัวชี้วัดกลุ่มนี้ตรวจเพียงว่า “อยู่ใน Top-5 หรือไม่” · และเพราะ $|\mathcal{R}_u| = 6 > K = 5$ ค่า Recall@5 จึงถูกจำกัดเพดานไว้ที่ 5/6 = 0.8333 ไม่มีทางถึง 1.0000

## ตอนที่ 2 · RR และ MRR

| ผู้ใช้ | Model X: ตำแหน่งที่พบ → ชิ้นแรก | RR (X) | Model Y: ตำแหน่งที่พบ → ชิ้นแรก | RR (Y) |
|---|---|---|---|---|
| U1 ชาคร | 1, 2, 4 → 1 | `1/1 = 1.0000` | 3, 4, 5 → 3 | `1/3 = 0.3333` |
| U2 อสมา | 1, 3, 5 → 1 | `1/1 = 1.0000` | 2, 4, 5 → 2 | `1/2 = 0.5000` |
| U3 ปานระวี | 2, 3, 4 → 2 | `1/2 = 0.5000` | 3, 4, 5 → 3 | `1/3 = 0.3333` |
| **MRR** | — | **(1.0000 + 1.0000 + 0.5000) / 3 = 0.8333** | — | **(0.3333 + 0.5000 + 0.3333) / 3 = 0.3889** |

> **บทเรียน:** MRR แยกความต่างได้แรงที่สุดในชุดนี้ (2.14 เท่า) เพราะ Model X พาผู้ใช้ไปเจอคำตอบแรก ที่อันดับ 1, 1, 2 ส่วน Model Y ที่อันดับ 3, 2, 3 · จุดอ่อนคือ MRR มองข้ามรายการถูกต้องชิ้นที่สองเป็นต้นไปทั้งหมด

## ตอนที่ 3 · AP@5 และ MAP@5

ตัวส่วน min(K, $|\mathcal{R}_u|$) = min(5, 6) = **5** ทุกแถว

**U1 ชาคร / Model X** — พบที่ตำแหน่ง 1, 2, 4

`Precision@i: 1/1 = 1.0000 · 2/2 = 1.0000 · 3/4 = 0.7500`

`AP@5 = (1.0000 + 1.0000 + 0.7500) / 5 = 2.7500 / 5 =` **`0.5500`**

**U1 ชาคร / Model Y** — พบที่ตำแหน่ง 3, 4, 5

`Precision@i: 1/3 = 0.3333 · 2/4 = 0.5000 · 3/5 = 0.6000`

`AP@5 = (0.3333 + 0.5000 + 0.6000) / 5 = 1.4333 / 5 =` **`0.2867`**

**U2 อสมา / Model X** — พบที่ตำแหน่ง 1, 3, 5

`Precision@i: 1/1 = 1.0000 · 2/3 = 0.6667 · 3/5 = 0.6000`

`AP@5 = (1.0000 + 0.6667 + 0.6000) / 5 = 2.2667 / 5 =` **`0.4533`**

**U2 อสมา / Model Y** — พบที่ตำแหน่ง 2, 4, 5

`Precision@i: 1/2 = 0.5000 · 2/4 = 0.5000 · 3/5 = 0.6000`

`AP@5 = (0.5000 + 0.5000 + 0.6000) / 5 = 1.6000 / 5 =` **`0.3200`**

**U3 ปานระวี / Model X** — พบที่ตำแหน่ง 2, 3, 4

`Precision@i: 1/2 = 0.5000 · 2/3 = 0.6667 · 3/4 = 0.7500`

`AP@5 = (0.5000 + 0.6667 + 0.7500) / 5 = 1.9167 / 5 =` **`0.3833`**

**U3 ปานระวี / Model Y** — พบที่ตำแหน่ง 3, 4, 5

`Precision@i: 1/3 = 0.3333 · 2/4 = 0.5000 · 3/5 = 0.6000`

`AP@5 = (0.3333 + 0.5000 + 0.6000) / 5 = 1.4333 / 5 =` **`0.2867`**

**`MAP@5 (X)`** `= (0.5500 + 0.4533 + 0.3833) / 3 =` **`0.4622`** · **`MAP@5 (Y)`** `= (0.2867 + 0.3200 + 0.2867) / 3 =` **`0.2978`**

> **ข้อสังเกต:** เพราะตัวส่วนถูกตรึงไว้ที่ 5 ทั้งที่เก็บได้จริงเพียง 3 ชิ้น ค่า AP@5 สูงสุดที่แถวใดจะทำได้ในข้อมูลชุดนี้จึงเท่ากับ (1+1+1)/5 = 0.6000 ไม่ใช่ 1.0000

## ตอนที่ 4 · nDCG@5

`ส่วนลด: 1/log₂2 = 1.0000 · 1/log₂3 = 0.6309 · 1/log₂4 = 0.5000 · 1/log₂5 = 0.4307 · 1/log₂6 = 0.3869`

IDCG@5 = 1.0000 + 0.6309 + 0.5000 + 0.4307 + 0.3869 = **2.9485** (เท่ากันทุกผู้ใช้ เพราะ $|\mathcal{R}_u| = 6 \geq K = 5$ เหมือนกันหมด)

**U1 ชาคร / Model X** – ตำแหน่งที่พบ 1, 2, 4
DCG@5 = 1.0000 + 0.6309 + 0.4307 = 2.0616 → nDCG@5 = 2.0616 / 2.9485 = **0.6992**

**U1 ชาคร / Model Y** – ตำแหน่งที่พบ 3, 4, 5
DCG@5 = 0.5000 + 0.4307 + 0.3869 = 1.3175 → nDCG@5 = 1.3175 / 2.9485 = **0.4469**

**U2 อสมา / Model X** – ตำแหน่งที่พบ 1, 3, 5
DCG@5 = 1.0000 + 0.5000 + 0.3869 = 1.8869 → nDCG@5 = 1.8869 / 2.9485 = **0.6399**

**U2 อสมา / Model Y** – ตำแหน่งที่พบ 2, 4, 5
DCG@5 = 0.6309 + 0.4307 + 0.3869 = 1.4485 → nDCG@5 = 1.4485 / 2.9485 = **0.4913**

**U3 ปานระวี / Model X** – ตำแหน่งที่พบ 2, 3, 4
DCG@5 = 0.6309 + 0.5000 + 0.4307 = 1.5616 → nDCG@5 = 1.5616 / 2.9485 = **0.5296**

**U3 ปานระวี / Model Y** – ตำแหน่งที่พบ 3, 4, 5
DCG@5 = 0.5000 + 0.4307 + 0.3869 = 1.3175 → nDCG@5 = 1.3175 / 2.9485 = **0.4469**

**เฉลี่ย X** = (0.6992 + 0.6399 + 0.5296) / 3 = **0.6229** · **เฉลี่ย Y** = (0.4469 + 0.4913 + 0.4469) / 3 = **0.4617**

> **ข้อสังเกต:** U1/Y กับ U3/Y ได้ nDCG เท่ากันพอดี (0.4469) เพราะพบรายการถูกต้องที่ตำแหน่ง 3, 4, 5 เหมือนกัน – nDCG สนใจ “รูปแบบของตำแหน่ง” ไม่ใช่ว่าเป็นรายการชิ้นใด · ค่า nDCG@5 สูงสุดที่ทำได้ในชุดนี้ (พบ 3 ชิ้นที่อันดับ 1, 2, 3) เท่ากับ 0.7227

## ตอนที่ 5 · AUC

$|\mathcal{R}_u| = 6 \cdot |\mathcal{N}_u| = 12 - 6 = 6 \cdot$ จำนวนคู่ทั้งหมด = 6 × 6 = 36 คู่ต่อผู้ใช้

**U1 ชาคร / Model X** – รายการไม่เกี่ยวข้องอยู่ที่ตำแหน่ง 3, 5, 7, 9, 10, 12
ตำแหน่ง 1 → มีของไม่ชอบอยู่ต่ำกว่า 6 ชิ้น · ตำแหน่ง 2 → มีของไม่ชอบอยู่ต่ำกว่า 6 ชิ้น · ตำแหน่ง 4 → มีของไม่ชอบอยู่ต่ำกว่า 5 ชิ้น · ตำแหน่ง 6 → มีของไม่ชอบอยู่ต่ำกว่า 4 ชิ้น · ตำแหน่ง 8 → มีของไม่ชอบอยู่ต่ำกว่า 3 ชิ้น · ตำแหน่ง 11 → มีของไม่ชอบอยู่ต่ำกว่า 1 ชิ้น
รวมคู่ที่ถูก = 6 + 6 + 5 + 4 + 3 + 1 = 25 → AUC = 25/36 = **0.6944**

**U1 ชาคร / Model Y** – รายการไม่เกี่ยวข้องอยู่ที่ตำแหน่ง 1, 2, 6, 8, 10, 11
ตำแหน่ง 3 → มีของไม่ชอบอยู่ต่ำกว่า 4 ชิ้น · ตำแหน่ง 4 → มีของไม่ชอบอยู่ต่ำกว่า 4 ชิ้น · ตำแหน่ง 5 → มีของไม่ชอบอยู่ต่ำกว่า 4 ชิ้น · ตำแหน่ง 7 → มีของไม่ชอบอยู่ต่ำกว่า 3 ชิ้น · ตำแหน่ง 9 → มีของไม่ชอบอยู่ต่ำกว่า 2 ชิ้น · ตำแหน่ง 12 → มีของไม่ชอบอยู่ต่ำกว่า 0 ชิ้น
รวมคู่ที่ถูก = 4 + 4 + 4 + 3 + 2 + 0 = 17 → AUC = 17/36 = **0.4722**

**U2 อสมา / Model X** – รายการไม่เกี่ยวข้องอยู่ที่ตำแหน่ง 2, 4, 6, 8, 11, 12
ตำแหน่ง 1 → มีของไม่ชอบอยู่ต่ำกว่า 6 ชิ้น · ตำแหน่ง 3 → มีของไม่ชอบอยู่ต่ำกว่า 5 ชิ้น · ตำแหน่ง 5 → มีของไม่ชอบอยู่ต่ำกว่า 4 ชิ้น · ตำแหน่ง 7 → มีของไม่ชอบอยู่ต่ำกว่า 3 ชิ้น · ตำแหน่ง 9 → มีของไม่ชอบอยู่ต่ำกว่า 2 ชิ้น · ตำแหน่ง 10 → มีของไม่ชอบอยู่ต่ำกว่า 2 ชิ้น
รวมคู่ที่ถูก = 6 + 5 + 4 + 3 + 2 + 2 = 22 → AUC = 22/36 = **0.6111**

**U2 อสมา / Model Y** – รายการไม่เกี่ยวข้องอยู่ที่ตำแหน่ง 1, 3, 7, 8, 9, 12
ตำแหน่ง 2 → มีของไม่ชอบอยู่ต่ำกว่า 5 ชิ้น · ตำแหน่ง 4 → มีของไม่ชอบอยู่ต่ำกว่า 4 ชิ้น · ตำแหน่ง 5 → มีของไม่ชอบอยู่ต่ำกว่า 4 ชิ้น · ตำแหน่ง 6 → มีของไม่ชอบอยู่ต่ำกว่า 4 ชิ้น · ตำแหน่ง 10 → มีของไม่ชอบอยู่ต่ำกว่า 1 ชิ้น · ตำแหน่ง 11 → มีของไม่ชอบอยู่ต่ำกว่า 1 ชิ้น
รวมคู่ที่ถูก = 5 + 4 + 4 + 4 + 1 + 1 = 19 → AUC = 19/36 = **0.5278**

**U3 ปานระวี / Model X** – รายการไม่เกี่ยวข้องอยู่ที่ตำแหน่ง 1, 5, 7, 9, 10, 12
ตำแหน่ง 2 → มีของไม่ชอบอยู่ต่ำกว่า 5 ชิ้น · ตำแหน่ง 3 → มีของไม่ชอบอยู่ต่ำกว่า 5 ชิ้น · ตำแหน่ง 4 → มีของไม่ชอบอยู่ต่ำ

กว่า 5 ชนิ้ · ตำแหน่ง 6 → มีของไม่ช่อบอยู่ต่ำกว่า 4 ชนิ้ · ตำแหน่ง 8 → มีของไม่ช่อบอยู่ต่ำกว่า 3 ชนิ้ · ตำแหน่ง 11 → มี ของไม่ช่อบอยู่ต่ำกว่า 1 ชนิ้

รวมคู่ไร้ยีงถูก = 5 + 5 + 5 + 4 + 3 + 1 = 23 → AUC = 23/36 = **0.6389**

**U3 ปานระวี / Model Y** — รายการไม่เกี่ยวข้องอยู่ที่ตำแหน่ง 1, 2, 6, 7, 10, 11

ตำแหน่ง 3 → มีของไม่ช่อบอยู่ต่ำกว่า 4 ชนิ้ · ตำแหน่ง 4 → มีของไม่ช่อบอยู่ต่ำกว่า 4 ชนิ้ · ตำแหน่ง 5 → มีของไม่ช่อบอยู่ต่ำ กว่า 4 ชนิ้ · ตำแหน่ง 8 → มีของไม่ช่อบอยู่ต่ำกว่า 2 ชนิ้ · ตำแหน่ง 9 → มีของไม่ช่อบอยู่ต่ำกว่า 2 ชนิ้ · ตำแหน่ง 12 → มี ของไม่ช่อบอยู่ต่ำกว่า 0 ชนิ้

รวมคู่ไร้ยีงถูก = 4 + 4 + 4 + 2 + 2 + 0 = 16 → AUC = 16/36 = **0.4444**

**เฉลยี่ X = 0.6481 · เฉลยี่ Y = 0.4815**

> **ข้อสังเกตสำคัญ:** Model Y ได้ AUC ต่ำกว่า 0.5 ถึงสองผู้ใช้ (0.4722 และ 0.4444) แปลว่าเรียงกลับด้านกับความจริงอย่างเป็นระบบ ไม่ใช่เพียงเรียงมั่ว · อย่างไรก็ตาม AUC ให้น้ำหนักคู่ที่อันดับ 11–12 เท่ากับคู่ที่อันดับ 1–2 ทั้งที่ผู้ใช้เห็นเพียง 5 อันดับแรก จึงควรใช้เป็นตัวชี้วัดรอง ไม่ใช่ Primary Metric ของระบบที่แสดง Top-5

## 5. ตารางสรุปตัวชี้วัดทั้งแปดตัว

| ตัวชี้วัด | Model X | Model Y | ผลต่าง (X - Y) | อัตราส่วน X/Y | แยกความต่างได้หรือไม่ |
|---|---|---|---|---|---|
| Precision@5 | 0.6000 | 0.6000 | 0.0000 | 1.00 | แยกไม่ออก |
| Recall@5 | 0.5000 | 0.5000 | 0.0000 | 1.00 | แยกไม่ออก |
| F1@5 | 0.5455 | 0.5455 | 0.0000 | 1.00 | แยกไม่ออก |
| HR@5 | 1.0000 | 1.0000 | 0.0000 | 1.00 | แยกไม่ออก |
| MRR | 0.8333 | 0.3889 | 0.4444 | 2.14 | **แยกออก** |
| MAP@5 | 0.4622 | 0.2978 | 0.1644 | 1.55 | **แยกออก** |
| nDCG@5 | 0.6229 | 0.4617 | 0.1613 | 1.35 | **แยกออก** |
| AUC | 0.6481 | 0.4815 | 0.1667 | 1.35 | **แยกออก** |

> **บทเรียนข้อที่หนึ่ง — การเลือกตัวชี้วัดคือการเลือกข้อสรุป**
> ทีมที่รายงาน Precision@5 จะสรุปว่าโมเดลทั้งสอง “ดีเท่ากันทุกประการ” ส่วนทีมที่รายงาน MRR จะสรุปว่า Model X “ดีกว่า 2.14 เท่า” ทั้งสองทีมคำนวณถูกต้องทุกหลัก แต่ให้คำตอบต่อผู้บริหารต่างกันโดยสิ้นเชิง จึงต้องประกาศ Primary Metric ก่อนเห็นผล

> **บทเรียนข้อที่สอง — ขนาดของความต่างก็ขึ้นกับตัวชี้วัด**
> แม้เฉพาะในกลุ่มสี่ตัวที่แยกความต่างได้ อัตราส่วน X/Y ก็ยังแกว่งตั้งแต่ 1.35 เท่า (AUC) ถึง 2.14 เท่า (MRR) การกล่าวว่า “โมเดลของเราดีกว่าอย่างมีนัยสำคัญ” จึงไม่มีความหมาย หากไม่ระบุว่าวัดด้วยตัวชี้วัดใด ที่ K เท่าใด และบนข้อมูลชุดใด

## 6. เฉลยภาคขยาย — ความเกี่ยวข้องหลายระดับ (ผู้ใช้ U1 — ชาคร)

| รายการใน $\mathcal{R}_u$ | i1 | i2 | i4 | i7 | i9 | i11 |
|---|---|---|---|---|---|---|
| rel | 1 | 3 | 2 | 3 | 1 | 2 |
| gain = 2^rel - 1 | 1 | 7 | 3 | 7 | 1 | 3 |

**Model X** (Top-5 = i1, i2, i5, i4, i8 · rel = 1, 3, 0, 2, 0)
DCG@5 = 1×1.0000 + 7×0.6309 + 0×0.5000 + 3×0.4307 + 0×0.3869 = **6.7085**

**Model Y** (Top-5 = i5, i8, i1, i2, i4 · rel = 0, 0, 1, 3, 2)
DCG@5 = 0×1.0000 + 0×0.6309 + 1×0.5000 + 7×0.4307 + 3×0.3869 = **4.6753**

**IDCG@5** (rel อุดมคติ = 3, 3, 2, 2, 1) = 7×1.0000 + 7×0.6309 + 3×0.5000 + 3×0.4307 + 1×0.3869 = **14.5954**

| โมเดล | DCG@5 (หลายระดับ) | nDCG@5 (หลายระดับ) | nDCG@5 (ทวิภาค) |
|---|---|---|---|
| Model X | 6.7085 | **0.4596** | 0.6992 |
| Model Y | 4.6753 | **0.3203** | 0.4469 |

**เหตุใด nDCG ของ Model X จึงลดลงจาก 0.6992 เหลือ 0.4596**
Model X วาง i1 ซึ่งมี rel เพียง 1 (gain = 1) ไว้ที่อันดับ 1 อันเป็นตำแหน่งที่มีน้ำหนักสูงสุด ขณะที่ลำดับอุดมคติต้องการรายการ rel = 3 (gain = 7) ที่ตำแหน่งนั้น เมื่อผลได้ถูกขยายด้วย 2^rel - 1 การ “วางของดีน้อยไว้บนสุด” จึงถูกลงโทษหนักกว่าเดิมมาก จำนวน hit ไม่ได้เปลี่ยน และ IDCG ก็ไม่ได้ลด (กลับเพิ่มจาก 2.9485 เป็น 14.5954) แต่ตัวเศษของ X ตามไม่ทัน
**บทเรียน:** การเปลี่ยน Gain Function เปลี่ยนทั้งค่าและขนาดของความต่าง โดยที่ข้อมูลและลำดับการจัดอันดับ ไม่ได้เปลี่ยนเลย จึงต้องประกาศ Gain Function และ Discount Function ควบคู่กับค่า nDCG เสมอ

## 7. เฉลยคำถามอภิปรายผล

### ก. คำถามคำนวณสั้น

**1.** Recall@5 สูงสุด = min(K, $|\mathcal{R}_u|$) / $|\mathcal{R}_u|$ = 5/6 = **0.8333** — เพราะแสดงได้เพียง 5 ช่อง แต่ผู้ใช้ชอบ 6 รายการ จึงเก็บครบไม่ได้แม้จัดอันดับสมบูรณ์แบบ

**2.** Precision@5 สูงสุด = 5/5 = **1.0000** — ต่างจากตัวอย่างในบทเรียนที่ $|\mathcal{R}_u|$ = 3 < K = 10 ซึ่ง Precision@10 มีเพดานเพียง 0.30 แสดงว่าเพดานของตัวชี้วัดขึ้นกับความสัมพันธ์ระหว่าง K กับ $|\mathcal{R}_u|$ เสมอ

**3. 4 ตัว** ได้แก่ Precision@5, Recall@5, F1@5 และ HR@5 ทั้งหมดเป็นตัวชี้วัดเชิงกลุ่มที่ไม่สนใจตำแหน่ง

**4. MRR** (2.14 เท่า) เพราะไวต่อตำแหน่งของรายการถูกต้องชิ้นแรกมากที่สุด

**5–6.** U1/Model X พบรายการถูกต้องที่ตำแหน่ง 1, 2, 4, 6, 8, 11 ภายใน Top-6 จึงมี 4 ชิ้น → Recall@6 = 4/6 = **0.6667** และ Precision@6 = 4/6 = **0.6667**
**จุดที่ต้องเข้าใจ:** Recall เพิ่มขึ้นเสมอเมื่อ K โตขึ้น (ไม่มีวันลด) ส่วน Precision ไม่ จำเป็นต้องลดลง ในกรณีนี้เพิ่มจาก 0.6000 เป็น 0.6667 เพราะตำแหน่งที่ 6 บังเอิญเป็นรายการถูกต้องพอดี การอ้างว่า “Precision ลดลงเมื่อ K เพิ่มเสมอ” จึงไม่ถูกต้อง

**7.** AUC = 0.4815 < 0.5 หมายถึง **เรียงลำดับได้แย่กว่าการเดาสุ่มเล็กน้อย** ไม่ใช่ “ความแม่นยำ 48.15%” เพราะ AUC วัดคุณภาพการเรียงคู่ ไม่ใช่สัดส่วนการทำนายถูก

**8. U2 — อสมา** ซึ่ง Model Y พบรายการถูกต้องชิ้นแรกที่อันดับ 2 ให้ RR = 0.5000 สูงกว่าอีกสองคนที่ได้ 0.3333 เท่ากัน

### ข. แนวคำตอบข้อเขียน

#### ข้อ 1 · ย่อหน้าสรุปเชิงเปรียบเทียบ

เมื่อประเมินด้วยผู้ใช้สามคนที่ K = 5 ตัวชี้วัดเชิงกลุ่มทั้งสี่ตัวให้ค่าเท่ากันทุกประการ คือ Precision@5 = 0.6000, Recall@5 = 0.5000, F1@5 = 0.5455 และ HR@5 = 1.0000 ทั้งสองโมเดล ขณะที่ตัวชี้วัดที่ไวต่ออันดับแยกความต่างได้ชัดเจน โดย Model X มี nDCG@5 = 0.6229 สูงกว่า Model Y ซึ่งมีค่า 0.4617 อยู่ 0.1613 จุด หรือประมาณ 1.35 เท่า ในทำนองเดียวกัน MRR ของ Model X เท่ากับ 0.8333 สูงกว่า Model Y ที่ 0.3889 ถึง 2.14 เท่า ผลนี้แสดงว่าทั้งสองโมเดลค้นพบรายการที่ผู้ใช้ชอบได้ “จำนวนเท่ากัน” แต่ Model X วางรายการเหล่านั้นไว้ในอันดับต้นซึ่งผู้ใช้มองเห็นจริงได้ดีกว่า

ทั้งนี้ ข้อสรุปข้างต้นจำกัดอยู่เฉพาะชุดข้อมูลตัวอย่างนี้ ที่ K = 5 ด้วย Candidate Set 12 รายการ และผู้ใช้เพียงสามคน จึงไม่ควรกล่าวกว้าง ๆ ว่า “Model X ดีกว่า 2.14 เท่า” โดยไม่ระบุตัวชี้วัดและเงื่อนไขการวัด

#### ข้อ 2 · Primary Metric และ Guardrail

**(ก) Primary Metric:** nDCG@5 เพราะหน้าจอแสดงเพียง 5 อันดับ ตัวชี้วัดหลักจึงควรตัดที่ K เดียวกับที่ผู้ใช้เห็นจริง และควรไวต่อทั้ง “ตำแหน่ง” และ “ระดับความเกี่ยวข้อง” ในกรณีที่ภายหลังเปลี่ยนไปใช้ rel หลายระดับก็ยังใช้สูตรเดิมได้

**(ข) Guardrail Metrics:** Recall@5 ต้องไม่ลดเกิน 2% เชิงสัมพัทธ์จากค่าฐาน (กันการไล่คะแนนอันดับจนละทิ้งความครอบคลุม), Coverage ของรายการต้องไม่ต่ำกว่าเกณฑ์ที่ตั้งไว้ และค่า Gini ของการเปิดเผยต้องไม่เพิ่มเกินเกณฑ์ (กัน popularity bias) พร้อมประกาศเกณฑ์ทั้งหมด **ก่อน** เห็นผลการทดลอง

**(ค) เหตุผลที่ไม่เลือกตัวอื่น:** Precision@5 / Recall@5 / F1@5 / HR@5 ในข้อมูลชุดนี้ให้ค่าเท่ากันทั้งสองโมเดล จึงไม่มีอำนาจจำแนก ส่วน AUC ให้น้ำหนักทุกคู่เท่ากันตลอด 12 อันดับ รวมถึงคู่ที่อยู่ท้ายรายการซึ่งผู้ใช้ไม่มีวันเห็น จึงเหมาะเป็นตัวชี้วัดรอง ขณะที่ MRR สนใจเพียงรายการถูกต้องชิ้นแรก ทั้งที่ระบบต้องแสดงถึง 5 ชิ้น

#### ข้อ 3 · เหตุใดตัวชี้วัดเชิงกลุ่มจึงเท่ากัน

ตัวชี้วัดทั้งสี่ตัวนี้ตรวจเพียงว่ารายการ “อยู่ภายใน Top-5 หรือไม่” โดยไม่สนใจว่าอยู่อันดับใดภายในนั้น เมื่อทั้งสองโมเดลมีรายการถูกต้องใน Top-5 จำนวนสามชิ้นเท่ากันในผู้ใช้ทุกคน ค่าที่ได้จึงเท่ากันหมดโดยหลีกเลี่ยงไม่ได้ (Precision = 3/5, Recall = 3/6, F1 = 0.5455, HR = 1)

บทเรียนคือ **การเลือกตัวชี้วัดคือการเลือกข้อสรุป** ทีมที่รายงานเฉพาะ Precision@5 จะสรุปว่าโมเดลทั้งสอง “ดีเท่ากัน” ส่วนทีมที่รายงาน MRR จะสรุปว่า Model X “ดีกว่าถึง 2.14 เท่า” ทั้งสองทีมคำนวณถูกต้องทุกหลัก แต่ให้คำตอบต่อผู้บริหารต่างกันโดยสิ้นเชิง จึงต้องประกาศ Primary Metric ไว้ก่อนเห็นผล และรายงานตัวชี้วัดหลายตัวประกอบกันเสมอ

## ข้อ 4 · การตีความ AUC ต่ำกว่า 0.5

AUC คือความน่าจะเป็นที่โมเดลจะให้คะแนนรายการที่ผู้ใช้ชอบสูงกว่ารายการที่ผู้ใช้ไม่ชอบ เมื่อสุ่มมาอย่างละหนึ่งรายการ ค่า 0.4722 ของ U1 จึงหมายความว่า Model Y เรียงคู่ได้ถูกเพียงประมาณ 47.2% ของคู่ทั้งหมด ซึ่ง**ต่ำกว่าการเดาสุ่ม**ที่ให้ค่า 0.5 นั่นแปลว่าในผู้ใช้คนนี้ Model Y มีแนวโน้มเรียงกลับด้านกับความจริงอย่างเป็นระบบ ไม่ใช่เพียงเรียงมั่ว

ข้อความ “ดีกว่า 35%” มีปัญหาสามชั้น หนึ่ง ไม่ระบุว่าเป็นตัวชี้วัดใด ทั้งที่อัตราส่วน X/Y ในข้อมูลชุดเดียวกันนี้ แกว่งตั้งแต่ 1.00 เท่า (Precision@5) ถึง 2.14 เท่า (MRR) สอง สับสนระหว่าง “ผลต่างเป็นจุด” กับ “ร้อยละเชิงสัมพัทธ์” และสาม AUC ไม่ใช่ “ความแม่นยำ” แต่เป็นคุณภาพการเรียงคู่ ที่ถูกต้องคือระบุตัวชี้วัด ค่าทั้งสองฝั่ง วิธีคำนวณผลต่าง และช่วงความเชื่อมั่นหากมี

## ข้อ 5 · ข้อจำกัดของข้อมูลออฟไลน์และขั้นถัดไป

**ข้อจำกัด** (1) ผู้ใช้เพียงสามคนและ Candidate Set 12 รายการ ทำให้ตัวเลขทุกตัวมีความไม่แน่นอนสูงมาก ค่าต่างที่เห็นอาจเกิดจากความบังเอิญ ควรรายงานช่วงความเชื่อมั่นด้วยวิธี Bootstrap และทดสอบนัยสำคัญแบบจับคู่รายผู้ใช้ก่อนสรุป (2) รายการที่ไม่อยู่ใน Ground Truth ไม่ได้แปลว่าผู้ใช้ไม่ชอบ อาจเป็นเพียงรายการที่ผู้ใช้ยังไม่เคยถูกแสดงให้เห็น ค่า FP และ FN บางส่วนจึงเป็น Pseudo FP/FN จาก Exposure Bias ทำให้ Precision และ Recall ออฟไลน์เป็นเพียง**ขอบล่าง**ของความสามารถจริง (3) ยังไม่ได้ประกาศวิธีแบ่งข้อมูล หากไม่ใช้ Temporal Split อาจเกิด Data Leakage จากการใช้อนาคตทำนายอดีต (4) Candidate Set ที่เล็กเช่นนี้ใกล้เคียงกับการใช้ Sampled Negatives ซึ่งทำให้ค่า AUC และตัวชี้วัดอันดับสูงเกินจริง เมื่อเทียบกับการจัดอันดับแคตตาล็อกเต็ม

**ขั้นถัดไป** ขยายจำนวนผู้ใช้ในชุดทดสอบ ใช้ Temporal Split ที่ประกาศจุดตัดเวลาชัดเจน รายงานผลบนแคตตาล็อกเต็มควบคู่กับ Sampled Negatives แนบช่วงความเชื่อมั่น จัดทำ Protocol Card ให้ทำซ้ำได้ แล้วจึงยืนยันด้วย A/B Test ออนไลน์ หรือ User Study ก่อนตัดสินใจนำขึ้นระบบจริง