ใบข้อมูล ค · ผลการทดลองบนชุดข้อมูล RSLab-Eval

ผู้ใช้ 800 คน · รายการ 500 ชิ้น · ปฏิสัมพันธ์ 21,696 ครั้ง · ความหนาแน่น 0.0542 · มีคอลัมน์เวลากำกับ

ตาราง ค.1 · การแบ่งข้อมูลสี่แบบ กับผลที่ได้ (แบบจำลองเดิม TopPopular ทุกประการ)

วิธีแบ่งข้อมูล	ชุดฝึก	ชุดทดสอบ	เหตุการณ์อนาคตในชุดฝึก	ผลตรวจ	nDCG@10	ผู้ใช้ที่ประเมินได้
สุ่ม (Random)	17,357	4,339	17,355 (100.0%)	พบการรั่วไหล	0.0921	756
ตามเวลาแบบรวม (Global Temporal)	17,356	4,340	0 (0.0%)	ปลอดภัย	0.0537	752
ตามเวลารายผู้ใช้ (Per-User Temporal)	17,355	4,341	6,257 (36.1%)	พบการรั่วไหล	0.0579	789
กันรายการสุดท้าย (Leave-One-Out)	20,896	800	4,557 (21.8%)	พบการรั่วไหล	0.0375	421

การรั่วไหลจากสถิติ · คำนวณความนิยมจากข้อมูลทั้งหมดก่อนแบ่ง ทำให้ nDCG@10 ขยับจาก 0.0537 เป็น 0.0561 หรือสูงขึ้นร้อยละ 4.6

ตาราง ค.2 · แบบจำลองสามแบบ กับตัวชี้วัดหลักหนึ่งตัวและตัวชี้วัดกำกับแปดตัว

ตัวชี้วัด	ทิศทางที่ดี	TopPopular	Personalized	Diversified
nDCG@10 (ตัวชี้วัดหลัก)	สูง	0.0537	0.1307	0.1027
Coverage@10	สูง	0.042	0.130	0.108
Gini ของการเปิดเผย	ต่ำ	0.9735	0.9145	0.9599
ILD	สูง	0.8730	0.5469	0.8903
Novelty	สูง	2.1200	2.7898	2.2467
Long-tail Ratio@10	สูง	0.0000	0.1029	0.0082
Calibration Error	ต่ำ	0.5240	0.3730	0.2994
Parity Gap (ฝั่งผู้ใช้)	ต่ำ	0.0117	0.0043	0.0072
Provider Gini	ต่ำ	0.6685	0.3945	0.5808

ตาราง ค.3 · ความผันผวนจากเมล็ดสุ่มล้วน ๆ (แบบจำลองเดิม ฝึกซ้ำแปดครั้ง)

ครั้งที่	1	2	3	4	5	6	7	8
nDCG@10	0.0917	0.0969	0.0934	0.0887	0.0931	0.0900	0.0979	0.0885

ค่าเฉลี่ย 0.0925 · ส่วนเบี่ยงเบนมาตรฐาน 0.0035 · ช่วงที่พบ [0.0885, 0.0979] กว้าง 0.0094 · ครึ่งความกว้างของช่วงเชื่อมั่น 95% ของค่าเฉลี่ย ±0.0024

ตาราง ค.4 · ผลการทดสอบนัยสำคัญ (Paired Bootstrap 4,000 รอบ บนผู้ใช้ 600 คน)

คู่เปรียบเทียบ	ส่วนต่างเฉลี่ย	ช่วงความเชื่อมั่น 95%	p-value	เกณฑ์ของโฮล์ม
A – B	+0.0202	[+0.0144, +0.0259]	0.0000	0.05 / 3 = 0.0167
C – B	+0.0177	[+0.0119, +0.0230]	0.0000	0.05 / 2 = 0.0250
A – C	+0.0025	[–0.0033, +0.0084]	0.4045	0.05 / 1 = 0.0500

ค่าเฉลี่ยรายแบบจำลอง A = 0.2148 · B = 0.1946 · C = 0.2123 · ผู้ใช้ 238 จาก 600 คน (ประมาณร้อยละ 40) ได้ผลแย่ลงแม้ค่าเฉลี่ยจะดีขึ้น

การสุ่มซ้ำผิดระดับ · ระดับผู้ใช้ n = 600 ได้ช่วงกว้าง 0.0115 (ถูกต้อง) · ระดับเหตุการณ์ n = 4,800 ได้ช่วงกว้าง 0.0040 (แคบเกินจริง 2.9 เท่า)

ตาราง ค.5 · การสุ่มรายการเชิงลบ และการสลับผู้ชนะ

m	nDCG@10 ของ Model P	nDCG@10 ของ Model Q	ผู้ชนะ
20	0.8591	0.6501	P
50	0.7049	0.5169	P
100	0.5364	0.3046	P
200	0.3891	0.2186	P
499 (เต็มคลัง)	**0.0000**	**0.1500**	**Q**

Model P วางรายการเป้าหมายไว้อันดับ 12 ให้ผู้ใช้ทุกคน · Model Q วางไว้อันดับ 3 ให้ร้อยละ 30 และอันดับ 60 ให้ที่เหลือ · คลัง 500 รายการ · K = 10

> สูตรอันดับคาดหวัง $E[\rho] \approx 1 + (\rho - 1) \cdot m / (|\mathcal{I}| - 1)$ · ตัวอย่าง $\rho = 500 \cdot |\mathcal{I}| = 5{,}000 \cdot m = 99$ ได้ 10.88 ทำให้ nDCG@10 กระโดดจาก 0.0000 เป็น sampled nDCG@10 = 0.1482

ตาราง ค.6 · บัตรโปรโตคอลของการทดลองชุดนี้

ช่องข้อมูล	ค่าที่บันทึก
dataset / n_users / n_items / n_interactions	RSLab-Eval / 800 / 500 / 21,696
k_core / split_method / train_frac	0 / global_temporal / 0.7
relevance_threshold / K	rating ≥ 4 / 10
candidate_set / gain_type	full_catalog / linear
seeds	(0, 1, 2, 3, 4)
primary_metric	nDCG@10 เฉลี่ยแบบมหภาคข้ามผู้ใช้ บนการจัดอันดับเต็มบัญชีรายการ
guardrail_metrics	Coverage@10 · Gini · Novelty · LongTail