รากฐานของระบบผู้แนะนำ
Foundations of Recommender Systems

แนวคิดพื้นฐาน องค์ประกอบ ปัญหา ข้อมูล แนวทางหลัก และตัวอย่างการคำนวณ สำหรับผู้เริ่มต้น

ระบบผู้แนะนำ ช่วยให้ผู้ใช้พบสิ่งที่ใช่ จากข้อมูลจำนวนมาก ได้ง่ายขึ้น ♪

1 ระบบผู้แนะนำคืออะไร?

ในโลกออนไลน์มีข้อมูลจำนวนมากเกินไป ผู้ใช้จึงเลือกดูได้ไม่หมด ระบบผู้แนะนำ (Recommender System) ช่วยคัดเลือกและจัดอันดับรายการที่น่าจะตรงกับความสนใจของแต่ละคน ให้เหลือเพียงไม่กี่รายการ

ระบบผู้แนะนำ
คัดเลือกและจัดอันดับรายการที่เหมาะกับคุณ

แตกต่างจากการค้นหา (Search)

การค้นหา
ผู้ใช้ระบุคำค้นเอง ได้รายการจำนวนมากที่เกี่ยวข้องกับคำค้น

ระบบผู้แนะนำ
ระบบคาดการณ์สิ่งที่ผู้ใช้น่าจะสนใจ โดยไม่ต้องระบุคำค้น และจัดอันดับให้เหมาะกับแต่ละคน

2 องค์ประกอบของระบบและวงจรข้อมูล

ระบบผู้แนะนำทำงานร่วมกันหลายองค์ประกอบ และมีการรับข้อมูลป้อนกลับเพื่อนำไปปรับปรุงผลลัพธ์อย่างต่อเนื่อง

ผู้ใช้ (User)

มีความสนใจและพฤติกรรมที่แตกต่างกัน

รายการ (Item)

เช่น ภาพยนตร์ เพลง สินค้า บทความ

ข้อมูลปฏิสัมพันธ์ (Interaction)
ให้คะแนน
คลิก ดู ซื้อ ฯ
หรือพฤติกรรมอื่น ๆ

แบบจำลอง (Model)
เรียนรู้จากข้อมูลเพื่อคาดการณ์ความสนใจ

การจัดอันดับ (Ranking)
1
2
3
สร้างรายการแนะนำ Top-K ที่เหมาะกับผู้ใช้

ข้อมูลป้อนกลับ (Feedback Loop)
ผู้ใช้ตอบสนองต่อคำแนะนำ เช่น คลิกหรือให้คะแนน ข้อมูลเหล่านี้จะถูกนำกลับไปพัฒนาแบบจำลองให้ดีขึ้น

3 คุณค่าทางธุรกิจและ Long Tail

ช่วยผู้ใช้

- พบรายการที่ตรงกับความสนใจ
- ประหยัดเวลาในการค้นหา
- ได้รับประสบการณ์ที่ดีขึ้น

ช่วยธุรกิจ

- เพิ่มการมีส่วนร่วมของผู้ใช้
- เพิ่มยอดขาย/การใช้งาน
- สร้างความภักดีในระยะยาว

ช่วยให้รายการเฉพาะกลุ่ม (Long Tail) ถูกค้นพบ

นอกจากรายการยอดนิยม ระบบผู้แนะนำยังช่วยให้รายการที่ไม่ค่อยเป็นที่รู้จัก แต่ตรงกับความสนใจเฉพาะกลุ่ม มีโอกาสถูกค้นพบได้มากขึ้น

4 นิยามปัญหา

เรามีข้อมูลปฏิสัมพันธ์ระหว่างผู้ใช้และรายการ ซึ่งมักจะมีเพียงบางส่วน (ข้อมูลส่วนใหญ่หายไป) เป้าหมายของระบบผู้แนะนำมี 2 แบบหลัก

ตัวอย่างเมทริกซ์ผู้ใช้–รายการ (User–Item Matrix)

	Item 1	Item 2	Item 3	Item 4	Item 5	…
User 1	5	–	3	–	4	…
User 2	–	4	–	2	–	…
User 3	1	–	–	5	–	…
User 4	–	2	4	–	–	…
…	…	…	…	…	…	…

Rating Prediction
คาดการณ์ค่าคะแนนที่ผู้ใช้จะให้กับรายการที่ยังไม่เคยมีปฏิสัมพันธ์

Top-K Ranking
จัดอันดับรายการที่ผู้ใช้น่าจะสนใจมากที่สุด และแนะนำ Top-K รายการ

5 ผลป้อนกลับแบบชัดแจ้งและโดยปริยาย

ระบบผู้แนะนำสามารถใช้ข้อมูลปฏิสัมพันธ์ได้หลายรูปแบบ ทั้งที่ผู้ใช้ระบุชัดเจน หรือเกิดขึ้นโดยอัตโนมัติจากพฤติกรรมการใช้งาน

ผลป้อนกลับแบบชัดแจ้ง (Explicit Feedback)
ผู้ใช้ระบุความชอบอย่างชัดเจน

- ★★★★☆ ให้คะแนน (เช่น 1–5)
- กดไลก์ (Like)
- กดถูกใจ (Favorite)
- รีวิว/ความคิดเห็น (Review)

ผลป้อนกลับโดยปริยาย (Implicit Feedback)
เกิดจากพฤติกรรมของผู้ใช้โดยไม่ต้องระบุ

- คลิก (Click)
- ดู/รับชม (View)
- ซื้อ (Purchase)
- ใช้เวลา (Time Spent)

6 แนวทางหลักของระบบผู้แนะนำ

มีหลายแนวทางในการสร้างระบบผู้แนะนำ แต่แนวทางหลักที่ใช้กันอย่างแพร่หลายมี 3 แบบ

Content-Based (อิงเนื้อหา)
แนะนำรายการที่มีเนื้อหาคล้ายกับรายการที่ผู้ใช้เคยชอบ

เช่น เคยชอบหนังแนวแอ็กชัน ก็แนะนำหนังแอ็กชันเรื่องอื่น

Collaborative Filtering (อิงพฤติกรรมของผู้ใช้)
แนะนำจากพฤติกรรมของผู้ใช้ที่มีความสนใจคล้ายกัน

เช่น ผู้ใช้ที่มีรสนิยมคล้ายคุณชอบรายการนี้ คุณอาจจะชอบด้วย

Hybrid (แบบผสมผสาน)
รวมข้อดีของหลายแนวทาง เช่น ใช้ทั้งเนื้อหาและพฤติกรรมร่วมกัน

เช่น ใช้ข้อมูลเนื้อหาร่วมกับพฤติกรรมผู้ใช้

7 AI, ML, DL และ GenAI

ระบบผู้แนะนำอยู่ในขอบข่ายของปัญญาประดิษฐ์ (AI) โดยใช้เทคนิคการเรียนรู้ของเครื่อง (ML) และอาจใช้การเรียนรู้เชิงลึก (DL) รวมถึงแนวทางใหม่ ๆ เช่น GenAI ในบางกรณี

ระบบผู้แนะนำ (Recommender Systems)
- เป็นหนึ่งในงานประยุกต์ของ AI/ML/DL
- ใช้ข้อมูลผู้ใช้และรายการในการเรียนรู้รูปแบบความสนใจ
- อาจใช้ DL สำหรับแบบจำลองที่ซับซ้อน
- และสามารถนำ GenAI มาช่วยสร้างคำอธิบายรายการแนะนำ หรือสร้างโปรไฟล์ผู้ใช้ได้

8 ชุดข้อมูลกลาง MovieMini-12

ในหนังสือเล่มนี้ใช้ชุดข้อมูลตัวอย่างขนาดเล็กชื่อ MovieMini-12 เพื่ออธิบายแนวคิดและทดลองวิธีต่าง ๆ ได้ง่าย

ผู้ใช้ 8 คน (8 users)

รายการ 12 เรื่อง (12 items)

- ✓ เป็นชุดข้อมูลขนาดเล็ก เหมาะสำหรับการเรียนรู้
- ✓ มีข้อมูลปฏิสัมพันธ์บางส่วน (ไม่สมบูรณ์)
- ✓ ใช้ในการสาธิตแนวคิดและการคำนวณเบื้องต้น
- ✓ สามารถนำไปทดลองวิธีต่าง ๆ ได้

9 ตัวอย่างการคำนวณอย่างง่าย

A คำนวณความหนาแน่นของข้อมูล (Density)

ใน MovieMini-12 มีผู้ใช้ 8 คน รายการ 12 เรื่อง และมีค่าที่สังเกตได้ (มีปฏิสัมพันธ์) 32 ค่า

$$\text{Density} = \frac{\text{จำนวนค่าที่สังเกตได้}}{\text{ผู้ใช้} \times \text{รายการ}} = \frac{32}{8 \times 12} = \frac{32}{96} = 0.3333 \approx 33.3\%$$

B ตัวอย่าง TopPopular (แนะนำรายการยอดนิยม)

นับจำนวนผู้ใช้ที่มีปฏิสัมพันธ์กับแต่ละรายการ และเลือกรายการที่มีจำนวนมากที่สุด

รายการ	จำนวนผู้ใช้ที่มีปฏิสัมพันธ์
Item 1	5
Item 2	3
Item 3	**8** 👑
Item 4	2
Item 5	6
…	…

Item 3 มีจำนวนผู้ใช้มากที่สุด จึงถูกแนะนำเป็นรายการยอดนิยม

10 สรุปสั้น ๆ

1. ระบบผู้แนะนำช่วยคัดเลือกและจัดอันดับรายการที่เหมาะกับผู้ใช้จากข้อมูลจำนวนมาก
2. อาศัยข้อมูลผู้ใช้ รายการ และปฏิสัมพันธ์ พร้อมวงจรการป้อนกลับเพื่อพัฒนาอย่างต่อเนื่อง
3. สร้างคุณค่าทั้งต่อผู้ใช้และธุรกิจ และช่วยให้รายการเฉพาะกลุ่มถูกค้นพบ
4. มีทั้งการทำนายคะแนนและการจัดอันดับ Top-K ใช้ผลป้อนกลับได้ทั้งแบบชัดแจ้งและโดยปริยาย
5. แนวทางหลักคือ Content-Based, Collaborative Filtering และ Hybrid
6. ระบบผู้แนะนำอยู่ในขอบข่ายของ AI/ML/DL และเชื่อมโยงกับ GenAI
7. ใช้ชุดข้อมูล MovieMini-12 (8 ผู้ใช้, 12 รายการ) ในการเรียนรู้และทดลอง
8. การคำนวณพื้นฐานช่วยให้เข้าใจลักษณะข้อมูล เช่น ความหนาแน่น และการแนะนำแบบง่าย ๆ เช่น TopPopular

การประเมินระบบผู้แนะนำ
Evaluation of Recommender Systems

ตัวชี้วัด การทดลอง การแบ่งข้อมูล และตัวอย่างการคำนวณอย่างง่าย

เลือกตัวชี้วัดที่เหมาะสม
ออกแบบการทดลองที่ถูกต้อง
ประเมินอย่างรอบด้าน
เพื่อสร้างระบบผู้แนะนำ
ที่ตอบโจทย์ผู้ใช้จริง

1 แผนที่ตัวชี้วัดในการประเมิน

การประเมินระบบผู้แนะนำมีหลายมุมมอง ควรเลือกตัวชี้วัดให้เหมาะกับเป้าหมายของระบบและลักษณะข้อมูล

การทำนายคะแนน (Rating Prediction)	การแนะนำแบบชุด (Top-K: Set-based)	การแนะนำแบบอันดับ (Top-K: Rank-aware)	ตัวชี้วัดอื่น ๆ (Beyond-Accuracy)
★★★☆☆	☑☑☑	1 2 3	
• MAE • RMSE	• Precision@K • Recall@K • F1@K • Hit Rate@K	• MRR • AP@K • nDCG@K	• Coverage • Gini • Novelty • Diversity (ILD) • Calibration • Fairness
วัดความแม่นยำในการทำนายคะแนน (เช่น ระดับความชอบ)	วัดว่ารายการที่แนะนำมีความเกี่ยวข้องมากน้อยเพียงใด	พิจารณาลำดับของรายการที่แนะนำ รายการที่ดีควรอยู่ด้านบน	ประเมินความหลากหลาย ความเป็นธรรม และประสบการณ์ผู้ใช้โดยรวม

2 MAE และ RMSE: วัดความแม่นยำในการทำนายคะแนน

แนวคิด วัดความแตกต่างระหว่างคะแนนที่ทำนายกับคะแนนจริง ยิ่งค่าน้อย ยิ่งทำนายได้แม่นยำ

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|$$

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2}$$

ตัวอย่างการคำนวณ

รายการ	คะแนนจริง	คะแนนทำนาย	|error|	error²
u1	4	5	1	1
u2	3	2	1	1
u3	5	4	1	1

$MAE = \frac{1+1+1}{3} = 1.00$ $RMSE = \sqrt{\frac{1+1+1}{3}} = 1.00$

MAE เข้าใจง่ายเพราะดูจากความต่างโดยตรง
ส่วน RMSE ลงโทษความคลาดเคลื่อนขนาดใหญ่มากกว่า

3 ตัวชี้วัด Top-K ที่ไม่ไวต่อการจัดอันดับ

แนวคิด พิจารณาว่ารายการที่ระบบแนะนำอยู่ในชุด Top-K มีความเกี่ยวข้องมากน้อยเพียงใด โดยไม่สนใจลำดับ

สูตรสำคัญ

$$Precision@K = \frac{|R_u \cap L_u@K|}{K}$$

$$Recall@K = \frac{|R_u \cap L_u@K|}{|R_u|}$$

$$F1@K = 2 \cdot \frac{Precision@K \cdot Recall@K}{Precision@K + Recall@K}$$

$$HitRate@K = \begin{cases} 1 & \text{ถ้า } |R_u \cap L_u@K| > 0 \\ 0 & \text{ถ้าไม่พบ} \end{cases}$$

ตัวอย่างการคำนวณ (K = 3)

รายการที่ผู้ใช้ชอบจริง $(R_u) = \{i_1, i_2, i_3\}$
รายการแนะนำ Top-3 $(L_u@3) = \{i_1, i_2, i_4\}$

รายการ	อยู่ใน R_u ?	อยู่ใน Top-3 ?
i_1	✓	✓
i_2	✓	✓
i_3	✓	✗
i4	✗	✓

ผลลัพธ์

$Precision@3 = \frac{2}{3} = 0.67$
$Recall@3 = \frac{2}{3} = 0.67$
$F1@3 = 0.67$
$HR@3 = 1$ (พบอย่างน้อย 1 รายการ)

4 ตัวชี้วัด Top-K ที่ไวต่อการจัดอันดับ

แนวคิด ให้ความสำคัญกับลำดับของรายการที่แนะนำ รายการที่ดีควรอยู่ในตำแหน่งบน ๆ

สูตรสำคัญ

$$MRR = \frac{1}{rank \text{ ของรายการที่ถูกต้องรายการแรก}}$$

$$AP@K = \frac{1}{|R_u|}\sum_{k=1}^{K} Precision@k \cdot rel_k$$

$$nDCG@K = \frac{DCG@K}{IDCG@K} \qquad DCG@K = \sum_{k=1}^{K}\frac{2^{rel_k}-1}{\log_2(k+1)}$$

ตัวอย่างการคำนวณ

รายการที่เกี่ยวข้องจริง $= \{i_1, i_3\}$
รายการแนะนำ Top-5 $= \{i_2, i_3, i_1, i_4, i_5\}$

ลำดับ k	รายการ	เกี่ยวข้อง?	rel_k	DCG
1	i_2	✗	0	0
2	i_3	✓	1	0.63
3	i_1	✓	1	0.50
4	i_4	✗	0	0
5	i_5	✗	0	0

$MRR = \frac{1}{2} = 0.50$ (รายการที่ถูกต้องลำดับที่ 2)
$DCG = 0.63 + 0.50 = 1.13$
$IDCG = 1 + 0.63 = 1.63$
$nDCG@5 = \frac{1.13}{1.63} = 0.69$

nDCG มีค่าอยู่ในช่วง 0–1
ยิ่งใกล้ 1 ยิ่งดี

5 AUC: วัดความสามารถในการแยกแยะรายการ

แนวคิด AUC วัดว่าระบบสามารถให้คะแนนรายการที่ผู้ใช้ชอบ (บวก) สูงกว่ารายการที่ไม่ชอบ (ลบ) ได้ดีเพียงใด ค่ามีอยู่ในช่วง 0–1 ยิ่งสูงยิ่งดี

ตัวอย่างการคำนวณ (เปรียบเทียบเป็นคู่)

มีคู่เปรียบเทียบ 3 คู่ จากคะแนนที่ทำนาย

คู่ที่	รายการบวก	รายการลบ	คะแนนบวก	คะแนนลบ	ผล
1	i_1	i_4	0.9	0.4	1
2	i_2	i_5	0.8	0.3	1
3	i_3	i_6	0.7	0.8	0

$AUC = \frac{2}{3} = 0.67$

AUC = 0.5 คือเดาสุ่ม
ถ้ามากกว่า 0.5 แสดงว่าแยกแยะได้ดีกว่าเดาสุ่ม

6 ตัวชี้วัดนอกเหนือความถูกต้อง (Beyond-Accuracy)

แนวคิด ประเมินมุมมองด้านความหลากหลาย ความครอบคลุม ความเป็นธรรม และประสบการณ์ผู้ใช้โดยรวม

Coverage ความครอบคลุมของรายการ
$Coverage = \frac{|I_{rec}|}{|I|}$

Gini ความไม่เท่าเทียมของการแนะนำ
$Gini = 1 - \frac{\sum_{i=1}^{n}(2i-n-1)p(i)}{n-1}$

Novelty แนะนำสิ่งใหม่ ๆ
$Novelty = -\log_2(p(i))$

Calibration ความสอดคล้องระหว่างคะแนนกับพฤติกรรมจริง
เช่น ECE, Brier

Diversity (ILD) ความหลากหลายของรายการที่แนะนำ
$ILD = 1 - \frac{1}{K(K-1)}\sum_{i=j} sim(i,j)$

Fairness ความเป็นธรรมในการแนะนำ
เช่น exposure parity

ตัวอย่างการคำนวณ Coverage

มีรายการทั้งหมด 10 ชิ้น และระบบแนะนำทั้งหมด 6 ชิ้น
$Coverage = \frac{6}{10} = 0.60$

ตัวชี้วัดเหล่านี้ช่วยให้ระบบมีความหลากหลายและเป็นธรรมมากขึ้น ไม่แนะนำแต่รายการเดิม ๆ ซ้ำ ๆ

7 ตัวชี้วัดหลักและตัวชี้วัดกำกับ

แนวคิด ในการพัฒนาระบบ ควรเลือก "ตัวชี้วัดหลัก (Primary)" ที่สอดคล้องกับเป้าหมาย แล้วติดตาม "ตัวชี้วัดกำกับ (Guardrail)" เพื่อป้องกันผลกระทบด้านลบ

ตัวอย่างแดชบอร์ดการประเมิน

Precision@10 (หลัก)	0.68
nDCG@10 (หลัก)	0.62
Coverage (กำกับ)	0.45
Novelty (กำกับ)	0.31
Diversity (กำกับ)	0.58
Fairness (กำกับ)	0.92

ควรพิจารณาหลายตัวชี้วัดร่วมกัน
ไม่ใช้มองแค่ตัวเดียว

8 การทดลองสามระดับ (Offline – User Study – Online)

แนวคิด ควรประเมินระบบแบบเป็นขั้นตอน เพื่อให้มั่นใจว่าระบบทำงานได้ดีทั้งในเชิงตัวชี้วัดและประสบการณ์ผู้ใช้จริง

ระดับที่ 1: ออฟไลน์ (Offline Evaluation)	ระดับที่ 2: การศึกษาผู้ใช้ (User Study)	ระดับที่ 3: ออนไลน์ (Online Experiment)
• ใช้ชุดข้อมูลทดสอบ • คำนวณตัวชี้วัดต่าง ๆ • เปรียบเทียบอัลกอริทึมได้เร็ว	• สัมภาษณ์/แบบสอบถาม • วัดความพึงพอใจ • ประเมินการใช้งานจริง	A B • A/B Test • วัดพฤติกรรมจริง • ดีดตามผลระยะยาว

9 การแบ่งข้อมูลและการรั่วไหลของข้อมูล

แนวคิด การแบ่งข้อมูลอย่างถูกต้องช่วยประเมินได้ใกล้เคียงการใช้งานจริง และป้องกันการรั่วไหลของข้อมูล (Data Leakage)

ตามเวลา (Temporal Split)

Train | Test → เวลา

- ฝึก: อดีต
- ทดสอบ: อนาคต
- เหมาะกับข้อมูลที่มีลำดับเวลา เช่น พฤติกรรมการใช้งาน

แบ่งผู้ใช้ (User Split)

Train users | Test users

- แบ่งกลุ่มผู้ใช้คนละชุด
- ทดสอบการคิ่วไปกับผู้ใช้ใหม่
- ป้องกันการมีพฤติกรรมเดียวกันทั้งชุดฝึกและทดสอบ

รายการใหม่ (New Item Split)

Train items | Test items

- ทดสอบการแนะนำรายการใหม่
- เหมาะกับสถานการณ์ที่มีรายการใหม่เข้ามาตลอด
- ยากกว่าแต่สะท้อนการใช้งานจริง

ข้อควรระวัง: การรั่วไหลของข้อมูล (Data Leakage)

- ข้อมูลในชุดทดสอบไปอยู่ในชุดฝึกโดยไม่ตั้งใจ
- ใช้ข้อมูลอนาคตในการฝึก
- ข้อมูลของผู้ใช้เดียวกันปรากฏทั้งในฝึกและทดสอบ
- ใช้ข้อมูลที่ไม่สามารถเข้าถึงได้จริงในการทดสอบ

สรุปสำคัญ

1. เลือกตัวชี้วัดให้เหมาะกับเป้าหมายของระบบ
2. พิจารณาทั้งความถูกต้องและตัวชี้วัดด้านอื่น ๆ
3. ใช้ตัวชี้วัดหลายตัวร่วมกัน พร้อมตัวชี้วัดกำกับ
4. ออกแบบการทดลองเป็นขั้นตอน ออฟไลน์ → ผู้ใช้ → ออนไลน์
5. แบ่งข้อมูลอย่างถูกต้องและป้องกันการรั่วไหล
6. วิเคราะห์ผลในภาพรวม ไม่ดูแค่ตัวเดียว

ระบบผู้แนะนำอิงเนื้อหา
Content-Based Recommender Systems

เวกเตอร์รายการ โปรไฟล์ผู้ใช้ การจัดลันดับ และตัวอย่างการคำนวณอย่างง่าย

แนะนำรายการที่คล้ายกับสิ่งที่ผู้ใช้เคยชอบ โดยใช้ข้อมูลจาก "เนื้อหาของรายการ" เช่น เครื่า ประเภท คำบรรยาย

1 แนวคิดของระบบผู้แนะนำอิงเนื้อหา

ระบบผู้แนะนำอิงเนื้อหา (Content-Based Recommender) แนะนำรายการที่คล้ายกับรายการที่ผู้ใช้เคยชอบ โดยใช้ข้อมูลจาก "เนื้อหาของรายการ" เช่น ประเภท คำบรรยาย เนื้อเรื่อง หรือคำสำคัญ เหมาะสำหรับรายการใหม่ที่ยังไม่มีผู้ใช้คนอื่นให้ความสนใจ (แก้ปัญหา Item Cold Start)

กระบวนการทำงาน 3 ส่วน

1 เวกเตอร์รายการ (Item Vector)

แปลงเนื้อหารายการเป็นเวกเตอร์ เช่น ประเภท, คำสำคัญ หรือ TF-IDF

2 โปรไฟล์ผู้ใช้ (User Profile)

สรุปความสนใจของผู้ใช้จากรายการที่เคยชอบเป็นเวกเตอร์เดียว

3 การจัดลันดับ (Ranking)

คำนวณความคล้ายและเรียงลำดับรายการที่น่าจะแนะนำ

2 เวกเตอร์แบบ Multi-hot (ตัวอย่างประเภทภาพยนตร์)

แสดงประเภท (Genre) ของภาพยนตร์เป็นเวกเตอร์ 0/1 ถ้ามีประเภทนั้นให้ใส่ 1 ถ้าไม่มีให้ใส่ 0 เรียกว่า Multi-hot vector

ภาพยนตร์	Action	Comedy	Drama	Romance	Sci-Fi
Toy Story	1	0	0	0	0
Coco	0	1	1	0	0
Interstellar	1	0	0	0	1

ตัวอย่างการสร้างเวกเตอร์

Toy Story มีประเภท Action เพียงอย่างเดียว

$$x = [1, 0, 0, 0, 0]$$

เวกเตอร์แบบ Multi-hot เหมาะกับข้อมูลประเภทที่ชัดเจนและเข้าใจง่าย

3 การวัดความคล้าย: โคไซน์ · Jaccard · ยูคลิด

ใช้วัดว่ารายการสองรายการมีลักษณะคล้ายกันมากน้อยเพียงใด

1 โคไซน์ (Cosine)

$$\cos(u, v) = \frac{u \cdot v}{\|u\| \|v\|}$$

ใช้กับข้อมูลเวกเตอร์ที่ค่าอยู่ในช่วงคล้าย ๆ กัน

2 Jaccard

$$\frac{|A \cap B|}{|A \cup B|}$$

เหมาะกับข้อมูลแบบ 0/1 (เซต)

3 ยูคลิด (Euclidean)

$$\text{dist}(u, v) = \sqrt{\sum_i (u_i - v_i)^2}$$

ยิ่งค่าน้อย ยิ่งคล้ายกัน

ตัวอย่างการคำนวณ (Multi-hot)

Toy Story $x = [1,0,0,0,0]$, Coco $y = [0,1,1,0,0]$

1 โคไซน์

$$\cos(x, y) = \frac{0}{1 \times \sqrt{2}} = 0$$

2 Jaccard

$$J(x, y) = \frac{0}{3} = 0$$

3 ยูคลิด

$$\text{dist}(x, y) = \sqrt{3} \approx 1.73$$

4 TF-IDF: น้ำหนักคำและความคล้ายของเอกสาร

ใช้กับข้อมูลข้อความ เช่น คำบรรยายภาพยนตร์ โดยให้คำน้ำหนักกับคำที่สำคัญ

สูตรสำคัญ

$$\text{TF}(t, d) = \frac{f_{t,d}}{|d|} \quad \text{IDF}(t) = \log \frac{N}{df(t)}$$

$$\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t)$$

ตัวอย่างการคำนวณอย่างง่าย

เอกสาร 2 เรื่อง (คำสำคัญ 3 คำ)

คำ	tf-d1	tf-d2	df	IDF
toy	1	0	1	0.477
family	1	1	2	0.176
space	0	1	1	0.477

เวกเตอร์เอกสารและการทำ L2 normalization)

$$v' = \frac{v}{\|v\|_2}, \quad \|v\|_2 = \sqrt{\sum_i v_i^2}$$

จากนั้นใช้โคไซน์ในการวัดความคล้าย

เวกเตอร์ TF-IDF (ยังไม่ทำ normalization)

d1 = [0.477, 0.176, 0]

d2 = [0, 0.176, 0.477]

$$\cos(d1, d2) = \frac{0.176^2}{\sqrt{0.477^2 + 0.176^2}} \approx 0.12$$

5 BM25: ปรับความยาวเอกสารและความอิ่มตัว

BM25 เป็นการพัฒนาจาก TF-IDF โดยปรับผลของความยาวเอกสารและใช้ฟังก์ชันความอิ่มตัวของความถี่คำ (term frequency saturation)

สูตรสำคัญ

$$\text{BM25}(t, d) = \text{IDF}(t) \times \frac{f_{t,d}(k_1 + 1)}{f_{t,d} + k_1\left(1 - b + b\frac{|d|}{\text{avgdl}}\right)}$$

ค่าโดยทั่วไป: $k_1 = 1.2$, $b = 0.75$

ช่วยลดผลกระทบจากเอกสารที่ยาวมากและควบคุมไม่ให้ความถี่คำมีผลมากเกินไป

ตัวอย่างการคำนวณ (ใช้ค่ากำหนดง่าย ๆ)

คำนวณเฉพาะคำ "toy" ในเอกสาร d1

ให้ $f_{toy,d1} = 3$, $|d1| = 100$, avgdl = 100

$k_1 = 1.2$, $b = 0.75$, IDF(toy) = 0.477

BM25(toy, d1)

$$= 0.477 \times \frac{3(1 + 1.2)}{3 + 1.2(1 - 0.75 + 0.75(100))}$$

$$= 0.477 \times \frac{6.6}{5.4} \approx 0.58$$

6 Static Word Embedding: ตัวแทนแบบคำกับแบบความหมาย

ฝังคำของรายการให้เป็นเวกเตอร์หนาแน่น เช่น Word2Vec หรือ GloVe คำที่มีความหมายใกล้กันจะอยู่ใกล้กันในเวกเตอร์ แม้จะไม่ใช่คำเดียวกัน

แบบคำตามตัวอักษร (Lexical)

- ดูจากรูปคำ อาจคล้ายเฉพาะคำที่เหมือนกันเท่านั้น
- เช่น king กับ queen คนละคำ จึงไม่คล้ายในระดับคำ

แบบความหมาย (Semantic)

- เรียนรู้จากบริบทของคำ ทำให้คำที่ความหมายใกล้กันอยู่ใกล้กัน
- เช่น king และ queen มีความหมาย related จึงมีความคล้ายกันสูง

ตัวอย่างเวกเตอร์ 2 มิติ (สมมติ)

king = [0.8, 0.7], queen = [0.78, 0.72]

$$\cos(\text{king}, \text{queen}) = \frac{0.8 \times 0.78 + 0.7 \times 0.72}{\sqrt{0.8^2 + 0.7^2}\sqrt{0.78^2 + 0.72^2}} \approx 0.99$$

7 โปรไฟล์ผู้ใช้: Mean · Mean-centered · Rocchio

สร้างโปรไฟล์ผู้ใช้จากเวกเตอร์ของรายการที่ผู้ใช้ชอบ มีหลายวิธีให้เหมาะกับข้อมูล

1 Mean (ค่าเฉลี่ย)

$$u = \frac{1}{|L|}\sum_{i \in L} v_i$$

เหมาะกับข้อมูลทั่วไป

2 Mean-centered (ปรับค่าเฉลี่ย)

$$u = \frac{1}{|L|}\sum_{i \in L} (v_i - \bar{v})$$

ลดอิทธิพลของคำที่พบได้บ่อย

3 Rocchio (ถ่วงน้ำหนัก)

$$u = \alpha u_0 + \beta \frac{1}{|L^+|}\sum_{i \in L^+} v_i - \gamma \frac{1}{|L^-|}\sum_{j \in L^-} v_j$$

ใช้ทั้งรายการที่ชอบและไม่ชอบ

ตัวอย่างการคำนวณ (2 มิติ, ใช้ Mean)

ผู้ใช้ชอบภาพยนตร์ 2 เรื่อง $v_1 = [1, 0]$, $v_2 = [0, 1]$

$$u = \frac{v_1 + v_2}{2} = \left[\frac{1+0}{2}, \frac{0+1}{2}\right] = [0.5, 0.5]$$

โปรไฟล์ผู้ใช้เป็นตัวแทนความสนใจของผู้ใช้ในพื้นที่เวกเตอร์

8 ข้อดีและข้อจำกัดของระบบผู้แนะนำอิงเนื้อหา

ข้อดี

- ✓ แนะนำรายการที่คล้ายกับสิ่งที่ผู้ใช้เคยชอบได้ดี
- ✓ เหมาะกับรายการใหม่ (Item Cold Start)
- ✓ อธิบายเหตุผลในการแนะนำได้ง่าย (จากเนื้อหา)
- ✓ ไม่ต้องพึ่งพาข้อมูลของผู้ใช้คนอื่น

เหมาะเมื่อมีข้อมูลเนื้อหาของรายการที่ชัดเจน เช่น ประเภท คำบรรยาย หรือคำสำคัญ

ข้อจำกัด

- ✗ แนะนำได้เฉพาะรายการที่คล้ายกับสิ่งที่เคยชอบ อาจพลาดรายการที่หลากหลาย
- ✗ ไม่สามารถค้นพบความสนใจใหม่ ๆ ได้ดี (ความหลากหลายต่ำ)
- ✗ คุณภาพขึ้นกับคุณภาพของข้อมูลเนื้อหา
- ✗ ยังต้องอาศัยการจัดการคำพ้องความหมายและภาษาธรรมชาติ

สรุปสิ่งที่ควรรู้

1. แปลงเนื้อหารายการเป็นเวกเตอร์ (เช่น Multi-hot, TF-IDF, Embedding)
2. สร้างโปรไฟล์ผู้ใช้จากรายการที่ชอบ เช่น Mean, Mean-centered, Rocchio
3. ใช้ความคล้าย (เช่น โคไซน์, Jaccard) เพื่อจัดลันดับและแนะนำรายการ
4. เหมาะกับรายการใหม่ แต่ควรผสมกับวิธีอื่นเพื่อเพิ่มความหลากหลาย

ระบบผู้แนะนำแบบการกรองร่วม
Collaborative Filtering Recommender Systems

แนวคิด เพื่อนบ้าน ปัจจัยแฝง ข้อมูลโดยปริยาย และตัวอย่างการคำนวณอย่างง่าย

ใช้ "ความคล้ายคลึงของผู้ใช้หรือรายการ" จากข้อมูลพฤติกรรมเดิม เพื่อแนะนำสิ่งที่น่าจะชอบ

1 ระบบผู้แนะนำแบบการกรองร่วมคืออะไร?

การกรองร่วม (Collaborative Filtering: CF) เป็นวิธีแนะนำรายการโดยอาศัย "พฤติกรรมในอดีตของผู้ใช้หลายคน" หรือ "ความสัมพันธ์ระหว่างรายการ" โดยไม่ต้องใช้ข้อมูลเนื้อหารายการ (เช่น ข้อความหรือคุณลักษณะสินค้า)

แนวทางหลักของ CF

แบบอิงหน่วยความจำ (Memory-based)
หาเพื่อนบ้าน (kNN) จากความคล้ายคลึงของผู้ใช้หรือรายการ แล้วใช้คะแนนของเพื่อนบ้านมาทำนาย

แบบอิงแบบจำลอง (Model-based)
เรียนรู้แบบจำลองจากข้อมูลทั้งหมด เช่น Matrix Factorization เพื่อทำนายคะแนน

2 เมทริกซ์ผู้ใช้-รายการ และความเบาบางของข้อมูล

ข้อมูลความชอบสามารถแทนด้วยเมทริกซ์ผู้ใช้-รายการ (User-Item Matrix) โดยส่วนใหญ่จะมีค่าที่ทราบเพียงบางส่วน ทำให้ข้อมูลมีความเบาบาง (Sparsity)

ตัวอย่างเมทริกซ์ผู้ใช้-รายการ (8 ผู้ใช้ × 12 รายการ)

	I1	I2	I3	I4	I5	I6	I7	I8	I9	I10	I11	I12
U1	5	3	-	-	4	-	-	-	1	-	-	-
U2	-	4	-	5	-	-	-	2	-	-	-	-
U3	3	-	4	-	-	5	-	-	-	-	4	-
U4	-	-	-	2	4	-	-	-	-	3	-	-
U5	4	-	-	-	-	-	5	-	-	-	-	1
U6	-	5	-	-	-	3	-	-	-	-	2	-
U7	-	-	2	-	-	-	4	-	-	-	-	-
U8	1	-	-	-	-	-	-	3	-	5	-	-

ความเบาบาง (Sparsity)

ในตัวอย่างนี้ มีคะแนนที่ทราบทั้งหมด 32 ค่า จากทั้งหมด 8 × 12 = 96 ช่อง

$$\text{Density} = \frac{32}{8 \times 12} = 0.3333 \approx 33.3\%$$

ดังนั้นข้อมูลเบาบางประมาณ **66.7%**

3 ขั้นตอนแนวคิดของการกรองร่วม

การสร้างคำแนะนำด้วย CF มักประกอบด้วย 4 ขั้นตอนหลัก

1 แทนข้อมูล (Represent)

สร้างเมทริกซ์ผู้ใช้-รายการจากพฤติกรรม เช่น การให้คะแนน การคลิก หรือการซื้อ

2 วัดความคล้ายคลึง (Measure Similarity)

หาความคล้ายกันของผู้ใช้ หรือความคล้ายกันของรายการ

3 ทำนายคะแนน (Predict Score)

ใช้คะแนนของเพื่อนบ้านหรือแบบจำลองเพื่อทำนายคะแนนรายการที่ยังไม่เคยมี

4 จัดลำดับ (Rank Top-K)

เลือก Top-K รายการที่คาดว่าจะชอบและแนะนำให้ผู้ใช้

4 User-kNN: หาเพื่อนบ้านจากผู้ใช้ที่คล้ายกัน

ความคล้ายคลึงของผู้ใช้ (เช่น Pearson)

$$sim(u, v) = \frac{\sum (r_{u,i} - \bar{r}_u)(r_{v,i} - \bar{r}_v)}{\sqrt{\sum (r_{u,i} - \bar{r}_u)^2} \sqrt{\sum (r_{v,i} - \bar{r}_v)^2}}$$

หรือใช้ Adjusted Cosine ก็ได้

ตัวอย่างความคล้ายคลึง

ผู้ใช้	sim(u, a)	sim(u, b)
u (ผู้ใช้เป้าหมาย)	-	-
a	0.9	-
b	0.6	-

ทำนายคะแนนด้วยเพื่อนบ้านแบบถ่วงน้ำหนัก

$$\hat{r}_{u,i} = \frac{\sum_{v \in N(u)} sim(u, v) \cdot r_{v,i}}{\sum_{v \in N(u)} |sim(u, v)|}$$

ตัวอย่างการคำนวณ

ผู้ใช้ u ยังไม่เคยให้คะแนนรายการ i มีเพื่อนบ้าน a และ b ให้คะแนน 5 และ 3

$$\hat{r}_{u,i} = \frac{0.9 \times 5 + 0.6 \times 3}{0.9 + 0.6} = \frac{6.3}{1.5} = 4.20$$

ผู้ใช้ที่มีรสนิยมคล้ายกัน มักชอบรายการที่คล้ายกัน!

5 Item-kNN: หาเพื่อนบ้านจากรายการที่คล้ายกัน

ความคล้ายคลึงของรายการ (เช่น Cosine)

$$sim(i, j) = \frac{r_i \cdot r_j}{\| r_i \| \, \| r_j \|}$$

ตัวอย่างความคล้ายคลึงระหว่างรายการ

รายการ	sim(i, j)
i (รายการเป้าหมาย)	-
j1	0.8
j2	0.5

ทำนายคะแนนจากรายการที่คล้ายกัน

$$\hat{r}_{u,i} = \frac{\sum_{j \in N(i)} sim(i, j) \cdot r_{u,j}}{\sum_{j \in N(i)} |sim(i, j)|}$$

ตัวอย่างการคำนวณ

ผู้ใช้ u เคยให้คะแนนรายการ j1 = 4 และ j2 = 2

$$\hat{r}_{u,i} = \frac{0.8 \times 4 + 0.5 \times 2}{0.8 + 0.5} = \frac{4.2}{1.3} = 3.23$$

รายการที่คล้ายกันมักถูกชอบโดยผู้ใช้คนเดียวกัน

6 โมเดลฐานนิยม (Bias / Baseline Model)

ปรับคะแนนด้วยค่าเฉลี่ยรวม และความเอนเอียงของผู้ใช้และรายการ เพื่อให้การทำนายแม่นยำขึ้น

$$\hat{r}_{u,i} = \mu + b_u + b_i$$

- μ : ค่าเฉลี่ยคะแนนทั้งหมด
- b_u : ค่าเอนเอียงของผู้ใช้ (ผู้ใช้ให้คะแนนสูง/ต่ำกว่าปกติ)
- b_i : ค่าเอนเอียงของรายการ (รายการเป็นที่นิยมนิยมต่ำ)

ตัวอย่างการคำนวณ

กำหนด $\mu = 3.5$, $b_u = 0.4$ (ผู้ใช้มักให้คะแนนสูง), $b_i = 0.5$ (รายการเป็นที่นิยม)

$$\hat{r}_{u,i} = 3.5 + 0.4 + 0.5 = 4.4$$

โมเดลฐานนิยมช่วยแก้ปัญหาความเอนเอียงของผู้ใช้และรายการได้อย่างมีประสิทธิภาพ

7 โมเดลปัจจัยแฝง (Latent Factor Models)

เรียนรู้ตัวแทนเชิงหนาแน่นของผู้ใช้และรายการในมิติปัจจัยแฝง (latent factors) เช่น Matrix Factorization (MF) โดยทำนายคะแนนจากผลคูณจุด (dot product)

แนวคิด Matrix Factorization

$$\hat{r}_{u,i} = \boldsymbol{p}_u \cdot \boldsymbol{q}_i + b_u + b_i$$

- $\boldsymbol{p}_u$: เวกเตอร์ปัจจัยแฝงของผู้ใช้ (ขนาด k)
- $\boldsymbol{q}_i$: เวกเตอร์ปัจจัยแฝงของรายการ (ขนาด k)

ตัวอย่างการคำนวณ (k = 2)

$\boldsymbol{p}_u = [0.8, 0.2]$, $\boldsymbol{q}_i = [0.9, 0.1]$

$\boldsymbol{p}_u \cdot \boldsymbol{q}_i = 0.8 \times 0.9 + 0.2 \times 0.1 = 0.72 + 0.02 = 0.74$

คะแนนที่ทำนาย (ไม่รวมโบนัส) ≈ 0.74

วิธีการเรียนรู้พารามิเตอร์

SGD (Stochastic Gradient Descent)
- อัปเดตพารามิเตอร์จากตัวอย่างทีละรายการ

$$p_u \leftarrow p_u - \eta \frac{\partial L}{\partial p_u}$$

ALS (Alternating Least Squares)
- สลับแก้ทีละฝั่ง (ผู้ใช้/รายการ) ด้วยการแก้ปัญหากำลังสองน้อยที่สุด

$$p_u = (Q^T Q + \lambda I)^{-1} Q^T r_u$$

SVD++
- ใช้ข้อมูลโดยปริยาย (implicit feedback) ร่วมด้วย

$$\hat{r}_{u,i} = \boldsymbol{p}_u \cdot \boldsymbol{q}_i + y_i \cdot \frac{1}{\sqrt{|N(u)|}} \sum_{j \in N(u)} y_j$$

8 โมเดลข้อมูลโดยปริยาย (Implicit Feedback Models)

ใช้กับข้อมูลพฤติกรรมที่ไม่มีคะแนนชัดเจน เช่น การคลิก การดู หรือการซื้อ

WRMF (Weighted Regularized MF)

กำหนดความมั่นใจ (confidence) ให้กับพฤติกรรมโดยปริยาย และเรียนรู้ด้วย ALS

$$\min_{P,Q} \sum c_{u,i} (\boldsymbol{p}_u \cdot \boldsymbol{q}_i - r_{u,i})^2 + \lambda(\|P\|^2 + \|Q\|^2)$$

ตัวอย่าง: ถ้าผู้ใช้คลิกรายการให้ $c_{u,i} = 5$ (มั่นใจมาก)
ไม่คลิกให้ $c_{u,i} = 0.1$ (มั่นใจน้อย)

BPR (Bayesian Personalized Ranking)

เรียนรู้ให้รายการที่ผู้ใช้ชอบมีคะแนนมากกว่ารายการที่ไม่ชอบด้วยการเปรียบเทียบเป็นคู่

$$L = -\sum_{(u,i,j)} \ln \sigma(x_{u,i} - x_{u,j})$$

ตัวอย่าง: $x_{u,i} = 0.8$, $x_{u,j} = 0.6$

$x_{u,i} - x_{u,j} = 0.22$

$\sigma(0.22) = \frac{1}{1 + e^{-0.22}} \approx 0.555$

EASE (Embarrassingly Shallow Autoencoder)

เรียนรู้ความสัมพันธ์ระหว่างรายการด้วยโมเดลเชิงเส้นที่ไม่ใช้ปัจจัยแฝง เหมาะกับข้อมูลขนาดใหญ่

$$\hat{R} = RB, \quad B = (G + \lambda I)^{-1} G - I$$

ตัวอย่าง: หากได้ค่าน้ำหนักความสัมพันธ์ $w_{k,j} = 0.3$ และผู้ใช้ u มีพฤติกรรมข้อ j = 1
คะแนนทำนาย $\hat{r}_{u,i} = 0.3 \times 1 = 0.3$

9 การประเมินผลและการเลือกโมเดล

สรุป ตัวชี้วัดที่ใช้บ่อย

MAE	RMSE	Precision@K	Recall@K	nDCG@K
ค่าเฉลี่ยความคลาดเคลื่อนของคะแนน (ยิ่งต่ำยิ่งดี)	ลงโทษความคลาดเคลื่อนขนาดใหญ่มากขึ้น	สัดส่วนรายการที่แนะนำที่ผู้ใช้ชอบ	สัดส่วนรายการที่ผู้ใช้ชอบที่ถูกแนะนำ	คำนึงถึงตำแหน่งรายการ (ยิ่งสูงยิ่งดี)

การเลือกใช้โมเดล

- ✓ ข้อมูลคะแนนชัดเจน → ใช้ kNN หรือ Matrix Factorization
- ✓ ข้อมูลโดยปริยายขนาดใหญ่ → ใช้ WRMF, BPR หรือ EASE
- ✓ ต้องการความแม่นยำสูง → โมเดลปัจจัยแฝง (MF)
- ✓ ต้องการอธิบายได้ง่าย → kNN หรือโมเดลฐานนิยม

ไม่มีโมเดลใดที่ดีที่สุดเสมอ ให้เลือกตามลักษณะข้อมูลและเป้าหมายการใช้งานค่ะ

10 สรุปสาระสำคัญ

1. CF ใช้ความคล้ายคลึงของผู้ใช้หรือรายการเพื่อแนะนำ
2. ข้อมูลผู้ใช้-รายการมักเบาบาง ต้องเลือกวิธีที่เหมาะสม
3. มีทั้งแบบอิงหน่วยความจำและแบบอิงแบบจำลอง
4. โมเดลปัจจัยแฝงและโมเดลข้อมูลโดยปริยายช่วยเพิ่มความแม่นยำ
5. ประเมินผลด้วย MAE, RMSE, Precision@K, Recall@K, nDCG@K
6. เลือกโมเดลตามข้อมูลและโจทย์การใช้งาน

ระบบผู้แนะนำแบบผสาน
Hybrid Recommender Systems

ระบบผสาน 7 แบบของ Burke การผสานระดับคุณลักษณะ และตัวอย่างการคำนวณอย่างง่าย

การผสานหลายวิธี ช่วยให้ระบบผู้แนะนำ แม่นยำ ครอบคลุม และใช้งานได้จริง ในสถานการณ์ต่าง ๆ

1 ทำไมต้องใช้ระบบผู้แนะนำแบบผสาน ?

แต่ละวิธีมีจุดแข็งและข้อจำกัดแตกต่างกัน การผสานหลายวิธี ช่วยลดข้อจำกัด และให้ผลลัพธ์ที่ดีกว่าเดิม

ปัญหาที่ช่วยแก้ไขได้

- **ความแม่นยำ (Accuracy)** — คาดะแนะนำได้ตรงความสนใจมากขึ้น
- **การครอบคลุม (Coverage)** — แนะนำรายการได้หลากหลายมากขึ้น
- **ความหลากหลาย (Diversity)** — หลีกเลี่ยงการแนะนำรายการเดิม ๆ
- **ปัญหาเริ่มต้น (Cold-start)** — แนะนำได้แม้ข้อมูลผู้ใช้/รายการยังน้อย

2 แนวคิดของระบบผู้แนะนำแบบผสาน

นำจุดแข็งของวิธีต่าง ๆ มาผสานกัน ทั้งในระดับคะแนน ระดับคุณลักษณะ ระดับการตัดสินใจ หรือระดับโมเดล เพื่อให้ได้ระบบที่มีประสิทธิภาพและยืดหยุ่น

วิธีที่ 1 เช่น Content-based (วิเคราะห์เนื้อหา) + **วิธีที่ 2** เช่น Collaborative (พฤติกรรมผู้ใช้) → **ระบบผู้แนะนำแบบผสาน**

- แม่นยำมากขึ้น
- ครอบคลุมมากขึ้น
- หลากหลายมากขึ้น
- ใช้งานได้ในข้อมูลน้อย

ไม่มีวิธีใดดีที่สุด แต่การผสานช่วยให้ได้ผลลัพธ์ที่ดีกว่าในหลายสถานการณ์

3 ระบบผู้แนะนำแบบผสาน 7 แบบของ Burke

Burke (2002) เสนอวิธีการผสาน 7 แบบ ซึ่งสามารถประยุกต์ใช้ได้กับระบบแนะนำหลากหลายประเภท

1 Weighted Hybrid (ผสานแบบถ่วงน้ำหนัก)

รวมคะแนนจากหลายวิธีด้วยน้ำหนักที่กำหนด เหมาะเมื่อวิธีต่าง ๆ ให้คะแนนในสเกลเดียวกัน

$$\hat{y} = w \cdot s_{CB} + (1 - w) \cdot s_{CF}$$

ตัวอย่างการคำนวณ

รายการ A: $s_{CB} = 0.8$, $s_{CF} = 0.6$

กำหนด $w = 0.7$

$\hat{y} = 0.7 \times 0.8 + 0.3 \times 0.6$

$= 0.56 + 0.18 = \mathbf{0.74}$

2 Switching Hybrid (ผสานแบบเลือกวิธี)

เลือกใช้วิธีที่เหมาะสมตามเงื่อนไข เช่น ความหนาแน่นของข้อมูล หรือประเภทผู้ใช้

ตัวอย่างกฎการเลือก

- ถ้าผู้ใช้ใหม่ (ข้อมูลน้อย) → ใช้ Content-based
- ถ้ามีข้อมูลมาก → ใช้ Collaborative

ตัวอย่าง

ผู้ใช้ U1 มีประวัติเพียง 1 รายการ (น้อยกว่า 5) → เลือกใช้ Content-based

ผู้ใช้ U2 มีประวัติ 20 รายการ → เลือกใช้ Collaborative

3 Mixed Hybrid (ผสานแบบผสมรายการ)

รวมรายการแนะนำจากหลายวิธี แล้วจัดลับหรือรวมกันในผลลัพธ์เดียว

ตัวอย่าง: สลับรายการ (Interleaving)

รายการจาก CB	รายการจาก CF	ผลลัพธ์
1. A	1. D	1. A (CB)
2. B	2. E	2. D (CF)
3. C	3. F	3. B (CB)
	สลับรายการ	4. E (CF)
		5. C (CB)
		6. F (CF)

ตัวอย่าง: Reciprocal Rank Fusion (RRF)

$$score(d) = \sum_{m} \frac{1}{k + rank_m(d)}$$

กำหนด $k = 60$, รายการ A อยู่ลำดับ 2 ใน CB และลำดับ 5 ใน CF

$$score(A) = \frac{1}{(60+2)} + \frac{1}{(60+5)}$$

$$= 0.0164 + 0.0159 = \mathbf{0.0323}$$

4 Feature Combination (ผสานระดับคุณลักษณะ)

รวมคุณลักษณะจากหลายแหล่งเป็นชุดเดียวกัน แล้วใช้โมเดลเดียวในการเรียนรู้

- **คุณลักษณะจากเนื้อหา** เช่น ประเภท คำสำคัญ
- **คุณลักษณะจากพฤติกรรม** เช่น การคลิก ประวัติการดู

→ **รวมเป็นชุดคุณลักษณะ (feature vector เดียว)**

→ **ใช้โมเดลเดียว** เช่น Logistic Regression, Factorization Machine, หรือโมเดลเชิงลึก

5 Feature Augmentation (ผสานโดยเพิ่มคุณลักษณะ)

ใช้ผลลัพธ์จากอีกวิธีหนึ่งเป็นคุณลักษณะเพิ่มเติม เช่น เพิ่มคะแนนจาก CF เป็นฟีเจอร์ในโมเดล CB

ตัวอย่าง

คุณลักษณะเดิมของรายการ (เนื้อหา) + คุณลักษณะเพิ่มเติม เช่น คะแนนจาก CF หรือจำนวนการคลิก → **ชุดฟีเจอร์ใหม่สำหรับโมเดล เช่น LightFM**

LightFM เป็นตัวอย่างโมเดลที่รองรับการผสานคุณลักษณะของผู้ใช้ รายการ และเนื้อหาในแบบเดียวกัน

6 Cascade Hybrid (ผสานแบบลำดับขั้น)

ใช้วิธีหนึ่งกรองรายการในขั้นแรก (เร็ว) แล้วใช้อีกวิธีจัดอันดับในขั้นถัดมา (แม่นยำ)

ขั้นที่ 1: กรองเบื้องต้น (Recall) — ใช้วิธีที่เร็ว เช่น Content-based หรือ Two-tower คัดเลือก top-N (เช่น 500 รายการ)

ขั้นที่ 2: จัดอันดับซ้ำ (Rerank) — ใช้วิธีที่แม่นยำกว่า เช่น Collaborative หรือโมเดลเชิงลึก จัดอันดับ top-K (เช่น 10 รายการ)

ช่วยลดเวลาในการคำนวณ และยังได้ผลลัพธ์ที่มีคุณภาพดี

7 Meta-level Hybrid (ผสานระดับเมตา)

ใช้ผลลัพธ์จากวิธีหนึ่งเป็นตัวแทนผู้ใช้/รายการ แล้วนำไปเป็นอินพุตให้กับอีกวิธีหนึ่ง

ตัวอย่าง: ใช้โปรไฟล์จาก Content-based เพื่อเป็นอินพุตให้ Collaborative

โปรไฟล์ผู้ใช้จาก CB เช่น เวกเตอร์ความสนใจจากเนื้อหาที่รอบ → นำไปเป็นอินพุตให้โมเดล CF → โมเดล CF เรียนรู้ความคล้ายจากความสนใจที่ได้จาก CB

แนวคิดนี้ใช้ได้ทั้งการใช้โปรไฟล์ผู้ใช้ หรือการใช้ตัวแทนของรายการ (item representation)

4 สรุปเปรียบเทียบระบบผู้แนะนำแบบผสาน 7 แบบ

แบบที่	ชื่อวิธี (อังกฤษ)	แนวคิดหลัก	จุดเด่น	เหมาะกับสถานการณ์	ตัวอย่าง/เทคนิค
1	Weighted	รวมคะแนนด้วยน้ำหนัก	ง่าย ยืดหยุ่น	วิธีต่าง ๆ ให้คะแนนในสเกลเดียวกัน	Linear weight, grid search
2	Switching	เลือกวิธีตามเงื่อนไข	เหมาะกับสถานการณ์ต่าง ๆ	ข้อมูลผู้ใช้แตกต่างกัน (เช่น ผู้ใช้ใหม่)	กฎจากความหนาแน่นของข้อมูล
3	Mixed	รวมรายการและสลับผลลัพธ์	เพิ่มความหลากหลาย	ต้องการความหลากหลายของรายการ	Interleaving, RRF
4	Feature Combination	รวมคุณลักษณะหลายแหล่ง	ใช้โมเดลเดียว เรียนรู้ร่วมกัน	มีคุณลักษณะจากหลายแหล่ง	Logistic Regression, FM, LightFM
5	Feature Augmentation	เพิ่มคุณลักษณะจากอีกวิธี	ใช้ข้อมูลจากหลายวิธี	ต้องการใช้ประโยชน์จากผลลัพธ์เดิม	เพิ่มคะแนนจาก CF เป็นฟีเจอร์
6	Cascade	กรองก่อน จัดอันดับทีหลัง	เร็วและแม่นยำ	มีรายการจำนวนมาก	Two-stage: Retrieve & Rerank
7	Meta-level	ใช้ผลลัพธ์เป็นอินพุตอีกวิธี	ยืดหยุ่นสูง	ต้องการให้โมเดลเรียนรู้จากกันและกัน	ใช้โปรไฟล์จาก CB → เป็นอินพุตให้ CF

5 ตัวอย่างโมเดลแบบผสานยุคใหม่ (ระดับโมเดล)

นอกจากวิธีพื้นฐานของ Burke ยังมีโมเดลสมัยใหม่ที่ผสานหลายแหล่งข้อมูลในตัวโมเดล

LightFM	ผสานคุณลักษณะของผู้ใช้ รายการ และเนื้อหาในโมเดลเดียว (Feature-level) รองรับข้อมูลแบบบาง (sparse)
LightGCN	ใช้กราฟความสัมพันธ์ของผู้ใช้-รายการ ผสานสัญญาณจากโครงสร้างกราฟ เหมาะกับข้อมูลเชิงปฏิสัมพันธ์
Two-tower (Deep Retrieval)	เรียนรู้เวกเตอร์ผู้ใช้และรายการจากหลายแหล่งคุณลักษณะ (เช่น เนื้อหาและพฤติกรรม) แล้วหาความคล้ายกัน

6 สรุปสาระสำคัญ

- ระบบผู้แนะนำแบบผสานช่วยแก้ปัญหาความแม่นยำ การครอบคลุม ความหลากหลาย และปัญหาเริ่มต้น
- มี 7 แบบหลักของ Burke ที่ครอบคลุมการผสานในระดับคะแนน รายการ คุณลักษณะ การตัดสินใจ และเมตา
- สามารถประยุกต์ใช้กับโมเดลสมัยใหม่ เช่น LightFM, LightGCN และ Two-tower
- เลือกวิธีผสานให้เหมาะกับข้อมูลและเป้าหมายของระบบ จะช่วยให้ได้ผลลัพธ์ที่ดีกว่าเดิม

การผสานหลายวิธี ช่วยให้ระบบผู้แนะนำ ทั้งแม่นยำ หลากหลาย และใช้งานได้จริงในโลกจริง!

แบบจำลองภาษาขนาดใหญ่กับระบบผู้แนะนำ
Large Language Models and Generative Recommendation

จากผู้ใช้สู่ผู้สร้างระบบ กระบวนการทำงาน การเชื่อมกับ CB/CF/Hybrid และการประเมิน

ใช้พลังของ LLM เพื่อเข้าใจผู้ใช้ สร้างคำแนะนำที่ดีขึ้น และอธิบายเหตุผลได้อย่างเป็นธรรมชาติ

1 ทำไม LLMs จึงสำคัญกับระบบผู้แนะนำ?

LLMs ช่วยเพิ่มความสามารถให้ระบบผู้แนะนำ ให้เข้าใจข้อมูลและผู้ใช้ได้ลึกขึ้น พร้อมอธิบายเหตุผลด้วยภาษาที่เป็นธรรมชาติ

อ่านและเข้าใจข้อมูลรายการ (Item)

เข้าใจเนื้อหาข้อความยาวๆ เช่น เรื่องย่อ รีวิว บทความ คุณสมบัติสินค้า และสรุปความหมายได้

เข้าใจความต้องการของผู้ใช้

ตีความคำขอที่เป็นภาษาธรรมชาติ เช่น "อยากดูหนังเบาๆ แนวอบอุ่นหัวใจ ไม่เครียด" แม้จะไม่ระบุคำตัดชัดเจน

อธิบายเหตุผลของคำแนะนำ

สร้างคำอธิบายว่าทำไมถึงแนะนำรายการนี้ ด้วยภาษาที่เข้าใจง่าย เพิ่มความน่าเชื่อถือ

2 จากผู้ใช้แชต สู่ผู้สร้างระบบ

เมื่อพัฒนาระบบ เราต้องแยกว่าอะไรให้ LLM ทำผ่าน Prompt และอะไรที่ต้องจัดการด้วยโปรแกรมเอง

สิ่งที่ใส่ใน Prompt ให้ LLM

- คำขอของผู้ใช้ (ภาษาธรรมชาติ)
- ข้อมูลรายการที่คัดเลือกมาแล้ว
- คำสั่งงาน เช่น ให้จัดอันดับ และอธิบายเหตุผล
- รูปแบบผลลัพธ์ที่ต้องการ

สิ่งที่ต้องจัดการด้วยโปรแกรมเอง

- การดึงข้อมูลผู้ใช้และรายการจากฐานข้อมูล
- การสร้างชุดผู้สมัคร (Candidate Set) ด้วยวิธี CB / CF / Hybrid
- การควบคุมกฎธุรกิจและความปลอดภัย เช่น การกรองเนื้อหา
- การประเมินผล และการวัดคุณภาพ

3 ภาพรวมการทำงานของระบบ (Workflow)

การใช้ LLM ในระบบผู้แนะนำ มักทำงานร่วมกับวิธีดั้งเดิมเป็นลำดับขั้น

1 คำขอจากผู้ใช้ (User Request)

"อยากดูหนังอบอุ่นหัวใจ แนวครอบครัว ไม่เครียดมาก"

ภาษาธรรมชาติ

2 สร้างชุดผู้สมัคร (Candidate Set)

ดึงรายการเบื้องต้นจาก CB / CF / Hybrid ได้รายการหลายสิบ/ร้อยรายการ

3 ให้ LLM เข้าใจ จัดอันดับ และสร้างคำอธิบาย

- เข้าใจความต้องการของผู้ใช้
- พิจารณาข้อมูลรายการ
- จัดอันดับ (Rerank)
- สร้างคำอธิบายเหตุผล

4 ผลลัพธ์การแนะนำ (Final Recommendation)

1. แนะนำรายการที่ดีที่สุด ★★★★★
2. ★★★★
3. ★★★★

4 การเชื่อมกับระบบ Content-Based (CB)

LLM ช่วยเข้าใจเนื้อหาของรายการ และจับคู่กับความต้องการของผู้ใช้

ข้อมูลเนื้อหาของรายการ

- เรื่องย่อ
- คำอธิบายสินค้า
- รีวิว
- แท็ก/คุณสมบัติ

→ LLM →

แปลงเป็นความหมาย (เช่น สรุปหัวข้อ / คำสำคัญ)

อบอุ่นหัวใจ | ครอบครัว | สร้างแรงบันดาลใจ | ไม่เครียด

ทำให้การจับคู่รายการกับความต้องการของผู้ใช้ แม้จะไม่มีคำซ้ำกัน ก็สามารถหาเนื้อหาที่เหมาะสมได้

5 การเชื่อมกับ Collaborative Filtering (CF)

LLM ช่วยใช้ข้อมูลพฤติกรรมของผู้ใช้และผู้ใช้ที่คล้ายกัน ในการตีความความต้องการและจัดอันดับ

ข้อมูลพฤติกรรมผู้ใช้ เช่น ดู/ซื้อ/ให้คะแนน

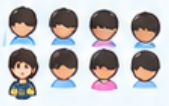

→ LLM →

- เข้าใจว่าผู้ใช้กลุ่มนี้ชอบอะไร
- จัดอันดับรายการจากความสอดคล้องกับความสนใจของผู้ใช้ และผู้ใช้ที่คล้ายกัน

ช่วยอธิบายเหตุผลได้ว่า "รายการนี้แนะนำเพราะผู้ใช้ที่มีรสนิยมคล้ายคุณชอบรายการนี้"

6 การเชื่อมกับ Hybrid Systems

ผสมผสานข้อดีของหลายวิธี โดยใช้ LLM เป็นตัวเชื่อมความหมายจากเนื้อหาและพฤติกรรมผู้ใช้

- Content-Based (เนื้อหา)
- Collaborative (พฤติกรรมผู้ใช้)

→ LLM →

- ✓ รวมสัญญาณจากหลายแหล่ง
- ✓ เข้าใจบริบทของผู้ใช้
- ✓ จัดอันดับรายการใหม่
- ✓ สร้างคำอธิบายที่สอดคล้อง

ทำให้ได้คำแนะนำที่แม่นยำขึ้น หลากหลายขึ้น และอธิบายได้อย่างเป็นธรรมชาติ

7 ความสามารถใหม่ของ LLMs ในระบบผู้แนะนำ

นอกจากการจัดอันดับ LLM ยังช่วยเพิ่มความสามารถสำคัญ 3 ด้าน

1 สร้างโค้ด (Generate Code)

ช่วยสร้างโค้ดตัวอย่างสำหรับการเรียกใช้ API การเตรียมข้อมูล หรือการพัฒนาระบบต้นแบบ

```
# ตัวอย่างโค้ดเรียก LLM
response = llm.chat(
    user_request,
    candidate_items,
    top_k=3
)
```

2 รองรับการสนทนา (Support Conversation)

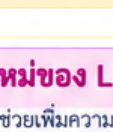

เข้าใจบริบทการสนทนาต่อเนื่อง สนทนาเหมือนผู้ช่วยส่วนตัว ปรับคำแนะนำตามคำถามเพิ่มเติมได้

อยากได้แนวอื่นอีกได้ไหม?

ได้เลย! ถ้าคุณชอบแนวอบอุ่น ลองดูแนวโรแมนติกคอมเมดี้ไหม?

ขอที่มีผู้กำกับคนเดียวกันด้วย

3 อธิบายเหตุผลด้วยภาษาธรรมชาติ

สร้างคำอธิบายที่ชัดเจน อ่านง่าย ทำให้ผู้ใช้เข้าใจ และเชื่อมั่นในคำแนะนำ

ตัวอย่างคำอธิบาย

แนะนำเรื่องนี้เพราะเป็นภาพยนตร์แนวครอบครัวที่อบอุ่นหัวใจ เนื้อหาเบาสบาย เหมาะกับการดูในวันพักผ่อน และผู้ใช้ที่มีความสนใจคล้ายคุณก็ชื่นชอบเรื่องนี้

8 การประเมินผลและข้อควรพิจารณา

การใช้ LLM ต้องคำนึงถึงคุณภาพ ค่าใช้จ่าย ความหน่วง และความเสี่ยง พร้อมเลือกใช้ให้เหมาะสมกับงาน

1 คุณภาพของคำแนะนำ

- ✓ ความเกี่ยวข้องกับความต้องการ
- ✓ ความหลากหลายของรายการ
- ✓ ความพึงพอใจของผู้ใช้

1 ค่าใช้จ่าย (Cost)

- คำบริการ API ตามจำนวนโทเคน
- คุมขนาด Prompt ให้เหมาะสม
- ใช้เฉพาะขั้นตอนที่จำเป็น

4 ความหน่วงเวลา (Latency)

- เวลาตอบกลับของโมเดล
- อาจช้ากว่าระบบเดิม
- ใช้เทคนิค เช่น Cache, Streaming, เรียกเฉพาะตอนที่จำเป็น

A ความเสี่ยง Hallucination

- อาจสร้างข้อมูลที่ไม่ถูกต้อง
- ควรตรวจสอบกับข้อมูลจริง
- ใช้การกรองและกฎความปลอดภัย
- ไม่ควรใช้แทนข้อเท็จจริงที่สำคัญ

ตัวอย่างการจัดอันดับด้วย LLM (ง่าย ๆ)

ผู้ใช้: "อยากดูหนังอบอุ่นหัวใจ แนวครอบครัว ไม่เครียดมาก"

ชุดผู้สมัครจาก CB/CF (บางส่วน)

A. ครอบครัวตัวป่วน (แนวครอบครัว/คอม)

B. โลกการ์ตูนมหัศจรรย์ (แนวผจญภัย)

C. ความน่ากลัว (แนวความน่ากลัว/จริงจัง)

คะแนนความเหมาะสม

รายการ	CB Score (เนื้อหา)	CF Score (พฤติกรรม)	LLM Rerank (ความสอดคล้อง)	
A. ครอบครัวตัวป่วน	0.80	0.60	0.92	1
B. โลกการ์ตูนมหัศจรรย์	0.70	0.50	0.68	2
C. ความน่ากลัว	0.30	0.40	0.25	3

ผลการแนะนำหลัง LLM จัดอันดับ

A. ครอบครัวตัวป่วน ★★★★★

"แนะนำเพราะเป็นแนวครอบครัวที่อบอุ่นหัวใจ เนื้อหาเบาสบาย เหมาะกับการดูในวันพักผ่อน และผู้ใช้ที่มีความสนใจคล้ายคุณก็ชื่นชอบเรื่องนี้

สรุปสิ่งสำคัญ

1. LLM ช่วยให้ระบบผู้แนะนำเข้าใจข้อมูลและผู้ใช้ได้ลึกขึ้น และอธิบายเหตุผลได้
2. แยกระหว่าง Prompt กับโปรแกรม เพื่อออกแบบระบบที่เหมาะสม
3. ทำงานร่วมกับ CB/CF/Hybrid ผ่านกระบวนการ Rerank
4. เพิ่มความสามารถใหม่ทั้งสร้างโค้ด รองรับการสนทนา และอธิบายเหตุผล
5. ประเมินคุณภาพ ค่าใช้จ่าย ความหน่วง และความเสี่ยง เลือกใช้ให้เหมาะสม

ระบบผู้แนะนำที่รับผิดชอบ
Responsible Recommender Systems

นิยาม วัด แก้ ตรวจสอบ อคติ ความเป็นธรรม ความหลากหลาย และการกำกับดูแล

ระบบผู้แนะนำ ควรแนะนำสิ่งที่ดี มีประโยชน์ หลากหลาย เป็นธรรม และโปร่งใส เพื่อผู้ใช้และสังคมที่ดีขึ้น

1 ทำไมความแม่นยำอย่างเดียวไม่พอ?

ระบบผู้แนะนำที่แม่นยำอาจยังมีปัญหา เช่น แนะนำแต่รายการยอดนิยม ซ้ำ ๆ ไม่หลากหลาย หรือไม่เป็นธรรมกับผู้ใช้บางกลุ่ม และอาจส่งผลกระทบต่อสังคม การตัดสินจึงต้องพิจารณามากกว่าแค่ “ความแม่นยำ”

ตัวอย่าง: แม่นยำแต่มีปัญหา

ระบบแนะนำ แต่หนังดังยอดนิยมตลอด ทั้งที่ก็แม่นยำ

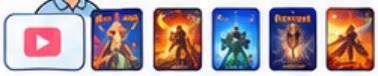

- ✕ รายการซ้ำ ๆ
- ✕ ไม่หลากหลาย
- ✕ ผู้ใช้กลุ่มอื่นถูกมองข้าม
- ✕ สร้างฟองข้อมูล (Filter Bubble)

2 วงจร 4 ขั้น: นิยาม → วัด → แก้ → ตรวจสอบ

แนวทางการพัฒนาระบบผู้แนะนำที่รับผิดชอบอย่างต่อเนื่อง

1 นิยาม (Define)

กำหนดปัญหาและเป้าหมาย เช่น ความเป็นธรรม ความหลากหลาย ความปลอดภัย

2 วัด (Measure)

เลือกตัวชี้วัดที่เหมาะสม และประเมินอย่างเป็นระบบ

3 แก้ (Mitigate)

ใช้เทคนิคและแนวทางต่าง ๆ เพื่อลดปัญหาและปรับปรุง

4 ตรวจสอบ (Audit)

ตรวจประเมินผลอย่างสม่ำเสมอ และติดตามในระยะยาว

วนซ้ำอย่างต่อเนื่อง เพื่อให้ระบบดีขึ้นและเป็นประโยชน์ต่อทุกคน

ไม่ใช่แค่สร้างแล้วจบ แต่ต้องวัด แก้ และตรวจสอบตลอดเวลานะคะ !

3 ปัญหาหลักของระบบผู้แนะนำ

แม้ระบบจะทำงานได้ดี แต่ยังอาจเกิดปัญหาต่อไปนี้

อคติจากความนิยม (Popularity Bias)

- แนะนำแต่รายการยอดนิยม
- รายการที่ไม่ดังถูกมองข้าม
- เกิดวงจรเสริมแรง (Feedback Loop)

ความไม่เป็นธรรม (Unfairness)

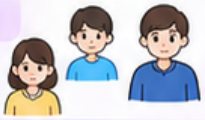

- ผู้ใช้บางกลุ่มได้รับคำแนะนำที่น้อยกว่า
- เนื้อหาบางกลุ่มถูกละเลย
- เช่น ความแตกต่างด้านเพศ อายุ พื้นที่ หรือกลุ่มผู้สร้างเนื้อหา

รายการซ้ำ / ไม่หลากหลาย (Repetitive Recommendations)

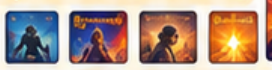

- แนะนำรายการคล้ายเดิมซ้ำ ๆ
- ขาดความหลากหลายของหมวดหมู่
- ทำให้ผู้ใช้พลาดโอกาสพบสิ่งใหม่ ๆ

4 ตัวชี้วัดจากบทที่ 2 ที่นำมาใช้ในบทนี้

ใช้ตัวชี้วัดเดิมในการประเมินความเป็นธรรม ความหลากหลาย และคุณภาพคำแนะนำ

Coverage (ความครอบคลุม)

สัดส่วนรายการทั้งหมดที่ถูกแนะนำ

Gini (ความไม่เท่าเทียม)

วัดการกระจุกตัวของการถูกแนะนำ

Tail Exposure / APLT (การส่งเสริมรายการหางยาว)

สัดส่วนหรืออันดับเฉลี่ยของรายการหางยาว

Parity Gap (ความเป็นธรรม)

ความแตกต่างของผลลัพธ์ระหว่างกลุ่ม

Calibration (การสอบเทียบ)

ความสอดคล้องระหว่างคะแนนที่คาดกับผลจริง

ILD (ความหลากหลาย)

ความหลากหลายในรายการคำแนะนำ

Novelty (ความใหม่)

ความใหม่ของรายการที่แนะนำ

MRR (อันดับรายการแรกที่ถูก)

สะท้อนตำแหน่งของรายการที่ตรงความต้องการ

5 ภาพรวมแนวทางการแก้ไขปัญหา

แก้ไขได้ในทุกขั้นตอนของการพัฒนาระบบ

ก่อนการฝึกโมเดล (Before Training)

- จัดการข้อมูลให้สมดุล
- เพิ่มความหลากหลายของข้อมูล
- กำหนดนโยบายธุรกิจและข้อกำกับ

ระหว่างการฝึกโมเดล (During Training)

- ใช้การถ่วงน้ำหนักข้อมูล
- ปรับฟังก์ชันการสูญเสีย
- เรียนรู้แบบคำนึงถึงความเป็นธรรมและความหลากหลาย

หลังการฝึกโมเดล (After Training)

- การจัดอันดับใหม่ (Reranking)
- กรองและปรับสมดุลผลลัพธ์
- ตรวจสอบและติดตามผลอย่างต่อเนื่อง

6 การจัดการข้อมูลและการฝึกโมเดล

แก้ปัญหาที่ต้นทางด้วยข้อมูลที่ดีและเทคนิคการเรียนรู้ที่เหมาะสม

1 Exploration (การสำรวจ)

- สุ่มแนะนำบางรายการเพื่อเก็บข้อมูลที่หลากหลาย

2 Propensity (ความน่าจะเป็นของการแสดง)

- ประมาณความน่าจะเป็นที่รายการถูกแสดง

3 IPS / SNIPS (การถ่วงน้ำหนักแบบผกผัน)

ให้น้ำหนักกับตัวอย่างที่ถูกแสดงยาก เพื่อลดอคติจากการเลือก

4 Reweighting (การถ่วงน้ำหนักข้อมูล)

- ปรับน้ำหนักข้อมูลให้สมดุลระหว่างกลุ่มผู้ใช้หรือรายการ

ข้อมูลที่หลากหลาย และการถ่วงน้ำหนักที่เหมาะสม ช่วยลดอคติและทำให้โมเดลเรียนรู้จากข้อมูลที่เป็นธรรมขึ้น

7 เทคนิคการจัดอันดับใหม่ (Reranking) เพื่อความเป็นธรรมและความหลากหลาย

ใช้หลังโมเดลพื้นฐาน เพื่อปรับผลลัพธ์ให้สมดุลและหลากหลายขึ้น

Fairness-aware Reranking (คำนึงถึงความเป็นธรรม)

- กำหนดสัดส่วนให้แต่ละกลุ่มได้รับการแนะนำอย่างเหมาะสม
- เช่น จำกัดความต่างของผลลัพธ์ระหว่างกลุ่ม (Parity Constraint)

Diversity Re-ranking (เพิ่มความหลากหลาย)

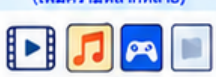

- เลือกรายการที่หลากหลายจากหลายหมวดหมู่
- ใช้วิธีเช่น MMR (Maximal Marginal Relevance)

Post-processing (การปรับผลลัพธ์ภายหลัง)

- กรองรายการซ้ำ
- เพิ่มสัดส่วนรายการหางยาว
- บังคับกฎความเป็นธรรมหรือความหลากหลาย

8 ความโปร่งใส ความเป็นส่วนตัว ความทนทาน และการกำกับดูแล

ความโปร่งใส (Transparency)

- อธิบายเหตุผลของคำแนะนำ
- ให้ผู้ใช้เข้าใจและตรวจสอบได้
- เช่น แสดงเหตุผลหลัก ๆ ว่าทำไมถึงแนะนำรายการนี้

ความเป็นส่วนตัว (Privacy)

- ปกป้องข้อมูลผู้ใช้
- ใช้การทำให้ไม่ระบุตัวตน (Anonymization)
- ควบคุมการใช้ข้อมูลอย่างเหมาะสม

ความทนทาน (Robustness)

- รับมือกับการโจมตี เช่น การสร้างรีวิวปลอม
- ตรวจจับพฤติกรรมที่ผิดปกติ
- ทำให้ระบบไม่ถูกชักจูงได้ง่าย

การกำกับดูแล (Governance)

- กำหนดนโยบายและแนวปฏิบัติ
- ตรวจสอบผลกระทบต่อสังคม
- ติดตามอย่างต่อเนื่อง และเปิดให้มีการตรวจสอบจากภายนอก

9 ตัวอย่างการคำนวณแบบง่าย

ตัวอย่าง: การคำนวณ Coverage

ระบบมีรายการทั้งหมด 12 รายการ และในผลแนะนำรายการที่ไม่ซ้ำกัน 10 รายการ

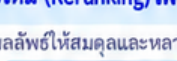

$$\text{Coverage} = \frac{\text{จำนวนรายการที่ถูกแนะนำ}}{\text{จำนวนรายการทั้งหมด}} = \frac{10}{12} = 0.8333$$

แนะนำ 10 รายการ จากทั้งหมด 12 รายการ ดังนั้น Coverage = 0.8333 แสดงว่าระบบครอบคลุมรายการได้ดี

10 สรุปสิ่งที่ได้เรียนรู้

1. ความแม่นยำอย่างเดียวไม่เพียงพอ ต้องคำนึงถึงความเป็นธรรม ความหลากหลาย และผลกระทบต่อสังคม
2. ใช้ตัวชี้วัดที่เหมาะสม เช่น Coverage, Gini, APLT, Parity Gap, Calibration, ILD, Novelty และ MRR
3. แก้ปัญหาได้ทุกขั้นตอน ของการพัฒนาระบบ ทั้งก่อน ระหว่าง และหลังการฝึกโมเดล
4. จัดการข้อมูลด้วย Exploration, Propensity, IPS/SNIPS และ Reweighting
5. ใช้เทคนิค Reranking เพื่อเพิ่มความเป็นธรรม และความหลากหลาย
6. ตรวจสอบและติดตามผลอย่างต่อเนื่อง เพื่อให้ระบบผู้แนะนำที่รับผิดชอบและเป็นประโยชน์ต่อทุกคน

ระบบผู้แนะนำที่ดี คือระบบที่ดูแล ทั้งผู้ใช้ เนื้อหา และสังคม ไปด้วยกันค่ะ !

ภาพรวมระบบผู้แนะนำ
Overview of Recommender Systems

สรุปเส้นทางการเรียนรู้ จากพื้นฐานสู่การประยุกต์ใช้ อย่างมีความรับผิดชอบ ในโลกจริง

รากฐาน การประเมิน อิงเนื้อหา การกรองร่วม ระบบผสาน LLM และความรับผิดชอบ

1 รากฐานของระบบผู้แนะนำ (Foundations)

เข้าใจปัญหาและองค์ประกอบพื้นฐาน

ปัญหา Information Overload

มีรายการจำนวนมาก
ผู้ใช้เลือกได้ยาก
จึงต้องการ "ระบบผู้แนะนำ"
ช่วยค้นพบรายการที่น่าสนใจ

เมทริกซ์ผู้ใช้-รายการ (User-Item Matrix)

	Item 1	Item 2	Item 3	Item 4	...
User 1	5	–	3	1	...
User 2	4	2	–	5	...
User 3	1	–	4	2	...
User 4	–	3	2	–	...

ประเภทข้อมูลป้อนกลับ (Feedback)

- Explicit Feedback (ระบุค่าโดยตรง): ให้คะแนน, ถูกใจ, รีวิว, รายการโปรด
- Implicit Feedback (พฤติกรรมการใช้งาน): คลิก, ดูรายการ, ซื้อ, เวลาที่ใช้

ข้อมูลผู้ใช้และข้อมูลรายการ คือรากฐานสำคัญของระบบผู้แนะนำ

2 การประเมินและการทดลอง (Evaluation & Experimentation)

เลือกตัวชี้วัดที่เหมาะสม และออกแบบการทดลองที่ถูกต้อง

แผนที่ตัวชี้วัด (Metric Map)

- ตัวชี้วัดความแม่นยำ: Precision@K, Recall@K, F1@K, Hit Rate@K, MRR / MAP, nDCG@K, AUC (ROC)
- ตัวชี้วัดความหลากหลาย: Diversity, Novelty, Serendipity
- ตัวชี้วัดความครอบคลุมและความเป็นธรรม: Coverage, Catalog Coverage, Fairness, Calibration

การแนะนำแบบ Top-K

แนะนำรายการ Top-K ที่คาดว่าจะถูกใจมากที่สุด

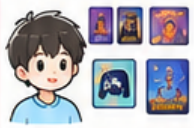

การออกแบบการทดลอง

- Offline Evaluation (ประเมินด้วยข้อมูลย้อนหลัง)
  - ✓ Train / Validation / Test
  - ✓ Temporal Split
  - ✓ User Split (Cold Start)
- Online Experiment (A/B Test)
  - A / B
  - ✓ วัดผลในโลกจริง
  - ✓ CTR, Conversion
  - ✓ ยืนยันคุณค่าทางธุรกิจ

เลือกตัวชี้วัดให้เหมาะกับเป้าหมาย และทดลองอย่างถูกต้อง เพื่อให้ผลการประเมินน่าเชื่อถือ

3 การแนะนำแบบอิงเนื้อหา (Content-Based Recommendation)

ใช้ข้อมูลรายการและโปรไฟล์ผู้ใช้ เพื่อหาสิ่งที่คล้ายกัน

แทนรายการด้วยเวกเตอร์

ข้อความ, คำสำคัญ, รูปภาพ

[0.1, 0.3, 0.0, 0.5, ...]

แปลงรายการเป็นเวกเตอร์ จากคุณลักษณะของรายการ

สร้างโปรไฟล์ผู้ใช้

รวมเวกเตอร์ของรายการที่ผู้ใช้สนใจ เพื่อแทนความสนใจของผู้ใช้แต่ละคน

วิธีการแทนคุณลักษณะของรายการ

- TF-IDF: น้ำหนักคำโดยสาระสำคัญของคำ
- BM25: ปรับปรุงจาก TF-IDF เหมาะกับข้อความสั้น
- Word Embedding: Word2Vec, GloVe หรือโมเดลยิ่งใหญ่ เช่น BERT, Sentence-BERT

เหมาะกับรายการใหม่ (Item Cold Start) และใช้ข้อมูลคุณลักษณะของรายการได้ดี

4 การกรองร่วม (Collaborative Filtering)

เรียนรู้จากพฤติกรรมของผู้ใช้หลายคน เพื่อหาความคล้ายคลึง

แนวคิดพื้นฐาน

ผู้ใช้ที่มีพฤติกรรมคล้ายกัน มักชอบรายการที่คล้ายกัน

วิธีการยอดนิยม

- User-kNN: หาผู้ใช้ที่คล้ายกัน เพื่อแนะนำรายการ
- Item-kNN: หารายการที่คล้ายกัน เพื่อแนะนำรายการ

ความคล้ายระหว่างผู้ใช้/รายการ

Cosine Similarity, Jaccard, Pearson

แบบจำลองขั้นสูง

- Matrix Factorization (MF): $R \approx P \times Q^T$ (User factors, Item factors)
- จัดการความเอนเอียง (Bias): $\hat{r}_{ui} = \mu + b_u + b_i + p_u^T q_i$ พิจารณาความเอนเอียงของผู้ใช้และรายการ
- ข้อความป้อนกลับโดยนัย: BPR, ALS, Hu & Koren ใช้ข้อมูลพฤติกรรม เช่น คลิก ดู ซื้อ ในการเรียนรู้

เหมาะกับสถานการณ์ที่มีประวัติการใช้งานจำนวนมาก และสามารถค้นพบรายการใหม่ที่ผู้ใช้ยังไม่เคยเห็น

5 ระบบผู้แนะนำแบบผสมผสาน (Hybrid Recommender Systems)

รวมสัญญาณหลายแหล่ง เพื่อให้คำแนะนำที่ดีขึ้นและครอบคลุมขึ้น

แนวคิดการผสมผสาน

Content-Based (อิงเนื้อหา) + Collaborative (กรองร่วม) + Context (บริบท) → Hybrid Recommender → คำแนะนำที่ดีขึ้น แม่นยำ ครอบคลุม และหลากหลายกว่า

7 รูปแบบของ Hybrid ตามแนวทางของ Burke

1. Weighted – ถ่วงน้ำหนักผลลัพธ์
2. Switching – เลือกวิธีที่เหมาะสม
3. Mixed – รวมผลลัพธ์หลายวิธี
4. Feature Augmentation – เพิ่มคุณลักษณะ
5. Cascade – เรียงลำดับหลายขั้น
6. Feature Combination – รวมคุณลักษณะในโมเดลเดียว
7. Meta-level – เรียนรู้การรวมผลลัพธ์

ตัวอย่างโมเดลสมัยใหม่

- LightFM: รวมสัญญาณเนื้อหาและกรองร่วมในโมเดลเดียว
- LightGCN: ใช้กราฟการเชื่อมต่อของผู้ใช้-รายการ สำหรับการกรองร่วม

การผสมผสานช่วยแก้ปัญหา Cold Start และเพิ่มความหลากหลาย โดยใช้จุดแข็งของแต่ละวิธีร่วมกัน

6 LLM และการแนะนำเชิงสร้างสรรค์ (LLM and Generative Recommendation)

นำพลังของโมเดลภาษาขนาดใหญ่ มาต่อยอดการแนะนำ

2 วิธีการใช้งาน LLM

- Prompt-based (ใช้คำสั่ง): สั่งด้วยภาษาธรรมชาติ, เหมาะกับงานง่าย ๆ, เริ่มต้นได้รวดเร็ว
- Program-based (เรียกใช้งานผ่าน API): ควบคุมได้ยืดหยุ่น, ผสานกับระบบเดิม, เหมาะกับงานจริง

ตัวอย่างการใช้งาน

- สร้างคำอธิบายรายการ (Explanation)
- สร้างโปรไฟล์ความสนใจจากข้อความ
- ช่วยจัดลำดับ/คัดกรองรายการ (Reranking)
- โต้ตอบแบบสนทนา (Conversational Rec)

กระบวนการแนะนำด้วย LLM

1. สร้างรายการผู้สมัคร (Candidate Generation)
2. จัดลำดับใหม่ด้วย LLM (Reranking)
3. สร้างคำอธิบายที่เข้าใจได้ (Explanation)

ข้อพิจารณาในการใช้งาน

ต้นทุน (Cost), ความหน่วง (Latency), ความถูกต้องและความน่าเชื่อถือ (Hallucination)

LLM ช่วยเพิ่มความยืดหยุ่น ความเข้าใจภาษาธรรมชาติ และสร้างคำอธิบายได้ดี แต่ต้องพิจารณาต้นทุนและความน่าเชื่อถือ

7 ความรับผิดชอบของระบบผู้แนะนำ (Responsible Recommender Systems)

พัฒนาระบบที่ให้คุณค่าทางธุรกิจ ควบคู่กับผลกระทบเชิงสังคม และมีความรับผิดชอบ

- กำหนด (Define): ✓ กำหนดเป้าหมายของระบบ และผู้มีส่วนได้ส่วนเสีย ✓ ระบุความเสี่ยงและผลกระทบต่อผู้ใช้และสังคม
- วัด (Measure): ✓ ใช้ตัวชี้วัดด้านความเป็นธรรม ความหลากหลาย ฯลฯ ✓ ตรวจสอบความเอนเอียง และผลกระทบที่ไม่พึงประสงค์
- ลดผลกระทบ (Mtiigate): ✓ ปรับปรุงข้อมูลและอัลกอริทึม ✓ ใช้เทคนิคเช่น re-ranking, constraints, debiasing ✓ เพิ่มความหลากหลายในการแนะนำ
- ตรวจสอบ (Audit): ✓ ประเมินอย่างสม่ำเสมอ ✓ ทดสอบกับกลุ่มผู้ใช้ที่หลากหลาย ✓ ติดตามผลหลังใช้งานจริง

ประเด็นสำคัญที่ต้องคำนึงถึง

- ความเป็นธรรม (Fairness): ลดความเอนเอียง ไม่เลือกปฏิบัติ
- ความหลากหลาย (Diversity): นำเสนอเนื้อหาที่หลากหลาย
- ความเป็นส่วนตัว (Privacy): ปกป้องข้อมูลผู้ใช้ ใช้ข้อมูลอย่างเหมาะสม
- ธรรมาภิบาล (Governance): ความโปร่งใส ความสอบได้ และมีความรับผิดชอบ

หัวข้อสำคัญที่เชื่อมโยงกันตลอดทั้งระบบผู้แนะนำ

- ข้อมูล (Data): ผู้ใช้ รายการ พฤติกรรม และข้อมูลบริบท
- แบบจำลอง (Models): Content-Based, CF, Hybrid, LLM
- การประเมิน (Metrics): ความแม่นยำ ความหลากหลาย และการทดลอง
- การใช้งานจริง (Deployment): ระบบออนไลน์ ขยายสเกล ติดตามและปรับปรุง
- ความรับผิดชอบ (Responsibility): ความเป็นธรรม ความหลากหลาย ความเป็นส่วนตัว และธรรมาภิบาล

ระบบผู้แนะนำที่ดี ไม่เพียงแค่แนะนำได้แม่นยำ แต่ต้องสร้างคุณค่าให้ผู้ใช้ ธุรกิจ และสังคมอย่างยั่งยืน