TOPIC 2:

Evaluation of Recommender System

204729

Recommender Systems

ผู้ช่วยศาสตราจารย์ ดร.ดุษฎี ประเสริฐธิติพงษ์



COMPUTER SCIENCE
Chiang Mai University

บทนี้ตอบคำถามว่า “ระบบผู้แนะนำที่ดี วัดอย่างไร”



- **Rating Prediction Metrics** MAE, RMSE
- **Set-based Ranking Metrics** Precision@K, Recall@K, F1@K, HR@K
- **Rank-aware Metrics** MRR, MAP@K, nDCG@K, AUC
- **Beyond-Accuracy** Coverage, Gini, ILD, Novelty, Calibration, Fairness
- **Methodology** Temporal Split, Data Leakage, Sampled Negatives, Significance Test

Exercise (Part1)



https://cmu.to/Chapter2EX1



https://cmu.to/Chapter2EX2

จับคู่ “คำถาม” กับ “ตัวชี้วัด” ให้ถูกต้อง

โจทย์พยากรณ์คะแนน
(Rating Prediction)

MAE — ค่าเฉลี่ยความคลาดเคลื่อนสัมบูรณ์
RMSE — ลงโทษความผิดพลาดก้อนใหญ่หนักกว่า

เหมาะกับผลป้อนกลับแบบชัดแจ้ง
แต่ RMSE ดีไม่ได้แปลว่าจัดอันดับดี

โจทย์จัดอันดับ: ไม่ไวต่อตำแหน่ง
(Set-based)

Precision@K — ของที่เสิร์ฟ ใช่กี่ชิ้น
Recall@K — ของที่ชอบ หยิบมาได้กี่ส่วน
F1@K — ค่าเฉลี่ยฮาร์มอนิก
HR@K — มีของถูกอย่างน้อยหนึ่งชิ้นไหม

นับเพียงจำนวน ไม่สนใจว่าอยู่อันดับใด

โจทย์จัดอันดับ: ไวต่อตำแหน่ง
(Rank-aware)

MRR — ส่วนกลับอันดับของถูกชิ้นแรก
MAP — เฉลี่ย Precision ทุกจุดที่ถูก
nDCG@K — ส่วนลดลอการิทึม + ทำบรรทัดฐาน
AUC — ความน่าจะเป็นที่เรียงคู่ถูก

ตัวชี้วัดหลักของงานสมัยใหม่

นอกเหนือความถูกต้อง
(Beyond-Accuracy)

Coverage — ครอบคลุมคลังกี่ %
Gini / Long-tail — กระจุกตัวแค่ไหน
ILD — ของที่แนะนำต่างกันเองไหม
Novelty — ใหม่สำหรับผู้ใช้แค่ไหน
Calibration — สัดส่วนหมวดตรงรสนิยมไหม
Fairness — ทุกกลุ่มได้คุณภาพเท่ากันไหม

- ความแม่นของคะแนน → MAE, RMSE
- อยู่ใน Top-K หรือไม่ → Precision, Recall, F1, HR
- ตำแหน่งสำคัญ → RR/MRR, AP/MAP, nDCG
- ผลต่อคลังของรายการและผู้ใช้ → Coverage, Diversity, Novelty, Calibration, Fairness

ประเภทตัวชี้วัด

ตระกูล	คำถามที่ตอบได้	ตัวชี้วัดในตระกูล	ใช้เมื่อใด
Rating Prediction (พยากรณ์คะแนน)	ทำนายตัวเลขคะแนนได้ใกล้ความจริงเพียงใด	MAE, RMSE	มี Explicit Feedback และผลลัพธ์ที่ต้องการเป็นตัวเลข
Set-based (ไม่ไวต่อตำแหน่ง)	ในรายการที่เสิร์ฟไป มีรายการที่แนะนำถูกต้องกี่ชิ้น	Precision@K, Recall@K, F1@K, HR@K	พื้นที่แสดงผลทุกช่องมีค่าเท่ากัน เช่น ตะกร้าสินค้าแนะนำ
Rank-aware (ไวต่อตำแหน่ง)	รายการที่ถูกต้องอยู่ใกล้ตำแหน่งบนสุดเพียงใด	MRR, MAP@K, nDCG@K, AUC	ตำแหน่งมีผลต่อโอกาสถูกเห็น ซึ่งเป็นกรณีส่วนใหญ่ในระบบจริง
Beyond-Accuracy (นอกเหนือความถูกต้อง)	ระบบดีต่อระบบนิเวศและผู้ใช้ในระยะยาวหรือไม่	Coverage, Gini, ILD, Novelty, Calibration, Fairness	ทุกครั้ง ในฐานะ Guardrail ควบคู่ Primary Metric

ข้อตกลงสัญลักษณ์ที่ใช้ตลอดบท

$\mathcal{U}$	เซตผู้ใช้ที่นำมาประเมิน
$\mathcal{I}$	บัญชีรายการทั้งหมด (Catalog)
$\mathcal{T} \subseteq \mathcal{U} \times \mathcal{I}$	เซตคู่ผู้ใช้–รายการในชุดทดสอบ
$\mathcal{R}_u$	เซตรายการที่เกี่ยวข้อง (Relevant) กับผู้ใช้ u
$\mathcal{L}_u^K$	รายการแนะนำแบบเรียงลำดับ K อันดับแรก
$rel_u(i)$	ระดับความเกี่ยวข้องของรายการที่อันดับ i

i ใช้แทนรายการในคู่ (u, i) และใช้เป็นดัชนีตำแหน่งเมื่อบริบทเป็นลิสต์จัดอันดับ

2.1

ตัวชี้วัด การพยากรณ์คะแนน

Rating Prediction • MAE • RMSE

2.1

ตัวชี้วัดเชิงอันดับที่ไม่ไวต่อตำแหน่งใน Top-K

Rating Prediction· Precision@K • Recall@K • F1@K • Hit Rate@K

2.1.1 Mean Absolute Error (MAE)

$$MAE = \frac{1}{|\mathcal{T}|} \sum_{(u,i) \in \mathcal{T}} |r_{ui} - \hat{r}_{ui}|$$

สมการ (2.1)

MAE ตอบคำถามง่าย ๆ ว่า “โดยเฉลี่ย Model ทายพลาดกี่หน่วย”

องค์ประกอบของสูตร

- $\mathcal{T}$ เซตคู่ (u, i) ในชุดทดสอบที่มีคะแนนจริงกำกับ
- r_{ui} คะแนนจริงที่ผู้ใช้ u ให้รายการ i
- $\hat{r}_{ui}$ คะแนนที่Model ทำนาย
- $|\cdot|$ ค่าสัมบูรณ์ จึงไม่หักล้างกันระหว่างทายสูงเกินกับต่ำเกิน

การตีความ

- หน่วยเดียวกับคะแนน ตีความตรงไปตรงมา
- MAE = 0.68 หมายถึง Model ทายคลาดเคลื่อนเฉลี่ย 0.68 ดาว
- ให้น้ำหนักความผิดพลาดทุกขนาดเท่ากัน (เชิงเส้น)

2.1.2 Root Mean Squared Error (RMSE)

$$RMSE = \sqrt{\frac{1}{|T|} \sum_{(u,i) \in T} (r_{ui} - \hat{r}_{ui})^2}$$

สมการ (2.2)

ใช้ความผิดพลาดชุดเดียวกับ MAE แต่ยกกำลังสองก่อนเฉลี่ย แล้วจึงถอดรากที่สอง

ทำไมต้องยกกำลังสอง

- ขยายอิทธิพลของความผิดพลาดขนาดใหญ่
- ความผิดพลาด 2 ดาวหนึ่งครั้ง ($2^2 = 4$) มีค่าเท่ากับความผิดพลาด 1 ดาวสี่ครั้งรวมกัน (4×1^2)
- เหมาะเมื่อการทายผิดรุนแรงมีต้นทุนสูงเป็นพิเศษ

ควรรายงานคู่กันเสมอ

- MAE สรุปขนาดความผิดพลาดโดยเฉลี่ย
- RMSE ตรวจจับความเสี่ยงจากความผิดพลาดก้อนใหญ่
- เลือกค่าหลักให้สอดคล้องกับต้นทุนของความผิดพลาดในงานจริง

ตัวอย่างการคำนวณ 2.1 MAE และ RMSE ทีละขั้นตอน : ข้อมูล

ข้อมูล: คะแนนจริงของผู้ใช้ Emma เทียบกับคะแนนที่ Model A ทำนาย บนภาพยนตร์ห้าเรื่อง

รายการ	คะแนนจริง r_{ui}	คะแนนที่ทำนาย $\hat{r}_{ui}$	ผิดพลาด e	|e|	e^2
The Matrix	5.0	4.20	−0.80	0.80	0.6400
Inception	5.0	4.60	−0.40	0.40	0.1600
Interstellar	4.0	4.30	+0.30	0.30	0.0900
Titanic	1.0	2.40	+1.40	1.40	1.9600
The Notebook	1.0	1.50	+0.50	0.50	0.2500
ผลรวม				3.40	3.1000

วิธีอ่านตาราง

- $e = \hat{r} - r$ (ทำนาย − จริง)
- $|e|$ ใช้กับ MAE
- e^2 ใช้กับ RMSE
- ผลรวม $|e| = 3.40$ และ $\sum e^2 = 3.1000$
- $|\mathcal{T}| = 5$ รายการ

Titanic ทายผิดถึง 1.40 ดาว ซึ่งจะมีอิทธิพลมากเป็นพิเศษต่อ RMSE

ตัวอย่างการคำนวณ 2.1 : แทนค่าและตีความ

1 แทนค่าลงในสูตร MAE

MAE = (0.80 + 0.40 + 0.30 + 1.40 + 0.50) / 5

= 3.40 / 5 = 0.6800

2 แทนค่าลงในสูตร RMSE

RMSE = $\sqrt{(3.1000 / 5)}$ = $\sqrt{0.6200}$

= 0.7874

3 ตีความ

- โดยเฉลี่ยModel ทำนายพลาดไป 0.68 ดาว; เมื่อเพิ่มน้ำหนักให้กรณีที่ทำนายผิดมาก ความคลาดเคลื่อนอยู่ที่ประมาณ 0.79 ดาว
- RMSE สูงกว่า MAE อยู่ 0.1074 แสดงว่ามีบางรายการผิดมากกว่ารายการอื่น เช่น Titanic ที่ผิด 1.40 ดาว
- ช่องว่างระหว่าง RMSE กับ MAE จึงใช้เป็นสัญญาณเบื้องต้นของ “ความไม่สม่ำเสมอของความผิดพลาด”

ตัวอย่างการคำนวณ 2.2 MAE เท่ากัน แต่ RMSE ต่างกันสองเท่า

กำหนดให้คะแนนจริงของสี่รายการเท่ากับ 4, 4, 4, 4 ทั้งหมด

กรณี	คะแนนที่ทาย	ความผิดพลาด	MAE	RMSE
กรณีที่ 1: ผิดพลาดกระจายสม่ำเสมอ	3.0, 3.0, 3.0, 3.0	1, 1, 1, 1	1.0000	1.0000
กรณีที่ 2: ผิดพลาดหนักจุดเดียว	4.0, 4.0, 4.0, 0.0	0, 0, 0, 4	1.0000	2.0000

1 การคำนวณกรณีที่ 2

$$\text{MAE} = (0 + 0 + 0 + 4) / 4 = 1.0000$$

$$\text{RMSE} = \sqrt{((0 + 0 + 0 + 16) / 4)} = \sqrt{4}$$

$$= 2.0000$$

2 บทเรียน

- MAE มองไม่เห็นความต่าง เพราะพิจารณาเพียงขนาดความผิดพลาดเฉลี่ย
- RMSE ยกกำลังสองก่อนเฉลี่ย จึงชี้ว่ากรณีที่ 2 มีความผิดพลาดขนาดใหญ่ ⟶ ต้องรายงานทั้งสองค่า

2.2

ตัวชี้วัดเชิงอันดับที่ไม่ไวต่อตำแหน่งใน Top-K

Set-based Metrics • Precision@K • Recall@K • F1@K • Hit Rate@K

Confusion Matrix ในบริบทของระบบผู้แนะนำ

Ground Truth อาจสร้างจากรายการที่ผู้ใช้เคยคลิก ซื้อ รับชม หรือให้คะแนนสูงในข้อมูลทดสอบ ทั้งนี้ รายการที่ไม่อยู่ใน Ground Truth ไม่ได้หมายความว่าผู้ใช้ไม่ชอบเสมอไป แต่อาจเป็นรายการที่ผู้ใช้ยังไม่เคยเห็นหรือยังไม่มีข้อมูลตอบกลับ



Top-K หมายถึงรายการ (K) อันดับแรกที่ระบบเลือกมาแนะนำแก่ผู้ใช้ (u) โดยเรียงจากรายการที่ระบบคาดว่าเหมาะสมมากที่สุดไปยังน้อยที่สุด



เมทริกซ์ความสับสนสำหรับการแนะนำแบบ Top-K

เปรียบเทียบ "รายการที่ระบบเลือกมาแสดง" กับ "รายการที่อยู่ใน Ground Truth"

	อยู่ใน Ground Truth	ไม่อยู่ใน Ground Truth
อยู่ใน Top-K (ระบบเลือกมาแสดง)	TP แนะนำถูก — อยู่ใน Top-K และอยู่ใน Ground Truth — รายการที่เกี่ยวข้องซึ่งระบบค้นพบ	FP ยังไม่ยืนยันว่าเกี่ยวข้อง — อยู่ใน Top-K แต่ไม่อยู่ใน Ground Truth — ไม่ควรสรุปทันทีว่าผู้ใช้ไม่ชอบ
อยู่นอก Top-K (ระบบไม่เลือกมาแสดง)	FN พลาดรายการที่เกี่ยวข้อง — อยู่นอก Top-K แต่อยู่ใน Ground Truth — รายการที่ควรค้นพบแต่ไม่ถูกแสดง	TN ไม่ถูกเลือกมาแสดง — อยู่นอก Top-K และไม่อยู่ใน Ground Truth — มักมีจำนวนมากและยังไม่หราบความชอบจริง

Precision@K = TP / (TP + FP)
ใน Top-K มีรายการที่ตรงกับ Ground Truth เท่าใด

Recall@K = TP / (TP + FN)
ระบบค้นพบรายการใน Ground Truth ได้ครบเพียงใด

TP: รายการอยู่ใน Top-K และอยู่ใน Ground Truth

FP: อยู่ใน Top-K แต่ไม่อยู่ใน Ground Truth : ยังไม่ยืนยันว่าผู้ใช้ไม่ชอบ

FN: อยู่ใน Ground Truth แต่ระบบไม่ได้นำมาไว้ใน Top-K

TN: ไม่อยู่ทั้งใน Top-K และ Ground Truth แต่ไม่ได้แปลว่าไม่เกี่ยวข้องจริงเสมอไป

ตารางที่ 2.2 ข้อมูลตั้งต้นสำหรับตัวชี้วัดเชิงอันดับทุกตัว

อันดับ	1	2	3	4	5	6	7	8	9	10
Model A	i2 ✓	i7	i5 ✓	i3	i9 ✓	i1	i4	i6	i8	i10
Model B	i7	i3	i1	i2 ✓	i4	i5 ✓	i6	i8	i9 ✓	i10

เงื่อนไขของตัวอย่าง

- Ground Truth (รายการที่ผู้ใช้ชอบจริง) = {i2, i5, i9} รวม 3 รายการ
- ค่าตัด K = 10
- เครื่องหมาย ✓ แสดงตำแหน่งของรายการที่ผู้ใช้ชอบจริง

ประเด็นสำคัญที่สุดของทั้งหัวข้อ

- Model A และ B มีรายการที่ถูกต้องใน Top-10 เท่ากันพอดี คือ 3 ชิ้น
- A วางไว้ที่อันดับ 1, 3, 5 ส่วน B วางไว้ที่อันดับ 4, 6, 9
- ต่างกันเพียง “ตำแหน่ง” เท่านั้น

2.2.1 Precision@K

$$Precision@K(u) = \frac{|\mathcal{R}(u) \cap \mathcal{L}_K(u)|}{K}$$

"ในรายการที่เรานำมาแนะนำ K ชิ้น เป็นรายการที่ถูกใจกี่ส่วน"

1 แทนค่า (จากตารางที่ 2.2)

Precision@10 (A) = 3 / 10 = 0.3000

Precision@10 (B) = 3 / 10 = 0.3000

2 ขอบเขตสูงสุด

Ground Truth มี m รายการ

$$\max = \min(K, m) \,/\, K$$

จากตัวอย่าง max(Precision@10) = 3 / 10 = 0.30

- จำนวน Ground Truth จึงไม่จำเป็นต้องเท่ากับ K และไม่ควรเพิ่ม Ground Truth ให้ครบ K เพียงเพื่อทำให้ Precision มีโอกาสเท่ากับ 1 เพราะ Ground Truth ต้องมาจากข้อมูลความเกี่ยวข้องจริง
- ดังนั้น จากตัวอย่าง ค่า Precision@10 เท่ากับ 0.30 ในตัวอย่างนี้หมายถึง "3 จาก 10 รายการตรงกับความเกี่ยวข้องที่สังเกตได้" ไม่ใช่ข้อสรุปว่าอีก 7 รายการไม่มีประโยชน์

2.2.2 Recall@K และ 2.2.4 Hit Rate@K

$$Recall@K(u) = \frac{|\mathcal{R}(u) \cap \mathcal{L}_K(u)|}{|\mathcal{R}(u)|}$$

“ในรายการที่ผู้ใช้ชอบทั้งหมด เรานำมาแนะนำได้กี่ส่วน” ตัวส่วนคือจำนวนที่ผู้ใช้ชอบจริง

1 แทนค่า Recall@10

Recall@10 (A) = = 3 / 3 = 1.0000

Recall@10 (B) = 3 / 3 = 1.0000

$$HR@K(u) = 1 \text{ if } |\mathcal{R}(u) \cap \mathcal{L}_K(u)| \neq \emptyset, \text{ else } 0$$

Hit Rate@K

- ละเอียดน้อยที่สุดในตระกูล: “มีรายการถูกต้องอย่างน้อยหนึ่งชิ้นหรือไม่”
- A และ B ได้ HR@10 = 1.0000 เท่ากัน

เหมาะกับ

- สถานการณ์ที่การโดนเพียงชิ้นเดียวก็ถือว่าสำเร็จ เช่น การแนะนำสินค้าเสริมตอนชำระเงิน

2.2.3 F1@K ค่าเฉลี่ยฮาร์มอนิกของ Precision และ Recall

$$F1@K(u) = \frac{2 \cdot Precision@K(u) \cdot Recall@K(u)}{Precision@K(u) + Recall@K(u)}$$

Harmonic Mean ถูกดึงลงโดยค่าที่ต่ำกว่า และสูงเมื่อทั้งสองดีพร้อมกัน

1 แทนค่า F1@10 (Model A และ B)

$$= \frac{2 \times 0.3000 \times 1.0000}{0.3000 + 1.0000}$$

$$= 0.6000 / 1.3000 = 0.4615$$

2 เหตุผลที่ไม่ใช้ค่าเฉลี่ยเลขคณิต

- ระบบที่มี Precision = 1.0 แต่ Recall = 0.0 จะได้ F1 = 0 ไม่ใช่ 0.5 แบบค่าเฉลี่ยเลขคณิต สะท้อนว่าระบบไม่สามารถสร้างสมดุลระหว่างความแม่นยำกับความครอบคลุมได้
- Precision@K=0.80 และ Recall@K=0.20 หากใช้ค่าเฉลี่ยเลขคณิตจะเท่ากับ 0.50 แต่ F1@K เท่ากับเพียง 0.32 แสดงว่าระบบแนะนำรายการได้ค่อนข้างแม่นยำ แต่ยังค้นพบรายการที่เกี่ยวข้องได้ไม่ครอบคลุม

ข้อสังเกต

แม้ A วางรายการถูกต้องไว้อันดับ (1, 3, 5) ส่วน B วางไว้ (4, 6, 9) แต่ตัวชี้วัดกลุ่มนี้ให้คะแนนเท่ากัน เพราะสนใจเพียงว่าอยู่ภายใน Top-10 หรือไม่

ข้อสรุปสำคัญของหัวข้อ 2.2 และ Position Bias

ตัวชี้วัด	Model A	Model B
Precision@10	0.3000	0.3000
Recall@10	1.0000	1.0000
F1@10	0.4615	0.4615
HR@10	1.0000	1.0000

- ทั้งสี่ตัวให้ค่าเท่ากัน เพราะตรวจเพียงว่ารายการ “อยู่ภายใน Top-10 หรือไม่”
- ผู้ใช้ Model A พบรายการที่เกี่ยวข้องเร็วกว่า

ส่วนผู้ใช้ Model B ต้องเลื่อนลงไปมากกว่า

Position Bias (Guan & Cutrell, 2007; Hofmann et al., 2014)

- รายการด้านบนมักถูกมองเห็นและคลิกมากกว่ารายการด้านล่าง แม้ความเกี่ยวข้องใกล้เคียงกัน
- อย่างไรก็ตาม ขนาดของผลขึ้นกับหน้าจอ อุปกรณ์ งาน และบริบท จึงไม่ควรสรุปว่า A ดีกว่า B “อย่างมีนัยสำคัญต่อผู้ใช้จริง” จากตัวอย่างออฟไลน์เดียว
- การยืนยันผลต่อผู้ใช้จริงต้องอาศัย User Study หรือ A/B Test → นี่คือเหตุผลที่ต้องมีตัวชี้วัดตระกูลถัดไป

2.3

ตัวชี้วัดเชิงอันดับที่ไวต่อตำแหน่งใน Top-K

Rank-aware Metrics • RR & MRR • AP & MAP • nDCG

ข้อมูลตั้งต้นสำหรับ Rank-aware Metrics (ผู้ใช้ 3 คน, K = 10)

ผู้ใช้ / Model	1	2	3	4	5	6	7	8	9	10
 Emma (GT)	i9	i5	i2							
Model A	i2	i7	i5	i3	i9	i1	i4	i6	i8	i10
Model B	i7	i3	i1	i2	i4	i5	i6	i8	i9	i10
 James (GT)	i8	i4	i1							
Model A	i7	i1	i3	i4	i5	i6	i2	i8	i9	i10
Model B	i1	i7	i3	i2	i4	i6	i8	i5	i9	i10
 Daniel (GT)	i10	i6	i3							
Model A	i7	i3	i6	i1	i10	i2	i4	i5	i8	i9
Model B	i7	i1	i4	i3	i2	i6	i5	i8	i9	i10

GT = Ground Truth; ตัวเลขในวงเล็บคือระดับความเกี่ยวข้อง (ใช้ในกรณีหลายระดับ) ตัวอย่างในบทใช้ความเกี่ยวข้องแบบทวิภาค rel $\in$ {0, 1}

2.3.1 Reciprocal Rank (RR@K) และ MRR@K

$$RR@K(u) = \frac{1}{rank_u} \text{ (found in Top-K)}, \quad 0 \text{ (not found)}$$

$$MRR@K = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} RR@K(u)$$

ความหมาย

- $rank_u$ = ตำแหน่งของรายการที่เกี่ยวข้อง “ชิ้นแรก” ใน $\mathcal{L}_u^K$
- ตัวอย่างเช่น หากคำตอบแรกในเซตของ Ground Truth
  - อยู่อันดับ 2 ค่า RR = 1/2 = 0.5
  - หาก อยู่อันดับ 8 ค่า 1/8 = 0.125

บทเรียน

- เหมาะกับงานที่ต้องการคำตอบดีเพียงรายการแรก เช่น การค้นเอกสารในองค์กร
- ไม่สนใจรายการที่เกี่ยวข้องลำดับถัดไป : หลังพบคำตอบแรกแล้วคะแนนไม่เปลี่ยน
- หากงานต้องการหลายรายการในลิสต์มีคุณภาพ ควรใช้ MAP@K หรือ nDCG@K ร่วมด้วย

ตัวอย่างการคำนวณ RR และ MRR@10 ของ Model A และ B

ผู้ใช้	อันดับที่พบรายการเกี่ยวข้อง (Model A)	RR (A)	อันดับที่พบรายการเกี่ยวข้อง (Model B)	RR (B)
Emma	1, 3, 5 ⟶ อันดับแรกคือ 1	1/1 = 1.0000	4, 6, 9 ⟶ อันดับแรกคือ 4	1/4 = 0.2500
James	2, 4, 8 ⟶ อันดับแรกคือ 2	1/2 = 0.5000	1, 5, 7 ⟶ อันดับแรกคือ 1	1/1 = 1.0000
Daniel	2, 3, 5 ⟶ อันดับแรกคือ 2	1/2 = 0.5000	4, 6, 10 ⟶ อันดับแรกคือ 4	1/4 = 0.2500

1



กรณี Emma

RR (A) = 1/1 = 1.0000

RR (B) = 1/4 = 0.2500

ต่างกันถึง 4 เท่า

2

MRR@10 เฉลี่ยข้ามผู้ใช้สามคน

MRR (A) = (1.0000 + 0.5000 + 0.5000) / 3 = 0.6667

MRR (B) = (0.2500 + 1.0000 + 0.2500) / 3 = 0.5000

3

บทเรียน

- RR แยกความต่างระหว่าง A กับ B ได้ทันที และแยกได้แรงที่สุด (Emma: 4 เท่า)
- จุดอ่อน: มองข้ามรายการที่ถูกต้องชิ้นที่สอง เป็นต้นไปทั้งหมด

ตีความการเปรียบเทียบ MRR@10

0.6667	vs	0.5000
MRR@10 Model A		MRR@10 Model B

Model A มีค่า MRR@10 เท่ากับ 0.6667 สูงกว่า Model B ซึ่งมีค่าเท่ากับ 0.5000 อยู่ 0.1667 จุด แสดงว่า Model A สามารถนำรายการที่เกี่ยวข้องรายการแรกขึ้นมาแสดงในอันดับต้นได้รวดเร็วและสม่ำเสมอกว่า เมื่อพิจารณาจากผู้ใช้ทั้งสามคน โดย Model A แสดงรายการที่เกี่ยวข้องรายการแรกในอันดับ 1, 2 และ 2 ส่วน Model B แสดงในอันดับ 4, 1 และ 4 ตามลำดับ

2.3.2 Average Precision (AP@K) และ MAP@K

$$AP@K(u) = \frac{1}{\min(K, |\mathcal{R}(u)|)} \sum_{i=1}^{K} Precision@i(u) \cdot rel_u(i)$$

$$MAP@K = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} AP@K(u)$$

แนวคิด

- AP@K วัดว่า รายการที่เกี่ยวข้องทุกชิ้นปรากฏอยู่ในอันดับต้นเพียงใด โดยคำนวณ Precision ทุกตำแหน่งที่พบรายการเกี่ยวข้อง แล้วนำมาเฉลี่ย
- คำตอบที่ถูกในอันดับต้นจึงมีอิทธิพลมากกว่าอันดับท้าย
- ต่างจาก RR ตรงที่ AP ใช้ข้อมูลจากรายการที่เกี่ยวข้อง “ทุกชิ้น” ภายใน Top-K

ตัวส่วน min(K, $|\mathcal{R}_u|$)

- ป้องกันการหารด้วยจำนวนที่เป็นไปไม่ได้: ถ้าผู้ใช้ชอบ 3 รายการ ก็เก็บได้สูงสุด 3 ชิ้น
- ในตัวอย่าง min(10, 3) = 3
- MAP@K คือค่าเฉลี่ยของ AP@K ของผู้ใช้ทุกคน

ตัวอย่างการคำนวณ 2.3 AP@10 ของ Model A ทีละตำแหน่ง

อันดับ	1	2	3	4	5	6	7	8	9	10
Model A	i2 ✓	i7	i5 ✓	i3	i9 ✓	i1	i4	i6	i8	i10



Emma (GT)	i9	i5	i2

ตำแหน่ง i	รายการ	rel(i)	Precision@i ณ จุดที่ rel = 1
1	i2	1	1 / 1 = 1.0000
2	i7	0	—
3	i5	1	2 / 3 = 0.6667
4	i3	0	—
5	i9	1	3 / 5 = 0.6000
6–10	i1, i4, i6, i8, i10	0	—

1 แทนค่า Model A

$$AP@K(u) = \frac{1}{\min(K, |\mathcal{R}(u)|)} \sum_{i=1}^{K} Precision@i(u) \cdot rel_u(i)$$

$\min(K, |\mathcal{R}_u|) = \min(10, 3) = 3$

ดังนั้น

AP@10(Model A)

$= \frac{1}{3}(1.0000 + 0.6667 + 0.6000)$

$= 2.2667 / 3 = 0.7556$

Precision@i = จำนวนรายการเกี่ยวข้องสะสมจนถึงตำแหน่ง i หารด้วย i (นับเฉพาะตำแหน่งที่ rel = 1)

ตัวอย่างการคำนวณ 2.3 AP@10 ของ Model B ทีละตำแหน่ง

อันดับ	1	2	3	4	5	6	7	8	9	10
Model B	i7	i3	i1	i2 ✓	i4	i5 ✓	i6	i8	i9 ✓	i10



Emma (GT)	i9	i5	i2

ตำแหน่ง i	รายการ	rel(i)	Precision@i ณ จุดที่ rel = 1
4	i2	1	1 / 4 = 0.2500
6	i5	1	2 / 6 = 0.3333
9	i9	1	3 / 9 = 0.3333

2 แทนค่า Model B

$$AP@K(u) = \frac{1}{\min(K, |\mathcal{R}(u)|)} \sum_{i=1}^{K} Precision@i(u) \cdot rel_u(i)$$

$\min(K, |\mathcal{R}_u|) = \min(10, 3) = 3$

ดังนั้น

AP@10(Model B)

$= \frac{1}{3}(0.2500 + 0.3333 + 0.3333)$

$= 0.9167 / 3 = 0.3056$

ตัวอย่างการคำนวณ AP และ MAP@10 ของ Model A และ B

ผู้ใช้	อันดับที่พบรายการเกี่ยวข้อง (Model A)	AP (A)	อันดับที่พบรายการเกี่ยวข้อง (Model B)	RR (B)
Emma	1, 3, 5	$\frac{1}{3}\left(\frac{1}{1}+\frac{2}{3}+\frac{3}{5}\right)$ =0.7556	4, 6, 9	$\frac{1}{3}\left(\frac{1}{4}+\frac{2}{6}+\frac{3}{9}\right)$ = 0.3056
James	2, 4, 8	$\frac{1}{3}\left(\frac{1}{2}+\frac{2}{4}+\frac{3}{8}\right)$ = 0.4583	1, 5, 7	$\frac{1}{3}\left(\frac{1}{1}+\frac{2}{5}+\frac{3}{7}\right)$ = 0.6095
Daniel	2, 3, 5	$\frac{1}{3}\left(\frac{1}{2}+\frac{2}{3}+\frac{3}{5}\right)$ = 0.5889	4, 6, 10	$\frac{1}{3}\left(\frac{1}{4}+\frac{2}{6}+\frac{3}{10}\right)$ = 0.2944
	MAP@10 ของ Model A = 0.6009		MAP@10 ของ Model B = 0.4032	

ตีความการเปรียบเทียบ MAP@10

0.6009	vs	0.4032
MAP@10 Model A		MAP@10 Model B

Model A มีค่า MAP@10 เท่ากับ 0.6009 สูงกว่า Model B ซึ่งมีค่าเท่ากับ 0.4032 อยู่ 0.1977 แสดงว่า เมื่อพิจารณาโดยเฉลี่ยจากผู้ใช้ทั้งสามคน Model A สามารถนำรายการที่เกี่ยวข้องขึ้นมาอยู่ในอันดับต้นของรายการแนะนำได้ดีกว่า Model B จึงกล่าวได้ว่า ค่า MAP@10 ของ Model A สูงกว่า Model B ประมาณ 49%

แต่ไม่ควรกล่าวกว้าง ๆ ว่า “Model A ดีกว่า 49%” เพราะผลนี้หมายถึงเฉพาะตัวชี้วัด MAP@10 และชุดข้อมูลตัวอย่างนี้เท่านั้นครับ

2.3.3 Normalized Discounted Cumulative Gain (nDCG@K)

$$DCG@K = \sum_{k=1}^{K} \frac{2^{rel_k} - 1}{\log_2(k+1)}$$

$$IDCG@K(u) = DCG@K \text{ of ideal ordering}$$

$$nDCG@K(u) = \frac{DCG@K(u)}{IDCG@K(u)}$$

การคำนวณ

1. หา DCG จากลิสต์จริง (ผลได้ ÷ ส่วนลดตามตำแหน่ง)

2. หา IDCG จากลิสต์อุดมคติที่เรียงความเกี่ยวข้องจากมากไปน้อย

3. หาร DCG ด้วย IDCG ⟶ “Normalized” ค่าอยู่ระหว่าง 0 กับ 1 เสมอ และเปรียบเทียบข้ามผู้ใช้ที่มีจำนวนรายการชอบไม่เท่ากันได้

เหมาะเมื่อทั้ง “ตำแหน่ง” และ “ระดับความเกี่ยวข้อง” มีความสำคัญ ต้องประกาศ Gain Function และ Discount Function ที่ใช้เสมอ

ตัวอย่างการคำนวณ 2.3 DCG@10 ของ Model A ทีละตำแหน่ง แบบที่ 1

หากระดับความเกี่ยวข้องเป็น 0–1

Model /อันดับ	1	2	3	4	5	6	7	8	9	10
Model A	i2	i7	i5	i3	i9	i1	i4	i6	i8	i10
Model B	i7	i3	i1	i2	i4	i5	i6	i8	i9	i10



Emma (GT)	i9	i5	i2

$rel(i9) = 1 \quad rel(i5) = 1 \; rel(i2) = 1$

ตำแหน่ง i	รายการ	rel(i)	ค่า DCG ในอันดับนั้น
1	i2	1	$\frac{2^1-1}{\log_2(2)} = \frac{1}{\log_2(2)} = 1.0000$
3	i5	1	$\frac{2^1-1}{\log_2(4)} = \frac{1}{\log_2(4)} = 0.5000$
5	i9	1	$\frac{2^1-1}{\log_2(6)} = \frac{1}{\log_2(6)} = 0.3869$
DCG@10(Model A)			1.8869

ตำแหน่ง i	รายการ	rel(i)	ค่า DCG ในอันดับนั้น
4	i2	1	$\frac{2^1-1}{\log_2(5)} = \frac{1}{\log_2(5)} = 0.4307$
6	i5	1	$\frac{2^2-1}{\log_2(7)} = \frac{1}{\log_2(7)} = 0.3562$
9	i9	1	$\frac{2^3-1}{\log_2(10)} = \frac{1}{\log_2(10)} = 0.3010$
DCG@10(Model B)			1.0879

ตัวอย่างการคำนวณ 2.3 DCG@10 ของ ทั้งสองModel ทีละตำแหน่ง แบบที่ 2

หากระดับความเกี่ยวข้องเป็น 0–3

Model /อันดับ	1	2	3	4	5	6	7	8	9	10
Model A	i2	i7	i5	i3	i9	i1	i4	i6	i8	i10
Model B	i7	i3	i1	i2	i4	i5	i6	i8	i9	i10



Emma (GT)	i9	i5	i2

หาก Ground เรียงตามลำดับความเกี่ยวข้อง

สมมุติกำหนดว่า $rel(i9) = 3, rel(i5) = 2,\ rel(i2) = 1$

ตำแหน่ง i	รายการ	rel(i)	ค่า DCG ในอันดับนั้น
1	i2	1	$\frac{2^1-1}{\log_2(2)} = \frac{1}{\log_2(2)} = 1.0000$
3	i5	1	$\frac{2^2-1}{\log_2(4)} = \frac{3}{\log_2(4)} = 1.5000$
5	i9	1	$\frac{2^3-1}{\log_2(6)} = \frac{7}{\log_2(6)} = 2.7080$
DCG@10(Model A)			5.2080

ตำแหน่ง i	รายการ	rel(i)	ค่า DCG ในอันดับนั้น
4	i2	1	$\frac{2^1-1}{\log_2(5)} = \frac{1}{\log_2(5)} = 0.4307$
6	i5	1	$\frac{2^2-1}{\log_2(7)} = \frac{3}{\log_2(7)} = 1.0686$
9	i9	1	$\frac{2^3-1}{\log_2(10)} = \frac{7}{\log_2(10)} = 2.1072$
DCG@10(Model B)			3.6065

ตัวอย่างการคำนวณ 2.3 DCG@10 ของ ทั้งสองModel ทีละตำแหน่ง แบบที่ 3

หากระดับความเกี่ยวข้องเป็น 0–3

Model /อันดับ	1	2	3	4	5	6	7	8	9	10
Model A	i2	i7	i5	i3	i9	i1	i4	i6	i8	i10
Model B	i7	i3	i1	i2	i4	i5	i6	i8	i9	i10



Emma (GT)	i9	i5	i2

หาก Ground เรียงตามลำดับความเกี่ยวข้อง

สมมุติกำหนดว่า $rel(i9) = 3, rel(i5) = 2,\ rel(i2) = 2$

ตำแหน่ง i	รายการ	rel(i)	ค่า DCG ในอันดับนั้น
1	i2	2	$\frac{2^2-1}{\log_2(2)} = \frac{3}{\log_2(2)}$
3	i5	2	$\frac{2^2-1}{\log_2(4)} = \frac{3}{\log_2(4)}$
5	i9	1	$\frac{2^3-1}{\log_2(6)} = \frac{7}{\log_2(6)}$
DCG@10(Model A)			7.2080

ตำแหน่ง i	รายการ	rel(i)	ค่า DCG ในอันดับนั้น
4	i2	2	$\frac{2^2-1}{\log_2(5)} = \frac{3}{\log_2(5)}$
6	i5	2	$\frac{2^2-1}{\log_2(7)} = \frac{3}{\log_2(7)}$
9	i9	1	$\frac{2^3-1}{\log_2(10)} = \frac{7}{\log_2(10)}$
DCG@10(Model B)			4.4679

ตัวอย่างการคำนวณ 2.4 nDCG@10 : ขั้นที่ 1 DCG ของ Model A

หากระดับความเกี่ยวข้องเป็น 0–1

อันดับ	1	2	3	4	5	6	7	8	9	10
Model A	i2 ✓	i7	i5 ✓	i3	i9 ✓	i1	i4	i6	i8	i10

ตำแหน่ง i	รายการ	rel_i	ส่วนลด $1/\log_2(i+1)$	ส่วนเพิ่ม DCG
1	i2	1	$1 / \log_2 2 = 1.0000$	1.0000
2	i7	0	$1 / \log_2 3 = 0.6309$	0.0000
3	i5	1	$1 / \log_2 4 = 0.5000$	0.5000
4	i3	0	$1 / \log_2 5 = 0.4307$	0.0000
5	i9	1	$1 / \log_2 6 = 0.3869$	0.3869
6–10	ไม่มีรายการที่ถูกต้อง	0	0.3562 ... 0.2891	0.0000
DCG@10 (Model A)				1.8869

1 คำนวณ DCG (Model A)

ใช้ gain(rel) = rel (ทวิภาค): รายการถูกต้องให้ 1, ไม่ถูกต้องให้ 0

DCG@10 = 1.0000 + 0.5000 + 0.3869

= 1.8869

ตัวอย่างการคำนวณ 2.4 : ขั้นที่ 2-4 IDCG และ nDCG

2 IDCG จากการเรียงอุดมคติ

ให้รายการถูกต้องทั้งสามอยู่ที่ตำแหน่ง 1, 2, 3

IDCG@10 = $1/\log_2 2 + 1/\log_2 3 + 1/\log_2 4$

= 1.0000 + 0.6309 + 0.5000 = 2.1309

3 หารเพื่อทำให้เป็นบรรทัดฐาน (Model A)

nDCG@10 (Model A) = 1.8869 / 2.1309

= 0.8855

4 ทำแบบเดียวกันกับ Model B

(ตำแหน่ง 4, 6, 9)

DCG@10 (B) = $1/\log_2 5 + 1/\log_2 7 + 1/\log_2 10$

= 0.4307 + 0.3562 + 0.3010 = 1.0879

IDCG@10 = 2.1309 (ค่าเดียวกัน)

nDCG@10 (Model B) = 1.0879 / 2.1309

= 0.5105

ผลลัพธ์

Model A ได้ nDCG@10= 0.8855 ส่วน Model B nDCG@10= ได้ 0.5105 ต่างกัน 1.73 เท่า โดย IDCG เป็นค่าเดียวกันทั้งสองModel เพราะขึ้นกับจำนวนรายการที่ผู้ใช้ชอบเท่านั้น ไม่ขึ้นกับผลลัพธ์ของModel

ตีความการเปรียบเทียบ nDCG @10

0.8855	vs	0.5105
nDCG @10 Model A		nDCG @10 Model B

แม้ Model A และ Model B จะแนะนำรายการที่เกี่ยวข้องได้ครบสามรายการเท่ากัน Model A มีค่า nDCG@10 เท่ากับ 0.8855 สูงกว่า Model B ซึ่งมีค่าเท่ากับ 0.5105 อยู่ 0.3750 จุด แสดงว่า Model A สามารถจัดวางรายการที่เกี่ยวข้องไว้ในอันดับต้นได้ใกล้เคียงกับลำดับอุดมคติมากกว่า

เลือกตัวชี้วัดให้สอดคล้องกับวัตถุประสงค์ของระบบ

แสดง/พยากรณ์ค่า Rating

- ใช้ MAE หรือ RMSE
- ต้องการให้คะแนนที่ทำนายใกล้เคียงคะแนนจริง

เลือกไม่กี่รายการมาแสดงด้านบน

- ใช้ Ranking Metrics เป็นหลัก
- Precision@K, Recall@K, nDCG@K

ต้องการทั้งสองด้าน

- รายงาน RMSE ร่วมกับ Ranking Metrics
- ไม่ใช้ค่าใดค่าหนึ่งแทนกัน

สรุป

RMSE ต่ำกว่า = ทำนาย “ค่าคะแนน” ใกล้จริงกว่า ภายใต้ชุดข้อมูล มาตราส่วน และวิธีแบ่งข้อมูลเดียวกันเท่านั้น แต่ไม่รับประกันว่าจะเลือก “รายการที่ดีที่สุด” หรือเรียงไว้อันดับต้นได้ดีกว่า

2.4

พื้นที่ใต้เส้นโค้ง ROC (AUC)

Area Under the ROC Curve • การเปรียบเทียบตัวชี้วัดทั้งแปดตัว • พฤติกรรมเมื่อ K เปลี่ยน

นิยาม 2.1 Area Under the ROC Curve (AUC)

$$AUC = \frac{\#\,\text{correctly ordered pairs}}{|\mathcal{R}_u| \times |\mathcal{N}_u|}$$

ความน่าจะเป็นที่Model จะให้คะแนนรายการที่ผู้ใช้ชอบ สูงกว่า รายการที่ผู้ใช้ไม่ชอบ เมื่อสุ่มมาอย่างละหนึ่งรายการ

องค์ประกอบ

- $|\mathcal{R}_u|$ = จำนวนรายการที่เกี่ยวข้อง
- $|\mathcal{N}_u|$ = จำนวนรายการที่ไม่เกี่ยวข้อง
- พิจารณาการจัดอันดับทั้ง Candidate Set โดยไม่ต้องกำหนด K
- แต่ต้องประกาศ Candidate Set ให้ชัด เพราะการเปลี่ยนรายการที่นำมาเปรียบเทียบเปลี่ยนค่า AUC ได้

การอ่านค่า

- AUC = 0.5 เดาสุ่ม
- AUC = 1.0 เรียงถูกทุกคู่
- AUC < 0.5 เรียงกลับด้านกับความจริงอย่างเป็นระบบ

ตัวอย่างการคำนวณ 2.5 AUC ด้วยการนับคู่ทีละคู่ (Model A)

อันดับ	1	2	3	4	5	6	7	8	9	10
Model A	i2 ✓	i7	i5 ✓	i3	i9 ✓	i1	i4	i6	i8	i10

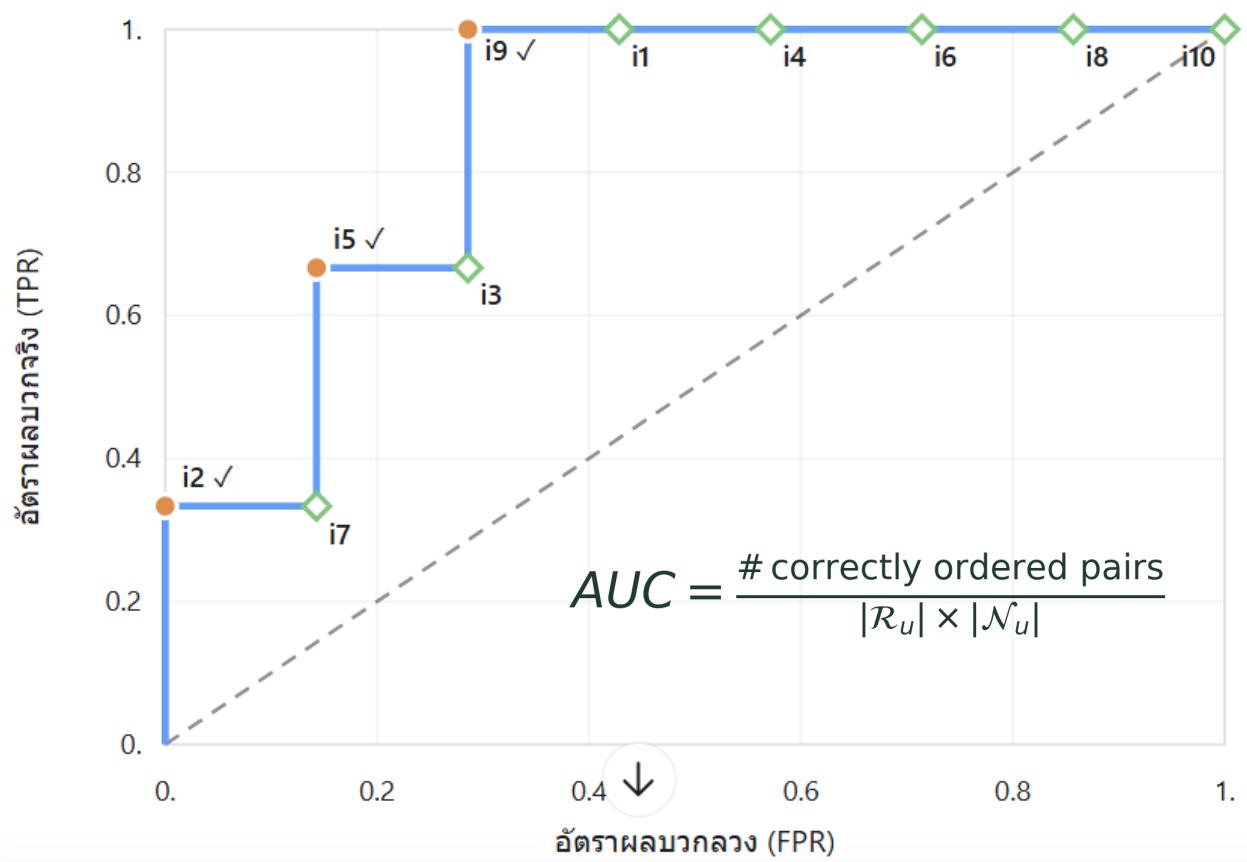
จุด/อันดับ	รายการที่เพิ่ม	ประเภท	TP สะสม	FP สะสม	TPR	FPR	จุด (FPR, TPR)
เริ่มต้น	–	–	0	0	$0/3 = 0$	$0/7 = 0$	$(0, 0)$
1	$i2$	เกี่ยวข้อง	1	0	$1/3 = 0.3333$	$0/7 = 0$	$(0, 0.3333)$
2	$i7$	ไม่เกี่ยวข้อง	1	1	$1/3 = 0.3333$	$1/7 = 0.1429$	$(0.1429, 0.3333)$
3	$i5$	เกี่ยวข้อง	2	1	$2/3 = 0.6667$	$1/7 = 0.1429$	$(0.1429, 0.6667)$
4	$i3$	ไม่เกี่ยวข้อง	2	2	$2/3 = 0.6667$	$2/7 = 0.2857$	$(0.2857, 0.6667)$
5	$i9$	เกี่ยวข้อง	3	2	$3/3 = 1.0000$	$2/7 = 0.2857$	$(0.2857, 1.0000)$
6	$i1$	ไม่เกี่ยวข้อง	3	3	1.0000	$3/7 = 0.4286$	$(0.4286, 1.0000)$
7	$i4$	ไม่เกี่ยวข้อง	3	4	1.0000	$4/7 = 0.5714$	$(0.5714, 1.0000)$
8	$i6$	ไม่เกี่ยวข้อง	3	5	1.0000	$5/7 = 0.7143$	$(0.7143, 1.0000)$
9	$i8$	ไม่เกี่ยวข้อง	3	6	1.0000	$6/7 = 0.8571$	$(0.8571, 1.0000)$
10	$i10$	ไม่เกี่ยวข้อง	3	7	1.0000	$7/7 = 1.0000$	$(1.0000, 1.0000)$

$$TPR = \frac{TP}{TP + FN} = \frac{TP}{3}$$

$$FPR = \frac{FP}{FP + TN} = \frac{FP}{7}$$

ตัวอย่างการคำนวณ 2.5 AUC ด้วยการนับคู่ทีละคู่ (Model A)

อันดับ	1	2	3	4	5	6	7	8	9	10
Model A	i2 ✓	i7	i5 ✓	i3	i9 ✓	i1	i4	i6	i8	i10



รายการที่เกี่ยวข้อง	ตำแหน่ง	จำนวนรายการไม่เกี่ยวข้องที่อยู่ใต้ลงไป
i2	1	7 ได้แก่ {i7, i3, i1, i4, i6, i8, i10}
i5	3	6 ได้แก่ {i3, i1, i4, i6, i8, i10}
i9	5	5 ได้แก่ {i1, i4, i6, i8, i10}
รวมคู่ที่เรียงถูก		18

1 แทนค่า

- $|\mathcal{R}_u|$ = จำนวนรายการที่เกี่ยวข้อง = 3
- $|\mathcal{N}_u|$ = จำนวนรายการที่ไม่เกี่ยวข้อง = 7
- จำนวนคู่ทั้งหมด = 3 × 7 = 21 คู่
- AUC = 18 / 21 = 0.8571

การตีความ AUC (Model A)

อันดับ	1	2	3	4	5	6	7	8	9	10
Model A	i2 ✓	i7	i5 ✓	i3	i9 ✓	i1	i4	i6	i8	i10

ตีความ AUC = 0.8571

- สุ่มรายการเกี่ยวข้อง 1 และไม่เกี่ยวข้อง 1 จะมีโอกาส 85.71% ที่จะจัดรายการเกี่ยวข้องไว้สูงกว่า
- ไม่ได้แปลว่า “ความแม่นยำ 85.71%” เพราะ AUC วัดคุณภาพการเรียงลำดับคู่
- เส้นทแยงมุมคือ AUC = 0.5 (การจัดอันดับแบบสุ่ม); i7, i3 ถูกวางเหนือรายการเกี่ยวข้องบางรายการ จึงยังไม่สมบูรณ์แบบ

ตัวอย่างการคำนวณ 2.5 AUC ด้วยการนับคู่ทีละคู่ (Model B)

อันดับ	1	2	3	4	5	6	7	8	9	10
Model B	i7	i3	i1	i2 ✓	i4	i5 ✓	i6	i8	i9 ✓	i10

Model B

รายการที่เกี่ยวข้อง	ตำแหน่ง	จำนวนรายการไม่เกี่ยวข้องที่อยู่ใต้ลงไป
i2	4	4 ได้แก่ {i4, i6, i8, i10}
i5	6	3 ได้แก่ {i6, i8, i10}
i9	5	1 ได้แก่ {i10}
รวมคู่ที่เรียงถูก		8

- $|\mathcal{R}_u|$ = จำนวนรายการที่เกี่ยวข้อง = 3
- $|\mathcal{N}_u|$ = จำนวนรายการที่ไม่เกี่ยวข้อง = 7
- จำนวนคู่ทั้งหมด = 3 × 7 = 21 คู่
- รวมจำนวนคู่ที่เรียงถูก = 8
- AUC = 8 / 21 = 0.3810

ตีความการเปรียบเทียบ AUC

0.8571	VS	0.3810
AUC Model A		AUC Model B

Model A มีค่า AUC เท่ากับ 0.8571 หมายความว่า แบบจำลองสามารถจัดรายการที่เกี่ยวข้องให้อยู่เหนือรายการที่ไม่เกี่ยวข้องได้ถูกต้องประมาณ 85.71% ของคู่เปรียบเทียบทั้งหมด ขณะที่ Model B มีค่า AUC เท่ากับ 0.3810 ซึ่งต่ำกว่าเกณฑ์การจัดอันดับแบบสุ่มที่มีค่าเท่ากับ 0.5 ผลลัพธ์จึงแสดงว่า Model A มีคุณภาพการจัดอันดับโดยรวมสูงกว่า Model B อย่างชัดเจน

AUC ที่ต้องรู้ก่อนใช้เป็น Primary Metric

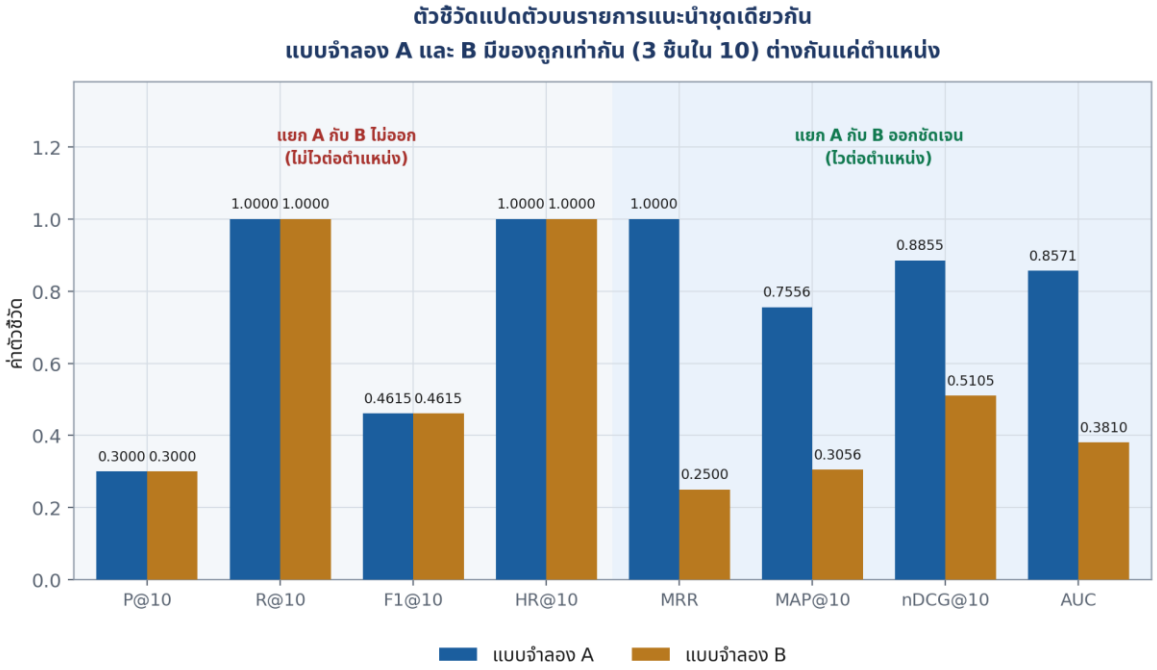
ข้อจำกัด: AUC ให้น้ำหนักทุกคู่เท่ากันหมด

- AUC พิจารณาว่า รายการที่เกี่ยวข้องถูกจัดให้อยู่เหนือรายการที่ไม่เกี่ยวข้องกี่คู่ โดยให้ความสำคัญกับทุกคู่เท่ากัน ไม่ว่าคู่นั้นจะอยู่บริเวณต้นหรือท้ายของรายการ ตัวอย่างเช่น หากรายการที่เกี่ยวข้องเลื่อนจากอันดับ 400 ขึ้นมาอันดับ 399 โดยแซงรายการที่ไม่เกี่ยวข้องหนึ่งรายการ ค่า AUC จะเพิ่มขึ้นเท่ากับกรณีที่รายการเกี่ยวข้องเลื่อนจากอันดับ 4 ขึ้นมาอันดับ 3 และแซงรายการที่ไม่เกี่ยวข้องหนึ่งรายการเช่นกัน
- อย่างไรก็ตาม การเลื่อนจากอันดับ 4 ขึ้นมาอันดับ 3 มีผลต่อประสบการณ์ของผู้ใช้มากกว่า เพราะเป็นตำแหน่งที่ผู้ใช้มีโอกาสมองเห็นจริง ขณะที่การเปลี่ยนแปลงบริเวณอันดับ 399–400 อาจไม่มีผลต่อผู้ใช้เลย
- ดังนั้น AUC จึงเหมาะสำหรับประเมินความสามารถในการจัดอันดับโดยรวม แต่หากระบบแสดงผลเพียง 10 อันดับแรก ควรใช้ตัวชี้วัดที่เน้นส่วนต้นของรายการ เช่น nDCG@10, Precision@10 หรือ Recall@10 เป็นตัวชี้วัดหลัก

ตัวชี้วัด	ใช้วัดอะไร	ค่าที่สูงกว่าแสดงว่า	ข้อจำกัดสำคัญ
RR	ตำแหน่งของรายการที่เกี่ยวข้องรายการแรกสำหรับผู้ใช้หนึ่งคน	ผู้ใช้พบรายการที่เกี่ยวข้องรายการแรกเร็วขึ้น	ไม่สนใจรายการที่เกี่ยวข้องชิ้นถัดไป
MRR	ค่าเฉลี่ย RR ของผู้ใช้ทั้งหมด	โดยเฉลี่ยผู้ใช้พบรายการที่เกี่ยวข้องรายการแรกเร็วขึ้น	พิจารณาเฉพาะรายการแรกของผู้ใช้แต่ละคน
AP@K	ความสามารถในการจัดรายการที่เกี่ยวข้องทุกชิ้นของผู้ใช้หนึ่งคนให้อยู่ในอันดับต้นของ Top-K	รายการที่เกี่ยวข้องของผู้ใช้คนนั้นปรากฏในอันดับต้นมากขึ้น	โดยทั่วไปใช้ความเกี่ยวข้องแบบ 0–1
MAP@K	ค่าเฉลี่ย AP@K ของผู้ใช้ทั้งหมด	โดยรวมระบบจัดรายการที่เกี่ยวข้องไว้ในอันดับต้นได้ดีขึ้น	อาจไม่สะท้อนความเกี่ยวข้องหลายระดับ
nDCG@K	ความใกล้เคียงกับลำดับอุดมคติ โดยพิจารณาทั้งตำแหน่งและระดับความเกี่ยวข้อง	รายการที่เกี่ยวข้องมากถูกจัดไว้ในอันดับต้น และลำดับใกล้เคียงอุดมคติมากขึ้น	ต้องระบุค่า rel ฟังก์ชันผลได้และฟังก์ชันส่วนลด
AUC	ความสามารถในการจัดรายการที่เกี่ยวข้องให้อยู่เหนือรายการที่ไม่เกี่ยวข้องตลอดรายการจัดอันดับ	ระบบแยกและจัดอันดับรายการที่เกี่ยวข้องได้ดีขึ้น	ไม่เน้นเฉพาะรายการอันดับต้นที่ผู้ใช้มองเห็น

2.4.1 ตารางที่ 2.3 ตัวชี้วัดทั้งแปดบนข้อมูลชุดเดียวกัน

ตัวชี้วัด	Model A	Model B	อัตราส่น A/B	แยกได้?
Precision@10	0.3000	0.3000	1.00	แยกไม่ออก
Recall@10	1.0000	1.0000	1.00	แยกไม่ออก
F1@10	0.4615	0.4615	1.00	แยกไม่ออก
HR@10	1.0000	1.0000	1.00	แยกไม่ออก
MRR	1.0000	0.2500	4.00	แยกออก
MAP@10	0.7556	0.3056	2.47	แยกออก
nDCG@10	0.8855	0.5105	1.73	แยกออก
AUC	0.8571	0.3810	2.25	แยกออก



บทเรียนสำคัญสองข้อจากตารางที่ 2.3

ข้อที่หนึ่ง การเลือกตัวชี้วัดคือการเลือกข้อสรุป

- ทีมที่รายงาน Precision@10 จะสรุปว่า Model ทั้งสองดีเท่ากัน
- ทีมที่รายงาน MRR จะสรุปว่า Model A ดีกว่าถึงสี่เท่า
- ทั้งสองทีมคำนวณถูกต้องทุกหลัก แต่ให้คำตอบต่อผู้บริหารต่างกันโดยสิ้นเชิง
- ต้องประกาศ Primary Metric ไว้ก่อนเห็นผล

ข้อที่สอง ขนาดของความต่างก็ขึ้นกับตัวชี้วัด

- แม้ในกลุ่มที่แยกความต่างได้ทั้งสี่ตัว ค่า **อัตราส่วน A/B** มีค่าตั้งแต่ 1.73 เท่า (nDCG) ถึง 4.00 เท่า (MRR)
- การอ้างว่า “Model Y องเราดีกว่าอย่างมีนัยสำคัญ” จึงไม่มีความหมาย หากไม่ระบุว่าวัดด้วยตัวชี้วัดใด

2.5

คุณภาพนอกเหนือความถูกต้อง (Beyond-Accuracy)

Coverage • Gini • Long-tail • ILD • Novelty • Calibration • Fairness

เหตุใดความถูกต้องเพียงด้านเดียวจึงไม่พอ

ปัญหา

- ระบบที่แนะนำรายการยอดนิยมชุดเดิมแก่ทุกคน อาจได้คะแนนออฟไลน์ดูดี
- แต่ผู้ใช้ไม่พบสิ่งใหม่ และรายการส่วนใหญ่ในคลังไม่เคยถูกแสดง
- ระบบเช่นนี้ “ไม่ได้แนะนำอะไรที่เป็นส่วนตัวเลย” และทำลายระบบนิเวศของผู้ผลิตเนื้อหาในระยะยาว

ตัวชี้ในหัวข้อนี้

- Catalog Coverage
- Gini Coefficient of Exposure
- Long-tail Ratio และ Intra-List Diversity (ILD)
- Novelty
- Calibration
- Fairness (User-side และ Provider-side)

วิธีการของหัวข้อนี้

สูตรแต่ละตัวดูเรียบง่ายจนหลอกตา ผู้เรียนมักคิดว่าเข้าใจแล้วหลังอ่านสูตร แต่คำนวณผิดทันทีเมื่อลงมือทำ หัวข้อนี้จึงกลับไปใช้ MovieMini-12 ชุดเดียวกับหัวข้อ 2.1 แล้วคำนวณทั้งเจ็ดตัวบนสถานการณ์เดียวกันทีละขั้นจนครบ เพื่อให้เห็นว่าตัวชี้วัดแต่ละตัว “มองเห็น” และ “มองไม่เห็น” อะไร

กรณีศึกษาร่วมของหัวข้อ 2.5: คลังภาพยนตร์ MovieMini-12

รหัส	ชื่อเรื่อง	แนว	ค่าย	ผู้เคยชม	กลุ่ม
i1	The Matrix	Sci-Fi	ก	400	**หัว**
i2	Inception	Sci-Fi	ก	150	หาง
i3	Interstellar	Sci-Fi	ก	25	หาง
i4	Titanic	Romantic	ข	300	**หัว**
i5	La La Land	Romantic	ข	100	หาง
i6	The Notebook	Romantic	ง	8	หาง
i7	John Wick	Action	ค	250	หาง
i8	Mad Max	Action	ง	15	หาง
i9	Parasite	Thriller	ข	60	หาง
i10	Toy Story	Animation	ข	200	หาง
i11	Coco	Animation	ค	40	หาง
i12	Spirited Away	Animation	ง	2	หาง

เงื่อนไข

- ภาพยนตร์ 12 เรื่อง ผู้ใช้ 8 คน
- แสดงผลคนละ 5 อันดับ (K = 5)
- ช่องแสดงผลทั้งระบบ 8 × 5 = 40 ช่อง
- “ผู้เคยชม” = จำนวนผู้ใช้ทั้งแพลตฟอร์ม (ฐาน 500 คน) ที่เคยชมเรื่องนั้น

ค่ายผู้ผลิต

- ค่าย ก: i1, i2, i3
- ค่าย ข: i4, i5, i9, i10
- ค่าย ค: i7, i11
- ค่าย ง: i6, i8, i12 (ค่ายเล็ก)

Head Items กับ Tail Items

กลุ่มหัว (Head Items)

- รายการจำนวนน้อยที่ได้รับความนิยมสูง มีปฏิสัมพันธ์มาก เช่น ภาพยนตร์ยอดนิยม เพลงติดอันดับ สินค้าขายดี
- ข้อมูลมาก Model เรียนรู้และแนะนำได้ง่าย แต่แนะนำมากเกินไปจะขาดความหลากหลาย

กลุ่มหาง (Tail Items)

- รายการจำนวนมากที่แต่ละรายการมีปฏิสัมพันธ์น้อย เช่น ภาพยนตร์เฉพาะกลุ่ม เพลงศิลปินหน้าใหม่
- อาจตรงกับความสนใจเฉพาะบุคคลได้ดี แต่มีข้อมูลน้อย จึงประเมินความเกี่ยวข้องได้ยากกว่า

$$\text{group}(i) = \text{Head} \quad \text{if } \textit{popularity}(i) \geq 300, \quad \text{Tail} \quad \text{otherwise}$$

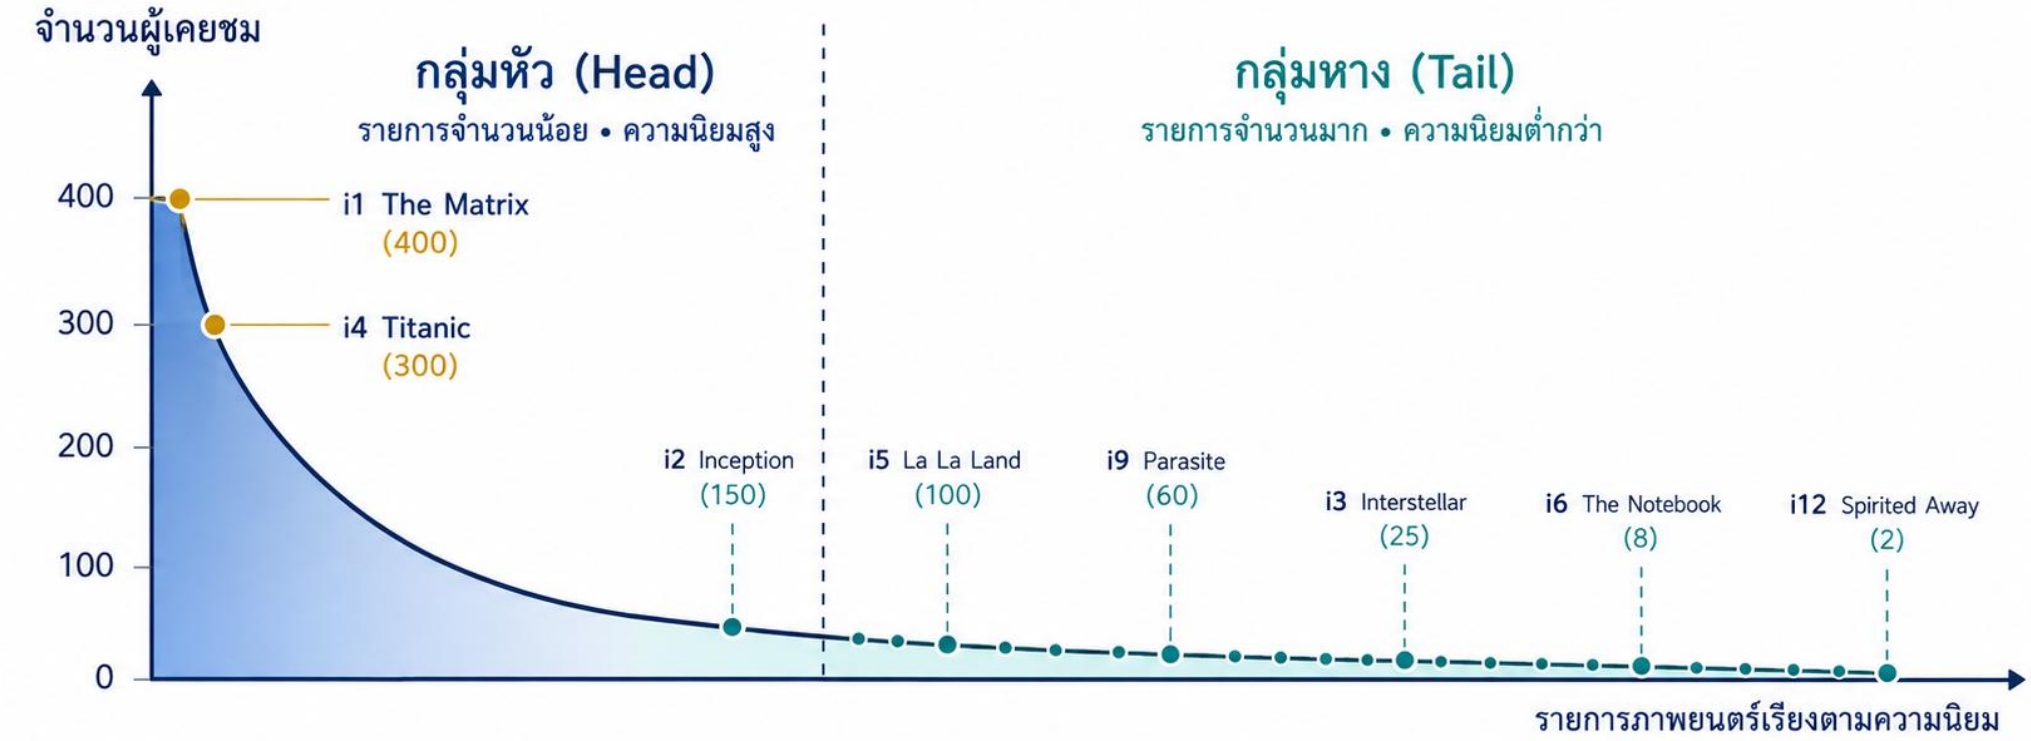
หัว: i1 The Matrix (400), i4 Titanic (300)

หาง: i2–i3, i5–i12 (รวม i7 ที่มี 250 คน)

ข้อควรระวัง

"หัว" และ "หาง" ไม่มีเกณฑ์ตายตัว (Top-2, 20% ของรายการ, หรือครอบคลุม 80% ของการรับชม) จึงต้องประกาศวิธีแบ่งทุกครั้ง

Head Items กับ Tail Items



กลุ่มหัว (Head)

รายการจำนวนน้อย • ความนิยมสูง

1	i1	The Matrix	400
2	i4	Titanic	300

กลุ่มหาง (Tail)

รายการจำนวนมาก • ความนิยมต่ำกว่า

1	i2	Inception	150
2	i5	La La Land	100
3	i9	Parasite	60
4	i3	Interstellar	25
5	i6	The Notebook	8
6	i12	Spirited Away	2

หัว = รายการน้อยแต่ได้รับความนิยมสูง | หาง = รายการมากแต่แต่ละรายการได้รับความนิยมน้อยกว่า

Model X (Popularity) เทียบ Model Y (Personalized) บน MovieMini-12

ผู้ใช้	กลุ่ม	Model X (Top-5)	Model Y (Top-5)
Emma	ประวัติยาว	i1 i4 i7 i10 i2	i1 i4 i7 i10 i2
Olivia	ประวัติยาว	i1 i4 i7 i10 i2	i4 i5 i6 i11 i9
Sophia	ประวัติยาว	i1 i4 i7 i10 i2	i4 i5 i6 i10 i12
Daniel	ประวัติยาว	i1 i4 i7 i10 i2	i2 i3 i9 i7 i8
James	ประวัติสั้น	i1 i4 i7 i10 i2	i1 i2 i3 i10 i5
Michael	ประวัติสั้น	i1 i4 i7 i10 i2	i3 i7 i8 i2 i1
Ava	ประวัติสั้น	i1 i4 i7 i10 i2	i2 i4 i6 i11 i10
Ethan	ประวัติสั้น	i1 i4 i7 i10 i2	i1 i5 i7 i3 i11

การแบ่งกลุ่มผู้ใช้

- Long-history: ให้คะแนน ≥ 8 เรื่อง (Emma, Olivia, Sophia, Daniel)
- Short-history: ที่เหลือสี่คน : มักเผชิญ User Cold-start

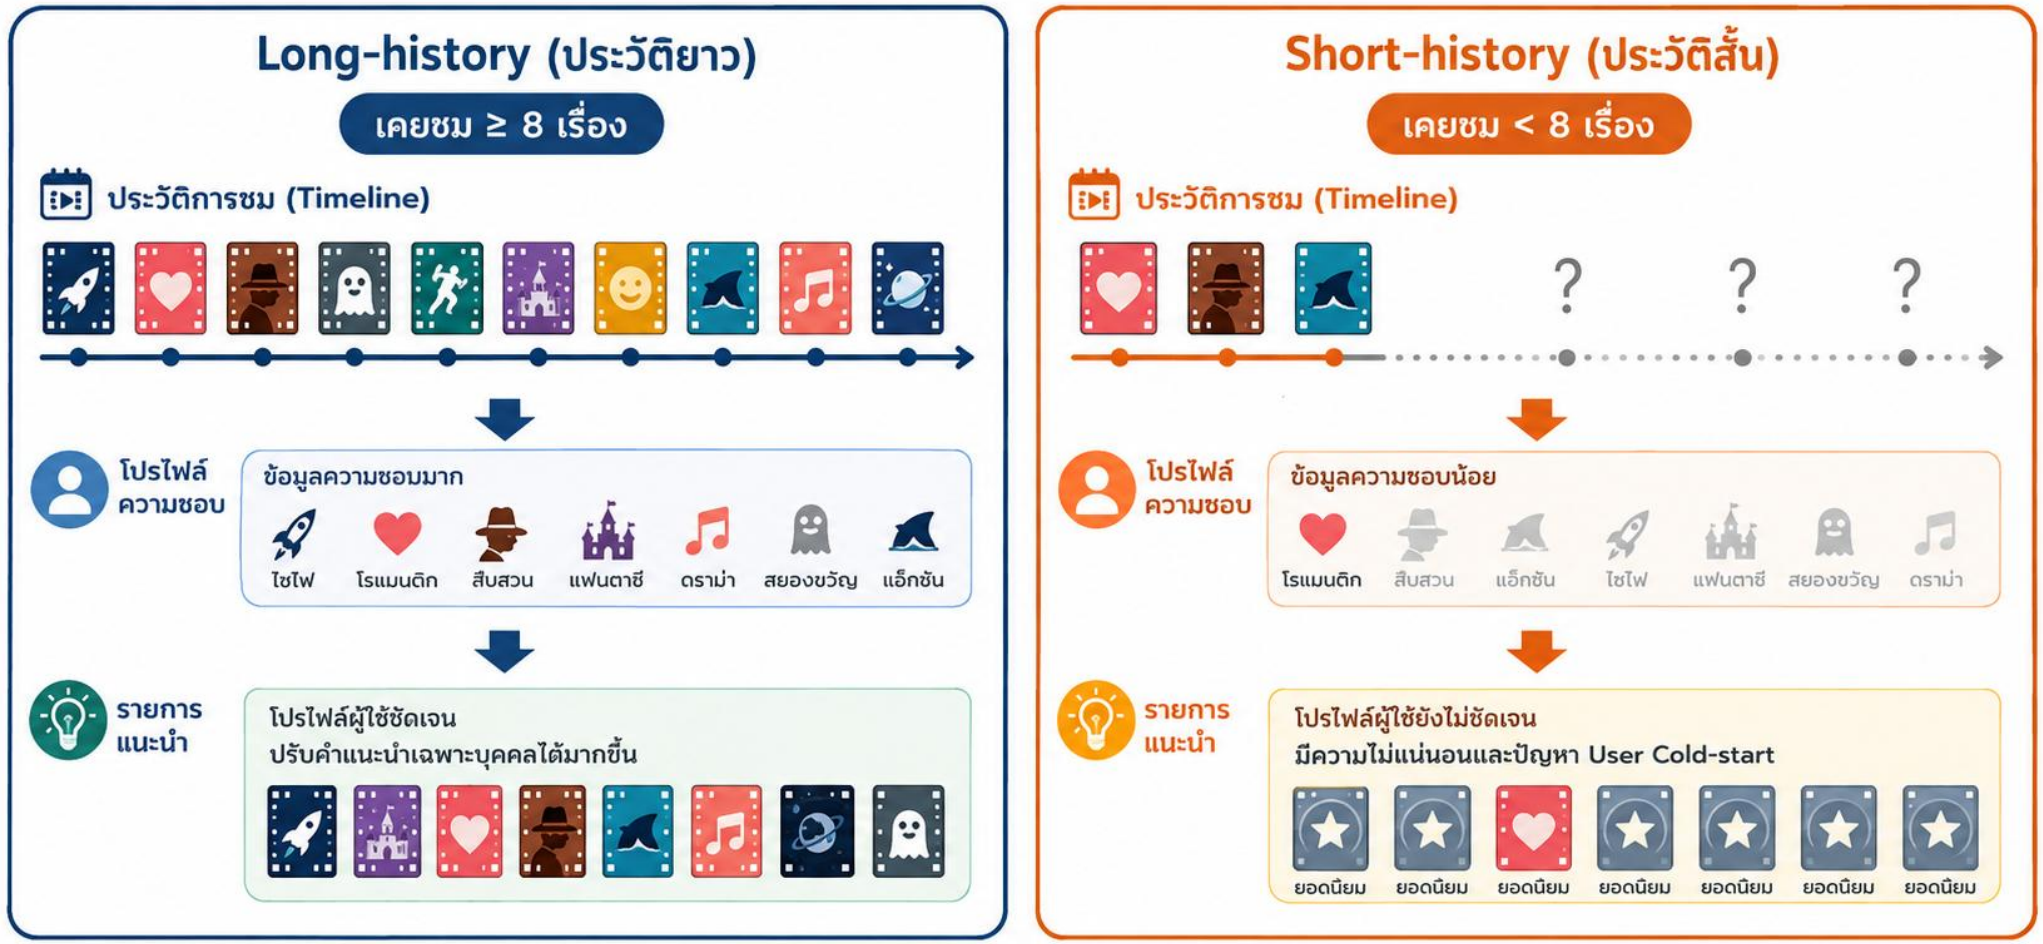
Ground Truth ของความแม่นยำ

- ภาพยนตร์ที่ผู้ใช้ให้คะแนนตั้งแต่ 4 ดาวขึ้นไปในตารางคะแนนของหัวข้อ 2.1
- ใช้ข้อมูลชุดเดียวทั้ง Rating Prediction และ Ranking โดยเปรียบเทียบข้ามหัวข้อได้

สังเกตด้วยตาเปล่าก่อนคำนวณ

คอลัมน์Model X เหมือนกันทั้งแปดแถว (ไม่มีสิ่งใดขึ้นกับตัวผู้ใช้) : ตัวชี้วัดตัวใดจับความต่างข้อนี้ได้ และตัวใดจับไม่ได้?

Long-history และ Short-history



เกณฑ์ ≥ 8 เรื่องใช้เฉพาะกรณีศึกษานี้

2.5.1 Catalog Coverage

$$Coverage@K = \frac{\left|\bigcup_{u \in \mathcal{U}} \mathcal{L}_u^K\right|}{|\mathcal{I}|}$$

สัดส่วนของรายการในคลังทั้งหมด ที่เคยปรากฏในรายการแนะนำของผู้ใช้อย่างน้อยหนึ่งคน

องค์ประกอบ

- $\mathcal{L}_u^K$ = รายการแนะนำ K อันดับแรกของผู้ใช้ u;
- $\mathcal{I}$ = เซตรายการทั้งหมดที่ระบบแนะนำได้
- สัญลักษณ์ $\bigcup$ คือยูเนียนของเซต ⟶ รายการหนึ่งชิ้นถูกนับเพียงครั้งเดียว ไม่ว่าจะปรากฏในผลลัพธ์ของผู้ใช้กี่คน
- คุณสมบัตินี้เป็นทั้งจุดแข็งและจุดอ่อน

ตัวอย่างการอ่านค่า

- Coverage@10 = 0.042 หมายความว่า มีเพียง 4.2% ของคลังที่ผู้ใช้ทั้งระบบมีโอกาสได้เห็น
- อีก 95.8% ไม่มีวันถูกค้นพบ ไม่ว่าจะดีเพียงใด

การอ่านค่า Catalog Coverage

ตัวอย่างการอ่านค่า Coverage@10 = 0.042

- หมายความว่า เมื่อรวมรายการ Top-10 ของผู้ใช้ทุกคนแล้ว ระบบนำรายการที่แตกต่างกันมาแนะนำเพียง 4.2% ของรายการทั้งหมดในแค็ตตาล็อก
- ตัวอย่างเช่น หากแค็ตตาล็อกมี 1,000 รายการ ค่า Coverage@10 เท่ากับ 0.042 หมายถึงมีรายการเพียง 0.042x1,000 =42รายการ ที่ปรากฏใน Top-10 อย่างน้อยหนึ่งครั้ง ส่วนอีก 958 รายการไม่ปรากฏในการแนะนำสำหรับกลุ่มผู้ใช้ที่นำมาประเมิน
- อย่างไรก็ตาม ข้อความว่า “อีก 95.8% ไม่มีวันถูกค้นพบ” รุนแรงเกินไป เพราะ Coverage บอกเพียงว่า รายการเหล่านั้น ไม่ปรากฏในผลการแนะนำของการประเมินครั้งนี้ ไม่ได้ยืนยันว่าจะไม่มีวันถูกแนะนำในอนาคต หากเปลี่ยนผู้ใช้ ข้อมูล หรือแบบจำลอง ผลลัพธ์อาจเปลี่ยนได้
- **ดังนั้น ค่า Coverage@10 เท่ากับ 0.042 ไม่ได้หมายความว่าระบบไม่ดีทันที แต่แสดงว่า ระบบใช้ประโยชน์จากแค็ตตาล็อกในวงแคบ และอาจมีปัญหาการกระจุกตัวอยู่กับรายการบางกลุ่ม**

สาเหตุ ที่ทำให้ค่า Catalog Coverage ต่ำ

เช่น

- ระบบแนะนำรายการยอดนิยมชุดเดิมให้ผู้ใช้จำนวนมาก
- จำนวนผู้ใช้ในการประเมินมีน้อยเมื่อเทียบกับขนาดแค็ตตาล็อก
- ค่า K ต่ำ ทำให้มีช่องสำหรับแสดงรายการจำกัด
- แบบจำลองให้ความสำคัญกับความแม่นยำมากกว่าความหลากหลาย
- รายการบางส่วนมีข้อมูลน้อยจนระบบไม่สามารถเรียนรู้ได้ดี

ตัวอย่างการคำนวณ 2.6 Coverage@5 ทีละขั้น บน MovieMini-12

1 Model X: สร้างเซตยูเนียนทีละผู้ใช้

Emma: {i1, i2, i4, i7, i10} ⟶ $|C_1| = 5$

Olivia: ชุดเดียวกัน ⟶ ไม่มีรายการใหม่

ผู้ใช้เจ็ดคนหลังไม่เพิ่มเรื่องใหม่แม้แต่เรื่องเดียว

Coverage@5 (ก) = 5 / 12

= 0.4167

2 Model Y : เซตโตขึ้นเรื่อย ๆ

Emma: {i1, i2, i4, i7, i10} ⟶ $|C_1| = 5$

Olivia เพิ่ม i5, i6, i11, i9 ⟶ $|C_2| = 9$

Sophia เพิ่ม i12 ⟶ $|C_3| = 10$

Daniel เพิ่ม i3, i8 ⟶ $|C_4| = 12$ ครบทั้งคลัง

James–Ethan ไม่มีรายการใหม่

Coverage@5 (ข) = 12 / 12 = 1.0000

3 ตีความ

- Model Y ครอบคลุม 100% ส่วนModel X เพียง 41.67%
- Model Y เปิดโอกาสให้คลังถูกค้นพบมากกว่า 2.4 เท่า

2.5.2 Gini Coefficient of Exposure

$$Gini = \frac{\sum_{i=1}^{n} (2i - n - 1)\, x_i}{n \sum_{i=1}^{n} x_i}$$

Coverage บอกได้เพียงว่ามีรายการกี่ชิ้นที่ “เคยถูกแนะนำอย่างน้อยหนึ่งครั้ง” แต่บอกไม่ได้ว่าการเปิดเผยนั้นกระจายอย่างเท่าเทียมเพียงใด ระบบที่แนะนำรายการหนึ่งชิ้นเป็นพันครั้ง และอีกสี่สิบเก้าชิ้นชิ้นละครั้ง มี Coverage เท่ากับระบบที่แนะนำทั้งห้าสิบชิ้นเท่า ๆ กัน ตัวชี้วัดที่จับความต่างนี้ได้คือสัมประสิทธิ์จีนี ซึ่งยืมมาจากเศรษฐศาสตร์ที่ใช้วัดความเหลื่อมล้ำของรายได้

สัญลักษณ์

- x_i = จำนวนครั้งที่รายการที่ i ถูกแนะนำ เรียงจากน้อยไปมาก; n = จำนวนรายการทั้งหมด
- 0 = ทุกรายการถูกเปิดเผยเท่ากัน; เข้าใกล้ 1 = กระจุกที่รายการเดียว

กฎบังคับ

- การเรียงลำดับก่อนคำนวณเป็นขั้นบังคับ ไม่ใช่ทางเลือก : ลืมเรียงแล้วสูตรจะคืนค่าที่ไม่มีความหมาย
- ตรวจสอบง่าย ๆ: ผลรวมของสัมประสิทธิ์ $\sum(2i - n - 1) = 0$ เสมอ

ตัวอย่างการคำนวณ 2.7 : ขั้นที่ 1 นับจำนวนครั้งที่แต่ละเรื่องถูกแนะนำ (การเปิดเผย)

ระบบ	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	รวม
Model X	8	8	0	8	0	0	8	0	0	8	0	0	40
Model Y	4	5	5	3	4	3	3	2	3	3	3	2	40

อ่านผล

- Model X เปิดเผยเพียงห้าเรื่อง เรื่องละแปดครั้งเท่ากันหมด และอีกเจ็ดเรื่องได้ศูนย์
- Model Y กระจายการเปิดเผยไปทั่วทั้งคลังในช่วง 2 ถึง 5 ครั้ง
- ผลรวมทั้งสองระบบต้องเท่ากับจำนวนช่องแสดงผล 8 × 5 = 40 พอดี (ใช้ตรวจทาน)

ขั้นถัดไป

- เรียงค่าจากน้อยไปมาก
- คูณด้วยสัมประสิทธิ์ (2i − n − 1) = (2i − 13) เมื่อ n = 12
- รวมผลคูณ แล้วหารด้วย $n \times \sum x_i = 12 \times 40 = 480$

ตัวอย่างการคำนวณ 2.7 : ขั้นที่ 2 คูณทีละพจน์ (Model X, n = 12)

อันดับ i	ภาพยนตร์	x_i (เรียงแล้ว)	2i − 13	(2i − 13)·x_i
1	i3 Interstellar	0	−11	0
2	i5 La La Land	0	−9	0
3	i6 The Notebook	0	−7	0
4	i8 Mad Max	0	−5	0
5	i9 Parasite	0	−3	0
6	i11 Coco	0	−1	0
7	i12 Spirited Away	0	1	0
8	i1 The Matrix	8	3	24
9	i2 Inception	8	5	40
10	i4 Titanic	8	7	56
11	i7 John Wick	8	9	72
12	i10 Toy Story	8	11	88
รวม		40	0	280

2 ตรวจทานอย่างรวดเร็ว

ผลรวมคอลัมน์ (2i − 13) = 0 ✓

ผลรวมคอลัมน์ x_i = 40 = จำนวนแสดงผล ✓

3 แทนค่า

Gini (Model X) = 280 / (12 × 40)

= 280 / 480 = 0.5833

ตัวอย่างการคำนวณ 2.7 : ขั้นที่ 2 คูณทีละพจน์ (Model Y, n = 12)

อันดับ i	ภาพยนตร์	x_i (เรียงแล้ว)	2i − 13	(2i − 13)·x_i
1	i8 Mad Max	2	−11	−22
2	i12 Spirited Away	2	−9	−18
3	i4 Titanic	3	−7	−21
4	i6 The Notebook	3	−5	−15
5	i7 John Wick	3	−3	−9
6	i9 Parasite	3	−1	−3
7	i10 Toy Story	3	1	3
8	i11 Coco	3	3	9
9	i1 The Matrix	4	5	20
10	i5 La La Land	4	7	28
11	i2 Inception	5	9	45
12	i3 Interstellar	5	11	55
รวม		40	0	72

2 ตรวจทานอย่างรวดเร็ว

ผลรวมคอลัมน์ (2i − 13) = 0 ✓

ผลรวมคอลัมน์ x_i = 40 = จำนวนแสดงผล ✓

3 แทนค่า

Gini (Model Y) = 72 / (12 × 40)

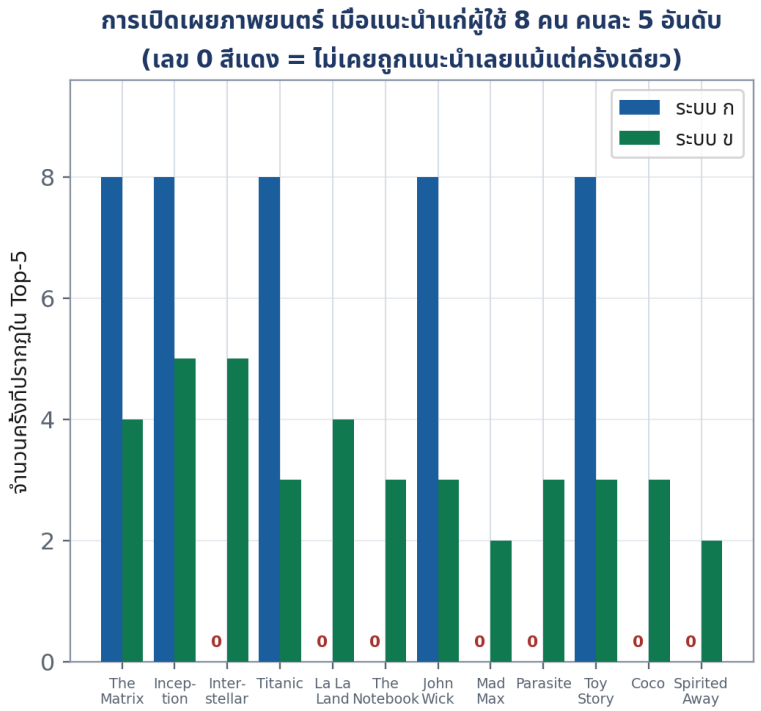
= 72 / 480 =0.1500

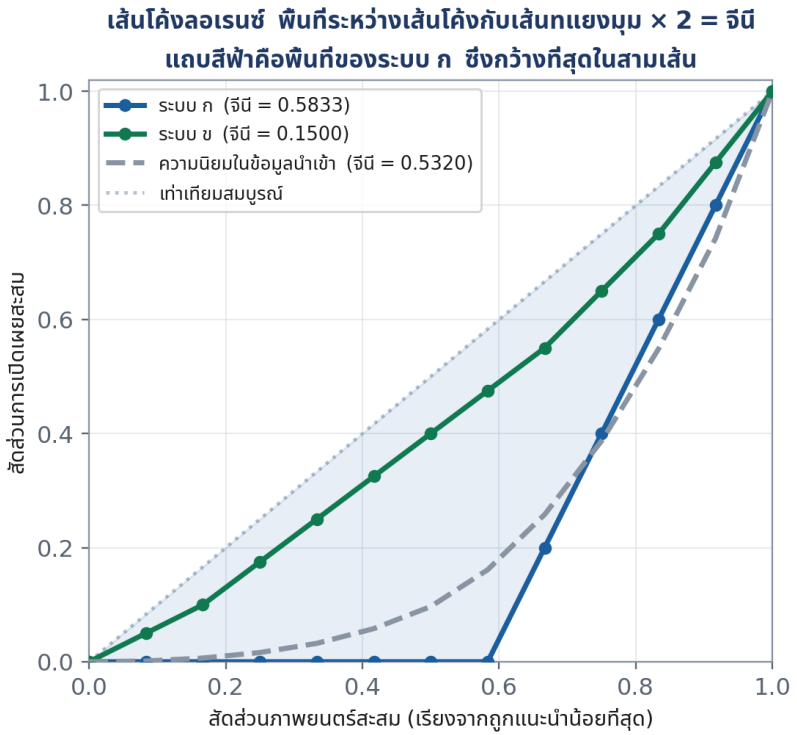
ตีความการเปรียบเทียบ Gini Coefficient of Exposure

0.5833	vs	0.1500
Gini Coefficient Model X	vs	Gini Coefficient Model Y

- Model Y มีค่า Gini Coefficient เท่ากับ 0.1500 ต่ำกว่า Model X ซึ่งมีค่าเท่ากับ 0.5833 แสดงว่า Model Y กระจายโอกาสในการถูกแนะนำไปยังภาพยนตร์ในแค็ตตาล็อกได้สม่ำเสมอกว่า ขณะที่ Model X มีการแนะนำกระจุกตัวอยู่กับภาพยนตร์เพียงไม่กี่เรื่อง
- อย่างไรก็ตาม ค่า Gini ต่ำไม่ได้หมายความว่ารายการแนะนำตรงกับความต้องการของผู้ใช้มากกว่า แต่หมายถึงระบบกระจายการแนะนำได้ทั่วถึงกว่าเท่านั้น จึงควรพิจารณาร่วมกับ Precision@K, Recall@K หรือ nDCG@K เพื่อประเมินความแม่นยำ

ภาพที่ 2.7 การเปิดเผยและ Lorenz Curve





- แกนนอน: สัดส่วนภาพยนตร์สะสม เรียงจากถูกแนะนำน้อย⟶มาก
- แกนตั้ง: สัดส่วนการเปิดเผยสะสม
- พื้นที่ระหว่างเส้นโค้งกับเส้นทแยงมุม × 2 = ค่า Gini
- เส้นของModel X ห้อยต่ำกว่า Model Y ชัดเจน

ซ้าย: จำนวนครั้งที่แต่ละเรื่องปรากฏใน Top-5 (เลขศูนย์สีแดง = ไม่เคยถูกแนะนำ) ขวา: Lorenz Curve

Lorenz Curve ตัดกันได้

เส้นModel X กับเส้นข้อมูลนำเข้าตัดกันช่วงท้าย ค่า Gini ตัวเดียวสรุปได้เพียง “พื้นที่รวม” ในรายงานที่จริงจังควรแนบ Lorenz Curve คู่กับค่า Gini เสมอ (เช่นเดียวกับ ROC คู่กับ AUC)

2.5.3 นิยาม 2.2 Long-Tail Items และ LongTailRatio@K

$$LongTailRatio@K(u) = \frac{|\mathcal{L}_u^K \cap \mathcal{I}_{tail}|}{K}$$

สัดส่วนของรายการใน Top-K ที่เป็นรายการส่วนหาง (Tail)

นิยาม

- เรียงรายการทั้งคลังตามความนิยมจากมากไปน้อย โดยกราฟจะเป็นเส้นโค้งลาดชันช่วงต้นแล้วแบนยาว
- กลุ่มแรกที่ความนิยมสูง = Head Items; ที่เหลือซึ่งแต่ละชิ้นมีปฏิสัมพันธ์น้อยแต่มีจำนวนมหาศาล = Long-Tail Items

เส้นแบ่งที่นิยมใช้

- จุดที่ปฏิสัมพันธ์สะสมถึง 1/3 ของทั้งหมด: รายการก่อนจุดนั้น = หัว ที่เหลือ = หาง
- บางงานวัจัยใช้เกณฑ์ 20% ของรายการ ดังนั้นต้องประกาศเกณฑ์ที่ใช้ทุกครั้ง

ตัวอย่างการคำนวณ 2.8 เส้นแบ่งหัว–หาง และ LongTailRatio@5

ขั้นที่ 1 เรียงคลังตามความนิยมจากมากไปน้อย แล้วไล่ผลรวมสะสมจนถึงหนึ่งในสาม: ปฏิสัมพันธ์รวม 1,550 ดังนั้น 1/3 = 516.67

ภาพยนตร์	ผู้เคยชม	สะสม	สัดส่วนสะสม	ถึง 1/3?	จัดเป็น
i1 The Matrix	400	400	0.2581	ยัง	หัว
i4 Titanic	300	700	0.4516	ถึงแล้ว	หัว
i7 John Wick	250	950	0.6129	—	หาง
อีกเก้าเรื่อง	รวม 600	1,550	1.0000	—	หาง

จากตัวอย่าง กลุ่มหัวเพียง 2 จาก 12 เรื่อง (16.7% ของคลัง) แต่ครองปฏิสัมพันธ์ 45.2%; กลุ่มหาง 10 เรื่อง (83.3%)

ตัวอย่างการคำนวณ LongTail@5 ของ Model X

ผู้ใช้	Model X (Top-5)	รายการส่วนหัว	จำนวนส่วนหาง	LongTail@5
Emma	i1 i4 i7 i10 i2	2	3	3/5 = 0.600
Olivia	i1 i4 i7 i10 i2	2	3	3/5 = 0.600
Sophia	i1 i4 i7 i10 i2	2	3	3/5 = 0.600
Daniel	i1 i4 i7 i10 i2	2	3	3/5 = 0.600
James	i1 i4 i7 i10 i2	2	3	3/5 = 0.600
Michael	i1 i4 i7 i10 i2	2	3	3/5 = 0.600
Ava	i1 i4 i7 i10 i2	2	3	3/5 = 0.600
Ethan	i1 i4 i7 i10 i2	2	3	3/5 = 0.600
			LongTail@5 (Model X)	$\frac{8x0.6}{8} = 0.600$

ตัวอย่างการคำนวณ LongTail@5 ของ Model Y

ผู้ใช้	Model Y (Top-5)	รายการส่วนหัว	จำนวนส่วนหาง	LongTail@5
Emma	i1 i4 i7 i10 i2	2	3	3/5 = 0.600
Olivia	i4 i5 i6 i11 i9	1	4	4/5 = 0.800
Sophia	i4 i5 i6 i10 i12	1	4	4/5 = 0.800
Daniel	i2 i3 i9 i7 i8	0	5	5/5 = 1.000
James	i1 i2 i3 i10 i5	1	4	4/5 = 0.800
Michael	i3 i7 i8 i2 i1	1	4	4/5 = 0.800
Ava	i2 i4 i6 i11 i10	1	4	4/5 = 0.800
Ethan	i1 i5 i7 i3 i11	1	4	4/5 = 0.800
			LongTail@5 (Model Y)	$\frac{0.6 + 1.0 + (6x0.8)}{8} = 0.800$

ตีความการเปรียบเทียบผลลัพธ์เฉลี่ย LongTail@5 ผลลัพธ์เฉลี่ย จากผู้ทดสอบ 8 คน

0.6000	vs	0.8000
ค่าเฉลี่ยของ LongTail@5 Model X		ค่าเฉลี่ยของ LongTail@5 Model Y

- Model Y มีค่า LongTail@5 เท่ากับ 0.8000 สูงกว่า Model X ซึ่งมีค่า 0.6000 อยู่ 0.2000 จุด แสดงว่า โดยเฉลี่ย Model Y แนะนำรายการส่วนหาง 4 จาก 5 รายการ ขณะที่ Model X แนะนำ 3 จาก 5 รายการ ดังนั้น Model Y มีแนวโน้มสนับสนุนการค้นพบรายการที่ได้รับความนิยมน้อยได้มากกว่า Model X
- อย่างไรก็ตามค่า LongTail@5 ที่สูงกว่าไม่ได้หมายความว่าคำแนะนำมีความแม่นยำหรือหลากหลายกว่าเสมอ จึงควรพิจารณาร่วมกับ Coverage, Gini และ nDCG@5

นิยาม 2.3 Intra-List Diversity (ILD)

$$ILD@K(u) = \frac{2}{K(K-1)} \sum_{1 \le a < b \le K} [1 - sim(i_{u,a}, i_{u,b})]$$

ความแตกต่างกันเองโดยเฉลี่ยของรายการทุกคู่ในรายการแนะนำชุดเดียวกัน

ความหมาย

- วัดจากคุณลักษณะของรายการ เช่น หมวดหมู่ ประเภท หรือ Embedding Vector
- เข้าใกล้ 1 = รายการที่แนะนำแตกต่างกันมาก; เข้าใกล้ 0 = แนะนำของคล้ายกันทั้งหมด
- วัดที่ระดับผู้ใช้หนึ่งคน แล้วจึงเฉลี่ยข้ามผู้ใช้

ตัวประกอบ 2 / (K(K−1))

- คือหนึ่งส่วนจำนวนคู่ทั้งหมด: การเลือกคู่จาก K รายการมีได้ K(K−1)/2 คู่
- ที่ K = 5 จึงมี 10 คู่พอดี ซึ่งคำนวณด้วยมือได้สบาย

จากกรณีศึกษาร่วมของหัวข้อ 2.5: คลังภาพยนตร์ MovieMini-12 และ Model X

Model X (Top-5)

รหัส	ชื่อเรื่อง	แนว
i1	The Matrix	Sci-Fi
i2	Inception	Sci-Fi
i4	Titanic	Romantic
i7	John Wick	Action
i10	Toy Story	Animation

ใช้ความคล้ายอย่างง่ายที่สุด: sim = 1 เมื่ออยู่แนวเดียวกัน และ sim = 0 เมื่อคนละแนว

คู่ที่	ภาพยนตร์คู่นั้น	แนวของทั้งคู่	sim	1 − sim
1	The Matrix – Titanic	Sci-Fi / Romantic	0	1
2	The Matrix – John Wick	Sci-Fi / Action	0	1
3	The Matrix – Toy Story	Sci-Fi / Animation	0	1
4	The Matrix – Inception	Sci-Fi / Sci-Fi	1	0
5	Titanic – John Wick	Romantic / Action	0	1
6	Titanic – Toy Story	Romantic / Animation	0	1
7	Titanic – Inception	Romantic / Sci-Fi	0	1
8	John Wick – Toy Story	Action / Animation	0	1
9	John Wick – Inception	Action / Sci-Fi	0	1
10	Toy Story – Inception	Animation / Sci-Fi	0	1
			ผลรวม	9

$$ILD@K(u) = \frac{2}{K(K-1)} \sum_{1 \le a < b \le K} [1 - sim(i_{u,a}, i_{u,b})]$$

$$\text{ILD@5 (Model X)} = \frac{2}{(5 \times (5-1))} \times 9 = \frac{18}{20} = 0.9000$$

จากกรณีศึกษาร่วมของหัวข้อ 2.5: คลังภาพยนตร์ MovieMini-12 และ Model Y กรณี Michael

Model Y (Top-5) กรณี Michel

รหัส	ชื่อเรื่อง	แนว
i1	The Matrix	Sci-Fi
i2	Inception	Sci-Fi
i3	Interstellar	Sci-Fi
i7	John Wick	Action
i8	Mad Max	Action

คู่ที่	ภาพยนตร์คู่นั้น	แนวของทั้งคู่	sim	1 − sim
1	Interstellar – John Wick	Sci-Fi/Action	0	1
2	Interstellar – Mad Max	Sci-Fi/Action	0	1
3	Interstellar – Inception	Sci-Fi/Sci-Fi	1	0
4	Interstellar – The Matrix	Sci-Fi/Sci-Fi	1	0
5	John Wick – Mad Max	Action/Action	1	0
6	John Wick – Inception	Action/Sci-Fi	0	1
7	John Wick – The Matrix	Action/Sci-Fi	0	1
8	Mad Max – Inception	Action/Sci-Fi	0	1
9	Mad Max – The Matrix	Action/Sci-Fi	0	1
10	Inception – The Matrix	Sci-Fi/Sci-Fi	1	0
		ผลรวม		6

$$ILD@K(u) = \frac{2}{K(K-1)} \sum_{1 \le a < b \le K} [1 - sim(i_{u,a}, i_{u,b})]$$

$$\text{ILD@5 (Model Y for Michel)} = \frac{2}{(5 \times (5-1))} \times 6 = \frac{12}{20} = 0.6000$$

ผลลัพธ์เฉลี่ย ILD@5 จากผู้ทดสอบ 8 คน

0.9000

ค่าเฉลี่ยของ ILD@5 Model X

0.7250

ค่าเฉลี่ยของ ILD@5 Model Y

Model X ให้ทุกคนเห็นชุดเดียวกัน แต่ ILD กลับสูงกว่าระบบเฉพาะบุคคลอย่างชัดเจน

เหตุผลคือนิยามของตัวชี้วัดเอง

- ILD วัดความหลากหลาย “ภายในรายการของผู้ใช้คนเดียว” : ไม่เคยเห็นผู้ใช้คนอื่นเลย
- จาก Model X ห้าอันดับความนิยมแรกของคลังนี้บังเอิญคาบเกี่ยวถึงสี่แนว ระบบที่แนะนำนั้นให้ทุกคนจึงได้ ILD สูง
- เนื่องจาก Model Y พัฒนาภายใต้แนวคิด ระบบเฉพาะบุคคลย่อมกระจุกในแนวที่ผู้ใช้ชอบ จึงได้ ILD ต่ำกว่าโดยธรรมชาติ

มิติที่ ILD มองไม่เห็น: Aggregate Diversity

ตัวชี้วัด	Model X	Model Y	การตีความ
ILD@5	0.9000	0.7250	X มีความหลากหลายภายในรายการของผู้ใช้แต่ละคนสูงกว่า
Coverage@5	0.4167	1.0000	Y นำรายการจากแค็ตตาล็อกมาใช้ครอบคลุมกว่า
Gini	0.5833	0.1500	Y กระจายจำนวนครั้งที่รายการถูกแนะนำได้สมดุลกว่า

Model X มีค่า ILD@5 สูงกว่า Model Y เพราะรายการห้าเรื่องที่แนะนำให้ผู้ใช้แต่ละคนมีความแตกต่างกันมาก อย่างไรก็ตาม Model X แนะนำรายการชุดเดียวกันให้ผู้ใช้ทุกคน จึงมี Coverage ต่ำและ Gini สูง ผลลัพธ์นี้แสดงว่า ILD วัดความหลากหลายภายในรายการของผู้ใช้แต่ละคน ไม่ได้วัดความหลากหลายของรายการที่ระบบนำเสนอแก่ผู้ใช้ทั้งหมด ดังนั้นจึงควรรายงาน ILD ร่วมกับ Coverage และ Gini เสมอ

2.5.4 Novelty ความแปลกใหม่

$$Novelty@K(u) = \frac{1}{K}\sum_{j=1}^{K} -\log_2 p(i_{u,j})$$

p(i) = สัดส่วนของผู้ใช้ที่เคยมีปฏิสัมพันธ์กับรายการ i

ความหมาย

- $-\log_2$ p(i) คือ Self-Information ของรายการนั้น
- รายการที่คนรู้จักน้อยมี p(i) ต่ำ จึงให้ค่าสูง
- “ระบบกำลังบอกสิ่งที่ผู้ใช้ไม่น่าจะรู้อยู่แล้วมากน้อยเพียงใด”

หน่วยและฐานลอการิทึม

- ใช้ log ฐาน 2 มีหน่วยเป็น “บิต”
- 1.0236 บิต ≈ สารสนเทศเท่ากับการรู้ผลโยนเหรียญหนึ่งครั้ง
- เปลี่ยนเป็น ln ค่าจะเปลี่ยนทันที ดังนั้น ต้องประกาศฐานที่ใช้เสมอ

ตัวอย่างการคำนวณ 2.10 Novelty@5 ทีละเรื่อง

ภาพยนตร์	ผู้เคยชม	p(i) = ผู้เคยชม/500	$-\log_2 p(i)$ (บิต)
i1 The Matrix	400	0.800	0.3219
i4 Titanic	300	0.600	0.7370
i7 John Wick	250	0.500	1.0000
i10 Toy Story	200	0.400	1.3219
i2 Inception	150	0.300	1.7370
i5 La La Land	100	0.200	2.3219
i9 Parasite	60	0.120	3.0589
i11 Coco	40	0.080	3.6439
i3 Interstellar	25	0.050	4.3219
i8 Mad Max	15	0.030	5.0589
i6 The Notebook	8	0.016	5.9658
i12 Spirited Away	2	0.004	7.9658

1 **แปลงผู้เคยชมเป็น p(i) แล้วเข้า $\log_2$**

ฐานผู้ใช้ทั้งแพลตฟอร์ม 500 คน ดังนั้น

p(i) = ผู้เคยชม / 500

ตัวอย่างการคำนวณ 2.10 Novelty@5 ทีละเรื่อง

Model X สำหรับ Michel (เหมือนกับคนอื่น)

ภาพยนตร์	ผู้เคยชม	p(i) = ผู้เคยชม/500	$-\log_2$ p(i) (บิต)
i1 The Matrix	400	0.800	0.3219
i4 Titanic	300	0.600	0.7370
i7 John Wick	250	0.500	1.0000
i10 Toy Story	200	0.400	1.3219
i2 Inception	150	0.300	1.7370

Model X:

(0.3219 + 0.7370 + 1.0000 + 1.3219 + 1.7370) / 5

= 5.1178 / 5

= 1.0236

Model Y สำหรับ Michel

ภาพยนตร์	ผู้เคยชม	p(i) = ผู้เคยชม/500	$-\log_2$ p(i) (บิต)
i1 The Matrix	400	0.800	0.3219
i7 John Wick	250	0.500	1.0000
i2 Inception	150	0.300	1.7370
i3 Interstellar	25	0.050	4.3219
i8 Mad Max	15	0.030	5.0589

Model Y:

(0.3219 + 1.0000 + 1.7370 + 4.3219 + 5.0589) / 5

= 12.4397 / 5

=2.4879

ผลลัพธ์ค่าเฉลี่ยของ Novelty@5 จากผู้ทดสอบ 8 คน

1.0236	vs	2.5453
ค่าเฉลี่ยของ Novelty@5 Model X		ค่าเฉลี่ยของ Novelty@5 Model Y

จากผู้ทดสอบ 8 คน Model Y มีค่า Novelty@5 เฉลี่ยเท่ากับ 2.5453 บิต สูงกว่า Model X ซึ่งมีค่าเท่ากับ 1.0236 บิตแสดงว่าโดยเฉลี่ย Model Y แนะนำภาพยนตร์ที่ได้รับความนิยมน้อยกว่าและมีโอกาสช่วยให้ผู้ใช้ค้นพบรายการที่ไม่คุ้นเคยได้มากกว่า ขณะที่ Model X เน้นแนะนำภาพยนตร์ยอดนิยม จึงมีค่า Novelty ต่ำกว่า หรืออาจกล่าวได้ว่า โดยเฉลี่ย Model Y นำเสนอรายการที่พบเห็นได้ยากกว่าและช่วยเพิ่มโอกาสในการค้นพบรายการใหม่มากกว่า Model X

2.5.5 Calibration การปรับเทียบ

$$CalibrationError(u) = \frac{1}{2}\sum_{c}|q_u(c) - p_u(c)|$$

Calibration Error วัดว่า **สัดส่วนประเภทของรายการที่ระบบแนะนำสอดคล้องกับความสนใจเดิมของผู้ใช้เพียงใด**

- p(c) = สัดส่วนแนว c ในประวัติผู้ใช้
- q(c) = สัดส่วนแนว c ในรายการที่แนะนำ
- ค่าอยู่ระหว่าง 0 ถึง 1
- ค่าใกล้ 0 หมายถึงคำแนะนำสอดคล้องกับประวัติ
- ค่าใกล้ 1 หมายถึงสัดส่วนแตกต่างจากประวัติมาก

2.5.5 Calibration การปรับเทียบ

$$CalibrationError(u) = \frac{1}{2}\sum_{c}|q_u(c) - p_u(c)|$$

ตัวอย่าง ประวัติของผู้ใช้มีสัดส่วนดังนี้:

$$p(\text{Action}) = 0.70\,, p(\text{สารคดี}) = 0.20\,, p(\text{ตลก}) = 0.10$$

ระบบแนะนำภาพยนตร์ 10 เรื่อง ประกอบด้วย Action 9 เรื่องและตลก 1 เรื่อง จึงได้

$$p(\text{Action}) = 0.90, p(\text{สารคดี}) = 0.00, p(\text{ตลก}) = 0.10$$

แนว	p(c) จากประวัติ	q(c) จากรายการแนะนำ	|q − p|
Action	0.70	0.90	0.20
สารคดี	0.20	0.00	0.20
ตลก	0.10	0.10	0.00
		ผลรวม	0.40

1 แทนค่า

CalibrationError = 0.5 × 0.40 = 0.2000

เมื่อรายการแนะนำมี 10 เรื่อง ค่า 0.20 จึงตีความได้ว่าต้องปรับประมาณ 20% ของรายการ หรือ 2 จาก 10 เรื่อง จากActionเป็นสารคดี จึงจะได้สัดส่วนตรงกับประวัติ

ตัวอย่างการคำนวณ 2.11 ส่วนที่ 2 ผู้ใช้ Sophia บน MovieMini-12

Sophia ให้ ≥ 4 ดาวแก่ Titanic, La La Land, The Notebook (Romantic 3) และ Toy Story, Coco (Animation 2) ประวัติของผู้ใช้มีสัดส่วนดังนี้:

$$p(\text{Romantic}) = 0.60\,, p(\text{Animation}) = 0.40$$

แนว	p(c) ของ Sophia	q(c) Model X	|q − p|	q(c) Model Y	|q − p|
Sci-Fi	0.00	0.40	0.40	0.00	0.00
Romantic	0.60	0.20	0.40	0.60	0.00
Action	0.00	0.20	0.20	0.00	0.00
Animation	0.40	0.20	0.20	0.40	0.00
ผลรวม			1.20		0.00

1 แทนค่า

Model X: 0.5 × 1.20 = 0.6000

Model Y : 0.5 × 0.00 = 0.0000

2.5.6 Fairness ความเป็นธรรมสองด้าน

User-Side Fairness

- ผู้ใช้ทุกกลุ่มได้รับคุณภาพบริการเท่ากันหรือไม่
- วัดด้วย Parity Gap = ผลต่างของ Primary Metric ระหว่างกลุ่ม เช่น ผู้ใช้ประวัติยาว vs ผู้ใช้ใหม่

Provider-Side Fairness

- ผู้ผลิตเนื้อหาทุกรายได้รับโอกาสถูกเปิดเผยอย่างเป็นธรรมหรือไม่
- วัดด้วย Gini ของการเปิดเผยที่รวมกลุ่มตามผู้ผลิต : เรื่องความยั่งยืนของระบบนิเวศ

$$ParityGap = |E[M(u) \mid u \in G_A] - E[M(u) \mid u \in G_B]|$$

ข้อควรระวัง

การวัดด้านเดียวแล้วอ้างว่าระบบเป็นธรรม เป็นข้อสรุปที่เกินหลักฐาน

ตัวอย่างการคำนวณ 2.12 ส่วนที่ 1 Parity Gap ฝั่งผู้ใช้ (Precision@5)

ผู้ใช้	กลุ่ม	P@5 Model X	P@5 Model Y
Emma	ประวัติยาว	0.6	0.8
Olivia	ประวัติยาว	0.2	0.8
Sophia	ประวัติยาว	0.4	0.8
Daniel	ประวัติยาว	0.4	0.6
ค่าเฉลี่ยกลุ่มประวัติยาว		0.4000	0.7500
James	ประวัติสั้น	0.4	0.6
Michael	ประวัติสั้น	0.2	0.6
Ava	ประวัติสั้น	0.4	0.4
Ethan	ประวัติสั้น	0.6	0.6
ค่าเฉลี่ยกลุ่มประวัติสั้น		0.4000	0.5500
ParityGap = |ยาว − สั้น|		0.0000	0.2000

1 แทนค่า

Model X: ยาว = 1.6/4 = 0.4000, สั้น = 1.6/4 = 0.4000 ⟶ Gap 0.0000

Model Y : ยาว = 3.0/4 = 0.7500, สั้น = 2.2/4 = 0.5500 ⟶ Gap 0.2000

Leveling Down

- Model X ได้ Gap = 0.0000 “สมบูรณ์แบบ” ทั้งที่แย่พอ ๆ กันกับทุกคน
- ส่วนModel Y ดีกว่าใน “ทุกกลุ่ม” แต่ได้ 0.2000

ตัวอย่างการคำนวณ 2.12 ส่วนที่ 2 Provider Gini และกับดักการเขียนโปรแกรม

Model	ค่าย ก	ค่าย ข	ค่าย ค	ค่าย ง	เรียงแล้ว	$\sum (2i - 5) \cdot x_i$	Provider Gini
X	16	16	8	0	0, 8, 16, 16	0 − 8 + 16 + 48 = 56	56/160 = 0.3500
Y	14	13	6	7	6, 7, 13, 14	−18 − 7 + 13 + 42 = 30	30/160 = 0.1875

Model X ไม่เคยแนะนำภาพยนตร์ของค่าย ง เลย ทั้งที่ค่าย ง มีถึงสามเรื่อง
เพราะไม่มีเรื่องใดติดห้าอันดับความนิยม : ค่ายเล็กจึงไม่มีทางถูกค้นพบ

2.5.7 สรุปผลการคำนวณด้วยมือทั้งหมดบน MovieMini-12

ตัวชี้วัด	ทิศทางที่ดี	Model X	Model Y	ตัวอย่างที่
Precision@5	สูง	0.4000	**0.6500**	2.12
Coverage@5	สูง	0.4167	**1.0000**	2.6
Gini ของการเปิดเผย	ต่ำ	0.5833	**0.1500**	2.7
LongTail@5	สูง	0.6000	**0.8250**	2.8
ILD@5	สูง	**0.9000**	0.7250	2.9
Novelty@5 (บิต)	สูง	1.0236	**2.8525**	2.10
Calibration Error	ต่ำ	0.4542	**0.2771**	2.11
Parity Gap (ฝั่งผู้ใช้)	ต่ำ	**0.0000**	0.2000	2.12
Provider Gini	ต่ำ	0.3500	**0.1875**	2.12

Model Y ชนะ 7 จาก 9 คอลัมน์

แพ้สองคอลัมน์คือ ILD@5 และ Parity Gap ซึ่งไม่ได้แปลว่าModel Y ด้อยกว่า แต่เกิดจากนิยามของตัวชี้วัดเองทั้งคู่

ข้อสังเกตที่สำคัญที่สุด

หากเลือกรายงานเฉพาะ ILD@5 กับ Parity Gap ผู้อ่านจะสรุปว่า “Model X หลากหลายกว่าและเป็นธรรมกว่า” ซึ่งกลับด้านจากความจริง → การเลือกตัวชี้วัดมีผลต่อข้อสรุปพอ ๆ กับการเลือกModel

2.6

ตัวชี้วัดหลักและตัวชี้วัดกำกับ

Primary Metric • Guardrail Metrics • Scalarization

2.6.1 คุณสมบัติสามกลุ่มของตัวชี้วัดในระบบผู้แนะนำ



ภาพที่ 2.10 คุณสมบัติของตัวชี้วัดในระบบผู้แนะนำ

Recommendation Quality

- Accuracy, Coverage, Diversity, Novelty วัดได้จากข้อมูลบันทึกย้อนหลัง :ซึ่งเป็นเนื้อหาแกนหลักของตำรานี้

User Experience

- Trust, Confidence, Explainability, Risk, Utility
- ส่วนใหญ่ต้องวัดด้วยแบบสอบถามหรือทดลองกับผู้ใช้จริง

System Properties

- Robustness, Privacy, Adaptivity, Scalability, Latency
- มักถูกละเลยในงานวิจัย แต่ตัดสินว่าขึ้นใช้งานจริงได้หรือไม่

นิยาม 2.4 Primary Metric ตัวชี้วัดหลัก

นิยาม

ตัวชี้วัดเพียง “หนึ่งตัว” ที่ประกาศไว้ล่วงหน้าว่าจะใช้ตัดสินว่าModel ใดชนะ การประกาศต้องระบุครบทั้ง ชื่อตัวชี้วัด • ค่า K • วิธีเฉลี่ยข้ามผู้ใช้ • Candidate Set ที่ใช้

ตัวอย่างการประกาศที่สมบูรณ์: nDCG@10 เฉลี่ยแบบ macro-average ข้ามผู้ใช้ บน Full-Catalog Ranking โดยตัดรายการที่ผู้ใช้เคยมีปฏิสัมพันธ์ในชุดฝึกออกก่อน

ทำไม “เราใช้ nDCG” เฉย ๆ ไม่พอ

- nDCG@10 บน Candidate Set 100 รายการ กับ 500 รายการ เป็นตัวเลขคนละสเกลอย่างสิ้นเชิง (หัวข้อ 2.9)

หลักการเลือก

- เลือกตัวที่สอดคล้องกับเป้าหมายผู้ใช้และธุรกิจมากที่สุด ไม่ใช่ตัวที่Model Y องเราทำได้ดีที่สุด

ตารางที่ 2.5 ตัวอย่างการเลือก Primary Metric ให้สอดคล้องกับลักษณะงาน

ลักษณะงาน	เป้าหมายที่แท้จริง	Primary Metric	เหตุผล
พยากรณ์คะแนนที่ผู้ใช้จะให้	ทำนายตัวเลขให้ใกล้ความจริง	RMSE หรือ MAE	ผลลัพธ์เป็นตัวเลขต่อเนื่อง ไม่ใช่การจัดอันดับ
แนะนำรายการหน้าแรก 10 ช่อง	ให้สิ่งที่ตรงใจอยู่ใกล้ตำแหน่งบนสุด	nDCG@10	ให้น้ำหนักตามตำแหน่ง รองรับความเกี่ยวข้องหลายระดับ
แนะนำสินค้าเสริมตอนชำระเงิน	ผู้ใช้กดเพิ่มสินค้าอย่างน้อยหนึ่งชิ้น	HR@3 หรือ Precision@3	พื้นที่แสดงน้อยมาก โดนชิ้นเดียวก็สำเร็จ
ค้นคืนเอกสารสำหรับผู้เชี่ยวชาญ	ไม่พลาดเอกสารสำคัญแม้แต่ฉบับเดียว	Recall@100	ต้นทุนการพลาดสูงกว่าต้นทุนการอ่านเกิน
ระบบช่วยค้นภายในองค์กร	ผู้ใช้เจอคำตอบเร็วที่สุด	MRR	สนใจเฉพาะตำแหน่งคำตอบที่ถูกต้องตัวแรก
จัดคิวเพลงต่อเนื่อง	ผู้ฟังไม่กดข้ามและฟังนาน	nDCG@20 ร่วมกับ ILD	ต้องถูกใจและไม่ซ้ำซากไปพร้อมกัน

นิยาม 2.5 Guardrail Metrics และตารางที่ 2.6

นิยาม

ชุดตัวชี้วัดที่ประกาศไว้ล่วงหน้าพร้อม “เกณฑ์ตัวเลขที่ยอมรับได้” ว่าห้ามแย่ลงเกินกว่านั้น แม้ Primary Metric จะดีขึ้น : ปิดช่องทางที่ Model จะ “โกง” ด้วยการทำลายคุณสมบัติที่เราไม่ได้วัด

Guardrail Metric	เกณฑ์ตัวอย่าง	ปิดช่องโกงแบบใด
Catalog Coverage@10	≥ 0.30	กัน Model ที่แนะนำแต่รายการยอดนิยมไม่กี่สิบรายการวนไปมา
ILD@10	≥ 0.55	กันรายการซ้ำซากจนผู้ใช้เบื่อ เช่น แนะนำภาพยนตร์ชุดเดียวกันครบสิบช่อง
Long-tail Ratio@10	≥ 0.20	กันการทอดทิ้งผู้ผลิตรายย่อยจนระบบนิเวศพังในระยะยาว
Calibration Error	≤ 0.15	กันการกลบความสนใจส่วนน้อยของผู้ใช้
Parity Gap	≤ 0.05	กันคุณภาพบริการที่ดีเฉพาะกับผู้ใช้กลุ่มใหญ่

กรอบเจาะลึก การรวมตัวชี้วัดหลายตัวเป็นตัวเดียว (Scalarization) ทำได้หรือไม่

$$S = w_1 \cdot nDCG@10 + w_2 \cdot Coverage@10 + w_3 \cdot ILD@10, \quad \sum_j w_j = 1$$

1 สเกลต่างกัน

- ตัวชี้วัดแต่ละตัวมีสเกลและการกระจายต่างกัน บวกตรง ๆ ไม่มีความหมายเชิงหน่วย
- ต้องทำให้เป็นมาตรฐานก่อน และวิธีนั้นก็เปลี่ยนผู้ชนะได้

ข้อแนะนำของตำรา

2 สูตรอาจมองข้ามทางเลือกที่สมดุล

- เมื่อเปลี่ยนน้ำหนัก สูตรอาจเลือกเฉพาะระบบที่เด่นด้านใดด้านหนึ่ง
- ระบบที่ให้ผลสมดุลหลายด้านอาจไม่เคยได้คะแนนรวมสูงสุด
- จึงควรดูผลของแต่ละตัวชี้วัดควบคู่กับคะแนนรวม

3 น้ำหนักคือการตัดสินใจเชิงคุณค่า

- ไม่มีค่าน้ำหนักที่ถูกต้องจากหลักเทคนิคเพียงอย่างเดียว
- การกำหนดน้ำหนักคือการตัดสินใจว่า ยอมลดความแม่นยำเพื่อเพิ่มความหลากหลายหรือความครอบคลุมได้เพียงใด
- ทีมพัฒนาและฝ่ายธุรกิจจึงควรกำหนดและอธิบายค่าน้ำหนักร่วมกัน

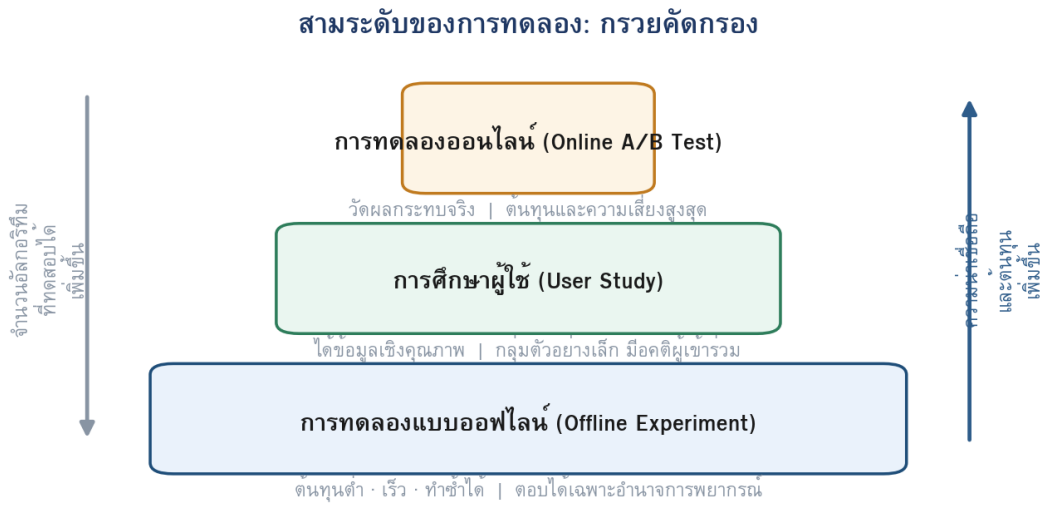
ใช้รูปแบบ Primary Metric หนึ่งตัว + Guardrail หลายตัวพร้อมเกณฑ์ ซึ่งเทียบเท่า Constrained Optimization และตีความง่ายกว่ามากในทางปฏิบัติ

2.7

รูปแบบการทดลองสามระดับ

Offline Experiment • User Study • Online A/B Test

กรวยคัดกรองสามระดับของการทดลอง



ภาพที่ 2.11 จากออฟไลน์ที่ถูกและเร็ว ไปสู่ออนไลน์ที่แพงแต่ตอบคำถามได้จริง

หลักการใช้ร่วมกัน

ไม่ใช่ทางเลือกอย่างใดอย่างหนึ่ง แต่เป็นกรวยคัดกรอง: หน้าที่ของออฟไลน์ไม่ใช่ “พิสูจน์ว่าดีกว่า” แต่คือ “ตัดสิ่งที่แย่ทิ้งให้เร็วที่สุดด้วยต้นทุนต่ำที่สุด”

2.7.1 Offline Experiment

- แบ่งข้อมูลย้อนหลังเป็นชุดฝึก/ทดสอบ ถูก เร็ว ทำซ้ำได้ ไม่กระทบผู้ใช้ : ตอบได้เพียง “ทำนายพฤติกรรมในอดีตภายใต้ระบบเดิมได้แม่นเพียงใด”

2.7.2 User Study

- ผู้เข้าร่วมกลุ่มเล็กในสภาพควบคุม ได้ทั้งข้อมูลเชิงปริมาณและเชิงคุณภาพ (เหตุผลที่ปฏิเสธคำแนะนำ) : จุดอ่อน: กลุ่มเล็ก, Hawthorne Effect หรือ “ผลจากการรู้ว่ากำลังถูกสังเกต”, ไม่ใช่ตัวแทนผู้ใช้ทั่วไป

2.7.3 Online A/B Test

- สุ่มแบ่งผู้ใช้จริงเป็นกลุ่มควบคุม/ทดลอง วัดผลต่างของตัวชี้วัดธุรกิจ : ระดับเดียวที่ตอบคำถามเชิงสาเหตุได้จริง แลกด้วยต้นทุนสูงสุด ความเสี่ยงต่อผู้ใช้ และเวลารอให้มีกำลังทดสอบพอ

ตารางที่ 2.7 เปรียบเทียบรูปแบบการทดลองสามระดับ

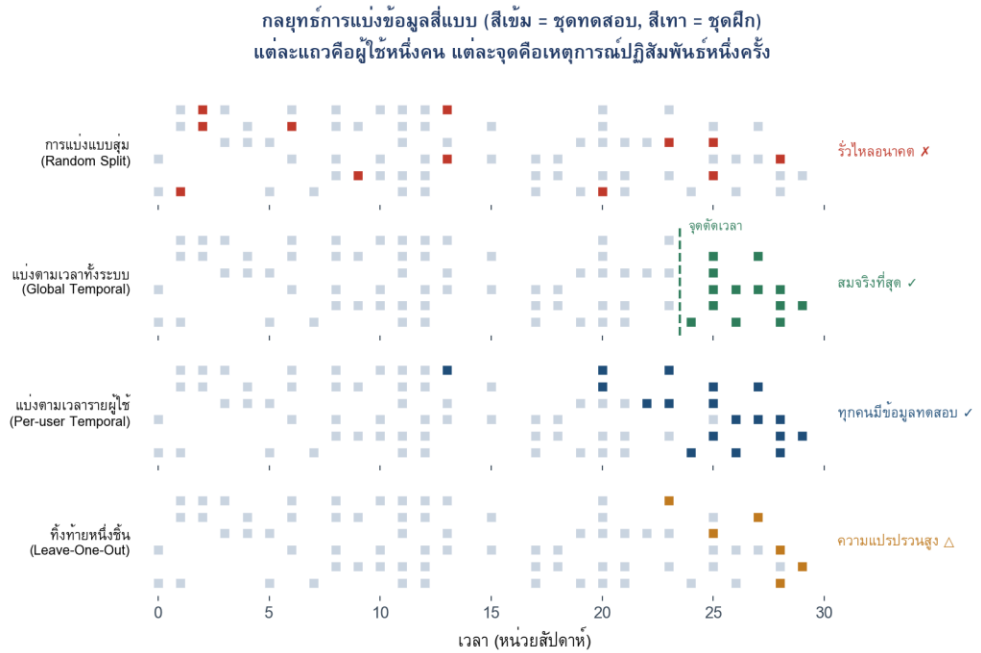
ประเด็นเปรียบเทียบ	Offline	User Study	Online A/B
ต้นทุนต่อการทดลองหนึ่งครั้ง	ต่ำมาก	ปานกลาง	สูง
เวลาที่ใช้	นาทีถึงชั่วโมง	วันถึงสัปดาห์	สัปดาห์ถึงเดือน
จำนวนแนวคิดที่ทดสอบได้	หลายร้อย	หลักหน่วยถึงสิบ	หลักหน่วย
ทำซ้ำได้ด้วย Random Seed เดิม	ได้	ไม่ได้	ไม่ได้
ตอบคำถามเชิงสาเหตุได้	ไม่ได้	ได้บางส่วน	ได้
ความเสี่ยงต่อผู้ใช้จริง	ไม่มี	ต่ำ	สูง
เห็นเหตุผลเบื้องหลังพฤติกรรม	ไม่เห็น	เห็นชัดที่สุด	ไม่เห็น
บทบาทที่เหมาะสม	คัดกรองขั้นต้น	เข้าใจสาเหตุ	ตัดสินขั้นสุดท้าย

2.8

การแบ่งข้อมูลตามเวลาและข้อมูลรั่วไหล

Temporal Split • Data Leakage • Rolling-Origin Evaluation

2.8.1 กลยุทธ์การแบ่งข้อมูลสี่แบบ



ภาพที่ 2.12 แต่ละแถวคือผู้ใช้หนึ่งคน แต่ละจุดคือปฏิสัมพันธ์หนึ่งครั้ง

หลักการ

ใช้อดีตเพื่อฝึก ใช้เหตุการณ์ที่เกิดภายหลังเพื่อทดสอบ

1 Random Split

สุ่ม 20% ไปเป็นชุดทดสอบโดยไม่สนใจเวลา : ชุดฝึกมีเหตุการณ์ที่เกิด “หลัง” ชุดทดสอบ = ใช้อนาคตทำนายอดีต

2 Global Temporal Split

จุดตัดเวลาจุดเดียวทั้งระบบ ก่อน = ฝึก หลัง = ทดสอบ จำลองการใช้งานจริงได้ตรงที่สุด

3 Per-User Temporal Split

กันส่วนท้าย 20% ของแต่ละคน ทุกคนมีข้อมูลทดสอบแน่นอน แต่จุดตัดไม่ตรงกัน : ยังรั่วข้ามผู้ใช้

4 Leave-One-Out

กันเหตุการณ์ล่าสุดของแต่ละคนหนึ่งชิ้น นิยมในงานตีพิมพ์ แต่ความแปรปรวนสูงมาก เพราะตัดสินผู้ใช้ด้วยเหตุการณ์เดียว

นิยาม 2.6 Data Leakage และตารางที่ 2.10 รูปแบบที่พบบ่อยห้าแบบ

นิยาม

สภาวะที่ข้อมูลซึ่งไม่ควรมีในขั้นฝึก ได้เข้าไปมีอิทธิพลต่อModel ไม่ว่าโดยตรงหรือโดยอ้อม : ตัวชี้วัดสูงเกินความสามารถจริง และจะไม่ปรากฏเป็นข้อผิดพลาดใด ๆ ในโปรแกรมเลย

รูปแบบการรั่วไหล	สิ่งที่เกิดขึ้นจริง	วิธีแก้
แบ่งข้อมูลแบบสุ่มทั้งที่ข้อมูลมีมิติเวลา	Model เห็นพฤติกรรมของสัปดาห์หน้ามาทำนายสัปดาห์นี้	ใช้จุดตัดเวลาเสมอเมื่อข้อมูลมีเวลากำกับ
คำนวณความนิยมจากข้อมูลทั้งหมด	ค่าคงที่ที่Model ใช้ มีข้อมูลชุดทดสอบปนอยู่	คำนวณสถิติทุกตัวจากชุดฝึกเท่านั้น
กรอง k-core หลังแบ่งข้อมูล	ชุดทดสอบเหลือแต่ผู้ใช้/รายการที่มีข้อมูลมาก งานง่ายเกินจริง	กำหนดเงื่อนไข k-core ก่อนสร้างชุดเปรียบเทียบ
ปรับสเกลฟีเจอร์ก่อนแบ่งข้อมูล	ค่าเฉลี่ยและ SD ที่ใช้ปรับสเกลรวมชุดทดสอบไว้ด้วย	ปรับสเกลด้วยพารามิเตอร์จากชุดฝึกเท่านั้น
เลือก Hyperparameter บนชุดทดสอบ	ชุดทดสอบกลายเป็นชุดตรวจสอบโดยปริยาย มองโลกในแง่ดีเกินไป	Train → ฝึกพารามิเตอร์ของโมเดล Validation → เลือก Hyperparameter และโมเดล Test → ประเมินสุดท้ายเพียงครั้งเดียว

2.8.4 การรั่วไหลจากสถิติ: ตัวอย่างที่ไม่มีบรรทัดใดดูผิดเลย

✗ ลำดับขั้นตอนที่ผิด

```
# แบบผิด : คำนวณความนิยมก่อนแบ่งข้อมูล
pop = df.groupby('item_id').size()     # ใช้ข้อมูลทั้งหมด
train, test = global_temporal_split(df, 0.2)
Model .fit(train, popularity=pop)      # ความนิยมมีอนาคตปนอยู่
```

✓ ลำดับขั้นตอนที่ถูก

```
# แบบถูก : แบ่งข้อมูลก่อน แล้วจึงคำนวณสถิติจากชุดฝึกเท่านั้น
train, test = global_temporal_split(df, 0.2)
pop = train.groupby('item_id').size()  # ใช้เฉพาะชุดฝึก
Model .fit(train, popularity=pop)
```

กรณี	แหล่งที่มาของความนิยม	nDCG@10	ส่วนต่าง
ทำถูก	ชุดฝึกเท่านั้น	0.0537	: (ค่าจริง)
ทำผิด	ข้อมูลทั้งหมดก่อนแบ่ง	0.0561	+4.6%

ภาพที่ 2.13 (สรุป): แบ่งข้อมูลก่อนคำนวณสถิติใด ๆ แม้แต่ค่าเฉลี่ยหรือพจนานุกรมรายการ

ตัวอย่างการคำนวณ 2.13

ส่วนต่าง 4.6% อาจดูน้อย แต่งานตีพิมพ์จำนวนมากอ้างการปรับปรุงเพียง 2–5% : การรั่วไหลบรรทัดเดียวกลบผลของวิธีการใหม่ได้ทั้งหมด ผู้ตรวจอ่านโค้ดจับไม่ได้ วินัยเดียวที่ป้องกันคือ “การแบ่งข้อมูลต้องเป็นคำสั่งแรกเสมอ”

กรอบเจาะลึก Rolling-Origin Evaluation การประเมินแบบเลื่อนหน้าต่างเวลา

ข้อจำกัดของจุดตัดเดียว

- ผลขึ้นกับว่าเลือกจุดตัดไว้ที่ใด
- หากช่วงทดสอบบังเอิญมีเหตุการณ์พิเศษ (เทศกาล การเปิดตัวเนื้อหาใหญ่) ข้อสรุปอาจเป็นผลของช่วงเวลามากกว่าModel

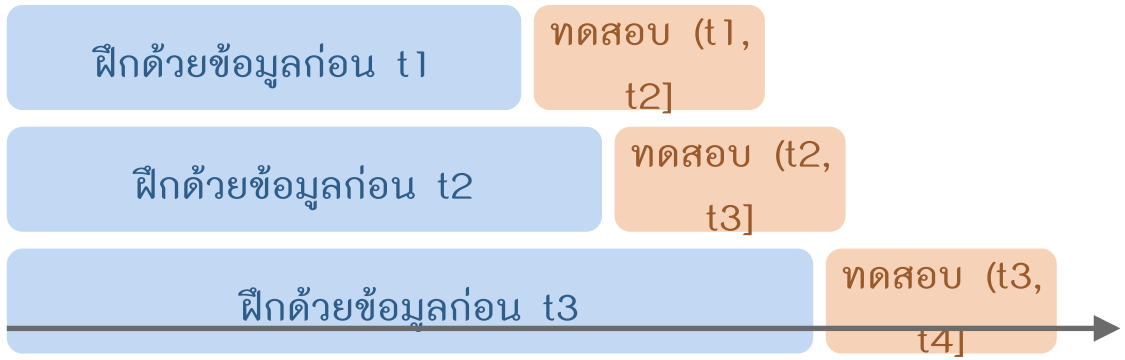
1 ขั้นตอน

กำหนดจุดตัดหลายจุด $t_1 < t_2 < \ldots < t_m$ ห่างกันจุดละหนึ่งสัปดาห์

ที่ t_k ฝึกด้วยข้อมูลก่อน t_k ทดสอบด้วยช่วง $(t_k, t_{k+1}]$

รายงานค่าเฉลี่ยพร้อม SD ข้ามจุดตัด (นิยม m = 4–8)

แนวคิด (ยืมจาก Time-series Forecasting)



ประโยชน์สองข้อ

ค่าประมาณไม่ขึ้นกับความบังเอิญของช่วงเวลาใดช่วงเวลาหนึ่ง และ SD ข้ามจุดตัดบอกว่า “Model มีเสถียรภาพตามเวลาเพียงใด” ซึ่งเป็นข้อมูลที่ทีมปฏิบัติการต้องการมากที่สุด

2.9

เต็มบัญชีรายการ เทียบกับ การสุ่มรายการเชิงลบ

Full-Catalog Ranking vs Sampled Negatives • Winner Flip : หัวข้อที่สำคัญที่สุดของทั้งบท

นิยาม 2.7 Candidate Set เซตผู้สมัคร

นิยาม

เซตของรายการที่Model ต้องนำมาจัดอันดับเพื่อเลือก Top-K ในการประเมินหนึ่งครั้ง

Full-Catalog Ranking

- นำรายการทั้งหมดในคลังที่ผู้ใช้ยังไม่เคยมีปฏิสัมพันธ์ในชุดฝึก มาจัดอันดับทั้งหมด

Sampled Negatives

- รายการเป้าหมาย 1 ชิ้น + รายการที่ผู้ใช้ไม่เคยมีปฏิสัมพันธ์ซึ่งสุ่มมา m ชิ้น แล้วจัดอันดับเฉพาะ m+1 ชิ้นนี้
- ค่าที่นิยมใช้ m = 99 หรือ m = 100

เหตุใดแนวทางที่สองจึงเกิดขึ้น

ต้นทุนการคำนวณ: คลังหลายล้านรายการ การจัดอันดับเต็มบัญชีสำหรับผู้ใช้ทุกคนใช้เวลามหาศาล การสุ่มลดต้นทุนได้หลายพันเท่า : แต่ต้องประกาศให้ชัด

ตัวอย่างการคำนวณ 2.14 เป้าหมายอยู่อันดับ 500 จากคลัง 5,000 (K = 10)

1 กรณีที่ 1 Full-Catalog Ranking

อันดับจริง = 500 > K = 10 : ไม่ปรากฏใน Top-10 เลย

nDCG@10 = 0.0000 (ศูนย์สนิท)

2 กรณีที่ 2 Sampled Negatives m = 99

รายการที่ “เหนือกว่า” เป้าหมายมี 499 ชิ้น ในคลังเชิงลบทั้งหมด 4,999 ชิ้น เมื่อสุ่มมาเพียง 99 ชิ้น

$$E[\text{observed rank}] = 1 + \frac{499 \times 99}{4{,}999} = 1 + 9.88 = 10.88 \qquad (2.24)$$

จำนวนรายการเหนือกว่าที่ติดมา = ตัวแปรสุ่ม Hypergeometric; การจำลอง 20,000 รอบ ให้ค่าเฉลี่ย 10.86 ตรงกับทฤษฎี

3 ผลจากการจำลอง

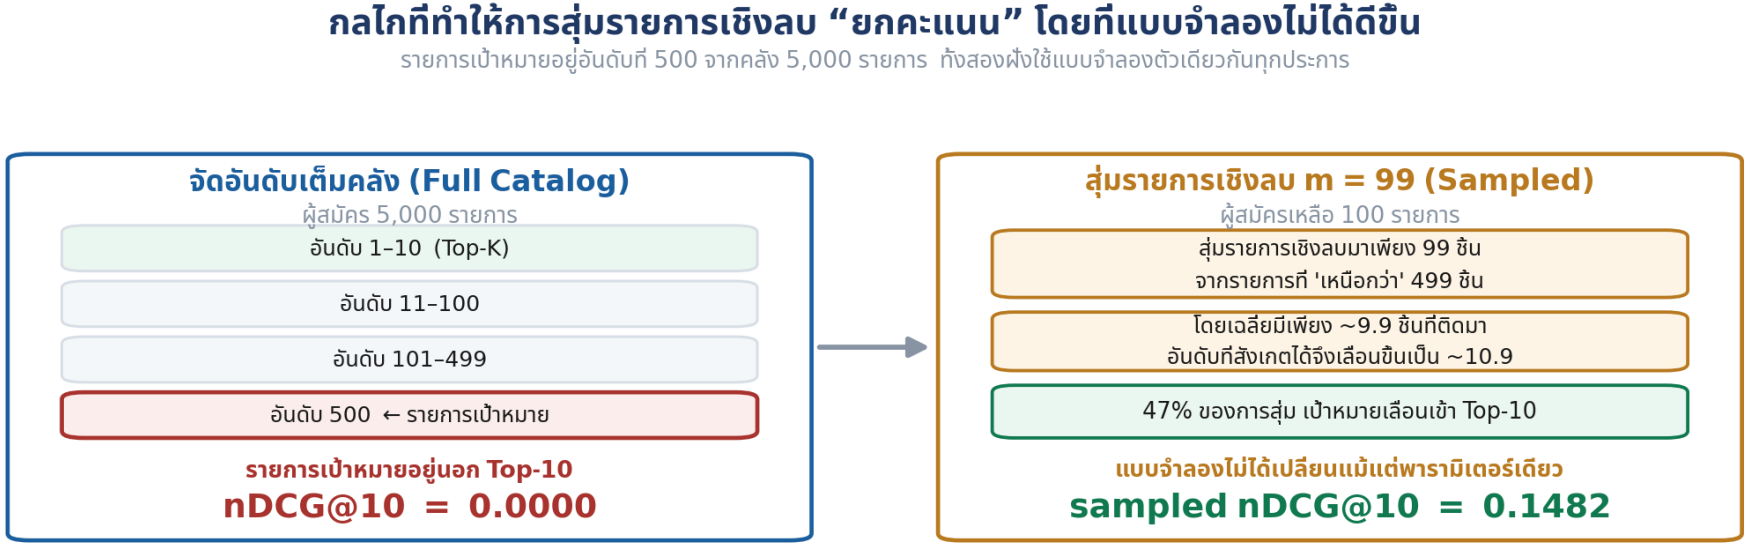
47.0% ของการสุ่ม รายการเป้าหมายเลื่อนเข้ามาอยู่ใน Top-10

sampled nDCG@10 = 0.1482

บทสรุปที่ต้องอ่านช้า ๆ

ตัวเลขกระโดดจาก 0.0000 เป็น 0.1482 โดยไม่ได้เปลี่ยนพารามิเตอร์แม้แต่ตัวเดียว Model ไม่ได้ดีขึ้นเลย มีเพียง “สนามสอบ” ที่ง่ายขึ้น 50 เท่า (5,000 : 100 ตัวเลือก)

ภาพที่ 2.14 กลไกที่ทำให้การสุ่มรายการเชิงลบยกคะแนน



E[อันดับที่สังเกตได้] ≈ 1 + (ρ − 1) × m / (|I| − 1) = 1 + 499 × 99/4999 = 10.88 (การจำลอง 20,000 รอบได้ 10.86)

สิ่งที่เปลี่ยนไปคือ “สนามสอบ” ที่ง่ายลง *50* เท่า มิใช่ความสามารถของแบบจำลอง

$$E[\tilde{\rho}] \approx 1 + \frac{(\rho - 1)\, m}{|\mathcal{I}| - 1} \qquad (2.25)$$

ρ = อันดับจริงของเป้าหมายในคลังขนาด $|\mathcal{I}|$; สุ่มรายการเชิงลบ m ชิ้นแบบสม่ำเสมอ : การสุ่ม “บีบ” อันดับทุกตัวเข้าหา 1 ด้วยตัวประกอบคงที่ $m/(|\mathcal{I}|-1)$ เท่ากันหมด

เหตุใดสูตร 2.25 จึงไม่ช่วยแก้ปัญหา (Krichene & Rendle, KDD 2020)

ข้อคิดที่ผิด

- “ในเมื่อการสุ่มบิบทุก Model เท่ากัน การเปรียบเทียบก็น่าจะยังยุติธรรม”

เหตุผลที่ผิด: Hard Cutoff ที่ K

- nDCG@K ไม่ใช่ฟังก์ชันเชิงเส้นของอันดับ: อันดับ 11 ให้ 0 ขณะที่อันดับ 10 ให้ 0.2891
- ฟังก์ชันไม่เชิงเส้นประกอบกับการแปลงเชิงเส้น ไม่รักษาลำดับของค่าเฉลี่ย

$$E[f(\tilde{\rho}_A)] > E[f(\tilde{\rho}_B)] \text{ says nothing about } E[f(\rho_A)] \text{ vs } E[f(\rho_B)] \qquad (2.26)$$

ผลกระทบต่อทั้งสาขา

งานตีพิมพ์จำนวนมากที่ใช้ m = 100 อาจสรุปผู้ชนะผิด โดยที่การคำนวณทุกบรรทัดถูกต้อง

2.9.3 ตารางที่ 2.11 ตรวจสอบสูตร 2.25 กับการจำลอง (คลัง 5,000)

อันดับจริง ρ	m	ทฤษฎี (2.25)	จำลอง	สัดส่วนเข้า Top-10	sampled nDCG@10
3	99	1.04	1.04	100.0%	0.9854
3	999	1.40	1.41	100.0%	0.8587
12	99	1.22	1.21	100.0%	0.9279
12	999	3.20	3.22	100.0%	0.5367
60	99	2.17	2.17	100.0%	0.6911
60	999	12.79	12.84	22.7%	0.0694
200	99	4.94	4.92	99.4%	0.4219
200	999	40.77	40.73	0.0%	0.0000
500	99	10.88	10.90	46.0%	0.1446
500	999	100.72	100.73	0.0%	0.0000

1 ทฤษฎีตรงกับการจำลองทุกกรณี

ใช้สูตร 2.25 ประมาณผลกระทบล่วงหน้าได้ โดยไม่ต้องรันการทดลอง

2 อันดับ 12 ที่หลุด Top-10 จริง

ได้ sampled nDCG@10 = 0.9279 ที่ m = 99 ซึ่งเกือบสมบูรณ์แบบ

3 m ใหญ่ขึ้น ปัญหาบรรเทา

m = 999 เข้าใกล้ความจริงทุกแถว แต่ไม่หายไปจนกว่า m = ขนาดคลัง

2.9.4 ตัวอย่างการคำนวณ 2.15 Winner Flip: Model P เทียบ Model Q

Model P

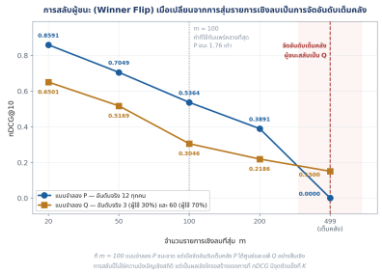
- จัดรายการเป้าหมายไว้ที่อันดับ 12 สำหรับผู้ใช้ทุกคน
- สม่ำเสมอมาก แต่หลุด Top-10 เสมอ

Model Q

- อันดับ 3 สำหรับผู้ใช้ 30% และอันดับ 60 สำหรับ 70%
- เก่งมากกับบางกลุ่ม แย่มากกับที่เหลือ

คลัง 500 รายการ ผู้ใช้ 800 คน K = 10 : Model ใดดีกว่าสำหรับระบบที่แสดงสิบอันดับแรก?

m	nDCG@10 P	nDCG@10 Q	ผู้ชนะ	อัตราส่วน
20	0.8591	0.6501	P	1.32
50	0.7049	0.5169	P	1.36
100	0.5364	0.3046	P	1.76
200	0.3891	0.2186	P	1.78
499 (เต็มคลัง)	0.0000	0.1500	Q	แพ้สิ้นเชิง



ผู้ชนะสลับกัน

ที่ m = 100 (ค่าที่ใช้แพร่หลายที่สุด) P ชนะ Q 1.76 เท่า แต่เมื่อจัดอันดับเต็มบัญชี P ได้ศูนย์สนิทและแพ้ Q : ไม่ใช่ความบังเอิญเชิงสถิติ แต่เป็นผลเชิงโครงสร้างของ Hard Cutoff: อันดับ 12 ของ P ถูกการสุ่ม “เลือก” เข้า Top-10 อย่างสม่ำเสมอ ขณะที่อันดับ 60 ของผู้ใช้ 70% ของ Q ไกลเกินกว่าจะถูกเลือก

2.9.5 แนวปฏิบัติ: ข้อกำหนดห้าข้อเมื่อจำเป็นต้องใช้การประเมินแบบสุ่ม

1 ระบุ m และวิธีสุ่มให้ครบ

สุ่มแบบสม่ำเสมอ ตามความนิยม หรือภายในหมวดเดียวกัน : วิธีสุ่มต่างกันให้ผลต่างกันมาก

2 เรียกว่า sampled nDCG@K

ไม่ใช่ nDCG@K เฉย ๆ เพื่อไม่ให้เข้าใจผิดว่าเทียบกับงานที่จัดอันดับเต็มบัญชีได้

3 รายงานทั้งสองค่าหากทรัพยากรเอื้อ

แล้วตรวจว่าอันดับของModel ตรงกันหรือไม่ หากไม่ตรงต้องรายงานอย่างเปิดเผย

4 ห้ามเปรียบเทียบค่าที่ m ต่างกัน

และห้ามนำ sampled metric ของตนไปเทียบกับ full metric ของงานอื่นโดยเด็ดขาด

5 m < 50 = การคัดกรองเบื้องต้นเท่านั้น

ไม่ใช่ข้อสรุปที่ใช้ตัดสินได้

ทางเลือกเมื่อคลังใหญ่เกินไป

แยกการประเมินเป็นสองขั้นตรงกับสถาปัตยกรรมจริง: Retrieval ด้วย ANN Index ดึงผู้สมัคร ~1,000–10,000 (วัด Recall@1000) แล้ว Re-ranking (วัด nDCG@10) : เซตผู้สมัครมาจากกลไกเดียวกับที่ระบบจริงใช้ ไม่ใช่การสุ่ม

2.10

การรายงานความไม่แน่นอนและการทดสอบนัยสำคัญ

Seed Variance • Paired Bootstrap • Holm–Bonferroni • Wilcoxon

2.10.1 ตัวอย่างการคำนวณ 2.16 ความผันผวนจาก Random Seed เพียงอย่างเดียว

ฝึกModel เดิมซ้ำแปดครั้ง เปลี่ยนเพียง Random Seed ไม่เปลี่ยนสถาปัตยกรรม Hyperparameter หรือข้อมูลใด ๆ

ครั้งที่	1	2	3	4	5	6	7	8
nDCG@10	0.0917	0.0969	0.0934	0.0887	0.0931	0.0900	0.0979	0.0885

0.0925
ค่าเฉลี่ย

0.0035
ส่วนเบี่ยงเบนมาตรฐาน

[0.0885, 0.0979]
ช่วงที่พบ กว้าง 0.0094

±0.0024
ครึ่งความกว้าง CI 95% ของค่าเฉลี่ย

กฎที่ใช้ได้เสมอ

หากส่วนต่างระหว่างสองการตั้งค่า เล็กกว่า SD ระหว่าง Seed ของการตั้งค่าเดียวกัน (0.0035) แสดงว่าไม่มีหลักฐานว่าทั้งสองต่างกัน : งานตีพิมพ์จำนวนมากอ้างการปรับปรุง 1–3% ซึ่งบนฐาน 0.0925 คิดเป็นเพียง 0.0009–0.0028 เล็กกว่าความผันผวนจาก Seed เสียอีก

2.10.2 Paired Bootstrap ระดับผู้ใช้

1. คำนวณตัวชี้วัดของ A และ B แยกรายผู้ใช้

   ได้เวกเตอร์ยาว |U| สองชุด

2. คำนวณผลต่างรายผู้ใช้

   [illegible]

3. สุ่มผู้ใช้กลับคืน (with replacement) จนครบ |U|

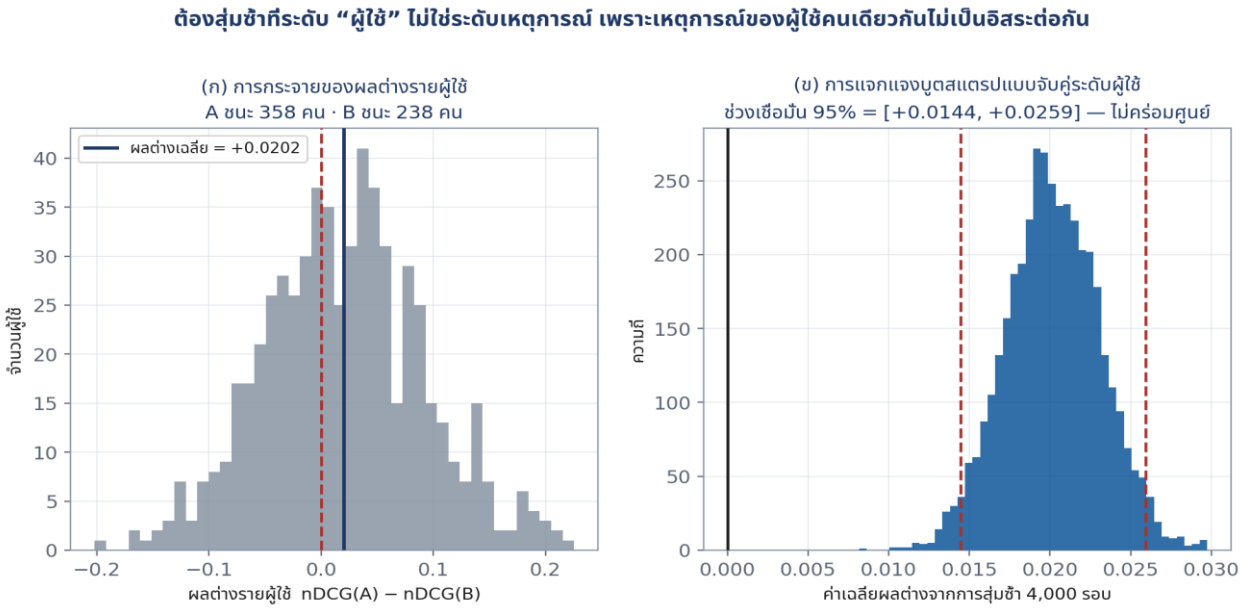
   แล้วคำนวณค่าเฉลี่ยของ d_u ในตัวอย่างนั้น

4. ทำซ้ำ 4,000–10,000 รอบ

   ได้การแจกแจงของค่าเฉลี่ยผลต่าง

5. อ่านเปอร์เซ็นไทล์ 2.5 และ 97.5

   = CI 95%; หากไม่คร่อมศูนย์ : มีหลักฐานว่าต่างกัน



ภาพที่ 2.16 การกระจายของผลต่างรายผู้ใช้ และการแจกแจง Bootstrap

สิ่งที่ค่าเฉลี่ยปิดบัง

แม้ A ดีกว่าโดยเฉลี่ย แต่ผู้ใช้ 238 จาก 600 คน (≈40%) ได้ผลแย่ลง การเปลี่ยนระบบอาจไม่คุ้มค่าแม้ค่าเฉลี่ยดีขึ้น

ตารางที่ 2.12 ผล Paired Bootstrap 4,000 รอบ บนผู้ใช้ 600 คน

คู่เปรียบเทียบ	ส่วนต่างเฉลี่ย	CI 95%	p-value	ข้อสรุป
A – B	+0.0202	[+0.0144, +0.0259]	0.0000	มีนัยสำคัญ
A – C	+0.0025	[−0.0033, +0.0084]	0.4045	ไม่มีหลักฐานว่าต่างกัน
C – B	+0.0177	[+0.0119, +0.0230]	0.0000	มีนัยสำคัญ

ค่าเฉลี่ย: A = 0.2148, B = 0.1946, C = 0.2123

อ่านจากค่าเฉลี่ยอย่างเดียวจะสรุปว่า A > C > B แต่ CI ของ A – C “คร่อมศูนย์”

✓ ประโยคที่เขียนได้

- “ไม่มีหลักฐานว่า A ดีกว่า C บนชุดข้อมูลนี้ ทั้งสองดีกว่า B อย่างมีนัยสำคัญ”

✗ ประโยคที่เขียนไม่ได้

- “A ดีที่สุด” หรือ “A ดีกว่า C เล็กน้อย” เพราะอ้างสิ่งที่ข้อมูลไม่รองรับ
- ช่วงคร่อมศูนย์ก็ไม่ได้แปลว่า A = C: การไม่พบหลักฐานของความต่าง ไม่ใช่หลักฐานของความไม่ต่าง

2.10.3 ตัวอย่างการคำนวณ 2.17 ความผิดพลาดคลาสสิก: สุ่มซ้ำผิดระดับ

ระดับที่สุ่มซ้ำ	จำนวนตัวอย่าง n	ความกว้าง CI 95%	ผลการประเมิน
ระดับผู้ใช้	600	0.0115	ถูกต้อง
ระดับเหตุการณ์	4,800	0.0040	ผิด

แคบเกินจริง 2.9 เท่า

มั่นใจเกินความเป็นจริงเกือบสามเท่า

เหตุผล

เหตุการณ์ของผู้ใช้คนเดียวกันไม่เป็นอิสระต่อกัน : ผู้ใช้ที่ชอบหนังแนวหนึ่งมักให้คะแนนคล้ายกันทุกเรื่อง การสุ่มซ้ำระดับเหตุการณ์จึงเท่ากับนับข้อมูลชุดเดิมซ้ำหลายครั้ง

กฎ

หน่วยของการสุ่มซ้ำต้องเป็นหน่วยที่เป็นอิสระต่อกัน ซึ่งในระบบผู้แนะนำคือ “ผู้ใช้” ไม่ใช่ “เหตุการณ์” มิฉะนั้นจะประกาศนัยสำคัญในกรณีที่ไม่ควรประกาศ

2.10.4 การเปรียบเทียบหลายคู่ และวิธีของ Holm–Bonferroni

$$P(\text{at least one false positive}) = 1 - (1-\alpha)^m = 1 - 0.95^{10} = 0.401 \quad (2.27)$$

ที่ α = 0.05 และ 10 คู่ โอกาสพบ “นัยสำคัญปลอม” อย่างน้อยหนึ่งค่สงถึง 40.1%

1 วิธีของ Holm

เรียงค่า p จากน้อยไปมาก

เปรียบเทียบค่าที่ i กับเกณฑ์ α / (m − i + 1)

เมื่อคู่ใดไม่ผ่าน คู่ที่เหลือทั้งหมดถือว่าไม่มีนัยสำคัญ (ขั้นบันไดลง)

ลำดับ	คู่เปรียบเทียบ	p-value	เกณฑ์ของ Holm	ผลหลังแก้
1	A − B	0.0000	0.05/3 = 0.0167	มีนัยสำคัญ
2	C − B	0.0000	0.05/2 = 0.0250	มีนัยสำคัญ

Wilcoxon Signed-Rank Test ทางเลือกที่ไม่ต้องสมมติการแจกแจง

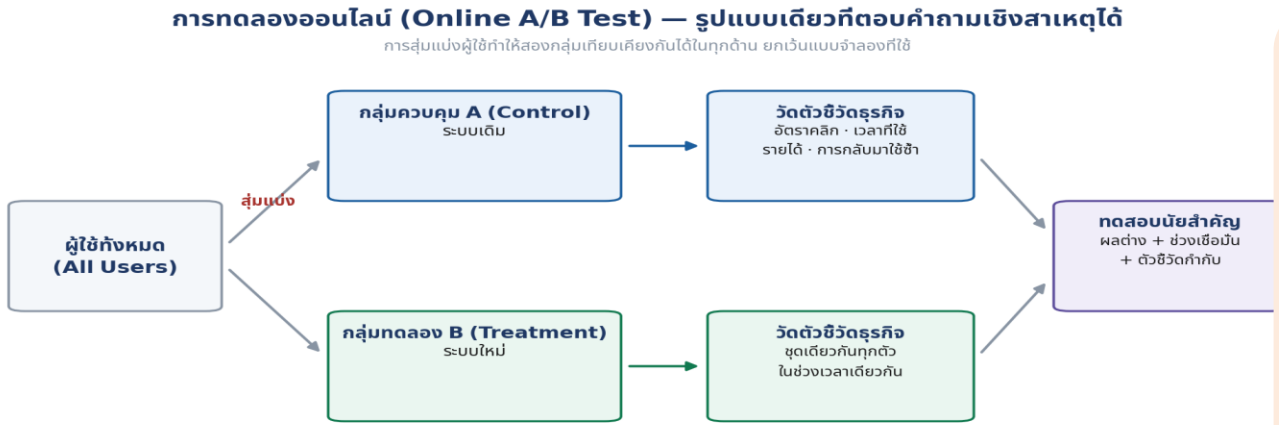
คำนวณ d_u ตัดกรณี 0 ออก : จัดอันดับ $|d_u|$: รวมอันดับของ $d_u > 0$ เป็น W^+ และ $d_u < 0$ เป็น W^- : $W = \min(W^+, W^-)$ | ข้อดี: เหมาะกับตัวชี้วัดที่เบ้ขวารุนแรง | ข้อจำกัด: ให้เพียงค่า p ไม่ให้ CI ของ Effect Size : ตำราแนะนำ Paired Bootstrap เป็นหลัก ใช้ Wilcoxon ยืนยัน และรายงานขนาดผลควบคู่กับ p เสมอ

2.11–2.12

การทดลองออนไลน์ และการประเมินแบบทวนข้อเท็จจริง

Online A/B Test • Business Metrics • Counterfactual / Off-Policy Evaluation (IPS)

2.11 โครงสร้างของการทดลองออนไลน์ (Online A/B Test)



ภาพที่ 2.17 การสุ่มแบ่งผู้ใช้ทำให้ตอบคำถามเชิงสาเหตุได้

ตอบคำถามเชิงสาเหตุว่า “เมื่อเปลี่ยนไปใช้Model ใหม่ พฤติกรรมผู้ใช้เปลี่ยนหรือไม่”

การสุ่มแบ่งผู้ใช้ทำให้กลุ่มควบคุมและกลุ่มทดลองเทียบเคียงกันได้ในทุกด้าน ยกเว้นModel ที่ใช้

ต้องกำหนด Primary Metric, Guardrail, ระยะเวลา และเกณฑ์หยุดล่วงหน้า

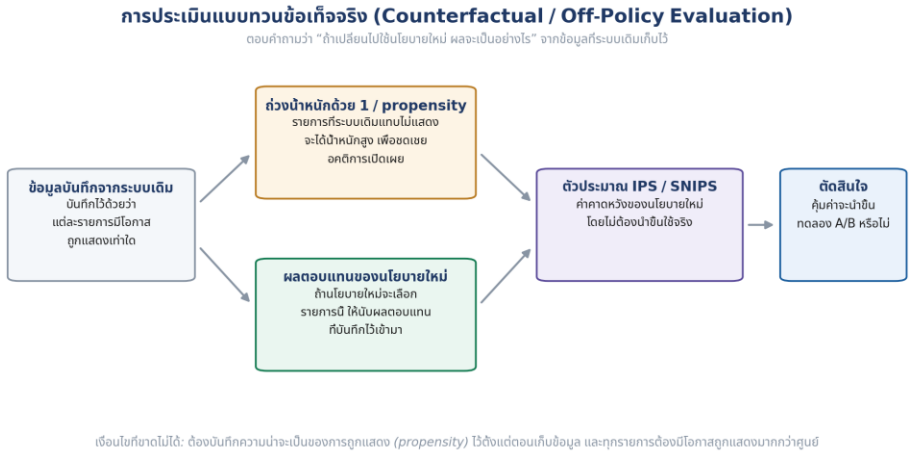
กับดักที่พบบ่อยที่สุด

- Peeking: แอบดูผลระหว่างทางแล้วหยุดเมื่อตัวเลขสวย ทำลายความหมายของค่า p : ใช้ Sequential Testing และกำหนดจุดตรวจล่วงหน้า
- Novelty Effect: ผู้ใช้คลิกมากขึ้นเพียงเพราะหน้าจอเปลี่ยน จางลงใน 1–2 สัปดาห์
- ละเลยผลระยะยาว: เนื้อหาเร้าอารมณ์เพิ่มคลิกระยะสั้นแต่ลดความไว้วางใจ : ต้องมี Holdback Group

ตารางที่ 2.14 สิ่งที่ต้องกำหนดเป็นลายลักษณ์อักษรก่อนเปิดการทดลองออนไลน์

สิ่งที่ต้องกำหนด	เหตุผล	ตัวอย่าง
Primary Metric เชิงธุรกิจ	กันการเลือกตัวชี้วัดที่ถูกใจหลังเห็นผล	อัตราการคลิกเข้าชมเนื้อหาต่อการเข้าใช้หนึ่งครั้ง
Guardrail เชิงธุรกิจ	กันการปรับปรุงที่แลกมาด้วยความเสียหายด้านอื่น	อัตราการยกเลิกสมาชิก ต้องไม่เพิ่มเกิน 0.5%
ขนาดตัวอย่างและ Statistical Power	กันการทดลองที่เล็กเกินกว่าจะสรุปอะไรได้	ต้องตรวจจับผลต่าง 2% ได้ที่กำลัง 0.80
ระยะเวลาทดลองขั้นต่ำ	กัน Novelty Effect ในสัปดาห์แรก	อย่างน้อยสองสัปดาห์เต็ม ครอบคลุมทุกวันในสัปดาห์
Rollback Trigger	จำกัดความเสียหายเมื่อผลเป็นลบชัดเจน	ยกเลิกทันทีเมื่อ Primary Metric ลดเกิน 3% ที่นัยสำคัญ 0.01
วิธีแบ่งหน่วยสุ่ม	กันการรั่วไหลข้ามกลุ่มเมื่อผู้ใช้ใช้หลายอุปกรณ์	สุ่มที่ระดับบัญชีผู้ใช้ ไม่ใช่ระดับ Session

2.12 นิยาม 2.8 Inverse Propensity Scoring (IPS)



ภาพที่ 2.18 โครงสร้างของ Counterfactual Evaluation

สัญชาตญาณ

รายการที่นโยบายเดิมแทบไม่เคยแสดง แต่บังเอิญถูกแสดงและได้ผลดี ควรนับด้วยน้ำหนักสูง (หลักฐานหายาก) ส่วนรายการที่แสดงตลอดเวลา นับด้วยน้ำหนักต่ำ เพื่อชดเชยข้อมูลที่มีมากเกินสัดส่วน

$$\hat{V}_{IPS}(\pi) = \frac{1}{n}\sum_{k=1}^{n}\frac{\pi(a_k \mid x_k)}{\pi_0(a_k \mid x_k)}\, r_k \qquad (2.28)$$

สัญลักษณ์

- π = นโยบายใหม่ที่ต้องการประเมิน; π_0 = นโยบายเดิมที่ใช้เก็บข้อมูล; a_k = รายการที่ถูกแสดง; x_k = บริบท; r_k =

เงื่อนไขที่ขาดไม่ได้สามข้อ

- บันทึก Propensity $\pi_0(a_k|x_k)$ ไว้ตั้งแต่ตอนเก็บข้อมูล ย้อนประมาณทีหลังไม่ได้
- Overlap/Positivity: ทุกรายการต้องมีโอกาสถูกแสดง > 0 : สงวน 1–5% ไว้สำรวจแบบสุ่ม
- ควบคุมความแปรปรวน: Clipping, SNIPS, Doubly Robust

2.13–2.14

การทำซ้ำได้ บัตรโปรโตคอล และโปรโตคอลการประเมิน 11 ขั้น

Reproducibility • Protocol Card • 11-Step Evaluation Protocol

นิยาม 2.9 Evaluation Protocol Card และตารางที่ 2.15

นิยาม

เอกสารสั้นที่บันทึกตัวเลือกเชิงระเบียบวิธีทุกข้อของการทดลองหนึ่งครั้ง : ผู้อ่านที่มีเพียงบัตรใบนี้กับชุดข้อมูล ต้องทำซ้ำผลได้ครบทุกหลัก กรอกให้ครบ “ก่อน” รันครั้งแรก และแนบไปกับผลทุกครั้ง

ช่องข้อมูล	ค่าที่บันทึก	เหตุผลที่ต้องบันทึก
dataset / n_users / n_items / n_interactions	RSLab-Eval / 800 / 500 / 21,696	ให้ผู้อ่านตรวจว่าใช้ข้อมูลชุดเดียวกัน
k_core / split_method / train_frac	0 / global_temporal / 0.7	การกรองเปลี่ยนความยาก; วิธีแบ่งเปลี่ยนผลได้ถึง 71.6%
relevance_threshold / K	rating ≥ 4 / 10	นิยามความเกี่ยวข้องเปลี่ยนทุกตัวชี้วัด; ห้ามเทียบ K ต่างกัน
candidate_set / gain_type	full_catalog / linear	Candidate Set สลับผู้ชนะได้; Gain เปลี่ยนผลเมื่อหลายระดับ
seeds	(0, 1, 2, 3, 4)	ให้ผู้อ่านทำซ้ำได้และเห็นความผันผวน
primary_metric / guardrail_metrics	nDCG@10 / Coverage@10, Gini, Novelty, LongTail	ตัวที่ใช้ตัดสิน ประกาศก่อนเห็นผล; สิ่งที่ห้ามแย่ลงเกินเกณฑ์

ชั้น ProtocolCard ในแพ็กเกจ rslab ทำหน้าที่สามอย่างพร้อมกัน

1 validate() บังคับให้ประกาศครบ

ยกข้อผิดพลาดทันทีหากมีช่องสำคัญว่าง : ลืมประกาศไม่ได้แม้จะรีบ

2 metric_name() ตั้งชื่อให้ถูกอัตโนมัติ

คืน nDCG@10 เมื่อใช้ Full Catalog และ sampled nDCG@10 (m=99) เมื่อใช้การสุ่ม : กันการเรียกชื่อผิดที่ 2.9.5 เตือนไว้

3 render() พิมพ์บัตรแนบผล

ผลิตข้อความที่คัดลอกไปวางในภาคผนวกของบทความได้ทันที

คำแนะนำ

ใช้ชั้นนี้กับทุกการทดลองตั้งแต่วันแรก เมื่อถึงเวลาเขียนวิทยานิพนธ์ ข้อมูลที่จำเป็นจะถูกบันทึกไว้ครบแล้วโดยอัตโนมัติ : สาเหตุที่ผลทำซ้ำไม่ได้ ไม่ใช่ความไม่ซื่อสัตย์ แต่คือตัวเลือกเชิงระเบียบวิธีจำนวนมากไม่เคยถูกบันทึกในบทความ ทั้งที่แต่ละตัวเลือกเปลี่ยนผลได้อย่างมีนัยสำคัญ

2.14 โปรโตคอลการประเมินระบบผู้แนะนำที่น่าเชื่อถือ 11 ขั้น



ภาพที่ 2.19 ทุกขั้นควรถูกกำหนดและบันทึกก่อนดูผลการทดลอง

1 กำหนดเป้าหมายผู้ใช้และธุรกิจ

2 เลือก Primary Metric

3 กำหนด Guardrail Metrics

4 ระบุสูตรและค่า K

5 แบ่งข้อมูลตามเวลา

6 ป้องกัน Data Leakage

7 กำหนด Candidate Set

8 ระบุวิธี Negative Sampling

9 วัดทั้ง Accuracy และ Beyond-Accuracy

10 รายงานความไม่แน่นอน

11 ตรวจผลด้วยผู้ใช้จริง

ตารางที่ 2.16 โปรโตคอล 11 ขั้น พร้อมค่าที่กรอกจริง (1/2)

ขั้น	สิ่งที่ต้องทำ	ค่าที่กรอกจริงในการทดลองของบทนี้ (lab2_07_full_protocol.py)
1	กำหนดเป้าหมายของผู้ใช้และธุรกิจ	ผู้ใช้: พบรายการที่ชอบภายในสิบอันดับแรกโดยไม่ต้องเลื่อนหา • ธุรกิจ: เพิ่มการค้นพบรายการใหม่โดยไม่ลดความพึงพอใจระยะสั้น
2	เลือก Primary Metric	nDCG@10 เพราะไวต่อตำแหน่งและตรงกับเป้าหมาย “สิบอันดับแรก”
3	กำหนด Guardrail Metrics	Coverage@10, Gini, Novelty, LongTail • เกณฑ์: Coverage ห้ามลดเกิน 10% และ Gini ห้ามเพิ่มเกิน 0.02
4	ระบุสูตรและค่า K	K = 10 • นิยามความเกี่ยวข้อง rating ≥ 4 • gain_type = linear
5	แบ่งข้อมูลตามเวลา	global_temporal • ฝึก 15,187 • ตรวจสอบ 2,169 • ทดสอบ 4,340
6	ป้องกันข้อมูลรั่วไหล	เหตุการณ์อนาคตในชุดฝึก = 0 (0.0%) ผลตรวจปลอดภัย • สถิติทุกตัวคำนวณจากชุดฝึกเท่านั้น

ตารางที่ 2.16 โปรโตคอล 11 ขั้น พร้อมค่าที่กรอกจริง (2/2)

ขั้น	สิ่งที่ต้องทำ	ค่าที่กรอกจริงในการทดลองของบทนี้
7	กำหนด Candidate Set	full_catalog โดยตัดรายการที่ผู้ใช้เห็นแล้วในชุดฝึกออก
8	ระบุวิธี Negative Sampling	ไม่ใช้การสุ่ม จึงรายงานได้ว่าเป็น nDCG@10 เต็มรูปแบบ ไม่ใช่ sampled nDCG@10
9	วัดทั้ง Accuracy และ Beyond-Accuracy	TopPopular: nDCG 0.0493, Cov 0.042, Gini 0.9743, Nov 2.2862, LT 0.0000 • Personalized: nDCG 0.1192, Cov 0.126, Gini 0.9190, Nov 2.9316, LT 0.0816
10	รายงานความไม่แน่นอน	ผู้ใช้ร่วม 752 คน สุ่มซ้ำระดับผู้ใช้ 4,000 รอบ • ผลต่าง +0.0699 • CI 95% = [+0.0600, +0.0800] • p = 0.0000 • มีนัยสำคัญ
11	ตรวจผลด้วยผู้ใช้จริง	ผลออฟไลน์เป็นเพียงการคัดกรอง ต้องผ่าน A/B Test พร้อม Guardrail เชิงธุรกิจและ Rollback Trigger ที่กำหนดล่วงหน้า

ประโยคปิดท้ายของโปรโตคอล

คะแนนประเมินไม่ได้เป็นคุณสมบัติของModel เพียงอย่างเดียว แต่เป็นผลร่วมของ Model • ข้อมูล • ตัวชี้วัด • เวลา • Candidate Set • และโปรโตคอลการประเมินทั้งหมด

2.15

เหตุใดการประเมินระบบผู้แนะนำจึงต่างจากงานทั่วไป

หกเหตุผล: Missing Negatives • Candidate Set • Position Bias • Temporal Drift • Exposure Bias • Offline ≠ Satisfaction

ภาพที่ 2.20 หกเหตุผลที่ทำให้การประเมินระบบผู้แนะนำต่างจาก ML ทั่วไป



ในงานจำแนกภาพแมว/สุนัข ภาพหนึ่งภาพมีคำตอบถูกเพียงคำตอบเดียว ไม่เปลี่ยนตามเวลา ไม่เปลี่ยนตามผู้ดู และไม่เปลี่ยนตามว่ามีภาพอื่นกี่ภาพวางข้าง ๆ

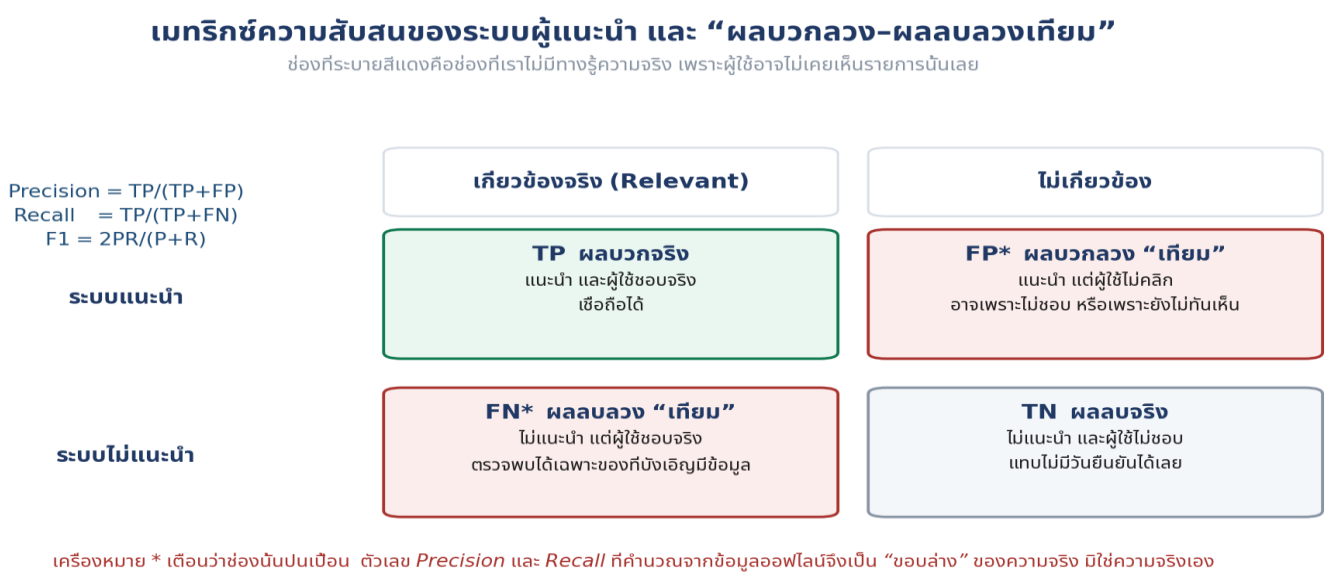
ในระบบผู้แนะนำ ไม่มีข้อใดในสามข้อนี้เป็นจริงเลย

ประเด็น

ไม่ใช่การอ้างว่าระบบผู้แนะนำ "พิเศษกว่า" งานอื่น แต่ผลลัพธ์ไวเป็นพิเศษต่อ Candidate Set, เวลา, การเปิดเผยรายการ และพฤติกรรมผู้ใช้

เหตุผลที่ 1 การไม่คลิกไม่ได้แปลว่าไม่ชอบ (Pseudo FP / FN)

ภาพที่ 2.21 ผลบวกลวง–ผลลบลวง “เทียม” จาก Exposure Bias



เครื่องหมาย * เตือนว่าช่องนั้นปนเปื้อน ตัวเลข *Precision* และ *Recall* ที่คำนวณจากข้อมูลออฟไลน์จึงเป็น “ขอบล่าง” ของความจริง มิใช่ความจริงเอง

- **การไม่คลิกเกิดได้จากอย่างน้อยห้าสาเหตุ:**
- ผู้ใช้ไม่ชอบจริง ๆ (กรณีเดียวที่เราสมมติ)
- ยังเลื่อนหน้าจอไปไม่ถึงตำแหน่งนั้น
- เห็นแล้วแต่ดูไปแล้วบนบริการอื่น
- เห็นแล้ว สนใจ แต่ยังไม่มีเวลา
- ปิดแอปไปก่อนด้วยเหตุผลที่ไม่เกี่ยวกับเนื้อหา

นิยาม 2.10

- Pseudo FP ระบบแนะนำแล้วผู้ใช้ไม่มีปฏิสัมพันธ์ : นับเป็น “ทายผิด” ทั้งที่อาจไม่เคยเห็น
- Pseudo FN ระบบไม่ได้แนะนำ : ถือว่าไม่เกี่ยวข้อง ทั้งที่ผู้ใช้อาจชอบมาก เพียงแต่ไม่เคยมีโอกาสพบ

ผลลัพธ์เชิงตัวเลข

Precision ออฟไลน์ต่ำกว่าความจริงอย่างเป็นระบบ (ตัวส่วนมี FP เทียม) และ Recall ก็ต่ำกว่าจริง (ตัวส่วนนับได้เฉพาะรายการที่บังเอิญมีข้อมูล) : ทั้งสองเป็นเพียง “ขอบล่าง” ของความจริง

ตัวอย่างการคำนวณ 2.18 ความเสียหายจากการตีความ “ไม่คลิก” ว่า “ไม่ชอบ”

สถานการณ์: บริการสตรีมมิงแสดงรายการแนะนำ 20 รายการต่อหน้าจอ ผู้ใช้เลื่อนดูจนถึงรายการที่ 20 เพียง 12% ของการเข้าใช้ ส่วนที่เหลือหยุดที่รายการที่ 6 โดยเฉลี่ย

1 รายการที่ผู้ใช้เห็นจริง

ถูก “แสดง” = 20

ถูก “เห็น” จริง ≈ 6

2 ป้ายกำกับเชิงลบที่เราสร้างขึ้นผิด ๆ

นับเป็น “ไม่ชอบ” = 20 – (จำนวนที่คลิก)

ทั้งที่ 14 รายการไม่เคยถูกเห็นเลย

3 ตีความ (คลิก 1 รายการ)

ป้ายเชิงลบ 19 รายการ: เห็นแล้วไม่คลิก เพียง 5

14 รายการ = แต่งขึ้นทั้งหมด (73.7%)

บทเรียน

ในงานจำแนกภาพ ป้ายกำกับ “ไม่ใช่แมว” คือความจริงที่ผู้ติดป้ายยืนยัน แต่ในระบบผู้แนะนำ ป้ายกำกับเชิงลบส่วนใหญ่คือ “สิ่งที่เราเดาเอาเอง” : ความต่างเชิงคุณภาพ มิใช่เชิงปริมาณ

เหตุผลที่ 2 Candidate Set ต่างกัน คะแนนเปลี่ยนมหาศาล (ตัวอย่าง 2.19)

1 Full Catalog

รายการที่ชอบอยู่อันดับ 500 จาก 5,000 : นอก Top-10 : nDCG@10 = 0.0000 (2.29)

2 Sampled Negatives m = 99

เซตผู้สมัครเหลือ 100 รายการ: เป้าหมาย 1 + รายการเชิงลบ 99

3 รายการที่เหนือกว่าถูกสุ่มติดมากี่ชิ้น

499 × 99 ÷ 4,999 = 9.88 ชิ้น

E[อันดับใหม่] = 1 + 9.88 = 10.88

(จำลอง 20,000 รอบได้ 10.86) (2.30)

4 คะแนน

เป้าหมายเข้ามาอยู่ใน Top-10 ถึง 47.0% ของการสุ่ม

sampled nDCG@10 = 0.1482 (2.31)

ข้อสรุปที่ต้องอ่านช้า ๆ

ตัวเลขกระโดดจาก 0.0000 เป็น 0.1482 โดยที่Model ไม่ได้เปลี่ยนแม้แต่พารามิเตอร์เดียว สิ่งที่เปลี่ยนไปคือ “สนามสอบ” ที่ง่ายลง 50 เท่า : และหัวข้อ 2.9 แสดงว่าการสุ่มเปลี่ยน “ผู้ชนะ” ได้ด้วย

เหตุผลที่ 3 Position Bias (นิยาม 2.11 และตัวอย่าง 2.20)

นิยาม 2.11

แนวโน้มที่ผู้ใช้จะมีปฏิสัมพันธ์กับรายการอันดับต้นมากกว่าอันดับท้าย แม้ทั้งสองมีความเกี่ยวข้องเท่ากันทุกประการ : ป้ายกำกับสะท้อนทั้ง “ความชอบ” และ “ตำแหน่ง” ปะปนกัน

ตำแหน่ง	1	3	5	10	20
ความน่าจะเป็นที่ถูกเห็น	0.95	0.72	0.55	0.28	0.09
อัตราคลิกที่สังเกตได้ (ความชอบจริง = 0.40)	0.380	0.288	0.220	0.112	0.036

1 คำนวณ

ตำแหน่ง 1: 0.95 × 0.40 = 0.380 | ตำแหน่ง 20: 0.09 × 0.40 = 0.036 | 0.380 ÷ 0.036 ≈ 10.6 เท่า

ตีความ

- รายการสองชิ้นที่ผู้ใช้ชอบเท่ากันเป๊ะ กลับมีอัตราคลิกต่างกันสิบเท่าเพียงเพราะตำแหน่ง
- นำไปเป็นป้ายกำกับ : Model รุ่นถัดไปเรียนรู้ “ตำแหน่ง” มิใช่ “ความชอบ”

แนวทางแก้ที่เป็นมาตรฐาน

- บันทึกตำแหน่งที่แสดงจริงไว้ในล็อกทุกครั้ง
- ชดเชยด้วยน้ำหนักส่วนกลับของความน่าจะเป็นที่ถูกเห็น : แนวคิดเดียวกับ Off-policy Evaluation (2.12)

เหตุผลที่ 4 และ 5 ความสนใจเปลี่ยนตามเวลา และ Exposure Bias (MNAR)

เหตุผลที่ 4 ความสนใจเปลี่ยนตามเวลา

- ภาพแมวเมื่อสิบปีก่อนยังเป็นภาพแมว แต่ความนิยมของรายการและรสนิยมผู้ใช้เปลี่ยนตลอดเวลา
- กฎเหล็ก: ห้ามใช้ข้อมูลอนาคตมาทำนายอดีต : การแบ่งแบบสุ่มละเมิดกฎนี้โดยไม่รู้ตัว (หัวข้อ 2.8: +71.6%)

นิยาม 2.12 Exposure Bias

- ผู้ใช้มีปฏิสัมพันธ์ได้เฉพาะกับรายการที่ระบบเลือกแสดง : ข้อมูลที่เก็บได้ไม่ใช่ตัวอย่างสุ่มจากความชอบจริง
- ภาษาสถิติ: Missing-Not-At-Random (MNAR)

1 รายการที่ไม่เคยแสดง จะไม่มีข้อมูลตลอดไป

ระบบยืนยันความเชื่อเดิมของตัวเองไปเรื่อย ๆ โดยไม่มีหลักฐานโต้แย้ง

2 ออฟไลน์วัด “ความเหมือนระบบเดิม” มากกว่า “ความดี”

Model ที่เลียนแบบระบบเดิมได้แม่นที่สุด มักได้คะแนนสูงสุด แม้ไม่ได้ดีขึ้นสำหรับผู้ใช้

3 แก้ที่ระดับการเก็บข้อมูล ไม่ใช่ระดับ Model

บันทึก Propensity ตั้งแต่ต้น และสงวนสัดส่วนการเข้าชมส่วนน้อยสำหรับการสำรวจแบบสุ่ม

เหตุผลที่ 6 คะแนนออฟไลน์สูง ไม่รับประกันความพึงพอใจ (กรณีศึกษา 2.1)

nDCG@10 +13.9%	เวลาใช้งาน −2.1%	ILD 0.62 : 0.41
0.180 : 0.205 ออฟไลน์	เมื่อขึ้น A/B Test จริง	แต่ไม่มีใครวัดตัวเลขนี้ก่อนปล่อย

สาเหตุที่พบเมื่อสอบสวน

- Model ใหม่แนะนำสิ่งที่คล้ายกับที่ผู้ใช้เพิ่งดูมากขึ้น ตรงกับข้อมูลอดีตจึงได้คะแนนออฟไลน์สูง
- ผู้ใช้จริงรู้สึกว่า “ซ้ำซาก” ไม่มีอะไรใหม่ให้ค้นพบ

บทเรียน

- Primary Metric ที่ดีขึ้น ไม่ได้แปลว่าระบบดีขึ้น หากไม่ได้กำหนด Guardrail ไว้ล่วงหน้า : ถ้าประกาศ ILD ≥ 0.55 Model นี้จะถูกปฏิเสธตั้งแต่ขั้นออฟไลน์

ประโยคสรุปหัวข้อ 2.15

หลักการประเมินเป็นเรื่องสำคัญของ AI/ML ทุกประเภท แต่ในระบบผู้แนะนำ ผลลัพธ์ไวต่อ Candidate Set เวลา การเปิดเผยรายการ และพฤติกรรมผู้ใช้เป็นพิเศษ จึงต้องกำหนดโปรโตคอลให้ครบก่อนเริ่มเปรียบเทียบModel