TOPIC 5:

Collaborative Filtering

204729

Recommender Systems

ผู้ช่วยศาสตราจารย์ ดร.ดุษฎี ประเสริฐธิติพงษ์



COMPUTER SCIENCE
Chiang Mai University

บทนี้ตอบคำถามว่า "พฤติกรรมของผู้ใช้คนอื่น ช่วยแนะนำได้อย่างไร"



- **Memory-based** User-kNN • Item-kNN • Pearson • Adjusted Cosine
- **Baseline** ค่าเอนเอียง $\mu + b_u + b_i$ พร้อมการหด
- **Latent Factor** Matrix Factorization ด้วย SGD และ ALS • SVD++
- **Implicit Feedback** WRMF • BPR • EASE • NCF
- **Evaluation** RMSE/MAE • HR@3 • MRR • ค่าคาดหมายเมื่อคะแนนเสมอ
- **Challenges** Cold Start • Sparsity • Scalability

วัตถุประสงค์การเรียนรู้ประจำบท

1 อธิบาย

แนวคิด สมมติฐาน และความต่างจากระบบอิงเนื้อหา (บทที่ 3–4)

2 อ่านและสรุป

ความหนาแน่น ค่าเฉลี่ยรายผู้ใช้/รายการ จำนวนรายการร่วม

3 คำนวณ

Pearson, Cosine, Adjusted Cosine, Jaccard + ถ่วงนัยสำคัญและการหด

4 ทำนายคะแนน

User-kNN, Item-kNN, ค่าเอนเอียงด้วยมือ และประกอบระบบครบวงจร

5 อธิบายและคำนวณ

MF ด้วย SGD หนึ่งก้าว และแนวคิดของ ALS

6 เลือกใช้

WRMF, BPR, EASE สำหรับข้อมูลโดยปริยาย และรู้จัก NCF

7 ประเมิน

ทั้งแบบทำนายคะแนนและจัดอันดับ เทียบกับระบบอิงเนื้อหา

8 วิเคราะห์

การเริ่มต้นเย็น ความเบาบาง และการขยายขนาด

9 เขียนโปรแกรม

ไพทอนสั้น ๆ สำหรับทุกวิธี และปฏิบัติการท้ายบท

ตารางที่ 5.1 ความรู้พื้นฐานที่ใช้ในบทนี้และแหล่งทบทวน

ความรู้	ใช้ในหัวข้อ	ทบทวนได้จาก
ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐาน	5.2, 5.4	สถิติพื้นฐาน
ผลคูณจุดและความคล้ายโคไซน์	5.4, 5.9	บทที่ 3
การลดตามเกรเดียนต์	5.9, 5.12	บทที่ 4 หัวข้อ 4.3.3
HR@K, MRR และการกันออกทีละรายการ	5.14	บทที่ 2 และบทที่ 3 หัวข้อ 3.11

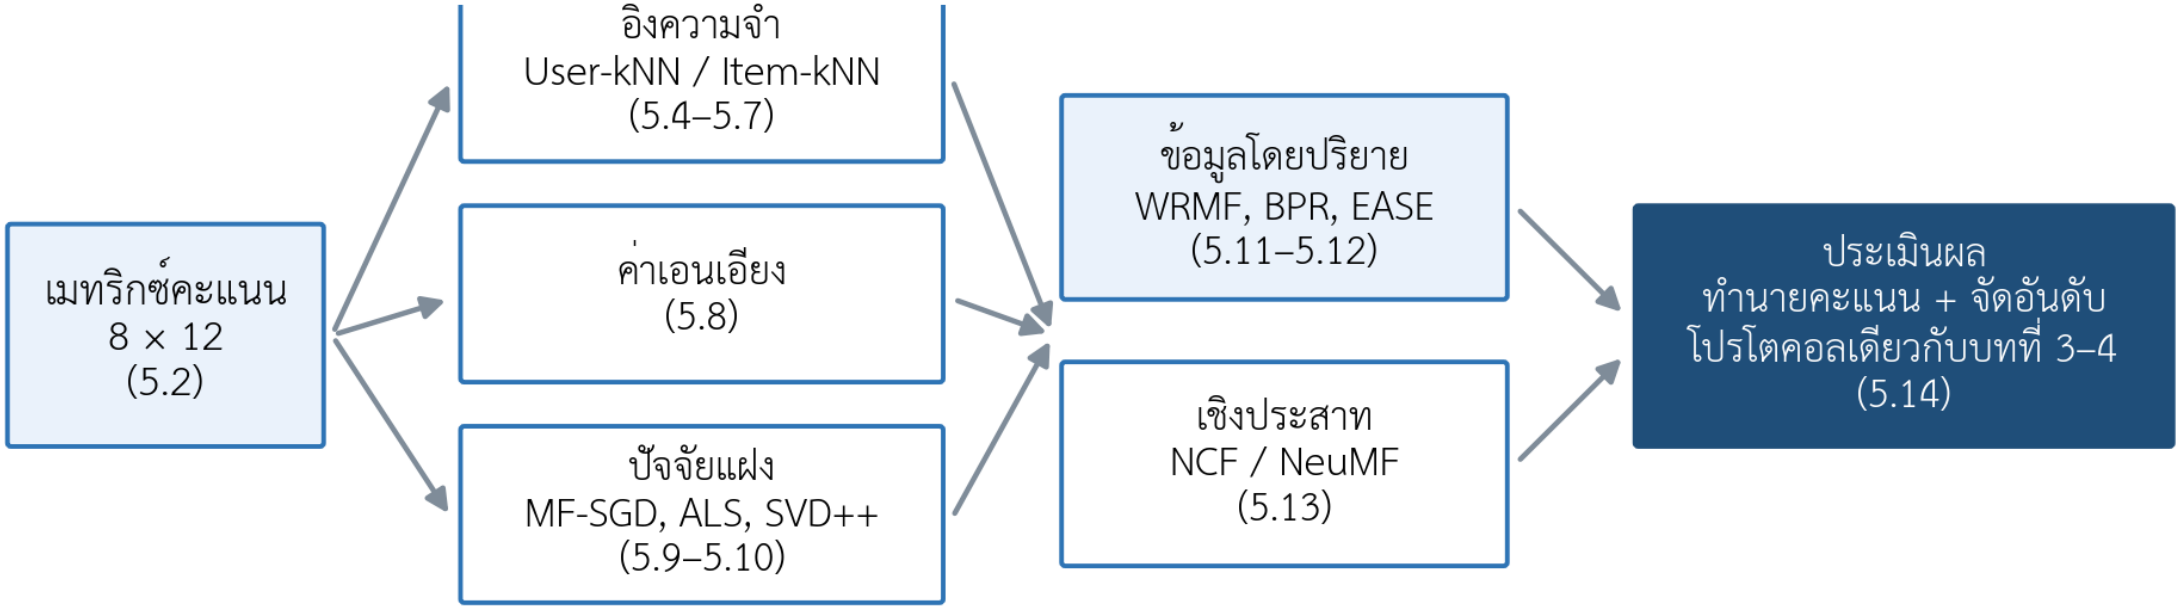
ทำไมต้องทบทวน

- ค่าเฉลี่ยใช้ลบสเกลของผู้ใช้ (Pearson)
- ผลคูณจุดใช้ทั้งโคไซน์และ MF

ข้อมูลที่ใช้ทั้งบท

- MovieMini-12 ชุดเดียวกับบทที่ 3–4
- ผู้ใช้ 8 คน · ภาพยนตร์ 12 เรื่อง · คะแนน 32 ค่า

แผนที่ของบทที่ 5: จากเมทริกซ์คะแนนสู่การประเมินผล



ภาพที่ 5.1 แผนที่ของบทที่ 5 จากเมทริกซ์คะแนนสู่แบบจำลองและการประเมินผล

ทุกวิธีเริ่มจาก **เมทริกซ์คะแนนเดียวกัน** แล้วแตกเป็นสามสาย: เพื่อนบ้าน (คำนวณมือได้ทั้งหมด) · ค่าเอนเอียง (สะพานสู่การเรียนพารามิเตอร์) · ปัจจัยแฝง → ข้อมูลโดยปริยาย → NCF → ประเมินผลด้วยโปรโตคอลเดียวกับบทที่ 3–4

MovieMini-12: ภาพยนตร์ 12 เรื่องที่ใช้ตลอดบท

รหัส	ชื่อเรื่อง	รหัส	ชื่อเรื่อง
i1	Toy Story 5	i7	Ballerina
i2	Inside Out 2	i8	Furiosa: A Mad Max Saga
i3	The Wild Robot	i9	Conclave
i4	It Ends with Us	i10	Dune: Part Two
i5	Wicked	i11	Mickey 17
i6	Bridget Jones: Mad About the Boy	i12	Project Hail Mary

ใช้ข้อมูลชุดเดียวกับบทที่ 3–4

- ผู้ใช้ 8 คน (u1–u8) ให้คะแนน 32 ค่า สเกล 1–5

สิ่งที่ต่างออกไป

- บทนี้ **ไม่ใช้เนื้อหาของภาพยนตร์เลย** ทั้งเรื่องย่อ โปสเตอร์ และเสียง

จึงตอบได้ว่า

- พฤติกรรมของผู้ใช้คนอื่นให้ข้อมูลที่เนื้อหาให้ไม่ได้มากน้อยเพียงใด

5.1

การกรองร่วมคืออะไร



จากสิ่งที่รายการเป็น สู่สิ่งที่ผู้คนทำ • ความเป็นมาโดยย่อ

5.1.1 จากสิ่งที่รายการเป็น สู่สิ่งที่ผู้คนทำ

บทที่ 3–4: อิงเนื้อหา

- สร้างจาก **สิ่งที่รายการเป็น** — เรื่องย่อ โปสเตอร์ เพลง ตัวอย่างภาพยนตร์
- ใช้พฤติกรรมของผู้ใช้ **คนเดียว** ที่กำลังรับคำแนะนำ

บทที่ 5: การกรองร่วม (CF)

- ไม่สนใจว่ารายการคืออะไร แต่ดูว่า **ผู้คนทำอะไรกับรายการ**
- สมมติฐาน: ผู้ที่เคยเห็นพ้องกันในอดีต มีแนวโน้มเห็นพ้องกันในอนาคต

ตัวอย่างใน MovieMini-12

- u5 ชอบทั้ง i3 The Wild Robot (แอนิเมชันหุ่นยนต์) และ i9 Conclave (ดราม่าการเมืองในวาติกัน)
- ระบบอิงเนื้อหา **เชื่อมสองเรื่องนี้ไม่ได้** แต่การกรองร่วมเห็นรูปแบบนี้ได้ทันทีจากพฤติกรรม
- สอดคล้องกับอันดับที่ต่ำของ u5 ในทุกระบบของบทที่ 4

อธิบายแบบเข้าใจง่าย: การกรองร่วมคือการถามเพื่อนที่รสนิยมตรงกัน



อธิบายแบบเข้าใจง่าย

- ก่อนไปดูภาพยนตร์ เรามักถามเพื่อนที่เคยชอบเรื่องเดียวกับเรา
- ถ้าเพื่อนเคยชอบ Toy Story 5 และ Inside Out 2 เหมือนเรา แล้วบอกว่า **The Wild Robot สนุกมาก** เราก็มีแนวโน้มจะชอบด้วย
- เราไม่จำเป็นต้องรู้ว่า The Wild Robot เล่าเรื่องอะไร รู้เพียงว่า **"คนที่คล้ายเราชอบ"** ก็พอ
- การกรองร่วมทำสิ่งนี้ด้วยคอมพิวเตอร์ กับผู้ใช้ **หลายล้านคน** พร้อมกัน

5.1.2 ความเป็นมาโดยย่อของการกรองร่วม

เส้นทางของงานวิจัยเรียงตรงกับลำดับหัวข้อในบทนี้: เพื่อนบ้าน → ปัจจัยแฝง → ข้อมูลโดยปริยาย → จัดอันดับ → โครงข่ายประสาท

1992	1994	2003	2006–09	2008–17
Tapestry [1] Xerox PARC ผู้ใช้ช่วยกันติดป้ายอีเมลที่น่าสนใจ	GroupLens [2] ทำให้อัตโนมัติสำหรับข่าว Usenet หาผู้ใช้ที่ให้คะแนนคล้ายกัน	Amazon [3] การกรองร่วมอิงรายการที่ขยายขนาดได้	Netflix Prize [4],[5] การแยกตัวประกอบเมทริกซ์กลายเป็นมาตรฐาน	Implicit • BPR • NCF ข้อมูลโดยปริยาย [6] การเรียนเพื่อจัดอันดับ [7] โครงข่ายประสาท [8]

ตารางที่ 5.2 เปรียบเทียบระบบอิงเนื้อหา (บทที่ 3–4) กับการกรองร่วม

ประเด็น	ระบบอิงเนื้อหา	การกรองร่วม
ข้อมูลที่ใช้	เนื้อหาของรายการ + ประวัติของผู้ใช้คนเดียว	ประวัติของผู้ใช้ทุกคน
รายการใหม่	แนะนำได้ทันทีถ้ามีเนื้อหา	แนะนำไม่ได้จนกว่าจะมีผู้โต้ตอบ
ผู้ใช้ใหม่	ต้องมีประวัติอย่างน้อยเล็กน้อย	ต้องมีประวัติอย่างน้อยเล็กน้อย
ความหลากหลาย	มักแนะนำเรื่องคล้ายเดิม	ค้นพบความเชื่อมโยงข้ามแนวได้
ต้องการความรู้โดเมน	ต้องออกแบบการสกัดเนื้อหา	ไม่ต้อง
จุดอ่อนหลัก	ติดอยู่ในกรอบของเนื้อหา	ความเบาบางและการเริ่มต้นเย็น

- แถว "ความหลากหลาย" เป็นแนวโน้มที่รายงานในข้อมูลขนาดใหญ่ ต้องตรวจเป็นกรณีไป — บน MovieMini-12 ผลบางข้อ **กลับด้าน** (หัวข้อ 5.14)

5.2

เมทริกซ์คะแนนของ MovieMini-12



ข้อมูลเข้าเพียงอย่างเดียว • สถิติพื้นฐาน • ชัดแจ้ง vs โดยปริยาย

ชุดข้อมูล MovieMini-12 : บัญชีภาพยนตร์

รหัส	ชื่อเรื่อง (ปี)	แนว	รหัส	ชื่อเรื่อง (ปี)	แนว
i1	Toy Story 5 (2026)	Animation, Family	i7	Ballerina (2025)	Action, Thriller
i2	Inside Out 2 (2024)	Animation, Family	i8	Furiosa: A Mad Max Saga	Action, Sci-Fi
i3	The Wild Robot (2024)	Animation, Sci-Fi	i9	Conclave (2024)	Drama, Thriller
i4	It Ends with Us (2024)	Drama, Romance	i10	Dune: Part Two (2024)	Action, Sci-Fi
i5	Wicked (2024)	Fantasy, Musical	i11	Mickey 17 (2025)	Sci-Fi, Thriller
i6	Bridget Jones: Mad About the Boy	Drama, Romance	i12	Project Hail Mary (2026)	Drama, Sci-Fi

แถบสีฟ้า = แอนิเมชันสามเรื่องที่ u1 ชอบ

ตารางที่ 5.3 เมทริกซ์คะแนนของ MovieMini-12 (• = ยังไม่มีคะแนน)

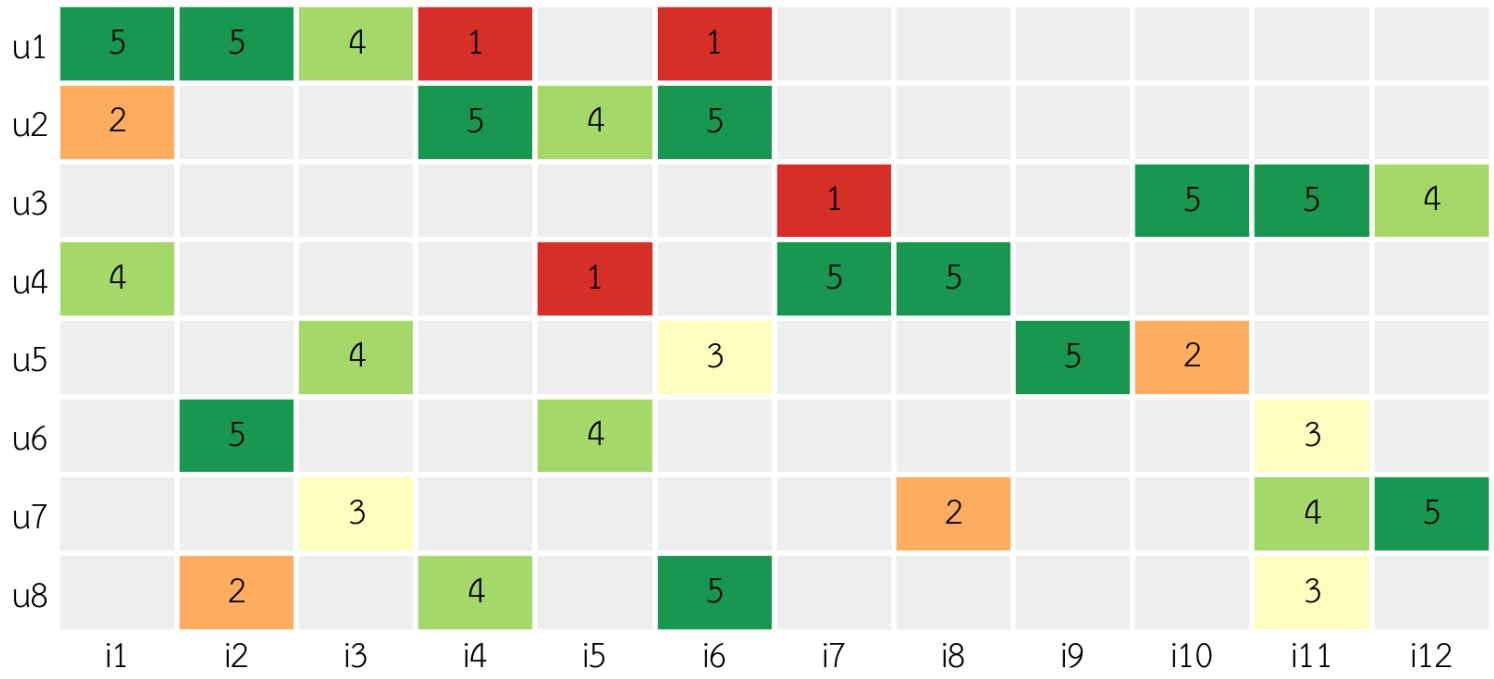
ผู้ใช้	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	ค่าเฉลี่ย
u1	5	5	4	1	•	1	•	•	•	•	•	•	3.20
u2	2	•	•	5	4	5	•	•	•	•	•	•	4.00
u3	•	•	•	•	•	•	1	•	•	5	5	4	3.75
u4	4	•	•	•	1	•	5	5	•	•	•	•	3.75
u5	•	•	4	•	•	3	•	•	5	2	•	•	3.50
u6	•	5	•	•	4	•	•	•	•	•	3	•	4.00
u7	•	•	3	•	•	•	•	2	•	•	4	5	3.50
u8	•	2	•	4	•	5	•	•	•	•	3	•	3.50

เมทริกซ์ R ขนาด |U| × |I| = 8 × 12 • ช่อง r_{ui} คือคะแนนที่ u ให้ i

งานของ CF ทั้งบท = **เติมช่องว่าง** แล้วแนะนำรายการที่เติมได้ค่าสูง

ที่มาของข้อมูล: ตารางที่ 5.3 คือข้อมูลต้นทางของทุกตัวอย่างในบท • คะแนนชุดเดียวกับบทที่ 3 ตารางที่ 3.6 และบทที่ 4 ตารางที่ 4.4 • คอลัมน์ค่าเฉลี่ย = ผลรวมคะแนนของแถว ÷ จำนวนช่องที่มีคะแนน เช่น u1 = (5+5+4+1+1)/5 = 16/5 = 3.20

ภาพที่ 5.2 เมทริกซ์คะแนนในรูปแผนภาพสี



ภาพที่ 5.2 เมทริกซ์คะแนนของ MovieMini-12 ช่องสีเทาคือคะแนนที่การกรองร่วมต้องทำนาย

วิธีอ่านภาพ

- สีเขียว = คะแนนสูง (4–5)
- สีแดง/ส้ม = คะแนนต่ำ (1–2)
- ช่องสีเทา **64 ช่อง** คือสิ่งที่ต้องทำนาย
- ผู้ใช้แต่ละคนเห็นเพียง 3–5 เรื่องจาก 12 เรื่อง

MovieMini-12 : คะแนนผู้ใช้และข้อตกลงของบท

ผู้ใช้	ชอบ (4–5)	กลาง (3)	ไม่ชอบ (1–2)
u1	i1 (5), i2 (5), i3 (4)	–	i4 (1), i6 (1)
u2	i4 (5), i5 (4), i6 (5)	–	i1 (2)
u3	i10 (5), i11 (5), i12 (4)	–	i7 (1)
u4	i1 (4), i7 (5), i8 (5)	–	i5 (1)
u5	i3 (4), i9 (5)	i6 (3)	i10 (2)
u6	i2 (5), i5 (4)	i11 (3)	–
u7	i11 (4), i12 (5)	i3 (3)	i8 (2)
u8	i4 (4), i6 (5)	i11 (3)	i2 (2)

ผู้ใช้หลัก u1

- Candidate 7 เรื่อง: i5, i7, i8, i9, i10, i11, i12

ที่มาของข้อมูล: จัดกลุ่มจากตารางที่ 5.3: ชอบ = คะแนน 4–5 • กลาง = 3 • ไม่ชอบ = 1–2 • รายการผู้สมัครของ u1 คือช่องว่าง 7 ช่องในแถว u1 (i5, i7, i8, i9, i10, i11, i12) • คู่ชอบรวม 3+3+3+3+2+2+2+2 = 20 คู่ ใช้เป็น 20 กรณีกันออกในหัวข้อ 5.14

ตารางที่ 5.4 สัญกรณ์ที่ใช้ตลอดบทนี้

สัญกรณ์	ความหมาย
r_{ui} , $\hat{r}_{ui}$	คะแนนจริงและค่าทำนายของผู้ใช้ u ต่อรายการ i
I_u , U_i	เซตรายการที่ u ให้คะแนน และเซตผู้ใช้ที่ให้คะแนน i
I_{uv}	รายการที่ทั้ง u และ v ให้คะแนน (รายการร่วม)
$\bar{r}_u$, μ	ค่าเฉลี่ยของผู้ใช้ u และค่าเฉลี่ยรวมของทุกคะแนน
$N_k(u; i)$	เพื่อนบ้านไม่เกิน k คนของ u ที่ให้คะแนน i
b_u , b_i	ค่าเอนเอียงของผู้ใช้และของรายการ
p_u , q_i	เวกเตอร์ปัจจัยแฝงของผู้ใช้และของรายการ มิติ k
λ , η	ค่าเรกูลาไรเซชัน และอัตราการเรียนรู้

ตัวอย่างการคำนวณ 5.1 สถิติพื้นฐานของเมทริกซ์คะแนน : โจทย์

โจทย์

จงหา **ความหนาแน่น** · **ค่าเฉลี่ยรวม** μ · **ค่าเฉลี่ยของ** u1 · **จำนวนรายการร่วมเฉลี่ย** ของผู้ใช้ทุกคู่ (จากตารางที่ 5.3)

ผู้ใช้	คะแนนที่ให้	จำนวน	ผลรวม
u1	5, 5, 4, 1, 1	5	16
u2	2, 5, 4, 5	4	16
u3	1, 5, 5, 4	4	15
u4	4, 1, 5, 5	4	15
u5	4, 3, 5, 2	4	14
u6	5, 4, 3	3	12
u7	3, 2, 4, 5	4	14
u8	2, 4, 5, 3	4	14
รวม		32	116

เตรียมข้อมูลก่อนคำนวณ

- นับคะแนนที่รู้ค่าทีละแถว แล้วรวม → 32 ค่า
- รวมคะแนนทุกค่า → 116
- ช่องทั้งหมด = 8 ผู้ใช้ × 12 รายการ = 96 ช่อง
- คู่ผู้ใช้ทั้งหมด = C(8,2) = 8×7/2 = 28 คู่

ที่มาของข้อมูล: ตารางนี้สรุปจากตารางที่ 5.3 ทีละแถว: "คะแนนที่ให้" = ช่องที่ไม่ใช่จุดเรียงจาก i1⟶i12 · จำนวน = นับช่อง · ผลรวม = บวกคะแนน ⟶ รวมทั้งตารางได้ |K| = 32 และ $\sum r$ = 116 · |U| = 8 และ |I| = 12 มาจากหัวแถวและหัวคอลัมน์

ตัวอย่างการคำนวณ 5.1 : ขั้นที่ 1–3

1 ความหนาแน่น (Density) และความเบาบาง (Sparsity)

$$\text{density} = \frac{|K|}{|U| \times |I|} = \frac{32}{8 \times 12} = \frac{32}{96} = 0.3333 \qquad \text{sparsity} = 1 - 0.3333 = 0.6667$$

2 ค่าเฉลี่ยรวม μ = ผลรวมคะแนนทั้งหมด ÷ จำนวนคะแนน

$$\mu = \frac{\sum r_{ui}}{|K|} = \frac{116}{32} = 3.6250$$

3 ค่าเฉลี่ยของ u1 — ต่ำกว่า μ เพราะ u1 ให้ 1 คะแนนสองเรื่อง (i4, i6)

$$\bar{r}_{u1} = \frac{5+5+4+1+1}{5} = \frac{16}{5} = 3.2$$

ที่มาของข้อมูล: |K| = 32 และ $\sum r$ = 116 มาจากคอลัมน์ "จำนวน" และ "ผลรวม" ของสไลด์ก่อนหน้า (นับจากตารางที่ 5.3) • 96 = 8 × 12 ช่อง • ค่าเฉลี่ยของ u1 ใช้เฉพาะ 5 คะแนนในแถว u1 (i1 5, i2 5, i3 4, i4 1, i6 1)

ตัวอย่างการคำนวณ 5.1 : ขั้นที่ 4 จำนวนรายการร่วมของทุกคู่

	u2	u3	u4	u5	u6	u7	u8
u1	3	0	1	2	1	1	3
u2		0	2	1	1	0	2
u3			1	1	1	2	1
u4				0	1	1	0
u5					0	1	1
u6						1	2
u7							1

4 ขั้นที่ 4

นับรายการที่ทั้งสองคนให้คะแนน เช่น u1–u2 ร่วมกันที่ i1, i4, i6 = 3

$$\sum_{28\ \text{pairs}} n_{uv} = 31, \qquad \bar{n} = \frac{31}{28} = 1.1071$$

ช่องสีชมพู = **ไม่มีรายการร่วมเลย 6 คู่**

แปลผล ความหนาแน่น 33% สูงกว่าข้อมูลจริงมาก (Netflix Prize ≈ 1.2%) แต่ผู้ใช้แต่ละคู่มีรายการร่วมเฉลี่ยเพียง ~1 เรื่อง → ปัญหาหลักคือ **จำนวนหลักฐานที่ใช้เปรียบเทียบผู้ใช้สองคน**

ที่มาของข้อมูล: แต่ละช่องคือจำนวนคอลัมน์ที่ทั้งสองแถวของตารางที่ 5.3 มีคะแนน เช่น u1–u2 ร่วมที่ i1, i4, i6 = 3 • ผลรวมทั้ง 28 ช่อง = 31 ⟶ ค่าเฉลี่ย 31/28 = 1.1071 • การกระจาย: 0 เรื่อง 6 คู่, 1 เรื่อง 15 คู่, 2 เรื่อง 5 คู่, 3 เรื่อง 2 คู่ • Netflix ≈ 1.2% (100,480,507 ÷ (480,189 × 17,770))

5.2.3 ผลป้อนกลับชัดแจ้งและโดยปริยาย

ผลป้อนกลับชัดแจ้ง (Explicit)

- คะแนน 1–5 ผู้ใช้บอกความชอบตรง ๆ
- บอกได้ทั้ง "ชอบ" และ "ไม่ชอบ"
- ใช้ในหัวข้อ 5.4–5.10

ผลป้อนกลับโดยปริยาย (Implicit)

- การกดดู ดูจนจบ เพิ่มรายการโปรด
- ไม่เคยกด ≠ ไม่ชอบ (อาจยังไม่เคยเห็น)
- ใช้ในหัวข้อ 5.11–5.12

กติกาแปลงคะแนน (เหมือนบทที่ 3–4): คะแนน 4–5 = "ชอบ" (1) • คะแนนอื่นและช่องว่าง = "ไม่ได้ชอบ" (0)

u1	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12
คะแนน	5	5	4	1	·	1	·	·	·	·	·	·
ชอบ (0/1)	1	1	1	0	0	0	0	0	0	0	0	0

ตัวอย่าง: แถวของ u1 หลังแปลง — คะแนน 1 กับช่องว่าง **กลายเป็น 0 เหมือนกัน**

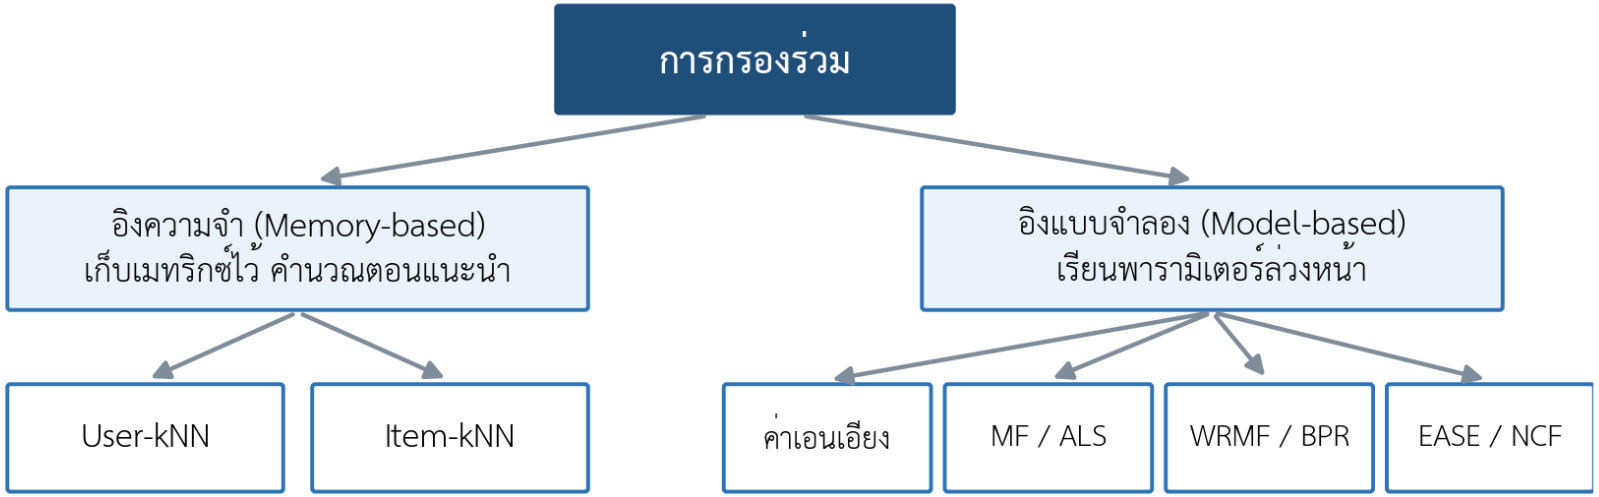
5.3

สองตระกูลของการกรองร่วม



Memory-based (อิงความจำ) • Model-based (อิงแบบจำลอง)

ภาพที่ 5.3 อนุกรมวิธานของการกรองร่วม



ภาพที่ 5.3 อนุกรมวิธานของการกรองร่วมและเทคนิคที่บทนี้ครอบคลุม

- **อิงความจำ (Momor-based)** เก็บเมทริกซ์ไว้ทั้งหมด คำนวณความคล้ายตอนแนะนำ ≈ ถามเพื่อนที่รสนิยมตรงกัน
- **อิงแบบจำลอง (Model-based)** เรียนพารามิเตอร์ล่วงหน้า แล้วใช้ทำนาย ≈ สรุปรสนิยมของทุกคนเป็นกฎกะทัดรัด

ตารางที่ 5.5 เปรียบเทียบสองตระกูลในเชิงวิศวกรรม

ประเด็น	อิงความจำ	อิงแบบจำลอง
สิ่งที่เก็บ	เมทริกซ์คะแนนทั้งหมด (และตารางความคล้าย)	พารามิเตอร์ เช่น เวกเตอร์ปัจจัยแฝง
เวลาฝึก	ไม่มี หรือคำนวณความคล้ายล่วงหน้า	ต้องฝึก อาจใช้เวลานาน
เวลาแนะนำ	ช้าเมื่อผู้ใช้หรือรายการมาก	เร็ว เป็นผลคูณจุด
การอธิบาย	ง่าย "เพราะผู้ใช้ที่คล้ายคุณชอบ"	ยากกว่า ปัจจัยแฝงไม่มีชื่อ
การรับข้อมูลใหม่	ทันที	ต้องฝึกใหม่หรือปรับบางส่วน
ความแม่นบนข้อมูลใหญ่	ปานกลาง	มักสูงกว่า

- ลำดับในบท: อิงความจำ (5.4–5.7) → ค่าเอนเอียง (5.8) → ปัจจัยแฝง (5.9–5.10) → โดยปริยาย (5.11–5.12) → NCF (5.13) → ประเมินผล (5.14)

5.4

มาตรวัดความคล้ายระหว่างผู้ใช้



Pearson • Cosine • Jaccard • Significance Weighting • Shrinkage

หัวใจของการกรองร่วมแบบอิงความจำ: ผู้ใช้สองคนคล้ายกันเพียงใด

ความยาก

- เปรียบเทียบได้เฉพาะ **รายการที่ทั้งสองคนให้คะแนนร่วมกัน** I_{uv}
- ในข้อมูลเบาบาง I_{uv} มักมีน้อยมาก (MovieMini-12 เฉลี่ย 1.1 เรื่อง)

หัวข้อนี้แนะนำ

- มาตรวัด 4 แบบ: Pearson • Cosine • Adjusted Cosine • Jaccard
- วิธีลดผลของความคล้ายที่มาจาก **หลักฐานน้อย**

ตัวอย่าง: รายการร่วมของ u1 กับผู้ใช้อื่น (u1 ให้คะแนน i1, i2, i3, i4, i6)

คู่	u1–u2	u1–u3	u1–u4	u1–u5	u1–u6	u1–u7	u1–u8
รายการร่วม I_{uv}	i1, i4, i6	—	i1	i3, i6	i2	i3	i2, i4, i6
$\lvert I_{uv} \rvert$	3	0	1	2	1	1	3

ที่มาของข้อมูล: รายการร่วมของ u1 กับผู้ใช้อื่นได้จากการตัดเซต: u1 ให้คะแนน {i1, i2, i3, i4, i6} (แถว u1 ตารางที่ 5.3) ∩ เซตของแต่ละคน เช่น u8 = {i2, i4, i6, i11} ⟶ {i2, i4, i6} • ค่าเฉลี่ย 1.1 เรื่องมาจากตัวอย่าง 5.1 ขั้นที่ 4 (31/28 = 1.1071)

อธิบายแบบเข้าใจง่าย: เพียร์สันแยกคนใจดีออกจากคนเข้มงวด



อธิบายแบบเข้าใจง่าย

- ผู้ใช้คนหนึ่ง **ใจดี** ให้ 4 ดาวกับเรื่องที่เฉย ๆ และ 5 ดาวกับเรื่องที่ชอบ
- อีกคน **เข้มงวด** ให้ 2 ดาวกับเรื่องที่เฉย ๆ และ 3 ดาวกับเรื่องที่ชอบ
- ตัวเลขต่างกัน แต่ **รสนิยมเหมือนกันทุกประการ**
- เพียร์สันถามว่า **"เรื่องนี้สูงหรือต่ำกว่าค่าปกติของคุณ"** ทั้งสองคนตอบว่า "สูงกว่า" กับเรื่องเดียวกัน จึงได้ความคล้ายเต็ม 1

5.4.1 สหสัมพันธ์เพียร์สัน (Pearson Correlation)

$$\text{sim}(u,v) = \frac{\sum_{i \in I_{uv}} (r_{ui} - \bar{r}_u)(r_{vi} - \bar{r}_v)}{\sqrt{\sum_{i \in I_{uv}} (r_{ui} - \bar{r}_u)^2} \sqrt{\sum_{i \in I_{uv}} (r_{vi} - \bar{r}_v)^2}}$$

สมการ (5.1)

วัดว่า **ทิศทาง** ของความชอบเหมือนกันหรือไม่ ไม่ใช่ระดับคะแนน

โดยที่

- I_{uv} = รายการที่ทั้ง u และ v ให้คะแนน
- $\bar{r}_u$ = ค่าเฉลี่ยของ u จาก **ทุกคะแนน** ของ u (ตาม [9])
- $r_{ui} - \bar{r}_u$ = ส่วนเบี่ยงเบนจากค่าปกติของ u
- ตัวเศษ = ผลรวมผลคูณส่วนเบี่ยงเบน • ตัวส่วน = ขนาดของเวกเตอร์ส่วนเบี่ยงเบน

การตีความ

- ค่าอยู่ในช่วง −1 ถึง +1
- +1 เห็นพ้องทุกเรื่อง • −1 ตรงข้ามทุกเรื่อง
- ข้อควรระวัง มีรายการร่วม 1 เรื่อง → ได้ ±1 เสมอ

ที่มาของข้อมูล: ค่าที่แทนในสมการ (5.1) มาจากตารางที่ 5.3: r_ui และ r_vi = คะแนนในคอลัมน์ที่ทั้งสองคนมีคะแนน (I_uv) • $\bar{r}_u$, $\bar{r}_v$ = คอลัมน์ค่าเฉลี่ยซึ่งคิดจากทุกคะแนนของผู้ใช้ • ใช้จริงในตัวอย่าง 5.2 (u1–u2) และคอลัมน์ Pearson ของตารางที่ 5.6

ตัวอย่างการคำนวณ 5.2 เพียร์สันระหว่าง u1 กับ u2 : โจทย์และข้อมูล

โจทย์ จงหาความคล้ายแบบเพียร์สันระหว่าง u1 กับ u2 ด้วยสมการ (5.1)

ผู้ใช้	i1	i2	i3	i4	i5	i6	$\bar{r}_u$
u1	5	5	4	1	·	1	3.20
u2	2	·	·	5	4	5	4.00

ค่าเฉลี่ยของผู้ใช้

$$\bar{r}_{u1} = \frac{16}{5} = 3.2 \qquad \bar{r}_{u2} = \frac{2+5+4+5}{4} = \frac{16}{4} = 4.0$$

สิ่งที่เห็นจากตาราง

- ช่องสีเขียว = รายการร่วม **i1, i4, i6**
- u1 ชอบ i1 แต่ไม่ชอบ i4, i6
- u2 กลับกันทุกเรื่อง
- ค่าเฉลี่ยใช้ **ทุกคะแนน** ของผู้ใช้ ไม่ใช่เฉพาะรายการร่วม

ที่มาของข้อมูล: แถว u1 และ u2 คัดจากตารางที่ 5.3 (เฉพาะ i1–i6 ซึ่งครอบคลุมทุกคะแนนของทั้งสองคน) • $\bar{r}_{u1}$ = 16/5 = 3.2 และ $\bar{r}_{u2}$ = (2+5+4+5)/4 = 16/4 = 4.0 ตรงกับคอลัมน์ค่าเฉลี่ยของตารางที่ 5.3 • ช่องสีเขียว i1, i4, i6 = $I_{u1} \cap I_{u2}$

ตัวอย่างการคำนวณ 5.2 : ขั้นที่ 1–2 ลบค่าเฉลี่ย แล้วทำตารางคำนวณ

$$\text{sim}(u,v) = \frac{\sum_{i \in I_{uv}} (r_{ui} - \bar{r}_u)(r_{vi} - \bar{r}_v)}{\sqrt{\sum_{i \in I_{uv}} (r_{ui} - \bar{r}_u)^2} \sqrt{\sum_{i \in I_{uv}} (r_{vi} - \bar{r}_v)^2}}$$

รายการร่วม	คะแนน u1	u1 − 3.2	คะแนน u2	u2 − 4.0	ผลคูณ	(u1 − 3.2)²	(u2 − 4.0)²
i1	5	1.8	2	−2	−3.6	3.24	4
i4	1	−2.2	5	1	−2.2	4.84	1
i6	1	−2.2	5	1	−2.2	4.84	1
รวม					−8.0	12.92	6

1 ขั้นที่ 1

- รายการร่วม: i1, i4, i6
- u1 = (5, 1, 1)
- u2 = (2, 5, 5)

2 ขั้นที่ 2

- u1 − 3.2 = (1.8, −2.2, −2.2)
- u2 − 4.0 = (−2, 1, 1)

ทริก

- คอลัมน์ **ผลคูณ** → ตัวเศษ
- คอลัมน์ **กำลังสอง** → ตัวส่วน

ที่มาของข้อมูล: คอลัมน์คะแนน u1 และ u2 มาจากแถว u1, u2 ของตารางที่ 5.3 เฉพาะรายการร่วม i1, i4, i6 • หักค่าเฉลี่ย 3.2 และ 4.0 (คอลัมน์ค่าเฉลี่ยตารางที่ 5.3) • ผลคูณ เช่น i1: 1.8 × (−2) = −3.6 • กำลังสอง เช่น $1.8^2 = 3.24$ • แถวรวม: −8.0, 12.92, 6

ตัวอย่างการคำนวณ 5.2 : ขั้นที่ 3–5 แทนค่าในสมการ (5.1)

รายการร่วม	คะแนน u1	u1 − 3.2	คะแนน u2	u2 − 4.0	ผลคูณ	(u1 − 3.2)²	(u2 − 4.0)²
i1	5	1.8	2	−2	−3.6	3.24	4
i4	1	−2.2	5	1	−2.2	4.84	1
i6	1	−2.2	5	1	−2.2	4.84	1
รวม					−8.0	12.92	6

3 ตัวเศษ = ผลรวมของผลคูณส่วนเบี่ยงเบน

$$1.8(-2) + (-2.2)(1) + (-2.2)(1) = -3.6 - 2.2 - 2.2 = -8.0$$

4 ตัวส่วน = รากที่สองของผลรวมกำลังสอง คูณกัน

$$\sqrt{3.24 + 4.84 + 4.84} \times \sqrt{4 + 1 + 1} = \sqrt{12.92} \times \sqrt{6} = 3.5944 \times 2.4495 = 8.8045$$

5 หารตัวเศษด้วยตัวส่วน

$$\text{sim}(u_1, u_2) = \frac{-8.0}{8.8045} = -0.9086$$

ที่มาของข้อมูล: ตัวเศษ −8.0 และผลรวมกำลังสอง 12.92, 6 มาจากแถว "รวม" ของตารางคำนวณ (ขั้นที่ 1–2) • √12.92 = 3.5944 • √6 = 2.4495 • ผลลัพธ์ −0.9086 คือแถว u2 คอลัมน์ Pearson ของตารางที่ 5.6

$$\text{sim}(u,v) = \frac{\sum_{i \in I_{uv}} (r_{ui} - \bar{r}_u)(r_{vi} - \bar{r}_v)}{\sqrt{\sum_{i \in I_{uv}} (r_{ui} - \bar{r}_u)^2} \sqrt{\sum_{i \in I_{uv}} (r_{vi} - \bar{r}_v)^2}}$$

ตัวอย่างการคำนวณ 5.2 : แปลผล

sim(u1, u2)

−0.9086

เห็นต่างกันเกือบสมบูรณ์

- u1 ชอบแอนิเมชัน i1 และไม่ชอบภาพยนตร์รักสองเรื่อง (i4, i6)
- u2 ตรงกันข้ามทุกเรื่อง

ใช้ผลนี้อย่างไร

- ค่าลบบอกว่า u2 เป็น **"เพื่อนบ้านกลับด้าน"**
- บทนี้ **ไม่นำเพื่อนบ้านความคล้ายเชิงลบมาใช้ทำนาย** เพราะการกลับทิศคะแนนไม่เสถียรเมื่อหลักฐานน้อย
- สังเกต: Pearson ใช้หลักฐาน 3 รายการ → เชื่อถือได้มากกว่าคู่ที่มีรายการร่วม 1 เรื่อง

ที่มาของข้อมูล: ค่า −0.9086 มาจากตัวอย่าง 5.2 ขั้นที่ 5 (−8.0 / 8.8045) • ทิศทางของความชอบอ่านจากส่วนเบี่ยงเบน: u1 (+1.8, −2.2, −2.2) กับ u2 (−2, +1, +1) บน i1, i4, i6 ตรงข้ามกันทุกเรื่อง • หลักฐาน 3 รายการ = |I_u1u2| จากตัวอย่าง 5.1

ฝึกคำนวณเพิ่ม: เพียร์สันระหว่าง u1 กับ u5 (ค่าในตารางที่ 5.6)

1 รายการร่วม i3, i6 • $\bar{r}_{u1} = 3.2$ • $\bar{r}_{u5} = (4+3+5+2)/4 = 3.5$

$$u_1 : (4 - 3.2,\ 1 - 3.2) = (0.8,\ -2.2) \qquad u_5 : (4 - 3.5,\ 3 - 3.5) = (0.5,\ -0.5)$$

2 ตัวเศษและตัวส่วน

$$\text{num} = 0.8(0.5) + (-2.2)(-0.5) = 0.4 + 1.1 = 1.5$$

$$\text{den} = \sqrt{0.64 + 4.84}\,\sqrt{0.25 + 0.25} = 2.3409 \times 0.7071 = 1.6553$$

3 ผลลัพธ์ — ทิศทางเดียวกันทั้งสองเรื่อง (ชอบ i3 • ไม่ค่อยชอบ i6)

$$\text{sim}(u_1, u_5) = \frac{1.5}{1.6553} = 0.9062$$

ที่มาของข้อมูล: แถว u5 ในตารางที่ 5.3: i3 = 4, i6 = 3, i9 = 5, i10 = 2 ⟶ $\bar{r}_{u5}$ = 14/4 = 3.5 • รายการร่วมกับ u1 = {i3, i6} • u1: (4 − 3.2, 1 − 3.2) = (0.8, −2.2) • u5: (0.5, −0.5) • ผลลัพธ์ 0.9062 = แถว u5 ของตารางที่ 5.6

ทำไมรายการร่วมเพียง 1 เรื่องจึงได้ ±1 เสมอ: ตัวอย่าง u1 กับ u4

1 รายการร่วมมีเพียง i1 • u1: 5 − 3.2 = 1.8 • u4: 4 − 3.75 = 0.25

$$\text{sim}(u_1, u_4) = \frac{1.8 \times 0.25}{\sqrt{1.8^2}\,\sqrt{0.25^2}} = \frac{0.45}{1.8 \times 0.25} = \frac{0.45}{0.45} = 1.0$$

2 ข้อสรุปทั่วไป

$$\frac{a\,b}{|a|\,|b|} = \text{sign}(a) \cdot \text{sign}(b) \in \{-1, +1\}$$

เมื่อมีจุดเดียว ตัวเศษกับตัวส่วนมีค่าสัมบูรณ์เท่ากัน **เหลือเพียงเครื่องหมาย** → u4, u6 ได้ +1 • u7 ได้ −1 จากหลักฐานคะแนนเดียว

ที่มาของข้อมูล: u1 กับ u4 ร่วมกันที่ i1 เพียงเรื่องเดียว (ตารางที่ 5.3: u1 = 5, u4 = 4) • $\bar{r}u4$ = (4+1+5+5)/4 = 3.75 ⟶ ส่วนเบี่ยงเบน 1.8 และ 0.25 • u6 ร่วมที่ i2 (5 − 4.0 = 1 > 0) ได้ +1 • u7 ร่วมที่ i3 (3 − 3.5 = −0.5 < 0) ได้ −1

5.4.2 มาตรวัดอื่น: โคไซน์ (Cosine) และ Jaccard

$$\cos(u,v) = \frac{\mathbf{r}_u \cdot \mathbf{r}_v}{\|\mathbf{r}_u\|\,\|\mathbf{r}_v\|} \qquad J(u,v) = \frac{|I_u \cap I_v|}{|I_u \cup I_v|}$$

สมการ (5.2)

สองมาตรวัดที่ใช้บ่อย ทั้งคู่ **ไม่ลบค่าเฉลี่ย**

โดยที่

- Cosine มองแถวผู้ใช้เป็นเวกเตอร์ 12 มิติ ช่องว่าง = 0 แล้ววัดมุม
- Jaccard ดูเพียงว่า "ให้คะแนนรายการเดียวกันหรือไม่" ไม่สนใจค่าคะแนน
- $\|r_u\|$ = รากที่สองของผลรวมกำลังสองของคะแนนทุกช่อง

ข้อสังเกต

- Cosine บนคะแนนดิบเป็นบวกทุกคู่ เพราะคะแนนทุกค่าเป็นบวก
- Jaccard ให้ค่าสูงกับคู่ที่ **ดูเรื่องเดียวกัน** แม้รสนิยมตรงข้าม

ที่มาของข้อมูล: ค่าที่แทนในสมการ (5.2) มาจากตารางที่ 5.3 ทั้งแถว: Cosine ใช้คะแนนดิบทุกช่องโดยให้ช่องว่าง = 0 • Jaccard ใช้เพียงเซตของรายการที่มีคะแนน |I_u ∩ I_v| / |I_u ∪ I_v| • ใช้จริงในสไลด์ฝึก u1–u2 และคอลัมน์ Cosine / Jaccard ของตารางที่ 5.6

ฝึกคำนวณเพิ่ม: Cosine และ Jaccard ระหว่าง u1 กับ u2

1 ผลคูณจุด — คิดเฉพาะช่องที่ทั้งคู่มีคะแนน (i1, i4, i6) เพราะช่องว่าง = 0

$$\mathbf{r}_{u1} \cdot \mathbf{r}_{u2} = 5(2) + 1(5) + 1(5) = 10 + 5 + 5 = 20$$

2 ขนาดของเวกเตอร์ (ใช้ทุกคะแนนของแต่ละคน)

$$\|\mathbf{r}_{u1}\| = \sqrt{25 + 25 + 16 + 1 + 1} = \sqrt{68} = 8.2462 \qquad \|\mathbf{r}_{u2}\| = \sqrt{4 + 25 + 16 + 25} = \sqrt{70} = 8.3666$$

3 Cosine และ Jaccard

$$\cos(u_1, u_2) = \frac{20}{8.2462 \times 8.3666} = 0.2899 \qquad J(u_1, u_2) = \frac{|\{i1, i4, i6\}|}{|I_{u1} \cup I_{u2}|} = \frac{3}{5 + 4 - 3} = 0.5$$

ที่มาของข้อมูล: แถว u1 = (5, 5, 4, 1, •, 1, ...) และ u2 = (2, •, •, 5, 4, 5, ...) จากตารางที่ 5.3 • ผลคูณจุดคิดที่ i1, i4, i6: 5•2 + 1•5 + 1•5 = 20 • $\|u1\|$ = √68 = 8.2462 • $\|u2\|$ = √(4+25+16+25) = √70 = 8.3666 • Jaccard = 3/(5+4−3) = 0.5

ตารางที่ 5.6 ความคล้ายระหว่าง u1 กับผู้ใช้อื่นด้วยสามมาตรวัด

ผู้ใช้	รายการร่วม	Pearson	Cosine	Jaccard
u2	3	−0.9086	0.2899	0.5000
u3	0	—	0.0000	0.0000
u4	1	1.0000	0.2963	0.1250
u5	2	0.9062	0.3135	0.2857
u6	1	1.0000	0.4287	0.1429
u7	1	−1.0000	0.1980	0.1250
u8	3	−0.9063	0.3135	0.5000

Pearson

- u4, u6, u7 ได้ ±1 จาก **หลักฐานคะแนนเดียว**
- ถ้าไม่ปรับ ระบบจะเชื่อ u4, u6 มากกว่า u5

Cosine

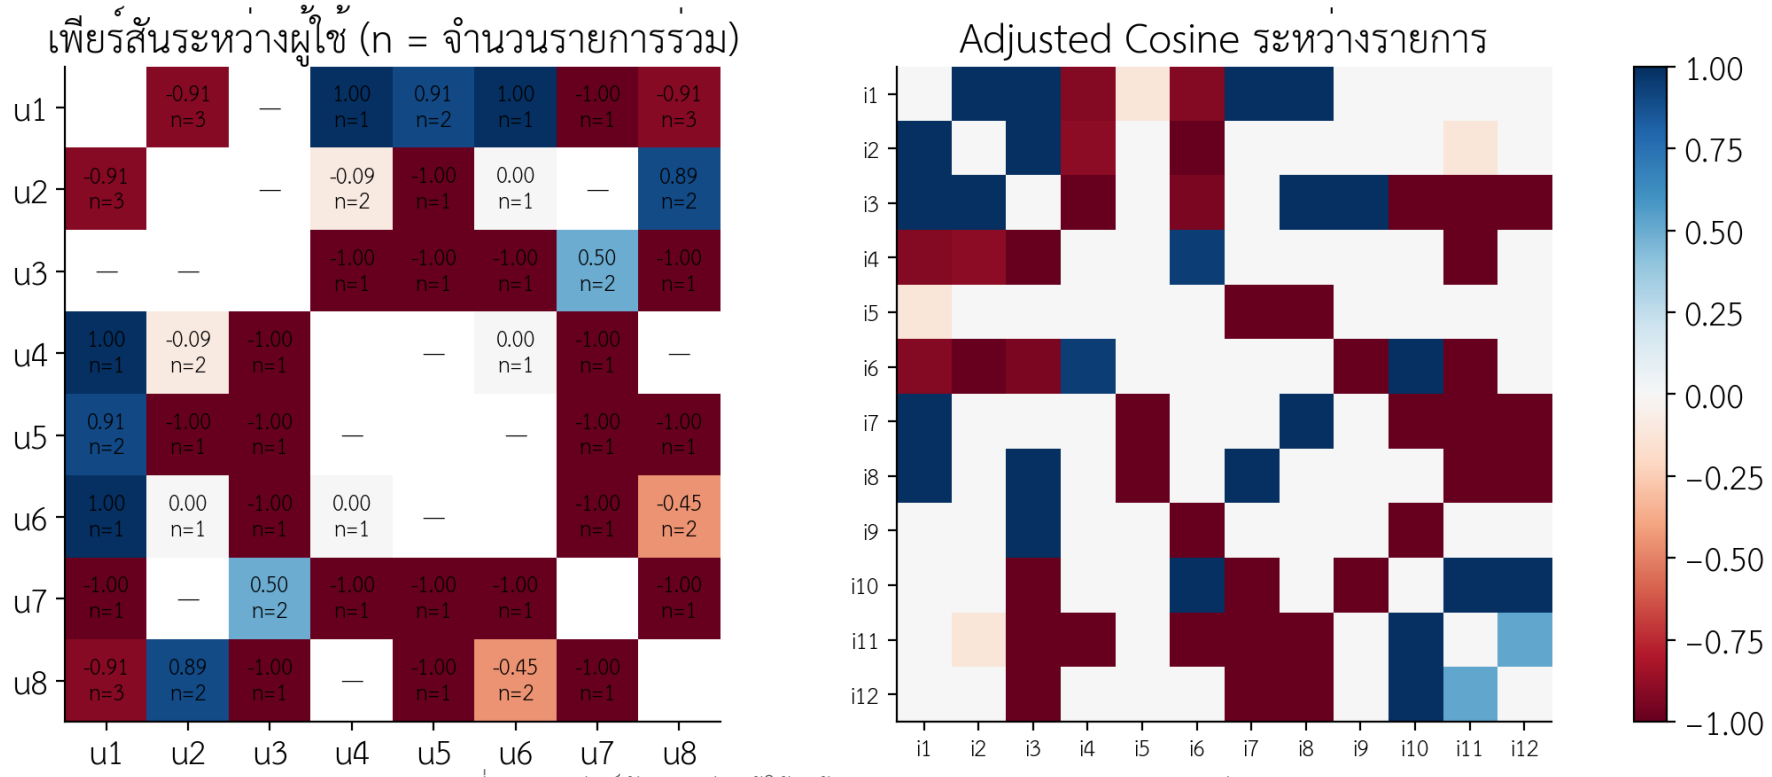
- บวกทุกคู่ เพราะคะแนนเป็นบวก

Jaccard

- u2, u8 สูงที่สุด ทั้งที่ **รสนิยมตรงข้าม** กับ u1

ที่มาของข้อมูล: ทุกแถวเทียบแถว u1 กับแถวของผู้ใช้อื่นในตารางที่ 5.3 • รายการร่วม = $|I_{u1} \cap I_v|$ • Pearson ใช้สมการ (5.1) เช่น u5 = 1.5/1.6553 = 0.9062 • Cosine ใช้สมการ (5.2) เช่น u6 = 25/(8.2462 × 7.0711) = 0.4287 • Jaccard เช่น u5 = 2/7 = 0.2857

ภาพที่ 5.4 ความคล้ายของทุกคู่



ภาพที่ 5.4 เพียร์สันระหว่างผู้ใช้ (ซ้าย) และ Adjusted Cosine ระหว่างรายการ (ขวา)

ช่องขีด = คู่ที่ไม่มีรายการร่วมเลย (**6 จาก 28 คู่**) • ค่าเกือบทั้งหมดอยู่ที่ขอบ ±1 ซึ่งเป็น **อาการของหลักฐานน้อย** ไม่ใช่รสนิยมที่ตรงกันหรือตรงข้ามกันจริง

อธิบายแบบเข้าใจง่าย: อย่าเชื่อรีวิวห้าดาวเพียงรีวิวเดียว



อธิบายแบบเข้าใจง่าย

- ร้าน A ได้ **5 ดาวจาก 1 รีวิว** และ ร้าน B ได้ **4.6 ดาวจาก 800 รีวิว**
- เรามักเชื่อร้าน B มากกว่า เพราะ **หลักฐานมากกว่า**
- การถ่วงนัยสำคัญและการหดทำแบบเดียวกันกับความคล้าย: ถ้าผู้ใช้สองคนดูเรื่องเดียวกันเพียงเรื่องเดียว ความคล้าย +1 อาจเป็นเพียงความบังเอิญ จึงถูก **ลดลงให้เข้าใกล้ศูนย์**

5.4.3 การถ่วงนัยสำคัญ (Significance Weighting) และการหด (Shrinkage)

$$\mathrm{sim}_{\beta}(u,v) = \frac{\min(n_{uv},\beta)}{\beta}\,\mathrm{sim}(u,v)$$

$$\mathrm{sim}_{\lambda}(u,v) = \frac{n_{uv}}{n_{uv}+\lambda}\,\mathrm{sim}(u,v)$$

สมการ (5.3)

คูณความคล้ายด้วย "ตัวคูณความน่าเชื่อถือ" ตามจำนวนหลักฐาน

โดยที่

- $n_{uv} = |I_{uv}|$ จำนวนรายการร่วม
- Herlocker [9]: $\min(n, \beta)/\beta$ · ระบบจริงใช้ $\beta = 50$
- Koren [5]: $n/(n + \lambda)$
- MovieMini-12 มีรายการร่วมสูงสุด 3 เรื่อง → บทนี้ใช้ $\beta = 3$ และ $\lambda = 2$

รูปร่างของตัวคูณ

- ถ่วงนัยสำคัญ: ลดเชิงเส้น แล้วคงที่ที่ 1 เมื่อ $n \geq \beta$
- การหด: ค่อย ๆ เข้าใกล้ 1 แต่ไม่ถึง

ที่มาของข้อมูล: ค่า n_uv ที่แทนในสมการ (5.3) คือคอลัมน์ "รายการร่วม" ของตารางที่ 5.6 (นับจากตารางที่ 5.3) · $\beta = 3$ เพราะรายการร่วมสูงสุดใน MovieMini-12 คือ 3 (u1–u2, u1–u8) · $\lambda = 2$ เป็นค่าที่บทเลือก · ค่าที่คูณคือคอลัมน์ Pearson ของตารางที่ 5.6

ตารางที่ 5.7 คำนวณความคล้ายก่อนและหลังถ่วง (เพื่อนบ้านเชิงบวกของ u1)

คู่	n	Pearson	ถ่วงนัยสำคัญ (β = 3)	Shrinkage (λ = 2)
u1–u4	1	1.0000	(1/3)(1.0000) = 0.3333	(1/3)(1.0000) = 0.3333
u1–u5	2	0.9062	(2/3)(0.9062) = **0.6041**	(2/4)(0.9062) = **0.4531**
u1–u6	1	1.0000	(1/3)(1.0000) = 0.3333	(1/3)(1.0000) = 0.3333

1 ตัวอย่างแทนค่า u1–u5

$$\beta: \frac{\min(2,3)}{3} \times 0.9062 = 0.6667 \times 0.9062 = 0.6041$$

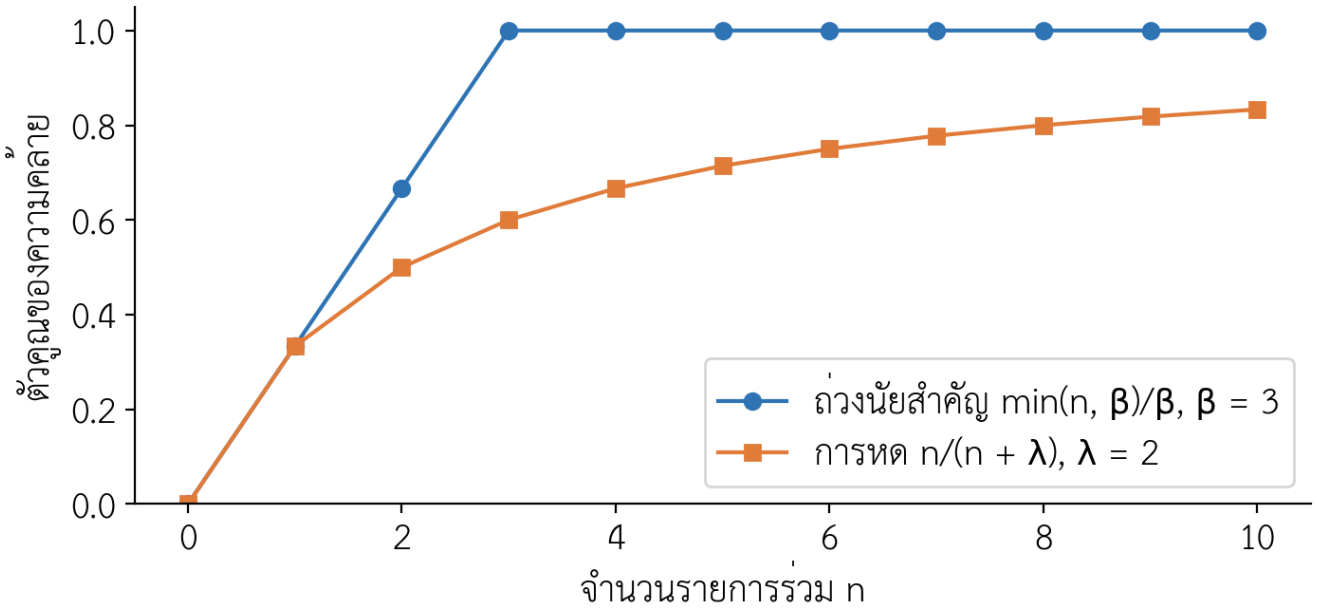
$$\lambda: \frac{2}{2+2} \times 0.9062 = 0.5 \times 0.9062 = 0.4531$$

ผลลัพธ์

- หลังถ่วง **u5 กลายเป็นเพื่อนบ้านที่ใกล้ที่สุด** ของ u1
- u4, u6 (หลักฐาน 1 เรื่อง) เหลือ **1/3** ของค่าเดิมทั้งสองวิธี

ที่มาของข้อมูล: n และ Pearson มาจากตารางที่ 5.6 (u4: n = 1, 1.0 • u5: n = 2, 0.9062 • u6: n = 1, 1.0) • ตัวคูณถ่วง = min(n, 3)/3 • ตัวคูณหด = n/(n + 2) ⟶ u5: (2/3)(0.9062) = 0.6041 และ (2/4)(0.9062) = 0.4531

ภาพที่ 5.5 ตัวคูณของการถ่วงนัยสำคัญและการหด



ภาพที่ 5.5 ตัวคูณของการถ่วงนัยสำคัญและการหดตามจำนวนรายการร่วม

ข้อสังเกตสำคัญ

- การถ่วงจะเปลี่ยนค่าทำนาย **ก็ต่อเมื่อ** เพื่อนบ้านที่ใช้ทำนายรายการเดียวกันมีจำนวนหลักฐาน **ต่างกัน**
- ถ้าเพื่อนบ้านทุกคนมี n เท่ากัน (หรือมีคนเดียว) ตัวคูณจะ **หักล้างกัน** ในเศษและส่วนของสมการทำนาย (5.4)

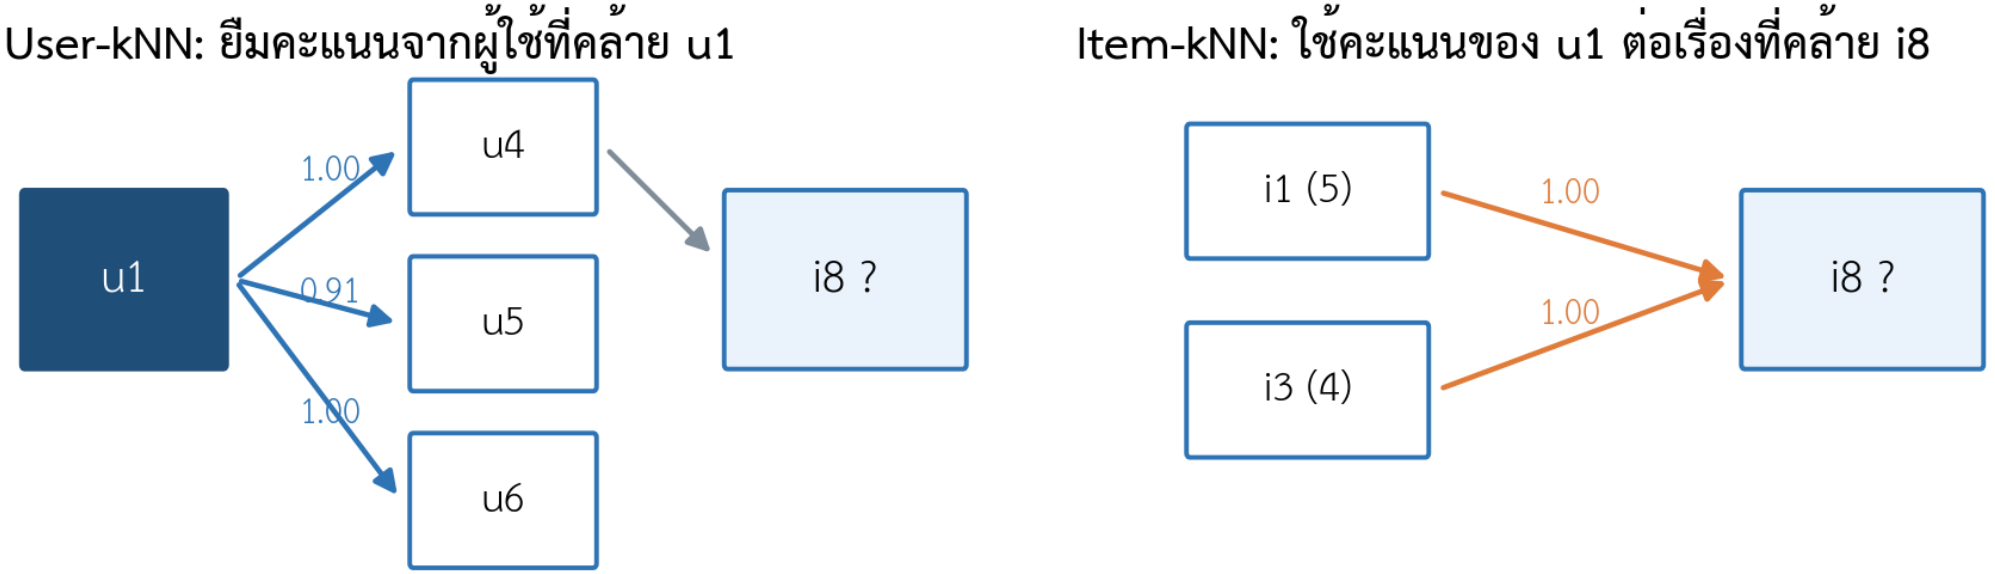
5.5

การกรองร่วมอิงผู้ใช้ (User-kNN)



ยืม "ส่วนเบี่ยงเบน" จากเพื่อนบ้านที่คล้ายกัน

User-kNN ยืมคะแนนจากเพื่อนบ้าน



ภาพที่ 5.6 User-kNN ยืมคะแนนจากผู้ใช้ที่คล้ายกัน ส่วน Item-kNN ใช้คะแนนของผู้ใช้เองต่อเรื่องที่คล้ายกัน

ถ้าเพื่อนบ้านที่เห็นพ้องกับ u1 ให้เรื่องหนึ่ง **สูงกว่าค่าเฉลี่ยของตนเอง** ก็คาดว่า u1 จะให้เรื่องนั้นสูงกว่าค่าเฉลี่ยของ u1 เช่นกัน ดังนั้นด้วยแนวคิดนี้คือ การยืม **ส่วนเบี่ยงเบน** ไม่ใช่คะแนนดิบ

อธิบายแบบเข้าใจง่าย: ยืม "ความตื่นเต้น" ของเพื่อน ไม่ใช่ยืมตัวเลข



อธิบายแบบเข้าใจง่าย

- เพื่อนที่ปกติให้ **3 ดาว** กับทุกเรื่อง ให้เรื่องหนึ่ง **5 ดาว** → ตื่นเต้นมากกว่าปกติ **+2 ดาว**
- เราจึงคาดว่าเราจะตื่นเต้นมากกว่าปกติของเราประมาณ +2 ดาวเช่นกัน
- ถ้าปกติเราให้ 3.2 ดาว ค่าทำนาย ≈ 3.2 + 2 = 5.2 → **ตัดให้ไม่เกิน 5**
- สมการ User-kNN = ทำแบบนี้กับเพื่อนหลายคน แล้ว **เฉลี่ยถ่วงตามความคล้าย**

สมการทำนายของ User-kNN

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in N_k(u;i)} \text{sim}(u,v)\,(r_{vi} - \bar{r}_v)}{\sum_{v \in N_k(u;i)} |\text{sim}(u,v)|}$$

สมการ (5.4)

ค่าเฉลี่ยของ u + ค่าเฉลี่ยถ่วงของส่วนเบี่ยงเบนของเพื่อนบ้าน

โดยที่

- $N_k(u; i)$ = เพื่อนบ้าน $\leq$ k คน ที่ **ให้คะแนน i แล้ว** และคล้ายเชิงบวกสูงสุด
- $r_{vi} - \bar{r}_v$ = ส่วนเบี่ยงเบนของเพื่อนบ้าน v ต่อ i
- บทนี้ใช้ k = 3 และตัดค่าทำนายให้อยู่ในช่วง 1–5

กติกาของบทนี้

- ตัดเพื่อนบ้านความคล้าย **เชิงลบ** ออก
- ไม่มีเพื่อนบ้านเชิงบวก → คืน $\bar{r}_u$ (= "ไม่มีหลักฐาน")

ที่มาของข้อมูล: ค่าที่แทนในสมการ (5.4): $\bar{r}_u$, $\bar{r}_v$ = คอลัมน์ค่าเฉลี่ยของตารางที่ 5.3 • r_vi = คะแนนในคอลัมน์ i ของตารางที่ 5.3 • sim(u, v) = คอลัมน์ Pearson ของตารางที่ 5.6 • k = 3 และตัดเพื่อนบ้านความคล้ายลบออก • ใช้จริงในตัวอย่าง 5.3, 5.6 และตารางที่ 5.8

ตัวอย่างการคำนวณ 5.3 ทำนาย u1 ต่อ i8 Furiosa และ i5 Wicked : ข้อมูล

โจทย์ ใช้ความคล้ายในตารางที่ 5.6 และสมการ (5.4) กับ $k = 3$ จงทำนาย $\hat{r}_{u1,i8}$ และ $\hat{r}_{u1,i5}$

ผู้ใช้ v	sim(u1, v)	คะแนน i5	คะแนน i8	ค่าเฉลี่ย v	ใช้ได้ไหม
u2	−0.9086	4	·	4.00	✗ ความคล้ายลบ
u4	1.0000	1	5	3.75	✓
u6	1.0000	4	·	4.00	✓
u7	−1.0000	·	2	3.50	✗ ความคล้ายลบ

$\bar{r}_{u1} = 3.2$ · ผู้ให้คะแนน i8 คือ u4, u7 · ผู้ให้คะแนน i5 คือ u2, u4, u6

ที่มาของข้อมูล: sim(u1, v) จากคอลัมน์ Pearson ตารางที่ 5.6 · คะแนน i5, i8 จากคอลัมน์ i5 (u2 4, u4 1, u6 4) และ i8 (u4 5, u7 2) ของตารางที่ 5.3 · ค่าเฉลี่ย v จากคอลัมน์ค่าเฉลี่ยตารางที่ 5.3 เช่น u4 = 15/4 = 3.75, u6 = 12/3 = 4.0 · u2, u7 ถูกตัดเพราะ sim < 0

ตัวอย่างการคำนวณ 5.3 : ทำนาย u1 ต่อ i5 Wicked และ i8 Furiosa

ผู้ใช้ v	sim(u1, v)	คะแนน i5	คะแนน i8	ค่าเฉลี่ย v
u4	1.0000	1	5	3.75
u6	1.0000	4	•	4.00

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{v \in N_k(u;i)} \text{sim}(u,v)\,(r_{vi} - \bar{r}_v)}{\sum_{v \in N_k(u;i)} |\text{sim}(u,v)|}$$

i5 Wicked

1. เลือกเพื่อนบ้าน: u4 และ u6

ส่วนเบี่ยงเบนของเพื่อนบ้าน

$$u_4 : 1 - 3.75 = -2.75 \qquad u_6 : 4 - 4.0 = 0$$

2. แทนค่าสมการ (5.4)

$$\hat{r}_{u1,i5} = 3.2 + \frac{1.0(-2.75) + 1.0(0)}{1.0 + 1.0} = 3.2 - 1.375 = 1.825$$

i8 Furiosa

1. เลือกเพื่อนบ้าน: เหลือ u4 คนเดียว

ส่วนเบี่ยงเบนของ u4 ต่อ i8 = 5 - 3.75 = 1.25

2. แทนค่าสมการ (5.4)

$$\hat{r}_{u1,i8} = 3.2 + \frac{1.0 \times 1.25}{1.0} = 3.2 + 1.25 = 4.45$$

i5 ต่ำ

- u4 ไม่ชอบ Wicked
- u6 ให้เท่ากับ ค่าเฉลี่ยของตนพอดี

i8 สูง

- u4 ชอบ Toy Story 5 เหมือน u1 และชอบ Furiosa มาก

ที่มาของข้อมูล: เพื่อนบ้าน u4, u6 และ sim = 1.0 มาจากตารางที่ 5.6 • คะแนน u4: i5 = 1, i8 = 5 • u6: i5 = 4 (ตารางที่ 5.3) • $\bar{r}_{u4}$ = 3.75, $\bar{r}_{u6}$ = 4.0, $\bar{r}_{u1}$ = 3.2 • ผลลัพธ์ 1.825 และ 4.45 = แถว i5, i8 ของตารางที่ 5.8

ฝึกคำนวณเพิ่ม: ค่าทำนาย User-kNN ของรายการผู้สมัครที่เหลือ

รายการ	เพื่อนบ้าน (sim, คะแนน, $\bar{r}_v$)	การคำนวณ	$\hat{r}_{u1,i}$
i9 Conclave	u5 (0.9062, 5, 3.5)	3.2 + 0.9062(1.5)/0.9062	4.70
i7 Ballerina	u4 (1.0, 5, 3.75)	3.2 + 1.0(1.25)/1.0	4.45
i12 Project Hail Mary	u3 (ไม่มีรายการร่วม), u7 (−1.0)	ไม่มีเพื่อนบ้านเชิงบวก → $\bar{r}_{u1}$	3.20
i11 Mickey 17	u6 (1.0, 3, 4.0)	3.2 + 1.0(−1.0)/1.0	2.20
i10 Dune: Part Two	u5 (0.9062, 2, 3.5)	3.2 + 0.9062(−1.5)/0.9062	1.70

ทริกคำนวณเร็ว

- มีเพื่อนบ้านคนเดียว → sim ตัดกันเอง ค่าทำนาย = $\bar{r}_{u1} + (r_{vi} - \bar{r}_v)$
- u7 ให้ i11 = 4 และ i12 = 5 แต่ถูกตัดเพราะ sim(u1, u7) = −1

ที่มาของข้อมูล: ผู้ให้คะแนนแต่ละรายการอ่านจากคอลัมน์ในตารางที่ 5.3 • sim จากตารางที่ 5.6 • เช่น i9: มีเพียง u5 ให้ 5 → 3.2 + 0.9062(5 − 3.5)/0.9062 = 4.70 • i12: ผู้ให้คะแนน u3 (ไม่มีรายการร่วมกับ u1) และ u7 (sim −1) → ไม่มีเพื่อนบ้าน → $\bar{r}_{u1}$ = 3.20

ตารางที่ 5.8 ค่าทำนายแบบ User-kNN ของ u1 (เรียงจากมากไปน้อย)

รหัส	ชื่อเรื่อง	เพื่อนบ้านที่ใช้ (ความคล้าย)	ค่าทำนาย
i9	Conclave	u5 (0.9062)	4.7000
i7	Ballerina	u4 (1.0000)	4.4500
i8	Furiosa: A Mad Max Saga	u4 (1.0000)	4.4500
i12	Project Hail Mary	—	3.2000
i11	Mickey 17	u6 (1.0000)	2.2000
i5	Wicked	u6 (1.0000), u4 (1.0000)	1.8250
i10	Dune: Part Two	u5 (0.9062)	1.7000

Top-3

- i9 Conclave • i7 Ballerina • i8 Furiosa
- แนะนำดราม่าการเมืองให้ผู้ชอบแอนิเมชัน — ระบบบทที่ 3–4 ทำไม่ได้

i12 = 3.2 (ไม่มีหลักฐาน)

- ค่าทำนาย = ค่าเฉลี่ยของผู้ใช้ → ทำให้เกิด **คะแนนเสมอ** เมื่อจัดอันดับ

ที่มาของข้อมูล: ทุกแถวใช้สมการ (5.4) แบบเดียวกับตัวอย่าง 5.3 • ผู้ให้คะแนนจากคอลัมน์ของตารางที่ 5.3 และความคล้ายจากตารางที่ 5.6 • i8, i5 มาจากตัวอย่าง 5.3 • i9, i7, i12, i11, i10 มาจากสไลด์ฝึกคำนวณก่อนหน้า • i7 กับ i8 เสมอกันที่ 4.45

User-kNN สำหรับข้อมูลโดยปริยาย (ชอบ / ไม่ได้ชอบ)

$$\mathrm{sim}(u,v) = \frac{|L_u \cap L_v|}{\sqrt{|L_u|}\sqrt{|L_v|}} \qquad s(u,i) = \sum_{v \in N_k(u),\ i \in L_v} \mathrm{sim}(u,v)$$

สมการ (5.5)

โคไซน์บนเวกเตอร์ 0/1 แล้วรวมความคล้ายของเพื่อนบ้านที่ชอบ i

โดยที่

- L_u = เซตรายการที่ u ชอบ (คะแนน 4–5)
- ค่าเฉลี่ยของผู้ใช้ **ไม่มีความหมาย** เมื่อข้อมูลเป็น 0/1
- s(u, i) = คะแนนสำหรับจัดอันดับ ไม่ใช่คะแนน 1–5

ข้อสังเกต

- นิยมในระบบจริง เพราะข้อมูลส่วนใหญ่เป็นแบบโดยปริยาย
- หารด้วยรากที่สองของ |L| → ให้น้ำหนักผู้ใช้ที่ชอบน้อยแต่ตรงกัน

ที่มาของข้อมูล: L_u ในสมการ (5.5) = เซตรายการที่ u ให้คะแนน 4–5 ในตารางที่ 5.3 (ข้อตกลง "ชอบ") • ความคล้าย = |L_u ∩ L_v| / √(|L_u| |L_v|) • คะแนน s(u, i) = ผลรวมความคล้ายของผู้ที่ชอบ i • ใช้จริงในตัวอย่าง 5.4

ตัวอย่างการคำนวณ 5.4 User-kNN แบบโดยปริยายสำหรับ u1

ขั้นที่ 1–2 u1 ชอบ {i1, i2, i3} (3 เรื่อง) → หาผู้ที่ชอบเรื่องร่วมกับ u1

ผู้ใช้	ชอบ L_v	$\lvert L_{u1} \cap L_v \rvert$	sim
u4	i1, i7, i8	1 (i1)	$1/(\sqrt{3}\sqrt{3}) = 0.3333$
u5	i3, i9	1 (i3)	$1/(\sqrt{3}\sqrt{2}) = 0.4082$
u6	i2, i5	1 (i2)	$1/(\sqrt{3}\sqrt{2}) = 0.4082$
อื่น ๆ	—	0	0

3 **ขั้นที่ 3 คะแนน = ผลรวม sim ของผู้ที่ชอบรายการ**

i5: u6 → 0.4082 • i9: u5 → 0.4082

i7: u4 → 0.3333 • i8: u4 → 0.3333

i10, i11, i12 → 0 (ไม่มีเพื่อนบ้านที่ชอบ)

แปลผล

i5 ซึ่งแบบ Explicit ได้คะแนนต่ำ กลับขึ้นอันดับต้น เพราะข้อมูล 0/1 **ไม่เห็นว่า u4 ไม่ชอบ Wicked**

ที่มาของข้อมูล: เซตที่ชอบ (คะแนน 4–5) จากตารางที่ 5.3: u1 {i1, i2, i3} • u4 {i1, i7, i8} • u5 {i3, i9} • u6 {i2, i5} • sim = |∩| / √(|L_u1||L_v|): u4 = 1/√9 = 0.3333, u5 = 1/√6 = 0.4082, u6 = 1/√6 = 0.4082 • คะแนนรายการ = ผลรวม sim ของผู้ที่ชอบรายการนั้น

5.6

การกรองร่วมอิงรายการ (Item-kNN)



Adjusted Cosine • "ลูกค้าที่ซื้อสินค้านี้ มักซื้อ..."

อธิบายแบบเข้าใจง่าย: Item-kNN คือ "ลูกค้าที่ซื้อสินค้านี้ มักซื้อ..."



อธิบายแบบเข้าใจง่าย

- User-kNN ถามว่า **"คนที่คล้ายคุณให้คะแนนเรื่องนี้อย่างไร"**
- Item-kNN ถามว่า **"คุณให้คะแนนเรื่องที่คล้ายเรื่องนี้อย่างไร"**
- สองรายการถือว่าคล้ายกันเมื่อ **คนกลุ่มเดียวกันชอบทั้งคู่** ไม่ใช่เพราะหน้าตาหรือเนื้อหาคล้ายกัน
- จะทำนายว่า u1 ชอบ Furiosa ไหม → ดูว่า u1 ให้คะแนนเรื่องที่ "คนชอบคู่กับ Furiosa" ไว้อย่างไร

สมการ Adjusted Cosine และการทำนายของ Item-kNN

$$\text{sim}(i,j) = \frac{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_u)(r_{uj} - \bar{r}_u)}{\sqrt{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_u)^2} \sqrt{\sum_{u \in U_{ij}} (r_{uj} - \bar{r}_u)^2}}$$

$$\hat{r}_{ui} = \bar{r}_u + \frac{\sum_{j \in N_k(i;u)} sim(i,j)(r_{uj} - \bar{r}_u)}{\sum_{j \in N_k(i;u)} |sim(i,j)|}$$

สมการ (5.6)

ลบค่าเฉลี่ยของ **ผู้ใช้** แล้ววัดมุมระหว่างรายการ

โดยที่

- U_{ij} = ผู้ใช้ที่ให้คะแนนทั้ง i และ j
- $N_k(i; u)$ = รายการ $\leq$ k ที่ u เคยให้คะแนนและคล้าย i เชิงบวกที่สุด

ข้อสังเกต

- ทำนาย = ค่าเฉลี่ยถ่วงของ **คะแนนดิบของผู้ใช้เอง** → อยู่ในช่วง 1–5 เสมอ

ที่มาของข้อมูล: ค่าที่แทนในสมการ (5.6): r_ui – r̄u ใช้คะแนนในตารางที่ 5.3 ลบค่าเฉลี่ยของ "ผู้ใช้" (คอลัมน์ค่าเฉลี่ย) • U_ij = ผู้ใช้ที่มีคะแนนทั้งคอลัมน์ i และ j • ค่าทำนายใช้คะแนนของ u1 เองต่อรายการที่คล้าย • ใช้จริงในตัวอย่าง 5.5 และตารางที่ 5.9

ตัวอย่างการคำนวณ 5.5 Adjusted Cosine และค่าทำนายของ u1 ต่อ i8 : ข้อมูล

โจทย์ หาความคล้ายระหว่าง i8 Furiosa กับรายการที่ u1 เคยให้คะแนน แล้วทำนาย $\hat{r}_{u1,i8}$ ด้วยสมการ (5.6)

ผู้ใช้	i1	i2	i3	i4	i6	i8	$\bar{r}_u$
u1	5	5	4	1	1	?	3.20
u4	4	·	·	·	·	5	3.75
u7	·	·	3	·	·	2	3.50

ขั้นที่ 1 หาผู้ใช้ร่วม

- ผู้ให้คะแนน i8: u4, u7
- i8–i1 ผ่าน u4
- i8–i3 ผ่าน u7
- i2, i4, i6 ไม่มีผู้ใช้ร่วมกับ i8 มีค่า sim = 0

$$\text{sim}(i,j) = \frac{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_u)(r_{uj} - \bar{r}_u)}{\sqrt{\sum_{u \in U_{ij}} (r_{ui} - \bar{r}_u)^2} \sqrt{\sum_{u \in U_{ij}} (r_{uj} - \bar{r}_u)^2}}$$

2 i8–i1 ผ่าน u4 ($\bar{r}_{u4}$ = 3.75) — มีจุดเดียว

$$-3.75,\ 4-3.75) = (1.25,\ 0.25) \Rightarrow sim(i8,i1) = \frac{(4-3.75)(5-3.75)}{\sqrt{(4-3.75)^2}\sqrt{(5-3.75)^2}} = 1.00$$

3 i8–i3 ผ่าน u7 ($\bar{r}_{u7}$ = 3.5) — ติดลบทั้งคู่ ผลคูณเป็นบวก

$$(2-3.5,\ 3-3.5) = (-1.5,\ -0.5) \Rightarrow sim(i8,i3) = \frac{(3-3.50)(2-3.50)}{\sqrt{(3-3.50)^2}\sqrt{(2-3.50)^2}} = 1.00$$

4 ทำนายจากคะแนนของ u1 ต่อ i1 (5) และ i3 (4)

$$\hat{r}_{u1,i8} = \bar{r}_{u1} + \frac{1(5-3.2)+1(4-3.2)}{1+1} = 3.2 + \frac{1.8+0.8}{2} = 4.50$$

เทียบกับ User-kNN

- User-kNN ได้ 4.45 · Item-kNN ได้ 4.5
- ทั้งสองวิธีเห็นว่า u1 น่าจะชอบ Furiosa

ที่มาของข้อมูล: คอลัมน์ i8 ของตารางที่ 5.3: u4 = 5, u7 = 2 · u4 ให้ i1 = 4 และ u7 ให้ i3 = 3 จึงเป็นผู้ใช้ร่วมของ i8–i1 และ i8–i3 · หักค่าเฉลี่ยผู้ใช้ $\bar{r}_{u4}$ = 3.75, $\bar{r}_{u7}$ = 3.5 · u1 ให้ i1 = 5, i3 = 4

⟶ (1×5 + 1×4)/2 = 4.5

ตัวอย่างการคำนวณ 5.5 : แปลผลและข้อควรระวัง

$\hat{r}(u1, i8)$ แบบ Item-kNN

4.5

เทียบกับ User-kNN

- User-kNN ได้ 4.45 • Item-kNN ได้ 4.5
- ทั้งสองวิธีเห็นว่า u1 น่าจะชอบ Furiosa



ข้อควรระวัง

- ความคล้าย i8–i3 มาจาก u7 ซึ่ง **"ไม่ค่อยชอบ" ทั้งสองเรื่อง**
- Adjusted Cosine วัดทิศทางเทียบกับค่าเฉลี่ยของ u7 จึงตีความว่า "เห็นพ้องกัน"
- ความคล้ายจากหลักฐานหนึ่งคะแนนอาจสะท้อน **"การไม่ชอบร่วมกัน"** มากกว่า "การชอบร่วมกัน"

ที่มาของข้อมูล: 4.5 มาจากตัวอย่าง 5.5 = (1.0×5 + 1.0×4)/2 โดย 5 และ 4 คือคะแนนที่ u1 ให้ i1 และ i3 (ตารางที่ 5.3) • 4.45 มาจากตัวอย่าง 5.3 (User-kNN) • ความคล้าย i8–i3 มาจาก u7 คนเดียว ซึ่งให้ทั้ง i3 (3) และ i8 (2) ต่ำกว่าค่าเฉลี่ย 3.5

ฝึกคำนวณเพิ่ม: Item-kNN ของ u1 ต่อ i7, i9, i10 และ i5

รายการ	ผู้ใช้ร่วมกับรายการของ u1	ส่วนเบี่ยงเบน	sim เชิงบวก	$\hat{r}_{u1,i}$
i7 Ballerina	i7–i1 ผ่าน u4	(5−3.75, 4−3.75) = (1.25, 0.25)	i1: 1.0	5(1.0)/1.0 = **5.0**
i9 Conclave	i9–i3, i9–i6 ผ่าน u5	i9: 1.5 · i3: 0.5 · i6: −0.5	i3: 1.0 (i6: −1.0 ตัด)	4(1.0)/1.0 = **4.0**
i10 Dune	i10–i3, i10–i6 ผ่าน u5	i10: −1.5 · i3: 0.5 · i6: −0.5	i6: 1.0 (i3: −1.0 ตัด)	1(1.0)/1.0 = **1.0**
i5 Wicked	i5–i1 ผ่าน u2, u4	ได้ −0.124 (ลบ)	ไม่มี	$\bar{r}_{u1}$ = 3.2

สังเกต i10

- u5 ไม่ค่อยชอบทั้ง i6 และ i10 → คล้ายกัน
- u1 ให้ i6 = 1 → ทำนาย i10 = **1.0** (ต่ำสุดที่เป็นไปได้)

สังเกต i5, i11, i12

- ไม่มีรายการคล้ายเชิงบวกเลย → ได้ $\bar{r}_{u1}$ = 3.2 **เท่ากันหมด**
- ผลของความเบาบาง

ที่มาของข้อมูล: ผู้ใช้ร่วมอ่านจากตารางที่ 5.3 · ส่วนเบี่ยงเบนหักค่าเฉลี่ยผู้ใช้ (u4 3.75, u5 3.5, u2 4.0) · ค่าทำนาย = คะแนนของ u1 ต่อรายการคล้ายเชิงบวก (i1 = 5, i3 = 4, i6 = 1) · i5–i1: u2 (0, −2), u4 (−2.75, 0.25) ⟶ −0.6875/(2.75 × 2.0156) = −0.124

ตารางที่ 5.9 ค่าทำนายแบบ Item-kNN ของ u1 (เรียงจากมากไปน้อย)

รหัส	ชื่อเรื่อง	รายการคล้ายที่ใช้ (ความคล้าย)	ค่าทำนาย
i7	Ballerina	i1 (1.00)	5.0000
i8	Furiosa: A Mad Max Saga	i3 (1.00), i1 (1.00)	4.5000
i9	Conclave	i3 (1.00)	4.0000
i5	Wicked	— (ใช้ค่าเฉลี่ยของ u1)	3.2000
i11	Mickey 17	— (ใช้ค่าเฉลี่ยของ u1)	3.2000
i12	Project Hail Mary	— (ใช้ค่าเฉลี่ยของ u1)	3.2000
i10	Dune: Part Two	i6 (1.00)	1.0000

Top-3

- i7 (5.0) · i8 (4.5) · i9 (4.0)
- **สามเรื่องเดียวกับ User-kNN** แต่ลำดับต่างกัน

ที่มาของข้อมูล: ทุกแถวใช้สมการ (5.6) แบบเดียวกับตัวอย่าง 5.5 · i8 จากตัวอย่าง 5.5 · i7, i9, i10, i5 จากสไลด์ฝึกคำนวณก่อนหน้า · i5, i11, i12 ไม่มีรายการคล้ายเชิงบวกจึงใช้ $\bar{r}_{u1} = 3.2$ · ค่าทำนายคือคะแนนของ u1 เอง (i1 = 5, i3 = 4, i6 = 1)

ตารางที่ 5.10 เปรียบเทียบ User-kNN กับ Item-kNN

ประเด็น	User-kNN	Item-kNN
คำถามที่ตอบ	คนที่คล้ายคุณให้เรื่องนี้เท่าไร	คุณให้เรื่องที่คล้ายเรื่องนี้เท่าไร
จำนวนคู่ที่ต้องคำนวณ	$\|U\|^2$ คู่ผู้ใช้	$\|I\|^2$ คู่รายการ
ความเสถียรของความคล้าย	เปลี่ยนเร็วเมื่อผู้ใช้ให้คะแนนใหม่	ค่อนข้างคงที่ คำนวณล่วงหน้าได้
การอธิบาย	"ผู้ใช้ที่คล้ายคุณชอบ"	"เพราะคุณชอบเรื่อง X"
ตัวอย่างการใช้จริง	GroupLens [2]	Amazon [3]

5.7

ตัวอย่างการคำนวณครบวงจร



แบ่งข้อมูล → ความคล้าย → เพื่อนบ้าน → ทำนาย → จัดอันดับ → วัดผล

ตัวอย่างการคำนวณ 5.6 User-kNN ครบวงจร: ซ่อนคะแนน u1 ต่อ i3

1 แบ่งข้อมูล → 2 ความคล้าย → 3 เพื่อนบ้าน → 4 ทำนาย → 5 จัดอันดับ → 6 วัดผล

โจทย์

ซ่อนคะแนน $r_{u1,i3}$ = 4 (The Wild Robot) เป็นข้อมูลทดสอบ แล้วถามว่า User-kNN (k = 3) จะนำ i3 กลับมาอยู่ใน **3 อันดับแรก** ได้หรือไม่

เป้าหมาย

- เห็นว่าแต่ละขั้นส่งผลต่อขั้นถัดไปอย่างไร
- เทียบกับระบบฐานแบบความนิยม (นับจำนวนผู้ชอบ)

ที่มาของข้อมูล: ข้อมูลฝึก = ตารางที่ 5.3 ทั้งตาราง ยกเว้นช่อง (u1, i3) = 4 ซึ่งย้ายไปเป็นข้อมูลทดสอบหนึ่งค่า • ใช้สมการ (5.1) หาความคล้าย, (5.4) ทำนาย (k = 3) • วัดผลด้วย HR@3 และ RR (บทที่ 2) • ระบบฐานนับผู้ชอบ (คะแนน 4–5) ในข้อมูลฝึก

ตัวอย่างการคำนวณ 5.6 : ขั้นที่ 1–2 แบ่งข้อมูลและคำนวณความคล้ายใหม่

u1	i1	i2	i3	i4	i6	$\bar{r}_{u1}$
ข้อมูลเต็ม	5	5	4	1	1	3.2
ข้อมูลฝึก	5	5	? (ทดสอบ)	1	1	3.0

1 ขั้นที่ 1 ค่าเฉลี่ยใหม่จากข้อมูลฝึกเท่านั้น

$$\bar{r}_{u1}^{\text{train}} = \frac{5+5+1+1}{4} = \frac{12}{4} = 3.0$$

2 ขั้นที่ 2 คำนวณความคล้ายใหม่

$$u_2 : \frac{2(-2)+(-2)(1)+(-2)(1)}{\sqrt{12}\sqrt{6}} = \frac{-8}{8.4853} = -0.9428$$

u5 เหลือรายการร่วม i6 เท่านั้น → (−2)(−0.5) > 0 → +1.0

ผู้ใช้	รายการร่วม	Pearson
u2	3	−0.9428
u3	0	—
u4	1	1.0000
u5	1	1.0000
u6	1	1.0000
u7	0	—
u8	3	−0.9272

u5 ลดจาก 0.9062 เป็น 1.0 เพราะ **หลักฐานลดเหลือ 1 เรื่อง**

ที่มาของข้อมูล: ข้อมูลฝึกของ u1 = แถว u1 ตารางที่ 5.3 ที่ซ่อน i3 ⟶ (5 + 5 + 1 + 1)/4 = 3.0 • ส่วนเบี่ยงเบนใหม่ i1 +2, i2 +2, i4 −2, i6 −2 • u2: −8/√(12 × 6) = −0.9428 • u8: −7/(√12 × √4.75) = −0.9272 • u5 เหลือรายการร่วม i6: (−2)(−0.5) > 0 ⟶ +1

ตัวอย่างการคำนวณ 5.6 : ขั้นที่ 3–4 เลือกเพื่อนบ้านและทำนาย ($\bar{r}_{u1} = 3.0$)

รายการ	เพื่อนบ้านเชิงบวก (คะแนน − $\bar{r}_v$)	การคำนวณ	$\hat{r}_{u1,i}$
i9	u5: 5 − 3.5 = 1.5	3.0 + 1.5	4.500
i7	u4: 5 − 3.75 = 1.25	3.0 + 1.25	4.250
i8	u4: 5 − 3.75 = 1.25	3.0 + 1.25	4.250
i3 (ซ่อน)	u5: 4 − 3.5 = 0.5	3.0 + 0.5	**3.500**
i12	— (ไม่มี)	$\bar{r}_{u1}$	3.000
i11	u6: 3 − 4.0 = −1.0	3.0 − 1.0	2.000
i5	u4: −2.75 · u6: 0	3.0 + (−2.75 + 0)/2	1.625
i10	u5: 2 − 3.5 = −1.5	3.0 − 1.5	1.500

3 ขั้นที่ 3

- เพื่อนบ้านเชิงบวก: **u4, u5, u6** (sim = 1.0 ทุกคน)
- แต่ละคนมีหลักฐานเพียง **1 เรื่อง**
- sim เท่ากันหมด → ค่าทำนาย = 3.0 + ค่าเฉลี่ยของส่วนเบี่ยงเบน

ที่มาของข้อมูล: เพื่อนบ้านเชิงบวก u4, u5, u6 (sim = 1.0) จากขั้นที่ 2 · ผู้ให้คะแนนแต่ละรายการจากคอลัมน์ในตารางที่ 5.3 · ค่าเฉลี่ยเพื่อนบ้าน u4 3.75, u5 3.5, u6 4.0 · ค่าทำนาย = 3.0 + ค่าเฉลี่ยส่วนเบี่ยงเบน เช่น i5: 3.0 + (−2.75 + 0)/2 = 1.625

ตัวอย่างการคำนวณ 5.6 : ขั้นที่ 5–6 จัดอันดับและวัดผล

อันดับ 1	อันดับ 2	อันดับ 3	อันดับ 4	อันดับ 5	อันดับ 6	อันดับ 7	อันดับ 8
i9	i7	i8	i3	i12	i11	i5	i10
4.50	4.25	4.25	3.50	3.00	2.00	1.63	1.50

6 ขั้นที่ 6 วัดผล User-kNN (i3 อยู่อันดับ 4)

$$\mathrm{HR@3} = \mathbf{1}[\mathrm{rank} \leq 3] = 0$$

$$\mathrm{RR} = \frac{1}{\mathrm{rank}} = \frac{1}{4} = 0.2500$$

ระบบฐานแบบความนิยม

- นับผู้ชอบในข้อมูลฝึก: i5, i11, i12 มี 2 คน
- i3 มี 1 คน **เสมอกับ** i7, i8, i9, i10
- บอกอันดับที่แน่นอนไม่ได้ → ต้องใช้ **ค่าคาดหมาย** (หัวข้อ 5.14)

ที่มาของข้อมูล: ลำดับเรียงจากค่าทำนายในขั้นที่ 4 • i3 มี 3 เรื่องสูงกว่าอย่างเคร่งครัด (i9 4.50, i7 4.25, i8 4.25) ⟶ อันดับ r = 4 ⟶ HR@3 = 0, RR = 1/4 = 0.25 • ระบบฐาน: นับผู้ชอบในข้อมูลฝึก i5, i11, i12 = 2 คน • i3 (เหลือ u5), i7, i8, i9, i10 = 1 คน ⟶ h = 3, t = 5

ตัวอย่างการคำนวณ 5.6 : แปลผล



User-kNN ยังไม่ติดสามอันดับแรก

- เรื่องที่ขึ้นมาก่อน i3 ล้วนได้คะแนนสูงจาก **เพื่อนบ้านเพียงคนเดียว**
- การซ่อน i3 ทำให้ u5 เหลือหลักฐานกับ u1 เพียงเรื่องเดียว

บทเรียน

- ในข้อมูลเล็ก ผลของ **กรณีเดียว** ขึ้นกับหลักฐานของผู้ใช้เพียงหนึ่งหรือสองคน
- การสรุปผลต้อง **ทำซ้ำกับทุกกรณี** (กันออกทีละรายการ 20 กรณี) → งานของหัวข้อ 5.14

ที่มาของข้อมูล: ผลของกรณีนี้มาจากขั้นที่ 5–6: i3 อยู่อันดับ 4 (RR = 0.25) ขณะที่ระบบฐานได้ ϵ[RR] = 0.1769 • เรื่องที่ขึ้นก่อน i3 ได้ค่าจากเพื่อนบ้านคนเดียว (i9 ⟵ u5, i7 และ i8 ⟵ u4) • u5 เหลือหลักฐานกับ u1 เพียง i6 หลังซ่อน i3

5.8

แบบจำลองค่าเอนเอียง (Baseline Predictor)



- $\mu + b_u + b_i$ • จุดเริ่มต้นของการเรียนรู้พารามิเตอร์

ก่อนเรียนปฏิสัมพันธ์ซับซ้อน ควรจับสิ่งที่ง่ายที่สุดก่อน

ผู้ใช้บางคนให้คะแนนสูงเสมอ

- u2 และ u6 มีค่าเฉลี่ย 4.0
- u1 มีค่าเฉลี่ยเพียง 3.2
- → ค่าเอนเอียงของผู้ใช้ b_u

รายการบางรายการได้คะแนนสูงเสมอ

- i9 Conclave ได้ 5 จากผู้ให้คะแนน **คนเดียว**
- i12 ได้ 4 และ 5
- → ค่าเอนเอียงของรายการ b_i

แบบจำลองค่าเอนเอียง [5]

- แยก "นิสัยการให้คะแนน" และ "ชื่อเสียงของเรื่อง" ออกจากค่าเฉลี่ยรวม
- หัวข้อ 5.4–5.7 ไม่ได้ "เรียนรู้" อะไร — คำนวณตอนใช้ • แบบจำลองนี้คือ **แบบจำลองที่ง่ายที่สุดของตระกูลอิงแบบจำลอง**
- เป็นส่วนหนึ่งของ MF ในหัวข้อ 5.9 ด้วย

อธิบายแบบเข้าใจง่าย: ค่าเอนเอียงคือ "นิสัยการให้คะแนน" และ "ชื่อเสียงของเรื่อง"



อธิบายแบบเข้าใจง่าย

ค่าทำนายเริ่มจาก **ค่าเฉลี่ยของทุกคน** แล้วปรับสองครั้ง

ครั้งแรกปรับตาม **ชื่อเสียงของเรื่อง** (b_i) เรื่องที่คนส่วนใหญ่ชอบได้บวก

ครั้งที่สองปรับตาม **นิสัยของผู้ใช้** (b_u) คนใจดีได้บวก คนเข้มงวดได้ลบ

เหมือนเดาคะแนนสอบจาก ค่าเฉลี่ยห้อง + ความยากของข้อสอบ + ความเก่งของนักเรียน โดยยังไม่ดูว่านักเรียนถนัดเรื่องใด

สมการของแบบจำลองค่าเอนเอียงพร้อมการหด

$$\hat{r}_{ui} = \mu + b_u + b_i$$

$$b_i = \frac{\sum_{u \in U_i} (r_{ui} - \mu)}{\lambda_i + |U_i|} \qquad b_u = \frac{\sum_{i \in I_u} (r_{ui} - \mu - b_i)}{\lambda_u + |I_u|}$$

สมการ (5.7)

คำนวณ b_i ก่อน แล้วใช้ b_i คำนวณ b_u

โดยที่

- μ = 3.625 ค่าเฉลี่ยรวม
- $|U_i|$ = จำนวนคะแนนของรายการ i • $|I_u|$ = จำนวนคะแนนของผู้ใช้ u
- บทนี้ใช้ $\lambda_i = \lambda_u = 2$

ทำไมต้องมี λ

- ตัวหาร $\lambda + |U_i|$ ทำหน้าที่ **หด** รายการที่มีคะแนนน้อยเข้าหาศูนย์
- ถ้าไม่มี λ รายการที่มีคะแนน 5 เพียงค่าเดียวจะได้ b_i สูงสุด ทั้งที่หลักฐานอ่อนมาก

ที่มาของข้อมูล: ค่าที่แทนในสมการ (5.7): μ = 3.625 จากตัวอย่าง 5.1 • $|U_i|$ = จำนวนคะแนนในคอลัมน์ i และ $|I_u|$ = จำนวนคะแนนในแถว u ของตารางที่ 5.3 • $\lambda_i = \lambda_u = 2$ • ใช้จริงในตัวอย่าง 5.7 และตารางที่ 5.11

ตัวอย่างการคำนวณ 5.7 ค่าเอนเอียงของ i9, i12 และ u1 : โจทย์

โจทย์ ใช้ $\mu = 3.625$ และ $\lambda = 2$ จงหา b_{i9}, b_{i12}, b_{u1} และค่าทำนายของ u1 ต่อ i9

รายการ	ผู้ให้คะแนน	คะแนน	$r - \mu$	$\lvert U_i \rvert$
i9 Conclave	u5	5	1.375	1
i12 Project Hail Mary	u3, u7	4, 5	0.375, 1.375	2

ลำดับการคิด

- หา b_i ของทุกรายการก่อน (ขั้นที่ 1–2)
- หาเศษเหลือของ u1 หลังหัก μ และ b_i แล้วหาร $(\lambda + |I_u|)$ (ขั้นที่ 3–4)
- รวม $\mu + b_u + b_i$ (ขั้นที่ 5)

ที่มาของข้อมูล: ผู้ให้คะแนนและคะแนนอ่านจากคอลัมน์ i9 (u5 = 5) และ i12 (u3 = 4, u7 = 5) ของตารางที่ 5.3 • r – μ ใช้ μ = 3.625 (ตัวอย่าง 5.1)
⟶ 5 – 3.625 = 1.375, 4 – 3.625 = 0.375 • |U_i| = จำนวนผู้ให้คะแนน (1 และ 2) • λ = 2

ตัวอย่างการคำนวณ 5.7 : ขั้นที่ 1–2 ค่าเอนเอียงของรายการ

1 i9 มีคะแนนเดียว (u5 ให้ 5) — ถ้าไม่หดจะได้ 1.375

$$b_{i9} = \frac{5 - 3.625}{2 + 1} = \frac{1.375}{3} = 0.4583$$

2 i12 มีสองคะแนน (4 และ 5)

$$b_{i12} = \frac{(4 - 3.625) + (5 - 3.625)}{2 + 2} = \frac{0.375 + 1.375}{4} = 0.4375$$

ที่มาของข้อมูล: i9: ผลรวม r − μ = 1.375 (u5 ให้ 5) หารด้วย λ + |U_i| = 2 + 1 = 3 ⟶ 0.4583 • i12: (0.375 + 1.375) = 1.75 หารด้วย 2 + 2 = 4 ⟶ 0.4375 • ค่าทั้งสองคือแถว i9 และ i12 ของตารางที่ 5.11

ตัวอย่างการคำนวณ 5.7 : ขั้นที่ 3–4 ค่าเอนเอียงของ u1

รายการของ u1	$r_{u1,i}$	b_i	$r - \mu - b_i$
i1	5	0.0250	5 − 3.625 − 0.0250 = 1.3500
i2	5	0.2250	5 − 3.625 − 0.2250 = 1.1500
i3	4	0.0250	4 − 3.625 − 0.0250 = 0.3500
i4	1	−0.1750	1 − 3.625 + 0.1750 = −2.4500
i6	1	−0.0833	1 − 3.625 + 0.0833 = −2.5417
รวม			−2.1417

3 ขั้นที่ 3

หัก μ และ b_i ออกจากคะแนนจริงทีละเรื่อง

4 ขั้นที่ 4

$$b_{u1} = \frac{-2.1417}{2+5} = -0.3060$$

b_{u1} ติดลบ → u1 เป็นผู้ใช้ **"เข้มงวด"** ให้ต่ำกว่าที่ μ และ b_i คาดไว้ (เพราะให้ 1 สองเรื่อง)

ที่มาของข้อมูล: คะแนนของ u1 จากแถว u1 ตารางที่ 5.3 (i1 5, i2 5, i3 4, i4 1, i6 1) • b_i ของแต่ละเรื่องจากตารางที่ 5.11 • μ = 3.625 • ผลรวมเศษเหลือ −2.1417 หารด้วย λ + |I_u1| = 2 + 5 = 7 ⟶ b_u1 = −0.3060

ตัวอย่างการคำนวณ 5.7 : ขั้นที่ 5 ค่าทำนาย และแปลผล

5 รวมสามส่วน

$$\hat{r}_{u1,i9} = \mu + b_{u1} + b_{i9} = 3.625 + (-0.3060) + 0.4583 = 3.7774$$

แปลผล

- การหดทำให้ i9 (หลักฐาน 1 คะแนน) ได้ค่าเอนเอียง **ใกล้กับ i12** (2 คะแนน) แทนที่จะสูงกว่ามาก
- แบบจำลองนี้ **ไม่ปรับเฉพาะบุคคลในเรื่องรสนิยม** — ทุกคนได้ลำดับรายการเหมือนกัน ต่างเพียงระดับ
- แต่เป็น **ฐานที่ควรเทียบเสมอ** และเป็นส่วนหนึ่งของ MF

ที่มาของข้อมูล: μ = 3.625 (ตัวอย่าง 5.1) • b_u1 = −0.3060 (ขั้นที่ 4) • b_i9 = 0.4583 (ขั้นที่ 1) ⟶ $\hat{r}_{u1,i9}$ = 3.625 − 0.3060 + 0.4583 = 3.7774 ตรงกับแถว i9 ของตารางที่ 5.11

ตารางที่ 5.11 ค่าเอนเอียงของรายการและค่าทำนายของ u1 ($\mu + b_{u1} = 3.3190$)

รหัส	ชื่อเรื่อง	n	$\Sigma(r - \mu)$	$b_i = \Sigma/(2 + n)$	$\hat{r}_{u1,i}$
i1	Toy Story 5	3	0.125	0.0250	(ให้คะแนนแล้ว)
i2	Inside Out 2	3	1.125	0.2250	(ให้คะแนนแล้ว)
i3	The Wild Robot	3	0.125	0.0250	(ให้คะแนนแล้ว)
i4	It Ends with Us	3	−0.875	−0.1750	(ให้คะแนนแล้ว)
i5	Wicked	3	−1.875	−0.3750	2.9440
i6	Bridget Jones	4	−0.500	−0.0833	(ให้คะแนนแล้ว)
i7	Ballerina	2	−1.250	−0.3125	3.0065
i8	Furiosa	2	−0.250	−0.0625	3.2565
i9	Conclave	1	1.375	0.4583	3.7774
i10	Dune: Part Two	2	−0.250	−0.0625	3.2565
i11	Mickey 17	4	0.500	0.0833	3.4024
i12	Project Hail Mary	2	1.750	0.4375	3.7565

ตัวอย่าง: $\hat{r}_{u1,i5} = 3.625 - 0.3060 - 0.3750 = 2.9440$ • อันดับของทุกคนเหมือนกัน (เรียงตาม b_i)

ที่มาของข้อมูล: n = จำนวนคะแนนในคอลัมน์ของตารางที่ 5.3 • $\Sigma(r - \mu)$ ใช้ $\mu = 3.625$ เช่น i5 (4, 1, 4): 0.375 − 2.625 + 0.375 = −1.875 ⟶ b = −1.875/5 = −0.3750 • ค่าทำนาย = μ + b_u1 + b_i = 3.3190 + b_i โดย b_u1 = −0.3060 จากตัวอย่าง 5.7

5.9

การแยกตัวประกอบเมทริกซ์ด้วย SGD



ปัจจัยแฝง • SGD • การเรียนรู้เกิน • การตีความปัจจัยแฝง

5.9.1 ปัจจัยแฝง: ทำไมต้องบีบเมทริกซ์

ข้อจำกัดของแบบจำลองเพื่อนบ้าน

- ต้องพบ **รายการร่วมโดยตรง** จึงจะส่งสารสนเทศได้
- u1 กับ u3 ไม่มีรายการร่วมเลย → ข้อมูลของ u3 **ไม่มีทางช่วย** u1

Matrix Factorization (MF) [5]

- ความชอบถูกกำหนดโดย **ปัจจัยแฝง** จำนวนน้อย k ปัจจัย
- เช่น ระดับความเป็นแอนิเมชัน ความเข้มข้นของฉากแอ็กชัน

สองเวกเตอร์

- ผู้ใช้ u มีเวกเตอร์ p_u = ชอบแต่ละปัจจัยมากเพียงใด
- รายการ i มีเวกเตอร์ q_i = มีแต่ละปัจจัยมากเพียงใด
- ค่าทำนาย = ค่าเอนเอียง + **ผลคูณจุด** $p_u \cdot q_i$

อธิบายแบบเข้าใจง่าย: MF คือการอธิบายรสนิยมด้วย "ส่วนผสม" ไม่กี่อย่าง



อธิบายแบบเข้าใจง่าย

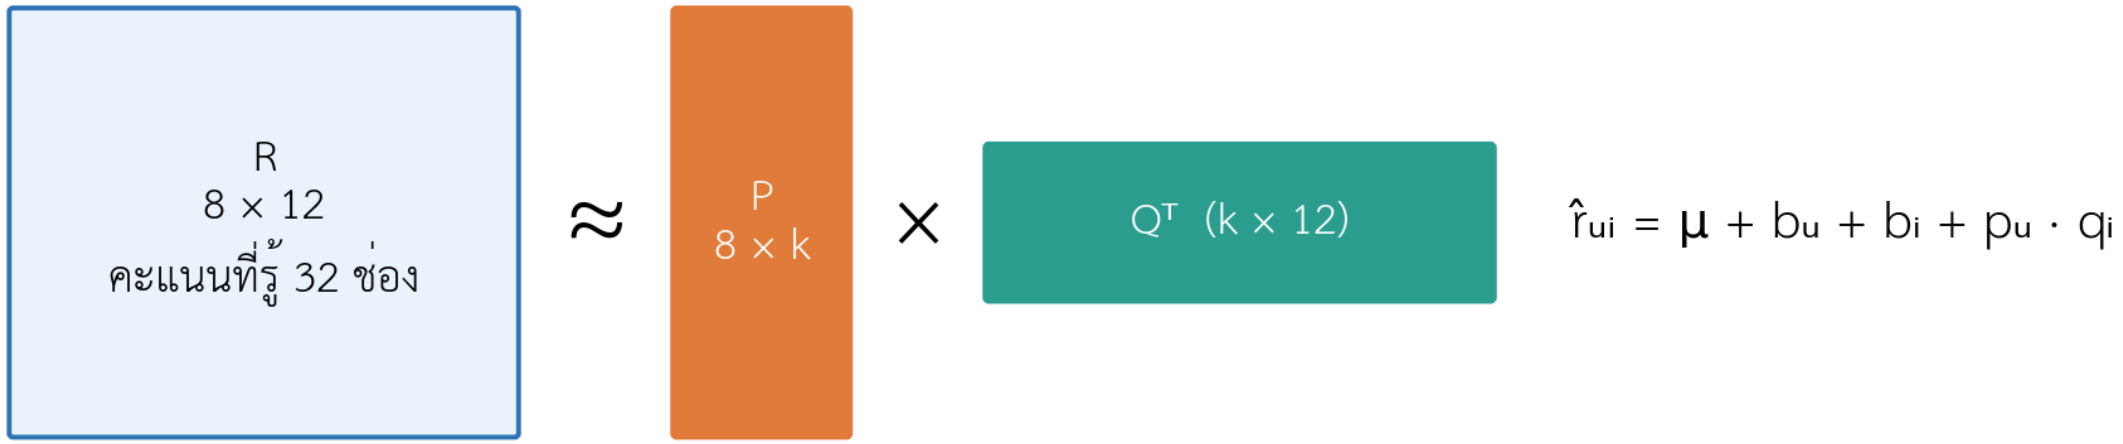
ร้านกาแฟอธิบายเครื่องดื่มทุกแก้วด้วยส่วนผสม 2 อย่าง: **ความเข้มของกาแฟ** และ **ความหวาน**

ลูกค้าแต่ละคนก็มีความชอบ 2 ค่าเช่นกัน คนที่ชอบเข้มแต่ไม่ชอบหวานจะให้เอสเปรสโซสูง

ผลคูณจุด = การจับคู่ความชอบของลูกค้ากับส่วนผสมของเครื่องดื่ม

MF ทำแบบเดียวกัน แต่ **เรียนส่วนผสมเองจากคะแนน** โดยไม่มีใครบอกว่าส่วนผสมแต่ละอย่างคืออะไร

ภาพที่ 5.7 บีบเมทริกซ์คะแนนให้เหลือเวกเตอร์สั้น



ภาพที่ 5.7 การแยกตัวประกอบเมทริกซ์บีบเมทริกซ์คะแนนให้เหลือเวกเตอร์สั้นของผู้ใช้และรายการ

R (8 × 12, รู้ค่า 32 ช่อง) ≈ P (8 × k) × Q^T (k × 12) • ทุกช่องที่ว่างจึง **เติมได้** จากผลคูณจุดของแถว u กับแถว i

ค่าทำนายและฟังก์ชันเป้าหมายของ MF

$$\hat{r}_{ui} = \mu + b_u + b_i + \mathbf{p}_u \cdot \mathbf{q}_i$$

$$\min_{b,P,Q} \sum_{(u,i)\in K} (r_{ui} - \hat{r}_{ui})^2 + \lambda\left(b_u^2 + b_i^2 + \|\mathbf{p}_u\|^2 + \|\mathbf{q}_i\|^2\right)$$

สมการ (5.8)

ความคลาดเคลื่อนกำลังสอง + เรกูลาไรเซชัน

โดยที่

- K = เซตคะแนนที่รู้ค่า — **ผลรวมคิดเฉพาะช่องที่รู้ค่า** ไม่ได้ถือว่าช่องว่างเป็น 0
- ต่างจาก SVD ในพีชคณิตเชิงเส้นที่ต้องใช้เมทริกซ์เต็ม

สองพจน์

- พจน์แรก: ทำนายผิดเท่าไร
- พจน์ที่สอง: ลงโทษพารามิเตอร์ค่ามาก → ป้องกันการจำข้อมูลฝึก

ที่มาของข้อมูล: ผลรวมในสมการ (5.8) คิดเฉพาะเซต K = 32 ช่องที่มีคะแนนในตารางที่ 5.3 (ไม่ถือช่องว่างเป็น 0) • μ = 3.625 จากตัวอย่าง 5.1 • บทนี้ใช้ k = 2 • ใช้ในตัวอย่าง 5.8 (SGD), ตารางที่ 5.12 และภาพที่ 5.8

คำนวณจำนวนพารามิเตอร์ของ MF บน MovieMini-12 (k = 2)

1 นับพารามิเตอร์: เวกเตอร์ผู้ใช้ + เวกเตอร์รายการ + ค่าเอนเอียง

$$\underbrace{(8+12)\times 2}_{\mathbf{p}_u,\,\mathbf{q}_i} + \underbrace{8}_{b_u} + \underbrace{12}_{b_i} = 40 + 8 + 12 = 60$$

2 เทียบกับจำนวนข้อมูล

$$\frac{\text{parameters}}{\text{ratings}} = \frac{60}{32} = 1.875$$

พารามิเตอร์ **มากกว่าข้อมูล** → เสี่ยงต่อ **การเรียนรู้เกิน** (Overfitting) อย่างยิ่ง (วัดให้เห็นในหัวข้อ 5.9.3)

ที่มาของข้อมูล: 8 และ 12 = จำนวนผู้ใช้และรายการในตารางที่ 5.3 • เวกเตอร์ k = 2 มิติ: (8 + 12) × 2 = 40 ค่า • ค่าเอนเอียง 8 + 12 = 20 ค่า ⟶ รวม 60 • 32 = จำนวนคะแนนที่รู้ค่า |K| จากตัวอย่าง 5.1 ⟶ 60/32 = 1.875

5.9.2 การลดตามเกรเดียนต์แบบสุ่ม (SGD)

SGD (Funk, Netflix Prize [11])

- วนผ่านคะแนนที่รู้ค่า **ทีละตัวในลำดับสุ่ม** · คำนวณ $e_{ui} = r_{ui} - \hat{r}_{ui}$ · ขยับพารามิเตอร์ในทิศที่ลดความคลาดเคลื่อน ด้วยอัตราการเรียนรู้ η
- คือการลดตามเกรเดียนต์ของบทที่ 4 หัวข้อ 4.3.3 ต่างเพียงใช้คะแนนทีละค่า

พารามิเตอร์ใหม่ = พารามิเตอร์เดิม + η × (ความคลาดเคลื่อน × ตัวคูณของพารามิเตอร์นั้น − λ × พารามิเตอร์เดิม)

พารามิเตอร์	ตัวคูณ	ความหมายของ $-\lambda$ × พารามิเตอร์
b_u , b_i	1	แรงดึงกลับเข้าหาศูนย์
p_u	q_i	(เรกูลาไรเซชัน)
q_i	p_u	

อธิบายแบบเข้าใจง่าย: SGD คือการปรับทีละนิดหลังเดาผิดแต่ละครั้ง



อธิบายแบบเข้าใจง่าย

ระบบเดาว่า u1 จะให้ Toy Story 5 เพียง **3.6 ดาว** แต่ u1 ให้ **5 ดาว** → เดาต่ำไป 1.4 ดาว

ระบบจึงเพิ่มค่าเอนเอียงของ u1 และ Toy Story 5 ขึ้นเล็กน้อย และขยับเวกเตอร์ของทั้งสองให้ **ชี้ไปทางเดียวกันมากขึ้น**

เดาผิดมากก็ขยับมาก เดาผิดน้อยก็ขยับน้อย

ทำซ้ำกับทุกคะแนนหลายร้อยรอบ จนค่าทำนายใกล้ความจริง

กฎการปรับพารามิเตอร์ของ SGD

$$b_u \leftarrow b_u + \eta\,(e_{ui} - \lambda b_u) \qquad b_i \leftarrow b_i + \eta\,(e_{ui} - \lambda b_i)$$
$$\mathbf{p}_u \leftarrow \mathbf{p}_u + \eta\,(e_{ui}\mathbf{q}_i - \lambda \mathbf{p}_u) \qquad \mathbf{q}_i \leftarrow \mathbf{q}_i + \eta\,(e_{ui}\mathbf{p}_u - \lambda \mathbf{q}_i)$$

สมการ (5.9)

ปรับ 4 กลุ่มพารามิเตอร์หลังเห็นคะแนนหนึ่งค่า

โดยที่

- $e_{ui} = r_{ui} - \hat{r}_{ui}$ ความคลาดเคลื่อน
- η = อัตราการเรียนรู้ · λ = ค่าเรกูลาไรเซชัน

ข้อควรระวังเวลาคำนวณมือ

- ปรับ q_i ด้วย p_u **ค่าเดิมก่อนปรับ** (เก็บสำเนาไว้ก่อน)
- $e > 0$ (เดาต่ำ) → พารามิเตอร์ขยับขึ้น

ที่มาของข้อมูล: ค่าที่แทนในสมการ (5.9): r_ui = คะแนนจริงจากตารางที่ 5.3 · e_ui = r_ui − $\hat{r}$_ui โดย $\hat{r}$ จากสมการ (5.8) · η = 0.05 และ λ = 0.1 ตรงกับ lr และ reg ของโปรแกรมที่ 5.7 · ใช้จริงในตัวอย่าง 5.8

ตัวอย่างการคำนวณ 5.8 หนึ่งก้าวของ SGD บนคะแนน $r_{u1,i1} = 5$: โจทย์

ค่าเริ่มต้น	ค่า
b_{u1} , b_{i1}	0 , 0
p_{u1}	(0.1, −0.1)
q_{i1}	(0.2, 0.1)
μ	3.625
η (อัตราการเรียนรู้)	0.05
λ (เรกูลาไรเซชัน)	0.1

โจทย์

จงปรับพารามิเตอร์ **หนึ่งก้าว** ด้วยสมการ (5.9) เมื่อเห็นคะแนน $r_{u1,i1} = 5$

แผนการคำนวณ

- ทำนาย → หาความคลาดเคลื่อน e
- ปรับ b_{u1}, b_{i1}
- ปรับ p_{u1}, q_{i1} ทีละมิติ
- ทำนายใหม่ ตรวจว่าเข้าใกล้ 5

ที่มาของข้อมูล: คะแนนที่ใช้คือ r_u1,i1 = 5 จากแถว u1 คอลัมน์ i1 ของตารางที่ 5.3 • μ = 3.625 จากตัวอย่าง 5.1 • b = 0 ตามการตั้งค่าเริ่มต้นของโปรแกรมที่ 5.7 • p_u1, q_i1 เป็นค่าเริ่มต้นสมมติเพื่อคำนวณมือ • η = 0.05, λ = 0.1 = lr และ reg ของโปรแกรมที่ 5.7

ตัวอย่างการคำนวณ 5.8 : ขั้นที่ 1–2

1 ค่าทำนายและความคลาดเคลื่อน

$$\hat{r} = 3.625 + 0 + 0 + (0.1)(0.2) + (-0.1)(0.1) = 3.625 + 0.02 - 0.01 = 3.6350$$

$$e = 5 - 3.6350 = 1.3650$$

2 ปรับค่าเอนเอียง ($\lambda \times 0 = 0$)

$$b_{u1} = 0 + 0.05\,(1.3650 - 0.1 \times 0) = 0.0683 \qquad b_{i1} = 0.0683 \text{ (same)}$$

ที่มาของข้อมูล: ทุกค่าเริ่มต้นมาจากสไลด์โจทย์: p_u1 • q_i1 = 0.1(0.2) + (−0.1)(0.1) = 0.01 • $\hat{r}$ = 3.625 + 0 + 0 + 0.01 = 3.635 • e = 5 − 3.635 = 1.365 • b ⟵ 0 + 0.05(1.365 − 0.1 × 0) = 0.06825

ตัวอย่างการคำนวณ 5.8 : ขั้นที่ 3–4 ปรับเวกเตอร์ทีละมิติ

3 $p_{u1} \leftarrow p_{u1} + \eta\,(e \cdot q_{i1} - \lambda \cdot p_{u1})$

$$e\,\mathbf{q}_{i1} - \lambda \mathbf{p}_{u1} = 1.365(0.2,\ 0.1) - 0.1(0.1,\ -0.1) = (0.273 - 0.01,\ 0.1365 + 0.01) = (0.263,\ 0.1465)$$

$$\mathbf{p}_{u1} = (0.1,\ -0.1) + 0.05(0.263,\ 0.1465) = (0.1132,\ -0.0927)$$

4 $q_{i1} \leftarrow q_{i1} + \eta\,(e \cdot p_{u1} - \lambda \cdot q_{i1})$ — ใช้ p_{u1} ค่าเดิม (0.1, −0.1)

$$e\,\mathbf{p}_{u1} - \lambda \mathbf{q}_{i1} = 1.365(0.1,\ -0.1) - 0.1(0.2,\ 0.1) = (0.1365 - 0.02,\ -0.1365 - 0.01) = (0.1165,\ -0.1465)$$

$$\mathbf{q}_{i1} = (0.2,\ 0.1) + 0.05(0.1165,\ -0.1465) = (0.2058,\ 0.0927)$$

ที่มาของข้อมูล: e = 1.365 จากขั้นที่ 1 • p_u1 = (0.1, −0.1), q_i1 = (0.2, 0.1) จากโจทย์ • มิติ 1: 0.1 + 0.05(1.365 × 0.2 − 0.1 × 0.1) = 0.11315 • q_i1 ใช้ p_u1 ค่าเดิม: 0.2 + 0.05(1.365 × 0.1 − 0.1 × 0.2) = 0.205825

ตัวอย่างการคำนวณ 5.8 : ขั้นที่ 5 ตรวจค่าทำนายใหม่ และแปลผล

5 ค่าทำนายหลังปรับหนึ่งก้าว

$$\hat{r}^{\,\text{new}} = 3.625 + 0.0683 + 0.0683 + (0.1132)(0.2058) + (-0.0927)(0.0927) = 3.7615 + 0.0233 - 0.0086 = 3.7762$$

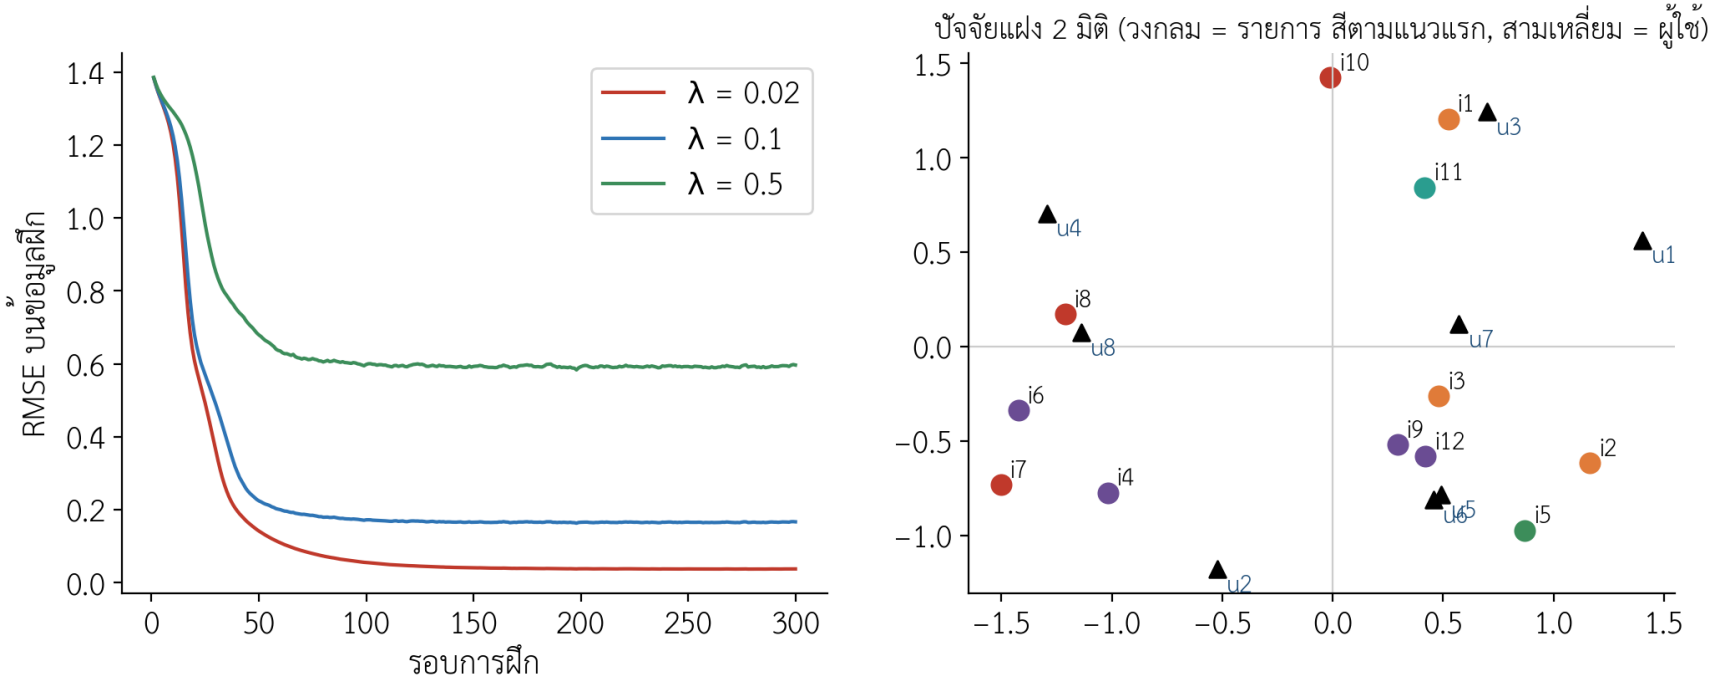
เข้าใกล้ 5 มากขึ้นจาก 3.6350 (ความคลาดเคลื่อนลดจาก 1.365 เหลือ 1.224)

แปลผล

- **ค่าเอนเอียงรับความคลาดเคลื่อนไปก่อนเกือบทั้งหมด** (+0.1365) เพราะเวกเตอร์ปัจจัยยังเล็ก (+0.0147)
- รอบต่อ ๆ ไป เมื่อค่าเอนเอียงอธิบายส่วนที่ง่ายแล้ว ปัจจัยแฝงจึงค่อย ๆ เรียนรูปแบบที่เหลือ

ที่มาของข้อมูล: ค่าใหม่จากขั้นที่ 2–4: b_u1 = b_i1 = 0.06825, p_u1 = (0.11315, −0.092675), q_i1 = (0.205825, 0.092675) • p • q = 0.023289 − 0.008589 = 0.0147 • $\hat{r}$ = 3.625 + 0.1365 + 0.0147 = 3.7762 ⟶ e ลดจาก 1.365 เหลือ 1.224

ภาพที่ 5.8 การลู่เข้าของ SGD และปัจจัยแฝงที่เรียนได้



ภาพที่ 5.8 การลู่เข้าของ SGD ที่ λ ต่างกัน (ซ้าย) และปัจจัยแฝงสองมิติที่เรียนได้ (ขวา)

λ = 0.1 ฝึก 300 รอบ: RMSE ข้อมูลฝึก 1.3841 (รอบแรก) → 0.2243 (รอบ 50) → 0.1668 (รอบ 300) • ขวา: สีของรายการ = แนวภาพยนตร์ ซึ่ง **แบบจำลองไม่ได้ใช้เลย** — ระวังตีความเกินหลักฐานบนข้อมูล 32 คะแนน

ที่มาของข้อมูล: กราฟซ้ายได้จากการฝึกโปรแกรมที่ 5.7 บนคะแนน 32 ค่าของตารางที่ 5.3 (k = 2, η = 0.05) แล้ววัด RMSE บนข้อมูลฝึกทุกรอบ • ค่า 1.3841 → 0.2243 → 0.1668 คือ λ = 0.1 ที่รอบ 1, 50, 300 • กราฟขวาคือ q_i ที่เรียนได้ สีแนวมาจากบัญชีภาพยนตร์ (ไม่ได้ใช้ในการฝึก)

5.9.3 การเรียนรู้เกินและเรกูลาไรเซชัน (ตารางที่ 5.12)

MF (k = 2, 150 รอบ) วัดสองแบบ: บนข้อมูลฝึก และ **กันออกทีละคะแนน** (ฝึกใหม่ 32 ครั้ง ซ่อนครั้งละ 1 ค่า)

λ	RMSE ข้อมูลฝึก	RMSE กันออก	MAE กันออก
0.02	0.0408	2.4472	2.1376
0.1	0.1658	2.3966	2.1232
0.5	0.5929	1.9803	1.7105
ค่าเฉลี่ยรวม (อ้างอิง)	—	1.4541	1.2581

ภาพคลาสสิกของการเรียนรู้เกิน

- λ ยิ่งเล็ก ข้อมูลฝึกยิ่งพอดี แต่ข้อมูลที่ซ่อนยิ่งผิดมาก
- ทุก λ ยัง **แพ้ค่าเฉลี่ยรวม**

สาเหตุ

- คะแนนค่อนไปทางสุดขั้ว (1 หรือ 5)
- ผู้ใช้มีคะแนนเพียง 3–5 ค่า

บทเรียน

- **ต้องเทียบกับระบบฐานที่ง่ายที่สุดเสมอ** ก่อนสรุปว่าแบบจำลองซับซ้อนดีกว่า

ที่มาของข้อมูล: ฝึกด้วยโปรแกรมที่ 5.7 (k = 2, η = 0.05, 150 รอบ, เมล็ดสุ่ม 2569) บนคะแนน 32 ค่าของตารางที่ 5.3 • RMSE ข้อมูลฝึกวัดบน 32 ค่าที่ใช้ฝึก • RMSE/MAE กันออกใช้สมการ (5.13): ฝึกใหม่ 32 ครั้ง ซ่อนครั้งละหนึ่งคะแนน (ตัดค่า 1–5) • แถวอ้างอิง = แถวค่าเฉลี่ยรวมของตารางที่ 5.16

5.9.4 การตีความปัจจัยแฝง: ปัจจัยแฝงไม่มีชื่อตายตัว (ตัวอย่างคำนวณ)

1 เวกเตอร์ตั้งต้น

$$\mathbf{p} = (1,\ 0),\quad \mathbf{q} = (0.6,\ 0.8)\ \Rightarrow\ \mathbf{p}\cdot\mathbf{q} = 0.6$$

2 หมุนแกนทั้งคู่ 90° พร้อมกัน: (x, y) → (−y, x)

$$\mathbf{p}' = (0,\ 1),\quad \mathbf{q}' = (-0.8,\ 0.6)\ \Rightarrow\ \mathbf{p}'\cdot\mathbf{q}' = 0 + 0.6 = 0.6$$

ข้อสรุป

- ผลคูณจุดเท่าเดิม → **ค่าทำนายไม่เปลี่ยน** แต่ค่าบนแต่ละแกนเปลี่ยนหมด (เหมือนหมุนแผนที่ ระยะทางเท่าเดิม แต่ "ทิศเหนือ" เปลี่ยน)
- ตีความเชิง **ความสัมพันธ์** เช่น รายการใดอยู่ใกล้กัน • λ = 0.1: p_{u1} • q_i สูงสุด = i1 (1.415), i2 (1.282), i11 (1.058), i10 (0.789), i5 (0.668)
- อธิบายคำแนะนำจาก MF อย่างซื่อตรง: รายงานทั้ง **ส่วนค่าเอนเอียง** และ **ส่วนปฏิสัมพันธ์**

ที่มาของข้อมูล: ขั้นที่ 1–2 ใช้เวกเตอร์สมมติ p = (1, 0), q = (0.6, 0.8) เพื่อให้เห็นการหมุนแกนชัด • การหมุน 90°: (x, y) ⟶ (–y, x) • ค่า p_u1 • q_i (i1 1.415, i2 1.282, ...) มาจาก MF ที่ฝึกด้วยโปรแกรมที่ 5.7 (λ = 0.1) บนตารางที่ 5.3

5.10

กำลังสองน้อยสุดสลับ (ALS)



แก้ทีละฝั่งด้วยคำตอบรูปปิด • SVD++

5.10.1 ALS: แก้ทีละฝั่งด้วยคำตอบรูปปิด

แนวคิด

- ปรับ P และ Q พร้อมกันยาก
- แต่ถ้า **ตรึง Q ไว้** การหา p_u = การถดถอยเชิงเส้นธรรมดา
- มีสูตรคำตอบสำเร็จรูป (คำตอบรูปปิด)

ALS [6]

- สลับ: แก้ p_u ทุกคน (ตรึง Q) ↔ แก้ q_i ทุกรายการ (ตรึง P)
- **ไม่ต้องเลือกอัตราการเรียนรู้**
- แต่ละผู้ใช้แก้แยกกัน → **ขนานได้ดี**

อธิบายแบบเข้าใจง่าย: ผลัดกันปรับทีละฝั่ง

สองคนช่วยกันยกโต๊ะให้ได้ระดับ ถ้าขยับพร้อมกันจะเอียงไปมา วิธีที่ง่ายกว่าคือให้คนหนึ่ง **ยืนนิ่ง** แล้วอีกคนปรับให้พอดี จากนั้นสลับกัน — ALS สลับไปมาไม่กี่รอบก็ลู่เข้า

สูตรคำตอบรูปปิดของ ALS สำหรับผู้ใช้ u

$$\mathbf{p}_u = \left(Q_u^\top Q_u + \lambda I\right)^{-1} Q_u^\top \mathbf{r}_u$$

สมการ (5.10)

เวกเตอร์ผู้ใช้ที่ดีที่สุดเมื่อ Q ถูกตรึงไว้

โดยที่

- Q_u = เมทริกซ์ที่แต่ละแถวคือ q_i ของรายการที่ u ให้คะแนน
- r_u = คะแนนเหล่านั้นที่ **หักค่าเฉลี่ยรวม** แล้ว
- I = เมทริกซ์เอกลักษณ์ k × k

ในตัวอย่าง 5.9

- ตัวอย่างใช้แบบจำลอง **ไม่มีค่าเอนเอียง**
- กำหนด Q **สมมติ** เพื่อให้เห็นสูตรชัด
- k = 2 → แก้ระบบสมการ 2 × 2

ที่มาของข้อมูล: ค่าที่แทนในสมการ (5.10): Q_u = แถว q_i ของรายการที่ u ให้คะแนน (u1: i1, i2, i3, i4, i6 ตามตารางที่ 5.3) • r_u = คะแนนเหล่านั้นลบ μ = 3.625 • λ = 0.1 • k = 2 ⟶ I เป็น 2 × 2 • ใช้จริงในตัวอย่าง 5.9

ตัวอย่างการคำนวณ 5.9 แก้เวกเตอร์ของ u1 ด้วย ALS หนึ่งขั้น : โจทย์

รายการ	q_i (มิติ 1, มิติ 2)	$r_{u1,i}$	ขั้นที่ 1: $r - \mu$
i1	(1.0, 0.2)	5	1.375
i2	(0.9, 0.1)	5	1.375
i3	(0.8, 0.3)	4	0.375
i4	(−0.7, 0.6)	1	−2.625
i6	(−0.8, 0.5)	1	−2.625

โจทย์

- กำหนดเวกเตอร์รายการตามตาราง และ $\lambda = 0.1$ จงหา p_{u1}
- $\mu = 3.625$

สังเกตก่อนคำนวณ

รายการที่ u1 ชอบ (i1, i2, i3) มี **มิติ 1 เป็นบวก** · รายการที่ไม่ชอบ (i4, i6) มี **มิติ 1 เป็นลบ** → คาดว่า p_{u1} มิติ 1 จะเป็นบวกมาก

ที่มาของข้อมูล: คะแนน r_u1,i อ่านจากแถว u1 ของตารางที่ 5.3 (i1 5, i2 5, i3 4, i4 1, i6 1) · ขั้นที่ 1 หัก $\mu = 3.625$ (ตัวอย่าง 5.1): 5 − 3.625 = 1.375, 4 − 3.625 = 0.375, 1 − 3.625 = −2.625 · q_i เป็นค่าสมมติที่ตรึงไว้ · $\lambda = 0.1$ ตามโปรแกรมที่ 5.8

ตัวอย่างการคำนวณ 5.9 : ขั้นที่ 2–3 สร้าง $Q^TQ + \lambda I$ และ Q^Tr

รายการ	q_1^2	$q_1\ q_2$	q_2^2	$q_1 \times r$	$q_2 \times r$
i1	1.00	0.20	0.04	1.3750	0.2750
i2	0.81	0.09	0.01	1.2375	0.1375
i3	0.64	0.24	0.09	0.3000	0.1125
i4	0.49	−0.42	0.36	1.8375	−1.5750
i6	0.64	−0.40	0.25	2.1000	−1.3125
รวม	3.58	−0.29	0.75	6.8500	−2.3625

2 ขั้นที่ 2

$$Q^\top Q + \lambda I = \begin{pmatrix} 3.58 + 0.1 & -0.29 \\ -0.29 & 0.75 + 0.1 \end{pmatrix} = \begin{pmatrix} 3.68 & -0.29 \\ -0.29 & 0.85 \end{pmatrix}$$

3 ขั้นที่ 3

$$Q^\top \mathbf{r} = \begin{pmatrix} 6.8500 \\ -2.3625 \end{pmatrix}$$

ที่มาของข้อมูล: q_1, q_2 ของแต่ละแถวมาจากตารางโจทย์ และ r = คอลัมน์ r − μ ของขั้นที่ 1 • เช่น i4: $q_1^2 = (-0.7)^2 = 0.49$, $q_1q_2 = (-0.7)(0.6) = -0.42$, $q_1 \times r = (-0.7)(-2.625) = 1.8375$ • แถวรวม ⟶ $Q^TQ + 0.1I$ = [[3.68, −0.29], [−0.29, 0.85]] และ Q^Tr = (6.85, −2.3625)

ตัวอย่างการคำนวณ 5.9 : ขั้นที่ 4 แก้ระบบ 2 × 2 ด้วยอินเวอร์ส

4 ดีเทอร์มิแนนต์และอินเวอร์สของเมทริกซ์ 2 × 2: สลับแนวทแยงหลัก กลับเครื่องหมายแนวทแยงรอง

$$\det = 3.68 \times 0.85 - (-0.29)^2 = 3.128 - 0.0841 = 3.0439 \qquad (\cdot)^{-1} = \frac{1}{3.0439}\begin{pmatrix} 0.85 & 0.29 \\ 0.29 & 3.68 \end{pmatrix}$$

คูณกับ $Q^T r$

$$p_1 = \frac{0.85(6.85) + 0.29(-2.3625)}{3.0439} = \frac{5.8225 - 0.6851}{3.0439} = 1.6878$$

$$p_2 = \frac{0.29(6.85) + 3.68(-2.3625)}{3.0439} = \frac{1.9865 - 8.6940}{3.0439} = -2.2036$$

ที่มาของข้อมูล: เมทริกซ์ [[3.68, −0.29], [−0.29, 0.85]] และเวกเตอร์ (6.85, −2.3625) มาจากขั้นที่ 2–3 • det = 3.68 × 0.85 − (−0.29)² = 3.128 − 0.0841 = 3.0439 • p_u1 = (0.85 × 6.85 + 0.29 × (−2.3625), 0.29 × 6.85 + 3.68 × (−2.3625)) / 3.0439 = (1.6878, −2.2036)

ตัวอย่างการคำนวณ 5.9 : ขั้นที่ 5 ตรวจคำตอบ และแปลผล

p_{u1}

(1.6878, −2.2036)

ตัวอย่าง i1: 1.0(1.6878) + 0.2(−2.2036) = 1.247

รายการ	$q_i \cdot p_{u1}$	+ μ	คะแนนจริง
i1	1.247	4.872	5
i2	1.299	4.924	5
i3	0.689	4.314	4
i4	−2.504	1.121	1
i6	−2.452	1.173	1

แปลผล

- มิติแรกของ p_{u1} **เป็นบวกมาก** เพราะ u1 ให้คะแนนสูงกับรายการที่มีมิติแรกบวก (i1, i2, i3) และต่ำกับรายการที่มีมิติแรกลบ (i4, i6)
- ALS หาเวกเตอร์ที่อธิบายรูปแบบนี้ได้ดีที่สุด **ในขั้นเดียว** ไม่ต้องขยับทีละก้าวแบบ SGD

ที่มาของข้อมูล: p_u1 = (1.6878, −2.2036) จากขั้นที่ 4 · q_i จากตารางโจทย์ · ค่าทำนาย = q_i · p_u1 + μ (μ = 3.625) เทียบกับคะแนนจริงในแถว u1 ของตารางที่ 5.3 เช่น i4: (−0.7)(1.6878) + 0.6(−2.2036) = −2.504 ⟶ 1.121 เทียบ 1

ตารางที่ 5.13 เปรียบเทียบ SGD กับ ALS

ประเด็น	SGD	ALS
หลักการ	ขยับทีละคะแนนตามเกรเดียนต์	แก้คำตอบรูปปิดทีละฝั่ง
ไฮเพอร์พารามิเตอร์	อัตราการเรียนรู้ η, λ, จำนวนรอบ	λ, จำนวนรอบ
การประมวลผลขนาน	ยากกว่า	ง่าย แต่ละผู้ใช้แยกกัน
ข้อมูลโดยปริยายที่เติมทุกช่อง	ช้ามาก	จัดการได้ดี (หัวข้อ 5.11)
การรับข้อมูลใหม่	ปรับเฉพาะคะแนนใหม่ได้	แก้ใหม่เฉพาะผู้ใช้/รายการที่เปลี่ยน

ส่วนขยาย SVD++ (Koren [12])

- **การเลือกว่าจะให้คะแนนเรื่องใดก็เป็นสารสนเทศ** — ผู้ที่ให้คะแนนแอนิเมชันห้าเรื่อง แม้ให้ต่ำบางเรื่อง ก็บอกได้ว่าสนใจแนวนี้
- เสริมเวกเตอร์ผู้ใช้ด้วยข้อมูลว่าเคยแตะรายการใด • ส่วนหนึ่งของทีมผู้ชนะ Netflix Prize

5.11

ผลป้อนกลับโดยปริยาย: WRMF



แยก "ความชอบ" ออกจาก "ความเชื่อมั่น" • ฝึกด้วย ALS

ข้อมูลโดยปริยายต่างจากคะแนนชัดแจ้งสองประการ

1 ประการแรก

- **ไม่มีตัวอย่างลบที่แน่ชัด**
- การที่ผู้ใช้ไม่เคยกด ไม่ได้แปลว่าไม่ชอบ

2 ประการที่สอง

- **ความเข้มของสัญญาณบอกความเชื่อมั่น**
- ดูซ้ำสามครั้ง น่าเชื่อกว่าดูครั้งเดียว

WRMF — Hu และคณะ [6]

- แยก **ความชอบ** $p_{ui} \in \{0, 1\}$ ออกจาก **ความเชื่อมั่น** $c_{ui} \geq 1$
- ให้ **ทุกช่อง** ของเมทริกซ์มีส่วนในค่าสูญเสีย รวมทั้งช่องว่าง (ด้วยน้ำหนักความเชื่อมั่นต่ำ)

อธิบายแบบเข้าใจง่าย: ความเงียบไม่ได้แปลว่าไม่ชอบ



อธิบายแบบเข้าใจง่าย

เพื่อนไม่เคยพูดถึงร้านอาหารร้านหนึ่ง อาจเพราะไม่ชอบ หรือ **ยังไม่เคยไปเลย** ก็ได้

แต่ถ้าเพื่อนไปร้านนั้น **ทุกสัปดาห์** เรามั่นใจได้มากว่าเพื่อนชอบ

WRMF ให้ทุกช่องมีคำตอบว่าชอบ (1) หรือไม่ได้ชอบ (0) แต่ให้ **น้ำหนักความเชื่อมั่นต่างกัน**

ช่องที่มีหลักฐานชัดได้น้ำหนักสูง ช่องที่เงียบได้น้ำหนักต่ำ → แบบจำลองพยายามทำนาย **ช่องที่มั่นใจ** ให้ถูกเป็นหลัก

ฟังก์ชันเป้าหมายของ WRMF

$$\min_{X,Y} \sum_{u,i} c_{ui} \left(p_{ui} - \mathbf{x}_u \cdot \mathbf{y}_i\right)^2 + \lambda \left(\sum_u \|\mathbf{x}_u\|^2 + \sum_i \|\mathbf{y}_i\|^2 \right)$$

$$c_{ui} = 1 + \alpha \frac{r_{ui}}{5}$$

สมการ (5.11)

ความคลาดเคลื่อนกำลังสองถ่วงด้วยความเชื่อมั่น บน **ทุกช่อง**

โดยที่

- p_{ui} = 1 เมื่อ $r_{ui} \geq 4$ · นอกนั้น 0
- c_{ui} = 1 + α r_{ui}/5 กับ α = 10 สำหรับช่องที่มีคะแนน · ช่องว่าง c = 1
- x_u, y_i = เวกเตอร์ปัจจัยแฝง

ข้อสังเกต

- ผลรวม $\sum_{u,i}$ คิด **ทุกช่อง** (ต่างจาก MF ที่คิดเฉพาะ K)
- → ใช้ SGD ทีละช่องช้ามาก จึงฝึกด้วย ALS

ที่มาของข้อมูล: ค่าที่แทนในสมการ (5.11) แปลงจากตารางที่ 5.3: p_ui = 1 เมื่อคะแนน ≥ 4 นอกนั้น 0 · c_ui = 1 + α r_ui/5 กับ α = 10 สำหรับช่องที่มีคะแนน · ช่องว่าง c = 1 · ผลรวมคิดทุกช่อง 96 ช่อง · ตัวอย่างของ u1 อยู่ในตารางที่ 5.14

ตัวอย่างการคำนวณ: ความชอบและความเชื่อมั่นของ u1 (ตารางที่ 5.14)

รายการ	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12
คะแนน	5	5	4	1	·	1	·	·	·	·	·	·
ความชอบ p	1	1	1	0	0	0	0	0	0	0	0	0
ความเชื่อมั่น c	11	11	9	3	1	3	1	1	1	1	1	1

1 แทนค่า $c = 1 + \alpha\, r/5$ ($\alpha = 10$)

$$r = 5:\ c = 1 + 10 \times \frac{5}{5} = 1 + 10 = 11$$

$$r = 4:\ c = 1 + 10 \times \frac{4}{5} = 1 + 8 = 9$$

$$r = 1:\ c = 1 + 10 \times \frac{1}{5} = 1 + 2 = 3$$

$$\text{empty}:\ c = 1$$

สังเกต

- คะแนน 1 → **ตัวอย่างลบที่เชื่อมั่นปานกลาง** ($c = 3$)
- ช่องว่าง → ตัวอย่างลบที่เชื่อมั่นต่ำ ($c = 1$)
- ทั้งสองมี $p = 0$ เหมือนกัน แต่น้ำหนักต่างกัน

ที่มาของข้อมูล: แถวคะแนนคือแถว u1 ของตารางที่ 5.3 · $p = 1$ เมื่อคะแนน ≥ 4 · $c = 1 + \alpha\, r/5$ กับ $\alpha = 10$: $r = 5 \Rightarrow 1 + 10 = 11$, $r = 4 \Rightarrow 1 + 8 = 9$, $r = 1 \Rightarrow 1 + 2 = 3$ · ช่องว่างได้ $c = 1$ ($p = 0$)

ฝึกคำนวณเพิ่ม: น้ำหนักความเชื่อมั่นเปลี่ยน "ราคาของความผิด" อย่างไร

1 สมมติแบบจำลองทำนาย $x_u \cdot y_i = 0.8$ เท่ากันในสามช่อง (ค่าสมมติเพื่อการสอน)

$$i1\ (p=1,\ c=11):\ 11\,(1-0.8)^2 = 11(0.04) = 0.44$$

$$i4\ (p=0,\ c=3):\ 3\,(0-0.8)^2 = 3(0.64) = 1.92$$

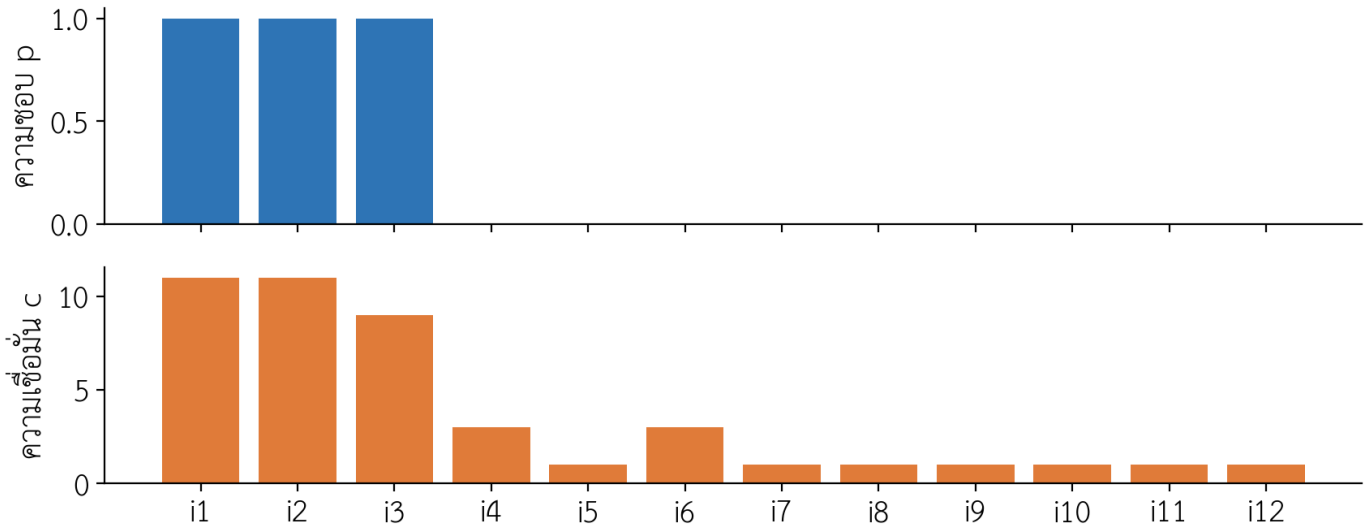
$$i5\ (p=0,\ c=1):\ 1\,(0-0.8)^2 = 1(0.64) = 0.64$$

แปลผล

- ทำนาย 0.8 ให้ **เรื่องที่ u1 ให้ 1 คะแนน** แพงกว่าให้ช่องว่างถึง **3 เท่า** → ALS จะดันค่าทำนายของ i4 ลงก่อน
- ช่องว่างยังมีส่วนในค่าสูญเสีย แต่ "เสียงเบา" กว่า

ที่มาของข้อมูล: p และ c ของ i1 (1, 11), i4 (0, 3), i5 (0, 1) มาจากตารางที่ 5.14 • ค่าทำนาย 0.8 เป็นค่าสมมติเพื่อการสอน • ค่าสูญเสียต่อช่อง = c(p − 0.8)² ตามสมการ (5.11) ⟶ 0.44, 1.92, 0.64

ภาพที่ 5.9 ความชอบและความเชื่อมั่นของ u1



ภาพที่ 5.9 ความชอบ (บน) และความเชื่อมั่น (ล่าง) ของ u1 ในข้อมูลโดยปริยาย

ผลการฝึก WRMF

- $k = 2$, $\lambda = 0.1$, 15 รอบ (ALS)
- Top-3 ของ u1: **i9 Conclave (0.8217)** · **i8 Furiosa (0.7671)** · **i7 Ballerina (0.7644)**
- ค่าที่ได้คือ **คะแนนความชอบ** ที่ประมาณ p_{ui} ไม่ใช่คะแนน 1–5
- คล้าย User-kNN และ Item-kNN เพราะ u4, u5 (ชอบเรื่องเดียวกับ u1 บางเรื่อง) ชอบ i7, i8, i9

5.12

จากการทำนายคะแนนสู่การจัดอันดับ



BPR (เรียนเฉพาะลำดับ) • EASE (แบบจำลองเชิงเส้นรูปปิด)

ผู้ใช้ไม่ได้เห็นค่าทำนายคะแนน ผู้ใช้เห็นรายการสิบอันดับแรก

แบบจำลองที่ **ทำนายคะแนนได้แม่น** ไม่จำเป็นต้อง **จัดอันดับได้ดี** — หัวข้อนี้แนะนำสองแบบจำลองที่ออกแบบมาเพื่อการจัดอันดับจากข้อมูลโดยปริยายโดยตรง

BPR (Bayesian Personalized Ranking) [7]

- สร้าง **ชุดสาม (u, i, j)**: i = ชอบ, j = สุ่มจากที่ไม่ได้ชอบ
- เพิ่มความน่าจะเป็นที่ i อยู่เหนือ j
- ฝึกด้วย SGD

EASE (Embarrassingly Shallow Autoencoder) [13]

- เรียนเมทริกซ์น้ำหนักรายการ–รายการ B
- ห้ามใช้ตัวเองทำนาย diag(B) = 0
- มี **คำตอบรูปปิด** ไม่ต้องใช้ SGD

อธิบายแบบเข้าใจง่าย: BPR ถามเพียงว่า "เรื่องไหนน่าดูกว่า"



อธิบายแบบเข้าใจง่าย

ถามว่า "จะให้ภาพยนตร์เรื่องนี้กี่ดาว" → **ตอบยาก**

ถามว่า "ระหว่าง Toy Story 5 กับ Conclave อยากดูเรื่องไหนมากกว่า" → **ตอบง่ายกว่ามาก**

BPR เรียนจากคำถามแบบจับคู่นี้ ทุกครั้งที่จัดเรื่องที่ไม่ได้ชอบไว้เหนือเรื่องที่ชอบ ก็ถูกปรับให้สลับลำดับ

ผลคือแบบจำลองเก่ง **การเรียงลำดับ** ซึ่งตรงกับสิ่งที่ผู้ใช้เห็นบนหน้าจอ

5.12.1 BPR: ค่าสูญเสียเชิงลำดับ

$$\hat{x}_{uij} = \hat{x}_{ui} - \hat{x}_{uj} \qquad \mathcal{L} = -\sum_{(u,i,j)} \ln \sigma(\hat{x}_{uij}) \qquad \sigma(x) = \frac{1}{1+e^{-x}}$$

สมการ (5.12)

ลบลอการิทึมของซิกมอยด์ของผลต่างคะแนน

โดยที่

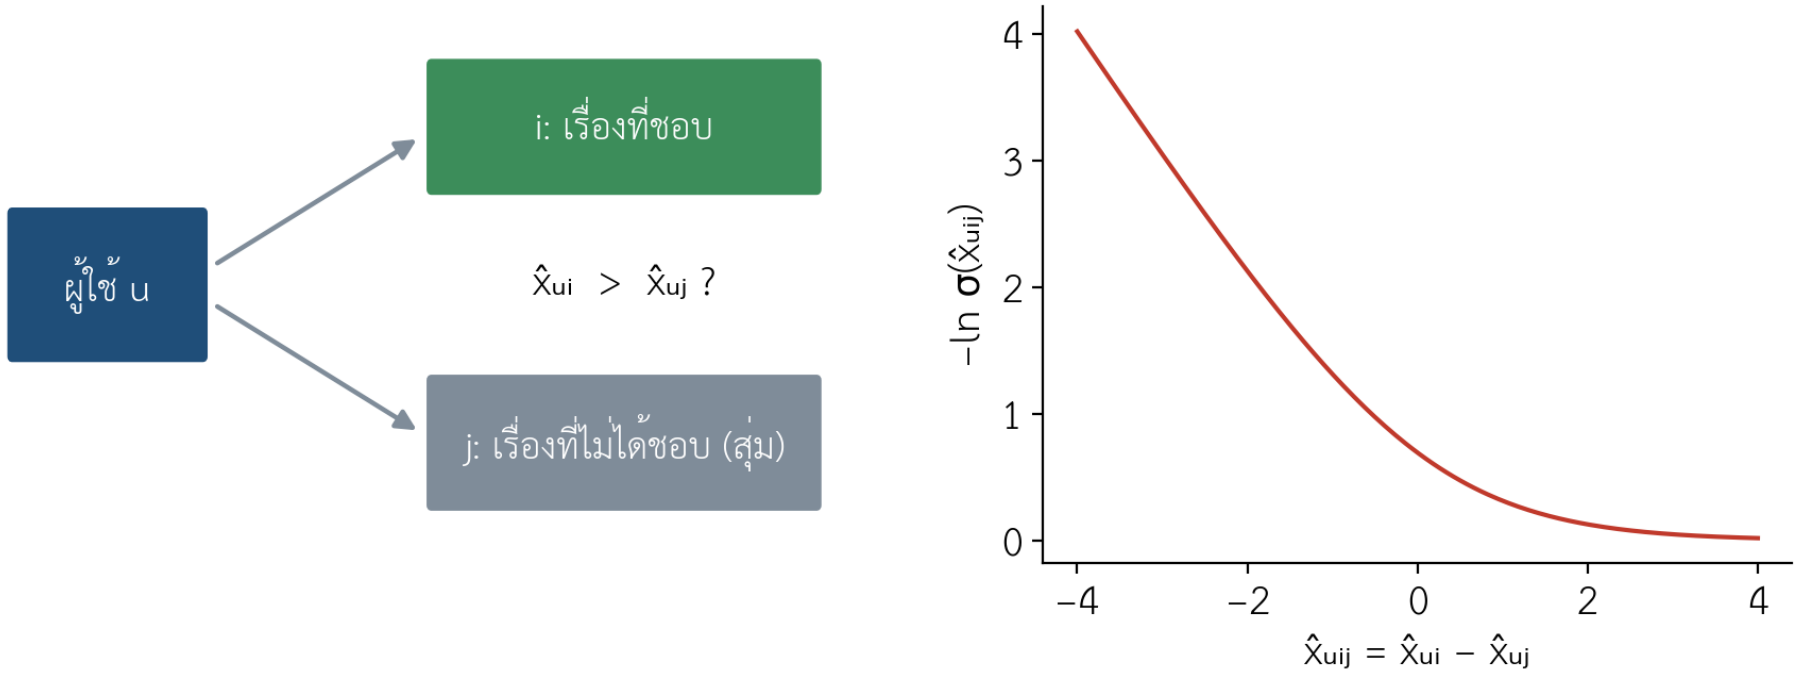
- $\hat{x}_{ui} = p_u \cdot q_i$ คะแนนของรายการ i
- σ แปลงผลต่างเป็นความน่าจะเป็น 0–1 ว่า i อยู่เหนือ j
- สนใจเพียง **ลำดับ** ไม่สนใจค่าคะแนนจริง

กฎการปรับ (SGD)

- $s = 1 - \sigma(\hat{x}_{uij})$ = ขนาดของความผิด
- $p_u \leftarrow p_u + \eta\, s\, (q_i - q_j)$
- $q_i \leftarrow q_i + \eta\, s\, p_u \cdot q_j \leftarrow q_j - \eta\, s\, p_u$
- (ตัวอย่างละเรกูลาไรเซชันไว้)

ที่มาของข้อมูล: ข้อมูลของสมการ (5.12) คือชุดสาม (u, i, j) ที่สร้างจากตารางที่ 5.3: i = เรื่องที่ u ชอบ (คะแนน ≥ 4) และ j = เรื่องที่ไม่ได้ชอบ (คะแนน 1–3 หรือช่องว่าง) สุ่มมาหนึ่งเรื่อง • คู่ชอบทั้งหมด 20 คู่ • $\hat{x}_{ui} = p_u \cdot q_i$

ภาพที่ 5.10 BPR เรียนจากชุดสาม



ภาพที่ 5.10 BPR เรียนจากชุดสาม และค่าสูญเสียสูงเมื่อรายการที่ไม่ได้ชอบถูกจัดไว้เหนือรายการที่ชอบ

กราฟขวา: $\hat{x}_{uij}$ ติดลบมาก (จัด j เหนือ i) → ค่าสูญเสียสูง · $\hat{x}_{uij}$ บวกมาก → ค่าสูญเสียเข้าใกล้ 0

ตัวอย่างการคำนวณ 5.10 หนึ่งก้าวของ BPR บนชุดสาม (u1, i3, i10) : โจทย์

พารามิเตอร์	ค่าเริ่มต้น
p_{u1}	(0.2, 0.1)
q_{i3} (ชอบ)	(0.1, 0.3)
q_{i10} (ไม่ได้ชอบ)	(0.3, 0.1)
η	0.1 (ไม่ใช้เรกูลาไรเซชัน)

โจทย์

- u1 **ชอบ** i3 และ **ไม่ได้ชอบ** i10
- จงปรับพารามิเตอร์หนึ่งก้าว แล้วตรวจว่าแบบจำลองขยับไปทางที่ถูกหรือไม่

แผนการคำนวณ

$\hat{x}_{uij} \rightarrow \sigma$, s, ค่าสูญเสีย $\rightarrow$ ขนาดการขยับ ηs $\rightarrow$ ปรับสามเวกเตอร์ $\rightarrow$ $\hat{x}_{uij}$ ใหม่

ที่มาของข้อมูล: ชุดสาม (u1, i3, i10) มาจากตารางที่ 5.3: u1 ให้ i3 = 4 (ชอบ ตามเกณฑ์ ≥ 4) และ i10 เป็นช่องว่างในแถว u1 (ไม่ได้ชอบ) • ค่าเริ่มต้น p_u1, q_i3, q_i10 เป็นค่าสมมติขนาดเล็ก • η = 0.1 และละเรกูลาไรเซชันเพื่อให้คำนวณมือได้

ตัวอย่างการคำนวณ 5.10 : ขั้นที่ 1–2

1 ผลต่างคะแนน — ติดลบ แปลว่าแบบจำลองยังจัด i10 ไว้เหนือ i3

$$\hat{x}_{uij} = \mathbf{p}_{u1} \cdot (\mathbf{q}_{i3} - \mathbf{q}_{i10}) = (0.2,\, 0.1) \cdot (-0.2,\, 0.2) = -0.04 + 0.02 = -0.0200$$

2 ซิกมอยด์ ขนาดความผิด และค่าสูญเสีย

$$\sigma(-0.02) = \frac{1}{1 + e^{0.02}} = \frac{1}{2.0202} = 0.4950 \qquad s = 1 - 0.4950 = 0.5050 \qquad -\ln(0.4950) = 0.7032$$

ที่มาของข้อมูล: ค่าเริ่มต้นจากสไลด์โจทย์: $\hat{x}_{u1,i3} = 0.2(0.1) + 0.1(0.3) = 0.05$ • $\hat{x}_{u1,i10} = 0.2(0.3) + 0.1(0.1) = 0.07$ • ผลต่าง -0.02 • $\sigma(-0.02) = 0.4950$ • $s = 1 - 0.4950 = 0.5050$ • ค่าสูญเสีย $= -\ln 0.4950 = 0.7032$

ตัวอย่างการคำนวณ 5.10 : ขั้นที่ 3–4

3 ขนาดการขยับ $\eta_s = 0.1 \times 0.5050 = 0.0505$ แล้วปรับทั้งสามเวกเตอร์ (ใช้ค่าเดิมทั้งหมด)

$$\mathbf{p}_{u1} = (0.2,\ 0.1) + 0.0505\,(-0.2,\ 0.2) = (0.1899,\ 0.1101)$$

$$\mathbf{q}_{i3} = (0.1,\ 0.3) + 0.0505\,(0.2,\ 0.1) = (0.1101,\ 0.3050)$$

$$\mathbf{q}_{i10} = (0.3,\ 0.1) - 0.0505\,(0.2,\ 0.1) = (0.2899,\ 0.0950)$$

4 ตรวจผลต่างใหม่ — เพิ่มขึ้นจาก −0.0200 → ขยับไปทางที่จัด i3 เหนือ i10

$$\hat{x}_{uij}^{\text{new}} = (0.1899,\ 0.1101) \cdot (-0.1798,\ 0.2100) = -0.0341 + 0.0231 = -0.0110$$

ที่มาของข้อมูล: $\eta_s = 0.1 \times 0.5050 = 0.0505$ (s จากขั้นที่ 2) • p ⟵ (0.2, 0.1) + 0.0505(q_i3 − q_i10) = (0.1899, 0.1101) • q_i3 ⟵ q_i3 + 0.0505 p = (0.1101, 0.30505) • q_i10 ⟵ q_i10 − 0.0505 p = (0.2899, 0.09495) • ผลต่างใหม่ −0.0110

ผล BPR บน MovieMini-12 และข้อควรระวัง

ผลการฝึก (k = 2, 400 รอบ, เมล็ดสุ่มเดียว)

Top-3 ของ u1: **i5 Wicked (0.9635)** • i12 Project Hail Mary (0.3338) • i11 Mickey 17 (0.1344) — **ต่างจาก WRMF มาก**



1 สาเหตุที่ 1

- BPR **ไม่แยกคะแนน 1** (ไม่ชอบชัดเจน) ออกจากช่องว่าง
- ทั้งสองเป็น "ไม่ได้ชอบ" เหมือนกัน

2 สาเหตุที่ 2

- การสุ่มตัวอย่างลบบนข้อมูลเพียง **20 คู่ชอบ** → ผลแปรปรวนตามเมล็ดสุ่มมาก
- ควรรายงานจาก **หลายเมล็ดสุ่ม** (บทที่ 2)

ที่มาของข้อมูล: ฝึก BPR บนคู่ชอบ 20 คู่ของตารางที่ 5.3 (k = 2, 400 รอบ, เมล็ดสุ่มเดียว) ตัวอย่างลบสุ่มจากเรื่องที่ไม่ได้ชอบ • ค่าในวงเล็บ = $\hat{x}_{u1,i} = p_{u1} \cdot q_i$ ของผู้สมัคร 7 เรื่อง (i5, i7–i12) • ค่าขึ้นกับเมล็ดสุ่ม คำนวณมือไม่ได้

5.12.2 EASE: สูตรรูปปิดสี่ขั้น (X = เมทริกซ์ชอบ 1 / ไม่ได้ชอบ 0)

1 นับการชอบร่วม

$$G = X^\top X$$

G_{ij} = จำนวนผู้ใช้ที่ชอบทั้ง i และ j

2 บวก λ แล้วหาอินเวอร์ส

$$\hat{P} = (G + \lambda I)^{-1}$$

λ ที่แนวทแยงทำหน้าที่เรกูลาไรเซชัน

3 หารด้วยแนวทแยง กลับเครื่องหมาย

$$B_{ij} = -\hat{P}_{ij} / \hat{P}_{jj},\ B_{jj} = 0$$

ห้ามใช้ตัวเองทำนาย

4 ให้คะแนน

$$S = XB$$

ผลรวมแถวของ B ของทุกเรื่องที่ผู้ใช้ชอบ

อธิบายแบบเข้าใจง่าย: ตาราง "ชอบเรื่องนี้ มักชอบเรื่องนั้น" ที่หักการนับซ้ำแล้ว

ขั้นที่ 1 เหมือน Item-kNN (นับว่าคนที่ชอบเรื่องหนึ่งชอบเรื่องอื่นด้วยกี่คน) แต่ขั้นที่ 2–3 ใช้อินเวอร์สเพื่อ **"หักหลักฐานที่ซ้ำกัน"** — ถ้าสองเรื่องได้รับความนิยมจากคนกลุ่มเดียวกันเสมอ เรื่องที่สองจะไม่ได้เครดิตซ้ำ

ที่มาของข้อมูล: X แปลงจากตารางที่ 5.3: X_ui = 1 เมื่อคะแนน ≥ 4 นอกนั้น 0 (ขนาด 8 × 12) • $G = X^\top X$ นับจำนวนผู้ชอบร่วมของทุกคู่รายการ • λ = 5 สำหรับคลังเต็ม (โปรแกรมที่ 5.10) และ λ = 1 สำหรับคลังย่อยในตัวอย่าง 5.11

ตัวอย่างการคำนวณ 5.11 EASE บนคลังย่อยสามเรื่อง i1, i2, i3 : ขั้นที่ 1

เมทริกซ์ชอบ X (เฉพาะผู้ที่ชอบ i1–i3)

ผู้ใช้	i1	i2	i3
u1	1	1	1
u4	1	0	0
u5	0	0	1
u6	0	1	0

1 **ขั้นที่ 1 นับการชอบร่วม**

$$G = X^\top X = \begin{pmatrix} 2 & 1 & 1 \\ 1 & 2 & 1 \\ 1 & 1 & 2 \end{pmatrix}$$

- แนวทแยง = จำนวนผู้ชอบแต่ละเรื่อง (2 คน)
- นอกแนวทแยง = จำนวนผู้ชอบทั้งคู่ = **u1 คนเดียว**

ตัวอย่าง G_{12}: ผู้ที่ชอบทั้ง i1 และ i2 → แถว u1 เท่านั้น (1·1) → $G_{12} = 1$ · G_{11}: ผู้ชอบ i1 = u1, u4 → 2

ที่มาของข้อมูล: X ได้จากตารางที่ 5.3 คอลัมน์ i1–i3 เฉพาะผู้ที่ชอบ (คะแนน ≥ 4): u1 ชอบทั้งสาม (5, 5, 4) · u4 ชอบ i1 (4) · u5 ชอบ i3 (4) · u6 ชอบ i2 (5) · ผู้ใช้อื่นไม่ได้ชอบเรื่องใดในสามเรื่องนี้ (u2 ให้ i1 = 2, u7 ให้ i3 = 3, u8 ให้ i2 = 2)

ตัวอย่างการคำนวณ 5.11 : ขั้นที่ 2–3 ($\lambda = 1$)

2 บวก λI แล้วหาอินเวอร์ส และตรวจคำตอบด้วยการคูณกลับ

$$G + I = \begin{pmatrix} 3 & 1 & 1 \\ 1 & 3 & 1 \\ 1 & 1 & 3 \end{pmatrix} \qquad \hat{P} = \begin{pmatrix} 0.4 & -0.1 & -0.1 \\ -0.1 & 0.4 & -0.1 \\ -0.1 & -0.1 & 0.4 \end{pmatrix}$$

$$3(0.4) + 1(-0.1) + 1(-0.1) = 1$$
$$3(-0.1) + 1(0.4) + 1(-0.1) = 0$$

3 หารแต่ละคอลัมน์ด้วยแนวทแยง กลับเครื่องหมาย และตั้งแนวทแยงเป็น 0

$$B_{ij} = -\frac{\hat{P}_{ij}}{\hat{P}_{jj}} = -\frac{-0.1}{0.4} = 0.25 \ (i \neq j) \qquad B = \begin{pmatrix} 0 & 0.25 & 0.25 \\ 0.25 & 0 & 0.25 \\ 0.25 & 0.25 & 0 \end{pmatrix}$$

ที่มาของข้อมูล: G = [[2,1,1],[1,2,1],[1,1,2]] จากขั้นที่ 1 • $\lambda = 1 \longrightarrow$ G + I = [[3,1,1],[1,3,1],[1,1,3]] • อินเวอร์ส P: แนวทแยง 0.4 นอกแนวทแยง −0.1 (ตรวจ: 3(0.4) + 1(−0.1) + 1(−0.1) = 1) • B_ij = −(−0.1)/0.4 = 0.25 และ B_jj = 0

ตัวอย่างการคำนวณ 5.11 : ขั้นที่ 4 ให้คะแนน และแปลผล

4 ขั้นที่ 4 (ฝึกเพิ่ม): ผู้ใช้ที่ชอบเฉพาะ i1

$$\mathbf{x} = (1, 0, 0) \;\Rightarrow\; \mathbf{x}B = (0,\ 0.25,\ 0.25)$$

ผู้ใช้ที่ชอบ i1 ได้คะแนน 0.25 สำหรับ i2 และ i3

แปลผล

- EASE เรียนว่าสามเรื่องนี้ **"มาด้วยกัน"** เพราะ u1 ชอบทั้งสามเรื่อง
- ผู้ใช้อื่นชอบเพียงเรื่องเดียว → น้ำหนัก **บวกแต่ไม่สูงมาก**

เมื่อคำนวณกับคลังเต็ม 12 เรื่อง ($\lambda = 5$)

- แถว i1 ของ B: ค่าเด่นที่ **i2, i3 (0.1300)** และ **i7, i8 (0.1267)** — ตรงกับผู้ชอบ Toy Story 5 สองคน: u1 (ชอบ i2, i3) และ u4 (ชอบ i7, i8)
- คะแนนของ u1 = ผลรวมน้ำหนักจาก i1, i2, i3 → Top-3: **i9 (0.1102)** • **i5 (0.1101)** • **i7 (0.0944)**
- i10, i11, i12 ได้ **0** เพราะไม่มีใครชอบเรื่องเหล่านี้ร่วมกับเรื่องที่ u1 ชอบ

ที่มาของข้อมูล: ผู้ใช้ที่ชอบเฉพาะ i1 มี x = (1, 0, 0) ⟶ คะแนน = แถว i1 ของ B = (0, 0.25, 0.25) จากขั้นที่ 3 • คลังเต็ม: X 8 × 12 จากตารางที่ 5.3, λ = 5 (โปรแกรมที่ 5.10) • คะแนน u1 = แถว B ของ i1 + i2 + i3 เช่น i9: −0.0193 − 0.0188 + 0.1483 = 0.1102

5.12.3 เลือกแบบจำลองสำหรับข้อมูลโดยปริยาย (ตารางที่ 5.15)

ประเด็น	WRMF	BPR	EASE
สิ่งที่เรียน	ความชอบทุกช่อง ถ่วงด้วยความเชื่อมั่น	ลำดับระหว่างเรื่องที่ชอบกับไม่ได้ชอบ	น้ำหนักรายการ–รายการ
วิธีฝึก	ALS	SGD + สุ่มตัวอย่างลบ	คำตอบรูปปิด
ใช้ความเข้มของสัญญาณ	ได้ ผ่าน c_{ui}	ไม่ได้โดยตรง	ไม่ได้ (0/1)
ต้นทุนเมื่อรายการมาก	เพิ่มเชิงเส้นตามรายการ	เพิ่มเชิงเส้นตามคู่ชอบ	อินเวอร์ส $\|\|\| \times \|\|\|$ แพง
จุดเด่น	เสถียร เหมาะข้อมูลการดู/ฟัง	ตรงกับเป้าหมายการจัดอันดับ	ง่ายมาก ระบบฐานที่แข็งแรง

EASE

- เริ่มที่นี่เมื่อรายการ $\leq$ หลักหมื่น
- ปรับเพียง λ

WRMF

- เมื่อมีสัญญาณความเข้ม เช่น จำนวนครั้ง/เวลาที่ดู

BPR

- เมื่อเป็นส่วนของโครงข่ายใหญ่ที่ฝึกด้วย SGD อยู่แล้ว (บทที่ 6)

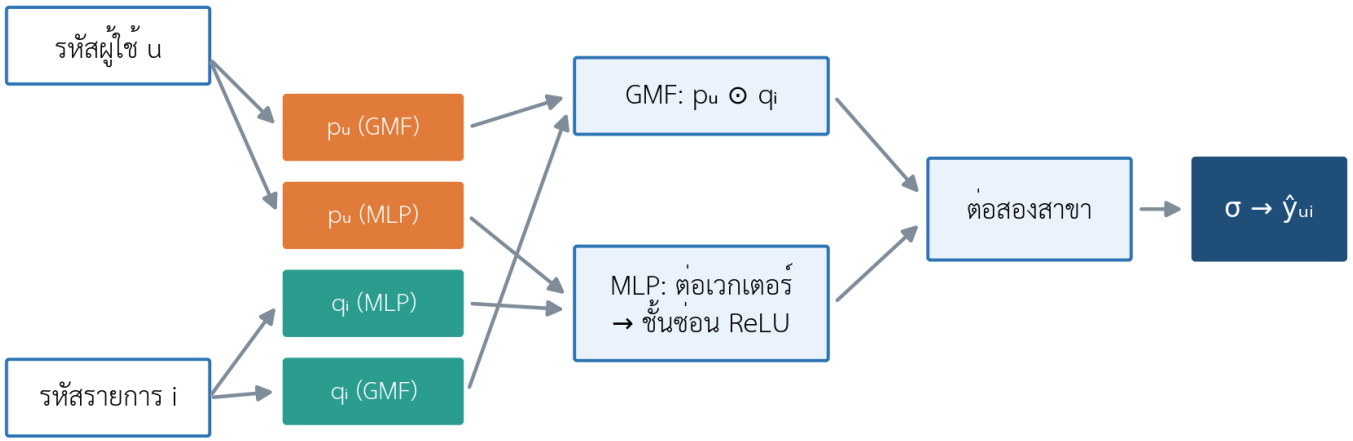
5.13

การกรองร่วมเชิงประสาท (NCF)



NeuMF = GMF + MLP • ข้อถกเถียงเรื่องระบบฐาน

สถาปัตยกรรม NeuMF



ภาพที่ 5.11 สถาปัตยกรรม NeuMF: สาขา GMF และสาขา MLP รวมกันที่ชั้นผลลัพธ์

NCF — He และคณะ [8]

- แทนผลคูณจุด $p_u \cdot q_i$ (เชิงเส้น) ด้วย **โครงข่ายประสาท**
- GMF: คูณทีละมิติ $p_u \odot q_i$ — รูปทั่วไปของ MF
- MLP: ต่อเวกเตอร์ผู้ใช้กับรายการ → ชั้นซ่อน ReLU หลายชั้น → ปฏิสัมพันธ์ไม่เชิงเส้น
- ต่อสองสาขา → ซิกมอยด์ → ความน่าจะเป็นที่จะโต้ตอบ

ฝึกคำนวณเพิ่ม: GMF คือรูปทั่วไปของ MF (ค่าสมมติเพื่อการสอน)

1 คูณทีละมิติ (Element-wise product)

$$\mathbf{p}_u = (0.5,\ -0.2),\ \mathbf{q}_i = (0.4,\ 0.3) \ \Rightarrow\ \mathbf{p}_u \odot \mathbf{q}_i = (0.5 \times 0.4,\ -0.2 \times 0.3) = (0.20,\ -0.06)$$

2 ชั้นผลลัพธ์ h · (p ⊙ q) แล้วผ่านซิกมอยด์

$$\mathbf{h} = (1,\ 1):\ 0.20 - 0.06 = 0.14 = \mathbf{p}_u \cdot \mathbf{q}_i \ \Rightarrow\ \sigma(0.14) = 0.5349$$

$$\mathbf{h} = (2,\ 0.5):\ 0.40 - 0.03 = 0.37 \ \Rightarrow\ \sigma(0.37) = 0.5915$$

สรุป

h = (1, 1) ได้ผลคูณจุดของ MF พอดี → GMF **เรียนน้ำหนักของแต่ละมิติ** ได้เพิ่มเติม

ที่มาของข้อมูล: p_u = (0.5, −0.2), q_i = (0.4, 0.3) และ h เป็นค่าสมมติเพื่อการสอน (ไม่ได้มาจากตารางที่ 5.3) · p ⊙ q = (0.5×0.4, −0.2×0.3) = (0.20, −0.06) · h = (1, 1) → 0.14 = p · q ของ MF · σ(0.14) = 1/(1 + e^−0.14) = 0.5349

ข้อถกเถียงเรื่อง NCF: บทเรียนเชิงระเบียบวิธี

NCF ได้รับความนิยมสูงหลังตีพิมพ์

- แต่ Rendle และคณะ [14] แสดงว่า **MF ผลคูณจุดที่ปรับไฮเพอร์พารามิเตอร์ดี** ทำได้ดีกว่า NCF บนชุดข้อมูลเดิม
- MLP เรียนฟังก์ชันผลคูณจุดได้ยากกว่าที่คาด

บทเรียน

- แบบจำลองใหม่ต้องเทียบกับ **ระบบฐานที่ปรับจูนดีแล้ว** เสมอ
- สอดคล้องกับวิกฤตการทำซ้ำผลในบทที่ 2

ต่อยอด

การกรองร่วมบนกราฟ เช่น **LightGCN** ส่งเวกเตอร์ผ่านกราฟผู้ใช้–รายการหลายชั้น → อธิบายในบทที่ 7

5.14

การประเมินผล: ทำนายคะแนนหรือจัดอันดับ



RMSE/MAE • HR@3 • MRR • nDCG@3 • ค่าคาดหมายเมื่อคะแนนเสมอ • Bootstrap

วิธีใดดีจริงบน MovieMini-12 และจะรู้ได้อย่างไร

1 แบบที่ 1: ทำนายคะแนน

- วัดว่าทำนายคะแนน 1–5 ได้ **ใกล้ค่าจริง** เพียงใด
- ตัวชี้วัด: RMSE, MAE
- ซ่อนคะแนน **ทีละค่า** ครบ 32 ค่า

2 แบบที่ 2: จัดอันดับ

- วัดว่ารายการที่ชอบจริงถูกจัดไว้ **อันดับต้น** หรือไม่
- ตัวชี้วัด: HR@3, MRR, nDCG@3
- กันออกทีละรายการที่ชอบ 20 **กรณี**

บทที่ 2 เตือนไว้แล้วว่าสองคำถามนี้ **อาจให้คำตอบต่างกันมาก** — ทุกวิธีถูกฝึกใหม่โดยไม่เห็นคะแนนที่ซ่อน และตัดค่าทำนายให้อยู่ในช่วง 1–5 ก่อนคำนวณ

5.14.1 ความแม่นยำของการทำนายคะแนน (กันออกทีละคะแนน)

$$\text{RMSE} = \sqrt{\frac{1}{|K|} \sum_{(u,i) \in K} \left(\hat{r}_{ui}^{(-ui)} - r_{ui} \right)^2} \qquad \text{MAE} = \frac{1}{|K|} \sum_{(u,i) \in K} \left| \hat{r}_{ui}^{(-ui)} - r_{ui} \right|$$

สมการ (5.13)

ความคลาดเคลื่อนเฉลี่ยเมื่อทำนายคะแนนที่ถูกซ่อน

โดยที่

- $\hat{r}^{(-ui)}$ = ค่าทำนายจากแบบจำลองที่ **ฝึกโดยไม่เห็น** r_{ui}
- $|K|$ = 32 คะแนน → ฝึกใหม่ 32 ครั้ง

ทบทวน

- RMSE ลงโทษความผิดก้อนใหญ่มากกว่า MAE
- นิยามเดียวกับบทที่ 2

ที่มาของข้อมูล: ค่าที่แทนในสมการ (5.13): r_ui = คะแนนที่ถูกซ่อนจาก 32 ช่องของตารางที่ 5.3 • r^(−ui) = ค่าทำนายจากแบบจำลองที่ฝึกใหม่โดยไม่เห็นคะแนนนั้น (ตัดค่า 1–5) • |K| = 32 ⟶ ฝึกใหม่ 32 ครั้ง • ผลอยู่ในตารางที่ 5.12 และ 5.16

ฝึกคำนวณเพิ่ม: "ค่าเฉลี่ยรวม" แบบกันออก บนคะแนน 3 ค่าของ u1

1 ซ่อนทีละค่า แล้วคำนวณ μ ใหม่จากอีก 31 คะแนน (ผลรวมเดิม 116)

$$\text{hide } r_{u1,i1} = 5: \ \hat{r} = \frac{116-5}{31} = 3.5806, \quad e = -1.4194$$

$$\text{hide } r_{u1,i3} = 4: \ \hat{r} = \frac{116-4}{31} = 3.6129, \quad e = -0.3871$$

$$\text{hide } r_{u1,i4} = 1: \ \hat{r} = \frac{116-1}{31} = 3.7097, \quad e = +2.7097$$

2 MAE และ RMSE ของสามกรณีนี้

$$\text{MAE} = \frac{1.4194 + 0.3871 + 2.7097}{3} = 1.5054 \qquad \text{RMSE} = \sqrt{\frac{2.0146 + 0.1498 + 7.3424}{3}} = \sqrt{3.1689} = 1.7801$$

ทำแบบนี้ครบ 32 คะแนน → ได้ค่าในแถว "ค่าเฉลี่ยรวม" ของตารางที่ 5.16

ที่มาของข้อมูล: คะแนนของ u1 ที่ซ่อน: i1 = 5, i3 = 4, i4 = 1 (แถว u1 ตารางที่ 5.3) • ผลรวมเดิม 116 จากตัวอย่าง 5.1 → μ ใหม่ = (116 − r)/31 เช่น (116 − 5)/31 = 3.5806 • e = ค่าทำนาย − ค่าจริง → MAE 1.5054, RMSE 1.7801

ตารางที่ 5.16 ความคลาดเคลื่อนของการทำนายคะแนนแบบกันออกทีละคะแนน (32 ครั้ง)

วิธี	RMSE	MAE
ค่าเฉลี่ยรวม	1.4541	1.2581
ค่าเฉลี่ยของผู้ใช้	1.8226	1.5625
ค่าเฉลี่ยของรายการ	2.2006	1.9194
ค่าเอนเอียง ($\lambda = 2$)	1.9531	1.7139
User-kNN ($k = 3$)	1.8534	1.5234
Item-kNN ($k = 3$)	1.6331	1.2969
MF-SGD ($k = 2$, $\lambda = 0.5$)	1.9803	1.7105

ทำไมค่าเฉลี่ยรวมชนะ

- คะแนนสุดขั้ว: ซ่อน 5 ของผู้ใช้ที่มีคะแนน 4 ค่า → ค่าเฉลี่ยถูกดึงลงแรง
- รายการมีคะแนน 2–3 ค่า → ซ่อนหนึ่งค่าเปลี่ยนค่าเฉลี่ยมาก
- พารามิเตอร์มากกว่าข้อมูล → เรียนรู้เกิน

ข้อสรุป

- **ไม่ได้** แปลว่า CF ใช้ไม่ได้
- บนข้อมูลเล็กมาก การทำนายคะแนนยากกว่าที่คิด และระบบฐานที่ง่ายเป็นคู่เทียบที่ขาดไม่ได้

ที่มาของข้อมูล: ทุกแถวซ่อนคะแนนทีละค่าครบ 32 ค่าของตารางที่ 5.3 ทำนายใหม่จากข้อมูลที่เหลือ แล้วใช้สมการ (5.13) • ค่าเฉลี่ยรวม = ค่าเฉลี่ยของ 31 คะแนนที่เหลือ • ค่าเฉลี่ยผู้ใช้/รายการ = คะแนนที่เหลือของผู้ใช้/รายการนั้น • ค่าเอนเอียงใช้สมการ (5.7) • User/Item-kNN ใช้ (5.4)/(5.6) • MF ใช้โปรแกรมที่ 5.7 ($\lambda = 0.5$)

5.14.2 การจัดอันดับบนโปรโตคอลเดียวกับบทที่ 3–4

โปรโตคอล

- กันออกทีละรายการที่ชอบ 20 **กรณี** ชุดเดียวกับบทที่ 3–4
- ฝึกใหม่ทุกครั้งโดยไม่เห็นคะแนนที่ซ่อน
- ผู้สมัคร = เรื่องที่ยังไม่มีคะแนน + เรื่องที่ถูกซ่อน

ปัญหาใหม่: คะแนนเสมอ

- แบบจำลองเพื่อนบ้านและความนิยมให้ **คะแนนเสมอกันบ่อยมาก**
- ถ้าเรียงคะแนนเสมอตามเลขรหัส ผลขึ้นกับว่ารายการที่ซ่อนมีรหัสเล็กหรือใหญ่ — **ไม่เกี่ยวกับคุณภาพ**

อธิบายแบบเข้าใจง่าย: คะแนนเสมอคือการจับสลาก

เรื่องที่ซ่อนได้คะแนนเท่ากับอีก 3 เรื่อง และมีเรื่องที่สูงกว่า 1 เรื่อง → ถ้าจับสลาก เรื่องที่ซ่อนมีโอกาสเท่า ๆ กันที่จะอยู่อันดับ 2, 3, 4 หรือ 5 → รายงาน **ค่าคาดหมาย** ซึ่งยุติธรรมกว่าการเรียงตามเลขรหัส

ค่าคาดหมายของ RR และ HR@3 เมื่อมีคะแนนเสมอ

$$\mathbb{E}[\mathrm{RR}_c] = \frac{1}{t_c}\sum_{m=1}^{t_c}\frac{1}{h_c+m} \qquad \mathbb{E}[\mathrm{HR@3}_c] = \frac{1}{t_c}\sum_{m=1}^{t_c}\mathbf{1}[h_c+m\le 3]$$

สมการ (5.14)

เฉลี่ยทุกตำแหน่งที่เรื่องที่ซ่อนอาจตกได้เท่า ๆ กัน

โดยที่

- h_c = จำนวนรายการที่ได้คะแนน **สูงกว่า** รายการที่ซ่อนอย่างเคร่งครัด
- t_c = จำนวนรายการที่ได้คะแนน **เท่ากับ** รายการที่ซ่อน (รวมตัวมันเอง)
- ตำแหน่งที่เป็นไปได้: $h_c + 1, \ldots, h_c + t_c$

ข้อสังเกต

- ไม่มีคะแนนเสมอ ($t_c = 1$) → ค่าคาดหมาย = ค่าปกติ
- MRR = ค่าเฉลี่ย RR ของทุกกรณี

ที่มาของข้อมูล: h_c และ t_c ในสมการ (5.14) นับจากรายการผู้สมัครของแต่ละกรณีกันออก: h_c = จำนวนเรื่องที่ได้คะแนนสูงกว่าเรื่องที่ซ่อนอย่างเคร่งครัด • t_c = จำนวนเรื่องที่คะแนนเท่ากัน (รวมตัวเอง) • ใช้กับ 20 กรณีของตารางที่ 5.17

ตัวอย่างการคำนวณ: ค่าคาดหมายเมื่อคะแนนเสมอ

1 h = 1 เรื่องสูงกว่า • t = 4 เรื่องเสมอ → ตำแหน่งที่เป็นไปได้ 2, 3, 4, 5

$$\mathbb{E}[\mathrm{RR}] = \frac{1}{4}\left(\frac{1}{2}+\frac{1}{3}+\frac{1}{4}+\frac{1}{5}\right) = \frac{0.5+0.3333+0.25+0.2}{4} = 0.3208 \qquad \mathbb{E}[\mathrm{HR@3}] = \frac{2}{4} = 0.5$$

2 ฝึกเพิ่ม: ระบบฐานความนิยมในตัวอย่าง 5.6 (i3 มีผู้ชอบ 1 คน) • h = 3 (i5, i11, i12) • t = 5 (i3, i7, i8, i9, i10)

$$\mathbb{E}[\mathrm{RR}] = \frac{1}{5}\left(\frac{1}{4}+\frac{1}{5}+\frac{1}{6}+\frac{1}{7}+\frac{1}{8}\right) = \frac{0.8845}{5} = 0.1769 \qquad \mathbb{E}[\mathrm{HR@3}] = 0 \ (\mathrm{rank} \geq 4)$$

ที่มาของข้อมูล: ข้อ 1 คือกรณีในกล่องอธิบายแบบเข้าใจง่ายของหัวข้อ 5.14.2 (h = 1, t = 4) • ข้อ 2 ใช้ระบบฐานความนิยมของตัวอย่าง 5.6: นับผู้ชอบในข้อมูลฝึก i5, i11, i12 = 2 คน ⟶ h = 3 • i3, i7, i8, i9, i10 = 1 คน ⟶ t = 5

ทบทวน: ตัวชี้วัดของกรณีเดียวเมื่อมีรายการที่ถูกซ่อน 1 เรื่อง

$$\mathrm{HR@3} = \mathbf{1}[\mathrm{rank} \le 3] \qquad \mathrm{RR} = \frac{1}{\mathrm{rank}} \qquad \mathrm{nDCG@3} = \begin{cases} \dfrac{1}{\log_2(\mathrm{rank}+1)} & \mathrm{rank} \le 3 \\ 0 & \text{otherwise} \end{cases}$$

อันดับของเรื่องที่ซ่อน	HR@3	RR	nDCG@3 (IDCG = 1)
1	1	1/1 = 1.0000	$1/\log_2 2 = 1.0000$
2	1	1/2 = 0.5000	$1/\log_2 3 = 0.6309$
3	1	1/3 = 0.3333	$1/\log_2 4 = 0.5000$
4	0	1/4 = 0.2500	0

ตัวอย่าง 5.6: i3 อยู่อันดับ 4 → HR@3 = 0 • RR = 0.25 • nDCG@3 = 0 • MRR / ค่าเฉลี่ยของตาราง = เฉลี่ย 20 กรณี

ที่มาของข้อมูล: อันดับของเรื่องที่ซ่อนมาจากการจัดอันดับผู้สมัครในแต่ละกรณี • HR@3 = 1[r ≤ 3] • RR = 1/r • nDCG@3 = $1/\log_2(r+1)$ เมื่อ r ≤ 3 (IDCG = 1 เพราะมีเรื่องที่ถูกต้องเรื่องเดียว) • ตัวอย่าง 5.6: r = 4 → 0, 0.25, 0

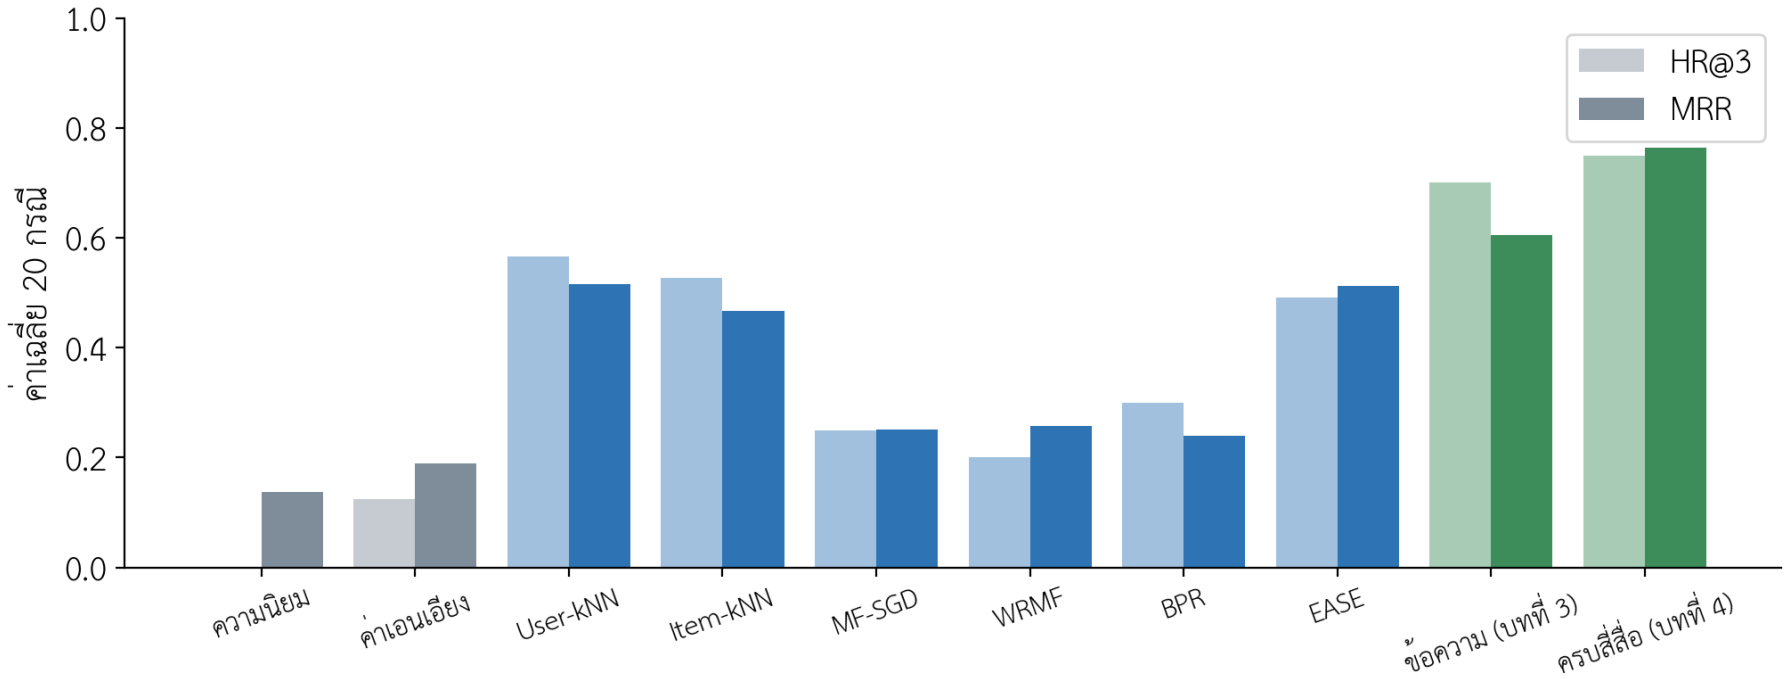
ตารางที่ 5.17 เปรียบเทียบการกรองร่วมกับระบบอิงเนื้อหาบน 20 กรณีกันออก

วิธี	HR@3	MRR	nDCG@3	HR@3 คาดหมาย	MRR คาดหมาย	กรณีเสมอ
ความนิยม (จำนวนผู้ชอบ)	0.0000	0.1629	0.0000	0.0000	0.1379	16/20
ค่าเอนเอียง	0.1000	0.1831	0.0565	0.1250	0.1901	11/20
User-kNN (k = 3)	0.7500	0.5621	0.5762	0.5662	**0.5164**	10/20
Item-kNN (k = 3)	0.6500	0.4655	0.4643	0.5265	0.4670	16/20
MF-SGD (k = 2)	0.2500	0.2504	0.1631	0.2500	0.2504	0/20
WRMF	0.2000	0.2577	0.1315	0.2000	0.2577	0/20
BPR	0.3000	0.2403	0.1696	0.3000	0.2403	0/20
EASE (λ = 5)	0.6000	0.5381	0.4881	0.4912	0.5117	14/20
อิงเนื้อหา: แนวภาพยนตร์ (บทที่ 3)	0.5500	0.5160	0.4565	0.6034	0.5455	13/20
อิงเนื้อหา: ข้อความ (บทที่ 3)	0.7000	0.6044	0.5946	0.7000	0.6044	0/20
อิงเนื้อหา: ครบสี่สื่อ (บทที่ 4)	0.7500	0.7635	0.7250	0.7500	**0.7635**	0/20

สามคอลัมน์แรกเรียงคะแนนเสมอตามเลขรหัส • สองคอลัมน์ถัดมาใช้สมการ (5.14) • แถวอิงเนื้อหาจากบทที่ 3 ตารางที่ 3.45 และบทที่ 4 ตารางที่ 4.27

ที่มาของข้อมูล: 20 กรณี = คู่ชอบ 20 คู่ (คะแนน ≥ 4) ของตารางที่ 5.3 ซ่อนทีละคู่ ฝึกใหม่ทุกวิธี จัดอันดับผู้สมัคร • สามคอลัมน์แรกเรียงคะแนนเสมอตามเลขรหัส • คาดหมายใช้สมการ (5.14) • กรณีเสมอ = จำนวนกรณีที่ $t_c > 1$ • แถวอิงเนื้อหาจากบทที่ 3 ตารางที่ 3.45 และบทที่ 4 ตารางที่ 4.27

ภาพที่ 5.12 HR@3 และ MRR แบบค่าคาดหมายของทุกวิธี



ภาพที่ 5.12 HR@3 (สีอ่อน) และ MRR (สีเข้ม) แบบค่าคาดหมายของทุกวิธีบน 20 กรณีกันออก

การกรองร่วมที่ดีที่สุด = **User-kNN (MRR คาดหมาย 0.5164)** • ระบบอิงเนื้อหา (ข้อความ 0.6044, ครบสี่สื่อ 0.7635) สูงกว่าทุกวิธีของ CF บนข้อมูลชุดนี้

ที่มาของข้อมูล: ความสูงของแท่งมาจากคอลัมน์ HR@3 คาดหมาย และ MRR คาดหมาย ของตารางที่ 5.17 (20 กรณีกันออก) • User-kNN = 0.5164 • ระบบข้อความ 0.6044 (บทที่ 3 ตารางที่ 3.45) • ครบสี่สื่อ 0.7635 (บทที่ 4 ตารางที่ 4.27)

ข้อสังเกตห้าข้อจากตารางที่ 5.17 และภาพที่ 5.12

1 ความนิยมและค่าเอนเอียงแทบใช้ไม่ได้

ซ่อนคู่ชอบหนึ่งคู่ → จำนวนผู้ชอบของรายการนั้นลดลงหนึ่งเสมอ → ตกไปอยู่ใต้รายการอื่น

2 CF ที่ดีที่สุดคือ User-kNN (k = 3)

MRR คาดหมาย 0.5164

3 กติกาคะแนนเสมอต้องรายงานเสมอ

ความต่างระหว่างเรียงตามรหัสกับค่าคาดหมายของบางวิธีมีขนาดใหญ่

4 แบบจำลองที่มีพารามิเตอร์มากแพ้

MF, WRMF, BPR แย่กว่าเพื่อนบ้านและ EASE บนข้อมูล 32 คะแนน

5 อิงเนื้อหาสูงกว่าบนข้อมูลชุดนี้

กลับด้านกับข้อมูลขนาดใหญ่ ซึ่ง CF มักได้เปรียบเมื่อมีพฤติกรรมมากพอ

Paired Bootstrap ระดับผู้ใช้: ระบบข้อความ − User-kNN

ผู้ใช้	u1	u2	u3	u4	u5	u6	u7	u8
Δ RR เฉลี่ยรายผู้ใช้	0.2793	0.0432	0.0432	0.2606	−0.1501	−0.0334	0.1250	0.0000

1 ขั้นที่ 1 ค่าเฉลี่ยของความต่าง

$$\bar{\Delta} = \frac{0.2793 + 0.0432 + 0.0432 + 0.2606 - 0.1501 - 0.0334 + 0.1250 + 0}{8} = \frac{0.5678}{8} = 0.0710$$

2 ขั้นที่ 2 Bootstrap

- สุ่มผู้ใช้ 8 คนแบบใส่คืน 4,000 รอบ (เมล็ดสุ่ม 2569) แล้วหาค่าเฉลี่ยทุกรอบ
- ช่วงความเชื่อมั่น 95% = [−0.0207, 0.1656]

สรุป

- ระบบข้อความชนะ 9 กรณี แพ้ 5 กรณี
- ช่วงความเชื่อมั่น **คร่อมศูนย์** → ยัง **สรุปไม่ได้** ว่าระบบข้อความดีกว่าจริงบนข้อมูลชุดนี้

ที่มาของข้อมูล: Δ RR รายผู้ใช้ = RR เฉลี่ยของระบบข้อความ (บทที่ 3 ตารางที่ 3.45) − RR เฉลี่ยของ User-kNN (โปรแกรมที่ 5.11) ของกรณีนั้นออกของผู้ใช้คนนั้น • ค่าเฉลี่ย = 0.5678/8 = 0.0710 • Bootstrap สุ่มผู้ใช้ 8 คนแบบใส่คืน 4,000 รอบ (เมล็ดสุ่ม 2569) แล้วใช้เปอร์เซ็นไทล์ที่ 2.5 และ 97.5

5.15

ความท้าทายของการกรองร่วม



การเริ่มต้นเย็น • ความเบาบาง • การขยายขนาด

5.15.1 การเริ่มต้นเย็น (Cold Start)

CF ต้องมีปฏิสัมพันธ์ก่อนจึงแนะนำได้ — **รายการใหม่** ไม่มีวันถูกแนะนำ · **ผู้ใช้ใหม่** ไม่มีเพื่อนบ้าน · ใน 20 กรณีมี **4 กรณี** ที่รายการที่ซ่อนไม่มีผู้อื่นชอบเลย (= รายการใหม่ในมุมของ CF)

ผู้ใช้	เรื่องที่ซ่อน	RR คาดหมาย (User-kNN, k = 3)	อันดับ (ระบบข้อความ บทที่ 3)
u3	i10 Dune: Part Two	0.3704	1
u4	i7 Ballerina	0.2186	3
u4	i8 Furiosa: A Mad Max Saga	0.2186	1
u5	i9 Conclave	0.2030	9

อิงเนื้อหายังจัดอันดับได้ เพราะเนื้อหามีตั้งแต่วันแรก → ระบบจริง **ผสาน** สองแนวทาง (บทที่ 8)

ทางแก้อื่น: ถามความชอบตอนสมัคร · แนะนำยอดนิยมก่อน · VBPR (บทที่ 4 หัวข้อ 4.12.1)

5.15.2 ความเบาบาง และ 5.15.3 การขยายขนาด

ความเบาบาง

- MovieMini-12: คู่ส่วนใหญ่มีรายการร่วม 0–1 เรื่อง ทั้งที่หนาแน่น 33%
- Netflix Prize หนาแน่นราว 1.2% → รุนแรงกว่ามาก

ทางแก้

- **ปัจจัยแฝง** ส่งสารสนเทศผ่านเวกเตอร์ร่วม ไม่ต้องมีรายการร่วมโดยตรง
- **แบบจำลองกราฟ** (บทที่ 7) ส่งผ่านเส้นทางหลายช่วง

คำนวณ: ทำไม Netflix Prize ต้องคิดเรื่องขนาด (ผู้ใช้ 480,189 คน ภาพยนตร์ 17,770 เรื่อง)

$$\text{user pairs} = \frac{480{,}189 \times 480{,}188}{2} \approx 1.15 \times 10^{11} \qquad \text{item pairs} = \frac{17{,}770 \times 17{,}769}{2} \approx 1.58 \times 10^{8}$$

$$\text{MF params (MovieLens-1M, } k = 64) = (6{,}040 + 3{,}706) \times 64 = 9{,}746 \times 64 = 623{,}744$$

คู่รายการน้อยกว่าคู่ผู้ใช้ราว 730 เท่า → เหตุผลที่ Amazon เลือก **Item-kNN** [3] • ระบบใหญ่ใช้ ANN ค้นผลคูณจุดสูงสุด (บทที่ 8)

ที่มาของข้อมูล: ความเบาบาง: 0–1 เรื่องจากตัวอย่าง 5.1 ขั้นที่ 4 (21 จาก 28 คู่) • Netflix 1.2% = 100,480,507 ÷ (480,189 × 17,770) • จำนวนคู่ = $n(n-1)/2$: $480{,}189 \times 480{,}188/2 = 115{,}290{,}497{,}766 \approx 1.15 \times 10^{11}$ • $17{,}770 \times 17{,}769/2 = 157{,}877{,}565 \approx 1.58 \times 10^{8}$ → ต่างกันราว 730 เท่า

ตารางที่ 5.19 ต้นทุนของแต่ละตระกูล (|U| ผู้ใช้ • |I| รายการ • |K| คะแนน)

วิธี	หน่วยความจำ	เวลาฝึก	เวลาแนะนำผู้ใช้หนึ่งคน
User-kNN	$O(\|U\|^2)$ ตารางความคล้าย	ไม่มี / คำนวณความคล้ายล่วงหน้า	$O(\|U\| \cdot \|I\|)$
Item-kNN	$O(\|I\|^2)$ หรือเก็บเพียง k เพื่อนบ้าน	คำนวณความคล้ายล่วงหน้า	$O(\|I_u\| \cdot k)$
MF (SGD/ALS)	$O((\|U\| + \|I\|)\ k)$	$O(\|K\|\ k)$ ต่อรอบ	$O(\|I\|\ k)$ หรือใช้ ANN
EASE	$O(\|I\|^2)$	$O(\|I\|^3)$ อินเวอร์สครั้งเดียว	$O(\|I_u\| \cdot \|I\|)$

ประเด็นท้าทายอื่น → บทที่ 10

- อคติความนิยมและวงจรป้อนกลับ • ผู้ใช้แกะเทา (Gray Sheep) • การโจมตีด้วยโปรไฟล์ปลอม • ความเป็นส่วนตัว — เกี่ยวข้องกับทุกแนวทาง

5.16

การเตรียมข้อมูลและแนวปฏิบัติ



หกขั้นที่ควรทำเสมอ • ไฮเพอร์พารามิเตอร์ • ตารางวินิจฉัยอาการ

5.16 ขั้นตอนเตรียมข้อมูลที่ควรทำเสมอ

1 ตรวจและกำจัดข้อมูลซ้ำ

ให้คะแนนซ้ำ → เก็บค่าล่าสุดหรือค่าเฉลี่ย และบันทึกกฎ

2 ทำดัชนีใหม่

รหัส → 0 … |U|−1 และ 0 … |I|−1

- เก็บเป็นเมทริกซ์เบาบาง (CSR/COO)

3 แปลงข้อมูลโดยปริยาย

กำหนดเกณฑ์ "ชอบ" และความเชื่อมั่น c_{ui} อย่างชัดเจน

4 กรองแบบ k-core

ตัดผู้ใช้/รายการที่มีปฏิสัมพันธ์ < k ซ้ำจนคงที่ • **ต้องรายงาน k** เพราะทำให้ตัวชี้วัดดูดีเกินจริง

5 แบ่งข้อมูลตามเวลา

ฝึกด้วยอดีต ทดสอบด้วยอนาคต (บทที่ 2)

6 เลือกไฮเพอร์พารามิเตอร์บนชุดตรวจสอบ

แยกจากชุดทดสอบ • ฝึกใหม่บน train + validation ก่อนรายงาน

ตารางที่ 5.20 ไฮเพอร์พารามิเตอร์สำคัญ ค่าที่บทนี้ใช้ และช่วงที่มักใช้กับข้อมูลขนาดใหญ่

วิธี	ไฮเพอร์พารามิเตอร์	ค่าในบทนี้	ช่วงที่มักใช้
User/Item-kNN	จำนวนเพื่อนบ้าน k, β	3, 3	20–100, 50
ค่าเอนเอียง	λ_i, λ_u	2, 2	10–25
MF-SGD	k, η, λ, จำนวนรอบ	2, 0.05, 0.1–0.5, 150–300	32–256, 0.001–0.01, 0.01–0.1, 20–100
WRMF	k, α, λ	2, 10, 0.1	64–256, 1–40, 0.01–1
BPR	k, η, λ	2, 0.05, 0.01	64–256, 0.01–0.05, 0.0001–0.01
EASE	λ	5	100–1,000

ที่มา: ค่าตั้งต้นที่ผู้เขียนแนะนำจากงานต้นฉบับ [5], [6], [7], [9], [13] ควรปรับบนชุดตรวจสอบเสมอ

- ค่าในบทนี้เล็กกว่าปกติมาก เพราะ MovieMini-12 มีเพียง 32 คะแนน — **อย่านำไปใช้กับข้อมูลจริงโดยตรง**

ตารางที่ 5.21 ตารางวินิจฉัยอาการที่พบบ่อยเมื่อสร้างการกรองร่วม

อาการ	สาเหตุที่เป็นไปได้	แนวทางแก้
RMSE ข้อมูลฝึกต่ำมาก แต่ข้อมูลทดสอบสูง	เรียนรู้เกิน	เพิ่ม λ • ลด k • หยุดฝึกก่อน
ทุกคนได้รายการแนะนำเหมือนกัน	ค่าเอนเอียงครอบงำ หรือข้อมูลเบาบางเกิน	ตรวจส่วนปฏิสัมพันธ์ • ใช้แบบจำลองจัดอันดับ
ค่าทำนายเท่ากันหลายรายการ	เพื่อนบ้านไม่มีหลักฐาน	ใช้ค่าเอนเอียงเป็นค่าสำรอง • รายงานกติกาคะแนนเสมอ
ผลเปลี่ยนมากเมื่อเปลี่ยนเมล็ดสุ่ม	ข้อมูลน้อยหรือการสุ่มตัวอย่างลบ	รายงานค่าเฉลี่ยจากหลายเมล็ดสุ่ม
ผลดีเกินจริงบนข้อมูลทดสอบ	ข้อมูลรั่วไหลหรือสุ่มตัวอย่างลบ	แบ่งตามเวลา • ประเมินเต็มบัญชีรายการ

5.17

บทวิเคราะห์ของผู้เขียนและประเด็นวิจัยที่เปิดอยู่



ทำไมวิธีง่ายจึงชนะบนข้อมูลเล็ก • ทำนายคะแนนหรือจัดอันดับ

5.17.1–5.17.2 บทวิเคราะห์ของผู้เขียน

ทำไมวิธีง่ายจึงชนะบนข้อมูลเล็ก

- หลักทั่วไป: **จำนวนพารามิเตอร์ต้องสมดุลกับจำนวนหลักฐาน**
- เพื่อนบ้าน: ไม่มีพารามิเตอร์ → ไม่เรียนรู้เกิน
- EASE: พารามิเตอร์มาก แต่มีคำตอบรูปปิดและเรกูลาไรเซชันแรงพอ
- MF (k = 2): **60 พารามิเตอร์ต่อ 32 คะแนน**
- คำนวณอัตราส่วนพารามิเตอร์ต่อข้อมูลเสมอ • เริ่มจาก Item-kNN และ EASE (สอดคล้องกับ Ferrari Dacrema และคณะ [15])

ทำนายคะแนนหรือจัดอันดับ

- วงการเปลี่ยนจากทำนายคะแนน (ยุค Netflix Prize) สู่การจัดอันดับจากข้อมูลโดยปริยาย — สอดคล้องกับประสบการณ์ผู้ใช้จริง
- ข้อควรระวัง: การประเมินการจัดอันดับคลาดเคลื่อนได้ง่ายกว่า เช่น **กติกาคะแนนเสมอ** และ **การสุ่มตัวอย่างลบ**
- ควรระบุกติกาเหล่านี้ใน **บัตรโปรโตคอล** ทุกครั้ง

5.17.3 ประเด็นวิจัยที่เปิดอยู่

1 **CF บนข้อมูลเล็กมาก**

ร้านค้าท้องถิ่น ห้องสมุดคณะ — ใช้ความรู้ภายนอก เช่น เนื้อหา หรือแบบจำลองภาษา (บทที่ 9)

2 **ความเป็นธรรมต่อรายการหางยาว**

CF เอื้อรายการยอดนิยมโดยโครงสร้าง — วิธีวัดและแก้ไขใน บทที่ 10

3 **การทำซ้ำผลได้**

ความต่างเล็ก ๆ ของการเตรียมข้อมูลและการปรับจูนเปลี่ยนผู้ชนะได้ — NCF [14] และ iALS [16]

4 **พลวัตตามเวลา**

ความชอบเปลี่ยนตามเวลา — แบบจำลองเชิงลำดับในบทที่ 6

สรุปท้ายบท (1/2)

1. CF ใช้ **สิ่งที่ผู้ใช้คนอื่นทำ** แทนเนื้อหา จึงค้นพบความเชื่อมโยงข้ามแนว เช่น u5 ที่ชอบทั้ง The Wild Robot และ Conclave
2. ความคล้ายควร **ลบค่าเฉลี่ยของผู้ใช้** (Pearson, Adjusted Cosine) และ **ถ่วงด้วยจำนวนรายการร่วม**
3. User-kNN ยืม **ส่วนเบี่ยงเบน** จากเพื่อนบ้าน • Item-kNN ถ่วงคะแนนของผู้ใช้เองด้วยความคล้ายระหว่างรายการ
4. ตัวอย่างครบวงจรหกขั้นแสดงว่าผลของกรณีเดียวขึ้นกับหลักฐานของผู้ใช้เพียงไม่กี่คน
5. แบบจำลองค่าเอนเอียงเป็นฐานที่ควรเทียบเสมอ และ **การหด** ป้องกันค่าสุดโต่ง
6. MF แทนผู้ใช้และรายการด้วยปัจจัยแฝง ฝึกด้วย SGD หรือ ALS • SVD++ เพิ่มข้อมูลว่าผู้ใช้แตะรายการใด

สรุปท้ายบท (2/2)

7 ข้อมูลโดยปริยาย: แยกความชอบกับความเชื่อมั่น (WRMF) หรือเรียนเฉพาะลำดับ (BPR) • EASE รูปปิด เป็นฐานที่แข็งแรง

8 NCF แทนผลคูณจุดด้วยโครงข่ายประสาท แต่ต้องเทียบกับ MF ที่ปรับจูนดีเสมอ

9 เมื่อหลายรายการได้คะแนนเท่ากัน ต้องรายงาน **ค่าคาดหมาย** ไม่ใช่เรียงตามเลขรหัส

10 บน MovieMini-12 **วิธีง่ายชนะวิธีซับซ้อน** และอิงเนื้อหาดีกว่า CF — ผลของข้อมูลที่เล็กมาก

11 จุดอ่อนหลัก: **เริ่มต้นเย็น** • **เบาบาง** • **ขยายขนาด** → ผสานกับอิงเนื้อหา (บทที่ 8) และกราฟ (บทที่ 7)

บทที่ 3–5 ครอบคลุมสามแหล่งสัญญาณ: ข้อความ • สื่อหลายรูปแบบ • พฤติกรรมของผู้ใช้ทุกคน → **บทที่** 6 มองประวัติเป็น **ลำดับ** แทนเซต

ฝึก

แบบฝึกหัดคำนวณด้วยมือท้ายบท



หกข้อ ครอบคลุมความคล้าย • ค่าเอนเอียง • User-kNN • SGD • ค่าคาดหมาย

แบบฝึกหัดคำนวณด้วยมือ (ใช้ตารางที่ 5.3)

1 Pearson

จงหา sim(u2, u8) ด้วยสมการ (5.1)

2 Jaccard และ Cosine

จงหา J(u3, u7) และ cos(u3, u7) บนคะแนนดิบ

3 ค่าเอนเอียง

กำหนด $b_{u2} = 0.3514$ จงหา b_{i5} และ $\hat{r}_{u2,i9}$ ($\lambda = 2$)

4 User-kNN

จงทำนาย $\hat{r}_{u5,i1}$ ด้วยสมการ (5.4) ($k = 3$) อย่าลืมตัดช่วง 1–5

5 SGD หนึ่งก้าว

คะแนน $r_{u1,i4} = 1$ · $b = 0$ · $p_{u1} = (0.1, -0.1)$ · $q_{i4} = (0.1, 0.1)$ · $\eta = 0.05$ · $\lambda = 0.1$

6 ค่าคาดหมาย

มี 2 เรื่องคะแนนสูงกว่า และ 3 เรื่องเสมอ (รวมเรื่องที่ซ่อน) จงหา $\mathbb{E}[RR]$ และ $\mathbb{E}[HR@3]$

ที่มาของข้อมูล: ทุกข้อใช้ตารางที่ 5.3 โดยตรง • ข้อ 3: b_u2 = 0.3514 คำนวณด้วยสมการ (5.7): เศษเหลือของ u2 (−1.65 + 1.55 + 0.75 + 1.4583) = 2.1083 ÷ (2 + 4) • ข้อ 4: sim จากสมการ (5.1) • ข้อ 5: ค่าเริ่มต้นแบบเดียวกับตัวอย่าง 5.8 • ข้อ 6: สมการ (5.14)

เฉลยข้อ 1–2

1 u2–u8: รายการร่วม i4, i6 • $\bar{r}_{u2} = 4.0$, $\bar{r}_{u8} = 3.5$ → u2: (1, 1) • u8: (0.5, 1.5)

$$\text{sim}(u_2, u_8) = \frac{1(0.5) + 1(1.5)}{\sqrt{1+1}\,\sqrt{0.25+2.25}} = \frac{2}{1.4142 \times 1.5811} = \frac{2}{2.2361} = 0.8944$$

2 u3 = {i7, i10, i11, i12} • u7 = {i3, i8, i11, i12} • ร่วมกัน i11, i12

$$J = \frac{2}{4+4-2} = \frac{2}{6} = 0.3333 \qquad \cos = \frac{5(4) + 4(5)}{\sqrt{1+25+25+16}\,\sqrt{9+4+16+25}} = \frac{40}{8.1854 \times 7.3485} = 0.6650$$

ที่มาของข้อมูล: ข้อ 1: รายการร่วมของ u2 {i1, i4, i5, i6} กับ u8 {i2, i4, i6, i11} = {i4, i6} • $\bar{r}_{u2} = 16/4 = 4.0$, $\bar{r}_{u8} = 14/4 = 3.5$ (ตารางที่ 5.3) → (1, 1) และ (0.5, 1.5) • ข้อ 2: cos ใช้คะแนนดิบร่วม i11 (5, 4), i12 (4, 5) และ $\|u_3\| = \sqrt{67}$, $\|u_7\| = \sqrt{54}$

เฉลยข้อ 3–4

3 i5 ได้คะแนน 4, 1, 4 จาก u2, u4, u6 • b_{i9} = 0.4583 (ตัวอย่าง 5.7)

$$b_{i5} = \frac{(4-3.625)+(1-3.625)+(4-3.625)}{2+3} = \frac{-1.875}{5} = -0.3750 \qquad \hat{r}_{u2,i9} = 3.625 + 0.3514 + 0.4583 = 4.4347$$

4 ผู้ให้คะแนน i1: u1 (sim 0.9062) • u2 (sim −1 ตัด) • u4 (ไม่มีรายการร่วมกับ u5 ตัด)

$$\hat{r}_{u5,i1} = 3.5 + \frac{0.9062\,(5-3.2)}{0.9062} = 3.5 + 1.8 = 5.3 \xrightarrow{\text{clip}} 5.0$$

ที่มาของข้อมูล: ข้อ 3: คอลัมน์ i5 ของตารางที่ 5.3 (u2 4, u4 1, u6 4) • b_i9 = 0.4583 จากตัวอย่าง 5.7 • b_u2 = 0.3514 จากโจทย์ • ข้อ 4: ผู้ให้คะแนน i1 คือ u1, u2, u4 • sim(u5, u1) = 0.9062 (ตารางที่ 5.6) • sim(u5, u2): ร่วม i6 (−0.5)(+1) < 0 ⟶ −1 • u4 ไม่มีรายการร่วมกับ u5

เฉลยข้อ 5–6

5 SGD: $\hat{\mathbf{r}} = 3.625 + (0.1)(0.1) + (-0.1)(0.1) = 3.625 \rightarrow e = 1 - 3.625 = -2.625$

$$b_{u1} = b_{i4} = 0.05(-2.625) = -0.1313$$

$$\mathbf{p}_{u1} = (0.1, -0.1) + 0.05\big(-2.625(0.1, 0.1) - 0.1(0.1, -0.1)\big) = (0.0864,\ -0.1126)$$

$$\mathbf{q}_{i4} = (0.1, 0.1) + 0.05\big(-2.625(0.1, -0.1) - 0.1(0.1, 0.1)\big) = (0.0864,\ 0.1126)$$

$$\hat{r}^{\,\text{new}} = 3.625 - 0.2625 + (0.0075 - 0.0127) = 3.3573 \text{ (closer to 1)}$$

6 h = 2, t = 3 → ตำแหน่งที่เป็นไปได้ 3, 4, 5

$$\mathbb{E}[\text{RR}] = \frac{1}{3}\left(\frac{1}{3} + \frac{1}{4} + \frac{1}{5}\right) = 0.2611 \qquad \mathbb{E}[\text{HR@3}] = \frac{1}{3} = 0.3333$$

ที่มาของข้อมูล: ข้อ 5: r_u1,i4 = 1 จากตารางที่ 5.3 • μ = 3.625 • p_u1 = (0.1, −0.1), q_i4 = (0.1, 0.1), η = 0.05, λ = 0.1 จากโจทย์ • e = 1 − 3.625 = −2.625 ⟶ b = 0.05(−2.625) = −0.1313 • ข้อ 6: h = 2, t = 3 ⟶ อันดับ 3, 4, 5 ตามสมการ (5.14)

เอกสารอ้างอิงตามหมายเลขที่ใช้ในบท

[1] D. Goldberg et al., "Using collaborative filtering to weave an information tapestry," CACM, 1992.

[2] P. Resnick et al., "GroupLens: An open architecture for collaborative filtering of netnews," CSCW, 1994.

[3] G. Linden, B. Smith, J. York, "Amazon.com recommendations: Item-to-item collaborative filtering," IEEE Internet Computing, 2003.

[4] J. Bennett, S. Lanning, "The Netflix Prize," KDD Cup and Workshop, 2007.

[5] Y. Koren, R. Bell, C. Volinsky, "Matrix factorization techniques for recommender systems," IEEE Computer, 2009.

[6] Y. Hu, Y. Koren, C. Volinsky, "Collaborative filtering for implicit feedback datasets," ICDM, 2008.

[7] S. Rendle et al., "BPR: Bayesian personalized ranking from implicit feedback," UAI, 2009.

[8] X. He et al., "Neural collaborative filtering," WWW, 2017.

เอกสารอ้างอิงตามหมายเลขที่ใช้ในบท (ต่อ)

[9] J. Herlocker et al., "An algorithmic framework for performing collaborative filtering," SIGIR, 1999.

[10] B. Sarwar et al., "Item-based collaborative filtering recommendation algorithms," WWW, 2001.

[11] S. Funk, "Netflix update: Try this at home," blog post, 2006.

[12] Y. Koren, "Factorization meets the neighborhood: A multifaceted collaborative filtering model," KDD, 2008.

[13] H. Steck, "Embarrassingly shallow autoencoders for sparse data," WWW, 2019.

[14] S. Rendle et al., "Neural collaborative filtering vs. matrix factorization revisited," RecSys, 2020.

[15] M. Ferrari Dacrema et al., "Are we really making much progress? A worrying analysis of recent neural recommendation approaches," RecSys, 2019.

[16] S. Rendle et al., "Revisiting the performance of iALS on item recommendation benchmarks," RecSys, 2022.

Q & A

ขอบคุณ — ร่วมถามและอภิปราย



บทถัดไป: บทที่ 6 ระบบผู้แนะนำเชิงลำดับ (มองประวัติเป็นลำดับ)