1

บทที่ 1 : รากฐานของระบบผู้แนะนำ
Foundations of Recommender Systems



ในโลกดิจิทัล ปัญหามิใช่การขาดข้อมูล แต่คือการมีตัวเลือกมากเกินกว่าจะพิจารณาได้ทั่วถึง ระบบผู้แนะนำ (recommender system) จึงทำหน้าที่ประมาณความเกี่ยวข้อง คัดเลือก และจัดอันดับรายการจำนวนน้อย ให้เหมาะกับผู้ใช้และบริบท ภายใต้ข้อจำกัดด้านเวลา ทรัพยากร กฎธุรกิจ และความรับผิดชอบต่อผู้มีส่วนได้ส่วนเสีย

บทนี้อธิบายระบบผู้แนะนำในฐานะระบบครบวงจร ตั้งแต่ข้อมูล วงจรป้อนกลับ นิยามเชิงคณิตศาสตร์ วิธีฐาน ไปจนถึงสถาปัตยกรรมหลายขั้นและการประเมินเบื้องต้น

เนื้อหา

1.1 ภาวะข้อมูลท่วมท้น 7
1.2 องค์ประกอบและวงจรข้อมูล 12
1.3 คุณค่าทางธุรกิจและหางยาว 16
1.4 นิยามเชิงรูปนัยของปัญหา 24
1.5 ประเภทข้อมูลและผลป้อนกลับ 28
1.6 การแก้ไขอคติเพื่อความยุติธรรม 32
1.7 อนุกรมวิธานของการแนะนำ 44
1.8 AI ⊃ ML ⊃ DL ⊃ GenAI 47
1.8 สถาปัตยกรรมหลายชั้น 51
1.9 ความท้าทายเจ็ดประการ 55
1.10 พัฒนาการ ค.ศ. 1992–2026 58
1.11 ตัวอย่างการคำนวณครบวงจร 61
1.13 การเตรียมข้อมูลปฏิสัมพันธ์ 81
1.14 ภาคปฏิบัติ 92
1.15 สรุปประจำบท 98

บทนี้วางรากฐานของระบบผู้แนะนำตั้งแต่นิยาม ข้อมูล และอนุกรมวิธาน ไปจนถึงสถาปัตยกรรมหลายขั้น พร้อมตัวอย่างการคำนวณด้วยมือครบวงจรบนชุดข้อมูล MovieMini 12 ผู้เรียนจะได้เห็นว่าเหตุใดการเลือกข้อมูล การเตรียมข้อมูล และการวัดผลจึงสำคัญไม่น้อยกว่าการเลือกขั้นตอนวิธี และจะได้ศึกษาหัวข้อใหม่ว่าด้วยการแก้ไขอคติของผลป้อนกลับเพื่อความยุติธรรม ซึ่งเป็นสะพานเชื่อมไปสู่บทที่ 2 ว่าด้วยระเบียบวิธีประเมินผล

วัตถุประสงค์การเรียนรู้ประจำบท

เมื่อศึกษาบทนี้จบแล้ว ผู้เรียนจะสามารถ

- **อธิบาย** นิยาม บทบาท และองค์ประกอบของระบบผู้แนะนำ (Recommender System) และอธิบายได้ว่าภาวะข้อมูลท่วมท้น (Information Overload) นำไปสู่ความจำเป็นของระบบนี้อย่างไร พร้อมแยกความต่างจากระบบค้นคืนสารสนเทศ (Information Retrieval System)
- **วิเคราะห์** วงจรข้อมูล (Feedback Loop) ของระบบผู้แนะนำ และอธิบายได้ว่าเหตุใดข้อมูลที่ระบบเก็บได้จึงไม่ใช่ตัวอย่างสุ่มจากความชอบจริงของผู้ใช้
- **นิยาม** ปัญหาการแนะนำในเชิงรูปนัยผ่านฟังก์ชันอรรถประโยชน์ (Utility Function) และเมทริกซ์ผู้ใช้–รายการ (User–Item Matrix) พร้อมแยกแยะโจทย์การพยากรณ์คะแนน (Rating Prediction) ออกจากโจทย์การจัดอันดับ (Top K Ranking)
- **จำแนก** ประเภทของระบบผู้แนะนำตามชนิดข้อมูลและกลไกการอนุมาน และแยกแยะผลป้อนกลับแบบชัดแจ้ง (Explicit Feedback) กับแบบโดยปริยาย (Implicit Feedback) พร้อมระบุผลกระทบต่อการเลือกขั้นตอนวิธีและตัวชี้วัด
- **ระบุตำแหน่ง** ของเทคนิคต่าง ๆ ในลำดับชั้น ปัญญาประดิษฐ์ (AI) ⊃ การเรียนรู้ของเครื่อง (ML) ⊃ การเรียนรู้เชิงลึก (DL) ⊃ ปัญญาประดิษฐ์เชิงกำเนิด (GenAI) และเลือกใช้คำเรียกทางวิชาการได้อย่างแม่นยำ
- **ประเมิน** สถาปัตยกรรมหลายขั้น (Multi Stage Architecture) ในเชิงงบประมาณเวลาและเพดานคุณภาพ พร้อมอธิบายได้ว่าเหตุใดจึงต้องวัดผลแต่ละขั้นด้วยตัวชี้วัดคนละตัว
- **คำนวณ** ความเบาบาง (Sparsity) สัมประสิทธิ์จีนี (Gini Coefficient) ความคล้ายเชิงโคไซน์ (Cosine Similarity) ค่าพยากรณ์แบบเฉลี่ยถ่วงน้ำหนัก และตัวชี้วัด Precision@K, Recall@K, nDCG@K ได้ด้วยมือทีละขั้น
- **ออกแบบ** กระบวนงานการทำความสะอาดและเตรียมข้อมูลปฏิสัมพันธ์ (Interaction Data) เจ็ดขั้น พร้อมอธิบายผลกระทบของการกรองแบบ k core ต่อค่าตัวชี้วัดที่รายงาน
- **เขียนโปรแกรม** ภาษาไพทอนเพื่อสำรวจชุดข้อมูลปฏิสัมพันธ์ และสร้างระบบผู้แนะนำฐาน (Baseline) ที่ใช้เป็นเกณฑ์เปรียบเทียบสำหรับทุกบทถัดไป



ภาพที่ 1.1 แผนที่ความคิดประจำบทที่ 1 แสดงหัวข้อทั้งหมดของบทและความเชื่อมโยงระหว่างกัน

ข้อตกลงเรื่องศัพท์และสัญกรณ์ที่ใช้ตลอดทั้งเล่ม

เพื่อให้ผู้อ่านเชื่อมโยงภาษาไทยเข้ากับวรรณกรรมสากลได้โดยไม่สับสน ตำราเล่มนี้ใช้ศัพท์บัญญัติภาษาไทยตามแนวทางของสำนักงานราชบัณฑิตยสภาเป็นหลัก และกำกับคำภาษาอังกฤษไว้ในวงเล็บเมื่อคำนั้นปรากฏเป็นครั้งแรก หลังจากนั้นจะใช้คำไทยอย่างสม่ำเสมอ ในกรณีที่การแปลทำให้ความหมายทางเทคนิคคลาดเคลื่อนหรือสูญเสียความเฉพาะเจาะจง จะใช้การทับศัพท์แทน เช่น โคไซน์ (cosine) จีนี (Gini) และเพียร์สัน (Pearson) ส่วนชื่อขั้นตอนวิธี ชื่อชุดข้อมูล และชื่อคลาสในรหัสโปรแกรม จะคงรูปภาษาอังกฤษไว้ทั้งหมด เพื่อให้ผู้อ่านค้นคว้าและทำการทดลองซ้ำได้

ตารางที่ 1.1 ศัพท์หลักที่ใช้ตลอดทั้งเล่ม พร้อมความหมายและข้อควรระวังในการใช้

ศัพท์ไทย (อังกฤษ)	ความหมายที่ใช้ในเล่มนี้
ระบบผู้แนะนำ (recommender system)	ระบบที่คัดเลือกและจัดลำดับรายการให้เหมาะกับผู้ใช้แต่ละคน โดยอาศัยข้อมูลผู้ใช้ รายการ ปฏิสัมพันธ์ และบริบท
รายการ (item)	สิ่งที่ระบบสามารถแนะนำได้ เช่น ภาพยนตร์ เพลง สินค้า บทความ หรือหลักสูตร
ขั้นตอนวิธี (algorithm)	ลำดับขั้นที่ระบุชัดว่ารับข้อมูลใด ประมวลผลอย่างไร สิ้นสุดเมื่อใด และให้ผลลัพธ์อะไร ต่างจาก "โปรแกรม" ตรงที่เป็นแนวคิดเชิงนามธรรม
แบบจำลอง (model)	ฟังก์ชันที่เรียนพารามิเตอร์จากข้อมูลเพื่อประมาณคะแนน ความน่าจะเป็น หรืออันดับ แบบจำลองเป็นเพียงส่วนหนึ่งของระบบ มิใช่ระบบทั้งหมด
เมทริกซ์ (matrix)	ตารางจำนวนเชิงคณิตศาสตร์ที่จัดเป็นแถวและคอลัมน์ เช่น เมทริกซ์ผู้ใช้–รายการ

ศัพท์ไทย (อังกฤษ)	ความหมายที่ใช้ในเล่มนี้
ตัวชี้วัด (metric)	ค่าปริมาณที่ใช้ประเมินคุณภาพของระบบ เช่น Recall@K และ nDCG@K ห้ามเขียนย่อว่า “เมทริก” เพราะจะสับสนกับเมทริกซ์
กระบวนงาน (pipeline)	ลำดับขั้นการประมวลผลที่ผลลัพธ์ของขั้นหนึ่งเป็นข้อมูลนำเข้าของขั้นถัดไป
ผลป้อนกลับ (feedback)	สัญญาณที่สะท้อนความสนใจของผู้ใช้ อาจเป็นการให้คะแนนโดยตรงหรือพฤติกรรมที่ต้องอนุมานความหมาย
เวกเตอร์ฝัง (embedding)	เวกเตอร์จำนวนจริงมิติต่ำที่ใช้แทนผู้ใช้หรือรายการ และเรียนรู้ได้จากข้อมูล
ปัจจัยแฝง (latent factor)	มิติที่ไม่ได้สังเกตโดยตรงแต่อธิบายรูปแบบความชอบได้ เช่น “ความชอบหนังแนวสืบสวน”
การปรับให้เหมาะเฉพาะบุคคล (personalization)	การทำให้ผลลัพธ์ต่างกันตามผู้ใช้หรือบริบท ต้องมีฐานเปรียบเทียบที่ไม่ปรับเฉพาะบุคคลเสมอ เพื่อพิสูจน์ว่าความซับซ้อนที่เพิ่มขึ้นให้ประโยชน์จริง

ตารางที่ 1.2 สัญกรณ์มาตรฐานที่ใช้ตลอดทั้งเล่ม

สัญกรณ์	ความหมาย	ตัวอย่างค่า
U, I	เซตของผู้ใช้ และเซตของรายการ ตามลำดับ	$\lvert U\rvert = 8, \lvert I\rvert = 12$
u, v	ดัชนีอ้างถึงผู้ใช้ (v ใช้เมื่อกล่าวถึงผู้ใช้อีกคนหนึ่ง)	u = Emmy
i, j	ดัชนีอ้างถึงรายการ	i = La La Land
R	เมทริกซ์ผู้ใช้–รายการ ขนาด |U| × |I|	$R \in \mathbb{R}^{(8\times12)}$
$r(u,i)$	คะแนนจริงที่ผู้ใช้ u ให้แก่รายการ i (ถ้าทราบ)	$r(u1, i1) = 5$
$\hat{r}(u,i)$	คะแนนที่แบบจำลอง “พยากรณ์” ว่าผู้ใช้ u จะให้แก่รายการ i	$\hat{r}(u1, i5) = 2.21$
Ω	เซตของคู่ (u, i) ที่ทราบค่าคะแนน	$\lvert\Omega\rvert = 60$
$I(u)$	เซตของรายการที่ผู้ใช้ u เคยให้คะแนน	$\lvert I(u1)\rvert = 8$
$I(u,v)$	เซตของรายการที่ผู้ใช้ u และ v ให้คะแนนร่วมกัน	$\lvert I(u1, u2)\rvert = 4$
$\bar{r}(u)$	ค่าเฉลี่ยคะแนนของผู้ใช้ u	$\bar{r}(u1) = 3.375$
μ	ค่าเฉลี่ยคะแนนรวมของทั้งเมทริกซ์	$\mu = 3.700$

สัญกรณ์	ความหมาย	ตัวอย่างค่า
$L(u)$	รายการที่ระบบแนะนำแก่ผู้ใช้ u เรียงตามอันดับ	$L(u1) = \langle i9, i12, i8 \rangle$
K	ความยาวของรายการแนะนำที่นำไปแสดง	$K = 3{,}10{,}20$

ประเด็นสำคัญ ชุดข้อมูลมาตรฐานประจำเล่ม

- **MovieMini 12** ผู้ใช้ 8 คน × ภาพยนตร์ 12 เรื่อง คะแนน 1–5 ดาว มีคะแนนที่ทราบ 60 ค่า จาก 96 ช่อง ชุดข้อมูลนี้เล็กพอที่จะคำนวณด้วยมือได้ทุกขั้นตอน จึงถูกใช้ซ้ำในทุกบทของตำรา เมื่อผู้อ่านพบชื่อ EMMA หรือ บดินทร์ ในบทใด ให้เข้าใจว่าเป็นข้อมูลชุดเดียวกันเสมอ ทำให้เปรียบเทียบผลของขั้นตอนวิธีต่าง ๆ บนข้อมูลเดียวกันได้โดยตรง
- **RSLab Synth** ผู้ใช้ 300 คน × รายการ 200 รายการ สร้างขึ้นจากปัจจัยแฝงที่ทราบค่าจริง จึงใช้ตรวจสอบได้ว่าขั้นตอนวิธีเรียนรู้สิ่งที่ควรเรียนรู้ได้จริงหรือไม่ ใช้ในภาพประกอบและภาคปฏิบัติที่ต้องการข้อมูลขนาดใหญ่กว่า
- **MovieLens** ชุดข้อมูลจริงมาตรฐานของวงการ จัดทำโดยกลุ่มวิจัย GroupLens มหาวิทยาลัยมินนิโซตา ใช้ในภาคปฏิบัติตั้งแต่บทที่ 1 เป็นต้นไป

1.1 ภาวะข้อมูลท่วมท้นและเหตุผลของการมีอยู่ของระบบผู้แนะนำ

ลองนึกภาพว่าท่านเปิดแอปพลิเคชันสตรีมมิงเพลงในคืนวันศุกร์ แล้วต้องการฟังเพลงสักเพลงที่ “ใช่” คลังเพลงของบริการนั้นมีมากกว่า 250 ล้านแทร็ก หากท่านฟังแต่ละเพลงเพียง 3 วินาทีเพื่อตัดสินใจว่าชอบหรือไม่ โดยไม่หลับไม่พักเลยแม้แต่วินาทีเดียว ท่านจะต้องใช้เวลาเกือบ 24 ปี จึงจะฟังครบทั้งคลัง

เหตุการณ์นี้นี่ไม่ใช่การเปรียบเปรย แต่เป็นการคำนวณตรงไปตรงมา และเป็นเหตุผลทั้งหมดที่ทำให้ระบบผู้แนะนำมีอยู่ ปัญหาของยุคดิจิทัลไม่ใช่การขาดแคลนตัวเลือก แต่คือการมีตัวเลือกมากเกินกว่าที่มนุษย์คนหนึ่งจะพิจารณาได้ทัน สภาวะเช่นนี้เรียกว่า ภาวะข้อมูลท่วมท้น

> **นิยาม 1.1 ภาวะข้อมูลท่วมท้น (Information Overload)**
>
> สภาวะที่ปริมาณสารสนเทศหรือจำนวนทางเลือกที่ผู้ตัดสินใจได้รับ **เกินขีดความสามารถในการประมวลผลของผู้ตัดสินใจนั้น** ทำให้คุณภาพและความเร็วของการตัดสินใจ **ลดลง** แทนที่จะเพิ่มขึ้นตามปริมาณสารสนเทศที่มากขึ้น

1.1.1 การวัดภาวะข้อมูลท่วมท้นเชิงปริมาณ

แนวคิดเรื่องข้อมูลท่วมท้นจะมีประโยชน์ในเชิงวิศวกรรมก็ต่อเมื่อวัดเป็นตัวเลขได้ วิธีวัดที่ง่ายที่สุดคือประมาณเวลาที่ต้องใช้หากผู้ใช้จะสำรวจคลังทั้งหมดด้วยตนเอง กำหนดให้ผู้ใช้ใช้เวลาพิจารณารายการละ τ (เทา) วินาที และคลังรายการมีขนาด $|I|$ เวลาที่ต้องใช้ในการค้นหาแบบสำรวจทั้งหมด (Exhaustive Search) คือ

$$T(\textit{สำรวจทั้งคลัง}) = \tau \cdot |I| \quad (1.1)$$

ตัวอย่างการคำนวณ 1.1 เวลาที่ต้องใช้ในการสำรวจคลังทั้งหมด

โจทย์ จงคำนวณเวลาที่ผู้ใช้ต้องใช้ในการสำรวจคลังของแพลตฟอร์มสามแห่ง หากพิจารณารายการละ 3 วินาที (สำหรับสองแห่งแรก) และ 5 วินาที (สำหรับร้านค้าออนไลน์ ซึ่งต้องอ่านรายละเอียดสินค้า)

ขั้นที่ 1 แทนค่าลงในสมการที่ (1.1)

$$T = 3 \text{ วินาที} \times 250{,}000{,}000 \text{ รายการ} = 750{,}000{,}000 \text{ วินาที}$$

ขั้นที่ 2 แปลงหน่วยให้เป็นสิ่งที่มนุษย์เข้าใจได้

750,000,000 ÷ 86,400 (วินาทีต่อวัน) = 8,680.6 วัน ≈ 23.8 ปี

ขั้นที่ 3 ทำซ้ำกับแพลตฟอร์มอื่น

แพลตฟอร์ม (ประมาณการ)	ขนาดคลัง $\|I\|$	τ (วินาที)	เวลาที่ต้องใช้
บริการสตรีมมิงวิดีโอ	≈ 8,000 เรื่อง	3	6.7 ชั่วโมง
บริการสตรีมมิงเพลง	≈ 250,000,000 แทร็ก	3	23.8 ปี
ร้านค้าออนไลน์ขนาดใหญ่	≈ 600,000,000 รายการ	5	95.1 ปี

ขั้นที่ 4 ตีความ

- ผลการคำนวณแสดงให้เห็นว่า การสำรวจรายการทั้งหมดด้วยตนเองไม่ใช่วิธีที่ใช้ได้จริง แม้คลังภาพยนตร์ประมาณ 8,000 เรื่องจะใช้เวลาราว 6.7 ชั่วโมง แต่ระยะเวลาดังกล่าวก็ยาวเกินกว่าผู้ใช้ทั่วไปจะใช้เพื่อเลือกภาพยนตร์เพียงหนึ่งเรื่อง ยิ่งไปกว่านั้น คลังเพลง 250 ล้านแทร็กต้องใช้เวลาประมาณ 23.8 ปี และร้านค้าออนไลน์ที่มีสินค้า 600 ล้านรายการต้องใช้เวลาประมาณ 95.1 ปี โดยสมมติว่าผู้ใช้พิจารณารายการอย่างต่อเนื่องโดยไม่หยุดพัก ตัวเลขเหล่านี้จึงเป็นเพียงค่าต่ำสุดในทางทฤษฎีเท่านั้น
- ความแตกต่างดังกล่าวไม่ได้หมายถึงเพียง “คลังหนึ่งใหญ่กว่าอีกคลังหนึ่ง” แต่แสดงถึงการเปลี่ยนระดับของปัญหา จากกรณีที่การสำรวจทั้งคลังทำได้ยาก ไปสู่กรณีที่ไม่สามารถทำได้ภายในช่วงชีวิตของมนุษย์ ระบบผู้แนะนำจึงมีหน้าที่ลดพื้นที่การตัดสินใจ โดยคัดกรองและจัดอันดับรายการจำนวนมหาศาลให้เหลือรายการ Top-K ที่มีแนวโน้มเหมาะสมกับผู้ใช้แต่ละคน แทนที่จะให้ผู้ใช้ตรวจสอบรายการทั้งหมดด้วยตนเอง

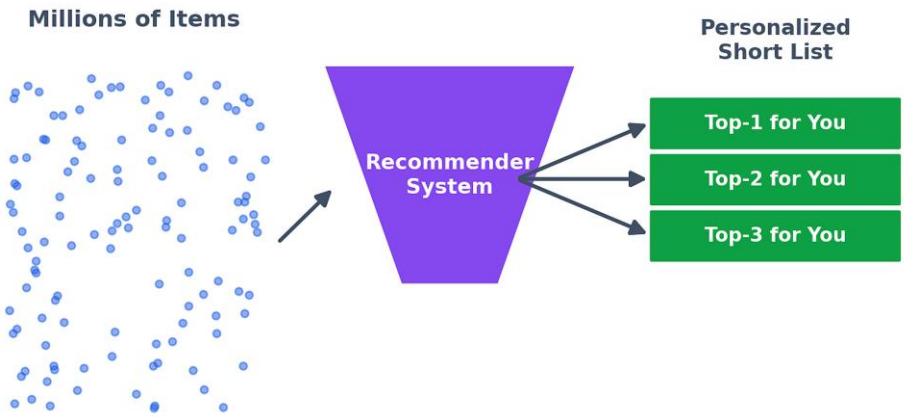
ดังนั้น คุณค่าหลักของระบบผู้แนะนำไม่ได้อยู่ที่การเพิ่มจำนวนตัวเลือก แต่คือการลดเวลาและภาระในการตัดสินใจ พร้อมเพิ่มโอกาสที่ผู้ใช้จะค้นพบรายการที่เหมาะสมจากคลังขนาดใหญ่ได้ทันเวลาที่ต้องการตัดสินใจ

1.1.2 ระบบค้นคืนสารสนเทศ เทียบกับ ระบบผู้แนะนำ

ผู้เริ่มต้นศึกษามักสับสนระหว่างเครื่องมือค้นหา (Search Engine) กับระบบผู้แนะนำ เพราะทั้งสองต่างทำหน้าที่ “กรอง” สารสนเทศเหมือนกัน แต่ทั้งสองแตกต่างกันในจุดที่สำคัญที่สุด นั่นคือใครเป็นฝ่ายเริ่มต้นบทสนทนา

ตารางที่ 1.3 เปรียบเทียบระบบค้นคืนสารสนเทศกับระบบผู้แนะนำ

ประเด็นเปรียบเทียบ	ระบบค้นคืนสารสนเทศ (Information Retrieval)	ระบบผู้แนะนำ (Recommender System)
ผู้เริ่มต้น	ผู้ใช้เป็นฝ่ายเริ่ม (Pull)	ระบบเป็นฝ่ายเริ่ม (Push)
ข้อมูลนำเข้าจากผู้ใช้	ข้อคำถาม (Query) ที่ผู้ใช้พิมพ์ชัดเจน	ประวัติพฤติกรรมและบริบท โดยผู้ใช้ไม่ต้องพิมพ์อะไร
ข้อสมมติเกี่ยวกับผู้ใช้	ผู้ใช้รู้ว่าตนต้องการอะไร และแปลงเป็นคำค้นได้	ผู้ใช้อาจยังไม่รู้ว่าตนต้องการอะไร
ผลลัพธ์สำหรับผู้ใช้ต่างคน	มักเหมือนกันสำหรับข้อคำถามเดียวกัน	ต่างกันสำหรับผู้ใช้แต่ละคนโดยเจตนา
เกณฑ์ความสำเร็จหลัก	ผลลัพธ์ตรงกับข้อคำถาม (Relevance to query)	ผู้ใช้พอใจและมีปฏิสัมพันธ์ต่อ (Relevance to user)
ตัวอย่างคำถามที่ระบบตอบ	“มีหนังชื่อ Parasite ไหม”	“คืนนี้ฉันน่าจะอยากดูอะไร”



ภาพที่ 1.2 ระบบผู้แนะนำทำหน้าที่กรองตัวเลือกนับล้านให้เหลือรายการสั้นที่เหมาะกับผู้ใช้แต่ละคน

ความต่างข้อสุดท้ายในตารางที่ 1.3 เป็นหัวใจของทั้งเล่ม เครื่องมือค้นหาที่ดีตอบคำถามที่ผู้ใช้ถาม ส่วนระบบผู้แนะนำที่ดีตอบคำถามที่ผู้ใช้ยังไม่ได้ถาม และบ่อยครั้งยังไม่รู้ตัวว่าอยากถาม คุณสมบัตินี้เรียกว่าการปรับให้เหมาะเฉพาะบุคคล (Personalization)

1.2 องค์ประกอบของระบบและวงจรข้อมูล

นิยาม 1.2 ระบบผู้แนะนำ (Recommender System)

ระบบกรองสารสนเทศ (Information Filtering System) ที่ **ประมาณค่าความชอบหรือความเกี่ยวข้อง** ที่ผู้ใช้คนหนึ่งจะมีต่อรายการที่ผู้ใช้คนนั้น **ยังไม่เคยพบ** แล้วเลือกและจัดลำดับรายการจำนวนน้อยเพื่อนำเสนอภายใต้ข้อจำกัดด้านเวลา ทรัพยากร และนโยบายของระบบ

นิยามข้างต้นมีคำสำคัญสามคำที่ควรสังเกต คำแรกคือ “ประมาณค่า” ซึ่งบอกว่างานนี้เป็นการอนุมานภายใต้ความไม่แน่นอน ไม่ใช่การค้นหาคำตอบที่ถูกต้องเพียงหนึ่งเดียว คำที่สองคือ “ยังไม่เคยพบ” ซึ่งบอกว่าเป้าหมายอยู่ที่สิ่งที่ยังไม่มีข้อมูล ไม่ใช่สิ่งที่ผู้ใช้รู้จักดีอยู่แล้ว และคำที่สามคือ “ภายใต้ข้อจำกัด” ซึ่งเตือนว่าระบบที่แม่นยำที่สุดแต่ตอบสนองใน 10 วินาที ไม่มีค่าใดในทางปฏิบัติ

1.2.1 องค์ประกอบและบริบท

ตารางที่ 1.4 องค์ประกอบของระบบผู้แนะนำ พร้อมคำถามออกแบบที่ต้องตอบก่อนเขียนโปรแกรมบรรทัดแรก

องค์ประกอบ	สัญกรณ์	ความหมาย	คำถามออกแบบที่มักถูกมองข้าม
ผู้ใช้ (Users)	U	เอนทิตีที่ระบบให้บริการ อาจเป็นบุคคล ครัวเรือน หรือกลุ่ม	หน่วยของ “ผู้ใช้” คืออะไร บัญชีเดียวที่คนทั้งบ้านใช้ร่วมกันนับเป็นกี่ผู้ใช้ ผู้ที่ยังไม่ล็อกอินจะนับอย่างไร
รายการ (Items)	I	วัตถุที่ถูกแนะนำ เช่น ภาพยนตร์ สินค้า บทความ	ระดับความละเอียดคืออะไร (ตอน / ซีซัน / ซีรีส์ทั้งเรื่อง) สินค้าที่หมดสต็อกยังอยู่ในคลังหรือไม่
ปฏิสัมพันธ์ (Interactions)	$\mathcal{D}$	เหตุการณ์ที่เชื่อมผู้ใช้กับรายการ พร้อมค่าผลป้อนกลับ เวลา และบริบท	เหตุการณ์ใดนับเป็นสัญญาณเชิงบวก การเปิดดู 5 วินาทีแล้วปิดนับหรือไม่
บริบท (Context)	x	สภาพแวดล้อมขณะเกิดปฏิสัมพันธ์ เช่น เวลา สถานที่ อุปกรณ์ ผู้ร่วมใช้งาน	บริบทใดที่มีผลจริงต่อความชอบ และเรามีวิธีวัดหรือไม่ว่ามันมีผล

เขียนเหตุการณ์ปฏิสัมพันธ์หนึ่งเหตุการณ์ในรูปทัปเพิล (tuple) ได้ว่า

$$\mathcal{D} = (u, i, y, t, x) | u \in U, i \in I \quad (1.2)$$

โดยที่ y คือค่าผลป้อนกลับ (คะแนน หรือค่าทวิภาค 0/1), t คือเวลาประทับ (Timestamp) และ x คือเวกเตอร์บริบท

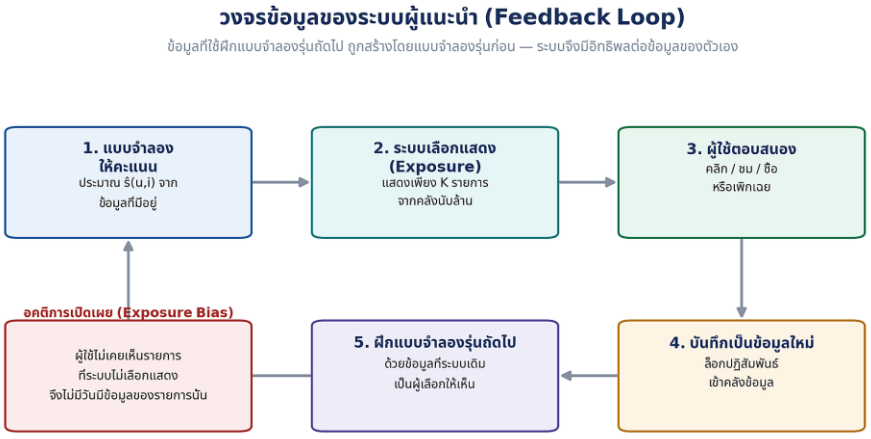
ข้อควรระวัง ข้อมูลที่ไม่ได้เก็บ ณ เวลานั้น จะไม่มีวันย้อนกลับไปเก็บได้

การเก็บเวลาประทับ t และเวกเตอร์บริบท x ตั้งแต่วันแรกที่ระบบเริ่มทำงาน เป็นการลงทุนที่ให้ผลตอบแทนสูงที่สุดอย่างหนึ่งในการออกแบบระบบผู้แนะนำ เหตุผลตรงไปตรงมา คือ คะแนนหรือการคลิกที่บันทึกไว้โดยไม่มีเวลาประทับ ทำให้ไม่สามารถแบ่งข้อมูลตามเวลาเพื่อประเมินผลอย่างซื่อสัตย์ได้เลย และไม่มีวิธีใดกอบกู้ได้ในภายหลัง

ผลลัพธ์ที่ตามมาคือ งานวิจัยหรือระบบที่ใช้ข้อมูลไม่มีเวลาประทับ ถูกบังคับให้ใช้การแบ่งข้อมูลแบบสุ่ม (Random Split) ซึ่งทำให้แบบจำลอง “เห็นอนาคต” ขณะฝึก และรายงานตัวชี้วัดที่สูงเกินจริงอย่างเป็นระบบ ประเด็นนี้จะกลับมาอย่างเป็นทางการในบทที่ 2

1.2.2 วงจรข้อมูล: เหตุใดข้อมูลของระบบผู้แนะนำจึงไม่เหมือนข้อมูลทั่วไป

ในงานการเรียนรู้ของเครื่องทั่วไป เช่น การจำแนกภาพ ข้อมูลฝึกถูกเก็บมาจากโลกภายนอกโดยอิสระจากตัวแบบจำลอง แต่ในระบบผู้แนะนำไม่เป็นเช่นนั้น ข้อมูลที่จะใช้ฝึกแบบจำลองรุ่นถัดไป ถูกสร้างขึ้นจากสิ่งที่แบบจำลองรุ่นก่อนเลือกแสดง คุณสมบัตินี้เรียกว่า วงจรป้อนกลับ (Feedback Loop) และเป็นเหตุผลเชิงโครงสร้างที่ทำให้การประเมินผลระบบผู้แนะนำยากกว่างานอื่นอย่างมีนัยสำคัญ



ภาพที่ 1.3 วงจรข้อมูลของระบบผู้แนะนำ ข้อมูลฝึกของแบบจำลองรุ่นถัดไปถูกคัดเลือกโดยแบบจำลองรุ่นก่อน

พิจารณาผลที่ตามมาให้ละเอียด สมมติว่าระบบไม่เคยแสดงภาพยนตร์สารคดีเรื่องหนึ่งแก่ผู้ใช้คนใดเลย เพราะแบบจำลองรุ่นแรกให้คะแนนต่ำโดยบังเอิญ ผลก็คือจะไม่มีวันเกิดข้อมูลปฏิสัมพันธ์กับภาพยนตร์เรื่องนั้น และเมื่อฝึกแบบจำลองรุ่นถัดไป ภาพยนตร์เรื่องนั้นก็จะยังคงมีข้อมูลเป็นศูนย์ ระบบจึงยืนยันความเชื่อเดิมของตัวเองไปเรื่อย ๆ โดยไม่มีหลักฐานใดมาโต้แย้ง

ประเด็นสำคัญ ข้อสรุปสำคัญสามข้อจากวงจรป้อนกลับ

- **ข้อมูลที่เก็บได้ไม่ใช่ตัวอย่างสุ่ม** ในภาษาสถิติเรียกว่าข้อมูลสูญหายแบบไม่สุ่ม (Missing Not At Random หรือ MNAR) การที่ผู้ใช้ไม่เคยให้คะแนนรายการหนึ่ง อาจเป็นเพราะไม่ชอบ หรือเพราะระบบไม่เคยแสดงให้เห็น ซึ่งเป็นคนละเรื่องกันโดยสิ้นเชิง
- **ตัวชี้วัดออฟไลน์อาจดีขึ้นขณะที่ประสบการณ์จริงแย่ลง** เพราะการประเมินออฟไลน์ทำบนข้อมูลที่ระบบเดิมเป็นผู้เลือกไว้ให้ แบบจำลองที่ “เลียนแบบระบบเดิมได้แม่นที่สุด” จึงได้คะแนนสูงสุด แม้จะไม่ได้ดีขึ้นสำหรับผู้ใช้เลย
- **การแก้ปัญหาต้องทำที่ระดับการเก็บข้อมูล ไม่ใช่ที่ระดับแบบจำลอง** แนวทางมาตรฐานคือบันทึกความน่าจะเป็นของการถูกแสดง (Propensity) ไว้ตั้งแต่ต้น และสงวนสัดส่วนการเข้าชมส่วนน้อยไว้สำหรับการสำรวจแบบสุ่ม เพื่อให้มีข้อมูลที่ปลอดจากอคติไว้ใช้ประเมิน

1.3 คุณค่าทางธุรกิจและปรากฏการณ์หางยาว

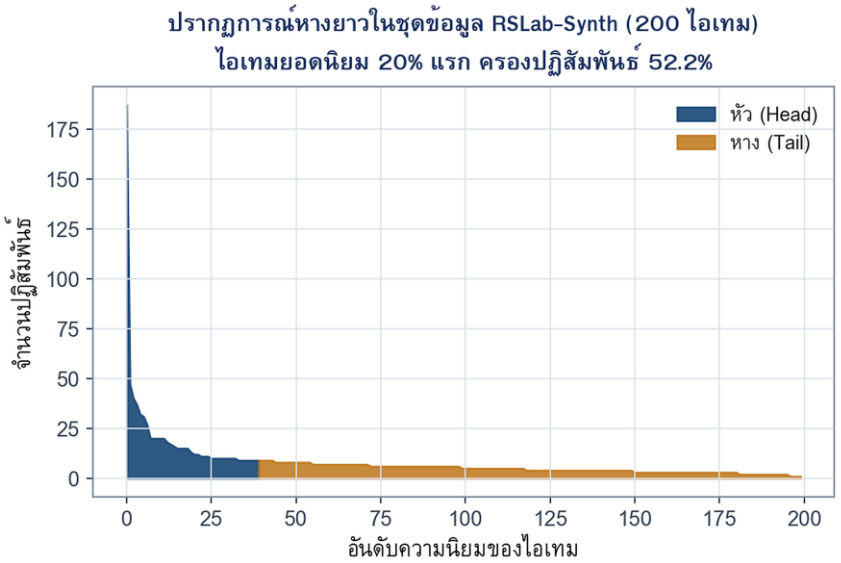
ระบบผู้แนะนำมิใช่เทคโนโลยีเสริมที่ “มีก็ดี” แต่เป็นสินทรัพย์หลักทางธุรกิจของแพลตฟอร์มดิจิทัลสมัยใหม่ อย่างไรก็ตาม ตัวเลขที่ถูกอ้างถึงบ่อยที่สุดในวงการนี้จำนวนหนึ่งกลับมีคุณภาพของแหล่งอ้างอิงแตกต่างกันมาก และการแยกแยะให้ออกเป็นทักษะทางวิชาการที่สำคัญไม่แพ้การเข้าใจขั้นตอนวิธี

1.3.1 ปรากฏการณ์หางยาว

นอกเหนือจากผลตอบแทนโดยตรง คุณค่าเชิงโครงสร้างที่สำคัญที่สุดของระบบผู้แนะนำคือการปลดล็อกสิ่งที่เรียกว่า ปรากฏการณ์หางยาว

นิยาม 1.3 ปรากฏการณ์หางยาว (Long Tail Phenomenon)

รูปแบบการกระจายความนิยมที่รายการจำนวนน้อย (ส่วนหัว, Head) ครองสัดส่วนปฏิสัมพันธ์หรือยอดขายส่วนใหญ่ ขณะที่รายการจำนวนมหาศาล (ส่วนหาง, Tail) แต่ละชิ้นมีปฏิสัมพันธ์น้อยมาก แต่เมื่อ **รวมกันทั้งหาง** กลับมีนัยสำคัญทางธุรกิจ



ภาพที่ 1.4 ปรากฏการณ์หางยาวในชุดข้อมูล RSLab Synth รายการยอดนิยมส่วนน้อยครองปฏิสัมพันธ์ส่วนใหญ่

ในทางคณิตศาสตร์ การกระจายเช่นนี้มักประมาณได้ด้วยกฎกำลัง (Power Law)

$$p(\text{ความนิยม} = c) \propto c^{(-\alpha)} \text{ โดยทั่วไป} \alpha \in [1.5, 3.0] \quad (1.3)$$

รูปแบบการกระจายความนิยมที่รายการจำนวนน้อย (ส่วนหัว, Head) ครองสัดส่วนปฏิสัมพันธ์หรือยอดขายส่วนใหญ่ ขณะที่รายการจำนวนมหาศาล (ส่วนหาง, Tail) แต่ละชิ้นมีปฏิสัมพันธ์น้อยมาก แต่เมื่อ รวมกันทั้งหางกลับมีนัยสำคัญทางธุรกิจ

เหตุผลเชิงเศรษฐศาสตร์ของเรื่องนี้ตรงไปตรงมา ร้านค้าที่มีหน้าร้านจริงมีชั้นวางจำกัด จึงคุ้มค่าที่จะเก็บเฉพาะสินค้าส่วนหัว แต่ร้านค้าออนไลน์มีต้นทุนการเก็บสินค้าเพิ่มอีกหนึ่งรายการต่ำมาก ปัญหาจึงย้ายจากคำถามว่า “มีของหรือไม่” ไปเป็นคำถามว่า “ผู้ใช้จะค้นเจอของนั้นได้อย่างไร” และคำถามหลังนี้เองคือหน้าที่ของระบบผู้แนะนำ

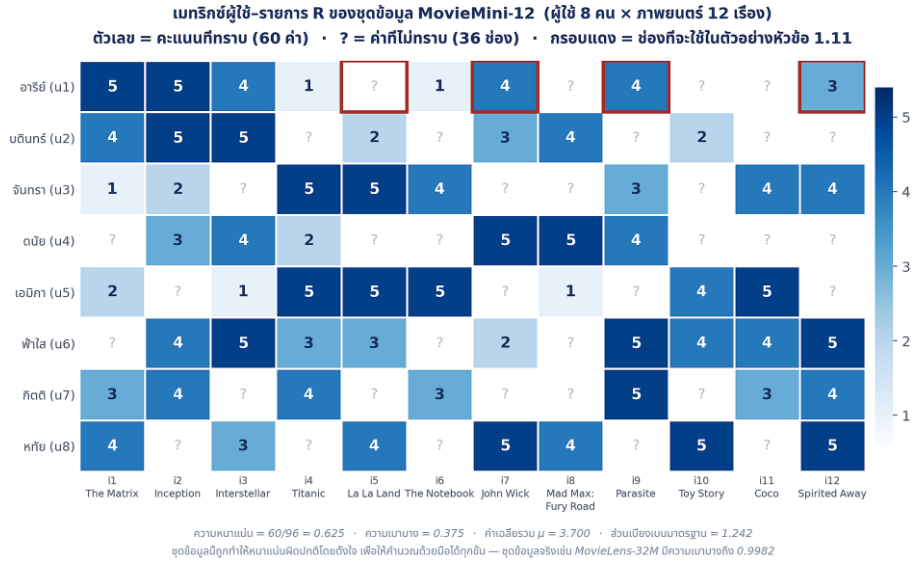
1.3 นิยามเชิงรูปนัยของปัญหา

จนถึงจุดนี้เราอธิบายระบบผู้แนะนำด้วยภาษาธรรมชาติ ซึ่งเพียงพอสำหรับการสื่อสาร แต่ไม่เพียงพอสำหรับการออกแบบขั้นตอนวิธีหรือการพิสูจน์สมบัติใด ๆ หัวข้อนี้จึงแปลงคำอธิบายทั้งหมดให้เป็นคณิตศาสตร์

กำหนดให้ U เป็นเซตของผู้ใช้ และ I เป็นเซตของรายการ สิ่งที่เราสนใจคือ ฟังก์ชันอรรถประโยชน์ (Utility Function) ซึ่งให้ค่าความชอบของผู้ใช้ที่มีต่อรายการ

$$f: U \times I \to \mathbb{R} \quad (1.5)$$

ปัญหาทั้งหมดของสาขานี้สรุปได้ในประโยคเดียวว่า เรารู้ค่าของ f เพียงบางส่วน และต้องประมาณค่าส่วนที่เหลือ ส่วนที่รู้แล้วถูกจัดเก็บในรูป เมทริกซ์ผู้ใช้–รายการ (User–Item Matrix) $R \in \mathbb{R}^{(|U| \times |I|)}$ โดยที่ช่อง $r(u, i)$ บรรจุคะแนนหากทราบ และเว้นว่าง (แทนด้วย “?”) หากยังไม่ทราบ



ภาพที่ 1.6 เมทริกซ์ผู้ใช้–รายการของชุดข้อมูล MovieMini 12

1.4.1 ความหนาแน่นและความเบาบาง

คุณสมบัติเชิงตัวเลขที่สำคัญที่สุดของเมทริกซ์ผู้ใช้–รายการ คือสัดส่วนของช่องที่มีข้อมูล นิยามได้สองแบบซึ่งเป็นส่วนเติมเต็มของกันและกัน

ความหนาแน่น (Density) $= |\Omega| \div (|U| \cdot |I|)$

ความเบาบาง (Sparsity) = 1 – ความหนาแน่น (1.7)

ตัวอย่างการคำนวณ 1.3 ความหนาแน่นของ MovieMini 12 เทียบกับชุดข้อมูลจริง

ขั้นที่ 1 นับช่องทั้งหมดและช่องที่มีข้อมูลของ MovieMini 12

$|U| \cdot |I| = 8 \times 12 = 96$ ช่อง $|\Omega| =$ 60 ค่า

ขั้นที่ 2 แทนลงในสมการที่ (1.7)

ความหนาแน่น = 60 ÷ 96 = 0.625 ความเบาบาง = 1 – 0.625 = 0.375

ขั้นที่ 3 เปรียบเทียบกับชุดข้อมูลจริง

ชุดข้อมูล	ผู้ใช้	รายการ	จำนวนคะแนน	ความเบาบาง
MovieMini 12 (ในตำรานี้)	8	12	60	**0.3750**
MovieLens 100K	943	1,682	100,000	0.9370
MovieLens 25M (พ.ศ. 2562)	162,541	62,423	25,000,095	0.9975
MovieLens 32M (พ.ศ. 2567)	200,948	87,585	32,000,204	**0.9982**

ขั้นที่ 4 ตีความ

ตัวเลข 0.9982 หมายความว่าใน 10,000 ช่องของเมทริกซ์ มีข้อมูลจริงเพียง 18 ช่อง MovieMini 12 จึงหนาแน่นผิดปกติอย่างยิ่งโดยเจตนา เพื่อให้คำนวณด้วยมือได้ทุกขั้น **ผู้อ่านต้องไม่สรุปสมรรถนะของขั้นตอนวิธีใด ๆ จากชุดข้อมูลของเล่นนี้ ข้อควรระวังนี้ใช้กับทุกตัวอย่างในตำราเล่มนี้**

1.4.2 สองรูปแบบของโจทย์ที่ต้องแยกให้ขาดจากกัน

เมื่อมีเมทริกซ์ R แล้ว คำถามถัดไปคือ “เราต้องการอะไรจากข้อมูลในเมทริกซ์นี้” คำตอบมีสองแบบที่ต่างกันอย่างสิ้นเชิง และการสับสนระหว่างสองแบบนี้เป็นต้นเหตุของความผิดพลาดจำนวนมากในงานวิจัยและในระบบจริง

ประเด็นสำคัญ กรอบแนวคิด 1.1 การพยากรณ์คะแนน เทียบกับ การจัดอันดับ

(ก) การพยากรณ์คะแนน (Rating Prediction)

ประมาณค่า $\hat{r}(u,i)$ให้ใกล้เคียงกับ $r(u,i)$ ที่แท้จริงมากที่สุด สำหรับช่องที่ยังว่าง เป็นโจทย์แบบการถดถอย (Regression) วัดผลด้วยรากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง (RMSE) หรือค่าเฉลี่ยความคลาดเคลื่อนสัมบูรณ์ (MAE)

(ข) การจัดอันดับสูงสุด K รายการ (Top K Recommendation)

สร้างรายการเรียงลำดับ L(u) ความยาว K ที่ทำให้รายการซึ่งผู้ใช้ชอบจริงอยู่ในตำแหน่งต้น ๆ เป็นโจทย์แบบการเรียนรู้เพื่อจัดอันดับ (Learning to Rank) วัดผลด้วย Precision@K, Recall@K หรือ nDCG@K

ความสัมพันธ์ที่ต้องจำ แบบจำลองที่พยากรณ์คะแนนได้แม่นยำ **ไม่จำเป็น** ต้องจัดอันดับได้ดี เพราะ RMSE ให้น้ำหนักเท่ากันกับทุกช่อง รวมทั้งช่องที่ผู้ใช้จะให้คะแนนต่ำ ซึ่งไม่มีวันปรากฏใน Top K อยู่แล้ว ในทางกลับกัน การลดความคลาดเคลื่อนของคะแนนสูง ๆ เพียงเล็กน้อย อาจสลับลำดับได้ทั้งรายการ ระบบระดับอุตสาหกรรมส่วนใหญ่จึงหันไปใช้ฟังก์ชันสูญเสียเชิงอันดับ

ข้อควรระวัง กับดักคลาสสิกของ Netflix Prize

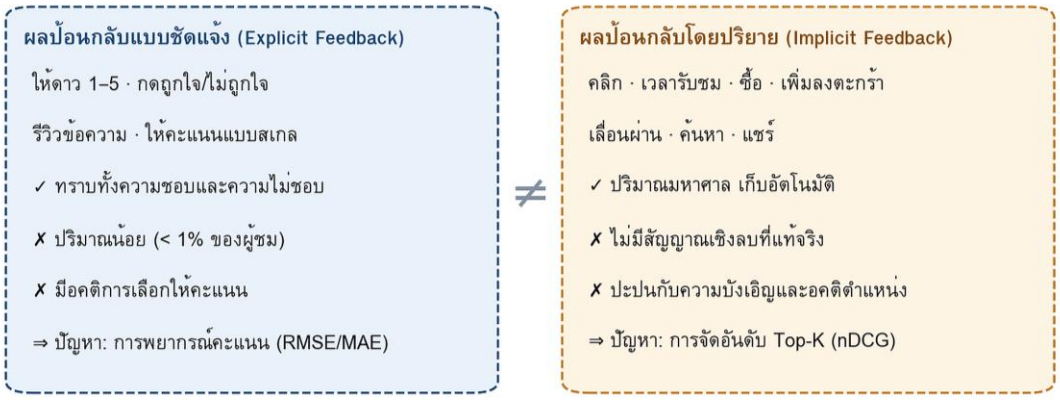
ระหว่าง ค.ศ. 2006–2009 เน็ตฟลิกซ์จัดการแข่งขันชิงรางวัลหนึ่งล้านดอลลาร์สหรัฐ ให้แก่ทีมที่ลดค่า RMSE ของระบบเดิมลงได้ร้อยละ 10 การแข่งขันนี้ดึงนักวิจัยหลายพันคนเข้าสู่สาขา และให้กำเนิดเทคนิคการแยกตัวประกอบเมทริกซ์ที่เป็นแกนกลางของบทที่ 5

แต่ข้อเท็จจริงที่ควรรู้คู่กันคือ **เน็ตฟลิกซ์ไม่เคยนำแบบจำลองของทีมผู้ชนะขึ้นใช้งานจริงเลยโจทย์ที่แข่งขัน (พยากรณ์จำนวนดาว) ไม่ใช่โจทย์ทางธุรกิจ (เลือกสิ่งที่ควรแสดงบนหน้าจอ)**

บทเรียนนี้คือเหตุผลที่ตำราเล่มนี้จัดให้บทที่ 2 ว่าด้วยการประเมินผล มาก่อนบทที่ว่าด้วยขั้นตอนวิธีทั้งหมด เพราะการเลือกวัดผิด ทำให้ความพยายามทั้งหมดที่ตามมาสูญเปล่า

1.5 ประเภทของข้อมูลและผลป้อนกลับ

คุณภาพของระบบผู้แนะนำถูกกำหนดโดยข้อมูลผลป้อนกลับที่ใช้ฝึกมากกว่าโดยความซับซ้อนของขั้นตอนวิธี ผลป้อนกลับแบ่งเป็นสองประเภทหลักที่มีสมบัติเชิงสถิติต่างกันอย่างสิ้นเชิง จนต้องใช้ขั้นตอนวิธี ฟังก์ชันสูญเสีย และตัวชี้วัดคนละชุด



ภาพที่ 1.7 เปรียบเทียบผลป้อนกลับแบบชัดแจ้งกับแบบโดยปริยาย พร้อมนัยที่มีต่อการเลือกโจทย์และตัวชี้วัด

ตารางที่ 1.6 เปรียบเทียบผลป้อนกลับสองประเภทในเชิงสถิติและเชิงวิศวกรรม

ประเด็น	ชัดแจ้ง (Explicit Feedback)	โดยปริยาย (Implicit Feedback)
ตัวอย่างสัญญาณ	ดาว 1–5, ถูกใจ/ไม่ถูกใจ, รีวิวข้อความ	คลิก, เวลารับชม, การซื้อ, การเพิ่มลงตะกร้า
ปริมาณข้อมูล	น้อยมาก มักน้อยกว่าร้อยละ 1 ของการเปิดชม	มหาศาล เก็บอัตโนมัติทุกเหตุการณ์
สัญญาณเชิงลบ	มีจริง การให้ 1 ดาวคือ “ไม่ชอบ” อย่างชัดเจน	**ไม่มี การไม่คลิกอาจแปลว่า “ไม่เห็น”**
การตีความค่าที่บันทึก	ระดับความชอบ (Preference)	ความเชื่อมั่นว่ามีความชอบ (Confidence)
อคติหลักที่แฝงอยู่	อคติการเลือกให้คะแนนด้วยตนเอง (Self Selection Bias)	อคติตำแหน่งและอคติการเปิดเผย (Position & Exposure Bias)
ความหมายของช่องว่าง	ค่าสูญหาย (Missing) ห้ามเติมศูนย์	ศูนย์ที่มีน้ำหนักต่ำ ไม่ควรทิ้ง
โจทย์ที่เหมาะสม	การพยากรณ์คะแนน (RMSE / MAE)	การจัดอันดับ Top K (nDCG / Recall)
ขั้นตอนวิธีตัวแทน	BiasedMF, SVD++ (บทที่ 5)	WRMF/iALS, BPR, EASE (บทที่ 4–5)

คุณภาพของระบบผู้แนะนำถูกกำหนดโดยข้อมูลผลป้อนกลับที่ใช้ฝึกมากกว่าโดยความซับซ้อนของขั้นตอนวิธี ผลป้อนกลับแบ่งเป็นสองประเภทหลักที่มีสมบัติเชิงสถิติต่างกันอย่างสิ้นเชิง จนต้องใช้ขั้นตอนวิธี ฟังก์ชันสูญเสีย และตัวชี้วัดคนละชุด ประเด็นสำคัญของข้อมูลผลป้อนกลับ

1) **ข้อมูลสัญญาณเชิงลบของระบบผู้แนะนำ**

สัญญาณเชิงลบ (Negative Signal) หมายถึงข้อมูลที่แสดงว่าผู้ใช้ไม่ชอบหรือไม่สนใจรายการหนึ่ง

สัญญาณเชิงลบ (Negative Signal) หมายถึงข้อมูลที่แสดงว่าผู้ใช้ไม่ชอบหรือไม่สนใจรายการหนึ่ง

- สำหรับ ผลป้อนกลับแบบชัดแจ้ง (Explicit Feedback) ค่าสัญญาณเชิงลบมีความชัดเจน เช่น- ให้คะแนน 1 ดาว หมายถึงไม่ชอบ หรือการกด Dislike รวมถึงการเขียนรีวิวในเชิงลบ ดังนั้น ระบบสามารถระบุได้ค่อนข้างตรงไปตรงมาว่า $r_{ui} = 1 \quad \Rightarrow$ ผู้ใช้ u ไม่ชอบรายการ i
- แต่สำหรับ ผลป้อนกลับโดยปริยาย (Implicit Feedback) โดยทั่วไปไม่มีสัญญาณเชิงลบที่แน่นอน ตัวอย่างเช่น ผู้ใช้ไม่คลิกภาพยนตร์เรื่องหนึ่ง อาจเกิดจากหลายสาเหตุ ได้แก่
  - ผู้ใช้เห็นแล้วแต่ไม่สนใจ
  - ผู้ใช้ยังไม่เห็นรายการนั้น
  - รายการอยู่ในตำแหน่งล่างเกินไป
  - ผู้ใช้ไม่มีเวลาเปิดดู
  - ชื่อหรือภาพปกไม่น่าสนใจ แม้เนื้อหาอาจตรงกับความชอบ

  ดังนั้นจึงไม่ควรสรุปว่า หากผู้ใช้ ไม่คลิก ≠ ไม่ชอบ แต่ควรตีความว่าเป็น “ข้อมูลที่มีระดับความเชื่อมั่นต่ำ” ว่าผู้ใช้อาจไม่สนใจ

2) อคติหลักของผลป้อนกลับ

- สำหรับผลป้อนกลับแบบชัดแจ้ง (Explicit Feedback) อคติหลักของผลป้อนกลับ คือ Self-Selection Bias หรืออคติจากการที่ผู้ใช้เลือกให้ข้อมูลด้วยตนเอง ผู้ใช้มักให้คะแนนเฉพาะรายการที่ตนเองมีแรงจูงใจจะประเมิน เช่น รายการที่ชอบมาก รายการที่ไม่ชอบอย่างมาก รายการที่เคยซื้อหรือรับชม รายการที่ผู้ใช้สนใจเป็นพิเศษ ส่วนรายการที่มีความรู้สึกเป็นกลางมักไม่ได้รับคะแนน ด้วยเหตุนี้ ข้อมูล Rating ที่เก็บได้จึงอาจไม่เป็นตัวแทนความรู้สึกของผู้ใช้ทั้งหมด

  ตัวอย่างเช่น ผู้ใช้รับชมภาพยนตร์ 20 เรื่อง แต่ให้คะแนนเพียง 3 เรื่อง ได้แก่ เรื่อง A: 5 ดาว เรื่อง B: 5 ดาว เรื่อง C: 1 ดาว ซึ่งหากพิจารณาเฉพาะข้อมูลที่บันทึกไว้ อาจเข้าใจว่าผู้ใช้มีความคิดเห็นเชิงบวกและลบระดับมากต่อภาพยนตร์ส่วนใหญ่ ทั้งที่ภาพยนตร์อีก 17 เรื่องอาจอยู่ในระดับปานกลาง แต่ผู้ใช้ไม่ได้ให้คะแนน

  ดังนั้น Self-Selection Bias จึงส่งผลให้
  - คะแนนที่สังเกตได้ไม่เป็นตัวแทนของรายการทั้งหมด
  - คะแนนสูงมากและต่ำมากอาจปรากฏบ่อยเกินจริง
  - ช่องว่างในเมทริกซ์ไม่ได้เกิดขึ้นแบบสุ่ม
  - ข้อมูลมีลักษณะ Missing Not at Random
  - การแทนช่องว่างด้วย 0 จะทำให้โมเดลเรียนรู้ผิดว่ารายการที่ไม่ได้รับคะแนนเป็นรายการที่ผู้ใช้ไม่ชอบ

  สำหรับผลป้อนกลับแบบชัดแจ้ง (Explicit Feedback) จะมีสัญญาณเชิงลบที่ชัดเจน แต่ข้อมูลมักมีปริมาณน้อยและได้รับผลกระทบจากการเลือกให้คะแนนของผู้ใช้

- สำหรับ ผลป้อนกลับโดยปริยาย (Implicit Feedback) มีอคติสำคัญสองประการ ได้แก่ Position Bias และ Exposure Bias
  - **Position Bias** หมายถึง ผู้ใช้มีแนวโน้มคลิกรายการที่อยู่ในตำแหน่งต้น ๆ มากกว่ารายการที่อยู่ด้านล่าง แม้ว่าความสนใจที่แท้จริงอาจเท่ากัน

ตัวอย่างเช่น

รายการ	ตำแหน่งแสดงผลในลิสต์ให้ผู้ใช้เลือก	จำนวนคลิก
ภาพยนตร์ A	1	500
ภาพยนตร์ B	20	50

จากตัวอย่าง ยังไม่สามารถสรุปได้ทันทีว่าภาพยนตร์ A ได้รับความนิยมมากกว่า B ถึง 10 เท่า เพราะ A มีโอกาสถูกมองเห็นมากกว่า

- **Exposure Bias** หมายถึง ผู้ใช้สามารถมีปฏิสัมพันธ์ได้เฉพาะกับรายการที่ระบบนำมาแสดงเท่านั้น ตัวอย่างเช่น ถ้าระบบไม่เคยแสดงภาพยนตร์ B แก่ผู้ใช้ การที่ไม่มีการคลิก B ไม่ได้หมายความว่า ผู้ใช้ไม่ชอบ แต่หมายความว่าผู้ใช้อาจไม่เคยมีโอกาสพิจารณา B

3) ความหมายของค่า “ไม่มีข้อมูล”

- ใน ผลป้อนกลับแบบชัดแจ้ง (Explicit Feedback) การไม่มี Rating ถือเป็น Missing Value เพราะไม่ทราบว่าผู้ใช้ชอบหรือไม่ชอบรายการนั้น
- ใน ผลป้อนกลับโดยปริยาย (Implicit Feedback) ระบบมักบันทึกค่าที่ไม่มีปฏิสัมพันธ์เป็น 0 แต่ค่า 0 ไม่ควรถือเป็น Negative Label ที่แน่นอน ควรกำหนดน้ำหนักความเชื่อมั่นต่ำกว่าเหตุการณ์ที่เกิดปฏิสัมพันธ์ เช่น

$$p_{ui} = \begin{cases} 1, & \text{ถ้าผู้ใช้มีปฏิสัมพันธ์กับรายการ} \\ 0, & \text{ถ้าไม่พบปฏิสัมพันธ์} \end{cases}$$

และกำหนด Confidence Weight เป็น

$$c_{ui} = 1 + \alpha \mathrm{n}_{ui}$$

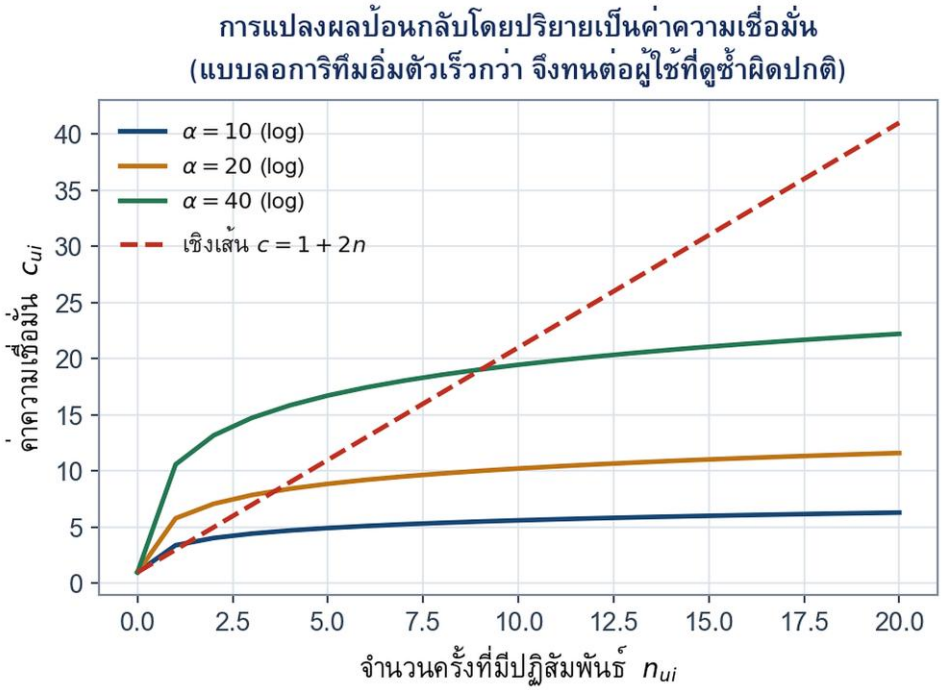
โดยจำนวนปฏิสัมพันธ์ n(u,i) หรือรายการที่มีการคลิก ซื้อ หรือรับชมมากจะมีน้ำหนักความเชื่อมั่นสูง ส่วนรายการที่มีค่าเป็นศูนย์ยังคงถูกใช้ได้ แต่ให้น้ำหนักต่ำ เพราะไม่ทราบว่าผู้ใช้ไม่ชอบหรือเพียงไม่เคยเห็น

1.5.1 การแปลงผลป้อนกลับโดยปริยายเป็นค่าความเชื่อมั่น

การเลือกฟังก์ชันแปลงจำนวนปฏิสัมพันธ์ n(u,i) เป็นค่าความเชื่อมั่น c(u,i) มีผลต่อความทนทานของแบบจำลองมากกว่าที่ผู้เริ่มต้นคาดคิด สองรูปแบบที่ใช้บ่อยคือ

$$c_{ui} = 1 + \alpha \mathrm{n}_{ui} \quad \text{(ฟังก์ชันแปลงเชิงเส้น)}$$

$$c_{ui} = 1 + \alpha \cdot \ln\left(1 + \frac{\mathrm{n}_{ui}}{\epsilon}\right) \text{ (ฟังก์ชันแปลงลอการิทึม)} \qquad (1.8)$$



ภาพที่ 1.8 เปรียบเทียบฟังก์ชันแปลงจำนวนปฏิสัมพันธ์เป็นค่าความเชื่อมั่น

จากภาพแสดงให้เห็นว่า การแปลงผลป้อนกลับโดยปริยายเป็นค่าความเชื่อมั่นด้วยฟังก์ชันรูปแบบลอการิทึมอิ่มตัวเร็วกว่า จึงทนต่อพฤติกรรมสุดโต่งได้ดีกว่า เนื่องจากจำนวนปฏิสัมพันธ์สูงผิดปกติอาจเกิดจากการเปิดเพลงวนอัตโนมัติ การรีเฟรชหน้าเว็บ การคลิกซ้ำโดยไม่ตั้งใจ บอตหรือสคริปต์อัตโนมัติ หรือ ข้อผิดพลาดของระบบบันทึกเหตุการณ์ เป็นต้น

ถ้าใช้ค่าความเชื่อมั่นเป็นน้ำหนักของค่าคลาดเคลื่อน ผู้ใช้ที่มีปฏิสัมพันธ์จำนวนมากจะมีอิทธิพลต่อการปรับพารามิเตอร์มากการแปลงแบบลอการิทึมช่วยให้ข้อมูลของผู้ใช้ทั่วไปยังมีความสำคัญ และไม่ถูกกลบด้วยผู้ใช้ที่ทำกิจกรรมหลายร้อยหรือหลายพันครั้ง ซึ่งการแปลงแบบลอการิทึมให้น้ำหนักมากกับปฏิสัมพันธ์ช่วงแรก แต่ลดน้ำหนักของการทำซ้ำครั้งหลัง ๆ จึงช่วยไม่ให้การคลิกหรือรับชมซ้ำจำนวนมากผิดปกติมีอิทธิพลต่อแบบจำลองมากเกินไป และทำให้การเรียนรู้มีความสมดุลขึ้น

ตัวอย่างการคำนวณ 1.4 ผลของการเลือกฟังก์ชันความเชื่อมั่นต่อผู้ใช้ที่มีพฤติกรรมสุดโต่ง

โจทย์ ผู้ใช้ ก เปิดฟังเพลงหนึ่ง 3 ครั้ง ส่วนผู้ใช้ ข เปิดฟังเพลงเดียวกัน 300 ครั้ง (ซึ่งอาจเป็นเพราะเปิดวนทิ้งไว้ทั้งคืนขณะหลับ) กำหนด $\alpha = 40$ และ $\varepsilon = 1$ จงเปรียบเทียบอิทธิพลของผู้ใช้ทั้งสองที่มีต่อฟังก์ชันสูญเสีย

ขั้นที่ 1 คำนวณแบบเชิงเส้น

$$c(\text{ก}) = 1 + 40 \times 3 = 121$$

$$c(\text{ข}) = 1 + 40 \times 300 = 12{,}001$$

อัตราส่วนอิทธิพล = $12{,}001 \div 121 \approx 99.2$ เท่า

ขั้นที่ 2 คำนวณแบบลอการิทึม

$$c(\text{ก}) = 1 + 40 \times \ln(1 + 3) = 1 + 40 \times 1.3863 = 56.45$$

$$c(\text{ข}) = 1 + 40 \times \ln(1 + 300) = 1 + 40 \times 5.7071 = 229.28$$

อัตราส่วนอิทธิพล = $229.28 \div 56.45 \approx 4.06$ เท่า

ขั้นที่ 3 ตีความ

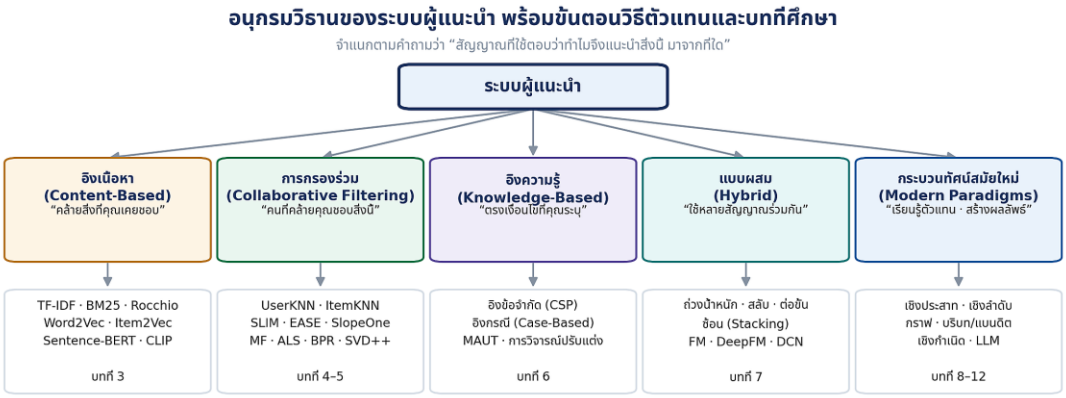
- เมื่อใช้ฟังก์ชันเชิงเส้น ข้อมูลของผู้ใช้ ข ซึ่งเปิดเพลง 300 ครั้ง จะได้รับน้ำหนักมากกว่าข้อมูลของผู้ใช้ ก ซึ่งเปิดเพลง 3 ครั้งประมาณ 99.2 เท่า ทำให้พฤติกรรมที่มีจำนวนครั้งสูงผิดปกติสามารถครอบงำการปรับแบบจำลองได้ง่าย
- เมื่อใช้ฟังก์ชันลอการิทึม ความเชื่อมั่นของผู้ใช้ ข ยังคงสูงกว่าผู้ใช้ ก แต่ความแตกต่างลดลงเหลือประมาณ 4.06 เท่า วิธีนี้จึงยังรักษาข้อมูลว่าผู้ใช้ ข มีปฏิสัมพันธ์มากกว่า ขณะเดียวกันก็ลดอิทธิพลของการเปิดซ้ำจำนวนมากไม่ให้มีน้ำหนักเกินสมควร
- ดังนั้น ฟังก์ชันลอการิทึมเหมาะกับข้อมูลที่มีการกระจายแบบหางยาวหรือมีค่าสุดโต่ง เพราะช่วยให้แบบจำลองทนต่อพฤติกรรมซ้ำผิดปกติได้ดีกว่า อย่างไรก็ตาม จำนวนปฏิสัมพันธ์ที่สูงอาจเกิดจากความสนใจจริง เช่น ผู้ใช้ฟังเพลงโปรดซ้ำหลายครั้ง หรืออาจเกิดจากความผิดปกติ เช่น บอต การเปิดวนอัตโนมัติ และการบันทึกข้อมูลซ้ำ จึงไม่ควรสรุปว่าค่าสูงทั้งหมดเป็นข้อมูลผิดปกติ แต่ควรตรวจสอบสาเหตุก่อนเลือกวิธีลดน้ำหนักหรือตัดข้อมูลออก

คำแนะนำเชิงปฏิบัติ ใช้แบบลอการิทึมเป็นค่าตั้งต้นเสมอเมื่อการกระจายของ $n(u,i)$ มีหางยาว และตรวจสอบทุกครั้งว่าค่า $n(u,i)$ สูงสุดในข้อมูลสมเหตุสมผลหรือไม่ก่อนฝึกแบบจำลอง หากพบค่าเช่น 62,300 ครั้งต่อวัน นั่นมักไม่ใช่มนุษย์

1.6 อนุกรมวิธานของแนวทางการแนะนำ

เมื่อพบระบบผู้แนะนำระบบหนึ่ง คำถามแรกที่ควรถามไม่ใช่ “ใช้แบบจำลองอะไร” แต่คือ “ระบบนี้ใช้สัญญาณอะไรตอบคำถามว่าทำไมจึงแนะนำสิ่งนี้” คำตอบของคำถามนี้จำแนกระบบผู้แนะนำทั้งหมดออกเป็นกลุ่มหลักได้อย่าง

ชัดเจน



ภาพที่ 1.8 อนุกรมวิธานของระบบผู้แนะนำ พร้อมขั้นตอนวิธีตัวแทนและบทที่ศึกษาแต่ละกลุ่ม

ประเด็นสำคัญ วิธีจำอนุกรมวิธานอย่างเป็นระบบ: คิดจากประโยคที่ระบบใช้อธิบายตัวเอง

- **อิงเนื้อหา (Content Based)** "เพราะ**รายการนี้คล้ายกับสิ่งที่คุณเคยชอบ**" สัญญาณมาจากคุณลักษณะของรายการ เช่น ประเภทหนัง ผู้กำกับ คำในเรื่องย่อ
- **การกรองร่วม (Collaborative Filtering)** "เพราะ**คนที่คล้ายคุณชอบสิ่งนี้**" สัญญาณมาจากพฤติกรรมของผู้ใช้คนอื่นล้วน ๆ โดยไม่ต้องรู้อะไรเกี่ยวกับตัวรายการเลย
- **อิงความรู้ (Knowledge Based)** "เพราะ**สิ่งนี้ตรงตามเงื่อนไขที่คุณระบุ**" สัญญาณมาจากกฎที่มนุษย์ผู้เชี่ยวชาญเขียนไว้ เช่น งบประมาณ ขนาด หรือข้อจำกัดทางเทคนิค
- **แบบผสม (Hybrid)** ใช้มากกว่าหนึ่งข้อข้างต้น พร้อมกลไกตัดสินว่าจะเชื่อสัญญาณใดมากกว่ากันเมื่อใด

ตัวอย่างที่ช่วยให้เห็นความต่างชัดที่สุดคือตัวอย่างคลาสสิกเรื่อง "ผ้าอ้อมกับเบียร์" ระบบการกรองร่วมอาจค้นพบว่าผู้ที่ซื้อผ้าอ้อมเด็กมักซื้อเบียร์ด้วย (คำอธิบายที่มักถูกยกคือพ่อบ้านที่ถูกส่งไปซื้อของ) ความสัมพันธ์นี้ไม่มีทางถูกค้นพบโดยระบบอิงเนื้อหา เพราะผ้าอ้อมกับเบียร์ไม่มีคุณลักษณะใดร่วมกันเลย นี่คือพลังของ "ภูมิปัญญาหมู่" (Wisdom of the Crowd) ที่การกรองร่วมนำมาใช้

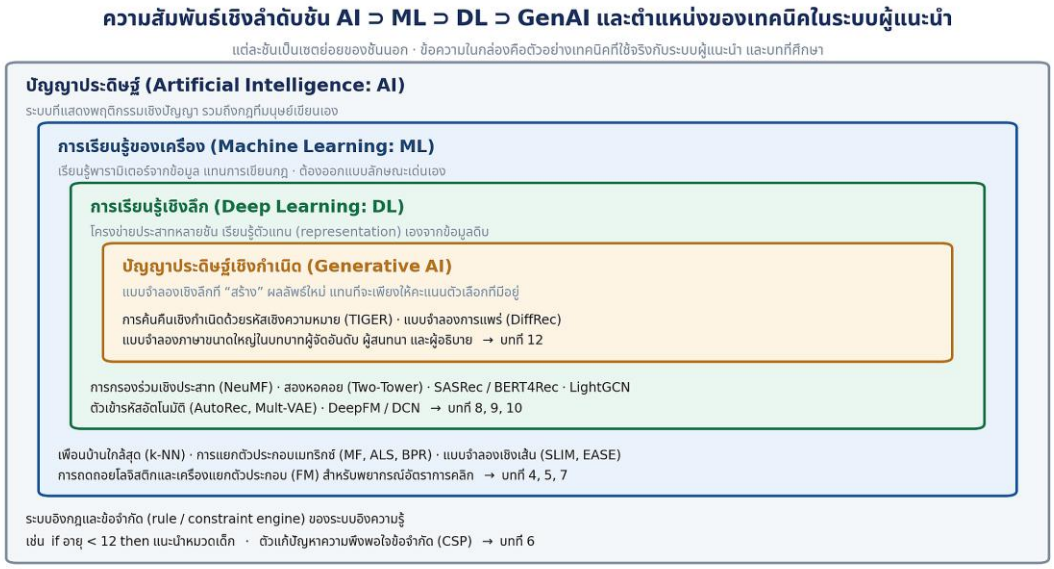
ตารางที่ 1.7 เปรียบเทียบสี่แนวทางหลักตามคุณสมบัติที่ใช้ตัดสินใจเลือกใช้งาน

คุณสมบัติ	อิงเนื้อหา	การกรองร่วม	อิงความรู้	แบบผสม
ข้อมูลที่ต้องมี	คุณลักษณะรายการ + ประวัติผู้ใช้	เมทริกซ์ปฏิสัมพันธ์เท่านั้น	ฐานความรู้และกฎของโดเมน	หลายแหล่งรวมกัน
รับมือรายการใหม่ (Cold Item)	ดี	ไม่ได้	ดี	ดี
รับมือผู้ใช้ใหม่ (Cold User)	ต้องมีประวัติเล็กน้อย	ไม่ได้	ดีมาก (ถามความต้องการได้)	ดี

คุณสมบัติ	อิงเนื้อหา	การกรองร่วม	อิงความรู้	แบบผสม
ค้นพบสิ่งใหม่โดยบังเอิญ (Serendipity)	ต่ำ (เกิดภาวะเชี่ยวชาญเกิน)	สูง	ต่ำถึงปานกลาง	ปานกลางถึงสูง
คุณภาพเมื่อข้อมูลมาก	ปานกลาง	ต่ำ	สูงมาก	ปานกลางถึงสูง
คุณภาพเมื่อข้อมูลมาก	ปานกลาง	สูงมาก	คงที่ ไม่ดีขึ้นตามข้อมูล	สูงที่สุด
อธิบายผลได้ (Explainability)	สูง	ปานกลาง	สูงมาก	ขึ้นกับการออกแบบ

1.7 ความสัมพันธ์ระหว่างปัญญาประดิษฐ์ การเรียนรู้ของเครื่อง การเรียนรู้เชิงลึก และปัญญาประดิษฐ์เชิงกำเนิด

ความเข้าใจคลาดเคลื่อนที่พบบ่อยที่สุดทั้งในหมู่ผู้เริ่มต้นและในเอกสารเชิงพาณิชย์ คือการใช้คำว่า AI, ML, DL และ GenAI สลับกันไปมาราวกับเป็นคำเดียวกัน ทั้งที่ทั้งสี่คำมีความสัมพันธ์เชิงลำดับชั้นที่ชัดเจน หัวข้อนี้จะกำหนดความสัมพันธ์นั้นให้ชัด และวางตำแหน่งของทุกเทคนิคที่จะปรากฏในตำราเล่มนี้ลงไป



ภาพที่ 1.9 ความสัมพันธ์เชิงลำดับชั้น AI ⊃ ML ⊃ DL ⊃ GenAI พร้อมตำแหน่งของเทคนิคที่ใช้จริงกับระบบผู้แนะนำ

จากภาพที่ 1.9 ความสัมพันธ์ทั้งหมดเป็นแบบเซตย่อย–เซตใหญ่ (subset–superset) อย่างเคร่งครัด กล่าวคือ ปัญญาประดิษฐ์เชิงกำเนิดทุกระบบเป็นการเรียนรู้เชิงลึก การเรียนรู้เชิงลึกทุกระบบเป็นการเรียนรู้ของเครื่อง และการเรียนรู้ของเครื่องทุกระบบเป็นปัญญาประดิษฐ์ แต่ข้อความกลับกันไม่จริงในทุกกรณี

ตารางที่ 1.8 เปรียบเทียบสี่ชั้นในเชิงลึก พร้อมบทบาทเฉพาะในระบบผู้แนะนำ

มิติ	ปัญญาประดิษฐ์ (AI)	การเรียนรู้ของเครื่อง (ML)	การเรียนรู้เชิงลึก (DL)	เชิงกำเนิด (GenAI)
นิยามสั้น	ทำให้เครื่องแสดงพฤติกรรมเชิงปัญญา	เรียนรู้จากข้อมูลแทนการเขียนกฎ	ML ที่ใช้โครงข่ายประสาทหลายชั้น	DL ที่สร้างเนื้อหาหรือผลลัพธ์ใหม่
ความต้องการข้อมูล	ต่ำ (ถ้าเป็นแบบอิงกฎ)	ปานกลาง	สูง	สูงมาก (ระดับเว็บ)
ทรัพยากรคำนวณ	ต่ำถึงปานกลาง	ปานกลาง (หน่วยประมวลผลกลางพอ)	สูง (ต้องใช้หน่วยประมวลผลกราฟิก)	สูงมาก (คลัสเตอร์)
การออกแบบลักษณะเด่น	ไม่จำเป็น (ใช้กฎ)	ต้องทำเอง (manual)	เรียนรู้อัตโนมัติ	เรียนรู้อัตโนมัติ
ตัวอย่างเทคนิคทั่วไป	ระบบผู้เชี่ยวชาญ, A*, Minimax	ต้นไม้ตัดสินใจ, SVM, kNN	CNN, RNN, Transformer	GPT, Diffusion, VAE
คุณภาพเมื่อข้อมูลมาก	คุณภาพเมื่อข้อมูลมาก	คุณภาพเมื่อข้อมูลมาก	NeuMF, SASRec, LightGCN	คุณภาพเมื่อข้อมูลมาก
บทที่ศึกษา	**บทที่ 6**	**บทที่ 4, 5, 7**	**บทที่ 8–10**	**บทที่ 12**

ตัวอย่างการคำนวณ 1.5 เทคนิคเดียวกัน คำถามเดียวกัน แต่คนละชั้น

เพื่อให้เห็นความต่างอย่างเป็นรูปธรรม พิจารณาคำถามเดียวกันว่า “ควรแนะนำภาพยนตร์เรื่องใดแก่ผู้ใช้คนนี้” แล้วดูว่าแต่ละชั้นตอบอย่างไร

มิติ	ปัญญาประดิษฐ์ (AI)	การเรียนรู้ของเครื่อง (ML)	การเรียนรู้เชิงลึก (DL)	เชิงกำเนิด (GenAI)

เทคนิคในแต่ละชั้น เขียนเป็นรหัสเทียม (Pseudocode)

ชั้น AI แบบอิงกฎ มนุษย์เขียนความรู้ลงไปตรง ๆ

```
if user.age < 12:            return catalog.filter(rating='G')
if season == 'ฤดูฝน':        return catalog.filter(genre='ดราม่า')
```

⟶ ตรวจสอบได้ อธิบายได้ แต่ไม่เรียนรู้จากข้อมูล และขยายไม่ได้

ชั้น ML เรียนพารามิเตอร์จากข้อมูล แต่ผู้พัฒนากำหนดรูปแบบเอง

```
score = p_u @ q_i + b_u + b_i + mu      # BiasedMF (บทที่ 5)
```

⟶ เรียนรู้ได้ แต่รูปแบบปฏิสัมพันธ์ถูกกำหนดไว้ว่าเป็นผลคูณจุด

ชั้น DL โครงข่ายเรียนรู้รูปแบบปฏิสัมพันธ์เองจากข้อมูล

```
h = MLP(concat(embed_u, embed_i))       # NeuMF (บทที่ 8)
score = sigmoid(w @ h)
```

⟶ ยืดหยุ่นกว่า แต่ต้องการข้อมูลและการปรับจูนมากกว่ามาก

ชั้น GenAI ไม่ให้คะแนนตัวเลือกที่มีอยู่ แต่ 'สร้าง' รหัสของรายการขึ้นมา

```
codes = seq2seq.generate(history_codes)  # TIGER (บทที่ 12)
item  = codebook.decode(codes)
```

⟶ รับมือรายการใหม่ได้ดี แต่ต้องตรวจว่ารหัสที่สร้างมีอยู่จริงในคลัง

ข้อสังเกตสำคัญ ชั้นที่ลึกกว่าไม่ได้ “ดีกว่า” เสมอไป แต่ **ยืดหยุ่นกว่าและต้องการข้อมูลมากกว่า** ระบบอิงกฎในชั้นแรกยังคงจำเป็นในโดเมนที่ผิดพลาดไม่ได้ เช่น การเงินหรือสุขภาพ ซึ่งการอธิบายผลเป็นข้อบังคับทางกฎหมาย ในทางกลับกัน

ข้อควรระวัง ข้อควรระวังเชิงวิชาการเรื่องการเลือกใช้คำ

ควรหลีกเลี่ยงการเขียนว่า “ระบบแนะนำที่ขับเคลื่อนด้วย AI” หรือ “AI powered recommender” ในเอกสารวิชาการ เพราะข้อความนี้ไม่ให้สารสนเทศใดเลย ระบบผู้แนะนำ ทุกระบบ ตั้งแต่ ค.ศ. 1992 เป็นต้นมาล้วนเป็นปัญญาประดิษฐ์ตามนิยาม การเขียนเช่นนั้นจึงเทียบได้กับการเขียนว่า “รถยนต์ที่ขับเคลื่อนด้วยเครื่องยนต์”

แนวปฏิบัติที่ถูกต้องคือระบุให้เจาะจงลงไปว่าเป็น แบบจำลองปัจจัยแฝงเชิงเส้น หรือ แบบจำลองเชิงประสาทแบบลำดับ หรือ แบบจำลองภาษาขนาดใหญ่ในบทบาทผู้จัดอันดับ ความเจาะจงนี้ทำให้ผู้อ่านทราบทันทีว่างานของท่านต้องการข้อมูลชนิดใด มีต้นทุนเท่าใด และควรเปรียบเทียบกับงานใด

1.7.1 แบบจำลองรากฐานในระบบผู้แนะนำ: สามกระบวนทัศน์ที่ต้องแยกให้ชัด

งานปริทัศน์ร่วมสมัยจำแนกการใช้แบบจำลองรากฐาน (Foundation Model) ในระบบผู้แนะนำออกเป็นสามกระบวนทัศน์ ซึ่งต่างกันทั้งข้อมูลนำเข้า ผลลัพธ์ ต้นทุน และความเสี่ยง ไม่ควรเรียกรวมทั้งหมดว่า ‘ระบบผู้แนะนำด้วยแอลแอลเอ็ม’

ตารางเสริม 1.1 สามกระบวนทัศน์ของระบบผู้แนะนำที่ขับเคลื่อนด้วยแบบจำลองรากฐาน

กระบวนทัศน์	บทบาทของแบบจำลองรากฐาน	ตัวอย่างผลลัพธ์	จุดที่ต้องระวัง
อิงคุณลักษณะ (Feature based)	สร้างตัวแทนข้อความ ภาพ หรือหลายสื่อ แล้วส่งต่อให้ตัวจัดอันดับเดิม	เวกเตอร์รายการหรือโปรไฟล์ผู้ใช้	คุณภาพการฝังตัว การรั่วไหล และต้นทุนประมวลผล
เชิงกำเนิด (Generative)	สร้างรหัสรายการ ลำดับรายการ หรือคำอธิบายโดยตรง	รายการ Top K หรือข้อความแนะนำ	รายการหลอน ความถูกต้องเชิงข้อเท็จจริง และข้อจำกัดแคตาล็อก
เชิงตัวแทน (Agentic)	สนทนา ถามคำถามเพิ่ม เรียกเครื่องมือ และวางแผนหลายขั้น	บทสนทนาและแผนการเลือก	ความหน่วง ความเป็นส่วนตัว การควบคุมเครื่องมือ และการตรวจสอบย้อนกลับ