2

ระเบียบวิธีประเมินผลระบบผู้แนะนำ

Evaluation Methodology for Recommender Systems



บทนี้ตอบคำถามว่า “ระบบผู้แนะนำที่ดีวัดอย่างไร” ตั้งแต่ตัวชี้วัดการพยากรณ์คะแนน ตัวชี้วัดเชิงอันดับที่ไวและไม่ไวต่อตำแหน่ง คุณภาพนอกเหนือความถูกต้อง ไปจนถึงการแบ่งข้อมูล การสุ่มรายการเชิงลบ การทดสอบนัยสำคัญ และโปรโตคอลการประเมิน 11 ขั้น

ทุกตัวอย่างการคำนวณทำซ้ำได้ด้วยสมุดบันทึก Google Colab ประจำบท (Lab2_Colab) และมีแบบฝึกหัดสามระดับพร้อมเฉลยละเอียดท้ายบท

เนื้อหา

2.1 แผนที่ตัวชี้วัด • MAE • RMSE 3
2.2 ตัวชี้วัดอันดับที่ไม่ไวต่อตำแหน่ง 14
2.3 ตัวชี้วัดอันดับที่ไวต่อตำแหน่ง 20
2.4 พื้นที่ใต้เส้นโค้ง ROC (AUC) 33
2.5 คุณภาพนอกเหนือความถูกต้อง 39
2.6 ตัวชี้วัดหลักและตัวชี้วัดกำกับ 65
2.7 รูปแบบการทดลองสามระดับ 69
2.8 การแบ่งข้อมูลและข้อมูลรั่วไหล 70
2.9 เต็มบัญชี เทียบ สุ่มรายการเชิงลบ 75
2.10 ความไม่แน่นอนและนัยสำคัญ 80
2.11 การทดลองออนไลน์ 83
2.12 การประเมินแบบทวนข้อเท็จจริง 84
2.13 การทำซ้ำได้และบัตรโปรโตคอล 86
2.14 โปรโตคอลการประเมิน 11 ขั้น 87
2.15 เหตุใดการประเมินจึงต่างออกไป 89

บทนี้อธิบายวิธีตอบคำถามว่า “ระบบผู้แนะนำดีขึ้นจริงหรือไม่” โดยเริ่มจากตัวชี้วัดที่ใช้กับข้อมูลออฟไลน์ แล้วเชื่อมไปสู่การศึกษาผู้ใช้และการทดลองออนไลน์ ผู้อ่านจะได้เห็นทั้งสูตร วิธีคำนวณทีละขั้น ตัวอย่างที่ตัวชี้วัดให้คำตอบต่างกัน และข้อผิดพลาดเชิงระเบียบวิธีที่ทำให้ผลดูดีเกินจริง ตัวอย่าง MovieMini-12 และชุดทดลอง RSLab-Eval ถูกใช้ต่อเนื่องตลอดบท เพื่อให้เปรียบเทียบแนวคิดต่าง ๆ บนบริบทเดียวกันได้

วัตถุประสงค์การเรียนรู้ประจำบท

เมื่อศึกษาบทนี้จบแล้ว ผู้เรียนจะสามารถ

1. **อธิบาย** ได้ว่าเหตุใดการประเมินระบบผู้แนะนำจึงต่างจากการประเมินงานการเรียนรู้ของเครื่องทั่วไป ครบทั้งหกเหตุผล พร้อมยกตัวอย่างที่จับต้องได้ของแต่ละข้อ
2. **แยกแยะ** ตัวชี้วัดหลัก (Primary Metric) ออกจากตัวชี้วัดกำกับ (Guardrail Metrics) และกำหนดเกณฑ์ตัวเลขของตัวชี้วัดกำกับได้อย่างสมเหตุสมผล
3. **คำนวณ** MAE, RMSE, Precision@K, Recall@K, F1@K, HR@K, MRR, MAP@K, nDCG@K และ AUC ได้ด้วยมือทีละขั้นบนข้อมูลชุดเดียวกัน และอธิบายได้ว่าตัวชี้วัดใดไวต่อตำแหน่งและตัวใดไม่ไว
4. **วิเคราะห์** ผลบวกลวงและผลลบลวง “เทียม” (Pseudo FP/FN) ที่เกิดจากอคติการเปิดเผยรายการ และอธิบายได้ว่าเหตุใด Precision กับ Recall ที่วัดออฟไลน์จึงเป็นเพียงขอบล่างของความจริง
5. **ออกแบบ** การแบ่งข้อมูลตามเวลา (Temporal Split) ที่ปลอดจากการรั่วไหล และตรวจจับรูปแบบการรั่วไหลที่พบบ่อยได้
6. **ประเมิน** ผลกระทบของการเลือกเซตผู้สมัคร ระหว่างการจัดอันดับเต็มบัญชีรายการ (Full Catalog) กับการสุ่มรายการเชิงลบ (Sampled Negatives) และอธิบายกลไกที่ทำให้การสุ่มสลับผู้ชนะได้
7. **วัด** คุณภาพนอกเหนือความถูกต้อง ได้แก่ ความครอบคลุมคลัง ความหลากหลาย สัดส่วนรายการส่วนหาง ความใหม่ การปรับเทียบ และความเป็นธรรม พร้อมอธิบายการแลกเปลี่ยนระหว่างกัน
8. **รายงาน** ความไม่แน่นอนของผลการทดลองด้วยหลายเมล็ดสุ่ม ช่วงความเชื่อมั่น และการทดสอบนัยสำคัญแบบจับคู่ที่ระดับผู้ใช้ พร้อมแก้ปัญหาการเปรียบเทียบหลายคู่
9. **ปฏิบัติตาม** โปรโตคอลการประเมิน 11 ขั้น และจัดทำบัตรโปรโตคอล (Protocol Card) ที่ทำให้ผู้อื่นทำซ้ำผลได้
10. **เขียนโปรแกรม** ภาษาไพทอนเพื่อประเมินระบบผู้แนะนำอย่างถูกวิธี โดยใช้แพ็กเกจ rslab ที่พัฒนาในบทนี้

ประเด็นสำคัญ ชุดข้อมูลและโปรแกรมประจำบท

MovieMini-12 (ผู้ใช้ u1–u8 × ภาพยนตร์ i1–i12 คะแนน 32 ค่า ชุดเดียวกับตารางที่ 5.3 ในบทที่ 5) ใช้ในตัวอย่างที่ต้องคำนวณด้วยมือทุกตัวอย่างของหัวข้อ 2.1–2.5 ดูตาราง MM-1 ถึง MM-3 และโค้ดประกอบ 2.1–2.14

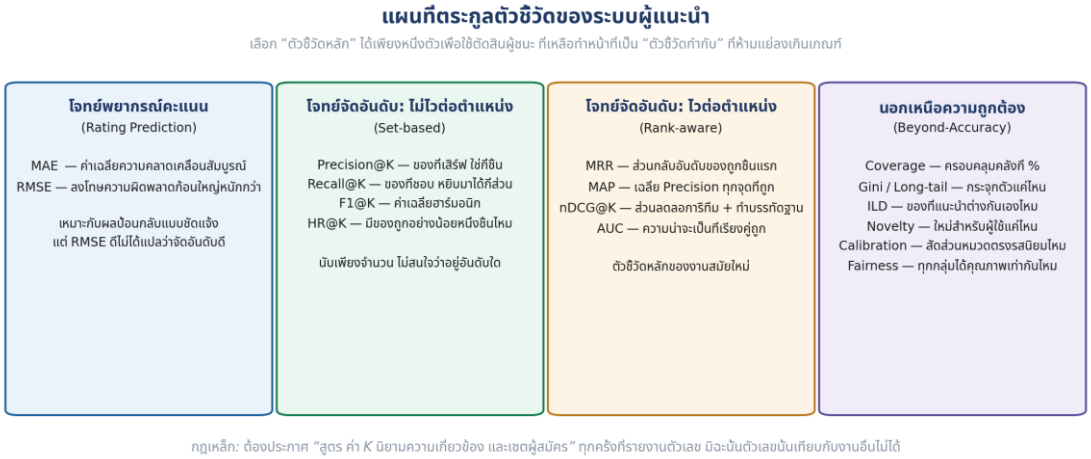
RSLab-Eval ชุดข้อมูลสังเคราะห์ใหม่ของบทนี้ (ผู้ใช้ 800 คน × รายการ 500 รายการ ปฏิสัมพันธ์ 21,696 ครั้ง ความหนาแน่น 0.0542) ออกแบบให้มีสมบัติสามข้อที่จำเป็น ได้แก่ ความนิยมกระจายแบบหางยาว ความนิยมเลื่อนตามเวลา และมีหมวดหมู่ชัดเจน จึงใช้พิสูจน์ความสัมพันธ์เชิงสาเหตุได้

แพ็กเกจ rslab เครื่องมือประเมินผลที่พัฒนาขึ้นในบทนี้และใช้ซ้ำในทุกบทถัดไป ประกอบด้วยหกโมดูล ครอบคลุมตัวชี้วัดทุกตระกูล การแบ่งข้อมูล การทดสอบนัยสำคัญ และบัตรโปรโตคอล

2.1 แผนที่ตัวชี้วัด และการพยากรณ์คะแนน

การประเมินที่ดีเริ่มจากการจับคู่ “คำถาม” กับ “ตัวชี้วัด” ให้ถูกต้อง หากต้องการวัดความแม่นของคะแนนให้ใช้ MAE หรือ RMSE; หากสนใจว่ารายการที่เกี่ยวข้องปรากฏใน Top-K หรือไม่ให้ใช้ Precision, Recall, F1 หรือ HR; หากตำแหน่งมีความสำคัญให้ใช้ RR, MRR, AP, MAP หรือ nDCG; และหากสนใจผลต่อคลังรายการและ

ประสบการณ์ผู้ใช้ ต้องรายงาน Coverage, Diversity, Novelty, Calibration และ Fairness เพิ่มเติม ตัวเลขที่คำนวณถูกต้องแต่เลือกผิดตระกูลย่อมตอบคนละคำถามกับที่งานวิจัยตั้งไว้



ภาพที่ 2.1 แผนที่ตระกูลตัวชี้วัดของระบบผู้แนะนำสี่ตระกูล พร้อมกฎเหล็กของการรายงานผล

ตารางที่ 2.1 ตระกูลตัวชี้วัดสี่ตระกูล คำถามที่แต่ละตระกูลตอบ และเงื่อนไขการใช้งาน

ตระกูล	คำถามที่ตอบได้	ตัวชี้วัดในตระกูล	ใช้เมื่อใด
พยากรณ์คะแนน (Rating Prediction)	ทำนายตัวเลขคะแนนได้ใกล้ความจริงเพียงใด	MAE, RMSE	มีผลป้อนกลับแบบชัดแจ้งและผลลัพธ์ที่ต้องการเป็นตัวเลข
จัดอันดับแบบไม่ไวต่อตำแหน่ง (Set-based)	ในรายการที่เสิร์ฟไป มีรายการที่แนะนำถูกต้องกี่ชิ้น	Precision@K, Recall@K, F1@K, HR@K	พื้นที่แสดงผลทุกช่องมีค่าเท่ากัน เช่น ตะกร้าสินค้าแนะนำ
จัดอันดับแบบไวต่อตำแหน่ง (Rank-aware)	รายการที่แนะนำถูกต้องอยู่ใกล้ตำแหน่งบนสุดเพียงใด	MRR, MAP@K, nDCG@K, AUC	ตำแหน่งมีผลต่อโอกาสถูกเห็น ซึ่งเป็นกรณีส่วนใหญ่ในระบบจริง
นอกเหนือความถูกต้อง (Beyond-Accuracy)	ระบบดีต่อระบบนิเวศและผู้ใช้ในระยะยาวหรือไม่	Coverage, Gini, ILD, Novelty, Calibration, Fairness	ทุกครั้ง ในฐานะตัวชี้วัดกำกับควบคู่ตัวชี้วัดหลัก

ข้อตกลงสัญลักษณ์ที่ใช้ตลอดบท: $\mathcal{U}$ คือเซตผู้ใช้ที่นำมาประเมิน, $\mathcal{I}$ คือบัญชีรายการทั้งหมด, $\mathcal{T} \subseteq \mathcal{U} \times \mathcal{I}$ คือเซตคู่ผู้ใช้–รายการในชุดทดสอบ, $\mathcal{R}_u$ คือเซตรายการที่เกี่ยวข้องกับผู้ใช้ u, $\mathcal{L}_u^K$ คือรายการแนะนำแบบเรียงลำดับ K อันดับแรก และ $\mathrm{rel}_u(i)$ คือระดับความเกี่ยวข้องของรายการที่อันดับ i โดย i ใช้แทนรายการในคู่ (u,i) และใช้เป็นดัชนีตำแหน่งเมื่อบริบทเป็นลิสต์จัดอันดับ

คำศัพท์พื้นฐานที่ต้องแยกให้ออก

ข้อมูลตอบกลับแบบชัดแจ้ง (Explicit Feedback) คือข้อมูลที่ผู้ใช้แสดงความเห็นโดยตรง เช่น คะแนนดาวหรือการกดชอบ ส่วนข้อมูลตอบกลับโดยนัย (Implicit Feedback) คือร่องรอยพฤติกรรม เช่น การคลิก การรับชม และการซื้อ ข้อมูลสองชนิดนี้ตีความไม่เหมือนกัน คะแนนดาวต่ำเป็นหลักฐานเชิงลบที่ค่อนข้างชัด แต่การไม่คลิกอาจเกิดจากผู้ใช้ไม่เคยเห็นรายการนั้น จึงไม่ควรถือว่าเป็นคำตอบเชิงลบโดยอัตโนมัติ

Ground Truth ในการประเมินออฟไลน์หมายถึงชุดคำตอบที่ผู้วิจัยกำหนดให้เป็นรายการที่เกี่ยวข้อง (Relevant Items) จากข้อมูลทดสอบ ไม่ได้หมายถึงความชอบที่แท้จริงทั้งหมดของผู้ใช้ ก่อนคำนวณจึงต้องประกาศกฎความเกี่ยวข้อง เช่น คะแนนอย่างน้อย 4 ดาว การรับชมเกินร้อยละ 70 หรือการซื้อภายในช่วงเวลาที่กำหนด กฎที่ต่างกันทำให้เซต $\mathcal{R}_u$ ต่างกันและทำให้คะแนนทุกตัวที่อาศัย $\mathcal{R}_u$ เปลี่ยนตาม

Candidate Set คือรายการทั้งหมดที่แบบจำลองมีสิทธิ์นำมาจัดอันดับในการทดลองหนึ่งครั้ง ส่วน Top-K คือ K รายการแรกหลังจัดอันดับแล้ว ตัวอย่างเช่น ระบบอาจจัดอันดับผู้สมัคร 5,000 รายการ แต่แสดงเพียง 10 รายการแรก ดังนั้น Candidate Set กำหนดความยากของสนามสอบ ขณะที่ K กำหนดขนาดของผลลัพธ์ที่นำมาวัด ทั้งสองค่าต้องคงที่เมื่อเปรียบเทียบแบบจำลอง

วิธีอ่านสูตรและตรวจการคำนวณ

สัญลักษณ์ |S| หมายถึงจำนวนสมาชิกของเซต S เครื่องหมาย ∩ หมายถึงสมาชิกที่อยู่ร่วมกันในสองเซต เครื่องหมาย Σ หมายถึงการบวกค่าหลายพจน์ และ @K หมายถึงคำนวณเฉพาะ K อันดับแรก ดัชนี u ระบุว่าค่านั้นเป็นของผู้ใช้คนใด เมื่อสูตรมี metric(u) ให้คำนวณรายผู้ใช้ก่อน แล้วจึงเฉลี่ยผู้ใช้ตามที่โปรโตคอลกำหนด

วิธีตรวจคำตอบที่ใช้ได้กับทุกตัวชี้วัดมีสี่ขั้น เริ่มจากระบุหน่วยวิเคราะห์และเซตที่เป็นตัวส่วน จากนั้นแทนค่าทีละพจน์ ตรวจช่วงค่าที่เป็นไปได้ และจึงตีความเป็นประโยค ตัวอย่างเช่น Precision@10 = 0.30 แปลว่าในรายการแนะนำ 10 ชิ้น มีรายการที่ตรงกับ Ground Truth 3 ชิ้น ไม่ได้แปลว่าแบบจำลองถูกต้องร้อยละ 30 สำหรับรายการทั้งคลัง

การรวมผลมีอย่างน้อยสองแบบ Macro Average ให้ผู้ใช้แต่ละคนมีน้ำหนักเท่ากันโดยเฉลี่ย metric(u) ส่วน Micro Average รวมจำนวน TP FP และ FN ของผู้ใช้ทั้งหมดก่อนคำนวณ ผู้ใช้ที่มีกิจกรรมมากจึงมีน้ำหนักสูงกว่า งานระบบผู้แนะนำมักใช้ Macro Average เพื่อไม่ให้ผู้ใช้ที่ใช้งานหนักครอบงำผล แต่ต้องระบุวิธีที่ใช้ รวมถึงวิธีจัดการผู้ใช้ที่ไม่มีรายการเกี่ยวข้องในชุดทดสอบ

เมื่อผลลัพธ์ของแบบจำลองเป็นคะแนนพยากรณ์ เช่น คะแนนภาพยนตร์ 1–5 ดาว เราวัดความต่างระหว่างคะแนนจริงกับคะแนนที่ทำนาย เฉพาะคู่ผู้ใช้–รายการในชุดทดสอบ $\mathcal{T}$ ตัวชี้วัดหลักสองค่าคือ MAE และ RMSE ซึ่งใช้ข้อมูลชุดเดียวกันแต่ให้น้ำหนักต่อความผิดพลาดต่างกัน

MAE สรุปขนาดความผิดพลาดโดยเฉลี่ยและตีความเป็นหน่วยเดียวกับคะแนน ส่วน RMSE ให้น้ำหนักกับความผิดพลาดขนาดใหญ่มากกว่า จึงควรรายงานทั้งสองค่าควบคู่กัน โดยเลือกค่าหลักให้สอดคล้องกับต้นทุนของความผิดพลาดในงานจริง

ชุดข้อมูลอ้างอิงและแบบจำลองที่ใช้ในหัวข้อ 2.1–2.5

ตัวอย่างการคำนวณทุกตัวอย่างในหัวข้อ 2.1 ถึง 2.5 ใช้ข้อมูลชุดเดียวกัน คือชุดข้อมูล **MovieMini-12** ซึ่งประกอบด้วยตาราง MM-1 บัญชีภาพยนตร์ 12 เรื่องพร้อมแนว และตาราง MM-2 เมทริกซ์คะแนนของผู้ใช้ 8 คน การยึดข้อมูลชุดเดียวทำให้ผู้อ่านย้อนตรวจที่มาของตัวเลขทุกตัวได้ถึงระดับแถวและคอลัมน์ และทำให้เปรียบเทียบตัวชี้วัดต่างตระกูลบนสถานการณ์เดียวกันได้โดยตรง

ตาราง MM-1 บัญชีภาพยนตร์ MovieMini-12

รหัส	ชื่อเรื่อง (ปี)	แนว
i1	Toy Story 5 (2026)	Animation, Family
i2	Inside Out 2 (2024)	Animation, Family
i3	The Wild Robot (2024)	Animation, Sci-Fi
i4	It Ends with Us (2024)	Drama, Romance
i5	Wicked (2024)	Fantasy, Musical
i6	Bridget Jones: Mad About the Boy	Drama, Romance
i7	Ballerina (2025)	Action, Thriller
i8	Furiosa: A Mad Max Saga	Action, Sci-Fi
i9	Conclave (2024)	Drama, Thriller
i10	Dune: Part Two (2024)	Action, Sci-Fi
i11	Mickey 17 (2025)	Sci-Fi, Thriller
i12	Project Hail Mary (2026)	Drama, Sci-Fi

ตาราง MM-2 เมทริกซ์คะแนนของ MovieMini-12 (· = ยังไม่มีคะแนน)

ผู้ใช้	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	จำนวน	เฉลี่ย
u1	5	5	4	1	·	1	·	·	·	·	·	·	5	3.20
u2	2	·	·	5	4	5	·	·	·	·	·	·	4	4.00
u3	·	·	·	·	·	·	1	·	·	5	5	4	4	3.75

ผู้ใช้	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	จำนวน	เฉลี่ย
u4	4	·	·	·	1	·	5	5	·	·	·	·	4	3.75
u5	·	·	4	·	·	3	·	·	5	2	·	·	4	3.50
u6	·	5	·	·	4	·	·	·	·	·	3	·	3	4.00
u7	·	·	3	·	·	·	·	2	·	·	4	5	4	3.50
u8	·	2	·	4	·	5	·	·	·	·	3	·	4	3.50
ผู้ให้คะแนน	**3**	**3**	**3**	**3**	**3**	**4**	**2**	**2**	**1**	**2**	**4**	**2**	**32**	**3.625**

จากตาราง MM-2 มีคะแนนจริงทั้งหมด 32 ค่า จากช่องทั้งหมด $8 \times 12 = 96$ ช่อง ความหนาแน่นจึงเท่ากับ $32/96 = 0.3333$ ค่าเฉลี่ยรวมของทุกคะแนนเท่ากับ $116/32 = 3.625$ ดาว ช่องที่มีจุด (·) หมายถึง “ยังไม่มีข้อมูล” ไม่ได้หมายถึง “ไม่ชอบ” ข้อตกลงนี้สำคัญมากเมื่อสร้าง Ground Truth ในหัวข้อ 2.2 เป็นต้นไป ส่วนแถวสุดท้าย “ผู้ให้คะแนน” คือจำนวนผู้ใช้ที่ให้คะแนนแต่ละเรื่อง ซึ่งหัวข้อ 2.5 จะใช้เป็นค่าความนิยมของรายการ

เพื่อให้มีสิ่งที่นำมาเปรียบเทียบได้ ตาราเล่มนี้สร้างแบบจำลองสองตัวที่คำนวณด้วยมือได้ทั้งหมด และใช้ซ้ำตลอดหัวข้อ 2.1–2.5 ดังนี้

- **แบบจำลอง A แบบอิงเนื้อหาตามแนวภาพยนตร์ (Genre-kNN)** ทำนายคะแนนที่ผู้ใช้ u จะให้รายการ i จากค่าเฉลี่ยถ่วงน้ำหนักของคะแนนที่ u เคยให้ภาพยนตร์เรื่องอื่น โดยน้ำหนักคือความคล้ายของแนวแบบแจ็กการ์ด (Jaccard) ตามสมการ (M1) และ (M2) หากไม่มีเรื่องใดมีแนวร่วมกับ i เลย ให้ใช้ค่าเฉลี่ยคะแนนเรื่องอื่นของผู้ใช้คนนั้นแทน

$$J(i,j) = \frac{|G_i \cap G_j|}{|G_i \cup G_j|} \quad \text{(M1)}$$

$$\hat{r}^{A}_{ui} = \frac{\sum_{j \in I_u, j \neq i} J(i,j)\, r_{uj}}{\sum_{j \in I_u, j \neq i} J(i,j)} \quad \text{(M2)}$$

- **แบบจำลอง B แบบความนิยม (Popularity)** ไม่ใช้ข้อมูลส่วนตัวของผู้ใช้เลย ทำนายคะแนนด้วยค่าเฉลี่ยของคะแนนที่ผู้ใช้คนอื่นให้รายการ i ตามสมการ (M3) และจัดอันดับด้วยจำนวนผู้ใช้คนอื่นที่ให้คะแนนรายการนั้น $n_i^{(-u)}$ ตามสมการ (M4) หากเสมอกันให้เรื่องที่มีค่าเฉลี่ยสูงกว่าอยู่ก่อน

$$\hat{r}^{B}_{ui} = \frac{1}{n_i^{(-u)}} \sum_{v \in U_i,\, v \neq u} r_{vi} \quad \text{(M3)}$$

$$n_i^{(-u)} = |U_i| - \mathbf{1}(u \in U_i) \quad \text{(M4)}$$

โดยที่ G_i คือเซตแนวของภาพยนตร์ i จากตาราง MM-1, I_u คือเซตภาพยนตร์ที่ผู้ใช้ u ให้คะแนนแล้ว, U_i คือเซตผู้ใช้ที่ให้คะแนนภาพยนตร์ i และ r_{uj} คือคะแนนในตาราง MM-2 ทั้งสองแบบจำลองใช้โปรโตคอล **ปิดบังทีละรายการ (Leave-One-Out)** กล่าวคือ เมื่อคำนวณค่าใด ๆ ของคู่ (u, i) จะไม่ใช้คะแนน r_{ui} ของคู่นั้นเองเลย เงื่อนไข $j \neq i$ และ $v \neq u$ ใต้เครื่องหมายผลรวม และพจน์ $\mathbf{1}(u \in U_i)$ ซึ่งมีค่า 1 เมื่อ u เคยให้คะแนน i คือการปิดบังดังกล่าว ซึ่งป้องกันไม่ให้แบบจำลอง “เห็นเฉลย” ก่อนทำนาย กรณีคะแนนเสมอกัน แบบจำลอง A ให้เรื่องที่ผลรวมน้ำหนัก $\sum J$ มากกว่า (มีหลักฐานมากกว่า) อยู่ก่อน และหากยังเสมอให้เรียงตามรหัสจากน้อยไปมาก

โค้ดประกอบ 2.1 สร้างชุดข้อมูล MovieMini-12 และแบบจำลอง A กับ B

```
import math, itertools
from collections import Counter
GENRE = {'i1':{'Animation','Family'}, 'i2':{'Animation','Family'},
         'i3':{'Animation','Sci-Fi'}, 'i4':{'Drama','Romance'},
         'i5':{'Fantasy','Musical'},  'i6':{'Drama','Romance'},
         'i7':{'Action','Thriller'},  'i8':{'Action','Sci-Fi'},
         'i9':{'Drama','Thriller'},   'i10':{'Action','Sci-Fi'},
         'i11':{'Sci-Fi','Thriller'}, 'i12':{'Drama','Sci-Fi'}}
ITEMS = [f'i{k}' for k in range(1, 13)]
# ตาราง MM-2
R = {'u1': {'i1':5, 'i2':5, 'i3':4, 'i4':1, 'i6':1},
     'u2': {'i1':2, 'i4':5, 'i5':4, 'i6':5},
     'u3': {'i7':1, 'i10':5, 'i11':5, 'i12':4},
     'u4': {'i1':4, 'i5':1, 'i7':5, 'i8':5},
     'u5': {'i3':4, 'i6':3, 'i9':5, 'i10':2},
     'u6': {'i2':5, 'i5':4, 'i11':3},
     'u7': {'i3':3, 'i8':2, 'i11':4, 'i12':5},
     'u8': {'i2':2, 'i4':4, 'i6':5, 'i11':3}}
USERS = list(R)
ALL = [(u, i, r) for u in USERS for i, r in R[u].items()]   # 32

def jac(i, j):                                          # สมการ (M1)
    return len(GENRE[i] & GENRE[j]) / len(GENRE[i] | GENRE[j])

def pred_A(u, i):                                       # สมการ (M2)
    nb = [(jac(i, j), r) for j, r in R[u].items()
          # ปิดบัง r_ui
          if j != i and jac(i, j) > 0]
    if not nb:                                          # ไม่มีแนวร่วม
        own = [r for j, r in R[u].items() if j != i]
        return sum(own) / len(own), 0.0
    w = sum(s for s, _ in nb)
    return sum(s * r for s, r in nb) / w, w

def pred_B(u, i):                                       # สมการ (M3)
    o = [R[v][i] for v in USERS if v != u and i in R[v]]
    if o: return sum(o) / len(o)
    rest = [r for v, j, r in ALL if (v, j) != (u, i)]
    return sum(rest) / len(rest)

print({i: round(pred_A('u1', i)[0], 4) for i in R['u1']})
print({i: round(pred_B('u1', i), 4) for i in R['u1']})
```

ผลลัพธ์ที่ได้

```
{'i1': 4.75, 'i2': 4.75, 'i3': 5.0, 'i4': 1.0, 'i6': 1.0}
{'i1': 3.0, 'i2': 3.5, 'i3': 3.5, 'i4': 4.5, 'i6': 4.3333}
```

2.1.1 ค่าเฉลี่ยความคลาดเคลื่อนสัมบูรณ์ (Mean Absolute Error, MAE)

MAE ตอบคำถามง่าย ๆ ว่า “โดยเฉลี่ยแบบจำลองทายพลาดกี่หน่วย” โดยนำค่าสัมบูรณ์ของความผิดพลาดทุกคู่ในชุดทดสอบมาหาค่าเฉลี่ย จึงไม่หักล้างกันระหว่างกรณีที่ทายสูงเกินไปกับต่ำเกินไป

$$MAE = \frac{1}{|\mathcal{T}|} \sum_{(u,i)\in\mathcal{T}} |r_{ui} - \hat{r}_{ui}| \qquad (2.1)$$

ในสมการ (2.1) $\mathcal{T}$ คือเซตคู่ (u,i) ในชุดทดสอบที่มีคะแนนจริงกำกับ, rui คือคะแนนจริงที่ผู้ใช้ u ให้รายการ i และ $\hat{r}_{ui}$ คือคะแนนที่แบบจำลองทำนาย ค่า MAE มีหน่วยเดียวกับคะแนน เช่น MAE = 0.30 หมายถึงแบบจำลองทายคลาดเคลื่อนเฉลี่ย 0.30 ดาว ดังที่ตัวอย่างการคำนวณ 2.1 จะคำนวณให้เห็น

2.1.2 รากที่สองของค่าเฉลี่ยความคลาดเคลื่อนกำลังสอง (Root Mean Squared Error, RMSE)

$$RMSE = \sqrt{\frac{1}{|\mathcal{T}|}\sum_{(u,i)\in\mathcal{T}}(r_{ui} - \hat{r}_{ui})^2} \qquad (2.2)$$

RMSE ใช้ความผิดพลาดชุดเดียวกับ MAE แต่ยกกำลังสองก่อนเฉลี่ยแล้วจึงถอดรากที่สอง ขั้นตอนนี้ขยายอิทธิพลของความผิดพลาดขนาดใหญ่ ตัวอย่างเช่น ความผิดพลาด 2 ดาวหนึ่งครั้งมีค่ากำลังสองเท่ากับความผิดพลาด 1 ดาวสี่ครั้งรวมกัน ดังนั้น RMSE จึงเหมาะเมื่อการทายผิดรุนแรงมีต้นทุนสูงเป็นพิเศษ

ตัวอย่างการคำนวณ 2.1 การคำนวณ MAE และ RMSE ทีละขั้นตอน บนคะแนนจริงของผู้ใช้ u1

ข้อมูล คะแนนจริงของผู้ใช้ u1 ทั้งห้าเรื่อง เทียบกับคะแนนที่แบบจำลอง A และ B ทำนายภายใต้โปรโตคอลปิดบังทีละรายการ

ที่มาของข้อมูล

- (ก) **คะแนนจริง** r_{ui} มาจากตาราง MM-2 แถว u1 ซึ่งมีค่าห้าช่อง ได้แก่ i1 = 5, i2 = 5, i3 = 4, i4 = 1 และ i6 = 1 ส่วนช่องอื่นของแถวนี้ว่าง จึงไม่อยู่ในชุดทดสอบ ทำให้ $|\mathcal{T}| = 5$
- (ข) **แนวของภาพยนตร์** ที่ใช้หาค่า $J(i,j)$ ในสมการ (M1) มาจากคอลัมน์ “แนว” ของตาราง MM-1 เช่น i1 และ i2 เป็น Animation, Family เหมือนกันทั้งคู่ จึงได้ $J = 2/2 = 1$ ส่วน i1 กับ i3 มีแนวร่วมเพียง Animation จากแนวรวมสามแนว จึงได้ $J = 1/3 = 0.3333$
- (ค) **ค่าทำนายของแบบจำลอง A** ใช้คะแนนอีกสี่เรื่องที่เหลือในแถว u1 ตามสมการ (M2) ส่วน **ค่าทำนายของแบบจำลอง B** ใช้คะแนนในคอลัมน์ของเรื่องนั้นจากผู้ใช้คนอื่นตามสมการ (M3) รายละเอียดอยู่ในตารางย่อยสองตารางถัดไป

รายการ (แนว)	เพื่อนบ้านที่มีแนวร่วม (จาก MM-1, MM-2)	แทนค่าในสมการ (M2)	$\hat{r}$ แบบจำลอง A
i1 (Animation, Family)	i2: J=1.0000, r=5, i3: J=0.3333, r=4	(1.0000×5 + 0.3333×4) / (1.0000 + 0.3333)	4.7500
i2 (Animation, Family)	i1: J=1.0000, r=5, i3: J=0.3333, r=4	(1.0000×5 + 0.3333×4) / (1.0000 + 0.3333)	4.7500
i3 (Animation, Sci-Fi)	i1: J=0.3333, r=5, i2: J=0.3333, r=5	(0.3333×5 + 0.3333×5) / (0.3333 + 0.3333)	5.0000
i4 (Drama, Romance)	i6: J=1.0000, r=1	(1.0000×1) / (1.0000)	1.0000
i6 (Drama, Romance)	i4: J=1.0000, r=1	(1.0000×1) / (1.0000)	1.0000

รายการ	คะแนนจากผู้ใช้คนอื่นในคอลัมน์ (MM-2)	แทนค่าในสมการ (M3)	$\hat{r}$ แบบจำลอง B
i1	u2=2, u4=4	6 / 2	3.0000
i2	u6=5, u8=2	7 / 2	3.5000
i3	u5=4, u7=3	7 / 2	3.5000
i4	u2=5, u8=4	9 / 2	4.5000
i6	u2=5, u5=3, u8=5	13 / 3	4.3333

สังเกตว่าแบบจำลอง A ทำนาย i4 และ i6 ได้ 1.0000 พอดี เพราะ u1 ให้ 1 ดาวแก่เรื่องแนว Drama, Romance อีกเรื่องหนึ่ง ในขณะที่แบบจำลอง B ทำนายสองเรื่องนี้สูงถึง 4.5000 และ 4.3333 เพราะผู้ใช้คนอื่น (u2, u5, u8) ชอบสองเรื่องนี้ แบบจำลอง B จึงไม่รู้เลยว่า u1 ไม่ชอบแนวนี้

ตารางคำนวณของตัวอย่าง 2.1 ความคลาดเคลื่อน e = r̂ − r ของผู้ใช้ u1

รายการ	r	r̂ (A)	e (A)	|e| (A)	e² (A)	r̂ (B)	e (B)	|e| (B)	e² (B)
i1	5	4.7500	−0.2500	0.2500	0.0625	3.0000	−2.0000	2.0000	4.0000
i2	5	4.7500	−0.2500	0.2500	0.0625	3.5000	−1.5000	1.5000	2.2500
i3	4	5.0000	+1.0000	1.0000	1.0000	3.5000	−0.5000	0.5000	0.2500
i4	1	1.0000	0.0000	0.0000	0.0000	4.5000	+3.5000	3.5000	12.2500
i6	1	1.0000	0.0000	0.0000	0.0000	4.3333	+3.3333	3.3333	11.1111
ผลรวม				**1.5000**	**1.1250**			**10.8333**	**29.8611**

ขั้นที่ 1 นำคอลัมน์ |e| ไปแทนค่าในสมการ (2.1)

$$\text{MAE}_A = \frac{0.25 + 0.25 + 1.00 + 0 + 0}{5} = \frac{1.5000}{5} = 0.3000$$

$$\text{MAE}_B = \frac{2.00 + 1.50 + 0.50 + 3.50 + 3.3333}{5} = \frac{10.8333}{5} = 2.1667$$

ขั้นที่ 2 นำคอลัมน์ e² ไปแทนค่าในสมการ (2.2)

$$\sum e_A^2 = 0.0625 + 0.0625 + 1.0000 + 0 + 0 = 1.1250$$

$$\text{RMSE}_A = \sqrt{\frac{1.1250}{5}} = \sqrt{0.2250} = 0.4743$$

$$\sum e_B^2 = 4.0000 + 2.2500 + 0.2500 + 12.2500 + 11.1111 = 29.8611$$

$$\text{RMSE}_B = \sqrt{\frac{29.8611}{5}} = \sqrt{5.9722} = 2.4438$$

ขั้นที่ 3 ตีความ

แบบจำลอง A ทำนายคลาดเคลื่อนเฉลี่ย 0.30 ดาว และ RMSE สูงกว่า MAE อยู่ 0.1743 ซึ่งเกิดจากความผิดพลาดก้อนเดียวคือ i3 ที่ทายเกินไป 1 ดาว ส่วนแบบจำลอง B ทำนายคลาดเคลื่อนเฉลี่ย 2.17 ดาว และช่องว่าง RMSE − MAE เท่ากับ 0.2771 ซึ่งมาจาก i4 และ i6 ที่ทายผิดถึง 3.50 และ 3.33 ดาว ทั้งสองเรื่องคือเรื่องที่ u1 ไม่ชอบ แต่ผู้ใช้คนอื่นชอบ

ตีความการเปรียบเทียบ MAE ของผู้ใช้ u1

0.3000	VS	2.1667
MAE แบบจำลอง A		MAE แบบจำลอง B

- แบบจำลอง A มีค่า MAE เท่ากับ 0.3000 ต่ำกว่าแบบจำลอง B ซึ่งมีค่าเท่ากับ 2.1667 อยู่ 1.8667 ดาว หรือคลาดเคลื่อนน้อยกว่าประมาณ 7.2 เท่า แสดงว่าการใช้ประวัติของผู้ใช้เองร่วมกับความคล้ายของแนวทำนายรสนิยมของ u1 ได้ใกล้ความจริงกว่าการใช้ค่าเฉลี่ยของคนทั้งระบบอย่างชัดเจน
- เมื่อพิจารณา RMSE ผลยังเป็นไปในทิศทางเดียวกัน คือ A = 0.4743 และ B = 2.4438 แต่สัดส่วนช่องว่าง RMSE/MAE ของ B (1.13) ต่ำกว่าของ A (1.58) เพราะความผิดพลาดของ B ใหญ่ทุกเรื่อง จึงสม่ำเสมอกว่า ในขณะที่ A ผิดเพียงเรื่องเดียว
- เมื่อขยายไปทั้ง 32 คะแนนของตาราง MM-2 ด้วยโค้ดประกอบ 2.2 ได้ MAE: A = 1.1719, B = 1.9194 และ RMSE: A = 1.5829, B = 2.2006 แบบจำลอง A ยังดีกว่า แต่ช่องว่างแคบลงมาก เพราะผู้ใช้บางคน เช่น u3 และ u5 ให้คะแนนสูงและต่ำแก่เรื่องที่มีแนวร่วมกัน (u3 ให้ i7 แนว Action, Thriller เพียง 1 ดาว แต่ให้ i10 และ i11 ซึ่งมีแนวร่วมกับ i7 ถึง 5 ดาว) จนแบบจำลอง A ทายผิดทาง และสำหรับ u5 แบบจำลอง B กลับคลาดเคลื่อนน้อยกว่า
- ข้อสรุปจากผู้ใช้เพียงคนเดียว (5 คะแนน) ยังไม่ใช่ข้อสรุปของระบบ ต้องรายงานค่าบนชุดทดสอบทั้งหมดเสมอ และไม่ควรเลือกแสดงเฉพาะผู้ใช้ที่ผลออกมาดี

โค้ดประกอบ 2.2 คำนวณ MAE และ RMSE ของผู้ใช้ u1 และของทั้ง 32 คะแนน

```
def mae_rmse(pairs, pred):
    e = [pred(u, i) - r for u, i, r in pairs]     # e = r̂ − r
    mae = sum(abs(x) for x in e) / len(e)
    return mae, math.sqrt(sum(x * x for x in e) / len(e))
pA = lambda u, i: pred_A(u, i)[0]
u1 = [(u, i, r) for u, i, r in ALL if u == 'u1']
for name, f in [('A', pA), ('B', pred_B)]:
    m1, r1 = mae_rmse(u1, f); m2, r2 = mae_rmse(ALL, f)
    print(f'{name}: u1 MAE={m1:.4f} RMSE={r1:.4f}'
          f' | all32 MAE={m2:.4f} RMSE={r2:.4f}')
```

ผลลัพธ์ที่ได้

```
A: u1 MAE=0.3000 RMSE=0.4743 | all32 MAE=1.1719 RMSE=1.5829
B: u1 MAE=2.1667 RMSE=2.4438 | all32 MAE=1.9194 RMSE=2.2006
```

ตัวอย่างการคำนวณ 2.2 กรณีที่ MAE เท่ากันทุกประการ แต่ RMSE ต่างกันสองเท่า

ตัวอย่างนี้แสดงให้เห็นว่าเหตุใดจึงต้องรายงานทั้งสองค่า ไม่ใช่เลือกเพียงค่าเดียว

ที่มาของข้อมูล

- (ก) **คะแนนจริง** ใช้แถว u2 ของตาราง MM-2 ซึ่งมีค่าสี่ช่อง คือ i1 = 2, i4 = 5, i5 = 4 และ i6 = 5
- (ข) **คะแนนที่ทาย** เป็น **ค่าสมมติ** ของแบบจำลองสองตัวที่ออกแบบให้ผลรวมความผิดพลาดสัมบูรณ์เท่ากันพอดี คือ 4 ดาว เพื่อแยกผลของ “รูปแบบความผิดพลาด” ออกจาก “ขนาดความผิดพลาดรวม” กรณีที่ 1 ทายผิดเรื่องละ 1 ดาวสลับขึ้นลง กรณีที่ 2 ทายถูกสามเรื่อง แต่ทาย i6 (Bridget Jones) เป็น 1 ดาว ทั้งที่ u2 ให้ 5 ดาว

กรณี	คะแนนจริง (i1, i4, i5, i6)	คะแนนที่ทาย	ความผิดพลาด |e|	MAE	RMSE
กรณีที่ 1: ผิดพลาดกระจายสม่ำเสมอ	2, 5, 4, 5	3, 4, 5, 4	1, 1, 1, 1	1.0000	1.0000
กรณีที่ 2: ผิดพลาดหนักจุดเดียว	2, 5, 4, 5	2, 5, 4, 1	0, 0, 0, 4	1.0000	2.0000

การคำนวณของกรณีที่หนึ่ง

$$\text{MAE}_1 = \frac{|3-2| + |4-5| + |5-4| + |4-5|}{4} = \frac{4}{4} = 1.0000$$

$$\text{RMSE}_1 = \sqrt{\frac{1^2 + 1^2 + 1^2 + 1^2}{4}} = \sqrt{1} = 1.0000$$

การคำนวณของกรณีที่สอง

- $MAE = (0 + 0 + 0 + 4)/4 = 1.0000$
- $RMSE = \sqrt{((0 + 0 + 0 + 16)/4)} = \sqrt{4} = 2.0000$

แม้ทั้งสองกรณีจะมีค่า (MAE=1.0000) เท่ากัน แต่มีรูปแบบความผิดพลาดแตกต่างกัน กรณีที่ 1 ทำนายผิดเล็กน้อยอย่างสม่ำเสมอ โดยผิดรายการละ 1 คะแนน ขณะที่กรณีที่ 2 ทำนายถูกสามรายการ แต่ผิดอย่างรุนแรงหนึ่งรายการถึง 4 คะแนน ค่า MAE จึงไม่สามารถแสดงความแตกต่างนี้ได้ชัดเจน เพราะพิจารณาเพียงขนาดความผิดพลาดเฉลี่ย ส่วน RMSE ยกกำลังสองความผิดพลาดก่อนเฉลี่ย จึงทำให้กรณีที่ 2 มีค่า RMSE สูงขึ้นเป็น 2.0000

ตัวอย่างนี้แสดงให้เห็นว่าควรรายงาน MAE และ RMSE ร่วมกัน โดย MAE ใช้อธิบายความผิดพลาดเฉลี่ยโดยทั่วไป ส่วน RMSE ใช้ตรวจจับความเสี่ยงจากความผิดพลาดขนาดใหญ่ หากความผิดพลาดรุนแรงสร้างผลเสียมาก ควรให้ความสำคัญกับ RMSE แต่หากความผิดพลาดทุกระดับมีต้นทุนใกล้เคียงกัน MAE จะตีความได้ง่ายกว่า ดังนั้น ไม่ควรตัดสินว่ากรณีใดดีกว่าโดยดูจากตัวชี้วัดเพียงค่าเดียว แต่ต้องพิจารณารูปแบบความผิดพลาดและวัตถุประสงค์ของระบบร่วมกัน

กรอบเจาะลึก เหตุใด RMSE ≥ MAE จึงเป็นจริงเสมอ

MAE และ RMSE คำนวณจากความผิดพลาดชุดเดียวกัน แต่ปฏิบัติต่อความผิดพลาดต่างกัน โดย MAE นำขนาดความผิดพลาดมาหาค่าเฉลี่ยโดยตรง ขณะที่ RMSE ยกกำลังสองความผิดพลาดก่อนหาค่าเฉลี่ย จึงให้น้ำหนักกับความผิดพลาดขนาดใหญ่มากกว่า

กำหนดให้ e เป็นความคลาดเคลื่อนและ a = |e| ≥ 0 จะได้ MAE = E[a] และ RMSE = √E[a²] จากอสมการของเยนเซน [E(a)]² ≤ E(a²) จึงสรุปได้ว่า MAE ≤ RMSE (2.3) เครื่องหมายเท่ากับเกิดขึ้นเมื่อขนาดความคลาดเคลื่อนทุกค่ามีขนาดเท่ากัน

- เครื่องหมายเท่ากับเกิดขึ้นเมื่อและต่อเมื่อค่า |e| ทุกตัวเท่ากันหมด กล่าวคือแบบจำลองผิดพลาดเท่ากันทุกจุดเช่น ความผิดพลาด ((1,1,1,1)) ให้ค่า (MAE=RMSE=1)
- แต่ถ้าความผิดพลาดมีขนาดไม่เท่ากัน เช่น ((0,0,0,4)) จะได้ (MAE=1) และ (RMSE=2) เพราะ RMSE ขยายผลของความผิดพลาดขนาดใหญ่
- ในทางปฏิบัติจึงพบว่า RMSE > MAE เสมอ และผลต่างระหว่างสองค่านี้ใช้เป็นตัววัด **ความไม่สม่ำเสมอของความผิดพลาด** ได้ในเบื้องต้น
- หากค่าทั้งสองใกล้กัน ความผิดพลาดมักมีขนาดค่อนข้างใกล้เคียงกัน แต่หาก RMSE สูงกว่า MAE มาก อาจมีบางรายการที่โมเดลทำนายผิดมาก อย่างไรก็ตาม ช่องว่างดังกล่าวเป็นเพียงสัญญาณสำหรับตรวจสอบเพิ่มเติม ไม่เพียงพอที่จะยืนยันว่าข้อมูลมีค่าผิดปกติ
-

ข้อควรระวังที่สำคัญกว่าเรื่องอสมการ

ประเด็นนี้ได้รับความสนใจมาอย่างต่อเนื่อง โดยงานของ McNee และคณะตั้งแต่ปี 2006 ชี้ว่า ความแม่นยำของคะแนนเพียงอย่างเดียวไม่เพียงพอสำหรับตัดสินประโยชน์ของระบบผู้แนะนำ ต่อมา Cremonesi และคณะในปี 2010 แสดงให้เห็นเชิงทดลองว่า การปรับโมเดลให้มี RMSE ต่ำลงไม่ได้ทำให้ประสิทธิภาพของการแนะนำแบบ Top-N ดีขึ้นเสมอไป เพราะการทำนายคะแนนและการจัดอันดับเป็นคนละภารกิจ แม้จะมีความเกี่ยวข้องกันก็ตาม (McNee et al., 2006; Cremonesi et al., 2010)

RMSE วัดว่า “คะแนนที่โมเดลทำนายอยู่ห่างจากคะแนนจริงโดยเฉลี่ยเท่าใด” โดยยกกำลังสองความผิดพลาดเพื่อเพิ่มน้ำหนักให้กรณีที่ทำนายผิดมาก หากโมเดลทำนายคะแนนภาพยนตร์จริง 4 ดาวเป็น 3.8 ดาว ความผิดพลาดดังกล่าวจะถูกนำไปรวมในการคำนวณ RMSE เช่นเดียวกับรายการอื่น ๆ โดยไม่ได้พิจารณาว่าภาพยนตร์เรื่องนั้นอยู่ในอันดับที่ 1 อันดับที่ 50 หรือไม่ปรากฏในรายการแนะนำเลย

ในทางตรงกันข้าม การแนะนำแบบ Top-N สนใจว่า “รายการที่ผู้ใช้น่าจะชอบมากที่สุดถูกนำขึ้นมาอยู่ในลำดับต้นหรือไม่” ระบบอาจไม่จำเป็นต้องทำนายคะแนนให้ตรงทุกตำแหน่งทศนิยม แต่ต้องแยกให้ออกว่ารายการใดควรอยู่เหนือรายการใด โดยเฉพาะบริเวณหัวรายการที่ผู้ใช้จะเห็นจริง

ดังนั้น การเลือกตัวชี้วัดต้องสอดคล้องกับวัตถุประสงค์ของระบบ

- หากระบบต้องแสดงหรือพยากรณ์คะแนนดาว ควรใช้ MAE หรือ RMSE เพราะต้องการให้คะแนนที่ทำนายใกล้เคียงคะแนนจริง
- หากระบบต้องเลือกสินค้า ภาพยนตร์ หรือเนื้อหาไม่กี่รายการมาแสดงด้านบน ควรใช้ตัวชี้วัดเชิงอันดับ เช่น Precision@K, Recall@K และ NDCG@K เป็นตัวชี้วัดหลัก
- หากต้องการประเมินทั้งความแม่นยำของคะแนนและคุณภาพของรายการแนะนำ ควรรายงาน RMSE ร่วมกับตัวชี้วัดเชิงอันดับ ไม่ควรใช้ค่าใดค่าหนึ่งแทนกัน

กล่าวโดยสรุป ค่า RMSE ที่ต่ำกว่าหมายถึงโมเดลทำนาย “ค่าคะแนน” ได้ใกล้เคียงคะแนนจริงมากกว่าภายใต้ชุดข้อมูล มาตราส่วน และวิธีแบ่งข้อมูลเดียวกันเท่านั้น แต่ไม่ได้รับประกันว่าโมเดลจะเลือก “รายการที่ดี

ที่สุด” หรือเรียงรายการเหล่านั้นไว้ในอันดับต้นได้ดีกว่า ด้วยเหตุนี้ งานแนะนำแบบ Top-N จึงควรให้ความสำคัญกับตัวชี้วัดเชิงอันดับ ซึ่งวัดผลได้ตรงกับสิ่งที่ผู้ใช้มองเห็นและใช้งานจริงมากกว่า

2.2 ตัวชี้วัดเชิงอันดับที่ไม่ไวต่อตำแหน่งใน Top-K

เมื่อผลลัพธ์เป็นรายการแนะนำแบบเรียงลำดับ เราเปลี่ยนจากการถามว่า “คะแนนที่ทายใกล้เพียงใด” เป็น “มีรายการที่เกี่ยวข้องกี่ชิ้นใน K อันดับแรก” ตัวชี้วัดในหัวข้อนี้มอง Top-K เป็นเซต จึงให้ค่าเท่ากันหากมีรายการที่เกี่ยวข้องจำนวนเท่ากัน แม้ตำแหน่งภายในลิสต์จะแตกต่างกัน



ภาพที่ 2.2 เมทริกซ์ความสับสนในบริบทของระบบผู้แนะนำ

โดยที่

- Ground Truth *อาจสร้างจากรายการที่ผู้ใช้เคยคลิก ซื้อ รับชม หรือให้คะแนนสูงในข้อมูลทดสอบ ทั้งนี้ รายการที่ไม่อยู่ใน* Ground Truth *ไม่ได้หมายความว่าผู้ใช้ไม่ชอบเสมอไป แต่อาจเป็นรายการที่ผู้ใช้ยังไม่เคยเห็นหรือยังไม่มีข้อมูลตอบกลับ*
- Top-K หมายถึง*รายการ (K) อันดับแรกที่ระบบเลือกมาแนะนำแก่ผู้ใช้ (u) โดยเรียงจากรายการที่ระบบคาดว่าเหมาะสมมากที่สุดไปยังน้อยที่สุด*
- ***TP:*** รายการอยู่ใน *Top-K* และอยู่ใน *Ground Truth*
- ***FP:*** รายการอยู่ใน *Top-K* แต่ไม่อยู่ใน *Ground Truth* ทั้งนี้ยังไม่ยืนยันว่าผู้ใช้ไม่ชอบ
- ***FN:*** รายการอยู่ใน *Ground Truth* แต่ระบบไม่ได้นำมาไว้ใน *Top-K*
- **TN:** รายการไม่อยู่ทั้งใน Top-K และ Ground Truth แต่ไม่ได้หมายความว่าไม่เกี่ยวข้องจริงเสมอไป

เพื่อให้เปรียบเทียบตัวชี้วัดทุกตัวได้อย่างเป็นธรรม ทุกสูตรในสามหัวข้อถัดไปจะคำนวณบนข้อมูลชุดเดียวกัน คือรายการแนะนำของผู้ใช้ **u1** ที่แบบจำลอง A และ B สร้างขึ้นจากตาราง MM-1 และ MM-2 ดังตารางที่ 2.2 ประเด็นสำคัญที่สุดของทั้งหัวข้อซึ่งควรสังเกตไว้ตั้งแต่ตอนนี้ คือ แบบจำลอง A และ B มีรายการที่แนะนำถูกต้องอยู่ในสิบอันดับแรก (Top-10) จำนวนเท่ากันพอดี คือสามชิ้น ต่างกันเพียงตำแหน่งที่รายการเหล่านั้นปรากฏเท่านั้น

ตารางที่ 2.2 *ข้อมูลตั้งต้นสำหรับการคำนวณตัวชี้วัดเชิงอันดับทุกตัว (ผู้ใช้ u1 จัดอันดับภาพยนตร์ทั้ง 12 เรื่อง)*

อันดับ	1	2	3	4	5	6	7	8	9	10	11	12
แบบจำลอง A	i3 ✓	i1 ✓	i2 ✓	i8	i10	i11	i5	i7	i12	i4	i6	i9
$\hat{r}$(A)	5.00	4.75	4.75	4.00	4.00	4.00	3.20	3.20	2.00	1.00	1.00	1.00
แบบจำลอง B	i11	i6	i5	i4	i12	i2 ✓	i3 ✓	i8	i10	i1 ✓	i7	i9
n / ค่าเฉลี่ย (B)	4 / 3.75	3 / 4.33	3 / 3.00	2 / 4.50	2 / 4.50	2 / 3.50	2 / 3.50	2 / 3.50	2 / 3.50	2 / 3.00	2 / 3.00	1 / 5.00

รายการที่ผู้ใช้ชอบจริง (Ground Truth) ของ u1 ได้จากตาราง MM-2 แถว u1 โดยใช้กฎความเกี่ยวข้อง “คะแนนตั้งแต่ 4 ดาวขึ้นไป” จึงได้ $\mathcal{R}$(u1) = {i1, i2, i3} ซึ่งได้ 5, 5 และ 4 ดาวตามลำดับ ส่วน i4 และ i6 ได้ 1 ดาว จึงไม่เกี่ยวข้อง และอีกเจ็ดเรื่องที่ยังไม่มีคะแนนถูกนับเป็นไม่เกี่ยวข้องตามข้อตกลงของการประเมินออฟไลน์ (ซึ่งเป็นผลลบเทียมได้ ดังหัวข้อ 2.15.1) กำหนดค่าตัด K = 10 เครื่องหมาย ✓ แสดงตำแหน่งของรายการที่ผู้ใช้ชอบจริง ส่วนอันดับ 11–12 อยู่นอก Top-10 แต่ยังต้องใช้เมื่อคำนวณ AUC ในหัวข้อ 2.4

ที่มาของข้อมูล ที่มาของรายการในตารางที่ 2.2 ทีละขั้น

ขั้นที่ 1 แบบจำลอง A คำนวณ $\hat{r}$ ของทั้ง 12 เรื่องด้วยสมการ (M2)

สำหรับเรื่องที่ u1 เคยให้คะแนน (i1, i2, i3, i4, i6) ต้องปิดบังคะแนนของเรื่องนั้นก่อน เช่น ขณะคำนวณ i3 จะใช้เพียง i1 และ i2 เป็นเพื่อนบ้าน ส่วนเรื่องที่ยังไม่มีคะแนนใช้ทั้งห้าเรื่อง ค่าเฉลี่ยของ u1 ที่ใช้แทนเมื่อไม่มีแนวร่วมคือ $(5+5+4+1+1)/5 = 3.2$

รายการ	แนว (MM-1)	เพื่อนบ้านในแถว u1 ที่มีแนวร่วม	ΣJ	$\hat{r}$ (A)	อันดับ
i1	Animation, Family	i2(J=1.00, r=5), i3(J=0.33, r=4)	1.33	4.7500	2
i2	Animation, Family	i1(J=1.00, r=5), i3(J=0.33, r=4)	1.33	4.7500	3
i3	Animation, Sci-Fi	i1(J=0.33, r=5), i2(J=0.33, r=5)	0.67	5.0000	1
i4	Drama, Romance	i6(J=1.00, r=1)	1.00	1.0000	10
i5	Fantasy, Musical	ไม่มีแนวร่วม ⟶ ใช้ค่าเฉลี่ยของ u1	0.00	3.2000	7
i6	Drama, Romance	i4(J=1.00, r=1)	1.00	1.0000	11
i7	Action, Thriller	ไม่มีแนวร่วม ⟶ ใช้ค่าเฉลี่ยของ u1	0.00	3.2000	8
i8	Action, Sci-Fi	i3(J=0.33, r=4)	0.33	4.0000	4
i9	Drama, Thriller	i4(J=0.33, r=1), i6(J=0.33, r=1)	0.67	1.0000	12
i10	Action, Sci-Fi	i3(J=0.33, r=4)	0.33	4.0000	5
i11	Sci-Fi, Thriller	i3(J=0.33, r=4)	0.33	4.0000	6
i12	Drama, Sci-Fi	i3(J=0.33, r=4), i4(J=0.33, r=1), i6(J=0.33, r=1)	1.00	2.0000	9

จากนั้นเรียง $\hat{r}$ จากมากไปน้อย i3 ได้ 5.00 จึงขึ้นอันดับ 1 ตามด้วย i1 และ i2 ซึ่งเสมอกันที่ 4.75 และมี ΣJ เท่ากัน จึงเรียงตามรหัส ส่วน i8, i10, i11 เสมอกันที่ 4.00 ส่วน i5 กับ i7 ไม่มีแนวร่วมกับประวัติของ u1 เลย จึงได้ค่าเฉลี่ย 3.20

ขั้นที่ 2 แบบจำลอง B นับผู้ให้คะแนนคนอื่นในแต่ละคอลัมน์ของตาราง MM-2 ด้วยสมการ (M4)

รายการ	คะแนนจากผู้ใช้คนอื่น (ไม่นับ u1)	n	ค่าเฉลี่ย	อันดับ
i1	u2=2, u4=4	2	3.0000	10
i2	u6=5, u8=2	2	3.5000	6
i3	u5=4, u7=3	2	3.5000	7
i4	u2=5, u8=4	2	4.5000	4
i5	u2=4, u4=1, u6=4	3	3.0000	3
i6	u2=5, u5=3, u8=5	3	4.3333	2
i7	u3=1, u4=5	2	3.0000	11
i8	u4=5, u7=2	2	3.5000	8
i9	u5=5	1	5.0000	12

i10	u3=5, u5=2	2	3.5000	9
i11	u3=5, u6=3, u7=4, u8=3	4	3.7500	1
i12	u3=4, u7=5	2	4.5000	5

i11 มีผู้ให้คะแนนมากที่สุด 4 คน จึงขึ้นอันดับ 1 ตามด้วย i6 และ i5 ที่มี 3 คน (i6 มีค่าเฉลี่ยสูงกว่า) เรื่องที่มี 2 คนมีถึงแปดเรื่องจึงต้องใช้ค่าเฉลี่ยตัดสิน สังเกตว่าเรื่องที่ u1 ชอบทั้งสามเรื่องเป็นเรื่องที่ “ไม่ดัง” ในหมู่ผู้ใช้คนอื่น แบบจำลอง B จึงวางไว้ที่อันดับ 6, 7 และ 10

โค้ดประกอบ 2.3 จัดอันดับภาพยนตร์ 12 เรื่องของผู้ใช้หนึ่งคนด้วยแบบจำลอง A และ B

```
# Ground Truth: r >= 4
def rel(u):
    return {i for i, r in R[u].items() if r >= 4}

# เรียง r̂ แล้ว ΣJ แล้วรหัส
def rank_A(u):
    sc = {i: pred_A(u, i) for i in ITEMS}
    return sorted(ITEMS, key=lambda i: (-round(sc[i][0], 10),
                                        -sc[i][1], int(i[1:])))

# สมการ (M4): n แล้วค่าเฉลี่ย
def rank_B(u):
    def key(i):
        o = [R[v][i] for v in USERS if v != u and i in R[v]]
        return (-len(o), -(sum(o) / len(o) if o else 0), int(i[1:]))
    return sorted(ITEMS, key=key)

LA = {u: rank_A(u) for u in USERS}
LB = {u: rank_B(u) for u in USERS}
print('GT', sorted(rel('u1')))
print('A ', LA['u1']);  print('B ', LB['u1'])
```

ผลลัพธ์ที่ได้

```
GT ['i1', 'i2', 'i3']
A  ['i3', 'i1', 'i2', 'i8', 'i10', 'i11', 'i5', 'i7', 'i12', 'i4', 'i6', 'i9']
B  ['i11', 'i6', 'i5', 'i4', 'i12', 'i2', 'i3', 'i8', 'i10', 'i1', 'i7', 'i9']
```

กติกาที่ต้องกำหนดก่อนคำนวณตัวชี้วัด Top K

ก่อนคำนวณ Precision Recall F1 และ Hit Rate ต้องตรึงหกเรื่องให้เหมือนกันทุกแบบจำลอง ได้แก่ นิยามความเกี่ยวข้อง ค่า K เซตผู้สมัคร การตัดรายการที่ผู้ใช้เคยเห็นออก วิธีจัดการคะแนนเสมอ และวิธีรวมผลข้ามผู้ใช้ หากระบบคืนผลน้อยกว่า K รายการ ต้องประกาศว่าจะใช้ K หรือจำนวนรายการที่คืนจริงเป็นตัวส่วนของ Precision การเปลี่ยนกติกาข้อนี้เพียงข้อเดียวอาจทำให้คะแนนเปรียบเทียบกันไม่ได้

รายการซ้ำไม่ควรถูกนับเป็นคำตอบถูกหลายครั้ง เพราะ Top-K ทางคณิตศาสตร์ถือเป็นเซตของรหัสรายการที่ไม่ซ้ำกัน หากกระบวนการสร้างคำแนะนำคืนรหัสเดิมซ้ำ ควรลบรายการซ้ำก่อนประเมินและบันทึกเหตุการณ์นั้นเป็นข้อผิดพลาดของระบบสร้างผลลัพธ์

2.2.1 ความแม่นยำที่ K (Precision@K)

$$Precision@K(u) = \frac{|\mathcal{R}(u) \cap \mathcal{L}_K(u)|}{K} \qquad (2.4)$$

โดยที่ $R(u)$ คือเซตรายการที่ผู้ใช้ u ชอบจริง และ $L_K(u)$ คือรายการ โดยที่ K อันดับแรกที่ระบบแนะนำ $|R(u) \cap L_K(u)|$ คือจำนวนของรายการที่ผู้ใช้ u ชอบจริงที่ได้รับการแนะนำเป็น K อันดับแรก ความหมายในถ้าอธิบายอย่างง่ายคือ “ในรายการที่เรานำมาแนะนำ K ชิ้น เป็นรายการที่ถูกใจกี่ส่วน”

จากตัวอย่างในตารางที่ 2.2 สามารถคำนวณค่าความแม่นยำ ณ ตำแหน่ง K ของทั้งสองโมเดลดังนี้

$Precision@10$ (แบบจำลอง A) = 3 / 10 = 0.3000

$Precision@10$ (แบบจำลอง B) = 3 / 10 = 0.3000

จากตัวอย่างนี้สิ่งที่น่าสังเกตคือ เมื่อ Ground Truth มีเพียง 3 รายการ ต่อให้ระบบนำทั้งสามรายการมาแสดงครบ ก็ไม่สามารถมีรายการที่ยืนยันว่าเกี่ยวข้องเกิน 3 รายการได้ ดังนั้นค่าสูงสุดคือ

$$max(Precision@10) = \frac{3}{10} = 0.30$$

กรณีทั่วไป หาก Ground Truth มี m รายการ จะได้ขอบเขตสูงสุดว่า

$$max(Precision@K) = \frac{\min(K, m)}{K}$$

ดังนั้น:

- ถ้า $m < K$ ค่า Precision@K สูงสุดจะน้อยกว่า 1
- ถ้า $m \geq K$ ค่า Precision@K จึงมีโอกาสสูงสุดถึง 1
- จำนวน Ground Truth ไม่จำเป็นต้องเท่ากับ K

2.2.2 ความระลึกที่ K (Recall@K)

$$Recall@K(u) = \frac{|\mathcal{R}(u) \cap \mathcal{L}_K(u)|}{|\mathcal{R}(u)|} \qquad (2.5)$$

ความหมายคือ “ในรายการที่ผู้ใช้ชอบทั้งหมด เรานำมาแนะนำได้กี่ส่วน” ตัวส่วนเปลี่ยนจาก K เป็นจำนวนรายการที่ผู้ใช้ชอบจริง

จากตัวอย่างในตารางที่ 2.2 สามารถคำนวณค่าการเรียกคืน ณ ตำแหน่ง K ของทั้งสองโมเดลดังนี้

Recall@10 (แบบจำลอง A) = 3 / 3 = 1.0000

Recall@10 (แบบจำลอง B) = 3 / 3 = 1.0000

กรณีพิเศษของ Recall

Recall@K มีตัวส่วนเป็นจำนวนรายการที่เกี่ยวข้องของผู้ใช้ หาก $|\mathcal{R}_u| = 0$ สูตรจะหารด้วยศูนย์ งานวิจัยจึงต้องกำหนดล่วงหน้าว่าจะตัดผู้ใช้นั้นออกจากการเฉลี่ยหรือกำหนดค่าเป็นศูนย์ วิธีแรกตอบคำถามเฉพาะผู้ใช้ที่มีคำตอบในชุดทดสอบ ส่วนวิธีที่สองผสมปัญหาความครอบคลุมของข้อมูลเข้ากับคุณภาพของแบบจำลอง จึงต้องรายงานจำนวนผู้ใช้ที่ถูกตัดออกควบคู่กัน

2.2.3 ค่าเฉลี่ยฮาร์มอนิกที่ K (F1@K)

$$F1@K(u) = \frac{2 \cdot Precision@K(u) \cdot Recall@K(u)}{(Precision@K(u) + Recall@K(u))} \quad (2.6)$$

ค่า F1@K เป็นค่าเฉลี่ยฮาร์มอนิกของ Precision@K และ Recall@K จึงมีค่าสูงเมื่อทั้งสองตัวชี้วัดอยู่ในระดับที่ดีพร้อมกัน การใช้ค่าเฉลี่ยฮาร์มอนิกแทนค่าเฉลี่ยเลขคณิตมีเหตุผลสำคัญ คือค่าเฉลี่ยฮาร์มอนิกจะถูกดึงลงโดยค่าที่ต่ำกว่า ตัวอย่างเช่น

- ระบบที่มี Precision = 1.0 แต่ Recall = 0.0 จะได้ F1 = 0 ไม่ใช่ 0.5 แบบค่าเฉลี่ยเลขคณิตสะท้อนว่าระบบไม่สามารถสร้างสมดุลระหว่างความแม่นยำกับความครอบคลุมได้
- Precision@K=0.80 และ Recall@K=0.20 หากใช้ค่าเฉลี่ยเลขคณิตจะเท่ากับ 0.50 แต่ F1@K เท่ากับเพียง 0.32 แสดงว่าระบบแนะนำรายการได้ค่อนข้างแม่นยำ แต่ยังค้นพบรายการที่เกี่ยวข้องได้ไม่ครอบคลุม

ดังนั้น (F1@K) จึงเหมาะสำหรับประเมินระบบที่ต้องการสร้างสมดุลระหว่างความแม่นยำและความครอบคลุม

จากตัวอย่างในตารางที่ 2.2 สามารถคำนวณค่า F1 ณ ตำแหน่ง K ของทั้งสองแบบจำลองได้ดังนี้

F1@10 (แบบจำลอง A) = 2 × 0.3000 × 1.0000 / (0.3000 + 1.0000)

= 0.6000 / 1.3000 = 0.4615

แม้แบบจำลอง A จะวางรายการที่เกี่ยวข้องไว้ในอันดับ (1, 2, 3) ส่วนแบบจำลอง B วางไว้ในอันดับ (6, 7, 10) แต่ตัวชี้วัดกลุ่มนี้ให้คะแนนเท่ากัน เพราะสนใจเพียงว่ารายการที่เกี่ยวข้องอยู่ภายใน Top-10 หรือไม่ โดยไม่สนใจตำแหน่ง

การอ่านค่า F1 อย่างถูกต้อง

F1@K เป็นค่าเฉลี่ยฮาร์มอนิกของ Precision@K และ Recall@K จึงสูงได้ต่อเมื่อทั้งสองค่ามีระดับใกล้เคียงกัน หากค่าใดค่าหนึ่งเป็นศูนย์ F1 จะเป็นศูนย์ทันที ในตัวอย่างที่ TP = 3 K = 10 และ $|\mathcal{R}_u| = 3$ จะได้ Precision = 3/10 = 0.3000, Recall = 3/3 = 1.0000 และ F1 = 2(0.3000)(1.0000)/(0.3000 + 1.0000) = 0.4615 ค่านี้ไม่ใช่ค่าเฉลี่ยเลขคณิต 0.6500

2.2.4 อัตราการพบรายการที่ K (Hit Rate@K)

$$HR@K(u) = \begin{cases} 1 & \text{ถ้า } |\mathcal{R}(u) \cap \mathcal{L}_K(u)| \neq \emptyset \\ 0 & |\mathcal{R}(u) \cap \mathcal{L}_K(u)| = \emptyset \end{cases} \quad (2.7)$$

อัตราการได้รับเลือก ณ ตำแหน่ง K เป็นตัวชี้วัดที่ละเอียดน้อยที่สุดในตระกูล ตอบเพียงว่า “มีรายการที่แนะนำถูกต้องอย่างน้อยหนึ่งชิ้นหรือไม่” เหมาะกับสถานการณ์ที่การโดนเพียงชิ้นเดียวก็ถือว่าสำเร็จ เช่น การแนะนำสินค้าเสริมตอนชำระเงิน ในกรณีนี้ทั้ง A และ B ได้ HR@10 = 1.0000 เท่ากัน

การรวม Hit Rate ข้ามผู้ใช้

Hit Rate@K ของผู้ใช้หนึ่งคนมีค่าเพียง 0 หรือ 1 คือไม่พบหรือพบรายการที่เกี่ยวข้องอย่างน้อยหนึ่งชิ้น เมื่อเฉลี่ยผู้ใช้ 100 คนแล้วได้ HR@10 = 0.72 ความหมายคือผู้ใช้ 72 คนมีอย่างน้อยหนึ่ง Hit ในสิบอันดับแรก ไม่ได้หมายความว่าร้อยละ 72 ของรายการที่แนะนำทั้งหมดเป็นรายการที่เกี่ยวข้อง เพราะคำถามหลังเป็นของ Precision

ตีความการเปรียบเทียบ Precision@10 · Recall@10 · F1@10 · HR@10 ของผู้ใช้ u1

0.3000 · 1.0000	VS	0.3000 · 1.0000
P@10 · R@10 (แบบจำลอง A)		P@10 · R@10 (แบบจำลอง B)

- แบบจำลอง A และ B ได้ Precision@10 = 0.3000, Recall@10 = 1.0000, F1@10 = 0.4615 และ HR@10 = 1.0000 เท่ากันทุกหลัก เพราะทั้งสองนำ i1, i2 และ i3 เข้ามาอยู่ใน Top-10 ครบทั้งสามเรื่อง ตัวชี้วัดกลุ่มนี้จึง “มองไม่เห็น” ว่า A วางเรื่องที่ u1 ชอบไว้สามอันดับแรก ในขณะที่ B วางไว้อันดับ 6, 7 และ 10
- ข้อสรุปนี้ขึ้นกับค่า K อย่างมาก หากลด K เหลือ 5 จะได้ Precision@5 ของ A = 3/5 = 0.6000 แต่ของ B = 0/5 = 0.0000 เพราะเรื่องที่ถูกต้องของ B ทั้งหมดอยู่หลังอันดับ 5 หัวข้อ 2.4.2 จะแสดงพฤติกรรมนี้ครบทุกค่า K
- ค่าที่เท่ากันของตัวชี้วัดแบบไม่ไวต่อตำแหน่งไม่ได้แปลว่าแบบจำลองดีเท่ากัน แต่แปลว่าตัวชี้วัดนั้นไม่มีข้อมูลพอจะแยกแยะ จึงต้องรายงานตัวชี้วัดที่ไวต่อตำแหน่งในหัวข้อ 2.3 ควบคู่เสมอ

โค้ดประกอบ 2.4 Precision@K, Recall@K, F1@K และ HR@K ตามสมการ (2.4)–(2.7)

```
def prec(L, Rs, K): return len(set(L[:K]) & Rs) / K
def recall(L, Rs, K): return len(set(L[:K]) & Rs) / len(Rs)
def f1(L, Rs, K):
    p, r = prec(L, Rs, K), recall(L, Rs, K)
    return 0.0 if p + r == 0 else 2 * p * r / (p + r)
def hit(L, Rs, K): return 1.0 if set(L[:K]) & Rs else 0.0

for m, L in [('A', LA['u1']), ('B', LB['u1'])]:
    v = [round(f(L, rel('u1'), 10), 4) for f in (prec, recall, f1, hit)]
    print(m, v,
          'P@5 =', prec(L, rel('u1'), 5))
```

ผลลัพธ์ที่ได้

```
A [0.3, 1.0, 0.4615, 1.0] P@5 = 0.6
B [0.3, 1.0, 0.4615, 1.0] P@5 = 0.0
```

2.3 ตัวชี้วัดเชิงอันดับที่ไวต่อตำแหน่งใน Top-K

Precision, Recall, F1 และ HR สนใจว่ารายการที่เกี่ยวข้องอยู่ใน Top-K หรือไม่ แต่ยังไม่สะท้อนความต่างระหว่างอันดับ 1 กับอันดับ 10 ในงานจริงรายการด้านบนมักถูกมองเห็นมากกว่า จึงต้องใช้ตัวชี้วัดที่ลดน้ำหนักตามตำแหน่ง ได้แก่ RR/MRR, AP/MAP และ nDCG

ตารางที่ 2.2 ใช้รายการแนะนำสองลิสต์ที่มีจำนวนคำตอบถูกเท่ากัน แต่จัดวางคำตอบไว้คนละตำแหน่ง จึงช่วยให้เห็นชัดว่าตัวชี้วัดแบบไวต่อตำแหน่งแยกแบบจำลอง A และ B ออกจากกันได้อย่างไร

ตารางที่ 2.2 แสดงรายการของผู้ใช้ u1 เพียงคนเดียว แต่ตัวชี้วัดในหัวข้อนี้ต้องเฉลี่ยข้ามผู้ใช้ (เช่น MRR และ MAP) ตารางถัดไปจึงแสดง Top-10 ของผู้ใช้ทั้งแปดคน ที่ได้จากโค้ดประกอบ 2.3 ชุดเดียวกัน Ground Truth ของแต่ละคนคือภาพยนตร์ที่ได้คะแนนตั้งแต่ 4 ดาวในแถวของผู้ใช้คนนั้นในตาราง MM-2

ตารางประกอบหัวข้อ 2.3 Ground Truth และ Top-10 ของผู้ใช้ทั้งแปดคน (✓ = เกี่ยวข้อง)

ผู้ใช้	Ground Truth (คะแนน)	Top-10 ของแบบจำลอง A	Top-10 ของแบบจำลอง B
u1	i1(5), i2(5), i3(4)	i3 ✓ i1 ✓ i2 ✓ i8 i10 i11 i5 i7 i12 i4	i11 i6 i5 i4 i12 i2 ✓ i3 ✓ i8 i10 i1 ✓
u2	i4(5), i5(4), i6(5)	i4 ✓ i6 ✓ i9 i12 i1 i5 ✓ i7 i8 i10 i11	i11 i2 i3 i6 ✓ i1 i12 i8 i10 i7 i4 ✓
u3	i10(5), i11(5), i12(4)	i7 i12 ✓ i3 i8 i4 i6 i1 i2 i5 i9	i6 i2 i1 i3 i4 i11 ✓ i5 i8 i7 i9
u4	i1(4), i7(5), i8(5)	i10 i11 i7 ✓ i8 ✓ i9 i12 i5 i3 i2 i4	i11 i6 i2 i3 i4 i12 i5 i1 ✓ i10 i9
u5	i3(4), i9(5)	i6 i1 i2 i10 i11 i4 i12 i7 i5 i9 ✓	i11 i2 i1 i6 i4 i5 i12 i3 ✓ i8 i7
u6	i2(5), i5(4)	i1 i11 i3 i4 i5 ✓ i6 i2 ✓ i7 i8 i9	i6 i11 i1 i3 i4 i12 i2 ✓ i8 i10 i7

ผู้ใช้	Ground Truth (คะแนน)	Top-10 ของแบบจำลอง A	Top-10 ของแบบจำลอง B
u7	i11(4), i12(5)	i4 i6 i9 i8 i3 i5 i11 ✓ i10 i12 ✓ i7	i6 i2 i1 i11 ✓ i4 i5 i3 i10 i7 i8
u8	i4(4), i6(5)	i4 ✓ i6 ✓ i9 i12 i2 i11 i5 i7 i8 i10	i11 i1 i3 i5 i6 ✓ i2 i12 i8 i10 i4 ✓

สังเกตว่ารายการที่เกี่ยวข้องบางเรื่องหลุดไปอยู่อันดับ 11–12 เช่น i10 และ i11 ของ u3 ในแบบจำลอง A ซึ่งเกิดจากโปรโตคอลปิดบังทีละรายการ ขณะคำนวณ i10 ของ u3 แบบจำลองต้องอาศัย i7 (ได้ 1 ดาว), i11 และ i12 เป็นเพื่อนบ้าน และ i7 มีแนว Action ร่วมกับ i10 ค่าทำนายจึงถูกดึงลง กรณีเช่นนี้คือจุดอ่อนที่แท้จริงของแบบจำลองอิงแนว ไม่ใช่ความผิดพลาดของการคำนวณ

เหตุใดตำแหน่งจึงเปลี่ยนคะแนน

ตัวชี้วัดที่ไวต่อตำแหน่งใช้หลักเดียวกันคือให้รางวัลกับคำตอบที่ปรากฏเร็วกว่า แต่ต่างกันที่จำนวนคำตอบที่นำมาพิจารณา RR สนใจคำตอบแรกเท่านั้น AP ให้รางวัลทุกตำแหน่งที่พบคำตอบ และ nDCG รองรับระดับความเกี่ยวข้องหลายระดับ การเลือกตัวชี้วัดจึงต้องอิงพฤติกรรมการใช้จริง เช่น งานค้นหารายการเดียวเหมาะกับ RR ขณะที่หน้ารวมคำแนะนำหลายรายการเหมาะกับ MAP หรือ nDCG มากกว่า

2.3.1 อันดับส่วนกลับและอันดับส่วนกลับเฉลี่ย (RR@K และ MRR@K)

RR@K(u) พิจารณาเฉพาะตำแหน่งของรายการที่เกี่ยวข้องชิ้นแรกสำหรับผู้ใช้ u ถ้ารายการแรกอยู่สูง ค่าจะสูง; ถ้าอยู่ลึก ค่าจะลดลง; และถ้าไม่พบรายการที่เกี่ยวข้องใน K อันดับแรก ให้ค่าเป็นศูนย์

1) ให้ rank_u เป็นตำแหน่งของรายการที่เกี่ยวข้องชิ้นแรกใน $\mathcal{L}_u^K$ แล้วกำหนด RR@K(u) = $1/\text{rank}_u$ เมื่อพบรายการดังกล่าว และ RR@K(u) = 0 เมื่อไม่พบ

ตัวอย่างเช่น หากคำตอบแรกอยู่ที่อันดับ 2 จะได้ RR@K(u) = 1/2 = 0.5 แต่ถ้าอยู่ที่อันดับ 8 จะเหลือ 1/8 = 0.125 ตัวชี้วัดนี้เหมาะกับงานที่ผู้ใช้ต้องการคำตอบที่ดีเพียงรายการแรก เช่น การค้นเอกสารหรือคำตอบในองค์กร

ตัวอย่างนี้กำหนด K = 10 และใช้ผู้ใช้ทั้ง 8 คน อันดับที่พบรายการเกี่ยวข้องอ่านได้จากตารางประกอบหัวข้อ 2.3 ข้างต้น

ผู้ใช้	อันดับที่พบรายการเกี่ยวข้อง (A)	RR (A)	อันดับที่พบรายการเกี่ยวข้อง (B)	RR (B)
u1	1, 2, 3 ⟶ อันดับแรกคือ 1	1/1 = 1.0000	6, 7, 10 ⟶ อันดับแรกคือ 6	1/6 = 0.1667
u2	1, 2, 6 ⟶ อันดับแรกคือ 1	1/1 = 1.0000	4, 10 ⟶ อันดับแรกคือ 4	1/4 = 0.2500
u3	2 ⟶ อันดับแรกคือ 2	1/2 = 0.5000	6 ⟶ อันดับแรกคือ 6	1/6 = 0.1667
u4	3, 4 ⟶ อันดับแรกคือ 3	1/3 = 0.3333	8 ⟶ อันดับแรกคือ 8	1/8 = 0.1250
u5	10 ⟶ อันดับแรกคือ 10	1/10 = 0.1000	8 ⟶ อันดับแรกคือ 8	1/8 = 0.1250
u6	5, 7 ⟶ อันดับแรกคือ 5	1/5 = 0.2000	7 ⟶ อันดับแรกคือ 7	1/7 = 0.1429
u7	7, 9 ⟶ อันดับแรกคือ 7	1/7 = 0.1429	4 ⟶ อันดับแรกคือ 4	1/4 = 0.2500

ผู้ใช้	อันดับที่พบรายการเกี่ยวข้อง (A)	RR (A)	อันดับที่พบรายการเกี่ยวข้อง (B)	RR (B)
u8	1, 2 ⟶ อันดับแรกคือ 1	1/1 = 1.0000	5, 10 ⟶ อันดับแรกคือ 5	1/5 = 0.2000
รวม		**4.2762**		**1.4262**

2) Mean Reciprocal Rank ที่จุดตัด K หรือ MRR@K คือค่าเฉลี่ย RR@K(u) ของผู้ใช้ทุกคนในเซตประเมิน $\mathcal{U}$

$$MRR@K = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} RR@K(u) \quad (2.8)$$

ข้อจำกัดของ MRR@K คือไม่สนใจรายการที่เกี่ยวข้องลำดับถัดไป หลังพบคำตอบแรกแล้วคะแนนจะไม่เปลี่ยน หากงานต้องการให้หลายรายการในลิสต์มีคุณภาพ ควรใช้ MAP@K หรือ nDCG@K ร่วมด้วย

สำหรับผู้ใช้ u1 จะได้ RR (แบบจำลอง A) = 1/1 = 1.0000 และ RR (แบบจำลอง B) = 1/6 = 0.1667 ต่างกันถึงหกเท่า เมื่อเฉลี่ยข้ามผู้ใช้ทั้งแปดคนตามสมการ (2.8) จะได้

$$\sum_{u} RR_A = 1 + 1 + 0.5 + 0.3333 + 0.1 + 0.2 + 0.1429 + 1 = 4.2762$$

$$\text{MRR@10}_A = \frac{4.2762}{8} = 0.5345$$

$$\sum_{u} RR_B = 0.1667 + 0.25 + 0.1667 + 0.125 + 0.125 + 0.1429 + 0.25 + 0.2 = 1.4262$$

$$\text{MRR@10}_B = \frac{1.4262}{8} = 0.1783$$

ตัวชี้วัดนี้แยกความต่างระหว่าง A กับ B ได้ทันทีตั้งแต่ระดับผู้ใช้คนเดียว จุดอ่อนของ MRR คือมองข้ามรายการที่ถูกต้องชิ้นที่สองเป็นต้นไปทั้งหมด เช่น u2 ในแบบจำลอง A พบเรื่องที่เกี่ยวข้องที่อันดับ 1, 2 และ 6 แต่ได้ RR = 1 เท่ากับ u8 ที่พบที่อันดับ 1 และ 2 จึงไม่เหมาะกับงานที่ผู้ใช้ต้องการหลายรายการ

ตีความการเปรียบเทียบ MRR@10 ของผู้ใช้ทั้งแปดคน

0.5345	VS	0.1783
MRR@10 แบบจำลอง A		MRR@10 แบบจำลอง B

- แบบจำลอง A มีค่า MRR@10 เท่ากับ 0.5345 สูงกว่าแบบจำลอง B ซึ่งมีค่าเท่ากับ 0.1783 อยู่ 0.3563 หรือประมาณ 3.0 เท่า แสดงว่าแบบจำลอง A นำรายการที่เกี่ยวข้องรายการแรกขึ้นมาแสดงในอันดับต้นได้เร็วกว่าโดยเฉลี่ย โดยแบบจำลอง A พบรายการแรกที่อันดับ 1, 1, 2, 3, 10, 5, 7 และ 1 ส่วนแบบจำลอง B พบที่อันดับ 6, 4, 6, 8, 8, 7, 4 และ 5 ตามลำดับผู้ใช้ u1–u8
- อย่างไรก็ตาม A ไม่ได้ชนะทุกคน ผู้ใช้ u5 และ u7 ได้ RR จากแบบจำลอง B สูงกว่า (0.1250 > 0.1000 และ 0.2500 > 0.1429) การรายงานค่าเฉลี่ยจึงควรแนบการกระจายรายผู้ใช้ด้วย
- MRR สูงไม่ได้รับประกันว่ารายการที่เกี่ยวข้องชิ้นที่สองและสามอยู่ในตำแหน่งที่ดี จึงควรรายงาน MAP@K หรือ nDCG@K ควบคู่

โค้ดประกอบ 2.5 Reciprocal Rank และ MRR@K ตามสมการ (2.8)

```
def rr(L, Rs, K):
    for k, i in enumerate(L[:K], 1):
        if i in Rs: return 1 / k
    return 0.0
for m, LL in [('A', LA), ('B', LB)]:
    v = [rr(LL[u], rel(u), 10) for u in USERS]
    print(m, [round(x, 4) for x in v],
          'MRR@10 =', round(sum(v) / len(v), 4))
```

ผลลัพธ์ที่ได้

```
A [1.0, 1.0, 0.5, 0.3333, 0.1, 0.2, 0.1429, 1.0] MRR@10 = 0.5345
B [0.1667, 0.25, 0.1667, 0.125, 0.125, 0.1429, 0.25, 0.2] MRR@10 = 0.1783
```

2.3.2 ค่าเฉลี่ยความแม่นยำและค่าเฉลี่ยของค่าเฉลี่ยความแม่นยำ (AP@K และ MAP@K)

$$AP@K(u) = \frac{1}{min(K,|\mathcal{R}(u)|)} \sum_{i=1}^{K} Precision@i(u) \cdot rel_u((i)) \quad (2.9)$$

$$MAP@K = \frac{1}{|\mathcal{U}|} \sum_{u \in \mathcal{U}} AP@K(u) \quad (2.10)$$

AP@K(u) ให้รางวัลทุกครั้งที่พบรายการที่เกี่ยวข้อง โดยคำนวณ Precision ณ ตำแหน่งนั้นแล้วนำมาเฉลี่ย คำตอบที่ถูกในอันดับต้นจึงมีอิทธิพลมากกว่าอันดับท้าย และต่างจาก RR ตรงที่ AP ใช้ข้อมูลจากรายการที่เกี่ยวข้องทุกชิ้นภายใน Top-K

ตัวอย่างการคำนวณ 2.3 การคำนวณ AP@10 ของผู้ใช้ u1 ทีละตำแหน่ง และ MAP@10 ของผู้ใช้ทั้งแปดคน

ที่มาของข้อมูล

- (ก) ลำดับรายการของแบบจำลอง A และ B ใช้แถว “แบบจำลอง A” และ “แบบจำลอง B” ของตารางที่ 2.2 (ผลจากโค้ดประกอบ 2.3)
- (ข) $\mathrm{rel}(i) = 1$ เมื่อรายการที่อันดับ i อยู่ใน $\mathcal{R}$(u1) = {i1, i2, i3} ซึ่งได้จากแถว u1 ของตาราง MM-2
- (ค) ตัวส่วนของสมการ (2.9) คือ $\min(K, |\mathcal{R}(u)|) = \min(10,3) = 3$

การคำนวณ AP@10 ของผู้ใช้ u1 ทีละตำแหน่ง (นำไปเฉลี่ยเฉพาะตำแหน่งที่ rel = 1)

ตำแหน่ง i	A: รายการ	rel	A: Precision@i	B: รายการ	rel	B: Precision@i
1	i3	1	1 / 1 = 1.0000	i11	0	—
2	i1	1	2 / 2 = 1.0000	i6	0	—
3	i2	1	3 / 3 = 1.0000	i5	0	—
4	i8	0	—	i4	0	—
5	i10	0	—	i12	0	—
6	i11	0	—	i2	1	1 / 6 = 0.1667
7	i5	0	—	i3	1	2 / 7 = 0.2857
8	i7	0	—	i8	0	—
9	i12	0	—	i10	0	—
10	i4	0	—	i1	1	3 / 10 = 0.3000

ขั้นที่ 1 แทนค่าลงในสมการ (2.9) สำหรับผู้ใช้ u1

$$\text{AP@10}_A(u_1) = \frac{1.0000 + 1.0000 + 1.0000}{3} = \frac{3.0000}{3} = 1.0000$$

$$\text{AP@10}_B(u_1) = \frac{\frac{1}{6} + \frac{2}{7} + \frac{3}{10}}{3} = \frac{0.1667 + 0.2857 + 0.3000}{3} = \frac{0.7524}{3} = 0.2508$$

แบบจำลอง A ได้ค่าสูงสุดที่เป็นไปได้ เพราะเรื่องที่ถูกต้องครองสามอันดับแรกพอดี ส่วนแบบจำลอง B ได้เพียง 0.2508 ทั้งที่มีรายการที่แนะนำถูกต้องจำนวนเท่ากัน ต่างกันประมาณ 3.99 เท่า

ขั้นที่ 2 ทำซ้ำกับผู้ใช้ทุกคน แล้วเฉลี่ยตามสมการ (2.10)

ผู้ใช้	$\lvert\mathcal{R}(u)\rvert$	การแทนค่า AP@10 (A)	AP (A)	การแทนค่า AP@10 (B)	AP (B)
u1	3	(1/1 + 2/2 + 3/3) / 3	1.0000	(1/6 + 2/7 + 3/10) / 3	0.2508
u2	3	(1/1 + 2/2 + 3/6) / 3	0.8333	(1/4 + 2/10) / 3	0.1500
u3	3	(1/2) / 3	0.1667	(1/6) / 3	0.0556
u4	3	(1/3 + 2/4) / 3	0.2778	(1/8) / 3	0.0417
u5	2	(1/10) / 2	0.0500	(1/8) / 2	0.0625
u6	2	(1/5 + 2/7) / 2	0.2429	(1/7) / 2	0.0714
u7	2	(1/7 + 2/9) / 2	0.1825	(1/4) / 2	0.1250
u8	2	(1/1 + 2/2) / 2	1.0000	(1/5 + 2/10) / 2	0.2000
รวม			**3.7532**		**0.9569**

$$\text{MAP@10}_A = \frac{3.7532}{8} = 0.4691$$

$$\text{MAP@10}_B = \frac{0.9569}{8} = 0.1196$$

ตีความการเปรียบเทียบ MAP@10 ของผู้ใช้ทั้งแปดคน

0.4691	VS	0.1196
MAP@10 แบบจำลอง A		MAP@10 แบบจำลอง B

- แบบจำลอง A มีค่า MAP@10 เท่ากับ 0.4691 สูงกว่าแบบจำลอง B ซึ่งมีค่าเท่ากับ 0.1196 อยู่ 0.3495 หรือประมาณ 3.9 เท่า แสดงว่าแบบจำลอง A ไม่เพียงพบรายการแรกเร็วกว่า แต่ยังวางรายการที่เกี่ยวข้อง “ทุกชิ้น” ไว้สูงกว่าโดยเฉลี่ย
- ช่องว่างของ MAP (3.9 เท่า) กว้างกว่าของ MRR (3.0 เท่า) เพราะ AP ลงโทษรายการที่ถูกต้องชิ้นที่สองและสามที่อยู่ลึก เช่น B ของ u2 พบเรื่องที่ถูกต้องชิ้นที่สองที่อันดับ 10 ได้ Precision@10 เพียง 2/10 ซึ่ง MRR มองไม่เห็นเลย
- AP ใช้ความเกี่ยวข้องแบบทวิภาคเท่านั้น หากต้องการแยก “ชอบมาก (5 ดาว)” ออกจาก “ชอบ (4 ดาว)” ต้องใช้ nDCG ที่รองรับความเกี่ยวข้องหลายระดับ

โค้ดประกอบ 2.6 AP@K และ MAP@K ตามสมการ (2.9)–(2.10)

```
def ap(L, Rs, K):
    hits, s = 0, 0.0
    for k, i in enumerate(L[:K], 1):
        if i in Rs:
            # Precision@k ณ จุดที่ rel = 1
            hits += 1; s += hits / k
    return s / min(K, len(Rs))
for m, LL in [('A', LA), ('B', LB)]:
    v = [ap(LL[u], rel(u), 10) for u in USERS]
    print(m, 'AP(u1) =', round(v[0], 4),
          'MAP@10 =', round(sum(v) / 8, 4))
```

ผลลัพธ์ที่ได้

```
A AP(u1) = 1.0 MAP@10 = 0.4691
B AP(u1) = 0.2508 MAP@10 = 0.1196
```

2.3.3 กำไรสะสมแบบลดทอนที่ปรับมาตรฐาน (nDCG@K)

nDCG@K(u) เหมาะเมื่อทั้งตำแหน่งและระดับความเกี่ยวข้องมีความสำคัญ การคำนวณมีสามขั้น: หา DCG จากลิสต์จริง, หา IDCG จากลิสต์อุดมคติที่เรียงความเกี่ยวข้องจากมากไปน้อย และหาร DCG ด้วย IDCG เพื่อปรับค่าให้อยู่ระหว่าง 0 กับ 1

$$DCG@K(u) = \sum_{i=1}^{K} \frac{gain(rel_u(i))}{log_2(i+1)} \qquad (2.11)$$

$$\mathrm{IDCG@}K(u) = \max_{\pi} \mathrm{DCG@}K(u;\pi) \qquad (2.12)$$

โดยที่ π คือการเรียงลำดับรายการแบบใดก็ได้ ค่าสูงสุดเกิดขึ้นเมื่อเรียงรายการตามระดับความเกี่ยวข้องจากมากไปน้อย จึงเรียกว่า **การเรียงลำดับอุดมคติ** และ IDCG@K(u) คือค่า DCG@K(u) ของการเรียงลำดับนั้น

$$nDCG@K(u) = \frac{DCG@K(u)}{IDCG@K(u)} \qquad (2.13)$$

ในการคำนวณ nDCG การหารด้วย IDCG คือหัวใจของคำว่า “ทำให้เป็นบรรทัดฐาน” (Normalized) ผลคือค่า nDCG อยู่ในช่วง 0 ถึง 1 เสมอ และเปรียบเทียบข้ามผู้ใช้ที่มีจำนวนรายการที่ชอบจำนวนไม่เท่ากันได้

- **ฟังก์ชันผลได้** เป็นฟังก์ชันกำหนดว่า “ระดับความเกี่ยวข้องแต่ละระดับมีคุณค่ามากเพียงใด”
  - **ผลได้เชิงเส้น** $gain_{\text{linear}}(rel) = rel$

    ตัวอย่างเช่น หากระดับความเกี่ยวข้องเป็น 0–5 จะได้ผลได้ดังนี้

ระดับความเกี่ยวข้อง	ผลได้เชิงเส้น
0	0
1	1
2	2
3	3
4	4
5	5

    ผลต่างระหว่างระดับติดกันเท่ากับ 1 เสมอ จึงถือว่าการเพิ่มจากระดับ 1 เป็น 2 มีคุณค่าเพิ่มขึ้นเท่ากับการเพิ่มจากระดับ 4 เป็น 5

  - **ผลได้แบบเลขชี้กำลัง** $gain_{\text{exp}}(rel) = 2^{rel} - 1$

ระดับความเกี่ยวข้อง	การแทนค่า	ผลได้แบบเลขชี้กำลัง
0	$2^0 - 1$	0
1	$2^1 - 1$	1
2	$2^2 - 1$	3
3	$2^3 - 1$	7
4	$2^4 - 1$	15
5	$2^5 - 1$	31

    ฟังก์ชันนี้ให้น้ำหนักกับรายการที่มีความเกี่ยวข้องสูงมากเป็นพิเศษ เช่น รายการระดับ 5 มีผลได้เท่ากับ 31 ขณะที่ผลได้เชิงเส้นมีค่าเพียง 5

- **ความเกี่ยวข้องเป็นทวิภาค**

หากใช้ความเกี่ยวข้องเพียงสองค่า คือ 0 หมายถึง “ไม่เกี่ยวข้อง” และ 1 หมายถึง “เกี่ยวข้อง” ฟังก์ชันทั้งสองจะให้ผลเหมือนกัน เพราะ $2^0 - 1 = 0$ และ $2^1 - 1 = 1$ ดังนั้น การเลือกฟังก์ชันผลได้จะมีผล

อย่างชัดเจนเมื่อข้อมูลความเกี่ยวข้องมีหลายระดับหรือไม่เป็นทวิภาพ เช่น 0–5 ดาว (0 หมายถึง ไม่เกี่ยวข้องเลย, 5 หมายถึง เกี่ยวข้องมากที่สุด)

ตัวอย่างที่การเลือกฟังก์ชันทำให้ผู้ชนะเปลี่ยน

สมมติพิจารณา 2 อันดับแรก และใช้ส่วนลดมาตรฐาน

$$d(i) = 1/\log_2(i+1)$$

จะได้ $d(1) = 1$ และ $d(2) \approx 0.631$ โดยกำหนดให้

- แบบจำลองที่ 1 จัดอันดับระดับความเกี่ยวข้องเป็น [5,0]
- แบบจำลองที่ 2 จัดอันดับระดับความเกี่ยวข้องเป็น [4,4]
- DCG@2 จากฟังก์ชันผลได้เชิงเส้น
  - แบบจำลองที่ 1 DCG@2 = 5(1)+ 0(0.631) =5
  - แบบจำลองที่ 2 DCG@2 = 4(1)+4(0.631)=6.524
- DCG@2 จากฟังก์ชันผลได้แบบเลขชี้กำลัง
  - แบบจำลองที่ 1 DCG@2 = $(2^5-1)(1) + (2^0-1)(0.631)$ =31
  - แบบจำลองที่ 2 DCG@2 = $(2^4-1)(1) + (2^4-1)(0.631))$ = 15+15(0.631)=24.465

จากกรณีกำหนดค่าความเกี่ยวข้องหลายระดับ ผลลัพธ์ DCG@K จากฟังก์ชันผลได้เชิงเส้น จะให้คำตอบว่าแบบจำลองที่ 2 ดีกว่า ในขณะผลลัพธ์ DCG@K จากที่ฟังก์ชันผลได้แบบเลขชี้กำลังเส้น จะให้คำตอบว่าแบบจำลองที่ 1 กลับเป็นผู้ชนะ เพราะการนำรายการระดับ 5 ขึ้นสู่อันดับแรกได้รับผลตอบแทนสูงมาก

- **ฟังก์ชันส่วนลด** แสดงสมมติฐานว่า ผู้ใช้ให้ความสนใจรายการในอันดับต้นมากกว่ารายการในอันดับท้าย ฟังก์ชันมาตรฐานที่ใช้กับ DCG คือ $d(i) = 1/log_2(i+1)$ ตัวอย่างค่าในแต่ละอันดับมีดังนี้

อันดับ	$1/log_2(i+1)$
1	1.000
2	0.631
3	0.500
4	0.431
5	0.387
10	0.289

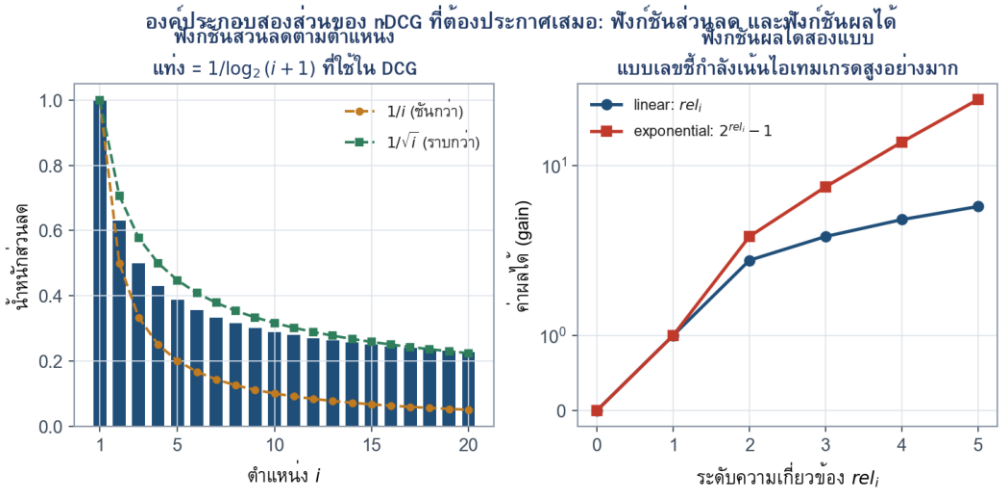
รายการที่เกี่ยวข้องในอันดับที่ 1 จึงได้รับผลได้เต็มจำนวน ส่วนรายการที่เกี่ยวข้องเท่ากันในอันดับที่ 10 จะเหลือน้ำหนักประมาณ 28.9%

อันดับ	$1/i$	$1/log_2(i+1)$	$1/\sqrt{i}$
1	1.000	1.000	1.000
2	0.500	0.631	0.707
3	0.333	0.500	0.577
10	0.100	0.289	0.316

หากใช้ $1/i$ รายการอันดับท้ายจะถูกลดน้ำหนักรุนแรงกว่า ทำให้ตัวชี้วัดให้ความสำคัญกับอันดับต้นมาก และมีพฤติกรรมใกล้เคียงตัวชี้วัดอย่าง MRR มากขึ้น อย่างไรก็ตาม ไม่ควรกล่าวว่าเทียบเท่า MRR เพราะ MRR พิจารณาเฉพาะตำแหน่งของรายการเกี่ยวข้องชิ้นแรก ขณะที่ DCG ยังรวมผลได้จากรายการเกี่ยวข้องรายการอื่นด้วย

นอกจากนี้ พบว่าฟังก์ชันส่วนลดแบบลอการิทึม $1/log_2(i+1)$ เป็นข้อตกลงมาตรฐานที่สะท้อนสมมติฐานว่าความสนใจของผู้ใช้ลดลงตามอันดับ ซึ่งสอดคล้องกับพฤติกรรมการกวาด

สายตาของผู้ใช้จริงมากที่สุด แต่รูปแบบการลดลงที่เหมาะสมอาจแตกต่างกันตามส่วนต่อประสานงาน และพฤติกรรมผู้ใช้



ภาพที่ 2.3 องค์ประกอบสองส่วนของ nDCG ที่ต้องประกาศเสมอ คือฟังก์ชันส่วนลดตามตำแหน่งและฟังก์ชันผลได้

ตัวอย่างการคำนวณ 2.4 การคำนวณ nDCG@10 ของผู้ใช้ u1 ทีละขั้นตอน และค่าเฉลี่ยของผู้ใช้ทั้งแปดคน

ที่มาของข้อมูล

- (ก) ลำดับรายการจากตารางที่ 2.2 และ $rel_i \in \{0, 1\}$ จาก $\mathcal{R}(u1) = \{i1, i2, i3\}$ ตามแถว u1 ของตาราง MM-2
- (ข) ใช้ผลได้แบบทวิภาค gain(rel) = rel และส่วนลด $1/\log_2(i+1)$ ตามสมการ (2.11) ค่าส่วนลดแต่ละอันดับคำนวณจากตารางส่วนลดข้างต้น

การคำนวณ DCG@10 ของผู้ใช้ u1 ทีละตำแหน่ง

ตำแหน่ง i	ส่วนลด $1/\log_2(i+1)$	A: รายการ	rel	A: ส่วนเพิ่ม	B: รายการ	rel	B: ส่วนเพิ่ม
1	$1/\log_2 2 = 1.0000$	i3	1	1.0000	i11	0	0.0000
2	$1/\log_2 3 = 0.6309$	i1	1	0.6309	i6	0	0.0000
3	$1/\log_2 4 = 0.5000$	i2	1	0.5000	i5	0	0.0000
4	$1/\log_2 5 = 0.4307$	i8	0	0.0000	i4	0	0.0000
5	$1/\log_2 6 = 0.3869$	i10	0	0.0000	i12	0	0.0000
6	$1/\log_2 7 = 0.3562$	i11	0	0.0000	i2	1	0.3562
7	$1/\log_2 8 = 0.3333$	i5	0	0.0000	i3	1	0.3333
8	$1/\log_2 9 = 0.3155$	i7	0	0.0000	i8	0	0.0000
9	$1/\log_2 10 = 0.3010$	i12	0	0.0000	i10	0	0.0000
10	$1/\log_2 11 = 0.2891$	i4	0	0.0000	i1	1	0.2891

ตำแหน่ง i	ส่วนลด $1/\log_2(i+1)$	A: รายการ	rel	A: ส่วนเพิ่ม	B: รายการ	rel	B: ส่วนเพิ่ม
DCG@10				2.1309			0.9786

ขั้นที่ 1 คำนวณ DCG ของทั้งสองแบบจำลอง

ความเกี่ยวข้องเป็นทวิภาค ผลได้เชิงเส้นและผลได้แบบเลขชี้กำลังจึงให้ค่าเท่ากัน รายการที่ถูกต้องให้ผลได้ 1 และรายการที่ไม่ถูกต้องให้ผลได้ 0

$$\text{DCG@10}_A = \frac{1}{\log_2 2} + \frac{1}{\log_2 3} + \frac{1}{\log_2 4} = 1.0000 + 0.6309 + 0.5000 = 2.1309$$

$$\text{DCG@10}_B = \frac{1}{\log_2 7} + \frac{1}{\log_2 8} + \frac{1}{\log_2 11} = 0.3562 + 0.3333 + 0.2891 = 0.9786$$

ขั้นที่ 2 คำนวณ IDCG จากการเรียงอุดมคติ

การเรียงที่ดีที่สุดเท่าที่เป็นไปได้คือวางเรื่องที่ถูกต้องทั้งสามเรื่องไว้ที่ตำแหน่ง 1, 2 และ 3 ค่านี้ขึ้นกับจำนวนรายการที่ผู้ใช้ชอบเท่านั้น จึงเท่ากันทั้งสองแบบจำลอง

$$\text{IDCG@10}(u_1) = 1.0000 + 0.6309 + 0.5000 = 2.1309$$

ขั้นที่ 3 หารเพื่อทำให้เป็นบรรทัดฐานตามสมการ (2.13)

$$\text{nDCG@10}_A = \frac{2.1309}{2.1309} = 1.0000$$

$$\text{nDCG@10}_B = \frac{0.9786}{2.1309} = 0.4592$$

แบบจำลอง A วางรายการที่ถูกต้องตรงกับลำดับอุดมคติพอดีจึงได้ 1.0000 ส่วน B ได้ 0.4592 ต่างกัน 2.18 เท่า

ขั้นที่ 4 ทำซ้ำกับผู้ใช้ทุกคน (ผู้ใช้ที่ชอบสองเรื่องมี IDCG = 1 + 0.6309 = 1.6309)

ผู้ใช้	IDCG@10	DCG@10 (A)	nDCG@10 (A)	DCG@10 (B)	nDCG@10 (B)
u1	2.1309	2.1309	1.0000	0.9786	0.4592
u2	2.1309	1.9871	0.9325	0.7197	0.3378
u3	2.1309	0.6309	0.2961	0.3562	0.1672
u4	2.1309	0.9307	0.4367	0.3155	0.1480
u5	1.6309	0.2891	0.1772	0.3155	0.1934
u6	1.6309	0.7202	0.4416	0.3333	0.2044
u7	1.6309	0.6344	0.3890	0.4307	0.2641
u8	1.6309	1.6309	1.0000	0.6759	0.4144
เฉลี่ย			**0.5841**		**0.2736**

ตีความการเปรียบเทียบ nDCG@10 ของผู้ใช้ทั้งแปดคน

0.5841	VS	0.2736
nDCG@10 แบบจำลอง A		nDCG@10 แบบจำลอง B

- แบบจำลอง A มีค่า nDCG@10 เท่ากับ 0.5841 สูงกว่าแบบจำลอง B ซึ่งมีค่าเท่ากับ 0.2736 อยู่ 0.3106 หรือประมาณ 2.14 เท่า หมายความว่าคุณภาพการจัดอันดับของ A อยู่ที่ประมาณร้อยละ 58.4 ของการจัดอันดับอุดมคติ ขณะที่ B อยู่ที่ร้อยละ 27.4
- nDCG แยกความต่างได้นุ่มนวลกว่า MRR และ MAP เพราะส่วนลดแบบลอการิทึมลดลงช้า รายการที่ถูกต้องในอันดับ 10 ยังได้น้ำหนัก 0.2891 ไม่ใช่ 0.1 เหมือน 1/i ช่องว่างระหว่างสองแบบจำลองจึงแคบที่สุดในบรรดาตัวชี้วัดที่ไวต่อตำแหน่ง
- หากใช้คะแนนดาวเป็นความเกี่ยวข้องหลายระดับ (เช่น rel = r − 3 สำหรับ r ≥ 4) ค่า nDCG จะเปลี่ยน และการเลือกผลได้เชิงเส้นหรือเลขชี้กำลังจะเริ่มมีผล จึงต้องประกาศฟังก์ชันผลได้ทุกครั้ง

โค้ดประกอบ 2.7 DCG, IDCG และ nDCG@K ตามสมการ (2.11)–(2.13)

```
def dcg(L, Rs, K):
    return sum(1 / math.log2(k + 1)
               for k, i in enumerate(L[:K], 1) if i in Rs)
def idcg(Rs, K):
    m = min(K, len(Rs))
    return sum(1 / math.log2(k + 1) for k in range(1, m + 1))
def ndcg(L, Rs, K): return dcg(L, Rs, K) / idcg(Rs, K)
for m, LL in [('A', LA), ('B', LB)]:
    v = [ndcg(LL[u], rel(u), 10) for u in USERS]
    print(m, 'DCG(u1) =', round(dcg(LL['u1'], rel('u1'), 10), 4),
          'nDCG(u1) =', round(v[0], 4),
          'mean =', round(sum(v) / 8, 4))
```

ผลลัพธ์ที่ได้

```
A DCG(u1) = 2.1309 nDCG(u1) = 1.0 mean = 0.5841
B DCG(u1) = 0.9786 nDCG(u1) = 0.4592 mean = 0.2736
```

กรอบเจาะลึก ผลได้เชิงเส้นกับผลได้แบบเลขชี้กำลัง และการเลือกฟังก์ชันส่วนลด

ประโยคว่า “เราใช้ nDCG@10” ยังไม่เพียงพอที่จะทำซ้ำผลได้ เพราะ nDCG มีตัวเลือกที่ต้องประกาศอีกสองข้อ

ข้อที่หนึ่ง ฟังก์ชันผลได้ (Gain Function)

$$\text{แบบเชิงเส้น: } gain(rel) = rel \quad \text{แบบเลขชี้กำลัง: } gain(rel) = 2^{rel} - 1 \qquad (2.14)$$

เมื่อความเกี่ยวข้องเป็นทวิภาค (0 หรือ 1) สองแบบให้ผลเท่ากันพอดี เพราะ $2^1 - 1 = 1$ และ $2^0 - 1 = 0$ แต่เมื่อความเกี่ยวข้องมีหลายระดับ เช่น 0 ถึง 5 แบบเลขชี้กำลังจะให้น้ำหนักระดับสูงมากกว่าอย่างชัดเจน ดังภาพที่ 2.3 ด้านขวา รายการระดับ 5 มีผลได้ 31 เทียบกับ 5 ของแบบเชิงเส้น การเลือกแบบใดจึงเปลี่ยนผู้ชนะได้เมื่อแบบจำลองสองตัวเก่งกับความเกี่ยวข้องคนละระดับ

ข้อที่สอง ฟังก์ชันส่วนลด (Discount Function)

มาตรฐานที่ใช้กันคือ $1/log_2(i+1)$ ซึ่งลดลงช้ากว่า $1/i$ และเร็วกว่า $1/\sqrt{i}$ ดังภาพที่ 2.3 ด้านซ้าย การเลือก $1/\log_2(i+1)$ มีเหตุผลเชิงประจักษ์ คือสอดคล้องกับพฤติกรรมการกวาดสายตาของผู้ใช้จริงมากที่สุด หากใช้ $1/i$ จะกดคะแนนให้ต่ำลง (PENALIZE) ตำแหน่งท้ายรุนแรงเกินไป จนแทบเทียบเท่า MRR

ข้อที่สาม วิธีจัดการผู้ใช้ที่ไม่มีรายการที่ถูกต้องเลย

เมื่อ IDCG = 0 นิยาม nDCG จะเป็นการหารด้วยศูนย์ ทางเลือกที่ใช้กันมีสองทาง คือกำหนดให้ nDCG = 0 หรือคัดผู้ใช้คนนั้นออกจากการเฉลี่ย สองทางนี้ให้ตัวเลขสุดท้ายต่างกันได้มาก ในตำราเล่มนี้ เลือกวิธีคัดออก และรายงานจำนวนผู้ใช้ที่ประเมินได้ควบคู่เสมอ

ข้อตกลงที่ต้องระบุสำหรับ AP MAP และ nDCG

AP@K มีนิยามตัวส่วนที่พบได้มากกว่าหนึ่งแบบ บางงานหารด้วย $|\mathcal{R}_u|$ และบางงานหารด้วย $\min(|\mathcal{R}_u|, K)$ นิยามแรกลงโทษเมื่อมีคำตอบจริงมากกว่า K ซึ่งระบบไม่มีทางเรียกคืนครบในหน้าจอเดียว ส่วนนิยามหลังวัดคุณภาพภายในขอบเขต K โดยตรง ทั้งสองแบบใช้ได้ แต่ห้ามเปรียบเทียบตัวเลขข้ามงานโดยไม่ตรวจนิยามสูตร

สำหรับ nDCG ต้องระบุฟังก์ชัน Gain และ Discount ด้วย หาก relevance เป็นแบบทวิภาค Gain มักเป็น 0 หรือ 1 แต่ถ้าใช้คะแนนหลายระดับ อาจใช้ rel หรือ 2^rel - 1 ส่วน Discount มักเป็น $\log_2(\text{rank} + 1)$ เมื่อผู้ใช้ไม่มีรายการเกี่ยวข้อง IDCG จะเป็นศูนย์ จึงต้องใช้กติกาการตัดออกหรือกำหนดศูนย์แบบเดียวกันตลอดทั้งการทดลอง

2.4 พื้นที่ใต้เส้นโค้ง ROC (AUC)

AUC

ตีความได้ว่าเป็นความน่าจะเป็นที่ระบบให้คะแนนรายการที่เกี่ยวข้องสูงกว่ารายการที่ไม่เกี่ยวข้องเมื่อสุ่มมาหนึ่งคู่ ตัวชี้วัดนี้พิจารณาการจัดอันดับทั้งเซตผู้สมัครและไม่ต้องกำหนด K แต่ต้องประกาศเซตผู้สมัครให้ชัด เพราะการเปลี่ยนรายการที่นำมาเปรียบเทียบเปลี่ยนค่า AUC ได้

นิยาม 2.1 พื้นที่ใต้เส้นโค้ง ROC (Area Under the ROC Curve)

ความน่าจะเป็นที่แบบจำลองจะให้คะแนนรายการที่ผู้ใช้ชอบ สูงกว่า รายการที่ผู้ใช้ไม่ชอบ เมื่อสุ่มนำมาแนะนำอย่างละหนึ่งรายการ

$$AUC = \frac{\text{จำนวนคู่ที่เรียงถูก}}{(|\mathcal{R}_u| \times |\mathcal{N}_u|)} \qquad (2.15)$$

โดย $|\mathcal{R}_u|$ คือจำนวนรายการที่เกี่ยวข้อง และ $|\mathcal{N}_u|$ คือจำนวนรายการที่ไม่เกี่ยวข้อง ดังนั้นหากค่า AUC = 0.5 หมายถึงเดาสุ่ม ค่า 1.0 หมายถึงเรียงถูกทุกคู่ และค่าต่ำกว่า 0.5 หมายถึงแบบจำลองเรียงกลับด้านกับความจริงอย่างเป็นระบบ

ตัวอย่างการคำนวณ 2.5 การคำนวณ AUC ด้วยการนับคู่ทีละคู่ บนรายการของผู้ใช้ u1

ที่มาของข้อมูล

- (ก) ลำดับรายการทั้ง 12 อันดับของแบบจำลอง A และ B มาจากตารางที่ 2.2 (AUC ไม่ใช้ค่าตัด K จึงต้องใช้ครบทุกอันดับ รวมถึงอันดับ 11–12)
- (ข) รายการที่เกี่ยวข้อง $\mathcal{R}$(u1) = {i1, i2, i3} จากแถว u1 ของตาราง MM-2 ดังนั้น $|\mathcal{R}_u| = 3$ และรายการที่ไม่เกี่ยวข้องคืออีก 9 เรื่อง $|\mathcal{N}_u| = 12 - 3 = 9$ จำนวนคู่ทั้งหมดจึงเท่ากับ $3 \times 9 = 27$ คู่
- (ค) ไม่มีคะแนนเสมอระหว่างรายการบวกกับรายการลบในลำดับทั้งสอง จึงไม่ต้องนับคู่ใดเป็น 0.5

แบบจำลอง B (ผู้ใช้ u1) จัดอันดับรายการทั้ง 12 รายการ

อันดับ	1	2	3	4	5	6	7	8	9	10	11	12
แบบจำลอง B	i11	i6	i5	i4	i12	i2 ✓	i3 ✓	i8	i10	i1 ✓	i7	i9

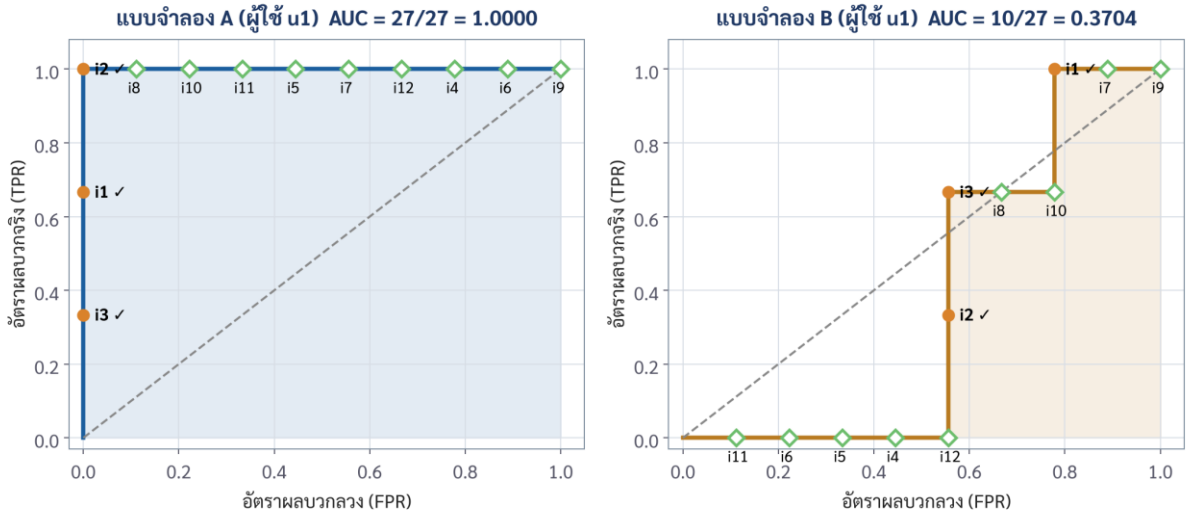
ขั้นที่ 1 นับจำนวนรายการที่ไม่เกี่ยวข้องซึ่งอยู่ **ใต้** รายการที่เกี่ยวข้องแต่ละรายการ (คู่ที่เรียงถูก) สำหรับแบบจำลอง B

รายการที่เกี่ยวข้อง	ตำแหน่ง	จำนวนรายการไม่เกี่ยวข้องที่อยู่ใต้ลงไป
i2	6	4 ได้แก่ {i8, i10, i7, i9}
i3	7	4 ได้แก่ {i8, i10, i7, i9}
i1	10	2 ได้แก่ {i7, i9}
รวมคู่ที่เรียงถูก		**10**

$$\mathrm{AUC}_B(u_1) = \frac{4+4+2}{3 \times 9} = \frac{10}{27} = 0.3704$$

ขั้นที่ 2 ทำซ้ำกับแบบจำลอง A ซึ่งวาง i3, i1, i2 ไว้สามอันดับแรก รายการที่ไม่เกี่ยวข้องทั้ง 9 เรื่องจึงอยู่ใต้รายการที่เกี่ยวข้องทุกรายการ ได้คู่ที่เรียงถูก $9+9+9 = 27$ คู่

$$\mathrm{AUC}_A(u_1) = \frac{9+9+9}{27} = \frac{27}{27} = 1.0000$$



ภาพที่ 2.4 เส้นโค้ง ROC ของผู้ใช้ u1 ที่สร้างจากการจัดอันดับรายการทั้ง 12 รายการ ของแบบจำลอง A (ซ้าย) และ B (ขวา)

ภาพที่ 2.4 สร้างเส้นโค้งโดยไล่ลำดับจากอันดับ 1 ลงไป เมื่อพบรายการที่เกี่ยวข้อง (จุดสีส้ม) เส้นจะขึ้นในแนวตั้ง 1/3 หน่วย และเมื่อพบรายการที่ไม่เกี่ยวข้อง (จุดสีเขียว) เส้นจะไปทางขวา 1/9 หน่วย พื้นที่ใต้เส้นจึงเท่ากับสัดส่วนคู่ที่เรียงถูกพอดี เส้นของแบบจำลอง A ขึ้นถึง 1 ก่อนเลื่อนไปทางขวาเลย จึงได้พื้นที่เต็ม ส่วนแบบจำลอง B ต้องเดินไปทางขวาห้าช่อง (i11, i6, i5, i4, i12) ก่อนจะพบรายการที่เกี่ยวข้องชิ้นแรก เส้นจึงอยู่ใต้เส้นทแยงมุมเกือบตลอด

ตีความ

AUC ของแบบจำลอง B = 0.3704 หมายความว่า เมื่อสุ่มรายการที่ u1 ชอบหนึ่งเรื่องและรายการที่ไม่เกี่ยวข้องหนึ่งเรื่อง แบบจำลอง B มีโอกาสเพียงประมาณ 37.04% ที่จะจัดเรื่องที่ชอบไว้สูงกว่า ซึ่ง **ต่ำกว่า 0.5** ของการเดาสุ่ม แปลว่าสำหรับผู้ใช้คนนี้ การจัดอันดับตามความนิยมเรียงกลับด้านกับรสนิยมอย่างเป็นระบบ

AUC ไม่ได้หมายความว่าแบบจำลองมี “ความแม่นยำ” ตามค่านั้น เพราะ AUC วัดคุณภาพการเรียงลำดับคู่ ไม่ใช่สัดส่วนการทำนายถูกทั้งหมด

สำหรับระบบผู้แนะนำ ค่า AUC ควรรายงานร่วมกับตัวชี้วัด Top-K เช่น Precision@K, Recall@K และ nDCG@K เพราะ AUC วัดคุณภาพทั่วทั้งรายการจัดอันดับ แต่อาจไม่สะท้อนคุณภาพของรายการไม่กี่อันดับแรกที่ผู้ใช้มองเห็นจริงเสมอไป

ตีความการเปรียบเทียบ AUC ของผู้ใช้ u1 และค่าเฉลี่ยผู้ใช้ทั้งแปดคน

1.0000 (0.5817)	VS	0.3704 (0.2549)
AUC แบบจำลอง A (เฉลี่ย 8 คน)		AUC แบบจำลอง B (เฉลี่ย 8 คน)

- สำหรับ u1 แบบจำลอง A ได้ AUC = 1.0000 สูงกว่าแบบจำลอง B ซึ่งได้ 0.3704 อยู่ 0.6296 เมื่อเฉลี่ยผู้ใช้ทั้งแปดคน (โค้ดประกอบ 2.8) A ได้ 0.5817 และ B ได้ 0.2549 แบบจำลอง A จึงเรียงคู่ถูกมากกว่าประมาณ 2.28 เท่า
- ค่าเฉลี่ยของ A (0.5817) สูงกว่าการเดาสุ่ม (0.5) เพียงเล็กน้อย เพราะในโปรโตคอลนี้รายการที่ยังไม่มีคะแนนทุกเรื่องถูกนับเป็นรายการลบ ซึ่งหลายเรื่องอาจเป็นเรื่องที่ผู้ใช้ชอบแต่ยังไม่เคยดู AUC จึงไวต่อผลลบเทียมมากกว่าตัวชี้วัดแบบ Top-K
- AUC ให้น้ำหนักทุกคู่เท่ากัน การเลื่อนเรื่องที่ชอบจากอันดับ 12 ขึ้นมาอันดับ 11 เพิ่ม AUC ได้เท่ากับการเลื่อนจากอันดับ 2 ขึ้นมาอันดับ 1 จึงไม่ควรใช้ AUC เป็นตัวชี้วัดหลักของหน้าจอที่แสดงเพียงไม่กี่อันดับ

โค้ดประกอบ 2.8 AUC ด้วยการนับคู่ตามสมการ (2.15)

```
def auc(L, Rs):
    pos = [k for k, i in enumerate(L) if i in Rs]
    neg = [k for k, i in enumerate(L) if i not in Rs]
    # บวกอยู่เหนือลบ
    good = sum(1 for p in pos for n in neg if p < n)
    return good / (len(pos) * len(neg))
for m, LL in [('A', LA), ('B', LB)]:
    v = [auc(LL[u], rel(u)) for u in USERS]
    print(m, 'AUC(u1) =', round(v[0], 4),
          'mean =', round(sum(v) / 8, 4))
```

ผลลัพธ์ที่ได้

```
A AUC(u1) = 1.0 mean = 0.5817
B AUC(u1) = 0.3704 mean = 0.2549
```

ข้อควรระวัง ข้อจำกัดของ AUC ที่ต้องรู้ก่อนใช้เป็นตัวชี้วัดหลัก

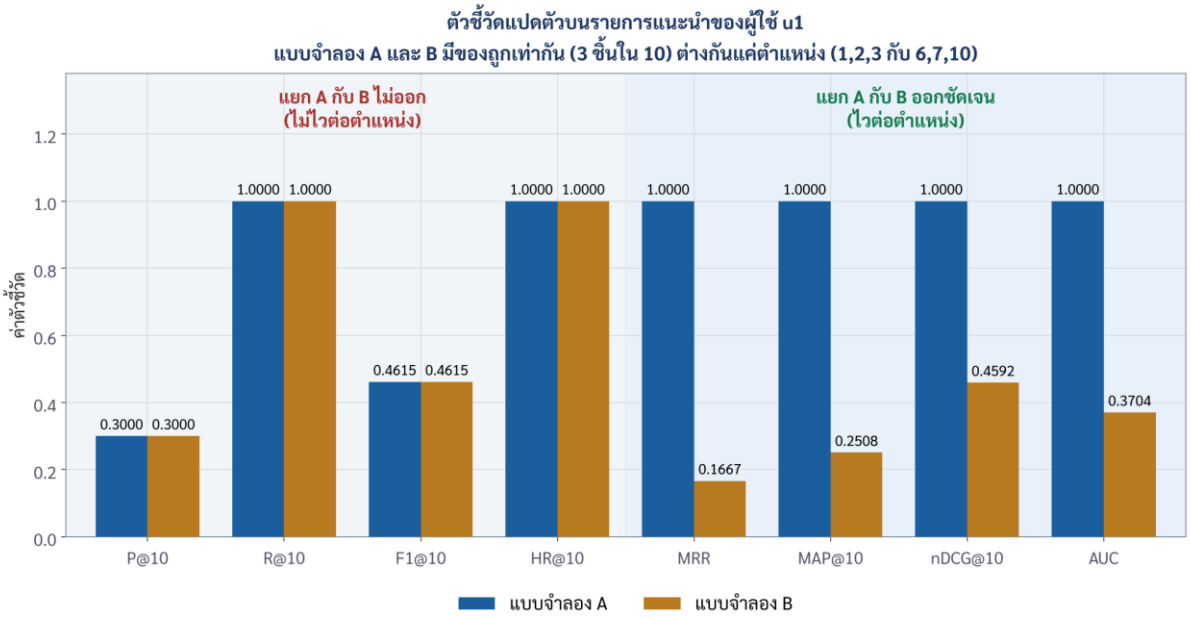
AUC ให้น้ำหนักทุกคู่เท่ากันหมด การเลื่อนรายการที่ถูกต้องจากอันดับ 400 ขึ้นมาอันดับ 300 เพิ่ม AUC ได้เท่ากับ การเลื่อนจากอันดับ 4 ขึ้นมาอันดับ 3 ทั้งที่การเลื่อนกรณีหลังมีค่าต่อผู้ใช้จริงมากกว่ามหาศาล เพราะผู้ใช้แทบไม่มีทางเลื่อนไปถึงอันดับ 300 เลย

ด้วยเหตุนี้ AUC จึงเหมาะเป็นตัวชี้วัดวินิจฉัยระหว่างการพัฒนา เพื่อดูว่าแบบจำลองเรียนรู้อะไรได้บ้าง แต่ไม่เหมาะเป็นตัวชี้วัดหลักของระบบที่แสดงผลเพียงสิบอันดับแรก ในกรณีนั้นต้องใช้ nDCG@10 แทน

2.4.1 สรุปเปรียบเทียบตัวชี้วัดทั้งแปดตัวบนข้อมูลชุดเดียวกัน

จากตัวอย่างของแบบจำลอง A และ B บนผู้ใช้ u1 ในตารางที่ 2.2 ซึ่งทั้งสองมีรายการที่ถูกต้องใน Top-10 สามชิ้นเท่ากัน

อันดับ	1	2	3	4	5	6	7	8	9	10
แบบจำลอง A	i3 ✓	i1 ✓	i2 ✓	i8	i10	i11	i5	i7	i12	i4
แบบจำลอง B	i11	i6	i5	i4	i12	i2 ✓	i3 ✓	i8	i10	i1 ✓



ภาพที่ 2.5 ตัวชี้วัดแปดตัวบนรายการแนะนำของผู้ใช้ u1 สี่ตัวแรกแยกแบบจำลองไม่ออก สี่ตัวหลังแยกออกชัดเจน

ตารางที่ 2.3 *ค่าตัวชี้วัดทั้งแปดของแบบจำลอง A และ B บนผู้ใช้ u1 (ตารางที่ 2.2) และค่าเฉลี่ยของผู้ใช้ทั้งแปดคน*

ตัวชี้วัด	u1: A	u1: B	อัตราส่วน A/B	แยกความต่างได้หรือไม่	เฉลี่ย 8 คน: A	เฉลี่ย 8 คน: B
Precision@10	0.3000	0.3000	1.00	แยกไม่ออก	0.2000	0.1500
Recall@10	1.0000	1.0000	1.00	แยกไม่ออก	0.8125	0.6042
F1@10	0.4615	0.4615	1.00	แยกไม่ออก	0.3189	0.2388
HR@10	1.0000	1.0000	1.00	แยกไม่ออก	1.0000	1.0000
MRR	1.0000	0.1667	6.00	แยกออก	0.5345	0.1783
MAP@10	1.0000	0.2508	3.99	แยกออก	0.4691	0.1196
nDCG@10	1.0000	0.4592	2.18	แยกออก	0.5841	0.2736
AUC	1.0000	0.3704	2.70	แยกออก	0.5817	0.2549

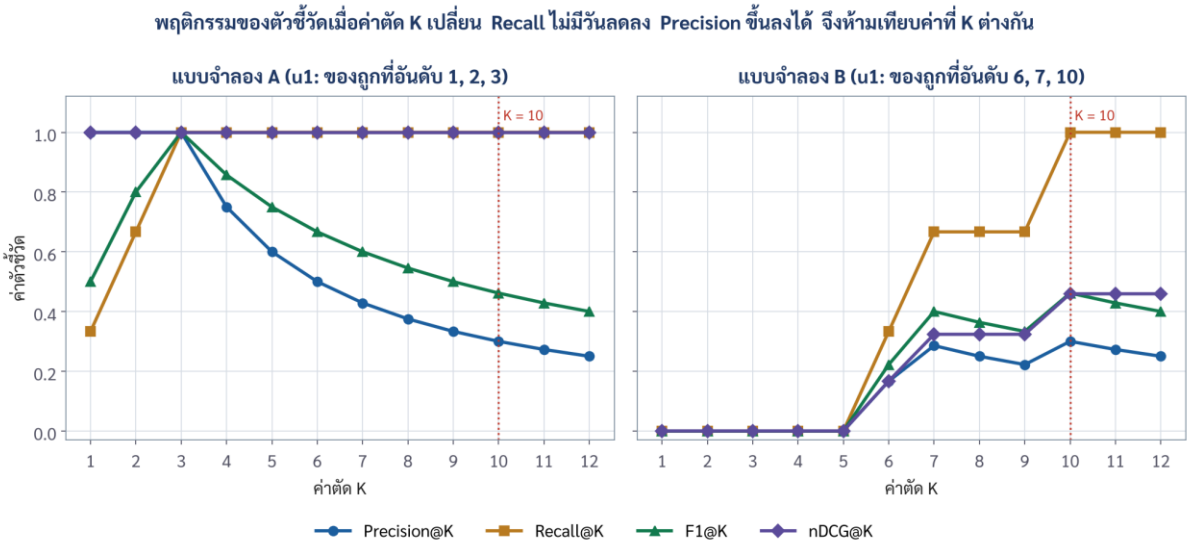
ประเด็นสำคัญ บทเรียนสำคัญสามข้อจากตารางที่ 2.3

ข้อที่หนึ่ง การเลือกตัวชี้วัดคือการเลือกข้อสรุป หากทีมหนึ่งรายงาน Precision@10 ของ u1 จะสรุปว่าแบบจำลองทั้งสองดีเท่ากัน หากอีกทีมรายงาน MRR จะสรุปว่าแบบจำลอง A ดีกว่าถึงหกเท่า ทั้งสองทีมคำนวณถูกต้องทุกหลัก แต่ให้คำตอบต่อผู้บริหารต่างกันโดยสิ้นเชิง นี่คือเหตุผลที่ต้องประกาศตัวชี้วัดหลักไว้ก่อนเห็นผล

ข้อที่สอง ขนาดของความต่างก็ขึ้นกับตัวชี้วัดเช่นกัน แม้ในกลุ่มที่แยกความต่างได้ทั้งสี่ตัว อัตราส่วน A/B ของ u1 ยังไล่ตั้งแต่ 2.18 เท่า (nDCG@10) ถึง 6.00 เท่า (MRR) การอ้างว่า “แบบจำลองของเราดีกว่าอย่างชัดเจน” จึงไม่มีความหมายหากไม่ระบุว่าวัดด้วยตัวชี้วัดใด

ข้อที่สาม ผู้ใช้คนเดียวไม่ใช่ทั้งระบบ เมื่อเฉลี่ยผู้ใช้ทั้งแปดคน Precision@10 และ Recall@10 เริ่มแยกได้ (0.2000 กับ 0.1500 และ 0.8125 กับ 0.6042) เพราะผู้ใช้บางคน เช่น u2 และ u4 มีเรื่องที่ชอบหลุดออกนอก Top-10 ของแบบจำลอง B ส่วน HR@10 ยังเท่ากันที่ 1.0000 เพราะทุกคนมีรายการที่ถูกต้องอย่างน้อยหนึ่งชิ้นใน 10 อันดับของคลังเพียง 12 เรื่อง

2.4.2 พฤติกรรมของตัวชี้วัดเมื่อค่าตัด K เปลี่ยน



ภาพที่ 2.6 พฤติกรรมของตัวชี้วัดสี่ตัวเมื่อค่าตัด K เปลี่ยนจาก 1 ถึง 12 บนผู้ใช้ u1 ของแบบจำลอง A และ B

ภาพที่ 2.6 แสดงข้อเท็จจริงเชิงโครงสร้างสามข้อ ซึ่งเป็นจริงเสมอสำหรับข้อมูลทุกชุด ไม่ใช่ความบังเอิญของตัวอย่างนี้

1) **Recall@K ไม่มีวันลดลงเมื่อ K เพิ่ม** เพราะตัวเศษเพิ่มได้แต่ไม่มีวันลด ส่วนตัวส่วนคงที่เท่ากับ $|\mathcal{R}_u|$ = 3 เสมอ ในแบบจำลอง B ค่าจึงขยับเป็นขั้นบันได 0 ⟶ 0.3333 ⟶ 0.6667 ⟶ 1.0000 ที่ K = 6, 7 และ 10 ซึ่งเป็นตำแหน่งที่พบ i2, i3 และ i1 พอดี
2) **Precision@K มีแนวโน้มลดลงเมื่อ K เพิ่ม แต่ไม่ได้ลดลงอย่างเอกภาพ** แบบจำลอง A ลดจาก 1.0000 ที่ K = 3 เหลือ 0.3000 ที่ K = 10 ส่วนแบบจำลอง B เป็นศูนย์ตลอดห้าอันดับแรก แล้วกระเพื่อมขึ้นเป็น 0.2857 ที่ K = 7 ลดลงเป็น 0.2222 ที่ K = 9 และขึ้นอีกเป็น 0.3000 ที่ K = 10 เมื่อพบรายการที่ถูกต้องพอดี

3) **nDCG@K เพิ่มขึ้นแบบไม่ลดลงและอิ่มตัว** แบบจำลอง A ได้ 1.0000 ตั้งแต่ K = 1 เพราะวางลำดับตรงกับอุดมคติ ส่วนแบบจำลอง B เพิ่มขึ้นเป็นขั้นที่ K = 6, 7 และ 10 แล้วคงที่ที่ 0.4592 เมื่อเลย K = 10 ไปแล้ว เพราะไม่มีรายการที่ถูกต้องเหลือให้เก็บอีก ข้อเท็จจริงสำคัญอีกข้อคือ ที่ K = 5 แบบจำลอง B ได้ศูนย์ทุกตัวชี้วัด ทั้งที่ที่ K = 10 ได้ Precision เท่ากับแบบจำลอง A การเลือก K จึงเปลี่ยนข้อสรุปได้ทั้งหมด

ข้อควรระวัง กฎที่ห้ามละเมิดโดยเด็ดขาด

ห้ามเปรียบเทียบค่าตัวชี้วัดที่ค่า K ต่างกัน การรายงานว่าแบบจำลองของเราได้ Recall@20 = 0.72 ในขณะที่งานก่อนหน้าได้ Recall@10 = 0.55 แล้วสรุปว่าดีกว่า เป็นการเปรียบเทียบที่ไม่มีความหมาย เพราะ Recall เพิ่มขึ้นเสมอเมื่อ K เพิ่ม แม้แบบจำลองจะแย่กว่าก็ตาม

การเปรียบเทียบที่ถูกต้องต้องใช้ค่า K เดียวกัน นิยามความเกี่ยวข้องเดียวกัน และเซตผู้สมัครเดียวกัน ครบทั้งสามข้อ หากขาดข้อใดข้อหนึ่ง ตัวเลขที่ได้เทียบกันไม่ได้

การตีความ AUC จากคู่รายการ

AUC

ในงานจัดอันดับตีความได้ว่าเป็นความน่าจะเป็นที่แบบจำลองให้คะแนนรายการที่เกี่ยวข้องสูงกว่ารายการที่ไม่เกี่ยวข้อง เมื่อสุ่มมาหนึ่งคู่ ในตัวอย่างการคำนวณ 2.5 มีรายการบวก 3 รายการและรายการลบ 9 รายการ จึงมีคู่เปรียบเทียบ 3 × 9 = 27 คู่ คู่ที่คะแนนบวกสูงกว่านับ 1 คะแนน คู่ที่เสมอกันมักนับ 0.5 และคู่ที่ต่ำกว่านับ 0 ก่อนหารด้วยจำนวนคู่ทั้งหมด จึงต้องระบุวิธีจัดการคะแนนเสมอและเซตคู่ลบที่ใช้

AUC พิจารณาลำดับทั่วทั้งเซตผู้สมัครและไม่รู้ว่าหน้าจอแสดงกี่รายการ จึงอาจสูงแม้รายการที่เกี่ยวข้องไม่ติด Top-K หากโจทย์สนใจเฉพาะรายการที่ผู้ใช้เห็นจริง ควรรายงาน AUC ร่วมกับ nDCG@K Recall@K หรือ Hit Rate@K ไม่ควรใช้แทนกัน

2.5 คุณภาพนอกเหนือความถูกต้อง (Beyond-Accuracy)

ความถูกต้องเพียงด้านเดียวอาจให้ระบบที่แนะนำรายการยอดนิยมชุดเดิมแก่ทุกคน แม้คะแนนออฟไลน์ดูดี แต่ผู้ใช้อาจไม่พบสิ่งใหม่และรายการส่วนใหญ่ในคลังไม่เคยถูกแสดง จึงควรประเมินคุณภาพนอกเหนือความถูกต้อง เช่น ความครอบคลุม ความหลากหลาย รายการส่วนหาง ความใหม่ การปรับเทียบ และความเป็นธรรม ควบคู่กับตัวชี้วัดหลัก

ระบบเช่นนี้ไม่ใช่ระบบผู้แนะนำ เพราะไม่ได้แนะนำอะไรที่เป็นส่วนตัวเลย และหากปล่อยให้ใช้งานจริง จะทำลายระบบนิเวศของผู้ผลิตเนื้อหาทั้งหมดในระยะยาว หัวข้อนี้จึงว่าด้วยตัวชี้วัดที่มองเห็นสิ่งที่ความแม่นยำมองไม่เห็น

ตัวชี้วัดในหัวข้อนี้มีเจ็ดตัว และแต่ละตัวมีสูตรที่ดูเรียบง่ายจนหลอกตา ประสบการณ์ในชั้นเรียนชี้ว่าผู้เรียนมักคิดว่าเข้าใจแล้วหลังอ่านสูตร แต่คำนวณผิดทันทีเมื่อลงมือทำเอง หัวข้อนี้จึงใช้วิธีต่างจากตำราทั่วไป คือกลับไปใช้ชุดข้อมูล MovieMini-12 ชุดเดียวกันกับที่หัวข้อ 2.1 ใช้คำนวณ MAE และ RMSE แล้วคำนวณตัวชี้วัดทั้งเจ็ดตัวบนสถานการณ์เดียวกันนั้นทีละขั้นจนครบ ข้อดีของการทำเช่นนี้คือผู้อ่านจะเห็นด้วยตาตนเองว่าตัวชี้วัดแต่ละตัว “มองเห็น” และ “มองไม่เห็น” อะไรบ้าง ซึ่งเป็นสิ่งที่การอ่านสูตรทีละตัวแยกกันไม่มีวันแสดงให้เห็นได้

กรณีศึกษา สถานการณ์ตัวอย่างร่วมของทั้งหัวข้อ 2.5 ชุดข้อมูล MovieMini-12

คลังมีภาพยนตร์ 12 เรื่อง (ตาราง MM-1) ผู้ใช้ 8 คน (ตาราง MM-2) และระบบแสดงผลลัพธ์คนละ 5 อันดับ (K = 5) รวมช่องแสดงผลทั้งระบบ $8 \times 5 = 40$ ช่อง หัวข้อนี้ไม่ใช้ตัวเลขสมมติเพิ่มเติม ค่าความนิยมของแต่ละเรื่องคือ **จำนวนผู้ให้คะแนน** $n(i) = |U_i|$ ซึ่งนับได้จากแถวสุดท้ายของตาราง MM-2 ส่วนผู้จัดจำหน่ายหลัก (Distributor) ของภาพยนตร์แต่ละเรื่องใช้เป็นหน่วย “ผู้ผลิต” ในหัวข้อ 2.5.6 โดย Universal รวมค่ายในเครือ คือ DreamWorks Animation และ Focus Features

ตาราง MM-3 ความนิยม ผู้จัดจำหน่าย และกลุ่มหัว–หางของภาพยนตร์ MovieMini-12

รหัส	ชื่อเรื่อง	แนว	ผู้จัดจำหน่าย	n(i)	p(i) = n(i)/8	กลุ่ม
i1	Toy Story 5 (2026)	Animation, Family	Disney	3	3/8 = 0.375	หาง
i2	Inside Out 2 (2024)	Animation, Family	Disney	3	3/8 = 0.375	หาง
i3	The Wild Robot (2024)	Animation, Sci-Fi	Universal	3	3/8 = 0.375	หาง
i4	It Ends with Us (2024)	Drama, Romance	Sony	3	3/8 = 0.375	หาง
i5	Wicked (2024)	Fantasy, Musical	Universal	3	3/8 = 0.375	หาง
i6	Bridget Jones: Mad About the Boy	Drama, Romance	Universal	4	4/8 = 0.500	หัว
i7	Ballerina (2025)	Action, Thriller	Lionsgate	2	2/8 = 0.250	หาง
i8	Furiosa: A Mad Max Saga	Action, Sci-Fi	Warner Bros.	2	2/8 = 0.250	หาง
i9	Conclave (2024)	Drama, Thriller	Universal	1	1/8 = 0.125	หาง
i10	Dune: Part Two (2024)	Action, Sci-Fi	Warner Bros.	2	2/8 = 0.250	หาง
i11	Mickey 17 (2025)	Sci-Fi, Thriller	Warner Bros.	4	4/8 = 0.500	หัว
i12	Project Hail Mary (2026)	Drama, Sci-Fi	Amazon MGM	2	2/8 = 0.250	หาง

ในระบบผู้แนะนำ คำว่า **กลุ่มหัว (Head)** และ **กลุ่มหาง (Tail)** ใช้แบ่งรายการตามระดับความนิยม หรือจำนวนครั้งที่ได้รับปฏิสัมพันธ์จากผู้ใช้ เช่น การคลิก การรับชม หรือการซื้อ

- **กลุ่มหัว (Head Items)** รายการจำนวนน้อยที่ได้รับความนิยมสูงและมีปฏิสัมพันธ์จำนวนมาก เช่น
  - ภาพยนตร์ยอดนิยม
  - เพลงติดอันดับ
  - สินค้าขายดี
  - ข่าวที่กำลังเป็นกระแส

  รายการกลุ่มนี้มีข้อมูลมาก แบบจำลองจึงเรียนรู้และแนะนำได้ง่าย แต่การแนะนำกลุ่มหัวมากเกินไปอาจทำให้ผลลัพธ์ขาดความหลากหลาย
- **กลุ่มหาง (Tail Items)** รายการจำนวนมากที่แต่ละรายการมีปฏิสัมพันธ์น้อย เช่น
  - ภาพยนตร์เฉพาะกลุ่ม
  - เพลงของศิลปินหน้าใหม่
  - หนังสือวิชาการเฉพาะสาขา
  - สินค้าที่มีผู้ซื้อจำนวนน้อย

รายการกลุ่มหางอาจตรงกับความสนใจเฉพาะบุคคลได้ดี แต่มีข้อมูลน้อย จึงประเมินความเกี่ยวข้องได้ยากกว่า

ในตัวอย่างนี้ เส้นแบ่งตามนิยาม 2.2 คือจุดที่ปฏิสัมพันธ์สะสมถึงหนึ่งในสามของทั้งหมด ปฏิสัมพันธ์รวมของคลังคือ 32 ครั้ง (ผลรวมแถวสุดท้ายของตาราง MM-2) หนึ่งในสามจึงเท่ากับ $32/3 = 10.67$ ครั้ง เมื่อเรียงตาม n(i) จากมากไปน้อย สองเรื่องแรก (i6 และ i11) สะสมได้ 8 ครั้ง ยังไม่ถึง 10.67 และเรื่องลำดับถัดไปเป็น **กลุ่มที่เสมอกันถึงห้าเรื่อง** ที่ n(i) = 3 (i1, i2, i3, i4, i5) จุดตัดหนึ่งในสามจึงตกอยู่กลางกลุ่มเสมอ การเลือกเอาเพียง i1 เข้ากลุ่มหัวเพราะรหัสน้อยกว่าย่อมไม่มีเหตุผลรองรับ ตารานี้จึงใช้เกณฑ์แบบค่าขีดแบ่งที่ไม่ตัดกลุ่มเสมอ ดังนี้

รหัส	n(i)	สะสม	สัดส่วนสะสม	กลุ่ม
i6	4	4	0.1250	หัว
i11	4	8	0.2500	หัว
i1	3	11	0.3438	หาง
i2	3	14	0.4375	หาง
i3	3	17	0.5312	หาง
i4	3	20	0.6250	หาง
i5	3	23	0.7188	หาง
i7	2	25	0.7812	หาง
i8	2	27	0.8438	หาง
i10	2	29	0.9062	หาง
i12	2	31	0.9688	หาง
i9	1	32	1.0000	หาง

$$\text{group}(i) = \begin{cases} \text{head}, & n(i) \geq 4 \\ \text{tail}, & n(i) < 4 \end{cases}$$

ข้อควรระวัง คือ คำว่า “หัว” และ “หาง” ไม่ได้มีเกณฑ์ตายตัว จึงไม่ควรแสดงเฉพาะป้ายกลุ่มโดยไม่บอกวิธีแบ่ง เพราะถ้าเปลี่ยนเป็นเกณฑ์ “20% ของรายการที่ได้รับความนิยมสูงสุด” หรือ “รายการที่รวมกันครอบคลุม 80% ของการรับชม”

จากเกณฑ์นี้จะได้กลุ่มหัวและกลุ่มหางดังนี้

- **กลุ่มหัว:** i6 Bridget Jones และ i11 Mickey 17 ซึ่งมีผู้ให้คะแนนเรื่องละ 4 คน รวม 8 จาก 32 ครั้ง คิดเป็นร้อยละ 25.0 ของปฏิสัมพันธ์ ทั้งที่มีเพียง 2 เรื่องจาก 12 เรื่อง (ร้อยละ 16.7 ของคลัง)
- **กลุ่มหาง:** อีก 10 เรื่องที่เหลือ ได้แก่ i1–i5, i7–i10 และ i12

ดังนั้น เรื่องอย่าง i1 Toy Story 5 หรือ i4 It Ends with Us ซึ่งมีผู้ให้คะแนน 3 คน ยังถูกจัดเป็นกลุ่มหาง แม้จะห่างจากกลุ่มหัวเพียงหนึ่งคน ข้อนี้ย้ำว่าเกณฑ์หัว–หางต้องประกาศเสมอ

กรณีศึกษา ระบบสองระบบที่ใช้เปรียบเทียบตลอดหัวข้อ 2.5

ระบบ ก คือแบบจำลอง B (ความนิยม) จากหัวข้อ 2.1 และ **ระบบ ข** คือแบบจำลอง A (อิงแนวภาพยนตร์) ทั้งสองใช้รายการชุดเดียวกับตารางประกอบหัวข้อ 2.3 แต่ตัดไว้ที่ 5 อันดับแรก ภายใต้โปรโตคอลปิดบังทีละรายการเหมือนเดิม

การแบ่งกลุ่มผู้ใช้ใช้ “ความยาวประวัติเชิงบวก” คือจำนวนเรื่องที่ผู้ใช้ให้ตั้งแต่ 4 ดาวในตาราง MM-2 ผู้ใช้ u1–u4 ชอบคนละ 3 เรื่อง จัดเป็น **กลุ่มประวัติยาว** ส่วน u5–u8 ชอบคนละ 2 เรื่อง จัดเป็น **กลุ่มประวัติสั้น** (เกณฑ์นี้แบ่งได้สี่ต่อสี่พอดี ในขณะที่การนับจำนวนคะแนนทั้งหมดจะได้ 4 คะแนนเกือบทุกคน จนแบ่งกลุ่มไม่ได้)

ผู้ใช้	กลุ่ม	ระบบ ก (Top-5)	ระบบ ข (Top-5)
u1	ประวัติยาว	i11 i6 i5 i4 i12	i3 i1 i2 i8 i10
u2	ประวัติยาว	i11 i2 i3 i6 i1	i4 i6 i9 i12 i1
u3	ประวัติยาว	i6 i2 i1 i3 i4	i7 i12 i3 i8 i4
u4	ประวัติยาว	i11 i6 i2 i3 i4	i10 i11 i7 i8 i9
u5	ประวัติสั้น	i11 i2 i1 i6 i4	i6 i1 i2 i10 i11
u6	ประวัติสั้น	i6 i11 i1 i3 i4	i1 i11 i3 i4 i5
u7	ประวัติสั้น	i6 i2 i1 i11 i4	i4 i6 i9 i8 i3
u8	ประวัติสั้น	i11 i1 i3 i5 i6	i4 i6 i9 i12 i2

- **กลุ่มประวัติยาว** (Long-history Users) หมายถึงผู้ใช้ที่มีข้อมูลพฤติกรรมในอดีตจำนวนมาก เช่น
  - ดูภาพยนตร์มาแล้วหลายเรื่อง
  - ให้คะแนนหรือกดชอบหลายครั้ง
  - ใช้ระบบมาเป็นเวลานาน
  - ระบบมีข้อมูลเพียงพอที่จะเรียนรู้ความสนใจ

  ตัวอย่างเช่น หากกำหนดว่า $h_u \geq 20$ เป็นประวัติยาว ผู้ใช้ที่เคยดูภาพยนตร์ 35 เรื่องจะอยู่ในกลุ่มนี้ ระบบมักแนะนำให้ผู้ใช้กลุ่มนี้ได้ง่ายกว่า เพราะมีหลักฐานเกี่ยวกับความชอบมาก
- **กลุ่มประวัติสั้น** (Short-history Users) หมายถึงผู้ใช้ที่มีข้อมูลพฤติกรรมในอดีตน้อย เช่น
  - เพิ่งเริ่มใช้ระบบ
  - เคยดูหรือให้คะแนนเพียงไม่กี่รายการ
  - ไม่ค่อยมีปฏิสัมพันธ์
  - ระบบยังไม่ทราบความสนใจอย่างมั่นใจ

  ตัวอย่างเช่น หากกำหนดว่า $h_u < 20$ เป็นประวัติสั้น ผู้ใช้ที่เคยดูภาพยนตร์เพียง 4 เรื่องจะอยู่ในกลุ่มนี้ กลุ่มนี้มักเผชิญปัญหา **ผู้ใช้เริ่มต้นใหม่ (user cold-start)** หรือปัญหาข้อมูลผู้ใช้เบาบาง แต่ผู้มีประวัติสั้นไม่จำเป็นต้องเป็นผู้ใช้ใหม่เสมอไป อาจเป็นผู้ใช้เก่าที่ใช้งานน้อยก็ได้

วิธีแบ่งกลุ่ม ต้องประกาศเกณฑ์ให้ชัดเจน อาจจะประกาสด้วยเงื่อนไข หรือแบ่งด้วยค่ามัธยฐานของจำนวนปฏิสัมพันธ์ เช่น

- ผู้ใช้ที่มีประวัติเท่ากับหรือสูงกว่าค่ามัธยฐาน ⟶ ประวัติยาว
- ผู้ใช้ที่มีประวัติต่ำกว่าค่ามัธยฐาน ⟶ ประวัติสั้น

กรณีศึกษา สังเกตด้วยตาเปล่าก่อนคำนวณ

คอลัมน์ของระบบ ก แทบเหมือนกันทั้งแปดแถว ทุกคนเห็น i6 และเจ็ดในแปดคนเห็น i11 เพราะระบบจัดอันดับตามจำนวนผู้ให้คะแนนล้วน ความต่างเล็กน้อยระหว่างแถวเกิดจากการปิดบังทีละรายการเท่านั้น (เช่น u1 ไม่เห็น i1, i2, i3 เพราะเมื่อไม่นับคะแนนของ u1 เอง สามเรื่องนี้เหลือผู้ให้คะแนนเพียง 2 คน) ส่วนระบบ ข ให้แต่ละคนเห็นคนละชุดตามแนวที่เคยให้คะแนน ประเด็นที่ต้องติดตามตลอดหัวข้อนี้คือ ตัวชี้วัดตัวใดจับความต่างข้อนี้ได้ และตัวใดจับไม่ได้เลย

เฉลยที่ใช้วัดความแม่นยำคือภาพยนตร์ที่ผู้ใช้ให้คะแนนตั้งแต่ 4 ดาวขึ้นไปในตาราง MM-2 ซึ่งเป็นการนำข้อมูลชุดเดียวมาใช้ทั้งการพยากรณ์คะแนนและการจัดอันดับ ทำให้เปรียบเทียบข้ามหัวข้อได้โดยตรง

2.5.1 ความครอบคลุมคลังรายการ (Catalog Coverage)

$$\text{Coverage@}K = \frac{|\cup_{u \in \mathcal{U}} \mathcal{L}_u^K|}{|\mathcal{I}|} \quad (2.16)$$

ให้ $\mathcal{L}_u^K$ เป็นรายการแนะนำแบบเรียงลำดับ K อันดับแรกของผู้ใช้ u และให้ $\mathcal{I}$ เป็นเซตรายการทั้งหมดที่ระบบสามารถแนะนำได้

ความครอบคลุมคลังรายการ (Catalog Coverage) คือสัดส่วนของรายการในคลังทั้งหมดที่เคยปรากฏในรายการแนะนำของผู้ใช้อย่างน้อยหนึ่งคน ค่า Coverage@10 = 0.042 หมายความว่ามีเพียงร้อยละ 4.2 ของคลังเท่านั้นที่ผู้ใช้ทั้งระบบมีโอกาสได้เห็น อีกร้อยละ 95.8 ไม่มีวันถูกค้นพบ ไม่ว่าจะดีเพียงใดก็ตาม

สัญลักษณ์ U ในสูตร 2.16 คือการยูเนียนของเซต ซึ่งหมายความว่ารายการหนึ่งชิ้นถูกนับเพียงครั้งเดียว โดยไม่นับรายการซ้ำ ไม่ว่าจะปรากฏในผลลัพธ์ของผู้ใช้กี่คนก็ตาม คุณสมบัติข้อนี้เป็นทั้งจุดแข็งและจุดอ่อนของตัวชี้วัด และเป็นสิ่งที่ตัวอย่าง 2.6 จะแสดงให้เห็น

ตัวอย่างการคำนวณ 2.6 การคำนวณ Coverage@5 ทีละขั้น บน MovieMini-12

ที่มาของข้อมูล

- (ก) รายการ Top-5 ของแต่ละผู้ใช้มาจากตารางระบบ ก และระบบ ข ข้างต้น (5 อันดับแรกของตารางประกอบหัวข้อ 2.3)
- (ข) ตัวส่วน $|\mathcal{I}| = 12$ คือจำนวนภาพยนตร์ทั้งหมดในตาราง MM-1 ที่ระบบมีสิทธิ์แนะนำ

ขั้นที่ 1 สร้างเซตยูเนียนของระบบ ก ทีละผู้ใช้ แล้วนับขนาดเซตสะสม

ผู้ใช้	Top-5 ของระบบ ก	รายการใหม่ที่เพิ่มเข้าเซต	|C| สะสม
u1	{i11, i6, i5, i4, i12}	i11, i6, i5, i4, i12	5
u2	{i11, i2, i3, i6, i1}	i2, i3, i1	8
u3	{i6, i2, i1, i3, i4}	—	8
u4	{i11, i6, i2, i3, i4}	—	8
u5	{i11, i2, i1, i6, i4}	—	8
u6	{i6, i11, i1, i3, i4}	—	8
u7	{i6, i2, i1, i11, i4}	—	8
u8	{i11, i1, i3, i5, i6}	—	8

หลังผู้ใช้ u2 เซตสะสมหยุดโตที่ 8 เรื่อง ผู้ใช้หกคนหลังไม่เพิ่มภาพยนตร์ใหม่เลยแม้แต่เรื่องเดียว ซึ่งเป็นลายเซ็นของระบบที่ให้ทุกคนเห็นของชุดเดิม ภาพยนตร์ที่ไม่เคยถูกแนะนำเลยคือ i7, i8, i9, i10 (Ballerina, Furiosa, Conclave และ Dune: Part Two)

$$\text{ระบบ ก} \quad \text{Coverage@5} = \frac{8}{12} = 0.6667$$

ขั้นที่ 2 ทำแบบเดียวกันกับระบบ ข

ผู้ใช้	Top-5 ของระบบ ข	รายการใหม่ที่เพิ่มเข้าเซต	|C| สะสม
u1	{i3, i1, i2, i8, i10}	i3, i1, i2, i8, i10	5
u2	{i4, i6, i9, i12, i1}	i4, i6, i9, i12	9
u3	{i7, i12, i3, i8, i4}	i7	10
u4	{i10, i11, i7, i8, i9}	i11	11
u5	{i6, i1, i2, i10, i11}	—	11
u6	{i1, i11, i3, i4, i5}	i5	12
u7	{i4, i6, i9, i8, i3}	—	12
u8	{i4, i6, i9, i12, i2}	—	12

เซตยูเนียนของระบบ ข โตขึ้นเกือบทุกครั้งที่อ่านรายการของผู้ใช้คนใหม่ และครบทั้งสิบสองเรื่องเมื่ออ่านถึง u6 ซึ่งได้ i5 Wicked เป็นเรื่องสุดท้าย

ระบบ ข Coverage@5 $= \frac{12}{12} = 1.0000$

ขั้นที่ 3 ตีความ

แต่ค่า 1.0000 นี้เองที่เผยจุดอ่อนของตัวชี้วัด เนื่องจาก Coverage ไม่สนใจว่ารายการนั้นถูกแนะนำกี่ครั้ง ระบบ ข แนะนำ i5 เพียงครั้งเดียว แต่แนะนำ i4 ถึงห้าครั้ง ก็ยังนับเป็น “ครอบคลุม” เท่ากัน และเมื่อ Coverage ชนเพดาน 1 แล้วจะไม่สามารถแยกระบบที่มีรูปแบบการกระจายต่างกันได้อีก เรียกว่า **ปัญหาการชนเพดาน (Ceiling Effect)** จึงต้องใช้สัมประสิทธิ์จีนีในหัวข้อถัดไปช่วยวัดความไม่เท่าเทียมของจำนวนครั้งที่ถูกแนะนำ

ตีความการเปรียบเทียบ Catalog Coverage@5

0.6667	VS	1.0000
Coverage@5 ระบบ ก		Coverage@5 ระบบ ข

- ระบบ ข มีความครอบคลุมคลังเท่ากับ 1.0000 (ร้อยละ 100) สูงกว่าระบบ ก ซึ่งครอบคลุมเพียง 0.6667 (ร้อยละ 66.67) คิดเป็น 1.5 เท่า แสดงว่าระบบ ข เปิดโอกาสให้ภาพยนตร์ทุกเรื่องในคลังถูกค้นพบ ขณะที่ระบบ ก ปิดตายภาพยนตร์ถึงสี่เรื่อง
- ภาพยนตร์สี่เรื่องที่ระบบ ก ไม่เคยแนะนำล้วนเป็นแนว Action หรือ Thriller ซึ่งมีผู้ให้คะแนนเพียง 1–2 คน หากผู้ใช้คนใดชอบแนวนี้ (เช่น u4 ที่ให้ i7 และ i8 ถึง 5 ดาว) ระบบ ก จะไม่มีวันแนะนำเรื่องแนวนี้ให้เลย
- Coverage สูงไม่ได้แปลว่าคำแนะนำตรงใจ และไม่ได้แปลว่าการเปิดเผยกระจายเท่าเทียม ต้องอ่านคู่กับ Precision@K และจีนีของการเปิดเผยเสมอ

โค้ดประกอบ 2.9 รายการ Top-5 ของระบบ ก และ ข และ Catalog Coverage ตามสมการ (2.16)

```
# ระบบ ก = แบบจำลอง B
SYS = {'ก': {u: LB[u][:5] for u in USERS},
       # ระบบ ข = แบบจำลอง A
       'ข': {u: LA[u][:5] for u in USERS}}
def coverage(D, n_items=12):
    return len(set().union(*D.values())) / n_items
for s, D in SYS.items():
    print(s, 'Coverage@5 =', round(coverage(D), 4),
          'never:', [i for i in ITEMS
                     if all(i not in L for L in D.values())])
```

ผลลัพธ์ที่ได้

```
ก Coverage@5 = 0.6667 never: ['i7', 'i8', 'i9', 'i10']
ข Coverage@5 = 1.0 never: []
```

2.5.2 สัมประสิทธิ์จีนีของการเปิดเผย (Gini Coefficient of Exposure)

Coverage บอกได้เพียงว่ามีรายการกี่ชิ้นที่ “เคยถูกแนะนำอย่างน้อยหนึ่งครั้ง” แต่บอกไม่ได้ว่าการเปิดเผยนั้นกระจายอย่างเท่าเทียมเพียงใด ระบบที่แนะนำรายการหนึ่งชิ้นเป็นพันครั้ง และอีกสี่สิบเก้าชิ้นชิ้นละครั้ง มี

Coverage เท่ากับระบบที่แนะนำทั้งห้าสิบชิ้นเท่า ๆ กัน ตัวชี้วัดที่จับความต่างนี้ได้คือสัมประสิทธิ์จีนี ซึ่งยืมมาจากเศรษฐศาสตร์ที่ใช้วัดความเหลื่อมล้ำของรายได้

$$Gini = \frac{\sum_{i=1}^{n}(2i-n-1)x_i}{n\sum_{i=1}^{n}x_i} \quad (2.17)$$

โดย x_i คือจำนวนครั้งที่รายการที่ i ถูกแนะนำ เรียงจากน้อยไปมาก และ n คือจำนวนรายการทั้งหมด ค่า 0 หมายถึงทุกรายการถูกเปิดเผยเท่ากันหมด และค่าเข้าใกล้ 1 หมายถึงการเปิดเผยกระจุกอยู่ที่รายการเดียว

กรอบเจาะลึก สูตร 2.17 มาจากไหน และเหตุใดสัมประสิทธิ์ (2i − n − 1) จึงหน้าตาเช่นนั้น

นิยามดั้งเดิมของจีนี คือ ครึ่งหนึ่งของผลต่างสัมบูรณ์เฉลี่ยสัมพัทธ์ นั่นคือ

$$Gini = \frac{\sum_{i=1}^{n}\sum_{j=1}^{n}|x_i - x_j|}{2n^2\bar{x}}$$

รูปนี้ต้องวนสองชั้นซึ่งมีต้นทุน $O(n^2)$ ใช้ไม่ได้กับคลังหลายแสนรายการ แต่เมื่อเรียงข้อมูลจากน้อยไปมากแล้ว ผลบวกสองชั้นยุบลงเหลือชั้นเดียวได้พอดี เพราะค่า x_i ที่อยู่อันดับที่ i จะถูก “ลบออก” โดยค่าที่ใหญ่กว่าจำนวน (n − i) ตัว และถูก “ลบเข้า” โดยค่าที่เล็กกว่าจำนวน (i − 1) ตัว ผลรวมของสัมประสิทธิ์จึงเป็น

$$(i-1) - (n-i) = 2i - n - 1$$

นี่คือที่มาของตัวเลข (2i − n − 1) ในสูตร 2.17 ทั้งหมด และเป็นเหตุผลที่ **การเรียงลำดับก่อนคำนวณเป็นขั้นบังคับ ไม่ใช่ทางเลือก** หากลืมเรียง สูตรจะคืนค่าที่ไม่มีความหมายใด ๆ เลย ซึ่งเป็นข้อผิดพลาดที่พบบ่อยที่สุดของตัวชี้วัดตัวนี้

สังเกตว่าผลรวมของสัมประสิทธิ์ทั้งหมดเป็นศูนย์เสมอ นั่นคือ $\sum(2i - n - 1) = 0$ จึงเป็นการตรวจสอบความถูกต้องอย่างง่ายที่ควรทำทุกครั้งก่อนคูณกับข้อมูล

ตัวอย่างการคำนวณ 2.7 การคำนวณสัมประสิทธิ์จีนีทีละพจน์ บน MovieMini-12

ที่มาของข้อมูล

- (ก) x_i คือจำนวนครั้งที่ภาพยนตร์ i ปรากฏใน Top-5 ของผู้ใช้ทั้งแปดคน นับจากตารางระบบ ก และระบบ ข ผลรวมของแต่ละระบบต้องเท่ากับ 40 ช่องพอดี
- (ข) ค่าฐานอ้างอิงคือความนิยมในข้อมูลนำเข้า $n(i)$ จากแถวสุดท้ายของตาราง MM-2 ซึ่งมีผลรวม 32

ขั้นที่ 1 นับจำนวนครั้งที่แต่ละเรื่องถูกแนะนำ (การเปิดเผย)

ระบบ	i1	i2	i3	i4	i5	i6	i7	i8	i9	i10	i11	i12	รวม
ระบบ ก	6	5	5	6	2	8	0	0	0	0	7	1	40
ระบบ ข	4	3	4	5	1	4	2	4	4	3	3	3	40
n(i) นำเข้า	3	3	3	3	3	4	2	2	1	2	4	2	32

ระบบ ก เปิดเผย i6 ถึง 8 ครั้งและ i11 อีก 7 ครั้ง ขณะที่สี่เรื่องได้ศูนย์ ส่วนระบบ ข กระจายการเปิดเผยไปทั่วทั้งคลังในช่วง 1 ถึง 5 ครั้ง

ขั้นที่ 2 เรียงค่าของระบบ ก จากน้อยไปมาก แล้วคูณด้วยสัมประสิทธิ์ (2i − n − 1) = (2i − 13) ทีละพจน์ (n = 12)

อันดับ i	ภาพยนตร์	xi (เรียงแล้ว)	2i − 13	ผลคูณ (2i − 13)·xi
1	i7 Ballerina	0	-11	0
2	i8 Furiosa	0	-9	0
3	i9 Conclave	0	-7	0
4	i10 Dune	0	-5	0
5	i12 Project Hail Mary	1	-3	-3
6	i5 Wicked	2	-1	-2
7	i2 Inside Out 2	5	1	5
8	i3 The Wild Robot	5	3	15
9	i1 Toy Story 5	6	5	30
10	i4 It Ends with Us	6	7	42
11	i11 Mickey 17	7	9	63
12	i6 Bridget Jones	8	11	88
รวม		**40**	**0**	**238**

ตรวจทานอย่างรวดเร็ว ผลรวมของคอลัมน์ (2i − 13) ต้องเป็นศูนย์เสมอ และผลรวมของคอลัมน์ xi ต้องเท่ากับจำนวนช่องแสดงผลทั้งระบบคือ 40 ช่องพอดี ซึ่งในตารางนี้เป็นจริงทั้งสองข้อ

$$\text{ระบบ ก} \quad \text{Gini} = \frac{238}{12\times40} = \frac{238}{480} = 0.4958$$

ขั้นที่ 3 ทำซ้ำกับระบบ ข

ค่าที่เรียงแล้วคือ 1, 2, 3, 3, 3, 3, 4, 4, 4, 4, 4, 5 ผลคูณรายพจน์คือ (-11)(1) + (-9)(2) + (-7)(3) + (-5)(3) + (-3)(3) + (-1)(3) + (1)(4) + (3)(4) + (5)(4) + (7)(4) + (9)(4) + (11)(5) = 78

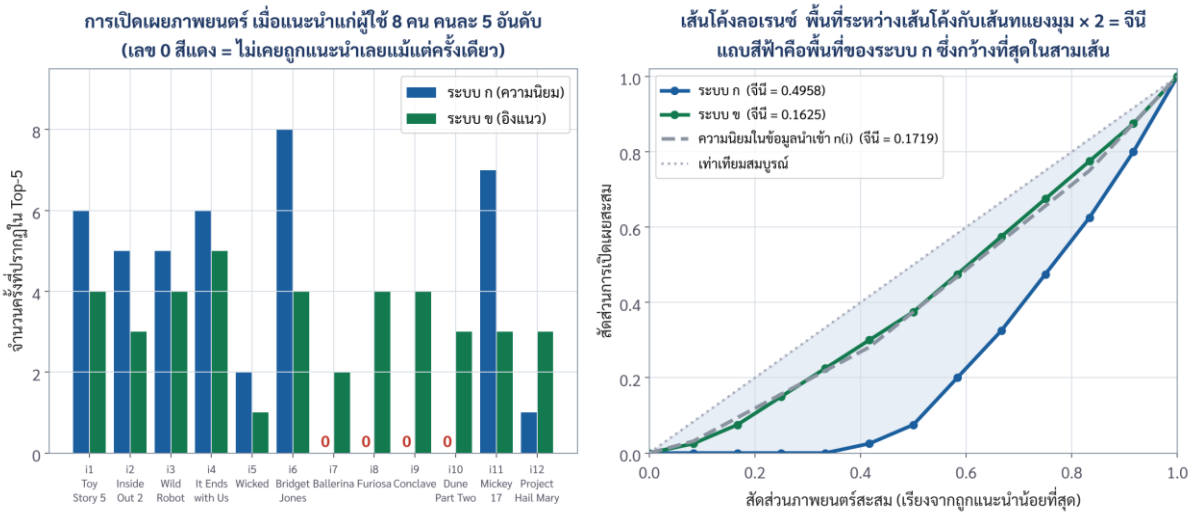
$$\text{ระบบ ข} \quad \text{Gini} = \frac{78}{12\times40} = \frac{78}{480} = 0.1625$$

ขั้นที่ 4 เทียบกับจีนีของข้อมูลนำเข้า ซึ่งเป็นขั้นที่มักถูกข้าม

ใช้สูตรเดียวกันกับแถว n(i) ซึ่งเรียงแล้วได้ 1, 2, 2, 2, 2, 3, 3, 3, 3, 3, 4, 4 มีผลรวม 32 และผลคูณรวม 66

$$\text{ข้อมูลนำเข้า} \quad \text{Gini} = \frac{66}{12\times32} = \frac{66}{384} = 0.1719$$

ตีความที่ตัดสินได้จริง ระบบ ก ให้จีนี 0.4958 ซึ่ง **สูงกว่า** จีนีของข้อมูลนำเข้า (0.1719) เกือบสามเท่า แปลว่าระบบ ก ขยายความไม่เท่าเทียมที่มีอยู่เดิมให้รุนแรงขึ้นมาก ส่วนระบบ ข ให้ 0.1625 ซึ่ง **ต่ำกว่า** ข้อมูลนำเข้าเล็กน้อย แปลว่าระบบ ข ไม่ได้ทำให้การกระจุกตัวแย่ลง นี่คือวิธีอ่านค่าจีนีที่ถูกต้อง คืออ่านเป็นการเปรียบเทียบ ไม่ใช่อ่านค่าเดี่ยว ๆ



ภาพที่ 2.7 การเปิดเผยภาพยนตร์ของระบบ ก และระบบ ข บน MovieMini-12 และเส้นโค้งลอเรนซ์ที่ให้จีนี 0.4958 กับ 0.1625 เทียบกับจีนีของข้อมูลนำเข้าที่ 0.1719

ภาพที่ 2.7 ด้านซ้ายแสดงจำนวนครั้งที่ภาพยนตร์แต่ละเรื่องปรากฏใน Top-5 ของผู้ใช้ทั้งแปดคน เลขศูนย์สีแดงกำกับเรื่องที่ระบบ ก ไม่เคยแนะนำเลยแม้แต่ครั้งเดียว ด้านขวาแปลงข้อมูลชุดเดียวกันเป็น **เส้นโค้งลอเรนซ์** (Lorenz Curve) โดยแกนนอนคือสัดส่วนภาพยนตร์สะสมเมื่อเรียงจากที่ถูกแนะนำน้อยที่สุดไปมากที่สุด และแกนตั้งคือสัดส่วนการเปิดเผยสะสม พื้นที่ระหว่างเส้นโค้งกับเส้นทแยงมุมเมื่อคูณสองแล้วคือค่าจีนีพอดี เส้นของระบบ ก จึงห้อยต่ำกว่าเส้นของระบบ ข อย่างชัดเจน ส่วนเส้นของระบบ ข แทบทับเส้นประของข้อมูลนำเข้า

กรอบเจาะลึก รายละเอียดที่ภาพที่ 2.7 เปิดเผย เส้นโค้งลอเรนซ์ตัดกันได้

เมื่อดูภาพขวาอย่างละเอียดจะพบว่าเส้นของระบบ ข (สีเขียว) กับเส้นของข้อมูลนำเข้า (เส้นประสีเทา) ตัดกัน ในช่วงต้นเส้นของระบบ ข อยู่ต่ำกว่าเล็กน้อย เพราะเรื่องที่ถูกแนะนำน้อยที่สุดคือ i5 ได้เพียง 1 จาก 40 ช่อง (ร้อยละ 2.5) ขณะที่เรื่องที่นิยมน้อยที่สุดในข้อมูลนำเข้าคือ i9 ยังครอง 1 จาก 32 ครั้ง (ร้อยละ 3.1) แต่ตั้งแต่เรื่องที่สี่เป็นต้นไป เส้นของระบบ ข อยู่เหนือหรือทับเส้นประตลอด ระบบ ข จึงเหลื่อมล้ำมากกว่าเล็กน้อยที่ปลายล่าง แต่เท่าเทียมกว่าในช่วงกลางถึงปลายบน

เมื่อเส้นโค้งสองเส้นตัดกัน การเปรียบเทียบด้วยค่าจีนีเพียงตัวเดียวจะสรุปได้เพียงว่า **พื้นที่รวม** ของฝ่ายใดมากกว่า ซึ่งเป็นการยุบข้อมูลสองมิติลงเหลือเลขตัวเดียว จึงเป็นไปได้ที่ระบบสองระบบจะมีจีนีใกล้เคียงกันมาก (เช่น 0.1625 กับ 0.1719 ในตัวอย่างนี้) ทั้งที่รูปแบบความไม่เท่าเทียมต่างกัน

บทเรียนเชิงปฏิบัติ ในรายงานที่จริงจัง ควรแนบเส้นโค้งลอเรนซ์มาพร้อมค่าจีนีเสมอ เช่นเดียวกับที่หัวข้อ 2.4 ยืนยันให้แนบเส้นโค้ง ROC มาพร้อมค่า AUC ด้วยเหตุผลทางคณิตศาสตร์แบบเดียวกันทุกประการ

ประเด็นสำคัญ กฎการอ่านค่าจีนีที่ใช้ได้จริง

ห้ามตัดสินค่าจีนีของผลลัพธ์แบบลอย ๆ เพราะข้อมูลนำเข้าเองก็มีความไม่เท่าเทียมอยู่แล้วโดยธรรมชาติ สิ่งที่ต้องดูคือ ระบบทำให้ความไม่เท่าเทียม **แย่ลงกว่าเดิม** หรือไม่

ตัวอย่างเช่น ความนิยมในข้อมูลนำเข้าจากตาราง MM-2 คือ n(i) = [3, 3, 3, 3, 3, 4, 2, 2, 1, 2, 4, 2] เมื่อเรียงจากน้อยไปมากจะได้ [1, 2, 2, 2, 2, 3, 3, 3, 3, 3, 4, 4] คำนวณด้วยสูตรจีนีได้ $G_{input} = 0.1719$ ซึ่งใช้เป็น **เส้นฐาน (Baseline)** แล้วนิยาม $\Delta G = G_{output} - G_{input}$

- $\Delta G > 0$: ระบบขยายความไม่เท่าเทียม และไม่ผ่านเกณฑ์กำกับ การเปิดเผยกระจุกตัวมากกว่าความนิยมเดิม
- $\Delta G = 0$: ระบบรักษาระดับความไม่เท่าเทียมเดิมไว้พอดี ไม่ได้ทำให้ดีขึ้นหรือแย่ลง
- $\Delta G < 0$: ระบบลดความไม่เท่าเทียม รายการที่มีความนิยมน้อยมีโอกาสปรากฏในผลคำแนะนำมากขึ้น

เกณฑ์กำกับที่แนะนำจึงเขียนในรูปเปรียบเทียบ เช่น $G_{output} \leq G_{input}$ ซึ่งในตัวอย่างนี้คือ $G_{output} \leq 0.1719$ เพราะหากระบบทำให้ค่าสูงขึ้น แปลว่าระบบกำลังขยายความไม่เท่าเทียมที่มีอยู่เดิม ซึ่งเป็นจุดเริ่มต้นของวงจรป้อนกลับที่กล่าวถึงในหัวข้อ 2.15.5

ระบบ	Gini ผลลัพธ์	Gini ข้อมูลนำเข้า	ΔG	ผลการประเมิน
ระบบ ก	0.4958	0.1719	+0.3240	ไม่ผ่าน — ขยายความไม่เท่าเทียม
ระบบ ข	0.1625	0.1719	−0.0094	ผ่าน — ลดความไม่เท่าเทียมเล็กน้อย

อย่างไรก็ตาม ผลดังกล่าวประเมินเฉพาะความเท่าเทียมของการเปิดเผยเท่านั้น และยังไม่ยืนยันความเกี่ยวข้องหรือคุณภาพโดยรวมของคำแนะนำ

ตีความการเปรียบเทียบ Gini Coefficient of Exposure

0.4958	VS	0.1625
Gini ระบบ ก		Gini ระบบ ข

- ระบบ ข มีค่า Gini เท่ากับ 0.1625 ต่ำกว่าระบบ ก ซึ่งมีค่าเท่ากับ 0.4958 อยู่ 0.3333 แสดงว่าระบบ ข กระจายโอกาสในการถูกแนะนำไปยังภาพยนตร์ในแค็ตตาล็อกได้สม่ำเสมอกว่า ขณะที่ระบบ ก กระจุกการแนะนำไว้ที่ i6 และ i11 ซึ่งรวมกันได้ 15 จาก 40 ช่อง (ร้อยละ 37.5)
- เมื่อเทียบกับฐาน 0.1719 ระบบ ก ได้ $\Delta G = +0.3240$ (ขยายความเหลื่อมล้ำ) ส่วนระบบ ข ได้ $\Delta G = -0.0094$ (ลดลงเล็กน้อย)
- ค่า Gini ต่ำไม่ได้หมายความว่ารายการแนะนำตรงกับความต้องการของผู้ใช้มากกว่า แต่หมายถึงระบบกระจายการแนะนำได้ทั่วถึงกว่าเท่านั้น จึงควรพิจารณาร่วมกับ Precision@K, Recall@K หรือ nDCG@K เพื่อประเมินความแม่นยำ

โค้ดประกอบ 2.10 จีนีของการเปิดเผยแบบแสดงทุกพจน์ตามสมการ (2.17)

```
def gini_steps(x):
    # ต้องเรียงก่อนเสมอ
    x = sorted(x); n = len(x)
    coef = [2 * k - n - 1 for k in range(1, n + 1)]
    num = sum(c * v for c, v in zip(coef, x))
    return num, num / (n * sum(x))
# n(i) จาก MM-2
N = {i: sum(i in R[u] for u in USERS) for i in ITEMS}
for s, D in SYS.items():
    cnt = Counter(i for L in D.values() for i in L)
    # นับศูนย์ให้ครบ 12 เรื่อง
    x = [cnt.get(i, 0) for i in ITEMS]
    num, g = gini_steps(x); print(s, x, num, round(g, 4))
num, g = gini_steps([N[i] for i in ITEMS])
print('input', num, round(g, 4))
```

ผลลัพธ์ที่ได้

```
ก [6, 5, 5, 6, 2, 8, 0, 0, 0, 0, 7, 1] 238 0.4958
ข [4, 3, 4, 5, 1, 4, 2, 4, 4, 3, 3, 3] 78 0.1625
input 66 0.1719
```

2.5.3 รายการส่วนหาง (Long-Tail Items) และความแตกต่างจากความหลากหลาย

คำสองคำนี้ถูกใช้สลับกันบ่อยมากจนเกิดความสับสน ทั้งที่วัดคนละสิ่งกันโดยสิ้นเชิง หัวข้อย่อยนี้จึงแยกให้ชัดก่อนให้สูตร

นิยาม 2.2 รายการส่วนหาง (Long-Tail Items)

เมื่อเรียงรายการทั้งคลังตามความนิยมจากมากไปน้อย จะได้เส้นโค้งที่ลาดชันมากในช่วงต้นแล้วแบนยาวออกไป รายการกลุ่มแรกที่ความนิยมสูงเรียกว่า **รายการส่วนหัว (Head Items)** ส่วนรายการที่เหลือซึ่งแต่ละชิ้นมีปฏิสัมพันธ์น้อยแต่มีจำนวนชิ้นมหาศาลเรียกว่า **รายการส่วนหาง (Long-Tail Items)**

เส้นแบ่งที่นิยมใช้คือจุดที่ปฏิสัมพันธ์สะสมถึงหนึ่งในสามของทั้งหมด รายการก่อนจุดนั้นเป็นส่วนหัว ที่เหลือเป็นส่วนหาง วรรณกรรมบางสายใช้เกณฑ์ร้อยละ 20 ของรายการแทน จึงต้องประกาศเกณฑ์ที่ใช้ทุกครั้ง

$$\text{LongTailRatio@}K(u) = \frac{|\mathcal{L}_u^K \cap \mathcal{I}_{tail}|}{K} \quad (2.18)$$

โดยที่ $\mathcal{I}_{tail}$ คือเซตรายการส่วนหาง และ $\mathcal{L}_u^K$ คือรายการแนะนำ K อันดับแรกของผู้ใช้ u

ตัวอย่างการคำนวณ 2.8 การหาเส้นแบ่งหัว–หาง และการคำนวณ LongTailRatio@5

ขั้นที่ 1 เส้นแบ่งหัว–หาง

ใช้ผลจากตาราง MM-3 คือกลุ่มหัว = {i6, i11} ซึ่งมี n(i) = 4 ส่วนอีก 10 เรื่องเป็นกลุ่มหาง (ร้อยละ 83.3 ของคลัง) กลุ่มหัวมีเพียง 2 เรื่อง คิดเป็นร้อยละ 16.7 ของคลัง แต่ครองปฏิสัมพันธ์ร้อยละ 25.0

ขั้นที่ 2 นับภาพยนตร์ส่วนหางในผลลัพธ์ของแต่ละคน แล้วหารด้วย K = 5 ตามสมการ (2.18)

ระบบ	ผู้ใช้	Top-5	เรื่องส่วนหัวที่ปรากฏ	จำนวนหาง	LongTail@5
ก	u1	i11 i6 i5 i4 i12	i11, i6	3	3/5 = 0.6000
ก	u2	i11 i2 i3 i6 i1	i11, i6	3	3/5 = 0.6000
ก	u3	i6 i2 i1 i3 i4	i6	4	4/5 = 0.8000
ก	u4	i11 i6 i2 i3 i4	i11, i6	3	3/5 = 0.6000
ก	u5	i11 i2 i1 i6 i4	i11, i6	3	3/5 = 0.6000
ก	u6	i6 i11 i1 i3 i4	i6, i11	3	3/5 = 0.6000
ก	u7	i6 i2 i1 i11 i4	i6, i11	3	3/5 = 0.6000
ก	u8	i11 i1 i3 i5 i6	i11, i6	3	3/5 = 0.6000
ข	u1	i3 i1 i2 i8 i10	— (ไม่มีเลย)	5	5/5 = 1.0000
ข	u2	i4 i6 i9 i12 i1	i6	4	4/5 = 0.8000
ข	u3	i7 i12 i3 i8 i4	— (ไม่มีเลย)	5	5/5 = 1.0000
ข	u4	i10 i11 i7 i8 i9	i11	4	4/5 = 0.8000
ข	u5	i6 i1 i2 i10 i11	i6, i11	3	3/5 = 0.6000
ข	u6	i1 i11 i3 i4 i5	i11	4	4/5 = 0.8000
ข	u7	i4 i6 i9 i8 i3	i6	4	4/5 = 0.8000
ข	u8	i4 i6 i9 i12 i2	i6	4	4/5 = 0.8000

$$\text{ระบบ ก}\quad \text{LongTail@5} = \frac{0.6+0.6+0.8+0.6+0.6+0.6+0.6+0.6}{8} = \frac{5.0}{8} = 0.6250$$

$$\text{ระบบ ข}\quad \text{LongTail@5} = \frac{1.0+0.8+1.0+0.8+0.6+0.8+0.8+0.8}{8} = \frac{6.6}{8} = 0.8250$$

ข้อควรระวังที่ต้องเน้น ค่า 0.6250 ของระบบ ก ดู “ไม่เลว” เมื่ออ่านลอย ๆ ทั้งที่ระบบ ก แนะนำของชุดเดิมให้เกือบทุกคน เหตุผลคือรายการส่วนหางในนิยามนี้กว้างมาก (10 ใน 12 เรื่อง) ภาพยนตร์อย่าง i2 Inside Out 2 หรือ i4 It Ends with Us ที่มีผู้ให้คะแนน 3 คนก็ถูกนับเป็นส่วนหางด้วย ตัวชี้วัดนี้จึงต้องอ่านคู่กับ Coverage และจีนีเสมอ และต้องประกาศเกณฑ์เส้นแบ่งที่ใช้ทุกครั้ง

ตีความการเปรียบเทียบ LongTailRatio@5

0.6250	VS	0.8250
LongTail@5 ระบบ ก		LongTail@5 ระบบ ข

- ระบบ ข มีสัดส่วนรายการส่วนหางเฉลี่ย 0.8250 สูงกว่าระบบ ก ซึ่งมีค่า 0.6250 อยู่ 0.2000 แสดงว่าระบบ ข นำภาพยนตร์ที่ไม่ใช่สองเรื่องยอดนิยมมาเสนอมากกว่า โดยผู้ใช้ u1 และ u3 ไม่ได้รับเรื่องส่วนหัวเลยแม้แต่เรื่องเดียว
- ในทางกลับกัน ระบบ ก ใส่ i6 ให้ผู้ใช้ทุกคน และใส่ i11 ให้ผู้ใช้เจ็ดคน ช่องแสดงผลถึง 15 จาก 40 ช่องจึงถูกใช้ไปกับภาพยนตร์เพียงสองเรื่อง
- สัดส่วนส่วนหางที่สูงไม่ได้แปลว่าดีเสมอไป ระบบที่สุ่มของหายากโดยไม่สนใจรสนิยมก็ได้ค่าสูงได้ จึงต้องรายงานคู่กับความแม่นยำ

นิยาม 2.3 ความหลากหลายภายในรายการ (Intra-List Diversity, ILD)

ความแตกต่างกันเองโดยเฉลี่ยของรายการทุกคู่ที่อยู่ในรายการแนะนำชุดเดียวกัน วัดจากคุณลักษณะของรายการ เช่น หมวดหมู่ ประเภท หรือเวกเตอร์ฝังตัว

$$\mathrm{ILD}@K(u) = \frac{2}{K(K-1)} \sum_{1 \le a < b \le K} \left[1 - \mathrm{sim}\left(i_{u,a}, i_{u,b}\right)\right] \quad (2.19)$$

ค่าเข้าใกล้ 1 หมายถึงรายการที่แนะนำแตกต่างกันมาก ค่าเข้าใกล้ 0 หมายถึงแนะนำของคล้ายกันทั้งหมด ตัวชี้วัดนี้วัดที่ระดับ **ผู้ใช้หนึ่งคน** แล้วจึงเฉลี่ยข้ามผู้ใช้

ตัวประกอบ $2/\left(K(K-1)\right)$ คือหนึ่งส่วนจำนวนคู่ทั้งหมด เพราะการเลือกคู่จาก K รายการมีได้ $K(K-1)/2$ คู่ ที่ K = 5 จึงมี 10 คู่พอดี ซึ่งเป็นจำนวนที่คำนวณด้วยมือได้สบาย

ตัวอย่างการคำนวณ 2.9 การคำนวณ ILD@5 ทีละคู่ ครบทั้งสิบคู่

ที่มาของข้อมูล

- (ก) ความคล้ายใช้ค่าแจ็กการ์ดของแนวภาพยนตร์ $\text{sim}(a,b) = J(a,b)$ ตามสมการ (M1) จากคอลัมน์ “แนว” ในตาราง MM-1 ดังนั้น $1 - \text{sim}$ จะเป็น 1 เมื่อไม่มีแนวร่วมกันเลย เป็น 0 เมื่อแนวเหมือนกันทั้งหมด และเป็น 0.6667 เมื่อมีแนวร่วมกันหนึ่งแนวจากสามแนว
- (ข) รายการที่ใช้คือ Top-5 ของผู้ใช้ u1 ในระบบ ก = {i11, i6, i5, i4, i12} และในระบบ ข = {i3, i1, i2, i8, i10} ที่ K = 5 มีคู่ทั้งหมด $5 \times 4/2 = 10$ คู่

กรณีที่ 1 ผลลัพธ์ของ u1 ในระบบ ก

คู่ที่	ภาพยนตร์คู่นั้น	แนวของทั้งคู่	sim	1 − sim
1	i11 – i6	Sci-Fi, Thriller / Drama, Romance	0.0000	1.0000
2	i11 – i5	Sci-Fi, Thriller / Fantasy, Musical	0.0000	1.0000
3	i11 – i4	Sci-Fi, Thriller / Drama, Romance	0.0000	1.0000
4	i11 – i12	Sci-Fi, Thriller / Drama, Sci-Fi	0.3333	0.6667
5	i6 – i5	Drama, Romance / Fantasy, Musical	0.0000	1.0000
6	i6 – i4	Drama, Romance / Drama, Romance	1.0000	0.0000
7	i6 – i12	Drama, Romance / Drama, Sci-Fi	0.3333	0.6667
8	i5 – i4	Fantasy, Musical / Drama, Romance	0.0000	1.0000
9	i5 – i12	Fantasy, Musical / Drama, Sci-Fi	0.0000	1.0000
10	i4 – i12	Drama, Romance / Drama, Sci-Fi	0.3333	0.6667
ผลรวม				**8.0000**

ระบบ ก $\text{ILD@5}(u_1) = \frac{2}{5\times4} \times 8.0000 = \frac{8.0000}{10} = 0.8000$

กรณีที่ 2 ผลลัพธ์ของ u1 ในระบบ ข

คู่ที่	ภาพยนตร์คู่นั้น	แนวของทั้งคู่	sim	1 − sim
1	i3 – i1	Animation, Sci-Fi / Animation, Family	0.3333	0.6667
2	i3 – i2	Animation, Sci-Fi / Animation, Family	0.3333	0.6667
3	i3 – i8	Animation, Sci-Fi / Action, Sci-Fi	0.3333	0.6667
4	i3 – i10	Animation, Sci-Fi / Action, Sci-Fi	0.3333	0.6667
5	i1 – i2	Animation, Family / Animation, Family	1.0000	0.0000
6	i1 – i8	Animation, Family / Action, Sci-Fi	0.0000	1.0000
7	i1 – i10	Animation, Family / Action, Sci-Fi	0.0000	1.0000
8	i2 – i8	Animation, Family / Action, Sci-Fi	0.0000	1.0000
9	i2 – i10	Animation, Family / Action, Sci-Fi	0.0000	1.0000

10	i8 – i10	Action, Sci-Fi / Action, Sci-Fi	1.0000	0.0000
ผลรวม				**6.6667**

ระบบ ข $\text{ILD@5}(u_1) = \frac{2}{5\times4} \times 6.6667 = \frac{6.6667}{10} = 0.6667$

คู่ i1–i2 (Animation, Family ทั้งคู่) และ i8–i10 (Action, Sci-Fi ทั้งคู่) มีแนวเหมือนกันทั้งหมด จึงไม่ช่วยเพิ่มความหลากหลายเลย ระบบ ข แนะนำตามรสนิยมแนว Animation และ Sci-Fi ของ u1 รายการจึงคล้ายกันเอง

ขั้นสุดท้าย เฉลี่ยข้ามผู้ใช้ทั้งแปดคน (โค้ดประกอบ 2.11)

ระบบ ก ได้ 0.8000, 0.8000, 0.7333, 0.8333, 0.8000, 0.8333, 0.8000, 0.9333 เฉลี่ย 0.8167 ส่วนระบบ ข ได้ 0.6667, 0.7333, 0.8333, 0.6667, 0.8667, 0.9333, 0.8000, 0.7333 เฉลี่ย 0.7792

ข้อควรระวัง ผลลัพธ์ที่ต้องอ่านสองครั้ง ระบบที่ครอบคลุมน้อยกว่ากลับได้ ILD สูงกว่า

ระบบ ก ให้ผู้ใช้เกือบทุกคนเห็นภาพยนตร์ชุดเดิม ส่วนระบบ ข ให้แต่ละคนเห็นคนละชุด แต่ค่า ILD ของระบบ ก กลับ **สูงกว่า** ระบบ ข คือ 0.8167 เทียบกับ 0.7792

เหตุผลไม่ใช่ความบกพร่องของการทดลอง แต่เป็นนิยามของตัวชี้วัดเอง ILD วัดความหลากหลาย **ภายในรายการของผู้ใช้คนเดียว** เท่านั้น มันไม่เคยเห็นผู้ใช้คนอื่นเลย ในคลังนี้ภาพยนตร์ที่มีผู้ให้คะแนนมากที่สุด (i6, i11, i1–i5) บังเอิญกระจายถึงแปดแนว ระบบที่ส่งของชุดนั้นให้ทุกคนจึงได้ ILD สูงโดยไม่ต้องพยายามอะไรเลย ในขณะที่ระบบเฉพาะบุคคลซึ่งแนะนำตามรสนิยม ย่อมกระจุกอยู่ในแนวที่ผู้ใช้ชอบ จึงได้ ILD ต่ำกว่าโดยธรรมชาติ

มิติที่ ILD มองไม่เห็นคือความซ้ำซากข้ามผู้ใช้ (Aggregate Diversity) ซึ่งต้องวัดด้วย Coverage และจีนี ซึ่งบนข้อมูลชุดเดียวกันนี้ชี้ไปคนละทางกับ ILD คือ Coverage 0.6667 เทียบ 1.0000 และจีนี 0.4958 เทียบ 0.1625

บทเรียนเชิงระเบียบวิธี การรายงาน ILD เพียงตัวเดียวแล้วสรุปว่า “ระบบมีความหลากหลาย” ไม่ใช่แค่หลักฐานไม่พอ แต่อาจนำไปสู่ข้อสรุปที่กลับด้านจากความจริง ทุกครั้งที่รายงาน ILD ต้องรายงาน Coverage หรือจีนีควบคู่เสมอ และหัวข้อ 2.5.7 จะแสดงว่าปรากฏการณ์เดียวกันนี้เกิดขึ้นจริงบนข้อมูลขนาด 500 รายการด้วย

ตีความการเปรียบเทียบ ILD@5 (เฉลี่ยผู้ใช้ 8 คน)

0.8167	VS	0.7792
ILD@5 ระบบ ก		ILD@5 ระบบ ข

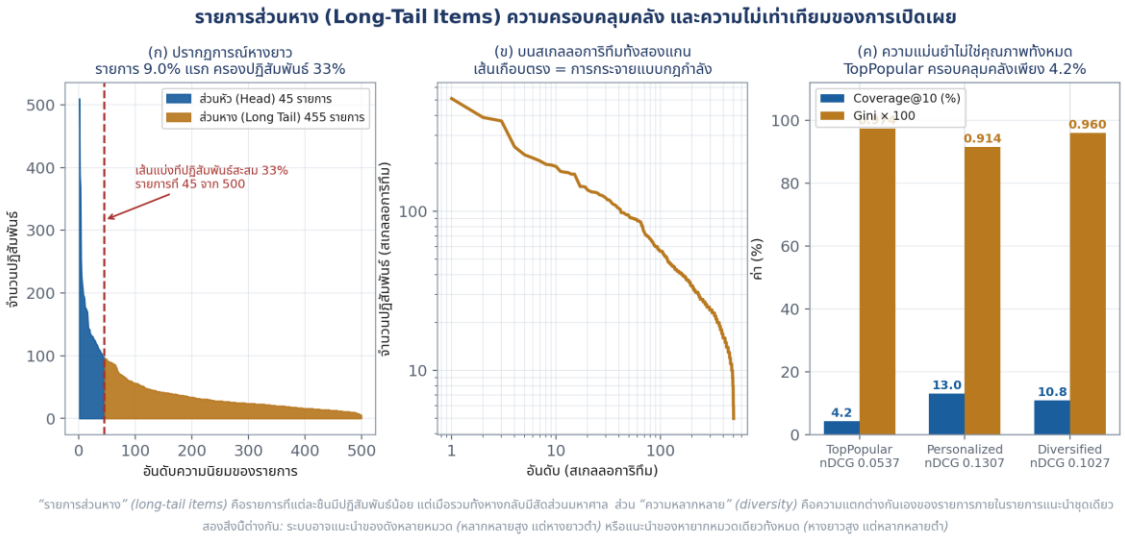
- ระบบ ก มีค่า ILD@5 เท่ากับ 0.8167 สูงกว่าระบบ ข ซึ่งมีค่าเท่ากับ 0.7792 อยู่ 0.0375 หากอ่านตัวเลขนี้ตัวเดียวจะสรุปว่าระบบ ก หลากหลายกว่า ซึ่งเป็นจริงเฉพาะ “ภายในรายการของแต่ละคน” เท่านั้น
- ผู้ใช้บางคนในระบบ ข ได้ ILD สูงกว่าระบบ ก เช่น u5 (0.8667 กับ 0.8000) และ u6 (0.9333 กับ 0.8333) แสดงว่าความหลากหลายภายในรายการของระบบเฉพาะบุคคลขึ้นกับความกว้างของรสนิยมผู้ใช้แต่ละคน
- ILD สูงไม่ได้แปลว่าระบบไม่ซ้ำซาก ระบบ ก ให้ทุกคนเห็น i6 ตรงกันทั้งแปดคน ต้องรายงาน Coverage หรือจีนีควบคู่เสมอ

โค้ดประกอบ 2.11 LongTailRatio@K และ ILD@K ตามสมการ (2.18)–(2.19)

```
HEAD = {i for i in ITEMS if N[i] >= 4}          # {'i6', 'i11'}
def longtail(L): return sum(i not in HEAD for i in L) / len(L)
def ild(L):
    pairs = list(itertools.combinations(L, 2))
    return sum(1 - jac(a, b) for a, b in pairs) / len(pairs)
for s, D in SYS.items():
    lt = [longtail(D[u]) for u in USERS]
    il = [ild(D[u]) for u in USERS]
    print(s, 'LongTail@5 =', round(sum(lt) / 8, 4),
          'ILD@5 =', round(sum(il) / 8, 4),
          'ILD(u1) =', round(il[0], 4))
```

ผลลัพธ์ที่ได้

```
ก LongTail@5 = 0.625 ILD@5 = 0.8167 ILD(u1) = 0.8
ข LongTail@5 = 0.825 ILD@5 = 0.7792 ILD(u1) = 0.6667
```



ภาพที่ 2.8 ปรากฏการณ์หางยาวในชุดข้อมูล RSLab-Eval บนสเกลปกติและสเกลลอการิทึม และผลกระทบต่อความครอบคลุมคลังของแบบจำลองสามแบบ

ภาพที่ 2.8 แผงซ้ายแสดงว่าในชุดข้อมูล RSLab-Eval รายการเพียง 45 ชิ้นจาก 500 ชิ้น คิดเป็นร้อยละ 9.0 ของคลัง ครองปฏิสัมพันธ์ถึงหนึ่งในสามของทั้งระบบ (เมื่อคำนวณจากชุดฝึกเพียงอย่างเดียวตามหลักการในหัวข้อ 2.8 เส้นแบ่งจะขยับมาอยู่ที่ 43 ชิ้น หรือร้อยละ 8.6) แผงกลางแสดงข้อมูลชุดเดียวกันบนสเกลลอการิทึมทั้งสองแกน เส้นที่เกือบตรงเป็นลายเซ็นของการกระจายแบบกฎกำลัง (Power-Law Distribution) ซึ่งพบในข้อมูลปฏิสัมพันธ์จริงแทบทุกชุด

ข้อควรระวัง รายการส่วนหางกับความหลากหลาย ต่างกันอย่างไร

สองตัวชี้วัดนี้เคลื่อนไหวเป็นอิสระจากกัน และเป็นไปได้ที่จะสูงตัวหนึ่งแต่ต่ำอีกตัวหนึ่ง

สถานการณ์	Long-tail Ratio	ILD	อธิบาย
แนะนำภาพยนตร์ฟอร์มยักษ์จากหกแนวที่ต่างกัน	ต่ำ	สูง	หลากหลายแนว แต่เป็นของดังทั้งหมด (กรณีของระบบ ก)
แนะนำภาพยนตร์อินดี้หายากแนวเดียวกันสิบเรื่อง	สูง	ต่ำ	เป็นของหายาก แต่ซ้ำซากในแนวเดียว
แนะนำของดังแนวเดียวกันสิบเรื่อง	ต่ำ	ต่ำ	กรณีที่แย่ที่สุด
แนะนำของหายากจากหลายแนว	สูง	สูง	กรณีที่ดีที่สุด แต่เสี่ยงต่อความแม่นยำ

ข้อสรุป ต้องรายงานทั้งสองค่า การรายงานเพียงค่าเดียวแล้วอ้างว่าระบบ "ไม่ซ้ำซาก" เป็นการอ้างที่ไม่มีหลักฐานรองรับ

2.5.4 ความแปลกใหม่ (Novelty)

$$\text{Novelty@}K(u) = \frac{1}{K}\sum_{j=1}^{K} -\log_2 p\left(i_{u,j}\right) \quad (2.20)$$

โดย p(i) คือสัดส่วนของผู้ใช้ที่เคยมีปฏิสัมพันธ์กับรายการ i ค่านี้จึงเป็นปริมาณสารสนเทศเชิงตนเอง (Self-Information) ของรายการนั้น รายการที่คนรู้จักน้อยมีค่า p(i) ต่ำ จึงให้ค่า $-\log_2 p(i)$ สูง ความหมายเชิงสัญชาตญาณคือ “ระบบกำลังบอกสิ่งที่ผู้ใช้ไม่น่าจะรู้อยู่แล้วมากน้อยเพียงใด”

ตัวอย่างการคำนวณ 2.10 การคำนวณ Novelty@5 ทีละเรื่อง

ขั้นที่ 1 แปลงจำนวนผู้ให้คะแนนเป็น p(i) แล้วเข้าลอการิทึมฐานสอง

ที่มาของข้อมูล: n(i) จากแถวสุดท้ายของตาราง MM-2 (หรือคอลัมน์ n(i) ในตาราง MM-3) และฐานผู้ใช้ทั้งระบบคือ 8 คน ดังนั้น $p(i) = n(i)/8$

ภาพยนตร์	ชื่อเรื่อง	n(i)	p(i) = n(i)/8	$-\log_2 p(i)$ (บิต)
i6	Bridget Jones: Mad About the Boy	4	4/8 = 0.500	1.0000
i11	Mickey 17	4	4/8 = 0.500	1.0000
i1	Toy Story 5	3	3/8 = 0.375	1.4150
i2	Inside Out 2	3	3/8 = 0.375	1.4150
i3	The Wild Robot	3	3/8 = 0.375	1.4150
i4	It Ends with Us	3	3/8 = 0.375	1.4150
i5	Wicked	3	3/8 = 0.375	1.4150
i7	Ballerina	2	2/8 = 0.250	2.0000
i8	Furiosa: A Mad Max Saga	2	2/8 = 0.250	2.0000
i10	Dune: Part Two	2	2/8 = 0.250	2.0000
i12	Project Hail Mary	2	2/8 = 0.250	2.0000
i9	Conclave	1	1/8 = 0.125	3.0000

สังเกตว่าค่าที่ได้มีเพียงสี่ระดับ คือ 1.0000 บิต (n = 4), 1.4150 บิต (n = 3), 2.0000 บิต (n = 2) และ 3.0000 บิต (n = 1) เพราะคลังขนาดเล็กมีความนิยมเพียงไม่กี่ระดับ

ขั้นที่ 2 เฉลี่ยค่าของห้าเรื่องในผลลัพธ์ของผู้ใช้ u1 ตามสมการ (2.20)

ระบบ ก $\text{Novelty@5}(u_1) = \frac{1.0000+1.0000+1.4150+1.4150+2.0000}{5} = \frac{6.8301}{5} = 1.3660$

(i11, i6, i5, i4, i12)

ระบบ ข $\text{Novelty@5}(u_1) = \frac{1.4150+1.4150+1.4150+2.0000+2.0000}{5} = \frac{8.2451}{5} = 1.6490$

(i3, i1, i2, i8, i10)

ขั้นที่ 3 เฉลี่ยข้ามผู้ใช้ทั้งแปดคน

ระบบ ก ได้ 1.3660, 1.2490, 1.3320, 1.2490, 1.2490, 1.2490, 1.2490, 1.2490 เฉลี่ย 1.2740 บิต ส่วนระบบ ข ได้ 1.6490, 1.7660, 1.7660, 2.0000, 1.3660, 1.3320, 1.7660, 1.7660 เฉลี่ย 1.6764 บิต

อ่านหน่วยให้ถูก เพราะใช้ลอการิทึมฐานสอง หน่วยของ Novelty จึงเป็น “บิต” ค่าประมาณ 1.27 บิตของระบบ ก หมายความว่าโดยเฉลี่ยแล้วการรู้ว่าภาพยนตร์เรื่องหนึ่งถูกแนะนำให้สารสนเทศแก่เราราวหนึ่งบิตเศษ ใกล้เคียงกับการรู้ผลการโยนเหรียญหนึ่งครั้ง หากเปลี่ยนไปใช้ลอการิทึมธรรมชาติ ค่าจะเปลี่ยนทันที จึงต้องประกาศฐานลอการิทึมที่ใช้เสมอ

ข้อควรระวัง ช่องโหว่ของ Novelty ที่ผู้ทำระบบใช้เอาเปรียบได้ง่ายที่สุด

จากตารางในตัวอย่าง 2.10 เรื่อง i9 Conclave ซึ่งมีผู้ให้คะแนนเพียงคนเดียวจากแปดคน ให้ค่า $-\log_2 p$ สูงถึง 3.0000 บิต ซึ่งเป็นสามเท่าของ i6 หรือ i11

ผลคือ ระบบสามารถ “ปั่น” ค่า Novelty ให้สูงขึ้นได้ทันทีเพียงยัดเรื่องที่แทบไม่มีใครรู้จักเข้าไปหนึ่งช่อง คำนวณดูจะพบว่าการแทน i12 ด้วย i9 ในผลลัพธ์ของ u1 ในระบบ ก ทำให้ค่าเพิ่มจาก 1.3660 เป็น 1.5660 หรือสูงขึ้นร้อยละ 14.6 ทั้งที่ u1 ให้คะแนนแนว Drama ต่ำมาก และ i9 ก็เป็นแนว Drama

เกณฑ์กำกับที่ต้องประกาศคู่กันเสมอ ห้ามรายงาน Novelty โดยไม่รายงานตัวชี้วัดความแม่นยำในตารางเดียวกัน และในทางปฏิบัติควรกำหนดเพดานไว้ด้วยว่า Novelty ที่สูงขึ้นต้องไม่ทำให้ตัวชี้วัดหลักตกเกินกี่เปอร์เซ็นต์

ต้องแยกความแปลกใหม่ออกจากความบังเอิญที่น่าพอใจ (Serendipity) ซึ่งเข้มงวดกว่า เพราะ Serendipity ต้องการทั้งความแปลกใหม่ และความพึงพอใจของผู้ใช้พร้อมกัน การแนะนำรายการที่ไม่มีใครรู้จักและผู้ใช้ก็ไม่ชอบด้วย ให้ค่า Novelty สูงแต่ Serendipity เป็นศูนย์

ตีความการเปรียบเทียบ Novelty@5 (บิต, เฉลี่ยผู้ใช้ 8 คน)

1.2740	VS	1.6764
Novelty@5 ระบบ ก		Novelty@5 ระบบ ข

- ระบบ ข มีค่า Novelty@5 เท่ากับ 1.6764 บิต สูงกว่าระบบ ก ซึ่งมีค่าเท่ากับ 1.2740 บิต อยู่ 0.4024 บิต หรือประมาณ 1.32 เท่า แสดงว่าระบบ ข เสนอภาพยนตร์ที่ผู้ใช้ส่วนใหญ่ยังไม่รู้จักมากกว่า
- ผู้ใช้ u4 ได้ค่าสูงสุดในระบบ ข (2.0000 บิต) เพราะได้รับ i10, i7, i8 และ i9 ซึ่งมีผู้ให้คะแนนเพียง 1–2 คน ส่วนผู้ใช้หกคนในระบบ ก ได้ค่าเท่ากันพอดีที่ 1.2490 บิต สะท้อนว่ารายการของพวกเขาประกอบด้วยเรื่องยอดนิยมชุดเดียวกัน
- Novelty สูงอาจเกิดจากการยัดเรื่องที่ไม่มีใครรู้จักโดยไม่สนใจรสนิยม จึงต้องอ่านคู่กับ Precision@K เสมอ

โค้ดประกอบ 2.12 Novelty@K ตามสมการ (2.20)

```
def novelty(L): return sum(-math.log2(N[i] / 8) for i in L) / len(L)
for s, D in SYS.items():
    v = [novelty(D[u]) for u in USERS]
    print(s, 'u1 =', round(v[0], 4), 'mean =', round(sum(v) / 8, 4))
```

ผลลัพธ์ที่ได้

```
ก u1 = 1.366 mean = 1.274
ข u1 = 1.649 mean = 1.6764
```

2.5.5 การปรับเทียบ (Calibration)

ผู้ใช้คนหนึ่งอาจดูภาพยนตร์แนวแอ็กชันร้อยละ 70 และแนวสารคดีร้อยละ 30 หากระบบแนะนำแนวแอ็กชันครบทั้งสิบช่อง ค่า Precision อาจสูงมาก

แต่ความสนใจส่วนน้อยของผู้ใช้ถูกกลบหายไปทั้งหมด การปรับเทียบวัดว่าสัดส่วนแนวในรายการที่แนะนำตรงกับสัดส่วนในประวัติของผู้ใช้เพียงใด

$$\text{CalibrationError}(u) = \frac{1}{2}\sum_c |q_u(c) - p_u(c)| \quad (2.21)$$

โดย p(c) คือสัดส่วนของแนว c ในประวัติของผู้ใช้ และ q(c) คือสัดส่วนของแนว c ในรายการที่แนะนำ รูปแบบนี้เรียกว่าระยะทางรวมแปรผัน (Total Variation Distance) ให้ค่าอยู่ในช่วง 0 ถึง 1 โดยศูนย์หมายถึงสัดส่วนตรงกันพอดี

ตัวอย่างการคำนวณ 2.11 การคำนวณค่าคลาดเคลื่อนของการปรับเทียบ ทีละขั้น

ส่วนที่ 1 กรณีพื้นฐาน (ค่าสมมติเพื่อแสดงหลักการ)

ผู้ใช้มีประวัติแบ่งตามแนวดังนี้ แอ็กชัน 0.70 · สารคดี 0.20 · ตลก 0.10 และระบบแนะนำสิบเรื่องที่เป็นแอ็กชัน 9 เรื่อง ตลก 1 เรื่อง

แนว	p(c) จากประวัติ	q(c) จากรายการที่แนะนำ	|q − p|
แอ็กชัน	0.70	0.90	0.20
สารคดี	0.20	0.00	0.20
ตลก	0.10	0.10	0.00
ผลรวม			**0.40**

$$\text{CalibrationError} = 0.5 \times 0.40 = 0.2000$$

เหตุใดต้องคูณด้วย 0.5 เพราะการแจกแจงทั้งสองมีผลรวมเท่ากับ 1 เสมอ สิ่งที่เกินในแนวหนึ่งจึงต้องขาดในอีกแนวหนึ่งเท่ากันพอดี ผลรวมของ |q − p| จึงนับความคลาดเคลื่อนก้อนเดียวกันสองครั้ง ตัวประกอบ 0.5 ทำให้ค่าที่ได้ตีความได้ตรงตัวว่า “ต้องย้ายน้ำหนักคิดเป็นสัดส่วนเท่าใดของรายการทั้งหมด จึงจะทำให้สองการแจกแจงตรงกัน” คำตอบคือร้อยละ 20 หรือ 2 ช่องจาก 10 ช่องพอดี

ส่วนที่ 2 กรณีจริงบน MovieMini-12 ผู้ใช้ u1

ที่มาของข้อมูล ประวัติ p(c) มาจากเรื่องที่ u1 ให้ตั้งแต่ 4 ดาวในตาราง MM-2 คือ i1, i2, i3 และแนวของแต่ละเรื่องจากตาราง MM-1 เนื่องจากภาพยนตร์แต่ละเรื่องมีสองแนว จึงแบ่งน้ำหนักเรื่องละ 1 ออกเป็นแนวละ 0.5 ได้ Animation = (0.5 + 0.5 + 0.5)/3 = 0.5000, Family = (0.5 + 0.5)/3 = 0.3333 และ Sci-Fi = 0.5/3 = 0.1667 ส่วน q(c) คำนวณแบบเดียวกันจาก Top-5 ของแต่ละระบบ (หารด้วย 5)

แนว	p(c) ของ u1	q(c) ระบบ ก	|q − p|	q(c) ระบบ ข	|q − p|
Animation	0.5000	0.0000	0.5000	0.3000	0.2000
Family	0.3333	0.0000	0.3333	0.2000	0.1333
Sci-Fi	0.1667	0.2000	0.0333	0.3000	0.1333
Action	0.0000	0.0000	0.0000	0.2000	0.2000
Drama	0.0000	0.3000	0.3000	0.0000	0.0000
Romance	0.0000	0.2000	0.2000	0.0000	0.0000
Fantasy	0.0000	0.1000	0.1000	0.0000	0.0000
Musical	0.0000	0.1000	0.1000	0.0000	0.0000
Thriller	0.0000	0.1000	0.1000	0.0000	0.0000
ผลรวม	**1.0000**	**1.0000**	**1.6667**	**1.0000**	**0.6667**

ระบบ ก $\text{CalibrationError}(u_1) = 0.5 \times 1.6667 = 0.8333$

ระบบ ข $\text{CalibrationError}(u_1) = 0.5 \times 0.6667 = 0.3333$

ตีความ ระบบ ก ส่งเรื่องยอดนิยมชุดเดียวกันให้ทุกคน u1 จึงได้ Drama, Romance, Thriller, Fantasy และ Musical มาเต็ม ๆ ทั้งที่ไม่เคยให้คะแนนสูงแก่แนวเหล่านี้ และไม่ได้ Animation เลย ค่าคลาดเคลื่อน 0.8333 แปลว่าต้องย้ายน้ำหนักถึงร้อยละ 83.3 ของรายการ ในขณะที่ระบบ ข ได้ 0.3333 ซึ่งยังไม่เป็นศูนย์ เพราะระบบ ข ใส่แนว Action (i8, i10) มาแทนสัดส่วนของ Family

ค่าเฉลี่ยข้ามผู้ใช้ทั้งแปดคนคือ ระบบ ก = 0.6667 และระบบ ข = 0.3979 แต่ค่าเฉลี่ยก็ยังกลบข้อเท็จจริงที่ว่าผู้ใช้บางคน เช่น u3 ต่างกันถึง 0.7333 เทียบ 0.2667 อันเป็นเหตุผลที่หัวข้อ 2.10 ยืนยันให้รายงานการกระจายรายผู้ใช้ ไม่ใช่รายงานแต่ค่าเฉลี่ย

ตีความการเปรียบเทียบ Calibration Error (เฉลี่ยผู้ใช้ 8 คน)

0.6667	VS	0.3979
Calibration Error ระบบ ก		Calibration Error ระบบ ข

- ระบบ ข มีค่าคลาดเคลื่อนของการปรับเทียบ 0.3979 ต่ำกว่าระบบ ก ซึ่งมีค่า 0.6667 อยู่ 0.2687 แสดงว่าสัดส่วนแนวในรายการของระบบ ข ใกล้เคียงกับรสนิยมในประวัติของผู้ใช้มากกว่า โดยระบบ ข ดีกว่าหรือเท่ากับระบบ ก ในผู้ใช้ทุกคน
- ค่าของระบบ ข ยังห่างจากศูนย์พอสมควร เพราะแบบจำลอง A ใช้ความคล้ายของแนวแบบแจ็กการ์ด จึงชอบเรื่องที่มีแนวร่วมเพียงแนวเดียวด้วย ทำให้แนวรองของเรื่องเหล่านั้นแทรกเข้ามาในรายการ
- Calibration Error ต่ำอาจแปลว่าระบบไม่กล้าแนะนำแนวใหม่เลย จึงต้องอ่านร่วมกับ Novelty และความแม่นยำ

โค้ดประกอบ 2.13 Calibration Error แบบ Total Variation ตามสมการ (2.21)

```
# แบ่งน้ำหนักเรื่องละ 1 ให้แนวเท่า ๆ กัน
def gdist(items):
    c = Counter()
    for i in items:
        for g in GENRE[i]: c[g] += 1 / len(GENRE[i])
    t = sum(c.values()); return {g: v / t for g, v in c.items()}
def calib(u, L):
    p, q = gdist(rel(u)), gdist(L)
    gs = set(p) | set(q)
    return 0.5 * sum(abs(q.get(g, 0) - p.get(g, 0)) for g in gs)
for s, D in SYS.items():
    v = [calib(u, D[u]) for u in USERS]
    print(s, 'u1 =', round(v[0], 4), 'mean =', round(sum(v) / 8, 4))
```

ผลลัพธ์ที่ได้

```
ก u1 = 0.8333 mean = 0.6667
ข u1 = 0.3333 mean = 0.3979
```

2.5.6 ความเป็นธรรม (Fairness)

ความเป็นธรรมในระบบผู้แนะนำมีสองด้านที่ต้องแยกจากกัน และการวัดด้านเดียวแล้วอ้างว่าระบบเป็นธรรมเป็นข้อสรุปที่เกินหลักฐาน

1. **ความเป็นธรรมฝั่งผู้ใช้ (User-Side Fairness)** ถามว่าผู้ใช้ทุกกลุ่มได้รับคุณภาพบริการเท่ากันหรือไม่ วัดด้วยช่องว่างสมภาค (Parity Gap) ซึ่งคือผลต่างของตัวชี้วัดหลักระหว่างกลุ่ม เช่น ผู้ใช้ที่มีประวัติมากกับผู้ใช้ใหม่

$$\text{ParityGap} = |\mathbb{E}[M(u) \mid u \in G_A] - \mathbb{E}[M(u) \mid u \in G_B]| \quad (2.22)$$

2. **ความเป็นธรรมฝั่งผู้ผลิต (Provider-Side Fairness)** ถามว่าผู้ผลิตเนื้อหาทุกรายได้รับโอกาสถูกเปิดเผยอย่างเป็นธรรมหรือไม่ วัดด้วยจีนีของการเปิดเผยที่รวมกลุ่มตามผู้ผลิต ประเด็นนี้เป็นเรื่องของความยั่งยืนของระบบนิเวศ เพราะหากผู้ผลิตรายย่อยไม่มีโอกาสถูกค้นพบเลย ในที่สุดก็จะไม่มีเนื้อหาใหม่เข้าสู่ระบบ

ตัวอย่างการคำนวณ 2.12 การคำนวณความเป็นธรรมทั้งสองด้าน บน MovieMini-12

ส่วนที่ 1 ช่องว่างสมภาคฝั่งผู้ใช้

ใช้ Precision@5 เป็นตัวชี้วัดคุณภาพ โดยนับว่าภาพยนตร์ที่ผู้ใช้ให้ไว้ตั้งแต่ 4 ดาวในตาราง MM-2 คือเรื่องที่เกี่ยวข้อง และแบ่งกลุ่มตามจำนวนเรื่องที่ชอบ (u1–u4 ชอบ 3 เรื่อง = ประวัติยาว, u5–u8 ชอบ 2 เรื่อง = ประวัติสั้น) ในวงเล็บคือเรื่องที่ตรงกับ Ground Truth

ผู้ใช้	กลุ่ม	P@5 ระบบ ก	P@5 ระบบ ข
u1	ประวัติยาว	0/5 = 0.0	3/5 = 0.6 (i3, i1, i2)
u2	ประวัติยาว	1/5 = 0.2 (i6)	2/5 = 0.4 (i4, i6)
u3	ประวัติยาว	0/5 = 0.0	1/5 = 0.2 (i12)
u4	ประวัติยาว	0/5 = 0.0	2/5 = 0.4 (i7, i8)
ค่าเฉลี่ยกลุ่มประวัติยาว		0.0500	0.4000
u5	ประวัติสั้น	0/5 = 0.0	0/5 = 0.0
u6	ประวัติสั้น	0/5 = 0.0	1/5 = 0.2 (i5)
u7	ประวัติสั้น	1/5 = 0.2 (i11)	0/5 = 0.0
u8	ประวัติสั้น	1/5 = 0.2 (i6)	2/5 = 0.4 (i4, i6)
ค่าเฉลี่ยกลุ่มประวัติสั้น		0.1000	0.1500
ParityGap = | ยาว − สั้น |		0.0500	0.2500

$$\text{ระบบ ก กลุ่มยาว } \bar{P}_{long} = \frac{0+0.2+0+0}{4} = 0.0500$$

$$\text{ระบบ ก กลุ่มสั้น } \bar{P}_{short} = \frac{0+0+0.2+0.2}{4} = 0.1000$$

$$\text{ระบบ ข กลุ่มยาว } \bar{P}_{long} = \frac{0.6+0.4+0.2+0.4}{4} = 0.4000$$

$$\text{ระบบ ข กลุ่มสั้น } \bar{P}_{short} = \frac{0+0.2+0+0.4}{4} = 0.1500$$

ผลที่ต้องอ่านอย่างระมัดระวังที่สุดของทั้งหัวข้อ ระบบ ก ได้ ParityGap = 0.0500 ซึ่งต่ำกว่าระบบ ข (0.2500) ถึงห้าเท่า ทั้งที่ระบบ ข ให้คุณภาพสูงกว่าใน **ทุกกลุ่ม** (0.4000 > 0.0500 และ 0.1500 > 0.1000) หากใช้เกณฑ์กำกับแบบตายตัวว่า “ParityGap ต้องไม่เกิน 0.10” ระบบ ข จะถูกปฏิเสธทันที ทั้งที่ผู้ใช้ทั้งสองกลุ่มได้ประโยชน์มากขึ้น

ช่องว่างที่แคบของระบบ ก ไม่ได้มาจากความเป็นธรรม แต่มาจากการที่ทุกคนได้รับผลลัพธ์เกือบชุดเดียวกัน จึงแย่พอ ๆ กันโดยอัตโนมัติ ปรากฏการณ์นี้เรียกว่า **การปรับให้เท่ากันโดยลดลง (Leveling Down)** บทเรียนคือ ต้องรายงานทั้งค่าเฉลี่ยของแต่ละกลุ่มและช่องว่างเสมอ

ส่วนที่ 2 จีนีของการเปิดเผยฝั่งผู้ผลิต

รวมการเปิดเผยทั้ง 40 ช่องเข้าตามผู้จัดจำหน่ายหกราย (คอลัมน์ “ผู้จัดจำหน่าย” ในตาราง MM-3) แล้วใช้สมการ (2.17) อีกครั้ง โดยคราวนี้ n = 6 สัมประสิทธิ์จึงเป็น (2i − 7) = −5, −3, −1, 1, 3, 5

ระบบ	Disney	Universal	Warner Bros.	Sony	Lionsgate	Amazon MGM	Provider Gini
ระบบ ก	11	15	7	6	0	1	106/240 = 0.4417
ระบบ ข	7	13	10	5	2	3	78/240 = 0.3250
จำนวนเรื่องในคลัง	2	4	3	1	1	1	22/72 = 0.3056

ระบบ ก: ค่าที่เรียงแล้ว 0, 1, 6, 7, 11, 15 ได้ (-5)(0) + (-3)(1) + (-1)(6) + (1)(7) + (3)(11) + (5)(15) = 106 ดังนั้น Gini = 106/(6 × 40) = 0.4417 ส่วนระบบ ข: 2, 3, 5, 7, 10, 13 ได้ (-5)(2) + (-3)(3) + (-1)(5) + (1)(7) + (3)(10) + (5)(13) = 78 ดังนั้น Gini = 78/240 = 0.3250

ระบบ ก ไม่เคยแนะนำภาพยนตร์ของ Lionsgate (i7 Ballerina) เลยแม้แต่ครั้งเดียว และแนะนำของ Amazon MGM (i12) เพียงครั้งเดียว เหตุผลตรงไปตรงมาคือภาพยนตร์ของผู้จัดจำหน่ายรายเล็กมีผู้ให้คะแนนน้อย เมื่อระบบจัดอันดับตามความนิยมล้วน จึงไม่มีทางถูกค้นพบ นอกจากนี้ควรเทียบกับฐานอ้างอิงคือ “สัดส่วนจำนวนเรื่องในคลัง” ซึ่งมีจีนี 0.3056 เพราะ Universal มีถึงสี่เรื่อง ระบบ ข ได้ 0.3250 ใกล้เคียงฐานนี้ ส่วนระบบ ก สูงกว่าฐานอย่างชัดเจน

ข้อควรระวัง กับดักการเขียนโปรแกรมที่ทำให้ตัวเลขความเป็นธรรมสวยเกินจริง

ในการคำนวณส่วนที่ 2 ของตัวอย่าง 2.12 ถ้าเขียนโปรแกรมด้วยการนับความถี่จากผลลัพธ์ตรง ๆ เช่นใช้ `Counter` แล้วส่งค่าที่นับได้เข้าสูตรจีนีทันที Lionsgate ซึ่งไม่เคยปรากฏในผลลัพธ์ของระบบ ก เลยจะ **หายไปจากเวกเตอร์ทั้งหมด** ทำให้คำนวณบนเวกเตอร์ (1, 6, 7, 11, 15) ที่มีสมาชิกเพียงห้าตัว

ผิด (ตัดศูนย์ทิ้ง) $\text{Gini} = \frac{66}{5\times40} = 0.3300$

ถูก (ครบหกราย) $\text{Gini} = \frac{106}{6\times40} = 0.4417$

ค่าที่ผิดต่ำกว่าความจริงถึง 0.1117 และผิดในทิศทางที่อันตรายที่สุด คือทำให้ระบบดูเป็นธรรมกว่าที่เป็นจริง สาเหตุเชิงตรรกะชัดเจนเมื่อชี้ให้เห็น นั่นคือ **กลุ่มที่ถูกกีดกันมากที่สุด คือกลุ่มที่หายไปจากการคำนวณพอดี** ปัญหาเดียวกันเกิดกับจีนีระดับรายการ หากตัดสี่เรื่องที่ได้ศูนย์ของระบบ ก ออก จะได้ 0.2437 แทน 0.4958

กฎที่ต้องจำ เวกเตอร์ที่ป้อนเข้าสูตรจีนีต้องมีสมาชิกครบทุกหน่วยที่ **มีสิทธิ์** ถูกเปิดเผย ไม่ใช่เฉพาะหน่วยที่ถูกเปิดเผยจริง ฟังก์ชัน gini_index และ provider_exposure_gap ในแพ็กเกจ rslab เขียนตามกฎนี้ทั้งคู่

ตีความการเปรียบเทียบ ความเป็นธรรมฝั่งผู้ใช้และฝั่งผู้ผลิต

0.0500 · 0.4417	VS	0.2500 · 0.3250
ParityGap · Provider Gini ระบบ ก		ParityGap · Provider Gini ระบบ ข

- ฝั่งผู้ใช้ ระบบ ก มีช่องว่างสมภาคเพียง 0.0500 ต่ำกว่าระบบ ข (0.2500) แต่ค่าเฉลี่ย Precision@5 ของระบบ ก อยู่ที่ 0.0500 และ 0.1000 ซึ่งต่ำกว่าระบบ ข (0.4000 และ 0.1500) ทั้งสองกลุ่ม ช่องว่างที่แคบจึงเป็นผลของการ “แย่เท่ากัน” ไม่ใช่ความเป็นธรรม
- ฝั่งผู้ผลิต ระบบ ข มี Provider Gini เท่ากับ 0.3250 ต่ำกว่าระบบ ก (0.4417) อยู่ 0.1167 แสดงว่าระบบ ข กระจายโอกาสถูกเปิดเผยไปยังผู้จัดจำหน่ายทุกรายได้สม่ำเสมอกว่า และใกล้เคียงกับสัดส่วนจำนวนเรื่องในคลัง (0.3056)
- ตัวชี้วัดความเป็นธรรมสองด้านอาจชี้ไปคนละทาง การวัดด้านเดียวแล้วอ้างว่าระบบเป็นธรรมจึงเป็นข้อสรุปที่เกินหลักฐาน

โค้ดประกอบ 2.14 ParityGap ตามสมการ (2.22) และ Provider Gini

```
PROV = {'i1': 'Disney', 'i2': 'Disney',
        'i3': 'Universal', 'i5': 'Universal', 'i6': 'Universal',
        'i9': 'Universal', 'i8': 'Warner', 'i10': 'Warner',
        'i11': 'Warner', 'i4': 'Sony', 'i7': 'Lionsgate',
        'i12': 'Amazon MGM'}
LONG = [u for u in USERS if len(rel(u)) >= 3]   # u1-u4
SHORT = [u for u in USERS if u not in LONG]     # u5-u8
for s, D in SYS.items():
    pl = sum(prec(D[u], rel(u), 5) for u in LONG) / len(LONG)
    ps = sum(prec(D[u], rel(u), 5) for u in SHORT) / len(SHORT)
    cnt = Counter(PROV[i] for L in D.values() for i in L)
    # ครบหกราย
    x = [cnt.get(p, 0) for p in sorted(set(PROV.values()))]
    print(s, round(pl, 4), round(ps, 4),
          'gap =', round(abs(pl - ps), 4),
          'provider gini =', round(gini_steps(x)[1], 4))
```

ผลลัพธ์ที่ได้

```
ก 0.05 0.1 gap = 0.05 provider gini = 0.4417
ข 0.4 0.15 gap = 0.25 provider gini = 0.325
```

2.5.7 หลักฐานเชิงตัวเลข ไม่มีแบบจำลองใดชนะทุกคอลัมน์

ก่อนไปสู่ข้อมูลจริง ควรรวบรวมผลการคำนวณด้วยมือทั้งหมดของหัวข้อนี้ไว้ในที่เดียว เพราะภาพรวมที่ได้จะเป็นแบบเดียวกันกับที่จะพบในข้อมูลจริงทุกประการ

ประเด็นสำคัญ สรุปผลการคำนวณด้วยมือทั้งหมดบน MovieMini-12

ตัวชี้วัด	ทิศทางที่ดี	ระบบ ก	ระบบ ข	คำนวณในตัวอย่างที่
Precision@5	สูง	0.0750	0.2750	2.12
Coverage@5	สูง	0.6667	1.0000	2.6
Gini ของการเปิดเผย	ต่ำ	0.4958	0.1625	2.7
LongTail@5	สูง	0.6250	0.8250	2.8
ILD@5	สูง	0.8167	0.7792	2.9
Novelty@5 (บิต)	สูง	1.2740	1.6764	2.10
Calibration Error	ต่ำ	0.6667	0.3979	2.11
Parity Gap (ฝั่งผู้ใช้)	ต่ำ	0.0500	0.2500	2.12
Provider Gini (ฝั่งผู้ผลิต)	ต่ำ	0.4417	0.3250	2.12

ระบบ ข ชนะเจ็ดคอลัมน์จากเก้าคอลัมน์ แต่แพ้สองคอลัมน์คือ ILD@5 และ Parity Gap (แถวที่ระบายสี) และตัวอย่าง 2.9 กับ 2.12 ได้แสดงแล้วว่าการแพ้ทั้งสองคอลัมน์นั้นไม่ได้แปลว่าระบบ ข ด้อยกว่าเลย แต่เกิดจากนิยามของตัวชี้วัดเองทั้งคู่ นี่คือเหตุผลที่ต้องประกาศตัวชี้วัดหลักไว้ล่วงหน้า และต้องอธิบายที่มาของทุกคอลัมน์ที่แพ้ ไม่ใช่ซ่อนมันไว้

ข้อสังเกตที่สำคัญที่สุดของทั้งตาราง ถ้าผู้ทำการทดลองเลือกรายงานเฉพาะ ILD@5 กับ Parity Gap ผู้อ่านจะสรุปว่า “ระบบ ก หลากหลายกว่าและเป็นธรรมกว่า” ซึ่งกลับด้านจากความจริงโดยสิ้นเชิง ในขณะที่ Coverage และจีนีไปในทิศทางที่ถูกต้องอย่างชัดเจน การเลือกตัวชี้วัดจึงเป็นการตัดสินใจที่มีผลต่อข้อสรุปมากพอ ๆ กับการเลือกแบบจำลอง

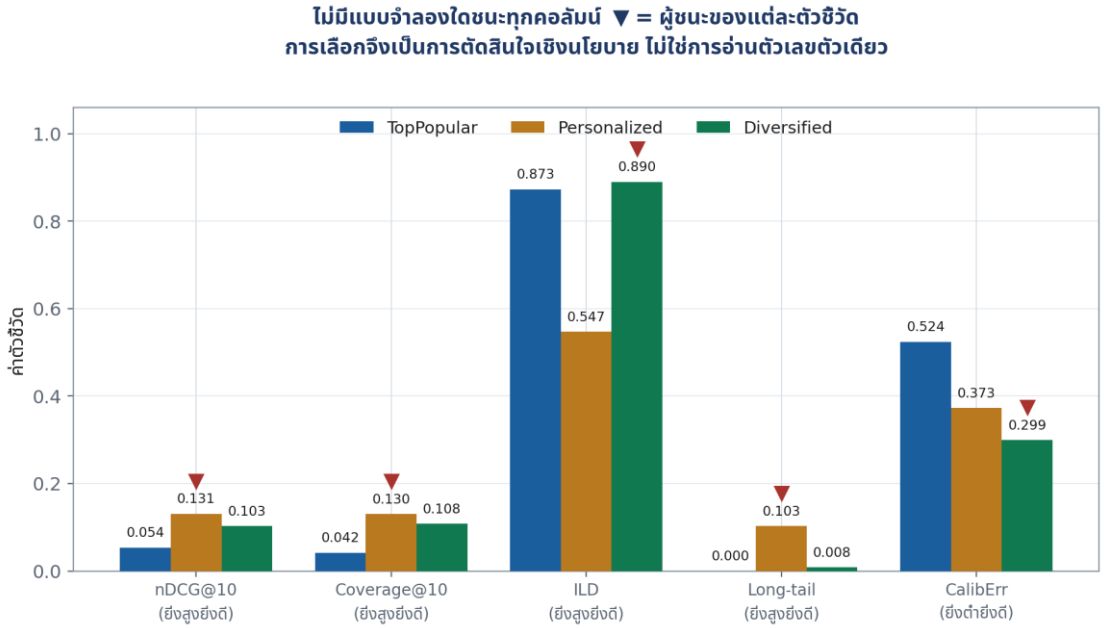
ทุกค่าในตารางนี้ทำซ้ำได้ด้วยโค้ดประกอบ 2.9–2.14 ซึ่งอ่านข้อมูลจากตาราง MM-1 ถึง MM-3 เพียงแหล่งเดียว

การทดลองต่อไปนี้เปรียบเทียบแบบจำลองสามแบบบนชุดข้อมูล RSLab-Eval ซึ่งมีรายการ 500 ชิ้น และผู้ใช้ 800 คน แบบจำลอง TopPopular แนะนำรายการยอดนิยมให้ทุกคนเหมือนกัน แบบจำลอง Personalized ใช้ความคล้ายของผู้ใช้ และแบบจำลอง Diversified ปรับผลลัพธ์ของ Personalized ให้กระจายข้ามหมวดหมู่มากขึ้น ผู้อ่านทำซ้ำได้ด้วย lab2_05_beyond_accuracy.py ซึ่งเป็นโปรแกรมเดียวกันกับที่ผลิตตัวเลขในตัวอย่าง 2.6 ถึง 2.12 ทั้งหมด

ตารางที่ 2.4 *ตัวชี้วัดหลักหนึ่งตัวและตัวชี้วัดกำกับแปดตัวของแบบจำลองสามแบบบนชุดข้อมูล RSLab-Eval*

ตัวชี้วัด	ทิศทางที่ดี	TopPopular	Personalized	Diversified
nDCG@10 (ตัวชี้วัดหลัก)	สูง	0.0537	**0.1307**	0.1027
Coverage@10	สูง	0.042	**0.130**	0.108
Gini ของการเปิดเผย	ต่ำ	0.9735	**0.9145**	0.9599

ตัวชี้วัด	ทิศทางที่ดี	TopPopular	Personalized	Diversified
ILD (ความหลากหลาย)	สูง	0.8730	0.5469	**0.8903**
Novelty	สูง	2.1200	**2.7898**	2.2467
Long-tail Ratio@10	สูง	0.0000	**0.1029**	0.0082
Calibration Error	ต่ำ	0.5240	0.3730	**0.2994**
Parity Gap (ฝั่งผู้ใช้)	ต่ำ	0.0117	**0.0043**	0.0072
Provider Gini (ฝั่งผู้ผลิต)	ต่ำ	0.6685	**0.3945**	0.5808



ภาพที่ 2.9 ไม่มีแบบจำลองใดชนะทุกตัวชี้วัด การเลือกจึงเป็นการตัดสินใจเชิงนโยบาย

ตัวเลขในตารางที่ 2.4 นำไปสู่ข้อสังเกตสามข้อที่เป็นแก่นของหัวข้อนี้

1. **TopPopular ไม่ได้แย่ที่สุดทุกด้าน และปรากฏการณ์นี้ทำนายไว้แล้วด้วยมือ** มันได้ ILD สูงถึง 0.8730 ซึ่งสูงกว่า Personalized (0.5469) อย่างชัดเจน ซึ่งเป็นรูปแบบเดียวกันพอดีกับที่ตัวอย่าง 2.9 คำนวณด้วยมือบนคลังเพียง 12 เรื่อง แล้วได้ 0.8167 เทียบกับ 0.7792 การที่ปรากฏการณ์เดียวกันเกิดซ้ำทั้งบนคลัง 12 เรื่อง และคลัง 500 ชิ้น ยืนยันว่าไม่ใช่ความบังเอิญของชุดข้อมูล แต่เป็นสมบัติของตัวชี้วัดเอง
2. **Personalized ดีขึ้นทั้งความแม่นและความครอบคลุมพร้อมกัน** ได้ nDCG@10 = 0.1307 สูงกว่า TopPopular ร้อยละ 143.4 และ Coverage@10 = 0.130 สูงกว่าร้อยละ 209.5 แสดงว่าการแลกเปลี่ยนระหว่างความแม่นกับความครอบคลุม ไม่ได้เป็นการแลกเปลี่ยนเสมอไป ในช่วงที่ระบบยังห่างจากขอบเขตพาเรโตมาก การปรับปรุงมักได้ทั้งสองด้าน
3. **Diversified แลกความแม่นเพื่อความหลากหลายอย่างชัดเจน** nDCG@10 ลดลงจาก 0.1307 เหลือ 0.1027 คิดเป็นลดลงร้อยละ 21.4 แลกกับ ILD ที่เพิ่มจาก 0.5469 เป็น 0.8903 คิดเป็นเพิ่มขึ้นร้อยละ 62.8 และ Calibration Error ที่ดีขึ้นจาก 0.3730 เหลือ 0.2994 แต่ต้องสังเกตด้วยว่าสัดส่วนหางยาวกลับ ลดลง

จาก 0.1029 เหลือ 0.0082 และ Provider Gini แย่ลงจาก 0.3945 เป็น 0.5808 เพราะการกระจายข้ามหมวดไม่ได้แปลว่ากระจายไปยังรายการที่หายาก

ประเด็นสำคัญ ข้อสรุปของหัวข้อ 2.5

ไม่มีแบบจำลองใดในตารางที่ 2.4 ชนะทุกคอลัมน์ และนี่ไม่ใช่ความบกพร่องของการทดลอง แต่เป็นธรรมชาติของปัญหาที่มีวัตถุประสงค์หลายอย่างขัดแย้งกัน

การเลือกแบบจำลองจึงเป็น **การตัดสินใจเชิงนโยบาย** ที่ต้องอาศัยเป้าหมายของผู้ใช้และธุรกิจเป็นตัวตั้ง ไม่ใช่การอ่านตัวเลขตัวเดียวแล้วประกาศผู้ชนะ หน้าที่ของผู้ทำการทดลองคือวางตัวเลขทั้งหมดบนโต๊ะให้ครบ พร้อมกับระบุตัวชี้วัดหลักที่ประกาศไว้ล่วงหน้า แล้วปล่อยให้การตัดสินใจเกิดขึ้นอย่างเปิดเผย ซึ่งเป็นเนื้อหาของหัวข้อ 2.6 ที่จะตามมาทันที

และสิ่งที่ต้องนำติดตัวไปจากหัวข้อนี้ที่สุดคือ ตัวชี้วัดแต่ละตัวมี **จุดบอด** ของตนเองที่ชัดเจนและอธิบายได้ Coverage ชนเพดานแล้วหยุดแยกความต่าง จีนีมองไม่เห็นว่าใครได้อะไร ILD มองไม่เห็นความซ้ำซากข้ามผู้ใช้จนถึงขั้นให้คะแนน ระบบที่แย่ที่สุดสูงที่สุด Novelty ถูกปั่นได้ด้วยรายการเดียว และ Parity Gap ให้รางวัลเต็มแก่ระบบที่แย่กับทุกคนเท่า ๆ กัน การรายงานเป็นชุดจึงไม่ใช่การรายงานให้ดูดี แต่เป็นเงื่อนไขขั้นต่ำของการรายงานที่ซื่อสัตย์

หน่วยและฐานอ้างอิงของตัวชี้วัดนอกเหนือความถูกต้อง

ตัวชี้วัดนอกเหนือความถูกต้องไวต่อฐานอ้างอิงต่างกัน Catalog Coverage ใช้ขนาดคลังที่อนุญาตให้แนะนำเป็นตัวส่วน Novelty ใช้ความนิยมที่คำนวณจากชุดฝึก ILD ใช้ระยะห่างของคุณลักษณะหรือเวกเตอร์รายการ Calibration เปรียบเทียบการกระจายหมวดหมู่ของประวัติกับคำแนะนำ และ Fairness ต้องระบุกลุ่มผู้ใช้หรือผู้ให้บริการที่นำมาเปรียบเทียบ หากเปลี่ยนฐานอ้างอิง คะแนนจะเปลี่ยนแม้รายการแนะนำเหมือนเดิม

ก่อนรายงานค่าควรตอบให้ครบว่า วัดต่อผู้ใช้หรือต่อระบบ ใช้ข้อมูลช่วงเวลาใด รวมรายการที่มีการเปิดเผยเป็นศูนย์หรือไม่ และค่าสูงหมายถึงดีเสมอหรือเป็นเพียงความแตกต่าง ตัวอย่างเช่น ILD สูงอาจเกิดจากรายการที่ไม่เกี่ยวข้องแต่แตกต่างกันมาก ส่วน Calibration ต่ำอาจแปลว่าระบบไม่กล้าแนะนำสิ่งใหม่ จึงต้องอ่านร่วมกับตัวชี้วัดหลักและ Guardrail

2.6 ตัวชี้วัดหลักและตัวชี้วัดกำกับ

ก่อนคำนวณต้องตอบให้ได้ว่า “คุณสมบัติใดคือเป้าหมายหลักของระบบ” เพราะความถูกต้อง ความครอบคลุม ความหลากหลาย และความเป็นธรรมอาจแลกเปลี่ยนกัน แนวทางที่ตรวจสอบได้คือกำหนดตัวชี้วัดหลักหนึ่งค่าเพื่อใช้ตัดสินผู้ชนะ แล้วกำหนดตัวชี้วัดกำกับพร้อมเกณฑ์ขั้นต่ำหรือเพดานเพื่อป้องกันผลเสียด้านอื่น



ภาพที่ 2.10 คุณสมบัติของตัวชี้วัดในระบบผู้แนะนำ

2.6.1 คุณสมบัติสามกลุ่ม

1) **คุณภาพของคำแนะนำ (Recommendation Quality)** เป็นกลุ่มที่วัดจากรายการที่ระบบผลิตออกมาโดยตรง ประกอบด้วยความถูกต้อง (Accuracy) ความครอบคลุม (Coverage) ความหลากหลาย (Diversity) ความแปลกใหม่ (Novelty) และความบังเอิญที่น่าพอใจ (Serendipity) กลุ่มนี้วัดได้จากข้อมูลบันทึกย้อนหลังทั้งหมด จึงเป็นกลุ่มที่ตำราเล่มนี้ใช้เป็นแกนหลัก
2) **ประสบการณ์ผู้ใช้ (User Experience)** เป็นกลุ่มที่วัดจากความรู้สึกและการตัดสินใจของผู้ใช้ ประกอบด้วยความไว้วางใจ (Trust) ความเชื่อมั่นของระบบต่อคำทำนายของตัวเอง (Confidence) การอธิบายผลได้ (Explainability) ความเสี่ยงที่ผู้ใช้ยอมรับได้ (Risk) และการใช้ประโยชน์ซ้ำ (Utility) กลุ่มนี้ส่วนใหญ่ต้องวัดด้วยแบบสอบถามหรือการทดลองกับผู้ใช้จริง
3) **คุณสมบัติเชิงระบบ (System Properties)** เป็นกลุ่มที่วัดจากพฤติกรรมของซอฟต์แวร์ ประกอบด้วยความทนทานต่อข้อมูลปนเปื้อน (Robustness) ความเป็นส่วนตัว (Privacy) การปรับตัวเมื่อข้อมูลใหม่เข้ามา (Adaptivity) การขยายขนาด (Scalability) และเวลาตอบสนอง (Latency) กลุ่มนี้มักถูกละเลยในงานวิจัยแต่เป็นตัวตัดสินว่าระบบขึ้นใช้งานจริงได้หรือไม่

2.6.2 ตัวชี้วัดหลัก (Primary Metric)

นิยาม 2.4 ตัวชี้วัดหลัก (Primary Metric)

ตัวชี้วัดเพียง **หนึ่งตัว** ที่ประกาศไว้ล่วงหน้าว่าจะใช้ตัดสินว่าแบบจำลองใดชนะ การประกาศต้องระบุครบทั้งชื่อตัวชี้วัด ค่า K วิธีเฉลี่ยข้ามผู้ใช้ และเซตผู้สมัครที่ใช้ ตัวอย่างการประกาศที่สมบูรณ์คือ

nDCG@10 เฉลี่ยแบบมหภาคข้ามผู้ใช้ (macro-average) บนการจัดอันดับเต็มบัญชีรายการ โดยตัดรายการที่ผู้ใช้เคยมีปฏิสัมพันธ์ในชุดฝึกออกก่อน

การประกาศแบบ “เราใช้ nDCG” เฉย ๆ ยังไม่พอ เพราะ nDCG@10 บนเซตผู้สมัคร 100 รายการ กับ nDCG@10 บนเซตผู้สมัคร 500 รายการ เป็นตัวเลขคนละสเกลอย่างสิ้นเชิง ดังที่หัวข้อ 2.9 จะแสดงให้เห็น

หลักการเลือกตัวชี้วัดหลักคือ ต้องเลือกตัวที่สอดคล้องกับเป้าหมายของผู้ใช้และธุรกิจมากที่สุด ไม่ใช่เลือกตัวที่แบบจำลองของเราทำได้ดีที่สุด ตารางที่ 2.5 แสดงการจับคู่ระหว่างลักษณะงานกับตัวชี้วัดหลักที่เหมาะสม

ตารางที่ 2.5 การเลือกตัวชี้วัดหลักให้สอดคล้องกับลักษณะงานและเป้าหมายทางธุรกิจ

ลักษณะงาน	เป้าหมายที่แท้จริง	ตัวชี้วัดหลักที่เหมาะสม	เหตุผล
พยากรณ์คะแนนที่ผู้ใช้จะให้	ทำนายตัวเลขให้ใกล้ความจริง	RMSE หรือ MAE	ผลลัพธ์เป็นตัวเลขต่อเนื่อง ไม่ใช่การจัดอันดับ
แนะนำรายการหน้าแรก 10 ช่อง	ให้สิ่งที่ตรงใจอยู่ใกล้ตำแหน่งบนสุด	nDCG@10	ให้น้ำหนักตามตำแหน่ง และรองรับความเกี่ยวข้องหลายระดับ
แนะนำสินค้าเสริมตอนชำระเงิน	ผู้ใช้กดเพิ่มสินค้าอย่างน้อยหนึ่งชิ้น	HR@3 หรือ Precision@3	พื้นที่แสดงน้อยมาก และการโดนเพียงชิ้นเดียวก็ถือว่าสำเร็จ
ค้นคืนเอกสารสำหรับผู้เชี่ยวชาญ	ไม่พลาดเอกสารสำคัญแม้แต่ฉบับเดียว	Recall@100	ต้นทุนของการพลาดสูงกว่าต้นทุนของการอ่านเกิน
ระบบช่วยค้นภายในองค์กร	ผู้ใช้เจอคำตอบเร็วที่สุด	MRR	สนใจเฉพาะตำแหน่งของคำตอบที่ถูกต้องตัวแรก
จัดคิวเพลงต่อเนื่อง	ผู้ฟังไม่กดข้ามและฟังนาน	nDCG@20 ร่วมกับ ILD	ต้องถูกใจและไม่ซ้ำซากไปพร้อมกัน

2.6.3 ตัวชี้วัดกำกับ (Guardrail Metrics)

> **นิยาม 2.5 ตัวชี้วัดกำกับ (Guardrail Metrics)**
>
> ชุดตัวชี้วัดที่ประกาศไว้ล่วงหน้าพร้อม **เกณฑ์ตัวเลขที่ยอมรับได้** ว่าห้ามแย่ลงเกินกว่านั้น แม้ตัวชี้วัดหลักจะดีขึ้นก็ตาม หน้าที่ของตัวชี้วัดกำกับคือปิดช่องทางที่แบบจำลองจะ “โกง” ตัวชี้วัดหลักด้วยการทำลายคุณสมบัติอื่นที่เราไม่ได้วัด
>
> กฎการเขียนเกณฑ์ที่ใช้ได้จริงคือต้องเป็นประโยคที่ตรวจสอบด้วยโปรแกรมได้โดยไม่ต้องตีความ เช่น **“Coverage@10 ต้องไม่ต่ำกว่า 0.30”** ใช้ได้ ส่วน “ระบบต้องไม่ซ้ำซากเกินไป” ใช้ไม่ได้

กรณีศึกษา 2.1 ในหัวข้อที่แล้วคือตัวอย่างที่ชัดเจนที่สุดของการไม่มีตัวชี้วัดกำกับ แบบจำลองทำ nDCG@10 ดีขึ้นร้อยละ 13.9 ด้วยการแนะนำสิ่งที่คล้ายกับสิ่งที่ผู้ใช้เพิ่งดู ซึ่งเป็นวิธีเพิ่มคะแนนออฟไลน์ที่ได้ผลเสมอ แต่ทำลายประสบการณ์จริง หากทีมพัฒนาประกาศไว้ล่วงหน้าว่า ILD ห้ามลดต่ำกว่า 0.55 แบบจำลองรุ่นนั้นจะถูกปฏิเสธตั้งแต่ขั้นออฟไลน์ และไม่มีวันได้ขึ้นทดลองกับผู้ใช้จริง

ตารางที่ 2.6 *ตัวอย่างชุดตัวชี้วัดกำกับที่ใช้ได้จริง พร้อมเกณฑ์เชิงตัวเลขและเหตุผลของแต่ละข้อ*

ตัวชี้วัดกำกับ	เกณฑ์ตัวอย่าง	ปิดช่องโกงแบบใด
ความครอบคลุมคลัง (Catalog Coverage@10)	≥ 0.30	กันแบบจำลองที่แนะนำแต่รายการยอดนิยมไม่กี่สิบรายการวนไปมา
ความหลากหลายภายในรายการ (ILD@10)	≥ 0.55	กันรายการที่ซ้ำซากจนผู้ใช้เบื่อ เช่น แนะนำภาพยนตร์ชุดเดียวกันครบสิบช่อง
สัดส่วนรายการส่วนหาง (Long-tail Ratio@10)	≥ 0.20	กันการทอดทิ้งผู้ผลิตเนื้อหารายย่อยจนระบบนิเวศพังในระยะยาว
ค่าคลาดเคลื่อนการปรับเทียบ (Calibration Error)	≤ 0.15	กันการกลบความสนใจส่วนน้อยของผู้ใช้ให้หายไปจากรายการ
ช่องว่างความเป็นธรรมระหว่างกลุ่ม (Parity Gap)	≤ 0.05	กันการที่คุณภาพบริการดีเฉพาะกับผู้ใช้กลุ่มใหญ่
เวลาตอบสนองที่เปอร์เซ็นไทล์ 95 (p95 Latency)	≤ 120 ms	กันแบบจำลองที่แม่นแต่ช้าจนใช้งานจริงไม่ได้
ความครอบคลุมผู้ใช้ (User Coverage)	≥ 0.95	กันแบบจำลองที่ให้คำแนะนำไม่ได้เลยกับผู้ใช้ใหม่แล้วเงียบไว้

กรอบเจาะลึก การรวมตัวชี้วัดหลายตัวเป็นตัวเดียว ทำได้หรือไม่

ผู้อ่านบางท่านอาจสงสัยว่า เหตุใดจึงไม่รวมตัวชี้วัดทั้งหมดเป็นคะแนนเดียวด้วยผลรวมถ่วงน้ำหนัก แล้วเปรียบเทียบเพียงตัวเลขเดียว วิธีนี้เรียกว่า scalarization และมีข้อจำกัดเชิงทฤษฎีที่ต้องรู้

$$S = w_1 \cdot \text{nDCG@10} + w_2 \cdot \text{Coverage@10} + w_3 \cdot \text{ILD@10}, \quad \text{โดยที่ } \sum_j w_j = 1 \qquad (2.23)$$

ปัญหาข้อที่หนึ่ง ตัวชี้วัดแต่ละตัวมีสเกลและการกระจายต่างกัน การบวกกันตรง ๆ จึงไม่มีความหมายเชิงหน่วย ต้องทำให้เป็นมาตรฐานก่อนเสมอ และการเลือกวิธีทำให้เป็นมาตรฐานก็เปลี่ยนผู้ชนะได้

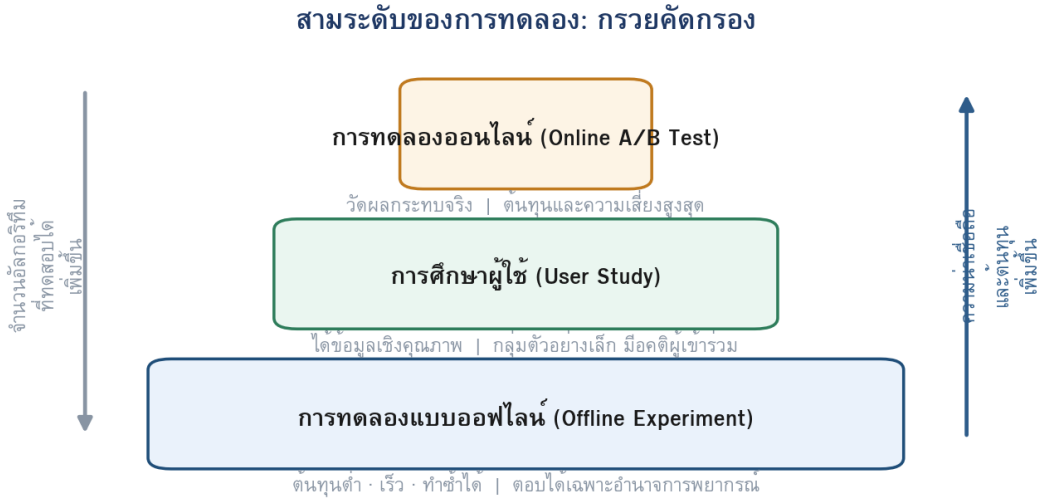
ปัญหาข้อที่สอง ผลรวมถ่วงน้ำหนักเชิงเส้นเข้าถึงได้เฉพาะจุดบนขอบเขตพาเรโต (Pareto Frontier) ที่เป็นส่วนนูนเท่านั้น หากขอบเขตพาเรโตมีส่วนเว้า จะมีคำตอบดี ๆ ที่ไม่มีค่าน้ำหนักชุดใดเลือกออกมาได้

ปัญหาข้อที่สาม ค่าน้ำหนักคือการตัดสินใจเชิงคุณค่า ไม่ใช่ข้อเท็จจริงเชิงเทคนิค การซ่อนมันไว้ในสูตรทำให้การอภิปรายที่ควรเกิดขึ้นระหว่างทีมพัฒนากับฝ่ายธุรกิจหายไป

ด้วยเหตุผลสามข้อนี้ ตำราเล่มนี้จึงแนะนำรูปแบบ **ตัวชี้วัดหลักหนึ่งตัวบวกตัวชี้วัดกำกับหลายตัวพร้อมเกณฑ์** ซึ่งเทียบเท่ากับการหาค่าเหมาะที่สุดแบบมีเงื่อนไขบังคับ (constrained optimization) และตีความง่ายกว่าอย่างมากในทางปฏิบัติ

2.7 รูปแบบการทดลองสามระดับ

รูปแบบการประเมินมีสามระดับที่ตอบคำถามต่างกัน: การทดลองออฟไลน์เหมาะกับการคัดกรองแบบจำลองจำนวนมาก, การศึกษาผู้ใช้ช่วยวัดการรับรู้และความพึงพอใจในสภาพควบคุม, และการทดลองออนไลน์วัดผลต่อพฤติกรรมจริง การประเมินที่น่าเชื่อถือใช้แต่ละระดับตามวัตถุประสงค์ ไม่ตีความคะแนนออฟไลน์เสมือนเป็นผลทางธุรกิจ



ภาพที่ 2.11 กรวยคัดกรองสามระดับของการทดลอง จากออฟไลน์ที่ถูกและเร็ว ไปสู่การทดลองออนไลน์ที่แพงแต่ตอบคำถามได้จริง

2.7.1 การทดลองแบบออฟไลน์ (Offline Experiment)

เป็นการนำข้อมูลบันทึกย้อนหลังมาแบ่งเป็นชุดฝึกกับชุดทดสอบ ฝึกแบบจำลองบนชุดฝึก แล้ววัดว่าแบบจำลองทำนายชุดทดสอบได้ดีเพียงใด ข้อดีคือถูก เร็ว ทำซ้ำได้ และไม่กระทบผู้ใช้จริง จึงเหมาะกับการคัดกรองแนวคิดจำนวนมากในขั้นต้น

แต่ต้องเข้าใจให้ชัดว่าการทดลองออฟไลน์ตอบได้เพียงคำถามเดียว คือ “แบบจำลองทำนายพฤติกรรมที่เคยเกิดขึ้นแล้วภายใต้ระบบเดิม ได้แม่นเพียงใด” ไม่ได้ตอบคำถามว่า “ถ้าเปลี่ยนไปใช้แบบจำลองนี้ ผู้ใช้จะมีพฤติกรรมอย่างไร” ซึ่งเป็นคำถามเชิงสาเหตุที่ข้อมูลย้อนหลังตอบไม่ได้โดยธรรมชาติ

2.7.2 การศึกษาผู้ใช้ (User Study)

เป็นการเชิญผู้เข้าร่วมกลุ่มเล็กมาใช้ระบบภายใต้เงื่อนไขที่ควบคุมได้ แล้วเก็บทั้งข้อมูลเชิงปริมาณ เช่น เวลาที่ใช้หาสิ่งที่ต้องการ และข้อมูลเชิงคุณภาพ เช่น เหตุผลที่ผู้ใช้ปฏิเสธคำแนะนำ ซึ่งเป็นข้อมูลที่ตัวเลขออฟไลน์ให้ไม่ได้เลย จุดอ่อนคือกลุ่มตัวอย่างเล็กและมีอคติจากการที่ผู้เข้าร่วมรู้ตัวว่ากำลังถูกสังเกต (ปรากฏการณ์ฮอว์ธอร์น) รวมทั้งผู้ที่ยินดีเข้าร่วมมักไม่ใช่ตัวแทนของผู้ใช้ทั่วไป

2.7.3 การทดลองออนไลน์ (Online A/B Test)

เป็นการสุ่มแบ่งผู้ใช้จริงออกเป็นกลุ่มควบคุมและกลุ่มทดลอง ให้แต่ละกลุ่มได้รับผลลัพธ์จากคนละแบบจำลอง แล้ววัดผลต่างของตัวชี้วัดทางธุรกิจ นี่คือรูปแบบเดียวในสามระดับที่ตอบคำถามเชิงสาเหตุได้จริง เพราะการสุ่มทำให้สองกลุ่มเทียบเคียงกันได้ในทุกด้านยกเว้นแบบจำลองที่ใช้ แลกมาด้วยต้นทุนสูงสุด

ความเสี่ยงต่อผู้ใช้จริง และเวลาที่ต้องรอเพื่อให้มีกำลังทดสอบเพียงพอ หัวข้อ 2.11 จะกล่าวถึงรายละเอียดของการออกแบบการทดลองออนไลน์

ตารางที่ 2.7 *การเปรียบเทียบรูปแบบการทดลองสามระดับ*

ประเด็นเปรียบเทียบ	ออฟไลน์	ศึกษาผู้ใช้	ออนไลน์ A/B
ต้นทุนต่อการทดลองหนึ่งครั้ง	ต่ำมาก	ปานกลาง	สูง
เวลาที่ใช้	นาทีถึงชั่วโมง	วันถึงสัปดาห์	สัปดาห์ถึงเดือน
จำนวนแนวคิดที่ทดสอบได้	หลายร้อย	หลักหน่วยถึงสิบ	หลักหน่วย
ทำซ้ำได้ด้วยเมล็ดสุ่มเดิม	ได้	ไม่ได้	ไม่ได้
ตอบคำถามเชิงสาเหตุได้	ไม่ได้	ได้บางส่วน	ได้
ความเสี่ยงต่อผู้ใช้จริง	ไม่มี	ต่ำ	สูง
เห็นเหตุผลเบื้องหลังพฤติกรรม	ไม่เห็น	เห็นชัดที่สุด	ไม่เห็น
บทบาทที่เหมาะสม	คัดกรองขั้นต้น	เข้าใจสาเหตุ	ตัดสินขั้นสุดท้าย

ประเด็นสำคัญ หลักการใช้งานทั้งสามระดับร่วมกัน

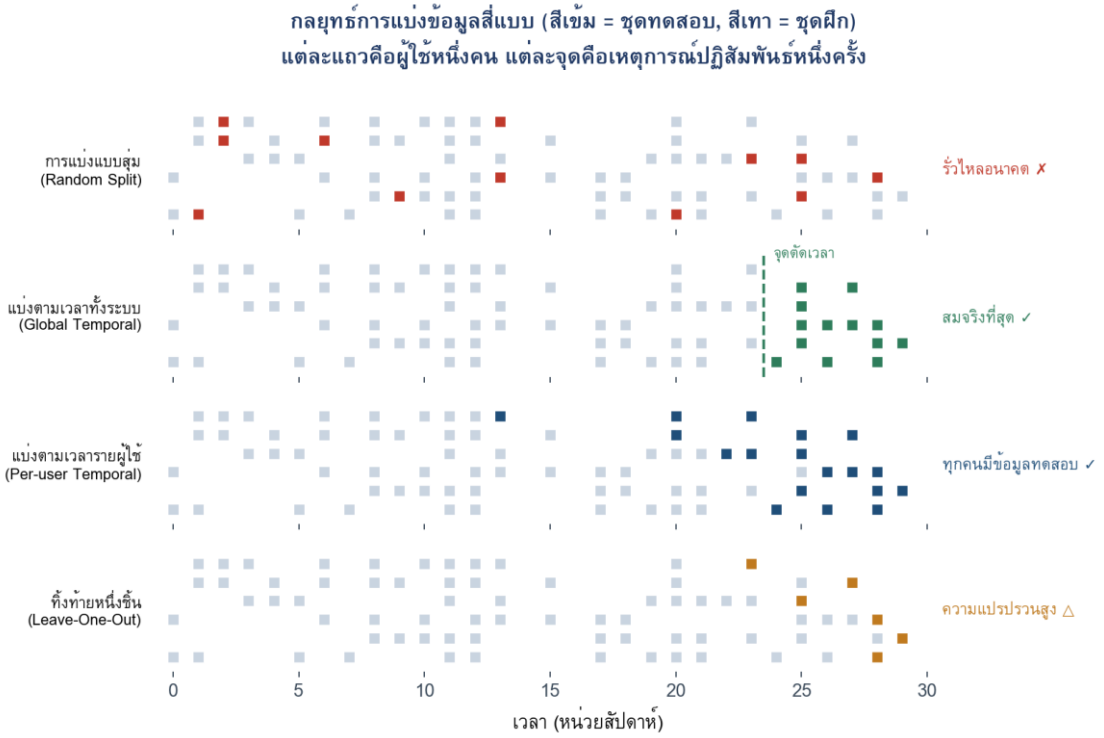
อย่ามองสามระดับนี้เป็นทางเลือกที่ต้องเลือกอย่างใดอย่างหนึ่ง แต่ให้มองเป็น **กรวยคัดกรอง** แนวคิดจำนวนมากเข้าที่ปากกรวย ผ่านการคัดออกด้วยการทดลองออฟไลน์ที่ถูกและเร็ว เหลือไม่กี่แนวคิดที่ไปสู่การศึกษาผู้ใช้เพื่อเข้าใจว่าเหตุใดจึงดีขึ้น และเหลือเพียงหนึ่งถึงสองแนวคิดที่คุ้มค่าจะนำขึ้นทดลองออนไลน์

หน้าที่ของการทดลองออฟไลน์จึงไม่ใช่การ “พิสูจน์ว่าดีกว่า” แต่คือการ **ตัดสิ่งที่แย่ทิ้งให้เร็วที่สุดด้วยต้นทุนต่ำที่สุด** เมื่อเข้าใจบทบาทนี้ตรงกัน การถกเถียงว่าตัวเลขออฟไลน์ “เชื่อได้หรือไม่” ก็หมดความจำเป็นไปเอง

2.8 การแบ่งข้อมูลตามเวลาและข้อมูลรั่วไหล

การแบ่งข้อมูลต้องเลียนแบบลำดับเหตุการณ์จริง: ใช้อดีตเพื่อฝึกและใช้เหตุการณ์ที่เกิดภายหลังเพื่อทดสอบ หากสุ่มเหตุการณ์ข้ามเวลา ข้อมูลอนาคตอาจรั่วเข้าสู่ชุดฝึก ทำให้แบบจำลองดูแม่นกว่าที่จะเป็นเมื่อใช้งานจริง แม้โปรแกรมจะทำงานสำเร็จและตัวเลขดูสมเหตุสมผลก็ตาม

2.8.1 กลยุทธ์การแบ่งข้อมูลสี่แบบ



ภาพที่ 2.12 กลยุทธ์การแบ่งข้อมูลสี่แบบบนแกนเวลา แต่ละแถวคือผู้ใช้หนึ่งคน แต่ละจุดคือปฏิสัมพันธ์หนึ่งครั้ง

ภาพที่ 2.12 แสดงกลยุทธ์การแบ่งข้อมูลสี่แบบที่ใช้กันแพร่หลาย จุดสีเทาคือเหตุการณ์ที่ถูกจัดเข้าชุดฝึก จุดสีเข้มคือเหตุการณ์ที่ถูกจัดเข้าชุดทดสอบ ให้สังเกตแถวบนสุดเป็นพิเศษ

1. **การแบ่งแบบสุ่ม (Random Split)** สุ่มเลือกเหตุการณ์ร้อยละ 20 ไปเป็นชุดทดสอบโดยไม่สนใจเวลา เห็นได้ชัดจากภาพว่าจุดสีเข้มกระจายอยู่ทั่วแกนเวลา แปลว่าชุดฝึกมีเหตุการณ์ที่เกิดขึ้น **หลัง** เหตุการณ์ในชุดทดสอบ ซึ่งเป็นการใช้อนาคตทำนายอดีตโดยตรง
2. **การแบ่งตามเวลาทั้งระบบ (Global Temporal Split)** กำหนดจุดตัดเวลาจุดเดียวสำหรับทั้งระบบ เหตุการณ์ก่อนจุดตัดเป็นชุดฝึก หลังจุดตัดเป็นชุดทดสอบ วิธีนี้จำลองสถานการณ์การใช้งานจริงได้ตรงที่สุด เพราะระบบจริงย่อมมีข้อมูลได้เพียงถึงปัจจุบันเท่านั้น
3. **การแบ่งตามเวลารายผู้ใช้ (Per-User Temporal Split)** เรียงเหตุการณ์ของผู้ใช้แต่ละคนตามเวลา แล้วกันส่วนท้ายร้อยละ 20 ของแต่ละคนไว้เป็นชุดทดสอบ ข้อดีคือผู้ใช้ทุกคนมีข้อมูลทดสอบแน่นอน ข้อเสียคือจุดตัดของแต่ละคนไม่ตรงกัน จึงยังมีการรั่วไหลข้ามผู้ใช้หลงเหลืออยู่
4. **การกันรายการสุดท้ายหนึ่งชิ้น (Leave-One-Out)** กันเหตุการณ์ล่าสุดของผู้ใช้แต่ละคนไว้เพียงหนึ่งชิ้น เป็นแบบที่นิยมที่สุดในงานตีพิมพ์ เพราะให้ข้อมูลฝึกมากที่สุด แต่มีความแปรปรวนสูงมาก เนื่องจากตัดสินผู้ใช้หนึ่งคนด้วยเหตุการณ์เพียงหนึ่งครั้ง

2.8.2 หลักฐานเชิงตัวเลข วิธีแบ่งข้อมูลเปลี่ยนคำตอบได้มากเพียงใด

เพื่อให้เห็นขนาดของปัญหาอย่างเป็นรูปธรรม การทดลองต่อไปนี้ใช้ แบบจำลองเดิมทุกประการ ข้อมูลชุดเดิมทุกประการ และตัวชี้วัดเดิมทุกประการ เปลี่ยนเพียงวิธีแบ่งข้อมูลเท่านั้น ผลที่ได้แสดงในตารางที่ 2.8 และ 2.5 ผู้อ่านทำซ้ำได้ด้วยโปรแกรม lab2_03_leakage_temporal.py

ตารางที่ 2.8 *การตรวจจับการรั่วไหลของเวลาในกลยุทธ์การแบ่งข้อมูลสี่แบบ บนชุดข้อมูล RSLab-Eval*

วิธีแบ่งข้อมูล	ขนาดชุดฝึก	ขนาดชุดทดสอบ	เหตุการณ์อนาคตที่ปนในชุดฝึก	ผลการตรวจ
สุ่ม (Random)	17,357	4,339	17,355 (100.0%)	**พบการรั่วไหล**
ตามเวลาแบบรวม (Global Temporal)	17,356	4,340	0 (0.0%)	**ปลอดภัย**
ตามเวลารายผู้ใช้ (Per-User Temporal)	17,355	4,341	6,257 (36.1%)	**พบการรั่วไหล**
กันรายการสุดท้าย (Leave-One-Out)	20,896	800	4,557 (21.8%)	**พบการรั่วไหล**

ตัวเลขในคอลัมน์ที่สี่คือจำนวนเหตุการณ์ในชุดฝึกที่มีเวลาเกิดขึ้น หลังกว่า เหตุการณ์ที่เก่าที่สุดในชุดทดสอบ ค่าร้อยละ 100.0 ของการแบ่งแบบสุ่มหมายความว่า แทบทุกเหตุการณ์ในชุดฝึกอยู่ในอนาคตของบางเหตุการณ์ในชุดทดสอบ ซึ่งเป็นสภาพที่เป็นไปไม่ได้ในระบบจริง

ตารางที่ 2.9 *ค่า nDCG@10 ของแบบจำลอง TopPopular ตัวเดียวกัน เมื่อเปลี่ยนเฉพาะวิธีแบ่งข้อมูล*

วิธีแบ่งข้อมูล	nDCG@10	จำนวนผู้ใช้ที่ประเมินได้	เทียบกับการแบ่งตามเวลา
สุ่ม (Random)	0.0921	756	**+71.6%**
ตามเวลาแบบรวม (Global Temporal)	0.0537	752	**— (ค่าอ้างอิง)**
ตามเวลารายผู้ใช้ (Per-User Temporal)	0.0579	789	+7.9%
กันรายการสุดท้าย (Leave-One-Out)	0.0375	421	−30.1%

ข้อควรระวัง อ่านตารางที่ 2.9 ให้ถูกต้อง

การแบ่งแบบสุ่มทำให้ค่า nDCG@10 สูงกว่าการแบ่งตามเวลาถึงร้อยละ 71.6 **โดยที่แบบจำลองไม่ได้ดีขึ้นเลยแม้แต่น้อย** เพราะเป็นแบบจำลองตัวเดียวกันทุกบรรทัดของโปรแกรม สิ่งที่เปลี่ยนไปมีเพียงความยากของ “สนามสอบ” เท่านั้น

กลไกที่ทำให้เกิดผลนี้คือ ชุดข้อมูล RSLab-Eval ออกแบบให้ความนิยมเลื่อนตามเวลา (popularity drift) เมื่อแบ่งแบบสุ่ม แบบจำลอง TopPopular ได้เห็นความนิยม **ในสัปดาห์เดียวกับที่ต้องทำนาย** จึงทำนายได้แม่นผิดปกติ ในขณะที่ระบบจริงไม่มีทางรู้ความนิยมของสัปดาห์หน้าล่วงหน้าได้

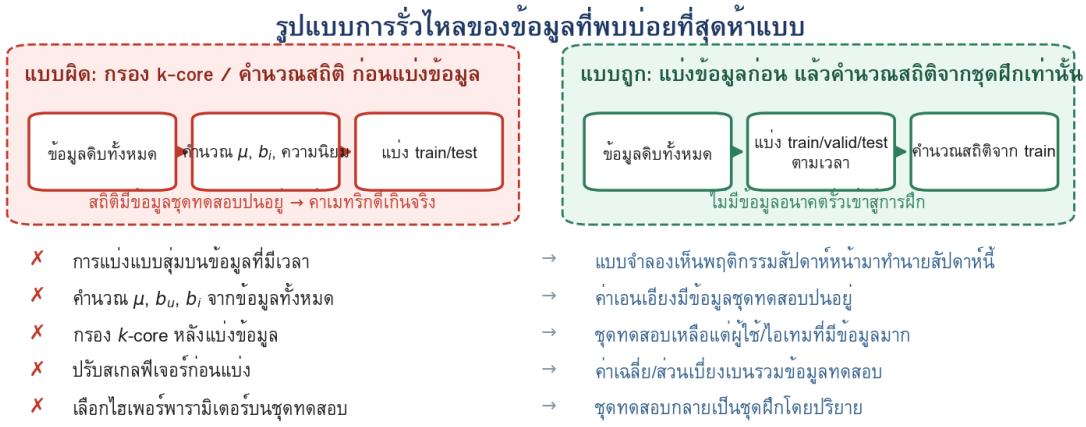
สมบัติความนิยมเลื่อนตามเวลานี้ไม่ใช่สิ่งที่ประดิษฐ์ขึ้นเพื่อการสาธิต แต่เป็นสมบัติที่ข้อมูลจริงทุกชุดมี ไม่ว่าจะเป็นภาพยนตร์ เพลง ข่าว หรือสินค้า ผลร้อยละ 71.6 นี้จึงไม่ใช่กรณีสุดโต่ง แต่เป็นสิ่งที่คาดหมายได้

จุดที่ต้องระวังอีกจุดหนึ่งคือคอลัมน์ “จำนวนผู้ใช้ที่ประเมินได้” การกันรายการสุดท้ายหนึ่งชิ้นประเมินได้เพียง 421 คนจาก 800 คน เพราะผู้ใช้จำนวนมากมีรายการสุดท้ายที่ไม่ผ่านเกณฑ์ความเกี่ยวข้อง การเปรียบเทียบค่า 0.0375 กับค่า 0.0537 จึงไม่ใช่การเปรียบเทียบที่ยุติธรรม เพราะเป็นการวัดบนประชากรคนละกลุ่ม ข้อสังเกตนี้นำไปสู่กฎที่ว่า เมื่อรายงานผลต้องรายงานจำนวนผู้ใช้ที่ประเมินได้ควบคู่ไปกับค่าตัวชี้วัดเสมอ

2.8.3 รูปแบบการรั่วไหลของข้อมูลที่พบบ่อย

นิยาม 2.6 การรั่วไหลของข้อมูล (Data Leakage)

สภาวะที่ข้อมูลซึ่งไม่ควรมีอยู่ในขั้นตอนการฝึก ได้เข้าไปมีอิทธิพลต่อแบบจำลองหรือค่าที่แบบจำลองใช้ ไม่ว่าจะโดยตรงหรือโดยอ้อม ผลของการรั่วไหลคือค่าตัวชี้วัดที่รายงานสูงเกินความสามารถจริงของระบบ และการรั่วไหลนั้นจะไม่ปรากฏเป็นข้อผิดพลาดใด ๆ ในโปรแกรมเลย



ภาพที่ 2.13 รูปแบบการรั่วไหลที่พบบ่อยที่สุดห้าแบบ และลำดับขั้นตอนที่ถูกต้อง คือแบ่งข้อมูลก่อนคำนวณสถิติใด ๆ

ตารางที่ 2.10 *รูปแบบการรั่วไหลของข้อมูลห้าแบบ อาการที่สังเกตได้ และวิธีแก้*

รูปแบบการรั่วไหล	สิ่งที่เกิดขึ้นจริง	วิธีแก้
แบ่งข้อมูลแบบสุ่มทั้งที่ข้อมูลมีมิติเวลา	แบบจำลองเห็นพฤติกรรมของสัปดาห์หน้ามาทำนายสัปดาห์นี้	ใช้จุดตัดเวลาเสมอเมื่อข้อมูลมีเวลากำกับ
คำนวณ μ, bu, bi หรือความนิยมจากข้อมูลทั้งหมด	ค่าคงที่แบบจำลองใช้มีข้อมูลชุดทดสอบปนอยู่	คำนวณสถิติทุกตัวจากชุดฝึกเท่านั้น
กรอง k-core หลังแบ่งข้อมูล	ชุดทดสอบเหลือแต่ผู้ใช้และรายการที่มีข้อมูลมาก งานจึงง่ายเกินจริง	กรอง k-core ก่อนแบ่ง แล้วรายงานเงื่อนไขการกรองให้ชัด
ปรับสเกลฟีเจอร์ก่อนแบ่งข้อมูล	ค่าเฉลี่ยและส่วนเบี่ยงเบนมาตรฐานที่ใช้ปรับสเกล รวมข้อมูลชุดทดสอบไว้ด้วย	ปรับสเกลด้วยพารามิเตอร์ที่ได้จากชุดฝึกเท่านั้น

รูปแบบการรั่วไหล	สิ่งที่เกิดขึ้นจริง	วิธีแก้
เลือกไฮเปอร์พารามิเตอร์บนชุดทดสอบ	ชุดทดสอบกลายเป็นชุดตรวจสอบโดยปริยาย ค่าที่รายงานจึงมองโลกในแง่ดีเกินไป	แบ่งสามส่วน ฝึก–ตรวจสอบ–ทดสอบ และเปิดชุดทดสอบเพียงครั้งเดียว

2.8.4 การรั่วไหลจากสถิติ ตัวอย่างที่ไม่มีบรรทัดใดดูผิดเลย

รูปแบบการรั่วไหลที่อันตรายที่สุดไม่ใช่การแบ่งแบบสุ่ม เพราะอย่างน้อยการแบ่งแบบสุ่มก็ยังมองเห็นได้จากโค้ด แต่คือการคำนวณสถิติจากข้อมูลทั้งหมดก่อนแบ่ง ซึ่งเขียนออกมาแล้วดูสะอาดตาและเป็นธรรมชาติมาก

เปรียบเทียบลำดับขั้นตอนที่ผิดกับที่ถูก

```
# แบบผิด — คำนวณความนิยมก่อนแบ่งข้อมูล
pop = df.groupby('item_id').size()          # <-- ใช้ข้อมูลทั้งหมด รวมชุดทดสอบ
train, test = global_temporal_split(df, 0.2)
model.fit(train, popularity=pop)            # ความนิยมมีอนาคตปนอยู่แล้ว
# แบบถูก — แบ่งข้อมูลก่อน แล้วจึงคำนวณสถิติจากชุดฝึกเท่านั้น
train, test = global_temporal_split(df, 0.2)
pop = train.groupby('item_id').size()       # <-- ใช้เฉพาะชุดฝึก
model.fit(train, popularity=pop)
```

ตัวอย่างการคำนวณ 2.13 ขนาดของผลกระทบจากการรั่วไหลของสถิติ

การทดลองใช้แบบจำลอง TopPopular และการแบ่งตามเวลาแบบรวมเหมือนกันทุกประการ ต่างกันเพียงว่าคำนวณความนิยมจากที่ใด

กรณี	แหล่งที่มาของความนิยม	nDCG@10	ส่วนต่าง
ทำถูก	ชุดฝึกเท่านั้น	0.0537	— (ค่าจริง)
ทำผิด	ข้อมูลทั้งหมดก่อนแบ่ง	0.0561	+4.6%

ส่วนต่างร้อยละ 4.6 อาจดูน้อย แต่ต้องเทียบกับบริบทของสาขานี้ที่งานตีพิมพ์จำนวนมากอ้างการปรับปรุงในระดับร้อยละ 2 ถึง 5 เท่านั้น **การรั่วไหลเพียงบรรทัดเดียวจึงกลบผลของวิธีการใหม่ได้ทั้งหมด**

ที่น่ากังวลกว่าคือ ในโปรแกรมฉบับผิดไม่มีบรรทัดใดที่ *ดูเหมือน* ผิดเลย ผู้ตรวจอ่านโค้ดผ่านสายตาจึงจับไม่ได้ ทางเดียวที่ป้องกันได้คือถือเป็นวินัยว่า การแบ่งข้อมูลต้องเป็นคำสั่งแรกเสมอ ก่อนการคำนวณใด ๆ แม้แต่ค่าเฉลี่ยหรือการสร้างพจนานุกรมรายการ

กรอบเจาะลึก การแบ่งข้อมูลแบบเลื่อนหน้าต่างเวลาสำหรับการประเมินที่เข้มงวด

การแบ่งด้วยจุดตัดเวลาจุดเดียวมีข้อจำกัดคือ ผลที่ได้ขึ้นกับว่าเราเลือกจุดตัดไว้ที่ใด หากช่วงเวลาที่ใช้ทดสอบบังเอิญมีเหตุการณ์พิเศษ เช่น เทศกาลหรือการเปิดตัวเนื้อหาใหญ่ ข้อสรุปทั้งหมดอาจเป็นผลของช่วงเวลานั้นมากกว่าเป็นผลของแบบจำลอง

แนวทางที่เข้มงวดกว่าคือการประเมินแบบเลื่อนหน้าต่างเวลา (Rolling-Origin Evaluation) ซึ่งยืมมาจากการพยากรณ์อนุกรมเวลา มีขั้นตอนดังนี้

- กำหนดจุดตัดหลายจุด เช่น $t_1 < t_2 < \ldots < t_m$ ห่างกันจุดละหนึ่งสัปดาห์
- ที่จุดตัด t_k ฝึกด้วยข้อมูลทั้งหมดก่อน t_k และทดสอบด้วยข้อมูลในช่วง $(t_k, t_{k+1}]$
- ทำซ้ำทุกจุดตัด แล้วรายงานค่าเฉลี่ยพร้อมส่วนเบี่ยงเบนมาตรฐานข้ามจุดตัด

ประโยชน์ที่ได้มีสองข้อ ข้อแรกคือได้ค่าประมาณที่ไม่ขึ้นกับความบังเอิญของช่วงเวลาใดช่วงเวลาหนึ่ง ข้อที่สองซึ่งสำคัญกว่าคือ ส่วนเบี่ยงเบนมาตรฐานข้ามจุดตัดบอกเราได้ว่า **แบบจำลองมีเสถียรภาพตามเวลาเพียงใด** ซึ่งเป็นข้อมูลที่การแบ่งจุดตัดเดียวให้ไม่ได้เลย และเป็นข้อมูลที่ทีมปฏิบัติการต้องการมากที่สุด

ต้นทุนคือต้องฝึกแบบจำลอง m ครั้งแทนที่จะเป็นครั้งเดียว ในทางปฏิบัติจึงนิยมใช้ m ระหว่าง 4 ถึง 8 ซึ่งเพียงพอให้ประมาณความแปรปรวนได้ในต้นทุนที่ยอมรับได้

2.9 เต็มบัญชีรายการ เทียบกับ การสุ่มรายการเชิงลบ

ข้อควรระวัง หัวข้อนี้สำคัญที่สุดของทั้งบท

หากผู้อ่านมีเวลาอ่านบทนี้เพียงหัวข้อเดียว ขอให้เลือกหัวข้อนี้ เพราะเป็นความผิดพลาดเชิงระเบียบวิธีที่แพร่หลายที่สุดในงานตีพิมพ์ด้านระบบผู้แนะนำ และเป็นความผิดพลาดที่ไม่เพียงทำให้ตัวเลขผิด แต่ทำให้ **ข้อสรุปว่าแบบจำลองใดดีกว่า กลับด้านได้ทั้งหมด**

2.9.1 เซตผู้สมัครคืออะไร และเหตุใดจึงต้องประกาศ

นิยาม 2.7 เซตผู้สมัคร (Candidate Set)

เซตของรายการที่แบบจำลองต้องนำมาจัดอันดับเพื่อเลือก Top-K ในการประเมินหนึ่งครั้ง การเลือกเซตผู้สมัครมีสองแนวทางหลัก

- **การจัดอันดับเต็มบัญชีรายการ (Full-Catalog Ranking)** นำรายการทั้งหมดในคลังที่ผู้ใช้ยังไม่เคยมีปฏิสัมพันธ์ในชุดฝึก มาจัดอันดับทั้งหมด
- **การสุ่มรายการเชิงลบ (Sampled Negatives)** นำรายการเป้าหมายหนึ่งชิ้นมารวมกับรายการที่ผู้ใช้ไม่เคยมีปฏิสัมพันธ์ซึ่งสุ่มมา m ชิ้น แล้วจัดอันดับเฉพาะ m+1 ชิ้นนี้ ค่าที่นิยมใช้คือ m = 99 หรือ m = 100

เหตุผลที่แนวทางที่สองเกิดขึ้นคือต้นทุนการคำนวณ ในคลังขนาดหลายล้านรายการ การจัดอันดับเต็มบัญชีสำหรับผู้ใช้ทุกคนใช้เวลามหาศาล การสุ่มจึงลดต้นทุนลงได้หลายพันเท่า

2.9.2 กลไกที่ทำให้การสุ่ม “ยกคะแนน” ทั้งที่แบบจำลองไม่ได้ดีขึ้น

ตัวอย่างต่อไปนี้เป็นตัวอย่างที่ผู้เขียนใช้สอนเป็นประจำ เพราะแสดงกลไกได้ชัดที่สุดด้วยตัวเลขชุดเดียว

ตัวอย่างการคำนวณ 2.14 รายการเป้าหมายอยู่อันดับที่ 500 จากคลัง 5,000 รายการ

สมมติสถานการณ์ แบบจำลองหนึ่งจัดอันดับรายการที่ผู้ใช้ชอบจริงไว้ที่อันดับ 500 จากคลังทั้งหมด 5,000 รายการ กำหนด K = 10

กรณีที่ 1 จัดอันดับเต็มบัญชีรายการ

อันดับจริง = 500 ซึ่งมากกว่า K = 10 รายการเป้าหมายจึงไม่ปรากฏใน Top-10 เลย

$$\text{nDCG@10} = 0.0000 \quad \text{(ศูนย์สนิท)}$$

กรณีที่ 2 สุ่มรายการเชิงลบ m = 99 ชิ้น

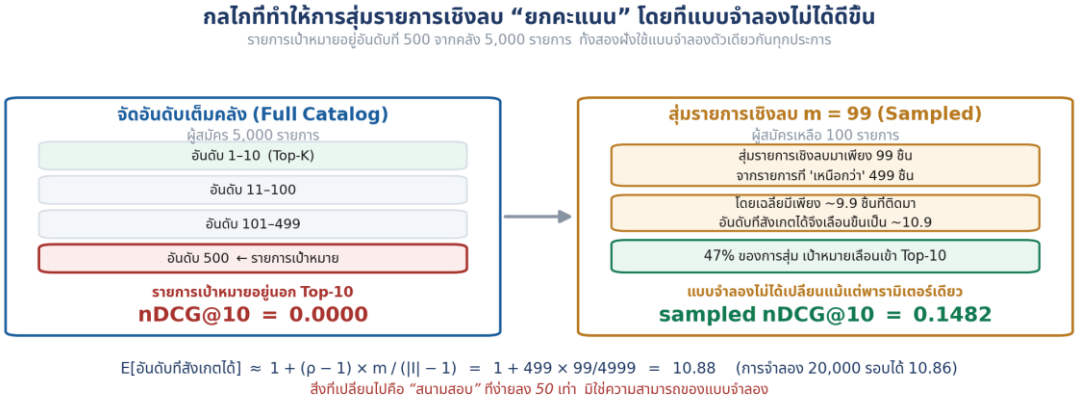
รายการที่ “เหนือกว่า” รายการเป้าหมายมีอยู่ 499 ชิ้น ในคลังรายการเชิงลบทั้งหมด 4,999 ชิ้น เมื่อสุ่มมาเพียง 99 ชิ้น จำนวนของรายการที่เหนือกว่าซึ่งติดมาด้วยเป็นตัวแปรสุ่มไฮเพอร์จีออเมตริก มีค่าคาดหวังเท่ากับ $499 \times 99 / 4{,}999 \approx 9.88$ ชิ้น อันดับที่สังเกตได้จึงเป็น

$$E[\text{อันดับที่สังเกตได้}] = 1 + 499 \times 99 / 4{,}999 = 1 + 9.88 = 10.88 \quad (2.24)$$

การจำลอง 20,000 รอบให้ค่าเฉลี่ย 10.86 ซึ่งตรงกับทฤษฎี และพบว่ามีถึง **ร้อยละ 47.0** ของการสุ่มที่รายการเป้าหมายเลื่อนเข้ามาอยู่ใน Top-10 ค่าเฉลี่ยของ nDCG@10 จึงเท่ากับ

$$\text{sampled nDCG@10} = 0.1482$$

บทสรุปที่ต้องอ่านช้า ๆ ตัวเลขกระโดดจาก 0.0000 เป็น 0.1482 โดยที่โปรแกรมไม่ได้เปลี่ยนพารามิเตอร์ของแบบจำลองแม้แต่ตัวเดียว **แบบจำลองไม่ได้ดีขึ้นเลย มีเพียง “สนามสอบ” ที่ง่ายขึ้น 50 เท่า** จาก 5,000 ตัวเลือกเหลือ 100 ตัวเลือก



ภาพที่ 2.14 กลไกที่ทำให้การสุ่มรายการเชิงลบยกคะแนนขึ้น ทั้งที่แบบจำลองเป็นตัวเดิมทุกประการ

กรอบเจาะลึก ที่มาของสูตรอันดับคาดหวังและเหตุผลที่สูตรนี้ไม่ช่วยแก้ปัญหา

ให้ ρ คืออันดับจริงของรายการเป้าหมายในคลังขนาด $|\mathcal{I}|$ และสุ่มรายการเชิงลบมา m ชิ้นแบบสม่ำเสมอ จำนวนรายการที่เหนือกว่าเป้าหมายและถูกสุ่มติดมา เป็นตัวแปรสุ่มไฮเพอร์จีออเมตริกที่มีค่าคาดหวัง $(\rho - 1) \cdot m / (|\mathcal{I}| - 1)$ จึงได้

$$E[\rho] \approx 1 + (\rho - 1) \cdot m / (|\mathcal{I}| - 1) \quad (2.25)$$

สูตรนี้เป็นการแปลงเชิงเส้นของอันดับ กล่าวคือการสุ่ม “บีบ” อันดับทุกตัวเข้าหา 1 ด้วยตัวประกอบคงที่ $m/(|\mathcal{I}|-1)$ เท่ากันหมด ผู้อ่านจึงอาจคิดว่า ในเมื่อมันบีบทุกแบบจำลองเท่ากัน การเปรียบเทียบก็น่าจะยังยุติธรรม

ข้อคิดนี้ผิด และเหตุผลอยู่ตรงนี้พอดี

nDCG@K ไม่ใช่ฟังก์ชันเชิงเส้นของอันดับ แต่มี **จุดตัดแข็ง (Hard Cutoff) ที่ K** อันดับ 11 ให้ค่า 0 ในขณะที่อันดับ 10 ให้ค่า 0.2891 การประกอบฟังก์ชันไม่เชิงเส้นเข้ากับการแปลงเชิงเส้นไม่รักษาลำดับของค่าเฉลี่ย นั่นคือโดยทั่วไปแล้ว

$$E[f(\rho_A)] > E[f(\rho_B)] \quad \text{ไม่ได้บอกอะไรเลยเกี่ยวกับ} \quad E[f(\rho_A)] \text{ เทียบกับ } E[f(\rho_B)] \tag{2.26}$$

ข้อสังเกตนี้เป็นผลหลักของงาน Krichene และ Rendle ที่ตีพิมพ์ในการประชุม KDD ปี ค.ศ. 2020 ซึ่งสั่นสะเทือนวรรณกรรมด้านนี้ทั้งสาขา เพราะแปลว่างานตีพิมพ์จำนวนมากที่ใช้ m = 100 อาจสรุปผู้ชนะผิดโดยที่การคำนวณทุกบรรทัดถูกต้อง

2.9.3 การตรวจสอบสูตรด้วยการจำลอง

ตารางที่ 2.11 ตรวจสอบว่าสูตร 2.25 ทำนายผลได้แม่นเพียงใด โดยเปรียบเทียบค่าที่คำนวณจากสูตรกับค่าเฉลี่ยจากการจำลอง 8,000 รอบต่อกรณี บนคลังขนาด 5,000 รายการ

ตารางที่ 2.11 *การตรวจสอบสูตรอันดับคาดหวังกับการจำลอง และผลกระทบต่อ sampled nDCG@10*

อันดับจริง ρ	m	ทฤษฎี (สูตร 2.25)	จำลอง	สัดส่วนที่เข้า Top-10	sampled nDCG@10
3	99	1.04	1.04	100.0%	0.9854
3	999	1.40	1.41	100.0%	0.8587
12	99	1.22	1.21	100.0%	0.9279
12	999	3.20	3.22	100.0%	0.5367
60	99	2.17	2.17	100.0%	0.6911
60	999	12.79	12.84	22.7%	0.0694
200	99	4.94	4.92	99.4%	0.4219
200	999	40.77	40.73	0.0%	0.0000
500	99	10.88	10.90	46.0%	0.1446
500	999	100.72	100.73	0.0%	0.0000

ตารางนี้ให้ข้อมูลที่ใช้ประโยชน์ได้ทันทีสามข้อ ข้อแรกคือทฤษฎีตรงกับการจำลองทุกกรณี จึงใช้สูตร 2.25 ประมาณผลกระทบล่วงหน้าได้โดยไม่ต้องรันการทดลอง ข้อที่สองคือรายการที่อยู่อันดับ 12 ซึ่ง หลุด Top-10 ในความเป็นจริง ได้ sampled nDCG@10 = 0.9279 ที่ m = 99 ซึ่งเกือบสมบูรณ์แบบ ข้อที่สามคือเมื่อเพิ่ม m เป็น

999 ค่าที่ได้เข้าใกล้ความจริงมากขึ้นทุกแถว แสดงว่าปัญหาบรรเทาลงเมื่อ m ใหญ่ขึ้น แต่ไม่หายไปจนกว่า m จะเท่ากับขนาดคลังทั้งหมด

2.9.4 การสลับผู้ชนะ (Winner Flip)

ถึงจุดนี้ผู้อ่านอาจยังคิดว่า ตัวเลขที่สูงเกินจริงเป็นเรื่องน่ารำคาญแต่ไม่ร้ายแรง เพราะหากทุกแบบจำลองถูกยกคะแนนเท่ากัน อันดับก็ยังคงเดิม การทดลองต่อไปนี้ออกแบบมาเพื่อหักล้างความคิดนั้นโดยตรง

ตัวอย่างการคำนวณ 2.15 แบบจำลอง P เทียบกับแบบจำลอง Q บนคลัง 500 รายการ ผู้ใช้ 800 คน

การออกแบบ

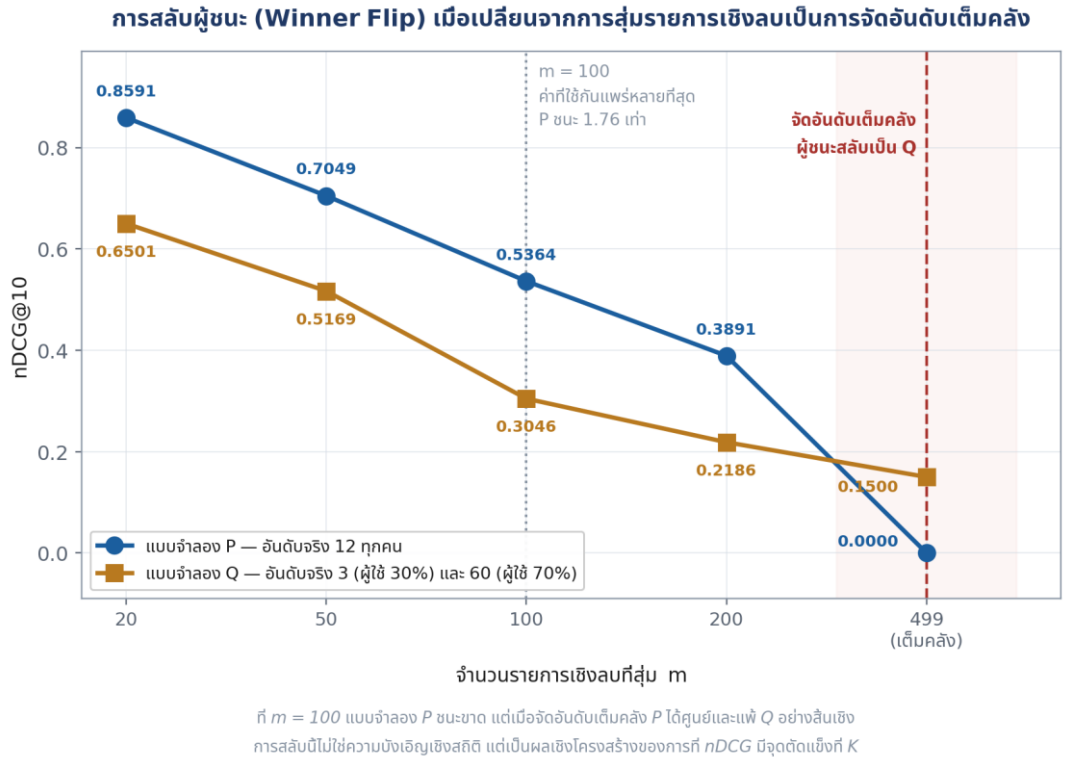
- **แบบจำลอง P** จัดรายการเป้าหมายไว้ที่อันดับ 12 สำหรับผู้ใช้ ทุกคน เป็นแบบจำลองที่สม่ำเสมอมาก แต่หลุด Top-10 เสมอ
- **แบบจำลอง Q** จัดรายการเป้าหมายไว้ที่อันดับ 3 สำหรับผู้ใช้ร้อยละ 30 และอันดับ 60 สำหรับที่เหลือร้อยละ 70 เป็นแบบจำลองที่เก่งมากกับคนบางกลุ่มและแย่มากกับที่เหลือ

คำถามคือ แบบจำลองใดดีกว่าสำหรับระบบที่แสดงผลเพียงสิบอันดับแรก คำตอบขึ้นกับว่าเราวัดอย่างไร

m	nDCG@10 ของ P	nDCG@10 ของ Q	ผู้ชนะ	อัตราส่วน
20	0.8591	0.6501	P	1.32 เท่า
50	0.7049	0.5169	P	1.36 เท่า
100	0.5364	0.3046	P	1.76 เท่า
200	0.3891	0.2186	P	1.78 เท่า
499 (เต็มคลัง)	**0.0000**	**0.1500**	Q	แพ้สิ้นเชิง

ที่ m = 100 ซึ่งเป็นค่าที่ใช้กันแพร่หลายที่สุดในวรรณกรรม แบบจำลอง P ชนะ Q ด้วยอัตราส่วน 1.76 เท่า แต่เมื่อจัดอันดับเต็มบัญชีรายการ P ได้ศูนย์สนิทและแพ้ Q อย่างสิ้นเชิง

ผู้ชนะสลับกัน และการสลับนี้ไม่ใช่ความบังเอิญเชิงสถิติที่จะหายไปเมื่อเพิ่มจำนวนตัวอย่าง แต่เป็นผลเชิงโครงสร้างของการที่ nDCG มีจุดตัดแข็งที่ K แบบจำลอง P ถูกการสุ่มช่วย “อุ้ม” เข้ามาใน Top-10 อย่างสม่ำเสมอเพราะอันดับจริงอยู่ที่ 12 ซึ่งใกล้เส้นมาก ในขณะที่ผู้ใช้ร้อยละ 70 ของแบบจำลอง Q อยู่ที่อันดับ 60 ซึ่งไกลเกินกว่าจะถูกอุ้มขึ้นมาได้



ภาพที่ 2.15 การสลับผู้ชนะเมื่อเปลี่ยนจากการสุ่มรายการเชิงลบเป็นการจัดอันดับเต็มบัญชีรายการ

2.9.5 แนวปฏิบัติที่ควรทำ

ข้อสรุปของหัวข้อนี้ไม่ใช่การห้ามใช้การสุ่มรายการเชิงลบโดยเด็ดขาด เพราะในระบบขนาดใหญ่จริง การจัดอันดับเต็มบัญชีอาจใช้ทรัพยากรเกินกว่าจะทำได้ในทุกรอบการทดลอง แต่คือการกำหนดเงื่อนไขการรายงานให้ชัดเจน เพื่อให้ผู้อ่านตีความตัวเลขได้ถูกต้อง

ประเด็นสำคัญ ข้อกำหนดห้าข้อเมื่อจำเป็นต้องใช้การประเมินแบบสุ่ม

1. **ระบุจำนวนรายการเชิงลบ m และวิธีสุ่มให้ครบ** ว่าสุ่มแบบสม่ำเสมอ สุ่มตามความนิยม หรือสุ่มภายในหมวดเดียวกัน เพราะวิธีสุ่มต่างกันให้ผลต่างกันมาก
2. **เรียกค่าที่ได้ว่า sampled nDCG@K ไม่ใช่ nDCG@K เฉย ๆ** เพื่อไม่ให้ผู้อ่านเข้าใจผิดว่าเทียบกับงานที่จัดอันดับเต็มบัญชีได้
3. **หากทรัพยากรเอื้ออำนวย ให้รายงานทั้งสองค่า** แล้วตรวจว่าอันดับของแบบจำลองตรงกันหรือไม่ หากไม่ตรง ต้องรายงานความไม่ตรงนั้นอย่างเปิดเผย
4. **ห้ามเปรียบเทียบค่าที่ m ต่างกัน** และห้ามนำ sampled metric ของตนไปเทียบกับ full metric ของงานอื่นโดยเด็ดขาด
5. **หาก m น้อยกว่า 50 ให้ถือว่าผลเป็นเพียงการคัดกรองเบื้องต้น** ไม่ใช่ข้อสรุปที่ใช้ตัดสินได้

ภาคปฏิบัติ ทางเลือกที่ใช้ได้จริงเมื่อคลังใหญ่เกินไป

การจัดอันดับเต็มบัญชีในระบบที่มีคลังหลายล้านรายการไม่จำเป็นต้องคำนวณคะแนนครบทุกรายการเสมอไป แนวทางที่อุตสาหกรรมใช้คือแยกการประเมินเป็นสองขั้นให้ตรงกับสถาปัตยกรรมจริงของระบบ

- **ขั้นค้นคืน (Retrieval)** ใช้ดัชนีเพื่อนบ้านใกล้สุดโดยประมาณ (Approximate Nearest Neighbour) ดึงรายการผู้สมัครมาราวหนึ่งพันถึงหนึ่งหมื่นรายการ แล้ววัดด้วย Recall@1000 ของขั้นนี้
- **ขั้นจัดอันดับใหม่ (Re-ranking)** จัดอันดับเฉพาะรายการผู้สมัครที่ได้จากขั้นแรก แล้ววัดด้วย nDCG@10

วิธีนี้ต่างจากการสุ่มรายการเชิงลบตรงที่เซตผู้สมัครมาจาก **กลไกเดียวกับที่ระบบจริงใช้** ไม่ใช่การสุ่ม จึงสะท้อนสิ่งที่จะเกิดขึ้นจริงเมื่อขึ้นใช้งาน และยังคงเงื่อนไขว่ารายการที่แบบจำลองต้องแข่งด้วยเป็นรายการที่แข่งกันจริงในระบบ

2.10 การรายงานความไม่แน่นอนและการทดสอบนัยสำคัญ

ค่าทศนิยมเพียงค่าเดียวไม่บอกว่าผลต่างเกิดจากแบบจำลองหรือความผันผวนของการสุ่ม การรายงานที่เหมาะสมจึงควรมีผลรายผู้ใช้หรือหลายเมล็ดสุ่ม ช่วงความเชื่อมั่น ขนาดผล และการทดสอบแบบจับคู่ พร้อมแก้ปัญหาการเปรียบเทียบหลายคู่เมื่อทดลองหลายแบบจำลอง

2.10.1 ความผันผวนจากเมล็ดสุ่มเพียงอย่างเดียว

การทดลองต่อไปนี้ฝึกแบบจำลองเดิมซ้ำแปดครั้ง โดยเปลี่ยนเพียงเมล็ดสุ่ม (Random Seed) เท่านั้น ไม่มีการเปลี่ยนสถาปัตยกรรม ไฮเพอร์พารามิเตอร์ หรือข้อมูลใด ๆ ทั้งสิ้น

ตัวอย่างการคำนวณ 2.16 ความผันผวนที่เกิดจากเมล็ดสุ่มล้วน ๆ

ครั้งที่	1	2	3	4	5	6	7	8
nDCG@10	0.0917	0.0969	0.0934	0.0887	0.0931	0.0900	0.0979	0.0885

ค่าเฉลี่ย = 0.0925 · ส่วนเบี่ยงเบนมาตรฐาน = 0.0035 · ช่วงที่พบ = [0.0885, 0.0979] กว้าง 0.0094 · ครึ่งความกว้างของช่วงเชื่อมั่น 95% ของค่าเฉลี่ย = ±0.0024

กฎที่ใช้ได้เสมอ หากส่วนต่างระหว่างสองการตั้งค่าเล็กกว่าส่วนเบี่ยงเบนมาตรฐานระหว่างเมล็ดสุ่มของการตั้งค่าเดียวกัน แสดงว่าไม่มีหลักฐานว่าทั้งสองต่างกัน ในกรณีนี้ส่วนต่างที่เล็กกว่า 0.0035 ไม่ควรถูกอ้างว่าเป็นการปรับปรุงเลย

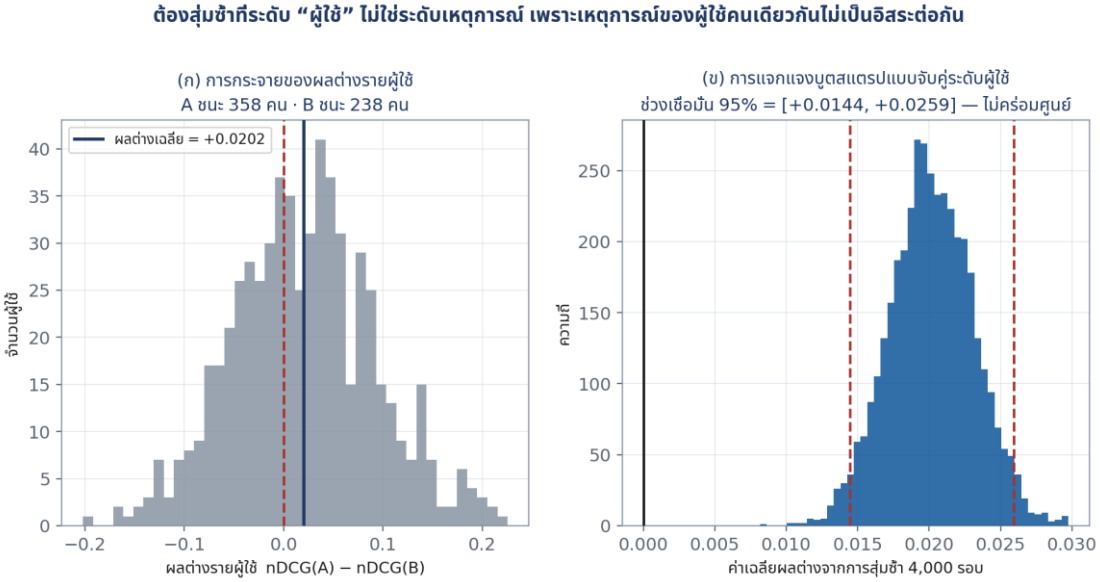
ข้อนี้มีนัยที่ต้องคิดตาม งานตีพิมพ์จำนวนมากในสาขานี้อ้างการปรับปรุงในระดับร้อยละ 1 ถึง 3 ซึ่งบนตัวเลขฐาน 0.0925 คิดเป็นส่วนต่างเพียง 0.0009 ถึง 0.0028 ซึ่งเล็กกว่าความผันผวนจากเมล็ดสุ่มของแบบจำลองเดิมเสียอีก

2.10.2 การสุ่มซ้ำแบบจับคู่ที่ระดับผู้ใช้ (Paired Bootstrap)

วิธีที่เหมาะสมที่สุดสำหรับการเปรียบเทียบสองแบบจำลองในระบบผู้แนะนำคือการสุ่มซ้ำแบบจับคู่ หลักการคือ แทนที่จะเปรียบเทียบค่าเฉลี่ยรวมสองค่า ให้คำนวณผลต่างที่ระดับผู้ใช้แต่ละคนก่อน แล้วจึงสุ่มเลือกผู้ใช้กลับคืน (with replacement) ซ้ำหลายพันรอบ เพื่อประมาณการกระจายของค่าเฉลี่ยผลต่าง

1. คำนวณค่าตัวชี้วัดของแบบจำลอง A และ B แยกรายผู้ใช้ ได้เวกเตอร์ยาว $|U|$ สองชุด
2. คำนวณผลต่างรายผู้ใช้ $d_u = \text{metric_A}(u) - \text{metric_B}(u)$ ได้เวกเตอร์ผลต่างหนึ่งชุด

3. สุ่มเลือกผู้ใช้กลับคืนจนครบ |U| คน แล้วคำนวณค่าเฉลี่ยของ d_u ในตัวอย่างนั้น
4. ทำซ้ำขั้นที่ 3 จำนวน 4,000 ถึง 10,000 รอบ ได้การแจกแจงของค่าเฉลี่ยผลต่าง
5. อ่านเปอร์เซ็นไทล์ที่ 2.5 และ 97.5 เป็นช่วงความเชื่อมั่น 95% หากช่วงนี้ไม่คร่อมศูนย์ แสดงว่ามีหลักฐานว่าทั้งสองต่างกัน



ภาพที่ 2.16 การกระจายของผลต่างรายผู้ใช้ และการแจกแจงบูตสแตรปแบบจับคู่ที่ให้ช่วงความเชื่อมั่น 95%

ภาพที่ 2.16 แผงซ้ายเผยข้อมูลที่ค่าเฉลี่ยเพียงค่าเดียวปิดบังไว้ทั้งหมด คือแม้แบบจำลอง A จะดีกว่าโดยเฉลี่ย แต่มีผู้ใช้ถึง 238 คนจาก 600 คนที่ได้ผลแย่ลง ข้อมูลนี้สำคัญมากในทางปฏิบัติ เพราะการเปลี่ยนระบบที่ทำให้ผู้ใช้ร้อยละ 40 แย่ลง อาจไม่คุ้มค่าแม้ค่าเฉลี่ยจะดีขึ้นก็ตาม

ตารางที่ 2.12 *ผลการทดสอบนัยสำคัญด้วยการสุ่มซ้ำแบบจับคู่ระดับผู้ใช้ 4,000 รอบ บนผู้ใช้ 600 คน*

คู่เปรียบเทียบ	ส่วนต่างเฉลี่ย	ช่วงความเชื่อมั่น 95%	p-value	ข้อสรุป
A – B	+0.0202	[+0.0144, +0.0259]	0.0000	มีนัยสำคัญ
A – C	+0.0025	[−0.0033, +0.0084]	0.4045	ไม่มีหลักฐานว่าต่างกัน
C – B	+0.0177	[+0.0119, +0.0230]	0.0000	มีนัยสำคัญ

ข้อควรระวัง การเขียนข้อสรุปให้ถูกต้องตามหลักสถิติ

ค่าเฉลี่ยของสามแบบจำลองคือ A = 0.2148, B = 0.1946 และ C = 0.2123 หากอ่านจากค่าเฉลี่ยอย่างเดียวจะสรุปว่า A > C > B และทำตัวหนาที่ A

แต่ช่วงความเชื่อมั่นของ A – C คือ [−0.0033, +0.0084] ซึ่ง **คร่อมศูนย์** แปลว่าข้อมูลชุดนี้ไม่มีหลักฐานเพียงพอที่จะบอกว่า A ต่างจาก C

ประโยคที่เขียนได้ "ไม่มีหลักฐานว่า A ดีกว่า C บนชุดข้อมูลนี้ ทั้งสองดีกว่า B อย่างมีนัยสำคัญ"

ประโยคที่เขียนไม่ได้ "A ดีที่สุด" หรือ "A ดีกว่า C เล็กน้อย" เพราะทั้งสองประโยคอ้างสิ่งที่ข้อมูลไม่รองรับ

อนึ่ง การที่ช่วงครอบคลุมศูนย์ก็ไม่ได้แปลว่า A เท่ากับ C เช่นกัน การไม่พบหลักฐานของความต่างไม่ใช่หลักฐานของความไม่ต่าง

2.10.3 ความผิดพลาดคลาสสิก การสุ่มซ้ำผิดระดับ

ความผิดพลาดที่พบบ่อยคือการสุ่มซ้ำที่ระดับ “เหตุการณ์” แทนที่จะเป็นระดับ “ผู้ใช้” ซึ่งดูเผิน ๆ เหมือนจะดีกว่าเพราะมีจำนวนตัวอย่างมากกว่า แต่ให้ผลที่ผิดอย่างเป็นระบบ

ตัวอย่างการคำนวณ 2.17 ผลของการสุ่มซ้ำผิดระดับ

ระดับที่สุ่มซ้ำ	จำนวนตัวอย่าง n	ความกว้างของช่วงเชื่อมั่น 95%	ผลการประเมิน
ระดับผู้ใช้	600	0.0115	ถูกต้อง
ระดับเหตุการณ์	4,800	0.0040	ผิด

ช่วงความเชื่อมั่นแคบเกินจริงถึง 2.9 เท่า ซึ่งแปลว่าผู้วิจัยจะมั่นใจในผลของตัวเองมากเกินความเป็นจริงเกือบสามเท่า และจะประกาศว่าพบนัยสำคัญในกรณีที่ไม่ควรประกาศ

เหตุผล เหตุการณ์ของผู้ใช้คนเดียวกันไม่เป็นอิสระต่อกัน ผู้ใช้ที่ชอบหนังแนวหนึ่งมักให้คะแนนคล้ายกันทุกเรื่อง การสุ่มซ้ำระดับเหตุการณ์จึงเท่ากับนับข้อมูลชุดเดิมซ้ำหลายครั้ง หน่วยของการสุ่มซ้ำต้องเป็นหน่วยที่เป็นอิสระต่อกัน ซึ่งในระบบผู้แนะนำคือผู้ใช้ ไม่ใช่เหตุการณ์

2.10.4 การเปรียบเทียบหลายคู่

เมื่อเปรียบเทียบแบบจำลองหลายตัวพร้อมกัน จำนวนคู่เปรียบเทียบเพิ่มขึ้นเร็วมาก และโอกาสที่จะพบ “นัยสำคัญปลอม” อย่างน้อยหนึ่งคู่ก็เพิ่มตามไปด้วย ที่ระดับนัยสำคัญ $\alpha = 0.05$ และเปรียบเทียบ 10 คู่ โอกาสพบนัยสำคัญปลอมอย่างน้อยหนึ่งคู่สูงถึงร้อยละ 40.1

$$P(\text{พบนัยสำคัญปลอมอย่างน้อยหนึ่งคู่}) = 1 - (1 - \alpha)^m = 1 - 0.95^{10} = 0.401 \qquad (2.27)$$

วิธีแก้ที่แนะนำในตำราเล่มนี้คือวิธีของโฮล์ม (Holm–Bonferroni) ซึ่งมีกำลังทดสอบสูงกว่าวิธีบอนเฟอโรนีแบบดั้งเดิม ขั้นตอนคือเรียงค่า p จากน้อยไปมาก แล้วเปรียบเทียบค่าที่ i กับเกณฑ์ $\alpha/(m - i + 1)$

ตารางที่ 2.13 การแก้ปัญหาการเปรียบเทียบหลายคู่ด้วยวิธีของโฮล์ม ที่ $\alpha = 0.05$ และ $m = 3$ คู่

ลำดับ	คู่เปรียบเทียบ	p-value	เกณฑ์ของโฮล์ม	ผลหลังแก้
1	A – B	0.0000	0.05/3 = 0.0167	มีนัยสำคัญ
2	C – B	0.0000	0.05/2 = 0.0250	มีนัยสำคัญ
3	A – C	0.4045	0.05/1 = 0.0500	ไม่มีนัยสำคัญ

กรอบเจาะลึก การทดสอบวิลค็อกซันแบบจับคู่ ทางเลือกที่ไม่ต้องสมมติการแจกแจง

นอกจากการสุ่มซ้ำแบบจับคู่แล้ว ยังมีการทดสอบเชิงอันดับที่ใช้กันแพร่หลายในสาขานี้ คือการทดสอบวิลค็อกซันแบบจับคู่ (Wilcoxon Signed-Rank Test) ซึ่งมีขั้นตอนดังนี้

- คำนวณผลต่างรายผู้ใช้ d_u แล้วตัดกรณีที่ $d_u = 0$ ออก
- จัดอันดับค่า $|d_u|$ จากน้อยไปมาก โดยค่าที่เท่ากันให้ใช้อันดับเฉลี่ย
- รวมอันดับของกรณีที่ $d_u > 0$ ได้ W^+ และของกรณีที่ $d_u < 0$ ได้ W^-
- ใช้ค่าสถิติ $W = \min(W^+, W^-)$ เทียบกับการแจกแจงอ้างอิง

ข้อดี ไม่ต้องสมมติว่าผลต่างมีการแจกแจงปกติ ซึ่งเหมาะกับตัวชี้วัดของระบบผู้แนะนำที่มักเบ้ขวาอย่างรุนแรงเพราะผู้ใช้จำนวนมากได้ค่าเป็นศูนย์

ข้อจำกัด ให้เพียงค่า p ไม่ให้ช่วงความเชื่อมั่นของขนาดผล (Effect Size) ในขณะที่การสุ่มซ้ำแบบจับคู่ให้ทั้งสองอย่าง ตำราเล่มนี้จึงแนะนำให้รายงานการสุ่มซ้ำแบบจับคู่เป็นหลัก และใช้วิลค็อกซันเป็นการตรวจสอบยืนยัน

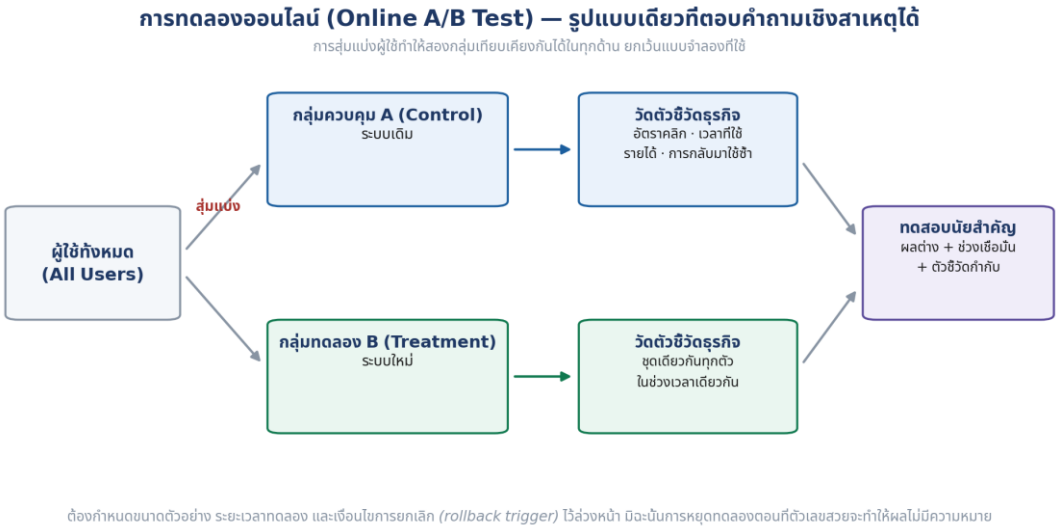
ประเด็นที่สำคัญกว่าการเลือกวิธี ค่า p ที่น้อยมากไม่ได้แปลว่าผลต่างมีความหมายในทางปฏิบัติ เมื่อจำนวนผู้ใช้มากพอ ส่วนต่างที่เล็กจนไร้ความหมายทางธุรกิจก็ให้ $p < 0.001$ ได้ จึงต้องรายงานขนาดผลควบคู่กับค่า p เสมอ

ขนาดผล ช่วงความเชื่อมั่น และนัยสำคัญ

ค่า p ตอบคำถามว่า หากแบบจำลองสองตัวไม่มีความแตกต่างจริง ผลที่สังเกตได้หรือสุดโต่งกว่านี้เกิดขึ้นได้บ่อยเพียงใดภายใต้สมมติฐานและวิธีสุ่มตัวอย่างที่ใช้ ค่า p ไม่ใช่ความน่าจะเป็นที่แบบจำลองใหม่ดีกว่า และไม่บอกว่าความแตกต่างมีขนาดสำคัญต่อธุรกิจหรือไม่

รายงานผลต่างเฉลี่ยควบคู่กับช่วงความเชื่อมั่นและเกณฑ์ขั้นต่ำที่มีความหมายในทางปฏิบัติ ตัวอย่างเช่น ΔnDCG@10 = 0.003 และช่วงความเชื่อมั่นร้อยละ 95 เท่ากับ [0.001, 0.005] แสดงว่าหลักฐานเชิงสถิติเป็นบวก แต่ทีมยังต้องตัดสินว่าเพิ่มขึ้น 0.003 คุ้มกับต้นทุน ความหน่วง หรือผลกระทบต่อ Guardrail หรือไม่

2.11 การทดลองออนไลน์กับตัวชี้วัดธุรกิจ



ภาพที่ 2.17 โครงสร้างของการทดลองออนไลน์ และเหตุผลที่การสุ่มแบ่งผู้ใช้ทำให้ตอบคำถามเชิงสาเหตุได้

การทดลองออนไลน์ตอบคำถามเชิงสาเหตุว่า “เมื่อเปลี่ยนไปใช้แบบจำลองใหม่ พฤติกรรมผู้ใช้เปลี่ยนหรือไม่” การสุ่มแบ่งผู้ใช้ทำให้กลุ่มควบคุมและกลุ่มทดลองเทียบเคียงกันได้ จึงเชื่อมผลต่างที่สังเกตกับแบบจำลองได้ แต่ต้องกำหนดตัวชี้วัดหลัก ตัวชี้วัดกำกับ ระยะเวลา และเกณฑ์หยุดล่วงหน้า

2.11.1 สิ่งที่ต้องกำหนดล่วงหน้าก่อนเปิดการทดลอง

ตารางที่ 2.14 *รายการที่ต้องกำหนดเป็นลายลักษณ์อักษรก่อนเปิดการทดลองออนไลน์*

สิ่งที่ต้องกำหนด	เหตุผล	ตัวอย่าง
ตัวชี้วัดหลักเชิงธุรกิจ	กันการเลือกตัวชี้วัดที่ถูกใจหลังเห็นผล	อัตราการคลิกเข้าชมเนื้อหาต่อการเข้าใช้หนึ่งครั้ง
ตัวชี้วัดกำกับเชิงธุรกิจ	กันการปรับปรุงที่แลกมาด้วยความเสียหายด้านอื่น	อัตราการยกเลิกสมาชิกต้องไม่เพิ่มเกินร้อยละ 0.5
ขนาดตัวอย่างและกำลังทดสอบ	กันการทดลองที่เล็กเกินกว่าจะสรุปอะไรได้	ต้องตรวจจับผลต่างร้อยละ 2 ได้ที่กำลัง 0.80
ระยะเวลาทดลองขั้นต่ำ	กันผลของความแปลกใหม่ (Novelty Effect) ในสัปดาห์แรก	อย่างน้อยสองสัปดาห์เต็ม ครอบคลุมทุกวันในสัปดาห์
เงื่อนไขการยกเลิก (Rollback Trigger)	จำกัดความเสียหายเมื่อผลเป็นลบอย่างชัดเจน	ยกเลิกทันทีเมื่อตัวชี้วัดหลักลดเกินร้อยละ 3 ที่นัยสำคัญ 0.01
วิธีแบ่งหน่วยสุ่ม	กันการรั่วไหลข้ามกลุ่มเมื่อผู้ใช้ใช้หลายอุปกรณ์	สุ่มที่ระดับบัญชีผู้ใช้ ไม่ใช่ระดับเซสชัน

ข้อควรระวัง กับดักที่พบบ่อยที่สุดในการทดลองออนไลน์

การแอบดูผลระหว่างทางแล้วหยุดเมื่อตัวเลขสวย (Peeking) เป็นการทำลายความหมายของค่า p ทั้งหมด เพราะเท่ากับทดสอบซ้ำหลายครั้งโดยไม่แก้ปัญหาการเปรียบเทียบหลายคู่ วิธีแก้คือกำหนดจุดตรวจไว้ล่วงหน้าและใช้วิธีทดสอบแบบลำดับ (Sequential Testing) ที่ออกแบบมาสำหรับกรณีนี้

ผลของความแปลกใหม่ (Novelty Effect) ผู้ใช้มักคลิกมากขึ้นเพียงเพราะหน้าจอเปลี่ยนไป ไม่ใช่เพราะคำแนะนำดีขึ้น ผลนี้จางลงในหนึ่งถึงสองสัปดาห์ การทดลองที่สั้นเกินไปจึงวัดความตื่นเต้นแทนที่จะวัดคุณภาพ

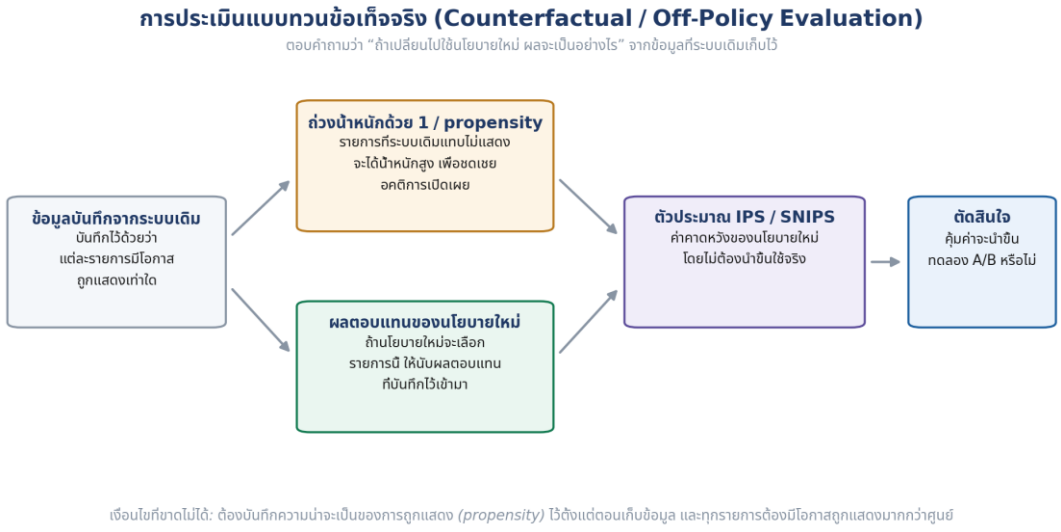
การละเลยผลระยะยาว ระบบที่เพิ่มการคลิกในระยะสั้นด้วยเนื้อหาที่เร้าอารมณ์ อาจลดความไว้วางใจและการกลับมาใช้ซ้ำในระยะยาว ซึ่งการทดลองสองสัปดาห์มองไม่เห็น จึงต้องมีการติดตามกลุ่มระยะยาว (Holdback Group) ควบคู่ไปด้วย

การเปลี่ยนแปลงแบบสัมบูรณ์และสัมพัทธ์

ผลการทดลองออนไลน์ควรรายงานทั้งการเปลี่ยนแปลงแบบสัมบูรณ์และสัมพัทธ์ หากอัตราคลิกเพิ่มจาก 4.0% เป็น 4.4% การเพิ่มแบบสัมบูรณ์คือ 0.4 จุดเปอร์เซ็นต์ ส่วนการเพิ่มแบบสัมพัทธ์คือ (4.4 - 4.0)/4.0 = 10% การเขียนเพียงว่าเพิ่มขึ้น 10% โดยไม่ให้ค่าฐานทำให้ผู้อ่านประเมินขนาดผลจริงไม่ได้

2.12 การประเมินแบบทวนข้อเท็จจริง

ข้อมูลบันทึกย้อนหลังสะท้อนสิ่งที่นโยบายเดิมเลือกแสดง จึงประเมินนโยบายใหม่แบบตรงไปตรงมาไม่ได้ การประเมินแบบทวนข้อเท็จจริงใช้ความน่าจะเป็นที่รายการถูกแสดง หรือ propensity มาถ่วงน้ำหนักเพื่อประมาณผลของนโยบายใหม่โดยยังไม่ต้องนำขึ้นใช้งานจริง ทั้งนี้ต้องควบคุมน้ำหนักที่สูงผิดปกติและรายงานความแปรปรวน



ภาพที่ 2.18

โครงสร้างของการประเมินแบบทวนข้อเท็จจริงด้วยการถ่วงน้ำหนักผกผันของความน่าจะเป็นการถูกแสดง

นิยาม 2.8 การถ่วงน้ำหนักผกผันของความโน้มเอียง (Inverse Propensity Scoring, IPS)

วิธีประมาณค่าคาดหวังของผลตอบแทนภายใต้นโยบายใหม่ จากข้อมูลที่เก็บด้วยนโยบายเดิม โดยถ่วงน้ำหนักแต่ละเหตุการณ์ด้วยส่วนกลับของความน่าจะเป็นที่เหตุการณ์นั้นจะถูกแสดง

$$\hat{V}_{IPS}(\pi) = (1/n)\cdot\sum_{k=1}^{n} [\pi(a_k|x_k)/\pi_0(a_k|x_k)]\cdot r_k \quad (2.28)$$

โดย π คือนโยบายใหม่ที่ต้องการประเมิน π_0 คือนโยบายเดิมที่ใช้เก็บข้อมูล a_k คือรายการที่ถูกแสดงในเหตุการณ์ที่ k x_k คือบริบท และ r_k คือผลตอบแทนที่สังเกตได้

สัญชาตญาณเบื้องหลังสูตรนี้ตรงไปตรงมา รายการที่นโยบายเดิมแทบไม่เคยแสดงเลย แต่บังเอิญถูกแสดงหนึ่งครั้งและได้ผลตอบแทนดี ควรถูกนับด้วยน้ำหนักสูง เพราะเป็นหลักฐานที่หายากมาก ในทางกลับกัน รายการที่นโยบายเดิมแสดงตลอดเวลา ควรถูกนับด้วยน้ำหนักต่ำ เพื่อชดเชยการที่ข้อมูลมีมันมากเกินสัดส่วน

ข้อควรระวัง เงื่อนไขที่ขาดไม่ได้สามข้อ

1. **ต้องบันทึกความโน้มเอียงไว้ตั้งแต่ตอนเก็บข้อมูล** ค่า $\pi_0(a_k|x_k)$ ต้องถูกบันทึกไว้พร้อมกับเหตุการณ์ ไม่สามารถย้อนไปประมาณทีหลังได้อย่างน่าเชื่อถือ ข้อนี้เป็นเหตุผลที่ทีมวิศวกรรมต้องออกแบบระบบบันทึกให้ถูกตั้งแต่วันแรก
2. **ทุกรายการต้องมีโอกาสถูกแสดงมากกว่าศูนย์** เงื่อนไขนี้เรียกว่าการครอบคลุม (Overlap หรือ Positivity) หากรายการใดมีความโน้มเอียงเป็นศูนย์ ตัวประมาณจะให้ค่าไม่นิยาม ในทางปฏิบัติจึงต้องสงวนสัดส่วนการเข้าชมส่วนน้อย เช่น ร้อยละ 1 ถึง 5 ไว้สำหรับการสำรวจแบบสุ่ม
3. **ต้องควบคุมความแปรปรวน** เมื่อความโน้มเอียงมีค่าเล็กมาก น้ำหนัก $1/\pi_0$ จะระเบิดขึ้นสูงมาก ทำให้ตัวประมาณมีความแปรปรวนสูงจนใช้ไม่ได้ วิธีแก้มาตรฐานคือการตัดยอดน้ำหนัก (Clipping) การใช้ตัวประมาณแบบทำให้เป็นบรรทัดฐาน (SNIPS) หรือการใช้ตัวประมาณสองชั้น (Doubly Robust) ที่ผสมแบบจำลองผลตอบแทนเข้ามาช่วย

ในทางปฏิบัติ การประเมินแบบทวนข้อเท็จจริงไม่ได้แทนที่การทดลองออนไลน์ แต่ทำหน้าที่เป็นด่านคัดกรองที่ดีกว่าการประเมินออฟไลน์แบบธรรมดา เพราะประมาณผลของนโยบายใหม่ได้โดยตรง แทนที่จะวัดเพียงความเหมือนกับนโยบายเดิม

ตัวอย่างย่อของน้ำหนัก IPS

สมมติว่าระบบเดิมแสดงรายการ A ด้วย propensity 0.50 และรายการ B ด้วย propensity 0.10 หากทั้งสองรายการได้รับรางวัลเท่ากับ 1 น้ำหนักส่วนกลับจะเป็น 1/0.50 = 2 สำหรับ A และ 1/0.10 = 10 สำหรับ B หลักฐานจาก B จึงมีน้ำหนักมากกว่าเพราะเกิดขึ้นภายใต้นโยบายเดิมได้ยาก อย่างไรก็ตาม propensity ที่เล็กมากทำให้น้ำหนักสูงและเพิ่มความแปรปรวน จึงมักใช้การตัดน้ำหนัก SNIPS หรือ Doubly Robust พร้อมรายงานค่าที่ใช้

เงื่อนไข Overlap หมายความว่านโยบายเดิมต้องให้โอกาสมากกว่าศูนย์แก่ทุกการกระทำที่นโยบายใหม่อาจเลือก หาก

propensity เป็นศูนย์ ข้อมูลในอดีตไม่มีหลักฐานสำหรับกรณีนั้นและ IPS ไม่สามารถแก้ปัญหาได้ การสุ่มสำรวจเพียงเล็กน้อยตั้งแต่ขั้นเก็บข้อมูลจึงสำคัญกว่าการพยายามประมาณ propensity ย้อนหลัง

2.13 การทำซ้ำได้และบัตรโปรโตคอล

ผลการทดลองจะทำซ้ำได้ต่อเมื่อบันทึกตัวเลือกที่มีผลต่อคะแนนครบถ้วน ไม่ใช่เพียงชื่อแบบจำลองและชุดข้อมูล บัตรโปรโตคอลจึงควรระบุการแบ่งข้อมูล เซตผู้สมัคร นิยาม relevance ค่า K ตัวชี้วัด วิธีรวมผล เมล็ดสุ่ม การปรับพารามิเตอร์ แบบจำลองฐาน และรุ่นของซอฟต์แวร์อย่างชัดเจน

สาเหตุไม่ใช่ความไม่ซื่อสัตย์ของผู้วิจัย แต่คือการที่ตัวเลือกเชิงระเบียบวิธีจำนวนมากไม่เคยถูกบันทึกไว้ในบทความ ทั้งที่แต่ละตัวเลือกเปลี่ยนผลได้อย่างมีนัยสำคัญ ดังที่บทนี้แสดงให้เห็นมาตลอด วิธีแก้ที่ตำราเล่มนี้เสนอคือการจัดทำบัตรโปรโตคอล

> **นิยาม 2.9 บัตรโปรโตคอลการประเมิน (Evaluation Protocol Card)**
>
> เอกสารสั้นที่บันทึกตัวเลือกเชิงระเบียบวิธีทุกข้อของการทดลองหนึ่งครั้ง โดยมีเงื่อนไขว่าผู้อ่านที่มีเพียงบัตรใบนี้กับชุดข้อมูล ต้องทำซ้ำผลได้ครบทุกหลัก บัตรต้องถูกกรอกให้ครบ ก่อนรันการทดลองครั้งแรก และแนบไปกับผลทุกครั้งที่รายงาน

ตารางที่ 2.15 *ตัวอย่างบัตรโปรโตคอลที่ผลิตโดยอัตโนมัติจากโปรแกรม lab2_07_full_protocol.py*

ช่องข้อมูล	ค่าที่บันทึก	เหตุผลที่ต้องบันทึก
dataset	RSLab-Eval	ระบุแหล่งข้อมูลและรุ่นให้ชัด
n_users / n_items / n_interactions	800 / 500 / 21,696	ให้ผู้อ่านตรวจว่าใช้ข้อมูลชุดเดียวกัน
k_core	0	การกรอง k-core เปลี่ยนความยากของงานอย่างมาก
split_method	global_temporal	ตัวเลือกนี้เปลี่ยนผลได้ถึงร้อยละ 71.6 (ตารางที่ 2.9)
train_frac	0.7	สัดส่วนการแบ่งมีผลต่อขนาดของชุดทดสอบ
relevance_threshold	rating ≥ 4	นิยามความเกี่ยวข้องเปลี่ยนค่าตัวชี้วัดทุกตัว
K	10	ห้ามเปรียบเทียบค่าที่ K ต่างกัน (หัวข้อ 2.4.2)
candidate_set	full_catalog	ตัวเลือกนี้สลับผู้ชนะได้ (หัวข้อ 2.9.4)
gain_type	linear	เชิงเส้นหรือเลขชี้กำลังให้ผลต่างกันเมื่อมีหลายระดับ
seeds	(0, 1, 2, 3, 4)	ให้ผู้อ่านทำซ้ำได้และเห็นความผันผวน
primary_metric	nDCG@10	ตัวที่ใช้ตัดสิน ประกาศไว้ก่อนเห็นผล

ช่องข้อมูล	ค่าที่บันทึก	เหตุผลที่ต้องบันทึก
guardrail_metrics	Coverage@10, Gini, Novelty, LongTail	สิ่งที่ห้ามแย่ลงเกินเกณฑ์

ภาคปฏิบัติ การใช้บัตรโปรโตคอลในทางปฏิบัติ

แพ็กเกจ rslab มีชั้น ProtocolCard ที่ทำหน้าที่สามอย่างพร้อมกัน

- **บังคับให้ประกาศครบ** เมธอด validate() จะยกข้อผิดพลาดขึ้นทันทีหากมีช่องสำคัญว่างอยู่ ทำให้ลืมประกาศไม่ได้แม้จะรีบเพียงใด
- **ผลิตชื่อตัวชี้วัดที่ถูกต้องให้อัตโนมัติ** เมธอด metric_name() จะคืนค่า nDCG@10 เมื่อใช้เต็มบัญชีรายการ และคืนค่า sampled nDCG@10 (m=99) เมื่อใช้การสุ่ม จึงกันการเรียกชื่อผิดที่หัวข้อ 2.9.5 เตือนไว้
- **พิมพ์บัตรออกมาแนบกับผล** เมธอด render() ผลิตข้อความที่คัดลอกไปวางในภาคผนวกของบทความได้ทันที

ผู้เขียนขอแนะนำให้ผู้เรียนใช้ชั้นนี้กับทุกการทดลองตั้งแต่วันแรก เพราะเมื่อถึงเวลาเขียนวิทยานิพนธ์ ข้อมูลที่จำเป็นจะถูกบันทึกไว้ครบแล้วโดยอัตโนมัติ

2.14 โปรโตคอลการประเมิน 11 ขั้น

โปรโตคอล 11 ขั้นในหัวข้อนี้รวบรวมการตัดสินใจตั้งแต่คำถามวิจัยจนถึงรูปแบบรายงานไว้ในลำดับเดียว ทุกขั้นควรถูกกำหนดและบันทึกก่อนดูผลการทดลอง เพื่อลดการเลือกวิธีที่เอื้อต่อผลลัพธ์ภายหลังและทำให้ผู้อื่นตรวจสอบหรือทำซ้ำได้



ภาพที่ 2.19 โปรโตคอลการประเมินระบบผู้แนะนำที่น่าเชื่อถือ 11 ขั้น

2.14.1 รายละเอียดของแต่ละขั้น พร้อมตัวอย่างที่กรอกจริง

ตัวอย่างในตารางที่ 2.16 เป็นค่าที่โปรแกรม lab2_07_full_protocol.py กรอกและตรวจสอบจริงบนชุดข้อมูล RSLab-Eval ผู้อ่านรันโปรแกรมแล้วจะเห็นผลลัพธ์ของทุกขั้นตามลำดับ

ตารางที่ 2.16 *โปรโตคอลการประเมิน 11 ขั้น พร้อมค่าที่กรอกจริงในการทดลองประกอบบทนี้*

ขั้น	สิ่งที่ต้องทำ	ค่าที่กรอกจริงในการทดลองของบทนี้
1	กำหนดเป้าหมายของผู้ใช้และธุรกิจ	ผู้ใช้: พบรายการที่ชอบภายในสิบอันดับแรกโดยไม่ต้องเลื่อนหา · ธุรกิจ: เพิ่มการค้นพบรายการใหม่โดยไม่ลดความพึงพอใจระยะสั้น
2	เลือกตัวชี้วัดหลัก (Primary Metric)	nDCG@10 เพราะไวต่อตำแหน่งและตรงกับเป้าหมาย “สิบอันดับแรก”
3	กำหนดตัวชี้วัดกำกับ (Guardrail Metrics)	Coverage@10, Gini, Novelty, LongTail · เกณฑ์: Coverage ห้ามลดเกินร้อยละ 10 และ Gini ห้ามเพิ่มเกิน 0.02
4	ระบุสูตรและค่า K	K = 10 · นิยามความเกี่ยวข้อง rating ≥ 4 · gain_type = linear
5	แบ่งข้อมูลตามเวลา	global_temporal · ฝึก 15,187 · ตรวจสอบ 2,169 · ทดสอบ 4,340
6	ป้องกันข้อมูลรั่วไหล	เหตุการณ์อนาคตในชุดฝึก = 0 (0.0%) ผลตรวจปลอดภัย · สถิติทุกตัวคำนวณจากชุดฝึกเท่านั้น
7	กำหนดเซตผู้สมัคร (Candidate Set)	full_catalog โดยตัดรายการที่ผู้ใช้เห็นแล้วในชุดฝึกออก
8	ระบุวิธีสุ่มรายการเชิงลบ	ไม่ใช้การสุ่ม จึงรายงานได้ว่าเป็น nDCG@10 เต็มรูปแบบ ไม่ใช่ sampled nDCG@10
9	วัดทั้งความถูกต้องและคุณภาพนอกเหนือความถูกต้อง	TopPopular: nDCG 0.0493, Cov 0.042, Gini 0.9743, Nov 2.2862, LT 0.0000 · Personalized: nDCG 0.1192, Cov 0.126, Gini 0.9190, Nov 2.9316, LT 0.0816
10	รายงานความไม่แน่นอน	บนผู้ใช้ร่วม 752 คน สุ่มซ้ำระดับผู้ใช้ 4,000 รอบ · ผลต่าง +0.0699 · ช่วงเชื่อมั่น 95% = [+0.0600, +0.0800] · p = 0.0000 · มีนัยสำคัญ
11	ตรวจผลด้วยผู้ใช้จริง	ผลออฟไลน์ข้างต้นเป็นเพียงการคัดกรอง ต้องผ่านการทดลอง A / B พร้อมตัวชี้วัดกำกับเชิงธุรกิจและเงื่อนไขการยกเลิกที่กำหนดไว้ล่วงหน้า

ประเด็นสำคัญ ประโยคปิดท้ายของโปรโตคอล

คะแนนประเมินไม่ได้เป็นคุณสมบัติของแบบจำลองเพียงอย่างเดียว แต่เป็นผลร่วมของแบบจำลอง ข้อมูล ตัวชี้วัด เวลา เซตผู้สมัคร และโปรโตคอลการประเมินทั้งหมด

ทุกหัวข้อในบทนี้เป็นการพิสูจน์ประโยคนี้ด้วยตัวเลขจริงทีละข้อ หัวข้อ 2.8 พิสูจน์ส่วนของ “เวลา” ด้วยส่วนต่างร้อยละ 71.6 หัวข้อ 2.4 พิสูจน์ส่วนของ “ตัวชี้วัด” ด้วยตารางที่ 2.3 ที่ตัวชี้วัดสี่ตัวแยกแบบจำลองไม่ออก หัวข้อ 2.9 พิสูจน์ส่วนของ “เซตผู้สมัคร” ด้วยการสลับผู้ชนะ และหัวข้อ 2.10 พิสูจน์ว่าแม้แต่ “เมล็ดสุ่ม” ก็สร้างส่วนต่างได้ใหญ่กว่าที่งานตีพิมพ์จำนวนมากอ้างว่าเป็นการปรับปรุง

2.15 เหตุใดการประเมินระบบผู้แนะนำจึงต่างจากงานทั่วไป

ระบบผู้แนะนำไวต่อเซตผู้สมัคร เวลา ตำแหน่งการเปิดเผยรายการ และพฤติกรรมผู้ใช้มากกว่างานทำนายทั่วไป หัวข้อนี้รวบรวมหกเหตุผลสำคัญ พร้อมเชื่อมกลับไปยังตัวอย่างก่อนหน้า เช่น การแบ่งข้อมูลผิดเวลาที่ทำให้ nDCG@10 สูงเกินจริง และการสุ่มรายการเชิงลบที่เปลี่ยนทั้งคะแนนและผู้ชนะ

หลักการประเมินผลเป็นเรื่องสำคัญของงานปัญญาประดิษฐ์และการเรียนรู้ของเครื่องทุกประเภท ไม่ว่าจะเป็นการจำแนกภาพ การรู้จำเสียง หรือการแปลภาษา ทุกงานล้วนต้องแบ่งข้อมูล เลือกตัวชี้วัด และรายงานผลอย่างซื่อสัตย์ ประเด็นของหัวข้อนี้จึงไม่ใช่การอ้างว่าระบบผู้แนะนำ “พิเศษกว่า” งานอื่น แต่คือการชี้ให้เห็นว่าผลลัพธ์ของระบบผู้แนะนำ ไวเป็นพิเศษต่อสิ่งที่งานอื่นแทบไม่ต้องกังวล ได้แก่ เซตผู้สมัคร เวลา การเปิดเผยรายการ และพฤติกรรมผู้ใช้

ลองเปรียบเทียบให้เห็นภาพ ในงานจำแนกภาพแมวกับสุนัข ภาพหนึ่งภาพมีคำตอบที่ถูกต้องเพียงคำตอบเดียว คำตอบนั้นไม่เปลี่ยนตามเวลา ไม่เปลี่ยนตามว่าใครเป็นคนดู และไม่เปลี่ยนตามว่าเราเอาภาพอื่นกี่ภาพมาวางข้าง ๆ แต่ในระบบผู้แนะนำ ไม่มีข้อใดในสามข้อนี้เป็นจริงเลย



ภาพที่ 2.20 หกเหตุผลที่ทำให้การประเมินระบบผู้แนะนำต่างจากการเรียนรู้ของเครื่องทั่วไป

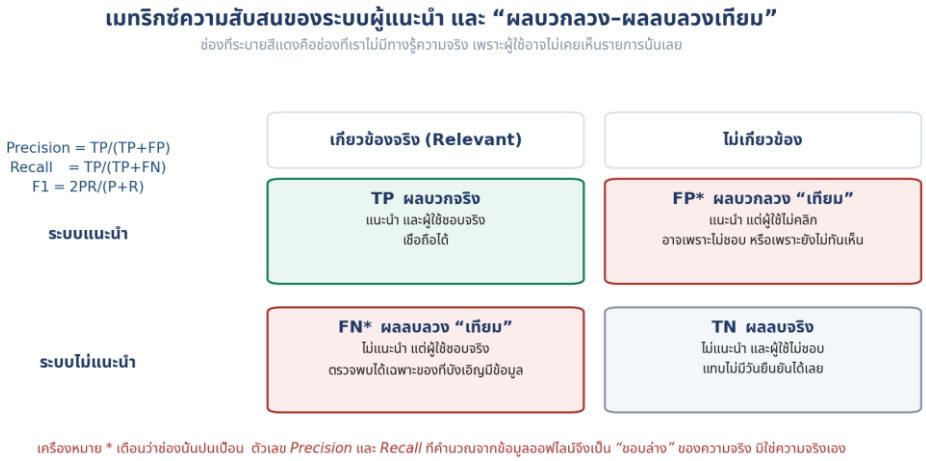
2.15.1 เหตุผลที่หนึ่ง การไม่คลิกไม่ได้แปลว่าไม่ชอบ

สมมติว่าระบบแนะนำภาพยนตร์เรื่องหนึ่งแก่ผู้ใช้ แล้วผู้ใช้ไม่คลิก คำถามคือเราควรบันทึกเหตุการณ์นี้ว่าอย่างไร คำตอบที่ผู้เริ่มต้นมักให้คือ “ผู้ใช้ไม่ชอบ” ซึ่งผิดในกรณีส่วนใหญ่

เหตุผลคือ การไม่คลิกอาจเกิดจากสาเหตุอย่างน้อยห้าประการที่ต่างกันโดยสิ้นเชิง และเราแยกไม่ออกจากข้อมูลที่มี

- ผู้ใช้ไม่ชอบภาพยนตร์เรื่องนั้นจริง ๆ (สัญญาณเชิงลบที่แท้จริง — เป็นกรณีเดียวที่เราสมมติไว้)
- ผู้ใช้ยังเลื่อนหน้าจอไปไม่ถึงตำแหน่งนั้น จึงไม่เคยเห็นเลย
- ผู้ใช้เห็นแล้วแต่ดูไปแล้วบนบริการอื่น จึงไม่จำเป็นต้องดูซ้ำ
- ผู้ใช้เห็นแล้วและสนใจ แต่ยังไม่มีเวลาในขณะนั้น
- ผู้ใช้ปิดแอปพลิเคชันไปก่อน เพราะเหตุผลที่ไม่เกี่ยวกับเนื้อหาเลย

ผลที่ตามมาในเชิงการวัดคือ ช่องในเมทริกซ์ความสับสน (Confusion Matrix) ที่เราเคยใช้อย่างสบายใจในงานจำแนกทั่วไป กลับปนเปื้อนอย่างรุนแรงในระบบผู้แนะนำ



ภาพที่ 2.21 เมทริกซ์ความสับสนของระบบผู้แนะนำ และผลบวกลวง–ผลลบลวง “เทียม” ที่เกิดจากอคติการเปิดเผยรายการ

นิยาม 2.10 ผลบวกลวงเทียมและผลลบลวงเทียม (Pseudo False Positive / False Negative)

ผลบวกลวงเทียม (Pseudo FP) กรณีที่ระบบแนะนำรายการหนึ่ง แล้วผู้ใช้ไม่มีปฏิสัมพันธ์ด้วย เราจึงนับเป็น “ทายผิด” ทั้งที่ผู้ใช้อาจไม่เคยเห็นรายการนั้นเลย

ผลลบลวงเทียม (Pseudo FN) กรณีที่ระบบไม่ได้แนะนำรายการหนึ่ง แล้วเราถือว่าไม่เกี่ยวข้อง ทั้งที่ผู้ใช้อาจชอบมาก เพียงแต่ไม่เคยมีโอกาสพบ จึงไม่มีหลักฐานปรากฏในข้อมูล

ผลลัพธ์เชิงตัวเลข ค่า Precision ที่คำนวณจากข้อมูลออฟไลน์จะ **ต่ำกว่าความจริง** อย่างเป็นระบบ เพราะตัวส่วนมี FP เทียมปนอยู่ ส่วนค่า Recall ก็ต่ำกว่าความจริงเช่นกัน เพราะตัวส่วนนับได้เฉพาะรายการที่บังเอิญมีข้อมูล ตัวเลขทั้งสองจึงเป็น “ขอบล่าง” ของความจริง มิใช่ความจริงเอง

ตัวอย่างการคำนวณ 2.18 ความเสียหายจากการตีความ “ไม่คลิก” ว่า “ไม่ชอบ”

สถานการณ์ บริการสตรีมมิงแห่งหนึ่งแสดงรายการแนะนำ 20 รายการต่อหน้าจอ จากการวัดพฤติกรรมจริงพบว่า ผู้ใช้เลื่อนดูจนถึงรายการที่ 20 เพียงร้อยละ 12 ของการเข้าใช้ ส่วนที่เหลือหยุดที่รายการที่ 6 โดยเฉลี่ย

ขั้นที่ 1 — คำนวณจำนวนรายการที่ผู้ใช้เห็นจริง

รายการที่ถูก “แสดง” = 20 แต่รายการที่ถูก “เห็น” จริง ≈ 6

ขั้นที่ 2 — นับป้ายกำกับเชิงลบที่เราสร้างขึ้นอย่างผิด ๆ

รายการที่ถูกนับเป็น “ไม่ชอบ” = 20 − (จำนวนที่คลิก) ทั้งที่ 14 รายการนั้นไม่เคยถูกเห็นเลย

ขั้นที่ 3 — ตีความ หากผู้ใช้คลิก 1 รายการ ระบบจะบันทึกป้ายกำกับเชิงลบ 19 รายการ ในจำนวนนี้มีเพียง 5 รายการเท่านั้นที่ผู้ใช้เห็นแล้วเลือกไม่คลิก ส่วนอีก **14 รายการเป็นป้ายกำกับที่แต่งขึ้นทั้งหมด** คิดเป็นสัดส่วนถึงร้อยละ 73.7 ของสัญญาณเชิงลบทั้งหมดที่นำไปฝึกและประเมิน

บทเรียน ในงานจำแนกภาพ ป้ายกำกับ “ไม่ใช่แมว” คือความจริงที่ผู้ติดป้ายยืนยัน แต่ในระบบผู้แนะนำ ป้ายกำกับเชิงลบส่วนใหญ่คือ “สิ่งที่เราเดาเอาเอง” ซึ่งเป็นความต่างเชิงคุณภาพ มิใช่เชิงปริมาณ

2.15.2 เหตุผลที่สอง เซตผู้สมัครที่ต่างกันทำให้คะแนนเปลี่ยนอย่างมหาศาล

ในงานจำแนกภาพ จำนวนคำตอบที่เป็นไปได้ถูกกำหนดตายตัว เช่น 10 ประเภท หรือ 1,000 ประเภท แต่ระบบผู้แนะนำต้องเลือกจากคลังที่มีนับแสนถึงนับร้อยล้านรายการ และในทางปฏิบัติผู้วิจัยมักไม่ได้จัดอันดับทั้งคลัง เพราะต้นทุนการคำนวณสูงเกินไป

คำถามที่ตามมาคือ ถ้าเราหยิบเฉพาะบางส่วนของคลังมาจัดอันดับ ผลลัพธ์จะยังเทียบเคียงได้กับการจัดอันดับทั้งคลังหรือไม่ คำตอบสั้น ๆ คือ ไม่ได้ และผลกระทบใหญ่กว่าที่ผู้เริ่มต้นเกือบทุกคนคาดคิด

ตัวอย่างการคำนวณ 2.19 ตัวอย่างที่ต้องจำให้ขึ้นใจ — รายการที่อยู่อันดับ 500

สถานการณ์ คลังมี 5,000 รายการ ผู้ใช้คนหนึ่งมีรายการที่ชอบจริงหนึ่งชิ้น แบบจำลองจัดอันดับรายการนั้นไว้ที่ **อันดับที่ 500** ค่าตัด K = 10

กรณีที่ 1 — ประเมินกับบัญชีรายการทั้งหมด (Full Catalog)

อันดับ 500 > K = 10 ดังนั้นรายการเป้าหมายอยู่นอก Top-10

$$\text{nDCG@10} = 0.0000 \quad (2.29)$$

กรณีที่ 2 — สุ่มรายการที่ไม่เกี่ยวข้องมาเพียง 99 รายการ (Sampled Negatives) เซตผู้สมัครเหลือ 100 รายการ คือ รายการเป้าหมาย 1 ชิ้น บวกรายการเชิงลบ 99 ชิ้น

ขั้นที่ 1 — คิดว่ามีรายการที่ “เหนือกว่า” เป้าหมายกี่ชิ้นที่ถูกสุ่มติดมา

ในคลังเดิมมีรายการที่อยู่เหนือเป้าหมาย 499 ชิ้น จากรายการเชิงลบทั้งหมด 4,999 ชิ้น เมื่อสุ่มมา 99 ชิ้น จำนวนที่ยังเหนือกว่าโดยเฉลี่ยจึงเป็น

$$499 \times 99 \div 4{,}999 = 9.88 \text{ ชิ้น}$$

ขั้นที่ 2 — อันดับที่สังเกตได้

$$E[\text{อันดับใหม่}] = 1 + 9.88 = 10.88 \quad \text{(การจำลอง 20,000 รอบได้ 10.86)} \quad (2.30)$$

ขั้นที่ 3 — คำนวณคะแนน จากการจำลอง 20,000 รอบพบว่ารายการเป้าหมายเลื่อนเข้ามาอยู่ใน Top-10 ถึง **ร้อยละ 47.0** ของการสุ่ม ทำให้ได้

$$\text{sampled nDCG@10} = 0.1482 \quad (2.31)$$

ขั้นที่ 4 — ข้อสรุปที่ต้องอ่านช้า ๆ ตัวเลขกระโดดจาก 0.0000 เป็น 0.1482 โดยที่ **แบบจำลองไม่ได้เปลี่ยนแม้แต่พารามิเตอร์เดียว** สิ่งที่เปลี่ยนไปคือ “สนามสอบ” ที่ง่ายลง 50 เท่า จาก 5,000 ตัวเลือกเหลือ 100 ตัวเลือก

หัวข้อ 2.9 จะกลับมาเจาะประเด็นนี้อย่างละเอียด พร้อมแสดงว่าการสุ่มไม่ได้เปลี่ยนแค่ตัวเลข แต่เปลี่ยน “ผู้ชนะ” ได้ด้วย

2.15.3 เหตุผลที่สาม ลำดับตำแหน่งมีผลต่อพฤติกรรมของผู้ใช้

ในงานจำแนกภาพ ผลลัพธ์ไม่เปลี่ยนตามลำดับที่เราแสดงคำตอบ แต่ในระบบผู้แนะนำ ตำแหน่งของรายการมีผลโดยตรงต่อโอกาสที่ผู้ใช้จะเห็นและคลิก ปรากฏการณ์นี้เรียกว่า อคติตำแหน่ง (Position Bias)

นิยาม 2.11 อคติตำแหน่ง (Position Bias)

แนวโน้มที่ผู้ใช้จะมีปฏิสัมพันธ์กับรายการที่อยู่อันดับต้นมากกว่ารายการที่อยู่อันดับท้าย **แม้ว่ารายการทั้งสองจะมีความเกี่ยวข้องกับผู้ใช้เท่ากันทุกประการ** ทำให้ป้ายกำกับที่บันทึกได้สะท้อนทั้ง “ความชอบ” และ “ตำแหน่งที่ถูกแสดง” ปะปนกันจนแยกไม่ออก

ตัวอย่างการคำนวณ 2.20 ผลของอคติตำแหน่งต่อการเปรียบเทียบแบบจำลอง

สมมติว่ารายการ ก และรายการ ข มีความเกี่ยวข้องกับผู้ใช้เท่ากันพอดี และสมมติแบบจำลองความน่าจะเป็นของการถูกเห็นตามตำแหน่ง p ดังนี้

ตำแหน่ง	1	3	5	10	20
ความน่าจะเป็นที่ถูกเห็น	0.95	0.72	0.55	0.28	0.09
อัตราคลิกที่สังเกตได้ (เมื่อความชอบจริง = 0.40)	0.380	0.288	0.220	0.112	0.036

ขั้นที่ 1 — คำนวณอัตราคลิกที่ตำแหน่งที่ 1

$$0.95 \times 0.40 = 0.380$$

ขั้นที่ 2 — คำนวณอัตราคลิกที่ตำแหน่งที่ 20

$$0.09 \times 0.40 = 0.036$$

ขั้นที่ 3 — เปรียบเทียบ

$$0.380 \div 0.036 \approx 10.6 \text{ เท่า}$$

ขั้นที่ 4 — ตีความ รายการสองชิ้นที่ผู้ใช้ชอบเท่ากันพอดี กลับมีอัตราคลิกต่างกันสิบเท่าเพียงเพราะถูกวางไว้คนละตำแหน่ง หากเรานำอัตราคลิกนี้ไปเป็นป้ายกำกับสำหรับฝึกและประเมินแบบจำลองรุ่นถัดไปจะเรียนรู้ว่า “รายการที่เคยอยู่อันดับต้นคือของดี” ซึ่งเป็นการเรียนรู้ตำแหน่งมิใช่ความชอบ

แนวทางแก้ที่เป็นมาตรฐาน บันทึกตำแหน่งที่แสดงจริงไว้ในล็อกทุกครั้ง แล้วชดเชยด้วยการให้น้ำหนักส่วนกลับความน่าจะเป็นของการถูกเห็น ซึ่งเป็นแนวคิดเดียวกับการประเมินนอกนโยบายในหัวข้อ 2.12

2.15.4 เหตุผลที่สี่ ความสนใจเปลี่ยนตามเวลา

ในงานจำแนกภาพ ภาพแมวเมื่อสิบปีก่อนก็ยังเป็นภาพแมวในวันนี้ แต่ในระบบผู้แนะนำ ทั้งความนิยมของรายการและรสนิยมของผู้ใช้เปลี่ยนแปลงตลอดเวลา ข้อเท็จจริงนี้ทำให้เกิดกฎเหล็กข้อหนึ่ง คือ ห้ามใช้ข้อมูลอนาคตมาทำนายอดีต

การละเมิดกฎข้อนี้เกิดขึ้นได้ง่ายมาก และมักเกิดโดยที่ผู้เขียนโปรแกรมไม่รู้ตัว วิธีที่พบบ่อยที่สุดคือการแบ่งข้อมูลแบบสุ่ม ซึ่งทำให้ชุดฝึกมีเหตุการณ์ที่เกิดหลังเหตุการณ์ในชุดทดสอบ หัวข้อ 2.8 จะแสดงตัวเลขจริงว่าความผิดพลาดนี้ทำให้ตัวเลขที่รายงานสูงเกินจริงเท่าใด

2.15.5 เหตุผลที่ห้า ระบบเดิมเป็นผู้กำหนดว่าผู้ใช้เคยเห็นอะไร

ข้อนี้เป็นข้อที่ลึกที่สุดและแก้ยากที่สุด ในงานการเรียนรู้ของเครื่องทั่วไป ข้อมูลฝึกถูกเก็บมาจากโลกภายนอกโดยอิสระจากตัวแบบจำลอง แต่ในระบบผู้แนะนำ ข้อมูลที่จะใช้ฝึกแบบจำลองรุ่นถัดไปถูกสร้างขึ้นจากสิ่งที่แบบจำลองรุ่นก่อนเลือกแสดง

> **นิยาม 2.12 อคติจากการเปิดเผยรายการ (Exposure Bias)**
>
> ความเอนเอียงที่เกิดจากการที่ผู้ใช้มีโอกาสมีปฏิสัมพันธ์ได้เฉพาะกับรายการที่ระบบเลือกแสดงให้เห็นเท่านั้น ทำให้ข้อมูลที่เก็บได้ **ไม่ใช่ตัวอย่างสุ่มจากความชอบจริงของผู้ใช้** ในภาษาสถิติเรียกสภาวะนี้ว่าข้อมูลสูญหายแบบไม่สุ่ม (Missing-Not-At-Random หรือ MNAR)

ผลที่ตามมามีสามข้อที่ต้องเข้าใจให้ชัด

1. **รายการที่ระบบไม่เคยแสด จะไม่มีข้อมูลตลอดไป** เพราะไม่มีโอกาสถูกคลิก ระบบจึงยืนยันความเชื่อเดิมของตัวเองไปเรื่อย ๆ โดยไม่มีหลักฐานใดมาโต้แย้ง
2. **การประเมินออฟไลน์วัด “ความเหมือนระบบเดิม” มากกว่า “ความดี”** เพราะทำบนข้อมูลที่ระบบเดิมเป็นผู้เลือกไว้ให้ แบบจำลองที่เลียนแบบระบบเดิมได้แม่นที่สุด จึงมักได้คะแนนสูงสุด แม้จะไม่ได้ดีขึ้นสำหรับผู้ใช้เลย
3. **การแก้ต้องทำที่ระดับการเก็บข้อมูล ไม่ใช่ที่ระดับแบบจำลอง** แนวทางมาตรฐานคือบันทึกความน่าจะเป็นของการถูกแสดง (Propensity) ไว้ตั้งแต่ต้น และสงวนสัดส่วนการเข้าชมส่วนน้อยไว้สำหรับการสำรวจแบบสุ่ม เพื่อให้มีข้อมูลที่ปลอดจากอคติไว้ใช้ประเมิน

2.15.6 เหตุผลที่หก คะแนนออฟไลน์สูงไม่รับประกันความพึงพอใจหรือผลทางธุรกิจ

แม้จะทำถูกครบทั้งห้าข้อข้างต้นแล้ว ยังมีช่องว่างสุดท้ายที่ปิดไม่ได้ด้วยการคำนวณ นั่นคือตัวชี้วัดออฟไลน์วัดความสอดคล้องกับ “พฤติกรรมในอดีต” ส่วนสิ่งที่เราต้องการจริงคือ “ความพึงพอใจในอนาคต”

> **กรณีศึกษา 2.1 เมื่อคะแนนออฟไลน์ดีขึ้นแต่ผู้ใช้กลับไม่พอใจ**
>
> **สถานการณ์ที่พบบ่อยในระบบจริง** ทีมพัฒนาปรับแบบจำลองให้ nDCG@10 เพิ่มจาก 0.180 เป็น 0.205 คิดเป็นการปรับปรุงร้อยละ 13.9 ซึ่งถือว่ามากสำหรับสาขานี้ แต่เมื่อนำขึ้นทดลอง A/B กลับพบว่าเวลาที่ผู้ใช้ใช้กับบริการ ลดลง ร้อยละ 2.1
>
> **สาเหตุที่พบเมื่อสอบสวน**
>
> - แบบจำลองใหม่แนะนำสิ่งที่คล้ายกับสิ่งที่ผู้ใช้เพิ่งดูมากขึ้น ซึ่งตรงกับข้อมูลในอดีตจึงได้คะแนนออฟไลน์สูง
> - แต่ในการใช้งานจริง ผู้ใช้รู้สึกว่าคำแนะนำ “ซ้ำซาก” และไม่มีอะไรใหม่ให้ค้นพบ

- ค่าความหลากหลายภายในรายการ (ILD) ลดลงจาก 0.62 เหลือ 0.41 แต่ไม่มีใครวัดตัวเลขนี้ก่อนปล่อย

บทเรียน ตัวชี้วัดหลักที่ดีขึ้น ไม่ได้แปลว่าระบบดีขึ้น หากไม่ได้กำหนด **ตัวชี้วัดกำกับ (Guardrail Metrics)** ไว้ล่วงหน้าว่าอะไรบ้างที่ห้ามแย่ลง หัวข้อ 2.6 จะอธิบายวิธีกำหนดตัวชี้วัดกำกับอย่างเป็นระบบ

ประเด็นสำคัญ สรุปหัวข้อ 2.15

หลักการประเมินเป็นเรื่องสำคัญของงานปัญญาประดิษฐ์และการเรียนรู้ของเครื่องทุกประเภท แต่ในระบบผู้แนะนำ ผลลัพธ์ไวต่อเซตผู้สมัคร เวลา การเปิดเผยรายการ และพฤติกรรมผู้ใช้เป็นพิเศษ จึงต้องกำหนดโปรโตคอลให้ครบก่อนเริ่มเปรียบเทียบแบบจำลอง